

STT-2902 – Modélisation statistique

Recueil d'exercices

Statistiques descriptives et échantillonnage

Exercice

Une municipalité souhaite connaître le temps moyen de déplacement domicile-travail de ses **30 000 résidents actifs**. Le bureau du transport vous fournit le tableau suivant :

Identifiant	Nom, Prénom	Quartier	Mode de transport	Temps (min)
1	Tremblay, Xavier	Centre-ville	Vélo	12
2	Lavoie, Marie	Banlieue Nord	Auto	35
3	Gagnon, Pierre	Banlieue Sud	Autobus	48
...	...	...	...	...

Supposez qu'il y a 6 quartiers, chacun contenant 5 000 résidents. Chaque quartier a 5 secteurs de 1 000 résidents. Vous souhaitez interroger **300 résidents**.

- (a) (3 points) Expliquez précisément comment vous procéderiez pour utiliser un échantillonnage par grappes.
- (b) (5 points) Proposez une stratification et expliquez dans quelle situation elle serait avantageuse.
- (c) (4 points) On vous dit que la distribution de la variable Temps (min) est fortement asymétrique à droite. Devrait-on utiliser la médiane plutôt que la moyenne pour résumer cette variable ? **Expliquez.**
- (d) (3 points) De quel type est la variable Mode de transport ?
- (e) (3 points) Votre collègue propose de calculer la corrélation entre la variable Quartier et la variable Temps (min). Qu'en pensez-vous ?
- (f) (2 points) Est-il pertinent de calculer le coefficient de variation de la variable Temps (min) ?

Exercice

Soit les 15 valeurs suivantes représentant le nombre d'heures d'étude par semaine d'un groupe d'étudiants :

2	4	5	7	8
8	10	10	12	14
15	18	22	30	45

- (a) (3 points) Calculez les quartiles Q_1 , Q_2 (médiane) et Q_3 .
- (b) (3 points) Y a-t-il des valeurs aberrantes selon la règle de $1,5 \times \text{EIQ}$? **Justifiez.**
- (c) (2 points) Quelle est la forme de cette distribution ?
- (d) (2 points) Laquelle de la moyenne ou de la médiane sera la plus grande ?

Exercice

Dites si chacun des énoncés suivants est vrai ou faux. *Justifiez brièvement.*

- (a) (2 points) La corrélation de Spearman et la corrélation de Pearson donnent toujours le même résultat.
- (b) (2 points) Si $X_1, \dots, X_n$ sont mesurés en kg, alors la variance est en kg^2 et l'écart-type est en kg.
- (c) (2 points) Dans un échantillonnage probabiliste, tous les individus de la population doivent avoir la même probabilité d'être sélectionnés.
- (d) (2 points) Si je constate que les variables X et Y sont fortement corrélées, il est certain que X cause Y ou que Y cause X .
- (e) (4 points) L'utilisation d'un diagramme en secteurs est toujours appropriée pour représenter les fréquences relatives d'une variable qualitative nominale.

Exercice

Un propriétaire de vignoble mesure le rendement (en kg par hectare) de ses 20 parcelles. Voici un résumé des données :

$$\sum_{i=1}^{20} x_i = 160\,000 \quad \text{et} \quad \sum_{i=1}^{20} x_i^2 = 1\,312\,000\,000.$$

- (a) (2 points) Calculez la moyenne échantillonnale.
- (b) (3 points) Calculez la variance échantillonnale (S^2) et l'écart-type échantillonnal (S).

- (c) (2 points) Calculez le coefficient de variation.
- (d) (3 points) Le vignoble voisin a un rendement moyen de 7 500 kg/ha avec un écart-type de 1 500 kg/ha. Lequel des deux vignobles présente la plus grande variabilité relative ?

Exercice

On interroge 1 000 résidents d'une ville sur leur satisfaction envers les transports en commun. On obtient 600 réponses.

- (a) (3 points) Le taux de non-réponse est de 40%. La non-réponse induit-elle nécessairement un biais ? **Expliquez.**
- (b) (3 points) Parmi les répondants, on souhaite comparer la satisfaction entre les 6 quartiers de la ville. Quel outil graphique serait approprié ?
- (c) (3 points) Un collègue affirme que l'utilisation de la liste téléphonique comme base de sondage est problématique. Donnez deux raisons.

Exercice

Soit les données de concentration d'un polluant (en ppm) mesurées dans 12 échantillons d'eau :

3, 5, 6, 7, 7, 8, 9, 10, 12, 15, 22, 35.

- (a) (3 points) Calculez les quartiles et l'étendue interquartile.
- (b) (3 points) Identifiez les valeurs aberrantes selon la règle de $1,5 \times \text{EIQ}$.
- (c) (2 points) Quelle est la forme de cette distribution ?
- (d) (2 points) La loi normale modélise-t-elle bien ces données ? **Expliquez.**

Exercice

Une population de 10 000 employés est répartie dans 4 usines. L'usine A compte 4 000 employés, l'usine B en compte 3 000, l'usine C en compte 2 000 et l'usine D en compte 1 000. Vous devez interroger 200 employés.

- (a) (3 points) Proposez un échantillonnage stratifié proportionnel. Combien d'employés devez-vous sélectionner dans chaque usine ?
- (b) (3 points) Décrivez comment faire un échantillonnage systématique.
- (c) (3 points) Vous constatez que l'usine D a le plus grand taux d'absentéisme. Pouvez-vous conclure que travailler à l'usine D cause un taux d'absentéisme plus élevé ? **Expliquez.**

Exercice

Dites de quel type est chacune des variables suivantes.

- (a) (1 point) Le nombre d'enfants dans un ménage.
- (b) (1 point) La couleur des yeux.
- (c) (1 point) Le niveau de satisfaction (Très insatisfait, Insatisfait, Neutre, Satisfait, Très satisfait).
- (d) (1 point) La température en degrés Celsius.
- (e) (1 point) Le revenu annuel en dollars.
- (f) (2 points) Pour laquelle de ces variables est-il **inapproprié** de calculer le coefficient de variation ? **Expliquez.**

Exercice

On considère deux populations d'étudiants dont les notes à un examen sont :

- Population A : 55, 60, 65, 70, 75, 80, 85
- Population B : 40, 50, 60, 70, 80, 90, 100

- (a) (2 points) Calculez la médiane de chaque population.
- (b) (2 points) Sans calculer, quelle population a la plus grande variance ? **Expliquez.**
- (c) (3 points) Les deux populations ont la même médiane. Un étudiant affirme qu'elles ont donc la même distribution. A-t-il raison ? **Expliquez.**

Variables aléatoires

Exercice

Soit la variable aléatoire X dont la fonction de probabilité est donnée par :

x	0	3	5
$P(X=x)$	0,2	0,5	0,3

- (a) (3 points) Calculez $E(X)$.
- (b) (3 points) Calculez $V(X)$.
- (c) (3 points) Soit $Y = 2X - 4$. Calculez $E(Y)$ et $V(Y)$.

Exercice

Soit X et Y , deux variables aléatoires indépendantes avec $E(X) = 5$, $V(X) = 4$, $E(Y) = 2$ et $V(Y) = 9$.

- (a) (3 points) Calculez $E(3X + 2Y - 7)$.
 (b) (3 points) Calculez $V(3X + 2Y - 7)$.
 (c) (3 points) Calculez $V(X - Y)$.

Exercice

Soit les variables aléatoires X et Y dont la fonction de probabilité conjointe est donnée par :

$p(x,y)$		y		
		0	1	2
x	1	$\frac{2}{20}$	$\frac{3}{20}$	a
	3	$\frac{4}{20}$	b	$\frac{1}{20}$
	5	$\frac{1}{20}$	$\frac{2}{20}$	$\frac{3}{20}$

On sait que $P(X = 1) = \frac{7}{20}$ et $P(Y = 1) = \frac{6}{20}$.

- (a) (3 points) Que valent a et b ?
 (b) (4 points) Est-ce que X et Y sont indépendantes ? *Justifiez.*
 (c) (3 points) Calculez $P(Y = 2 | X = 3)$.

Exercice

Parmi les expressions suivantes, cochez celles qui sont des expressions valides de la variance pour une variable aléatoire X .

- ☐ $V(X) = E[(X - \mu)^2]$
☐ $V(X) = E(X^2) - [E(X)]^2$
☐ $V(X) = E(X) - E(X)^2$
☐ $V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dx$
☐ $V(X) = \sum_{\mathbb{R}_X} (x - \mu)^2$

Exercice

Soit la variable aléatoire X avec la fonction de probabilité suivante :

x	-2	0	1	4
$P(X = x)$	0,1	0,3	0,4	0,2

- (a) (2 points) Calculez $E(X)$.
 (b) (3 points) Calculez $E(X^2)$ et $V(X)$.
 (c) (3 points) Calculez $E(3X^2 - 2X + 5)$.

Exercice

Soit X_1, X_2, X_3 trois variables aléatoires indépendantes et identiquement distribuées avec $E(X_i) = 10$ et $V(X_i) = 6$.

- (a) (3 points) Calculez $E(\bar{X})$ et $V(\bar{X})$.
 (b) (3 points) Calculez $V(X_1 - X_2 + 2X_3)$.

Exercice

Soit X une variable aléatoire dont la fonction de probabilité est :

x	1	2	3
$P(X = x)$	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{3}{6}$

- (a) (2 points) Calculez $E(X)$.
 (b) (3 points) Calculez $V(X)$.
 (c) (3 points) L'espérance de X est-elle un résultat possible de X ? Est-ce problématique ?

Exercice

Soit X et Y deux variables aléatoires. On sait que $E(X) = 3$, $E(Y) = 7$, $V(X) = 2$, $V(Y) = 5$ et $\text{Cov}(X, Y) = -1$.

- (a) (3 points) Calculez $V(X + Y)$.
 (b) (3 points) Calculez $V(2X - 3Y + 1)$.
 (c) (2 points) X et Y sont-ils indépendants ? *Justifiez.*

Exercice

Soit (X, Y) un couple de variables aléatoires dont la fonction de probabilité conjointe est :

$p(x,y)$		y	
		0	1
x	0	$1/4$	$1/4$
	1	$1/4$	$1/4$

- (a) (2 points) Calculez les lois marginales de X et de Y .
 (b) (3 points) X et Y sont-elles indépendantes ? **Justifiez.**
 (c) (2 points) Calculez $\text{Cov}(X,Y)$.

Exercice

L'espérance d'une variable aléatoire est invariante par translation, mais sa variance n'est pas invariante par translation.

☐ Vrai ☐ Faux

Intervalles de confiance

Exercice

Dites si chacun des énoncés suivants est vrai ou faux.

- (a) (3 points) L'intervalle de confiance pour la variance n'est pas symétrique autour de S^2 .
☐ Vrai ☐ Faux
 (b) (3 points) L'intervalle de confiance pour μ est symétrique autour de μ .
☐ Vrai ☐ Faux
 (c) (3 points) Si un intervalle de confiance à 95% pour μ est $[12,34; 17,10]$, alors $\bar{x} = 14,72$.
☐ Vrai ☐ Faux
 (d) (3 points) Plus un intervalle de confiance est large, plus il est précis.
☐ Vrai ☐ Faux
 (e) (3 points) Toutes choses étant égales par ailleurs, un intervalle de confiance construit avec la variance connue (et $\sigma^2 = s^2$) est plus court qu'un intervalle construit avec la variance inconnue.
☐ Vrai ☐ Faux

Exercice

Soit un échantillon de taille $n = 16$ provenant d'une variable aléatoire normale d'espérance μ et de variance $\sigma^2 = 4$. La moyenne échantillonnale est $\bar{x} = 25$.

- (a) (5 points) Construisez un intervalle de confiance de niveau 95% pour μ .
 (b) (3 points) Comment l'intervalle changerait-il si σ^2 était inconnue mais que $s^2 = 4$?

Exercice

Sachant que $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ et $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$, montrez que l'intervalle de confiance de niveau $1 - \alpha$ pour σ^2 est

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2}; \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2} \right].$$

Exercice

Soit un échantillon de taille $n = 25$ provenant d'une loi normale avec $\bar{x} = 50$ et $s^2 = 16$.

- (a) (4 points) Construisez un intervalle de confiance de niveau 90% pour μ .
 (b) (4 points) Construisez un intervalle de confiance de niveau 95% pour σ^2 .
 (c) (3 points) L'intervalle pour σ^2 est-il symétrique autour de $s^2 = 16$? **Expliquez.**

Exercice

On veut estimer la proportion p d'étudiants favorables à un changement d'horaire. Sur 400 étudiants interrogés, 240 sont favorables.

- (a) (3 points) Calculez un intervalle de confiance de niveau 95% pour p .
 (b) (3 points) Peut-on affirmer au seuil de 5% que la majorité des étudiants sont favorables ?
 (c) (3 points) Quelle taille d'échantillon faudrait-il pour que la marge d'erreur soit au plus de 2% avec un niveau de confiance de 95% ?

Exercice

On souhaite construire un IC de niveau 99% pour la moyenne μ avec un échantillon de taille $n = 10$ provenant d'une loi normale.

- (a) (3 points) Si σ^2 est connue, quelle loi utilise-t-on pour le quantile ?
- (b) (3 points) Si σ^2 est inconnue, quelle loi utilise-t-on ?
- (c) (3 points) L'intervalle avec σ^2 inconnue est-il plus long ou plus court ? Pourquoi ?

Exercice

Cochez le ou les énoncés qui sont vrais.

- ☐ La probabilité que μ soit dans l'intervalle de confiance est $1 - \alpha$.
- ☐ Avant d'observer les données, la probabilité que l'intervalle aléatoire $[L; U]$ contienne μ est $1 - \alpha$.
- ☐ Augmenter α augmente la longueur de l'intervalle.
- ☐ Augmenter n diminue la longueur de l'intervalle (toutes choses étant égales par ailleurs).
- ☐ Un IC de 99% est plus précis qu'un IC de 95%.

Exercice

Un échantillon de $n = 36$ pièces usinées a un diamètre moyen de $\bar{x} = 5,02$ mm et un écart-type $s = 0,10$ mm. La spécification est $\mu_0 = 5,00$ mm.

- (a) (4 points) Construisez un intervalle de confiance de niveau 95% pour μ .
- (b) (3 points) La valeur $\mu_0 = 5,00$ fait-elle partie de l'IC ? Qu'est-ce que cela implique pour un test $H_0 : \mu = 5$ contre $H_1 : \mu \neq 5$ au seuil de 5% ?

Exercice

Expliquez pourquoi augmenter le niveau de confiance de 95% à 99% n'est pas toujours souhaitable.

Tests d'hypothèses

Exercice

Cochez l'énoncé qui décrit correctement chaque type d'erreur.

- (a) (3 points) L'erreur de type I est :

- ☐ La probabilité de ne pas rejeter H_0 alors que H_0 est fausse.
- ☐ La probabilité de rejeter H_0 alors que H_0 est vraie.
- ☐ La décision de rejeter H_0 alors que H_0 est vraie.
- ☐ La décision de ne pas rejeter H_0 alors que H_0 est fausse.

- (b) (3 points) L'erreur de type II est :

- ☐ La probabilité de ne pas rejeter H_0 alors que H_0 est fausse.
- ☐ La probabilité de rejeter H_0 alors que H_0 est vraie.
- ☐ La décision de rejeter H_0 alors que H_0 est vraie.
- ☐ La décision de ne pas rejeter H_0 alors que H_0 est fausse.

Exercice

Vous faites un test sur 25 observations pour confronter les hypothèses $H_0 : \mu = 10$ et $H_1 : \mu > 10$. Vous obtenez un seuil observé (valeur-p) de 0,03.

- (a) (3 points) Quelle est la décision du test au seuil de 5% ?
- (b) (3 points) Quelle est la décision du test au seuil de 1% ?
- (c) (3 points) La moyenne échantillonnale est-elle supérieure ou inférieure à 10 ?
- (d) (3 points) Vous refaites l'expérience avec 50 observations et obtenez la même moyenne échantillonnale. Le seuil observé sera-t-il plus petit ou plus grand que 0,03 ?

Exercice

Cochez l'énoncé qui est vrai.

- ☐ Si $\hat{\theta}$ est un estimateur sans biais pour θ , la valeur calculée de $\hat{\theta}$ à partir d'un échantillon sera toujours très proche de θ .
- ☐ Toutes choses étant égales par ailleurs, pour passer d'un IC de 95% à un IC de 99%, il suffit d'augmenter n .
- ☐ L'erreur quadratique moyenne d'un estimateur sans biais est égale à sa variance au carré.
- ☐ Dans un test au seuil α , quand H_0 est vraie, la probabilité de ne pas commettre d'erreur est $1 - \alpha$.

Exercice

Soit un échantillon provenant d'une variable aléatoire normale d'espérance μ et de variance $\sigma^2 = 1,44$:

4, 5, 5, 6, 6, 6, 7, 7, 8,

pour lequel $\sum_{i=1}^9 x_i = 54$ et $\sum_{i=1}^9 x_i^2 = 336$.

- (a) On souhaite faire un test d'hypothèses unilatéral à droite de seuil 5% avec $H_0 : \mu = 5,5$.
 - i. (2 points) Quelle est l'hypothèse alternative ?
 - ii. (3 points) Quelle est la valeur critique du test ?
 - iii. (5 points) Calculez la statistique de test et prenez une décision.
- (b) (5 points) Construisez un intervalle de confiance de niveau 95% pour μ .

Exercice

La loi de Student de $n - 1$ degrés de liberté a une espérance égale à 0.

☐ Vrai ☐ Faux

Exercice

Soit $X \sim \text{Bin}(n; \theta)$. On teste $H_0 : \theta = 0,5$ contre $H_1 : \theta > 0,5$. La règle de décision est de rejeter H_0 si $X = n$ (c'est-à-dire aucun échec). Trouvez la plus petite valeur de n telle que $\alpha \leq 0,05$.

Exercice

Vous testez $H_0 : \mu = 100$ contre $H_1 : \mu \neq 100$ au seuil de 5% avec un échantillon de taille $n = 20$ provenant d'une loi normale de variance inconnue. Vous obtenez $\bar{x} = 103$ et $s = 6$.

- (a) (3 points) Calculez la statistique de test.
- (b) (3 points) Quelle est la décision du test ?
- (c) (3 points) La valeur-p est-elle inférieure ou supérieure à 5% ?

Exercice

On teste $H_0 : \mu = 50$ contre $H_1 : \mu < 50$ avec $n = 15$, $\bar{x} = 47$, $s = 5$ et σ^2 inconnue.

- (a) (2 points) Quelle est la statistique de test ?
- (b) (3 points) Prenez votre décision au seuil de 5%.
- (c) (3 points) L'intervalle de confiance de niveau 90% pour μ contient-il la valeur 50 ? **Expliquez.**

Exercice

Dites si chacun des énoncés suivants est vrai ou faux. Justifiez brièvement.

- (a) (3 points) Si la valeur-p est de 0,001, cela signifie qu'il y a 0,1% de chances que H_0 soit vraie.

☐ Vrai ☐ Faux

- (b) (3 points) Si on ne rejette pas H_0 , cela signifie que H_0 est vraie.

☐ Vrai ☐ Faux

- (c) (3 points) Augmenter la taille d'échantillon n diminue la probabilité de commettre une erreur de type II.

☐ Vrai ☐ Faux

Exercice

Vous faites un test avec $n = 50$ observations. La valeur-p est de 0,046.

- (a) (2 points) Votre décision au seuil de 5% : _____
- (b) (2 points) Votre décision au seuil de 1% : _____
- (c) (2 points) Votre décision au seuil de 10% : _____
- (d) (3 points) Un collègue obtient une valeur-p de 0,046 et dit que son résultat est «très significatif». Commentez.

Régression linéaire simple

Exercice

Dans un modèle de régression linéaire simple $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$:

- (a) (3 points) Si $\beta_0 = 0$, quel est l'interprétation de β_1 ?
- (b) (3 points) Pour faire de l'inférence sur β_1 , quelles hypothèses doit-on supposer ?

- ☐ Les Y_i sont des variables aléatoires normales indépendantes d'espérance nulle et de variance constante.
- ☐ Les ϵ_i sont des variables aléatoires normales indépendantes d'espérance nulle et de variance constante.
- ☐ X doit suivre une loi normale.

☐ Toutes les valeurs de X doivent être distinctes.

Exercice

D'au moins combien de paires d'observations avons-nous besoin pour pouvoir utiliser chacune des méthodes suivantes ?

(a) (1 point) Méthode de Mayer

☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

(b) (1 point) Méthode Med-Med


☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

(c) (1 point) Méthode des moindres carrés (estimation et inférence incluses)

☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

Exercice

Soit le graphique suivant qui représente les observations $(x_1, y_1), \dots, (x_8, y_8)$.



(a) (3 points) Estimez la droite de régression avec la méthode de Mayer.

(b) (3 points) Estimez la droite de régression avec la méthode Med-Med.

(c) (5 points) En utilisant les informations suivantes, estimez la droite par les moindres carrés :

$$\sum_{i=1}^8 x_i = 36$$

$$\sum_{i=1}^8 x_i^2 = 204$$

$$\sum_{i=1}^8 y_i = 36$$

$$\sum_{i=1}^8 x_i y_i = 199$$

(d) (4 points) En utilisant la droite estimée en c), complétez le tableau suivant.

x_i	y_i	$\hat{y}_i$	$\hat{\epsilon}_i$
1	1		
2	3		
3	2		
4	4		
5	5		
6	6		
7	7		
8	8		

- (e) (4 points) Calculez MSE .
- (f) (4 points) Donnez l'intervalle de confiance à 95% pour β_1 .
- (g) (3 points) Donnez une interprétation de l'intervalle de confiance.

Exercice

Soit l'intervalle de confiance de niveau 95% pour $\beta_1 : [1,3; 4,7]$.

- (a) (1 point) $\hat{\beta}_1 = 3,0$.
☐ Vrai ☐ Faux
- (b) (1 point) On rejette $H_0 : \beta_1 = 0$ au profit de $H_1 : \beta_1 \neq 0$ au seuil de 5%.
☐ Vrai ☐ Faux
- (c) (1 point) On rejette $H_0 : \beta_1 = 0$ au profit de $H_1 : \beta_1 \neq 0$ au seuil de 10%.
☐ Vrai ☐ Faux
- (d) (1 point) On rejette $H_0 : \beta_1 = 2$ au profit de $H_1 : \beta_1 \neq 2$ au seuil de 5%.
☐ Vrai ☐ Faux

Exercice

On ajuste un modèle de régression linéaire simple à $n = 12$ observations et on obtient $\hat{\beta}_0 = 2,5$, $\hat{\beta}_1 = 1,8$ et $MSE = 3,6$.

- (a) (3 points) Donnez la valeur prédite $\hat{y}$ lorsque $x = 5$.
- (b) (3 points) Calculez le résidu si l'observation correspondante est $y = 13$.
- (c) (3 points) Que vaut SSE (somme des carrés des résidus) ?
- (d) (3 points) Interprétez la valeur $\hat{\beta}_1 = 1,8$ dans le contexte de la régression.

Exercice

On dispose de $n = 20$ paires d'observations. Le coefficient de détermination est $R^2 = 0,85$.

- (a) (3 points) Interprétez $R^2 = 0,85$.
- (b) (3 points) Quelle est la valeur de la corrélation linéaire r si la pente $\hat{\beta}_1$ est positive ?
- (c) (3 points) Si $SST = 200$, que vaut SSE ?

Exercice

On ajuste un modèle de régression linéaire simple avec $n = 15$ observations. On obtient $\hat{\beta}_1 = 0,75$, $S_{xx} = 40$ et $MSE = 2,5$.

- (a) (4 points) Calculez l'erreur-type de $\hat{\beta}_1$.
- (b) (4 points) Testez $H_0 : \beta_1 = 0$ contre $H_1 : \beta_1 \neq 0$ au seuil de 5%.
- (c) (3 points) Construisez un IC à 95% pour β_1 .

Exercice

Dites si chacun des énoncés suivants est vrai ou faux.

- (a) (2 points) $\hat{\beta}_0$ représente toujours la valeur de Y quand $X = 0$.
☐ Vrai ☐ Faux
- (b) (2 points) La somme des résidus dans une régression par moindres carrés est toujours nulle.
☐ Vrai ☐ Faux
- (c) (2 points) Si R^2 est proche de 1, cela prouve que la relation entre X et Y est causale.
☐ Vrai ☐ Faux
- (d) (2 points) La méthode de Mayer est plus robuste aux valeurs aberrantes que les moindres carrés.
☐ Vrai ☐ Faux
- (e) (2 points) Pour la méthode des moindres carrés, on minimise $\sum_{i=1}^n |\hat{\epsilon}_i|$.
☐ Vrai ☐ Faux

Exercice

Avec $n = 30$, on effectue un test pour confronter $H_0 : \beta_1 = 0$ et $H_1 : \beta_1 \neq 0$.

- (a) (2 points) Sous H_0 , quelle loi suit la statistique de test ?
- (b) (3 points) On obtient $t_{obs} = 2,8$. La valeur critique au seuil de 5% est $t_{0,025;28} = 2,048$. Quelle est la décision ?
- (c) (3 points) Le même test est-il significatif au seuil de 1% ? ($t_{0,005;28} = 2,763$)

Association entre variables catégoriques

Exercice

La statistique du khi-carré pour tester l'indépendance compare :

- ☐ Les lois marginales entre elles
- ☐ Les fréquences observées aux fréquences attendues
- ☐ Les moyennes conditionnelles
- ☐ La variance de Y pour chaque valeur de X

Exercice

Un chercheur veut savoir si le choix de boisson chaude est associé à la saison. Il obtient le tableau suivant auprès de 200 personnes :

[innerwidth=3cm]BoissonSaison	Hiver	Été	Automne
Café	40	30	25
Thé	20	35	15
Chocolat chaud	25	5	5

- (a) (4 points) Calculez les fréquences attendues sous l'hypothèse d'indépendance.
(b) (5 points) Effectuez le test d'indépendance au seuil de 5%.

Exercice

Un hôpital examine si le groupe sanguin (A, B, AB, O) est associé à la présence d'une certaine complication post-opératoire (Oui/Non). On observe 200 patients :

[innerwidth=2.5cm]GroupeComplic.	Oui	Non
A	15	55
B	10	30
AB	5	15
O	20	50

- (a) (3 points) Combien de degrés de liberté a le test du khi-carré pour ce problème ?
(b) (4 points) Calculez les fréquences attendues pour la première ligne (groupe A).
(c) (3 points) Quelles sont les hypothèses du test ?

Exercice

On observe 300 individus et on s'intéresse à la relation entre le statut tabagique (Fumeur, Non-fumeur) et la pratique d'activité physique (Active, Inactive).

[innerwidth=2.5cm]TabacSport	Active	Inactive
Fumeur	30	70
Non-fumeur	120	80

- (a) (4 points) Calculez les fréquences attendues sous H_0 d'indépendance.
(b) (5 points) Effectuez le test du χ^2 au seuil de 5%.

Exercice

Pour un test d'indépendance du khi-carré, dites si les énoncés suivants sont vrais ou faux.

- (a) (2 points) Le test du χ^2 mesure la force de l'association entre deux variables.

☐ Vrai ☐ Faux

(b) (2 points) Les fréquences attendues doivent toutes être supérieures à 5 pour que le test soit valide.

☐ Vrai ☐ Faux

(c) (2 points) H_0 dans le test du χ^2 d'indépendance est que les proportions marginales sont égales.

☐ Vrai ☐ Faux

(d) (2 points) Le test du χ^2 ne peut pas être unilatéral.

☐ Vrai ☐ Faux

Exercice

On étudie la relation entre le type de logement (Appartement, Maison, Condo) et la possession d'un animal (Oui, Non) chez 150 personnes. On obtient $\chi_{obs}^2 = 3,2$.

(a) (2 points) Combien de degrés de liberté a le test ?

(b) (3 points) Prenez une décision au seuil de 5% sachant que $\chi_{0,05;2}^2 = 5,991$.

Exercice

On observe le tableau de contingence suivant chez $n = 120$ étudiants :

Niveau	Moyen	Bus	Vélo	Auto
Bacc.		20	15	25
Maîtrise		12	18	10
Doctorat		8	7	5

(a) (4 points) Calculez toutes les fréquences attendues.

(b) (5 points) Calculez χ_{obs}^2 et prenez une décision au seuil de 5%.

Exercice

On vous donne la formule de la statistique du khi-carré :

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

(a) (2 points) Que représentent O_{ij} et E_{ij} ?

(b) (2 points) Que se passe-t-il si $O_{ij} = E_{ij}$ pour toutes les cellules ?

(c) (3 points) Comment calcule-t-on E_{ij} ?

Exercice

On observe 400 personnes à qui on demande leur couleur préférée (Rouge, Bleu, Vert) et leur saison préférée (Hiver, Été). On obtient $\chi_{obs}^2 = 12,4$.

(a) (2 points) Quels sont les degrés de liberté ?

(b) (3 points) Prenez une décision au seuil de 1% sachant que $\chi_{0,01;2}^2 = 9,210$.

(c) (3 points) La valeur-p est-elle inférieure à 5% ? à 1% ?

Exercices supplémentaires

Exercice

Soit $X_1, \dots, X_m$ des variables aléatoires iid d'une loi Bernoulli de paramètre p , c'est-à-dire $P(X_i = 1) = p$ et $P(X_i = 0) = 1 - p$. On sait que $E(X_i) = p$ et $V(X_i) = p(1 - p)$. L'estimateur naturel de p est $\hat{p} = \bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$.

(a) (3 points) Montrez que $\hat{p}$ est un estimateur sans biais pour p .

(b) (4 points) Calculez la variance de $\hat{p}$.

(c) (4 points) Quelle est la longueur maximale de la marge d'erreur d'un intervalle de confiance à 95% pour p lorsque $m = 100$?

Exercice

Soit deux échantillons indépendants $X_1, \dots, X_n \sim \mathcal{N}(\mu_X, \sigma_X^2)$ et $Y_1, \dots, Y_m \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$. On sait que

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n-1; m-1}.$$

Donnez un intervalle de confiance de niveau $1 - \alpha$ pour le ratio $\frac{\sigma_Y^2}{\sigma_X^2}$.

Exercice

Soit $X_1, \dots, X_n$ un échantillon aléatoire simple d'une loi de moyenne μ et de variance σ^2 . On considère l'estimateur $\hat{\mu} = \alpha X_1 + (1 - \alpha)\bar{X}$ où $\alpha \in [0, 1]$ est une constante et $\bar{X}$ est la moyenne échantillonnale.

- (a) (3 points) Montrez que $\hat{\mu}$ est un estimateur sans biais pour μ .
- (b) (4 points) Calculez $V(\hat{\mu})$ en supposant que $n \geq 2$.
- (c) (3 points) Pour quelle valeur de α la variance est-elle minimale? Interprétez.

Exercice

L'erreur quadratique moyenne (EQM) d'un estimateur $\hat{\theta}$ pour θ est définie par $\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$.

- (a) (3 points) Montrez que $\text{EQM}(\hat{\theta}) = V(\hat{\theta}) + [\text{biais}(\hat{\theta})]^2$.
- (b) (4 points) Soit $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$. On considère l'estimateur $\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$. On sait que $E(\tilde{\sigma}^2) = \frac{n-1}{n} \sigma^2$ et $V(\tilde{\sigma}^2) = \frac{2(n-1)}{n^2} \sigma^4$. Calculez l'EQM de $\tilde{\sigma}^2$.
- (c) (3 points) Comparez avec l'estimateur sans biais $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ dont on sait que $V(S^2) = \frac{2\sigma^4}{n-1}$. Lequel a la plus petite EQM?

Exercice

Soit $X \sim \mathcal{N}(100, 25)$. Un échantillon de taille $n = 50$ est prélevé.

- (a) (3 points) En utilisant le théorème central limite, donnez la distribution approximative de $\bar{X}$.
- (b) (4 points) Calculez $P(\bar{X} > 101)$.
- (c) (3 points) On observe $\bar{x} = 101,2$ et $s = 5,3$. Construisez un intervalle de confiance à 95% pour μ .

Exercice

Un sondage est effectué auprès de $n = 600$ personnes pour connaître la proportion p de gens favorables à une nouvelle politique. On obtient $\hat{p} = 0,52$.

- (a) (3 points) Construisez un intervalle de confiance à 95% pour p .
- (b) (4 points) Peut-on conclure que plus de la moitié de la population est favorable? Effectuez un test au seuil $\alpha = 0,05$.
- (c) (3 points) Quelle taille d'échantillon minimale faudrait-il pour que la marge d'erreur soit au plus de 2% à 95% de confiance?

Exercice

Un chercheur mesure la résistance Y (en MPa) d'un matériau en fonction de la température X (en °C). À partir de $n = 15$ observations, il obtient :

$$\sum x_i = 750, \quad \sum y_i = 300, \quad \sum x_i^2 = 42\,500, \quad \sum x_i y_i = 13\,500, \quad \sum y_i^2 = 6\,500.$$

- (a) (3 points) Calculez $\bar{x}$, $\bar{y}$, S_{xx} , S_{xy} et S_{yy} .
- (b) (3 points) Estimez $\hat{\beta}_1$ et $\hat{\beta}_0$. Interprétez $\hat{\beta}_1$.
- (c) (3 points) Calculez R^2 et interprétez.
- (d) (4 points) Testez $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$ au seuil $\alpha = 0,05$.

Exercice

Vrai ou faux. Justifiez chaque réponse.

- (a) (2 points) Si un estimateur $\hat{\theta}$ est sans biais et consistant, alors son EQM tend vers 0 lorsque $n \rightarrow \infty$.
- (b) (2 points) La distribution de Student converge vers la loi normale lorsque $n \rightarrow \infty$.
- (c) (2 points) Si le coefficient de détermination R^2 est élevé, cela prouve un lien de causalité entre X et Y .
- (d) (2 points) Le théorème central limite s'applique uniquement lorsque la population suit une loi normale.
- (e) (2 points) Dans un test bilatéral, la valeur-p est toujours le double de la valeur-p du test unilatéral correspondant.

Exercice

On effectue un contrôle de qualité dans une usine. En temps normal, le poids des pièces suit une loi $\mathcal{N}(500, 16)$ (en grammes). On prélève un échantillon de $n = 25$ pièces et on obtient $\bar{x} = 497,5$ et $s^2 = 20$.

- (a) (3 points) Testez si le poids moyen a changé au seuil $\alpha = 0,05$.
- (b) (3 points) Construisez un IC à 95% pour μ en utilisant $\sigma^2 = 16$.
- (c) (4 points) Testez si la variance a augmenté au seuil $\alpha = 0,05$ en utilisant la loi khi-deux.

Exercice

Soit X et Y deux variables aléatoires discrètes avec la distribution conjointe suivante :

$X \backslash Y$	0	1	2	Total
0	0,10	0,15	0,05	0,30
1	0,20	a	0,10	
2	0,05	0,10	b	
Total				1

- (a) (3 points) Trouvez les valeurs de a et b .
- (b) (4 points) Avec $a = 0,15$ et $b = 0,10$, calculez $E(X)$, $E(Y)$ et $\text{Cov}(X, Y)$.
- (c) (3 points) X et Y sont-elles indépendantes ?