


STT-1900 – Méthodes statistiques pour l'ingénierie

Recueil d'exercices

Module 1 - Introduction aux probabilités

Exercice

(A23) Considérons le montage électronique représenté ci-dessous.



Le bloc A contient trois éléments. Nous avons que

- L'élément A1 fonctionne avec une probabilité de 0,60.
- L'élément A2 fonctionne avec une probabilité de 0,50.
- L'élément A3 fonctionne avec une probabilité de 0,60.

Pour que le montage fonctionne, au moins un élément du bloc A doit fonctionner. Les éléments d'un bloc fonctionnent de façon indépendante.

Quelle est la probabilité que le montage ne fonctionne pas ?

☐ 0,08 ☐ 0,92 ☐ 0,18 ☐ 0,82 ☐ 0,63

Exercice

(A23) Soit A , B et C trois événements avec $P(A) = 0,5$, $P(B) = 0,5$, $P(C) = 0,2$, $P(A \cap B) = 0,25$. Nous avons aussi que C est indépendant de l'événement A et de l'événement B . Dites si chacun des énoncés ci-dessous est vrai ou faux. Votre réponse doit être justifiée en mots ou par des calculs. Un vrai ou faux sans justification n'aura aucun point.

(a) Les événements A et B sont indépendants.

☐ VRAI ☐ FAUX

Justification :

(b) $P(A \cup C) = 0,6$.

☐ VRAI ☐ FAUX

Justification :

(c) Les événements A et B forment une partition de l'espace échantillonnal.

☐ VRAI ☐ FAUX

Justification :

Exercice

(A23) La lune suscite un grand intérêt pour les pêcheurs car la qualité de la pêche dépend directement des différentes phases lunaires. Un pêcheur a remarqué les faits suivants pour chaque période d'une heure de pêche :

- Lorsque la lune est croissante, la probabilité de pêcher au moins un poisson est de cinq sur sept ;
- Lorsque la lune est décroissante, la probabilité de ne pêcher aucun poisson est de deux sur cinq.

La lune est considérée la moitié du temps comme croissante, et l'autre moitié comme décroissante.

- (a) Quelle est la probabilité qu'en pêchant une heure, le pêcheur pêche au moins un poisson ?
- (b) Si le pêcheur ne pêche aucun poisson après une heure de pêche, quelle est la probabilité que la lune soit croissante ?
- (c) Si, en période de lune croissante, il pêche trois heures de suite, quelle est la probabilité qu'il ne pêche aucun poisson ?
- (d) Si, en période de lune décroissante, il pêche aussi trois heures de suite, quelle est la probabilité qu'il pêche au moins un poisson ?

Exercice

(H24) On nous donne les probabilités suivantes :

$$\begin{aligned}P(A) &= 0,45 \\P(B) &= 0,25 \\P(C) &= 0,30 \\P(C|A) &= 0,30 \\P(C|B) &= 0,30 \\P(A \cap B) &= 0,05\end{aligned}$$

(a) Cochez tous les énoncés qui sont **vrais**.

- ☐ La probabilité de l'événement complémentaire de A, $P(\bar{A}) = 0,55$
- ☐ $P(A \cup B) = 0,70$
- ☐ $P(A \cap \bar{B}) = 0,40$
- ☐ $P(A \cap C) = 0,1575$
- ☐ $P(A \cup C) = 0,75$

(b) A et B sont indépendants.

☐ VRAI ☐ FAUX

Justification :

Exercice

(H24) Dans une usine, deux machines, A et B, produisent des composants. La machine A produit 45% des composants et la machine B produit le reste. 15% des composants produits par A sont défectueux, tandis que 10% des composants produits par B sont défectueux. Si un composant est défectueux, quelle est la probabilité qu'il ait été produit par la machine A ?

Exercice

(A24) On nous donne les probabilités suivantes :

$$\begin{aligned}P(A) &= 0,45 \\P(B) &= 0,55 \\P(C) &= 0,1 \\P(A \cap C) &= 0 \\P(B \cap C) &= 0 \\P(A|B) &= 0,45\end{aligned}$$

(a) Cochez tous les énoncés qui sont **vrais**. *Chaque énoncé qui est coché alors qu'il ne devrait pas l'être annule les points d'un élément coché qui devrait l'être.*

- ☐ La probabilité du complément de A est égale à 0,55.
- ☐ $P(A \cup B) = 1$.
- ☐ A, B et C sont mutuellement exclusifs.
- ☐ A et C sont indépendants.
- ☐ Comme $P(A) + P(B) = 1$, l'intersection de A et B est vide, c'est-à-dire $A \cap B = \emptyset$.
- ☐ Il y a certainement une erreur dans les probabilités données, car $P(A) + P(B) + P(C) > 1$.

(b) A et B sont indépendants.

☐ VRAI ☐ FAUX

Justification :

Exercice

(A24)

Un sac contient 40 billes rouges, 40 billes vertes et 20 billes bleues. Sur certaines de ces billes, une étoile a été dessinée. Nous savons que la probabilité de choisir une bille sans étoile parmi les billes rouges est de 0,875, la probabilité de choisir une bille qui est verte et qui a une étoile est de 0,1 et la probabilité de choisir une bille qui a une étoile parmi les billes bleue est de 0,5.

En utilisant les événements suivants :

- R : la bille est rouge
- V : la bille est verte
- B : la bille est bleue
- E : une étoile est dessinée sur la bille

- (a) Tracez le diagramme de Venn qui représente cette situation. Vous n'avez qu'à identifier les événements et **l'espace échantillonnal**. Il n'est pas nécessaire d'inscrire les probabilités.
- (b) Si vous avez pigé une bille avec une étoile, quelle est la probabilité que celle-ci soit bleue ?

Module 2 - Variables aléatoires à une dimension

Exercice

(A23) Laquelle des fonctions suivantes est une fonction de densité ?

☐ $f(a) = a$, pour $0 < a$

☐ $f(b) = \begin{cases} 0 & \text{si } b < 0, \\ b & \text{si } 0 \leq b < 2, \\ 0 & \text{si } 2 \leq b \end{cases}$

☐ $f(c) = \begin{cases} \sqrt{c} & \text{si } 0 \leq c \leq 1, \\ 0 & \text{sinon} \end{cases}$

☐ $f(d) = \begin{cases} 0 & \text{si } d < 0, \\ d & \text{si } 0 \leq d \leq 1, \\ 1 & \text{si } 1 < d \end{cases}$

Exercice

(A23) Soit la fonction f définie sur $\mathbb{R}$ par

$$f(x) = \begin{cases} ce^x, & \text{si } x < 0, \\ 0, & \text{sinon,} \end{cases}$$

où $c \in \mathbb{R}$ est une constante donnée.

- (a) Quelle doit être la valeur de la constante c pour que f soit une densité de probabilité d'une certaine variable aléatoire X ?
- (b) Déterminer la fonction de répartition de X . Si vous n'avez pas trouvé « c » à la question (a), vous pouvez exprimer la répartition avec « c ».
- (c) Calculer l'espérance de X . Si vous n'avez pas trouvé « c » à la question (a), vous pouvez exprimer l'espérance avec « c ».

Exercice

(H24) X est une variable aléatoire continue dont la densité est donnée par :

$$f(x) = \begin{cases} \frac{6}{5}(1 - 2x^2) & \text{si } -0.5 < x < 0.5 \\ 0 & \text{sinon.} \end{cases}$$

- (a) Cochez tous les énoncés qui sont **vrais**.

☐ $F(x) = \frac{6}{5}(x - \frac{2}{3}x^3 + \frac{5}{12})$

☐ $E(3X + 20) = 3E(X)$

☐ $V(2X) = 2V(X)$

☐ $V(X + 10) > V(X)$

- (b) $V(X) = E(X^2) - 2E(X)^2$.

☐ VRAI ☐ FAUX

Justification :

- (c) Calculez $P(X < 0 \mid X > -0.25)$:

Exercice

(A24) En analyse de survie, nous définissons la fonction de survie $S(x)$ comme étant la probabilité de survivre plus de x unités de temps, c'est-à-dire $S(x) = P(X > x)$, où X est une variable aléatoire continue qui mesure la durée de vie. Soit la variable aléatoire X , dont la fonction de survie est donnée par

$$S(x) = \begin{cases} 1 & \text{si } x < 1 \\ -x^2 + 2x & \text{si } 1 \leq x \leq 2, \\ 0 & \text{si } x > 2. \end{cases}$$

STT-1900

Laquelle des fonctions suivantes est la fonction de densité de X ?

☐ $f(x) = \begin{cases} 1 - x^2 + 2x & \text{si } 1 \leq x \leq 2, \\ 0 & \text{sinon.} \end{cases}$

☐ $f(x) = \begin{cases} 1 + x^2 - 2x & \text{si } 1 \leq x \leq 2, \\ 0 & \text{sinon.} \end{cases}$

☐ $f(x) = \begin{cases} -2x + 2 & \text{si } 1 \leq x \leq 2, \\ 0 & \text{sinon.} \end{cases}$

☐ $f(x) = \begin{cases} 2x - 2 & \text{si } 1 \leq x \leq 2, \\ 0 & \text{sinon.} \end{cases}$

☐ $f(x) = \begin{cases} \frac{-x^3}{3} + x^2 & \text{si } 1 \leq x \leq 2, \\ 0 & \text{sinon.} \end{cases}$

☐ Nous ne pouvons pas déterminer la fonction de densité à partir des informations données.

Exercice

(A24) Laquelle des fonctions suivantes est une fonction de répartition ?

☐ $F(x) = \begin{cases} x & \text{si } x \geq 0, \\ 0 & \text{sinon.} \end{cases}$

☐ $F(x) = \begin{cases} 0 & \text{si } x < 0, \\ x/2 & \text{si } 0 \leq x < 2, \\ 0 & \text{si } x \geq 2. \end{cases}$

☐ $F(x) = \begin{cases} 0 & \text{si } x < 0 \\ \sqrt{x} & \text{si } 0 \leq x \leq 1, \\ 1 & \text{si } x > 1 \end{cases}$

☐ $F(x) = \begin{cases} 0 & \text{si } x < 0, \\ x + 1 & \text{si } 0 \leq x \leq 1, \\ 1 & \text{si } x > 1. \end{cases}$

☐ $F(x) = \begin{cases} 0 & \text{si } x < 0, \\ x & \text{si } 0 \leq x \leq 1, \\ 1 - x & \text{si } 1 < x \leq 2, \\ 1 & \text{si } x > 2. \end{cases}$

Exercice

(A24) Soit la variable aléatoire X et sa fonction de répartition

$$F(x) = \begin{cases} 1 - e^{-(x/\beta)^\alpha} & \text{si } x \geq 0, \\ 0 & \text{sinon,} \end{cases}$$

où α et β sont des constantes.

En posant $\alpha = 0,5$ et $\beta = 1$, calculez $P(16 \leq X \leq 25 | X \geq 9)$.

Module 3 - Loi normale et théorème central limite

Exercice

(A23) L'examen A et l'examen B servent pour la classification à un même emploi. Nous savons que les notes de ces deux examens suivent des lois normales d'espérance $\mu_A = 1100$ et $\mu_B = 21$, respectivement, de variance $\sigma_A^2 = 40\,000$ et $\sigma_B^2 = 36$, respectivement et de fonctions de répartition F_A et F_B , respectivement. Nous établissons le pointage d'un candidat par la probabilité d'obtenir une note inférieure ou égale à la note du candidat en question (donc en évaluant $F_A(a)$ ou $F_B(b)$, pour un candidat ayant obtenu a à l'examen A ou b à l'examen B).

(a) Sophie a eu une note de 1300 à l'examen A alors que Maxime a eu une note de 24 à l'examen B. Lequel des deux a un meilleur pointage ?

(b) Quelle note aurait dû avoir Sophie afin d'obtenir le même pointage que Maxime ?

Exercice

(A23) La variable aléatoire X suit une loi normale d'espérance μ et de variance μ^4 .

Sachant que $P(X \leq 0) = 0,84134$ et que $P(X > 1) = 0,02775$, que vaut μ ?

Exercice

(H24) Supposons qu'un ingénieur travaille sur le développement de deux capteurs de température pour un processus industriel. On peut modéliser les mesures des deux capteurs X et Y comme deux variables aléatoires normales indépendantes, avec des moyennes respectives $\mu_X = 20$ et $\mu_Y = 25$ et des variances $\sigma_X^2 = 4$ et $\sigma_Y^2 = 9$.

(a) Cochez tous les énoncés qui sont **vrais**.

☐ $X - Y$ est également une variable aléatoire qui suit une loi normale.

☐ $\frac{X - 20}{4} \sim \mathcal{N}(0, 1)$

☐ $P(X < 18.5) > P(X > 21.5)$.

☐ $P(Y < 20) > P(Y > 29)$.

☐ $P(X < 18) < P(Y < 18)$

(b) $\text{Var}[X - Y] < \text{Var}[X + Y]$.

☐ VRAI ☐ FAUX

Justification :

(c) Calculez $P(5Y > 4X + 62)$.

Exercice

(A24) Soit les variables aléatoires $X \sim \mathcal{N}(70, 100)$ et $Y \sim \mathcal{N}(80, 64)$. Calculez $P(X > Y)$.

Exercice

(A24) Un producteur de Gruyère sait que le poids d'une de ses meules de fromage, X , est une variable aléatoire d'espérance $\mu = 30$ kg et de variance $\sigma^2 = 9$ kg². Il doit envoyer 144 meules à un festival. Le transporteur lui chargera 1500\$, à condition que le poids total des 144 meules soit inférieur ou égal à 4431,24 kg. Dans le cas contraire, il lui chargera 2000\$.

Quelle est la probabilité approximative que le transporteur lui charge 1500\$?

Module 5 - Statistiques descriptives


Exercice

(A23) Dans un laboratoire de microtechnique, Audrey et Vincent ont étudié le temps de réaction (en millisecondes) d'un certain type de détecteur de mouvements. Les 21 valeurs suivantes sont des temps de réaction collectés au cours d'une journée :

111	111	111	112	113	113	113
113	115	115	115	115	115	116
116	118	118	119	125	125	128

Le diagramme en boîte ci-dessous a été tracé à partir de ces résultats. Il manque toutefois quelque chose à ce diagramme (il ne s'agit pas d'un titre ou de noms d'axes).

(a) Ajoutez **sur le diagramme** l'élément manquant et dites ce que vous avez fait (ceci *doit* inclure des calculs) sous le diagramme. Un ajout sur le diagramme sans justification n'aura aucun point.



(b) Nous apprenons que la plus grande observation (128) est erronée. Nous ne connaissons pas sa valeur, mais nous savons que celle-ci est plus grande que 150. Nous notons cette valeur XXX et nous savons que $XXX > 150$. Le nouveau jeu de données est donc :

111	111	111	112	113	113	113
113	115	115	115	115	115	116
116	118	118	119	125	127	XXX

À partir de ce nouveau jeu de données, répondez aux questions suivantes. Nous nommons «jeu de données original» celui qui contient l'observation 128 et «nouveau jeu de données» celui qui contient l'observation XXX. Déterminez si les énoncés suivants sont vrais ou faux.

Une bonne réponse vaut 2 points, une mauvaise réponse vaut -1 point et une réponse vide vaut 0 point, pour un total minimum de 0 point.

i. La médiane échantillonnale du nouveau jeu de données est supérieure à celle du jeu de données original.

☐ Vrai ☐ Faux

ii. La moyenne échantillonnale du nouveau jeu de données est supérieure à celle du jeu de données original.

☐ Vrai ☐ Faux

iii. La variance échantillonnale du nouveau jeu de données est supérieure à celle du jeu de données original.


☐ Vrai ☐ Faux

Exercice

(A24) Soit les 21 valeurs suivantes :

111	112	112	112	113	113	113
113	115	115	115	115	115	116
118	118	118	119	124	124	125

Le diagramme en boîte ci-dessous a été tracé à partir de ces résultats.



Lequel des énoncés suivants est vrai ?

- ☐ La médiane n'est pas au bon endroit.
- ☐ La moyenne échantillonnale n'est pas au bon endroit.
- ☐ Il devrait y avoir deux points : un à 105,5 et un à 125,5.
- ☐ La moustache de gauche devrait être à 105,5.
- ☐ La moustache de droite devrait être à 125,5.
- ☐ Il y a plus qu'une erreur.
- ☐ Il n'y a aucune erreur.

Module 6 - Échantillons aléatoires, lois échantillonnales et estimation ponctuelle

Exercice

(A23) Laquelle des affirmations suivantes est toujours vraie au sujet de $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, où les X_i sont indépendants et identiquement distribués de loi quelconque d'espérance μ_X et de variance σ_X^2 ?

- ☐ $Z = \frac{\bar{X} - \mu_X}{\sigma_X / \sqrt{n}} \sim \mathcal{N}(0, 1)$
- ☐ $\mathbb{E}[\bar{X}] = \mu_X$ seulement si $n > 30$
- ☐ $\mathbb{E}[\bar{X}] = \mu_X$ peu importe la loi des X_i
- ☐ $\mathbb{E}[\bar{X}] = \mu_X$ seulement si les X_i sont de loi normale
- ☐ $\text{Var}[\bar{X}] = \sigma_X^2$

Exercice

(H24) Soit K , S et F des variables aléatoires indépendantes qui suivent respectivement une khi-carré à 4 degrés de liberté, une Student à 35 degrés de liberté et une Fisher à 3 et 4 degrés de liberté.

Cochez tous les énoncés qui sont **faux** ?

- ☐ $P(S > 35) = 0,50$

- ☐ $P(K < 9,49) = 0,95$
- ☐ $P(F > 6,59) = 0,05$
- ☐ $P(S > a \cap K > b \cap F > c) = P(S > a) \times P(K > b) \times P(F > c)$

Exercice

(A24) Soit deux échantillons aléatoires indépendants provenant de populations normales, tels que :

$$X_1, \dots, X_{16} \sim \mathcal{N}(7, 4),$$

$$Y_1, \dots, Y_{100} \sim \mathcal{N}(8, 9).$$

(a) Quelle est la loi de $A = X_1 + X_2 - X_3$?

- ☐ $A \sim \mathcal{N}(7; 8)$
- ☐ $A \sim \mathcal{N}(7; 12)$
- ☐ $A \sim \mathcal{N}(14; 8)$
- ☐ $A \sim \mathcal{N}(14; 12)$
- ☐ $A \sim \mathcal{N}(21; 8)$
- ☐ $A \sim \mathcal{N}(21; 12)$
- ☐ Aucune de ces réponses

(b) Quelle est la loi de $B = \frac{1}{100} \sum_{i=1}^{100} Y_i$?

- ☐ $B \sim \mathcal{N}(0,08; 9)$
- ☐ $B \sim \mathcal{N}(0,08; 0,81)$
- ☐ $B \sim \mathcal{N}(0,08; 0,09)$
- ☐ $B \sim \mathcal{N}(8; 9)$
- ☐ $B \sim \mathcal{N}(8; 0,81)$
- ☐ $B \sim \mathcal{N}(8; 0,09)$
- ☐ Aucune de ces réponses

(c) Quelle est la loi de $C = X_1$?

- ☐ $C \sim \mathcal{N}(0,4375; 4)$
- ☐ $C \sim \mathcal{N}(0,4375; 0,25)$
- ☐ $C \sim \mathcal{N}(0,4375; 1)$
- ☐ $C \sim \mathcal{N}(7; 4)$
- ☐ $C \sim \mathcal{N}(7; 0,25)$
- ☐ $C \sim \mathcal{N}(7; 1)$
- ☐ Aucune de ces réponses

(d) Quelle est l'espérance de $D = \frac{\bar{Y} - 8}{S_Y/10}$, où S_Y est l'écart-type échantillonnal de Y ?

- ☐ $E(D) = 8$
- ☐ $E(D) = 100$
- ☐ $E(D) = 99$
- ☐ $E(D) = 0$
- ☐ $E(D) = 15$
- ☐ $E(D) = 800$
- ☐ Aucune de ces réponses

Exercice

(A24) Déterminez si les énoncés suivants sont vrais ou faux.

Une bonne réponse vaut 2 points, une mauvaise réponse vaut -1 point et une réponse vide vaut 0 point, pour un total minimum de 0 point.

- (a) Si $X_1, \dots, X_{100}$ constituent un échantillon aléatoire simple issu d'une loi normale d'espérance $\mu = 16$ et de variance $\sigma^2 = 100$, alors la moyenne échantillonnale de ces 100 valeurs suit approximativement une loi normale centrée-réduite.
☐ Vrai ☐ Faux
- (b) Si $X_1, \dots, X_{17}$ constituent un échantillon aléatoire simple issu d'une loi $\mathcal{N}(5; 4)$, alors la variable $4S^2$ a une espérance de 16 et une variance de 32.
☐ Vrai ☐ Faux
- (c) Si W suit une χ_4^2 (khi-carré avec 4 degrés de liberté), alors $P(W > 4) = P(W < 4)$.
☐ Vrai ☐ Faux
- (d) Le poids des tomates d'un certain agriculteur suit une loi normale de moyenne 300 grammes et de variance 100 grammes². On prend des mesures sur 25 tomates choisies aléatoirement et on obtient une moyenne échantillonnale de 309,12 grammes et une variance échantillonnale de 118,3 grammes². Dans cette situation, les nombres 309,12 et 118,3 sont des paramètres et les nombres 300 et 100 sont des statistiques.
☐ Vrai ☐ Faux
- (e) Soit deux échantillons aléatoires indépendants de taille $n = 26$ et $m = 26$ qui proviennent de lois normales $\mathcal{N}(\mu_X, \sigma_X^2)$ et $\mathcal{N}(\mu_Y, \sigma_Y^2)$. Les moyennes échantillonnales sont respectivement $\bar{X}$ et $\bar{Y}$, alors que les variances échantillonnales sont respectivement S_X^2 et S_Y^2 . La statistique S_X^2/S_Y^2 suit une $F_{25,25}$.
☐ Vrai ☐ Faux

Exercice

(A24) Soit $X_1, \dots, X_9$ des réalisations indépendantes d'une variable $X \sim \mathcal{N}(12, 24)$ et $Y_1, \dots, Y_{18}$ des réalisations indépendantes d'une variable $Y \sim \mathcal{N}(21, 24)$. Notez S_X^2 et S_Y^2 , les variances des deux échantillons.

Quelle est la probabilité que S_X^2 soit deux fois plus grande que S_Y^2 ?

Module 7 - Intervalles de confiance

Exercice

(H24) Nous nous intéressons aux prix des loyers des étudiants de l'Université Laval. Avec un échantillon aléatoire de $n = 241$ étudiants, nous obtenons l'intervalle de confiance à 95% pour μ suivant : [550; 1630]. Cochez tous les énoncés qui sont vrais parmi les suivants. **Une réponse cochée alors qu'elle ne devrait pas l'être entraîne une pénalité de 1 point. Le minimum possible pour cette question est 0 point.**

- ☐ Il y a 95% des étudiants qui ont un loyer entre 550 \$ et 1630 \$
- ☐ Si on choisissait un échantillon de 100 étudiants pour construire un nouvel intervalle de confiance à 95% sur la moyenne, celui-ci aurait une plus faible probabilité de contenir la vraie valeur de μ que celui obtenu à partir de 241 étudiants.
- ☐ Si on choisissait un autre échantillon de 241 étudiants pour construire un intervalle de confiance à 95% sur la moyenne, l'intervalle obtenu aurait nécessairement la même longueur que celui-ci.
- ☐ Si on choisissait plusieurs échantillons de 241 étudiants dans cette population, et qu'on construisait avec chacun d'eux l'intervalle de confiance à 95% pour μ , alors environ 95% de ces intervalles contiendraient la vraie valeur moyenne des loyers des étudiants de l'Université Laval.
- ☐ Si on suppose que le prix des loyers ne suit pas une loi normale, l'intervalle de confiance est toujours valide, car $n \geq 30$, mais son niveau est approximatif.

Exercice

(H24) Soit $X_1, \dots, X_{25}$, des variables aléatoires indépendantes de loi normale d'espérance μ et de variance σ^2 . Voici plusieurs intervalles :

1	$\bar{X} \pm t_{\alpha/2;24} \frac{S}{\sqrt{25}}$	6	$\bar{X} \pm z_{\alpha/2} \frac{\sigma^2}{\sqrt{25}}$
2	$\bar{X} \pm t_{\alpha/2;25} \frac{S}{\sqrt{25}}$	7	$\bar{X} \pm t_{\alpha/2;24} \frac{S}{\sqrt{24}}$
3	$\bar{X} \pm t_{\alpha/2;25} \frac{\sigma}{\sqrt{24}}$	8	$\bar{X} \pm z_{\alpha/2} \frac{S}{\sqrt{25}}$
4	$\bar{X} \pm t_{\alpha/2;25} \frac{\sigma}{\sqrt{25}}$	9	$\left[\frac{24S^2}{\chi_{\alpha/2;24}^2}; \frac{24S^2}{\chi_{1-\alpha/2;24}^2} \right]$
5	$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{25}}$	10	$\left[\frac{25S^2}{\chi_{\alpha/2;25}^2}; \frac{25S^2}{\chi_{1-\alpha/2;25}^2} \right]$

Associez chacune des situations suivantes au numéro de l'intervalle de confiance de niveau $1 - \alpha$ qui correspond. Une seule réponse est bonne pour chaque situation.

(a) Intervalle de confiance pour μ lorsque σ^2 est connue.

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5 ☐ 6 ☐ 7 ☐ 8 ☐ 9 ☐ 10

(b) Intervalle de confiance pour σ^2 .

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5 ☐ 6 ☐ 7 ☐ 8 ☐ 9 ☐ 10

(c) Intervalle de confiance pour μ lorsque σ^2 est inconnue.

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5 ☐ 6 ☐ 7 ☐ 8 ☐ 9 ☐ 10

Exercice

(A23) Un intervalle de confiance au niveau 95% pour l'espérance μ est $[10,11; 19,11]$. Pour chaque énoncé qui suit, indiquez si l'énoncé est vrai, faux ou si nous n'avons pas assez d'information pour le savoir.

(a) Au seuil 5%, on rejette $H_0 : \mu = 10$ pour $H_1 : \mu \neq 10$.

☐ Vrai ☐ Faux ☐ Nous n'avons pas assez d'information pour le savoir.

(b) Au seuil 1%, on rejette $H_0 : \mu = 10$ pour $H_1 : \mu \neq 10$.

☐ Vrai ☐ Faux ☐ Nous n'avons pas assez d'information pour le savoir.

(c) Au seuil 10%, on rejette $H_0 : \mu = 10$ pour $H_1 : \mu \neq 10$.

☐ Vrai ☐ Faux ☐ Nous n'avons pas assez d'information pour le savoir.

(d) Au seuil 5%, on rejette $H_0 : \mu = 28$ pour $H_1 : \mu \neq 28$.

☐ Vrai ☐ Faux ☐ Nous n'avons pas assez d'information pour le savoir.

Exercice

(A24) On a noté la fréquence cardiaque de neuf hommes. L'intervalle de confiance à 90% obtenu pour la fréquence cardiaque moyenne est $[94; 112]$. On suppose que la loi normale est adéquate pour cette variable aléatoire.

Déterminez si les énoncés suivants sont vrais ou faux.

Une bonne réponse vaut 1 point, une mauvaise réponse vaut -0,5 point et une réponse vide vaut 0 point, pour un total minimum de 0 point.

(a) La fréquence cardiaque moyenne des hommes ayant participé à l'étude est de 100 battements par minute.

☐ Vrai ☐ Faux

(b) Si on recommençait la même expérience avec neuf autres individus de la même population, il y aurait 90% de chances que la nouvelle moyenne échantillonnale soit comprise entre 94 et 112.

☐ Vrai ☐ Faux

(c) Environ 90% des hommes de cette population ont une fréquence cardiaque comprise entre 94 et 112.

☐ Vrai ☐ Faux

(d) Environ 90% des hommes de cet échantillon ont une fréquence cardiaque comprise entre 94 et 112.

☐ Vrai ☐ Faux

(e) La probabilité que la moyenne échantillonnale soit comprise entre 94 et 112 est 90%.

☐ Vrai ☐ Faux

(f) La probabilité que la moyenne de la population soit comprise entre 94 et 112 est 90%.

☐ Vrai ☐ Faux

(g) Si on avait utilisé un échantillon de 50 individus, l'intervalle de confiance aurait probablement été plus court.

☐ Vrai ☐ Faux

Exercice

(A24) On veut calibrer une certaine machine pour qu'elle soit le plus stable possible. On veut d'abord estimer la variation de la taille des pièces produites à l'aide d'un intervalle de confiance, en supposant que la loi normale modélise bien la variable aléatoire en question. Un échantillon de taille 25 a donné une variance échantillonnale de 0,03642 cm². La borne inférieure de l'intervalle de confiance pour la variance est 0,024.

- (a) Quel est le niveau de l'intervalle de confiance ?
- (b) Que vaut la borne supérieure de l'intervalle de confiance ?

Module 8 - Tests d'hypothèses

Exercice

(A23, H24) On veut faire le test d'hypothèse suivant

$$H_0 : \sigma_1^2 = \sigma_2^2$$
$$H_1 : \sigma_1^2 \neq \sigma_2^2,$$

où la variable 1 suit une loi normale de moyenne μ_1 et de variance σ_1^2 et la variable 2 suit une loi normale de moyenne μ_2 et de variance σ_2^2 . On sélectionne aléatoirement 30 observations de la variable 1 et 30 observations de la variable 2 de façon indépendante. On obtient la sortie Rcmdr suivante :

```
> var.test(x ~ obs, alternative='two.sided', conf.level=.95, data=donnees)
```

F test to compare two variances

```
data: x by obs
F = 0.15, num df = AAA, denom df = BBB, p-value = 0.00000204
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
0.07139472 0.3151494
sample estimates:
ratio of variances
0.15
```

- (a) Donnez la valeur de AAA, soit le nombre de degrés de liberté associés au numérateur de la statistique de test. Justifiez votre réponse.
- (b) Donnez la valeur de BBB, soit le nombre de degrés de liberté associés au dénominateur de la statistique de test. Justifiez votre réponse.
- (c) On vous indique que la variance échantillonnale de la variable 1, s_1^2 , vaut 6,69. Quelle est la valeur de la variance échantillonnale de la variable 2, soit s_2^2 ? Justifiez votre réponse.
- (d) En utilisant l'information disponible dans la sortie Rcmdr, choisissez l'énoncé qui est vrai.
 - ☐ La variance de la variable 1 est significativement différente de celle de la variable 2 au seuil 5%.
 - ☐ La variance de la variable 1 n'est pas significativement différente de celle de la variable 2 au seuil 5%.
 - ☐ Au seuil 5%, on ne peut rien conclure à partir de la sortie Rcmdr.

Exercice

(A23) Dans une manufacture, on considère que X , la variable aléatoire représentant le temps nécessaire pour fabriquer un clavier (en minutes), suit une loi normale de moyenne μ et de variance $\sigma^2 = 4$. On désire faire un test d'hypothèse au seuil $\alpha = 10\%$, avec les hypothèses suivantes :

$$H_0 : \mu = 5$$
$$H_1 : \mu > 5.$$

On sélectionne au hasard un échantillon de 9 claviers. Le temps total pour fabriquer les 9 claviers est de 49,5 minutes. Dans ce qui suit, les quantiles z_α ont été arrondis à 3 décimales.

1	$P\left(\frac{\bar{X}-5}{2/3} > 1,280 \mid \mu = 5\right)$	9	$P\left(\frac{\bar{X}-5,5}{2/3} > 1,280 \mid \mu = 7\right)$
2	$P\left(\frac{\bar{X}-5}{4/9} > 1,280 \mid \mu = 5\right)$	10	$P\left(\frac{\bar{X}-5}{2/3} > 1,280 \mid \mu = 7\right)$
3	$P\left(\frac{\bar{X}-5}{2/3} > 1,645 \mid \mu = 5\right)$	11	$P\left(\frac{\bar{X}-5}{2/3} > 1,645 \mid \mu = 7\right)$
4	$P\left(\frac{\bar{X}-5}{4/9} > 1,645 \mid \mu = 5\right)$	12	$P\left(\frac{\bar{X}-7}{2/3} > 1,280 \mid \mu = 7\right)$
5	$P\left(\frac{\bar{X}-7}{2/3} > 1,280 \mid \mu = 5\right)$	13	$P\left(\frac{\bar{X}-5}{4/9} > 1,280 \mid \mu = 7\right)$
6	$P\left(Z > \frac{5,5-7}{2/3}\right)$	14	$P\left(Z > \frac{5,5-5}{4/9}\right)$
7	$P(\bar{X} > 5)$	15	$P(\bar{X} > 7)$
8	$P\left(Z > \frac{5,5-5}{2/3}\right)$	16	$P\left(Z > \frac{5-7}{2/3}\right)$

Sachant qu'en vérité $\mu = 7$, complétez correctement les énoncés suivants.

(a) La puissance de test est donnée par le numéro

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5 ☐ 6 ☐ 7 ☐ 8
☐ 9 ☐ 10 ☐ 11 ☐ 12 ☐ 13 ☐ 14 ☐ 15 ☐ 16

(b) Le seuil observé pour cet échantillon est donné par le numéro

☐ 1 ☐ 2 ☐ 3 ☐ 4 ☐ 5 ☐ 6 ☐ 7 ☐ 8
☐ 9 ☐ 10 ☐ 11 ☐ 12 ☐ 13 ☐ 14 ☐ 15 ☐ 16

Exercice

(A23) Voici deux mises en situation :

- **Mise en situation 1** : On aimerait comparer les performances de coureurs automobiles avec les pneus A et les performances avec les pneus B. Un groupe de 14 coureurs choisis au hasard parcourront un même circuit deux fois : une fois avec les pneus A, et une fois avec les pneus B. En supposant que le temps de parcours du circuit suit une loi normale, pouvez-vous conclure au seuil $\alpha = 5\%$ que le temps de parcours moyen avec les pneus A est supérieur au temps de parcours moyen avec les pneus B ?
- **Mise en situation 2** : Une entreprise fabrique des ampoules jaunes et des ampoules blanches. On aimerait savoir si les ampoules jaunes ont une durée de vie (en heures) supérieure à celle des ampoules blanches. On choisit un échantillon aléatoire de 12 ampoules jaunes et, de façon indépendante, un échantillon aléatoire de 13 ampoules blanches. On suppose que la durée de vie des deux types d'ampoules suivent des lois normales de même variance. Pouvés-vous conclure au seuil $\alpha = 5\%$ que la durée de vie des ampoules jaunes est supérieure à celle des ampoules blanches ?

Pour un test d'hypothèse, on note l'hypothèse nulle par H_0 et on note la statistique observée du test par t_0 . Voici des règles de décision de tests d'hypothèse :

- **Règle de décision A** : On rejette H_0 si $t_0 > 1,771$.
- **Règle de décision B** : On rejette H_0 si $t_0 < 1,771$.
- **Règle de décision C** : On rejette H_0 si $|t_0| > 2,069$.
- **Règle de décision D** : On rejette H_0 si $t_0 > 2,069$.
- **Règle de décision E** : On rejette H_0 si $|t_0| > 2,160$.
- **Règle de décision F** : On rejette H_0 si $t_0 > 2,160$.
- **Règle de décision G** : On rejette H_0 si $t_0 > 1,714$.
- **Règle de décision H** : On rejette H_0 si $t_0 < 1,714$.

Associez chaque mise en situation à la règle de décision correspondante.

(a) La règle de décision correspondant à la mise en situation 1 est la règle de décision

☐ A ☐ B ☐ C ☐ D ☐ E ☐ F ☐ G ☐ H

(b) La règle de décision correspondant à la mise en situation 2 est la règle de décision

☐ A ☐ B ☐ C ☐ D ☐ E ☐ F ☐ G ☐ H

Exercice

(A23) Une entreprise fabrique des palettes de chocolat et s'intéresse à la quantité moyenne de sucre dans une palette. Elle choisit au hasard 16 palettes. Dans l'échantillon, la quantité moyenne de sucre par palette est de 5,4 g et la variance échantillonnale est de 5,29 g². Sachant que X , la quantité de sucre dans une palette, est une variable aléatoire qui suit une loi normale d'espérance μ et de variance $\sigma^2 = 4$, elle fait le test suivant, au seuil $\alpha = 10\%$,

$$H_0 : \mu = 5$$

$$H_1 : \mu > 5.$$

(a) Quelle est la valeur de la statistique du test sous H_0 , arrondie à 3 décimales ?

☐ 1,341 ☐ 1,600 ☐ 0,800 ☐ 0,696 ☐ 1,210

(b) Le seuil observé du test est 0,212. Choisissez l'énoncé qui est vrai.

- ☐ Au seuil $\alpha = 5\%$, la quantité moyenne de sucre dans une palette est significativement supérieure à 5 g.
- ☐ Au seuil $\alpha = 5\%$, la quantité moyenne de sucre dans une palette n'est pas significativement supérieure à 5 g.
- ☐ Au seuil $\alpha = 5\%$, la variance de la quantité de sucre dans une palette est significativement supérieure à 5 g.
- ☐ Au seuil $\alpha = 5\%$, on ne peut pas dire si la quantité moyenne de sucre dans une palette est significativement différente de 5 g.

Exercice

(H24) Amandine s'intéresse à la quantité moyenne de sel par kilogramme de gruyère. Elle choisit au hasard 16 morceaux de 1 kilogramme. Dans l'échantillon, la quantité moyenne de sel par kilogramme est de 3,4 g et la variance échantillonnale est de 4,41 g². Sachant que X , la quantité de sel, est une variable aléatoire qui suit une loi normale d'espérance μ et de variance $\sigma^2 = 4$ g², elle confronte les hypothèses suivantes, au seuil $\alpha = 5\%$,

$$H_0 : \mu = 3$$

$$H_1 : \mu > 3.$$

(a) Quelle est la valeur critique du test, arrondie à 3 décimales ?

☐ 1,645 ☐ 1,960 ☐ 0,800 ☐ 0,762 ☐ 2,131 ☐ 1,753

☐ Comme $n < 30$, il est impossible de faire un test d'hypothèse valide.

(b) Le seuil observé du test est 0,212. Choisissez tous les énoncés qui sont vrais. **Une réponse cochée alors qu'elle ne devrait pas l'être entraîne une pénalité de 1 point. Le minimum possible pour cette question est 0 point.**

- ☐ Au seuil $\alpha = 5\%$, Amandine rejette H_0 .
- ☐ Au seuil $\alpha = 5\%$, Amandine ne rejette pas H_0 .
- ☐ Au seuil $\alpha = 5\%$, la variance de la quantité de sel dans un kilogramme est significativement supérieure à 3 g.
- ☐ Au seuil $\alpha = 5\%$, nous ne pouvons pas dire si la quantité moyenne de sel dans un kilogramme est significativement différente de 3 g.
- ☐ Amandine rejetterait H_0 pour tous les tests dont le seuil est supérieur ou égal à 0,212.
- ☐ Amandine rejetterait H_0 pour tous les tests dont le seuil est inférieur ou égal à 0,212.

Exercice

(H24) Deux populations sont distribuées selon des lois normales de moyennes μ_X et μ_Y et de variances σ_X^2 et σ_Y^2 inconnues qui sont supposées inégales. Soit les échantillons

$$X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu_1, \sigma_1^2),$$

$$Y_1, \dots, Y_m \stackrel{i.i.d.}{\sim} N(\mu_2, \sigma_2^2),$$

où $n = 8$ et $m = 8$, et les hypothèses

$$H_0 : \mu_X - \mu_Y = 0,$$

$$H_1 : \mu_X - \mu_Y > 0.$$

Sachant que $\alpha^* = 0,01$, $\bar{y} = 100$, $s_X = 12$ et $s_Y = 12$, que vaut $\bar{x}$?

Exercice

(H24) Soit $X_1, \dots, X_{36}$, des variables aléatoires indépendantes et identiquement distribuées selon une loi normale d'espérance μ et de variance $\sigma^2 = 1296$. Nous désirons faire un **test unilatéral à droite** avec $H_0 : \mu = 10$ au seuil $\alpha = 0,025$. Nous avons les résultats suivants :

$$\bar{x} = 11,34$$

$$s^2 = 754.$$

Si nous savons qu'en réalité $\mu = \mu_1$ et que la puissance du test est 0,13567, que vaut μ_1 ?

Exercice

(A24) Amandine s'intéresse au poids moyen des citrons que produisent ses citronniers. Habituellement, le poids moyen des citrons est de 125 g. Elle veut savoir si son nouvel engrais a un impact positif sur le poids des citrons. Les citrons qui poussent à l'aide du nouvel engrais ont une variance théorique de 196 g². Elle choisit au hasard 25 citrons ayant poussé à l'aide de son nouvel engrais. Dans l'échantillon, le poids moyen des citrons est de 132 g et la variance échantillonnale est de 169 g².

(a) Quelles hypothèses devra-t-elle confronter ?

☐ $H_0 : \mu = 125$ et $H_1 : \mu \neq 125$

☐ $H_0 : \mu = 125$ et $H_1 : \mu > 125$

☐ $H_0 : \mu = 125$ et $H_1 : \mu < 125$

☐ $H_0 : \mu = 132$ et $H_1 : \mu \neq 132$

☐ $H_0 : \mu = 132$ et $H_1 : \mu > 132$

☐ $H_0 : \mu = 132$ et $H_1 : \mu < 132$

☐ Nous ne pouvons pas connaître les hypothèses, car nous ne connaissons pas le seuil α .

(b) Supposons qu'elle désire faire un test unilatéral à droite au seuil $\alpha = 1,5\%$.

i. Quelle est la valeur critique du test, arrondie à 3 décimales ?

☐ 1,885

☐ 2,170

☐ 2,692

☐ 2,500

☐ 2,064

☐ 1,711

☐ 0,0150

☐ 1,500

ii. Le seuil observé du test est 0,00621. Choisissez tous les énoncés qui sont vrais. **Une réponse cochée alors qu'elle ne devrait pas l'être entraîne une pénalité de 1 point. Le minimum possible pour cette question est 0 point.**

☐ Au seuil $\alpha = 1,5\%$, Amandine rejette H_0 .

☐ Au seuil $\alpha = 1,5\%$, Amandine ne rejette pas H_0 .

☐ Au seuil $\alpha = 1,5\%$, la variance du poids des citrons est significativement supérieure à 196 g.

☐ Au seuil $\alpha = 1,5\%$, nous ne pouvons pas dire si le poids moyen des citrons est influencé par le nouvel engrais.

☐ Amandine rejetterait H_0 pour tous les seuils supérieurs à 0,00621.

☐ Amandine rejetterait H_0 pour tous les seuils inférieurs à 0,00621.

Exercice

(a24) On veut savoir si les élèves de 16 ans sont plus forts en mathématiques en juin qu'en septembre. On choisit 6 étudiants au hasard qui passent un examen similaire avant et après les vacances. Voici les résultats :

Examen	Étudiant						Moyenne
	1	2	3	4	5	6	
Examen 1	77	74	82	73	87	AAA	???
Examen 2	72	68	76	68	85	63	72

Répondez aux questions suivantes en sachant qu'il s'agit d'échantillons appariés et en utilisant les quantités suivantes :

$$s_D^2 = 2,8$$

$$\bar{d} = 4.$$

(a) Que vaut AAA ? Justifiez votre réponse.

(b) En confrontant les hypothèses $H_0 : \mu_1 = \mu_2$ et $H_1 : \mu_1 > \mu_2$ au seuil $\alpha = 5\%$, quelle est la loi de la statistique du test ?

☐ t_5

- ☐ t_6
- ☐ t_{11}
- ☐ t_{12}
- ☐ $t_{0,05;5}$
- ☐ $t_{0,025;5}$
- ☐ $t_{0,05;6}$
- ☐ $t_{0,025;6}$
- ☐ $t_{0,05;11}$
- ☐ $t_{0,025;11}$
- ☐ $t_{0,05;12}$
- ☐ $t_{0,025;12}$

(c) Pourquoi est-il probablement préférable d'utiliser des échantillons appariés dans ce contexte ? Une seule réponse est bonne.

- ☐ Car l'examen 1 est plus facile que l'examen 2.
- ☐ Car nous supposons que tous les élèves ont environ le même niveau en mathématiques.
- ☐ Car nous voulons nous protéger contre la possibilité que la difficulté des examens influence la décision du test.
- ☐ Car nous voulons nous protéger contre la possibilité que la force des élèves influence la décision du test.
- ☐ Car nous rejetons H_0 au seuil $\alpha = 5\%$.
- ☐ Car nous ne rejetons pas H_0 au seuil $\alpha = 5\%$.
- ☐ Car il s'agit d'observations prises dans le temps.

Exercice

(A24) Soit $X_1, \dots, X_{16}$, des variables aléatoires indépendantes et identiquement distribuées selon une loi normale d'espérance $\mu = 36$ et de variance σ^2 . Nous désirons faire un **test unilatéral à droite** avec $H_0 : \sigma^2 = 33$ au seuil $\alpha = 0,025$. Nous avons les résultats suivants :

$$\bar{x} = 34,56$$

$$s^2 = 42,1.$$

Si nous savons qu'en réalité $\sigma^2 = \sigma_1^2$ et que la puissance du test est 0,05, que vaut σ_1^2 ? Justifiez toutes les étapes de votre démarche.

Exercice

(A24) Nous voulons faire le test d'hypothèse suivant

$$H_0 : \sigma_1^2 = \sigma_2^2$$

$$H_1 : \sigma_1^2 > \sigma_2^2,$$

où la variable 1 suit une loi normale d'espérance μ_1 et de variance σ_1^2 et la variable 2 suit une loi normale d'espérance μ_2 et de variance σ_2^2 . Nous sélectionnons aléatoirement 25 observations de la variable 1 et 30 observations de la variable 2 de façon indépendante et utilisons la statistique

$$F_0 = \frac{S_1^2}{S_2^2},$$

où S_1^2 et S_2^2 sont les variances échantillonnelles des variables 1 et 2 respectivement.

- (a) Donnez la loi échantillonnale de F_0 , sous H_0 .
- (b) Nous obtenons $F_0 = 2,15$. Quelle est la valeur du seuil observé du test ?
- (c) Lequel des énoncés suivant est vrai, au seuil $\alpha = 5\%$?

- ☐ Nous rejetons H_0 .
- ☐ Nous ne rejetons pas H_0 .
- ☐ Il nous manque d'information.

Module 9 - ANOVA à un facteur

Exercice

(A23) Soit la table d'ANOVA suivante obtenue à l'aide de Rcmdr :

```
>summary(ANOVAModel)
      Df Sum Sq Mean Sq F value    Pr(>F)
Fromages  4  926.12   231.53   238.72 0.000001
Residuals 48   46.55    0.97
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est vraie ?

- ☐ L'estimation de la moyenne du facteur Fromages est égale à 231,53.
- ☐ Nous avons 49 observations dans le jeu de données.
- ☐ La variance du facteur Fromages est environ 20 fois plus grande que la variance du facteur Residuals.
- ☐ L'hypothèse nulle supposait que les moyennes des différents niveaux du facteur Fromages étaient toutes égales.

Exercice

(H24) Soit la table d'analyse de la variance suivante obtenue à l'aide de Rcmdr :

```
>summary(ANOVAModel)
      Df Sum Sq Mean Sq F value    Pr(>F)
Raclette  4  926.12   231.53   238.72 0.0001
Residuals 48   46.55    0.97
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est vraie ? Une seule réponse est bonne.

- ☐ La proportion de la variance totale expliquée par le facteur Raclette est égale à 0,0001.
- ☐ Il y a 4 niveaux différents pour le facteur Raclette.
- ☐ La variance du facteur Raclette est environ 20 fois plus grande que la variance du facteur Residuals.
- ☐ L'hypothèse nulle supposait que les moyennes des différents niveaux du facteur Raclette étaient toutes égales.
- ☐ L'hypothèse nulle supposait que les moyennes des différents niveaux du facteur Residuals étaient toutes égales.
- ☐ Il s'agit d'une ANOVA à blocs aléatoires.
- ☐ Il manque la ligne d'interaction entre Raclette et Residuals.

Exercice

(A24) Soit la table d'analyse de la variance à un facteur suivante obtenue à l'aide de Rcmdr :

```
>summary(ANOVAModel)
      Df Sum Sq Mean Sq F value    Pr(>F)
Fromage  2  170.45    85.225    5.704 0.0251
Residuals 9 134.467   14.941
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est vraie ? Une seule réponse est bonne.

- ☐ La proportion de la variance totale expliquée par le facteur Fromage est égale à 0,0251.
- ☐ La valeur-p du test d'égalité des moyennes est égale à 5,704%.
- ☐ La variance du facteur Fromage vaut 170,45.
- ☐ La valeur critique du test d'hypothèses au seuil 5% que l'on fait avec cette table d'ANOVA est égale à 4,26.
- ☐ L'hypothèse nulle spécifie que les variances des différents niveaux du facteur Fromage sont toutes égales.
- ☐ Il s'agit d'une ANOVA à blocs aléatoires.
- ☐ Il manque la ligne d'interaction entre Fromage et Residuals pour pouvoir rejeter ou non H_0 .

Exercice

(A24) Un ingénieur veut vérifier s'il existe une différence de rigidité d'un certain type de cylindre, selon le pourcentage de *Vachopouliotum* qui le compose.

Il compare donc la rigidité de 6 pourcentages différents (10%, 20%, 25%, 30%, 35%, et 40%) en produisant 5 cylindres pour chaque pourcentage. La table d'ANOVA suivante est produite par Rcmdr. Dans celle-ci, certaines quantités ont été remplacées par AAA, BBB, CCC et ????. Nous considérons que les postulats du modèle sont respectés.

Analysis of Variance Table

Response: Y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
pourcentage	???	278.85	???	AAA	0.01
Residuals	BBB	343.20	???		
Total	???	CCC			

(a) Que vaut AAA ?

- ☐ 55,77
- ☐ 278,85
- ☐ 3,90
- ☐ 0,8125
- ☐ Il n'est pas possible de trouver la valeur de AAA avec les informations données.

(b) Que vaut BBB ?

- ☐ 5
- ☐ 6
- ☐ 24
- ☐ 25
- ☐ 29
- ☐ 30
- ☐ Il n'est pas possible de trouver la valeur de BBB avec les informations données.

(c) Que vaut CCC ?

- ☐ 1,231
- ☐ 64,35
- ☐ 622,05
- ☐ 0,8125
- ☐ Il n'est pas possible de trouver la valeur de CCC avec les informations données.

(d) Au seuil de 5%, quelle conclusion pouvons-nous tirer de la table d'ANOVA ? Une seule réponse est bonne.

- ☐ Il n'est pas possible de tirer de conclusion car nous ne connaissons pas les valeurs remplacées par ???.
- ☐ Il faudrait répéter l'expérience plus de fois pour pouvoir conclure.
- ☐ Toutes les moyennes sont significativement différentes.
- ☐ La rigidité moyenne des cylindres d'au moins un pourcentage est significativement différente de celle d'au moins un autre pourcentage.
- ☐ Toutes les moyennes sont significativement égales.

Module 10 - Régression linéaire simple

Exercice

(A23) Dans la forêt amazonienne, on veut prédire la taille des arbres (Y) en mètres à partir de leur diamètre (X) en centimètres. Pour ce faire, un statisticien dispose de 31 mesures (X_i, Y_i) et à l'aide de Rcmdr, il a ajusté le modèle de régression suivant

$$Y_i = \beta_0 + \beta_1 X_i + E_i, \quad i = 1, \dots, 31.$$

Il a obtenu les sorties ci-dessous (où certains éléments ont été remplacés par un point d'interrogation). On suppose que tous les postulats du modèle sont respectés.

```
> RegModel.1 <- lm(Y~X, data=Foret)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	102.2655	14.6302	6.99	1.1e-07

x 1.6514 0.4652 3.55 ?

Residual standard error: 22.15 on 29 degrees of freedom

Multiple R-squared: ?, Adjusted R-squared: 0.2789

F-statistic: 12.6 on 1 and 29 DF, p-value: ?

```
> Anova(RegModel.1, type="II")
```

Anova Table (Type II tests)

Response: y

	Sum Sq	Df	F value	Pr(>F)
x	6181.8	1	12.603	?
Residuals	14225.1	29		

(a) Calculez un intervalle de confiance à 90% pour l'effet d'une augmentation d'un centimètre de diamètre sur la taille moyenne des arbres. Justifiez votre réponse.

(b) Existe-t-il une relation linéaire significative entre le diamètre et la taille des arbres au seuil 10%? Justifiez votre réponse.

☐ Oui. ☐ Non.

Justification :

(c) Calculez le coefficient de corrélation échantillonnal entre le diamètre et la taille des arbres. Justifiez votre réponse.

(d) L'une des observations de ce jeu de données est $(x, y) = (25, 135)$. Calculez le résidu associé à cette observation. Justifiez votre réponse.

(e) Déterminez si les indications suivantes sont vraies ou fausses.

Dans le modèle de régression linéaire simple $Y_i = \beta_0 + \beta_1 X_i + E_i, \dots$

i. les estimations de β_0 et β_1 sont obtenues en minimisant la valeur de $SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$.

☐ Vrai ☐ Faux

ii. l'estimation de la variance σ^2 représente la variabilité des observations autour de $\bar{y}$ et se calcule avec

$$\sum_{i=1}^n (y_i - \bar{y})^2 / (n - 2).$$

☐ Vrai ☐ Faux

iii. si tous les points sont sur la droite de régression de Y par rapport à X, le coefficient de corrélation échantillonnal entre Y et X est égal à 1 ou -1 (en supposant que tous les points n'ont pas la même valeur de Y).

☐ Vrai ☐ Faux

Exercice

(H24) Afin d'estimer le volume de bois disponible dans la forêt entre Burtigny et Saint-Oyens, nous aimerions modéliser le volume de bois d'un arbre à l'aide de sa circonférence. Nous disposons du volume (Y) et de la circonférence (X) de 31 arbres. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, nous avons les résultats suivants :

```
lm(formula = volume ~ circonfer, data = foret)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-36.943	6.546373	-5.643	0.000001
circonfer	5.066	2.456783	2.062	0.024135

(a) Quelle est l'équation de la droite de régression permettant de prédire le volume de bois d'un arbre de circonférence précise ?

(b) Calculez la prévision ponctuelle du volume de bois d'un arbre ayant une circonférence de 11.

(c) Gérard aimerait estimer le volume de bois de l'arbre devant sa maison. Cet arbre a une circonférence de 14. La prévision ponctuelle du volume de bois de cet arbre est environ 33.98. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir le volume de bois de cet arbre de circonférence 14.

☐ $33.98 \pm t_{0,05;29} \sqrt{MS_E \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

- ☐ $33.98 \pm t_{0,025;1} \sqrt{MS_E \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $33.98 \pm t_{0,025;29} \sqrt{MS_E \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $33.98 \pm t_{0,025;29} \sqrt{MS_E \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $33.98 \pm t_{0,025;1} \sqrt{MS_E \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

(d) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?

- ☐ La circonférence d'un arbre et le volume de celui-ci ne sont pas unis par une relation linéaire significative.
- ☐ Nous ne pouvons pas prédire la valeur du volume de bois d'un arbre à partir de sa circonférence.
- ☐ La circonférence d'un arbre et le volume de celui-ci sont indépendants.
- ☐ La relation linéaire entre le volume de bois d'un arbre et sa circonférence est significative.

Exercice

(A24) Un limnologue a étudié certaines propriétés physico-chimiques de l'eau du lac Mistassini en 1973. En particulier, il a étudié la quantité d'oxygène dissous Y (en ppm) à diverses profondeurs X (en pieds), à l'aide de la méthode de Winkler. Les résultats obtenus sont les suivants :

X	10	20	30	50	110
Y	10,4	10,4	10,5	10,9	11,4

Il a aussi la sortie Rcmdr suivante, dans laquelle certaines valeurs ont été remplacées par ????

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	10.249367	0.064875	157.987	5.59e-07
X	0.010696	????	????	????

Residual standard error: 0.09117 on 3 degrees of freedom

Multiple R-squared: ????, Adjusted R-squared: ????

F-statistic: 86.99 on ??? and ??? DF, p-value: ????

(a) Quelle est l'équation de la droite de régression estimée ?

(b) (2 points) Donnez une estimation pour la quantité moyenne d'oxygène dissous lorsque la profondeur du lac est de 10 pieds. Justifiez votre réponse.

(c) La prévision ponctuelle à une profondeur de 25 pieds est de 10,5168. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la quantité moyenne d'oxygène dissous à cette profondeur.

- ☐ $10,5168 \pm t_{0,05;3} \sqrt{MS_E \left[\frac{1}{n} + \frac{(25 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $10,5168 \pm t_{0,025;1} \sqrt{MS_E \left[\frac{1}{n} + \frac{(25 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $10,5168 \pm t_{0,025;3} \sqrt{MS_E \left[\frac{1}{n} + \frac{(25 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $10,5168 \pm t_{0,025;3} \sqrt{MS_E \left[1 + \frac{1}{n} + \frac{(25 - \bar{x})^2}{S_{XX}} \right]}$
- ☐ $10,5168 \pm t_{0,025;1} \sqrt{MS_E \left[1 + \frac{1}{n} + \frac{(25 - \bar{x})^2}{S_{XX}} \right]}$

(d) Les données présentent-elles de l'évidence, au seuil de 5%, qu'il y a une relation linéaire significative entre la quantité d'oxygène dissous et la profondeur du lac ? Justifiez votre réponse.

Module 11 - Régression linéaire multiple

Exercice

(H24) Soit le modèle de régression linéaire multiple suivant :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 X_{i5} + E_i,$$

STT-1900

où les E_i sont indépendants et identiquement distribués de loi $\mathcal{N}(0, \sigma^2)$. Nous ajustons ce modèle aux données recueillies et nous obtenons les sorties suivantes, avec deux éléments remplacés par AAA et BBB.

```
> summary(RegModel.2)
Call:
lm(formula = Y ~ X1 + X2 + X3 + X4 + X5, data = Donnees)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.54046	0.19274	7.992	0.000001
X1	0.15321	0.07522	AAA	0.0423
X2	0.06662	0.04895	1.361	0.1743
X3	0.37692	0.08315	4.533	0.000001
X4	0.36810	0.05893	6.246	0.000001
X5	0.14618	0.08388	1.743	0.0821

Residual standard error: 1.019 on 402 degrees of freedom
Multiple R-squared: 0.5339, Adjusted R-squared: BBB
F-statistic: 92.11 on 5 and 402 DF, p-value: 0.000012

(a) Quelle est la valeur de AAA ?

☐ 2.037 ☐ -1.251 ☐ 3.798 ☐ -3.029

(b) Au seuil de 5%, l'effet de la variable indépendante X_2 sur la variable réponse Y est-il significatif, lorsque les autres variables sont dans le modèle ?

☐ Oui. ☐ Non. ☐ Nous n'avons pas assez d'information pour le savoir.

(c) Quelle est la valeur de BBB ?

☐ 0.7815 ☐ 0.5281 ☐ 0.2037 ☐ 0.6963

(d) Nous voulons maintenant tester, au seuil 1%,

H_0 : aucune des variables X_1, X_2, X_3, X_4, X_5 n'a un effet sur la variable réponse Y

H_1 : au moins une variable indépendante a un effet sur Y .

i. Quelle est la valeur-p associée à ce test ?

☐ 0,000001.
☐ 0,0423.
☐ 0,1743.
☐ 0,0821
☐ 0,000012.
☐ 0,01
☐ 0,05
☐ 0,10
☐ Nous n'avons pas assez d'information pour le savoir.

ii. Quelle est la conclusion ?

☐ Nous rejetons l'hypothèse nulle au seuil 1%.
☐ Nous ne rejetons pas l'hypothèse nulle au seuil 1%.
☐ Aucune des 5 variables explicatives n'a un effet sur Y au seuil 1%.
☐ Nous ne pouvons pas conclure sur ce test d'hypothèses car nous n'avons pas assez d'information.

Exercice

(A24) Lors d'une expérience, on cherche à construire un modèle pour expliquer et prédire une variable réponse Y par des variables explicatives X_1, X_2, X_3, X_4 et X_5 . Pour cela, on a recueilli les données et on a considéré le modèle de régression linéaire multiple suivant :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 X_{i5} + E_i,$$

où les E_i sont i.i.d et de loi $\mathcal{N}(0, \sigma^2)$. Vous ajustez ce modèle aux données recueillies et vous obtenez les sorties de Rcmdr suivantes, avec quelques éléments remplacés par des points d'interrogation.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.5405	0.1927	7.992	0.0001
X1	0.1532	0.0752	?????	0.0423
X2	0.0666	0.0489	1.361	0.1743
X3	0.3769	0.0832	4.533	0.0001
X4	0.3681	0.0589	6.246	0.0001
X5	0.1462	0.0839	1.743	0.0821

Residual standard error: 1.019 on 402 degrees of freedom
Multiple R-squared: 0.5339, Adjusted R-squared: ????
F-statistic: 92.11 on 5 and 402 DF, p-value: 0.00001

(a) Quelle est la valeur de la statistique du test pour tester la nullité de β_1 , lorsque les autres variables sont dans le modèle?

☐ 2.037 ☐ -1.251 ☐ 3.798 ☐ -3.029

(b) Au seuil de 5%, l'effet de la variable indépendante X_2 sur la variable réponse Y est-il significatif, lorsque les autres variables sont dans le modèle?

☐ Oui. ☐ Non. ☐ Nous n'avons pas assez d'information pour le savoir.

(c) Vous voulez maintenant tester, au seuil 1%,

H_0 : aucune des variables X_1, X_2, X_3, X_4, X_5 n'a un effet sur la variable réponse Y

H_1 : au moins une variable indépendante a un effet sur Y .

i. Quelle est la valeur-p associée à ce test?

ii. Quelle est votre conclusion?

- ☐ On rejette l'hypothèse nulle au seuil 1%.
- ☐ On ne rejette pas l'hypothèse nulle au seuil 1%.
- ☐ Aucune des 5 variables explicatives n'a un effet sur Y au seuil 1%.
- ☐ Nous ne pouvons pas conclure sur ce test d'hypothèses car nous n'avons pas assez d'information.

Plusieurs modules

Exercice

(H24) Déterminez si les énoncés suivants sont vrais ou faux.

Une bonne réponse vaut 2 points, une mauvaise réponse vaut -1 point et une réponse vide vaut 0 point, pour un total minimum de 0 point.

(a) L'analyse de la variance à 1 facteur tente d'isoler la variabilité causée par des phénomènes externes afin que celle-ci n'impacte pas les résultats.

☐ Vrai ☐ Faux

(b) Dans un test unilatéral de comparaison de moyennes, plus le seuil α est petit, plus la valeur-p est petite.

☐ Vrai ☐ Faux

(c) Dans un modèle de régression linéaire multiple, si l'intervalle de confiance à 95% pour β_0 est [0.345; 12.765], nous sommes certain qu'une relation linéaire existe entre X et Y .

☐ Vrai ☐ Faux

(d) Dans le contexte d'une régression linéaire simple, nous avons que $y_i = x_i$ pour $i = 1, \dots, n$. L'estimateur de β_0 est 0 et l'estimateur de β_1 est 1.

☐ Vrai ☐ Faux

(e) Dans le contexte d'une régression linéaire simple, si nous rejetons $H_0 : \beta_1 = 0$ à l'aide du test F au seuil α , il est certain que nous rejetons $H_0 : \beta_1 = 0$ à l'aide du test t au seuil α .

☐ Vrai ☐ Faux

Exercice

(H24) Soit $X_1, \dots, X_{16}$, des variables aléatoires indépendantes et identiquement distribuées selon une loi normale d'espérance μ et de variance σ^2 . Un intervalle de confiance de niveau 95% pour μ est [2,848; 11,372].

Parmi les énoncés suivants, cochez ceux qui sont vrais, en vous basant sur ce qui est mentionné plus haut et sachant qu'il y a cinq énoncés qui sont vrais. **Une réponse cochée alors qu'elle ne devrait pas l'être entraîne une pénalité de 1 point. Le minimum possible pour cette question est 0 point.**

- ☐ Au seuil 1%, nous rejetons $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ Au seuil 5%, nous rejetons $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ Au seuil 10%, nous rejetons $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ Au seuil 1%, nous ne rejetons pas $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ Au seuil 5%, nous ne rejetons pas $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ Au seuil 10%, nous ne rejetons pas $H_0 : \mu = 1,4$ pour $H_1 : \mu \neq 1,4$.
- ☐ À variance égale, un intervalle de confiance construit avec 25 observations serait forcément plus court.
- ☐ À variance égale, un intervalle de confiance construit avec 25 observations serait forcément plus long.
- ☐ Nous savons que $\mu = 7,11$.
- ☐ Nous savons que $\bar{x} = 7,11$.
- ☐ Si l'intervalle de confiance a été construit en utilisant les quantiles de la loi de Student (donc en supposant la variance inconnue), $s = 8$.
- ☐ Si l'intervalle de confiance a été construit en utilisant les quantiles de la loi normale (donc en supposant la variance connue), $\sigma = 8$.

Exercice

(A24) Déterminez si les énoncés suivants sont vrais ou faux.

Une bonne réponse vaut 1 point, une mauvaise réponse vaut -1 point et une réponse vide vaut 0 point, pour un total minimum de 0 point.

- (a) L'analyse de variance à un facteur a comme objectif principal de déterminer si les variances de a populations sont toutes égales ou si certaines diffèrent significativement.
- ☐ Vrai ☐ Faux
- (b) Le plan avec blocs aléatoires est utile lorsque les unités expérimentales sont hétérogènes.
- ☐ Vrai ☐ Faux
- (c) Dans un test unilatéral sur une moyenne μ , le calcul de la valeur-p dépend du seuil du test.
- ☐ Vrai ☐ Faux
- (d) Dans un modèle de régression linéaire simple, si $\beta_1 = 0$, alors les valeurs prédites de Y devraient être proches de la moyenne $\bar{y}$.
- ☐ Vrai ☐ Faux

Les modules suivants ne sont plus à l'étude depuis A25

Lois conjointes

Exercice

(A23) Soit X et Y deux variables aléatoires dont la loi conjointe est

$$f(x,y) = \begin{cases} \frac{\lambda \exp\{-\lambda(x+7)\} \exp\left(\frac{-y^2}{2}\right)}{\sqrt{2\pi}} & \text{si } -7 \leq x \leq \infty, -\infty \leq y \leq \infty \\ 0 & \text{sinon.} \end{cases}$$

Les variables X et Y sont indépendantes et

$$f_X(x) = \begin{cases} \lambda \exp\{-\lambda(x+7)\} & \text{si } -7 \leq x \leq \infty \\ 0 & \text{sinon.} \end{cases}$$

Dans ces fonctions de densité, $\lambda > 0$.

- (a) Quelle est la loi marginale de Y ?
- (b) Si $\lambda = 1$, calculez $P(0 \leq X \leq 1)$.

Exercice

(H24)

Soit X et Y deux variables aléatoires dont la loi conjointe est

$$f(x,y) = \begin{cases} \frac{e^{-x}}{b-a} & \text{si } 0 \leq x \text{ et } a \leq y \leq b, \\ 0 & \text{sinon.} \end{cases}$$

Dans cette fonction de densité, $a < b$. Nous savons que la fonction de densité marginale de X est

$$f_X(x) = \begin{cases} e^{-x} & \text{si } 0 \leq x, \\ 0 & \text{sinon.} \end{cases}$$

- (a) Quelle est la fonction de densité marginale de Y ?
(b) Les variables aléatoires X et Y sont-elles indépendantes ?

☐ OUI ☐ NON

Justification :

- (c) Si $a = 0$ et $b = 1$, calculez $P(X \leq 1 \cap Y > 0,5)$.

Exercice

(A24)

Soit X et Y deux variables aléatoires dont la loi conjointe est

$$f(x,y) = \begin{cases} \frac{1}{384} x^2 y^4 e^{-y-(x/2)} & \text{si } x > 0 \text{ et } y > 0, \\ 0 & \text{sinon,} \end{cases}$$

et dont les deux fonctions marginales sont données par

$$f_X(x) = \begin{cases} x^2 e^{-x/2} & \text{si } x > 0, \\ 0 & \text{sinon,} \end{cases}$$

$$f_Y(y) = \begin{cases} \frac{1}{384} y^4 e^{-y} & \text{si } y > 0, \\ 0 & \text{sinon.} \end{cases}$$

- (a) Déterminez la densité de X lorsque $y = 1$.
(b) Les variables aléatoires X et Y sont-elles indépendantes ?

☐ OUI ☐ NON

Justification :

ANOVA deux facteurs

Exercice

(H24) Sophie a planifié une expérience afin d'étudier l'effet du canton (Vaud, Genève et Jura) et du type de logement (maison et appartement) sur le prix de vente du logement. Elle a évalué aléatoirement k logements pour chacune des 6 combinaisons. Voici une partie d'une sortie R.

	Df	Sum Sq	F value	Pr(>F)
canton	2	491994	11.543	0.0016
type	1	154939	7.270	0.0194
canton:type	2	95069	2.231	0.1501
Residuals	12	255728		

- (a) Donnez MS_E , l'estimation de la variance des termes d'erreur.
(b) Trouvez la valeur de k , le nombre de logements évalués par combinaison des facteurs.

ANOVA blocs

Exercice

(H24) Benjamin veut vérifier si le type de fourrage que mange une vache laitière a un impact sur sa production de lait. Comme il pense qu'il y a de la variabilité qui est induite par les vaches, il décide de faire un plan par blocs. Dans son expérience, une même vache mange du fourrage de type A pendant une semaine, de type B pendant une semaine et de type C pendant une semaine. Il obtient la table suivante :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
fourrage	2	706.11	353.055	44.35	0.0003
vache	5	12.25	2.450		
Residuals	6	47.76	7.960		

À la lumière des résultats, est-ce que le plan par blocs était nécessaire dans ce cas? Pourquoi? Une seule réponse est bonne.

- ☐ Oui, car nous savons que les vaches ne produisent pas toutes la même quantité de lait.
- ☐ Oui, car nous rejetons H_0 .
- ☐ Oui, car la variabilité totale expliquée par les blocs est environ de 1,5%.
- ☐ Oui, car $MS_{trt} = 353,055$.
- ☐ Oui, car $MS_{blocs} = 2,450$.
- ☐ Oui, car $MS_E = 7,960$.
- ☐ Non, car nous rejetons H_0 .
- ☐ Non, car la variabilité totale expliquée par les blocs ne vaut environ que 1,5%.
- ☐ Non, car $MS_{trt} = 353,055$.
- ☐ Non, car $MS_{blocs} = 2,450$.
- ☐ Non, car $MS_E = 7,960$.