

Exercices de révision des chapitres 9 à 13

Question 1

Pour chacune des situations suivantes, choisissez le type d'analyse statistique approprié. Identifiez les variables (en considérant que toutes les variables spécifiées sont incluses dans le modèle), et le nombre de degrés de liberté associés à l'erreur.

- (a) Vous souhaitez comparer la consommation d'essence de 3 modèles de voiture. Vous n'êtes pas intéressé par la variation de la consommation d'essence entre les conducteurs, mais vous vous attendez à ce que le style de conduite ait un effet important sur la consommation d'essence.

Vous planifiez une expérience où 5 personnes conduisent (une fois chacune) les voitures des trois modèles sur un circuit déterminé, dans un ordre aléatoire. Chaque essai est réalisé sur le même parcours dans des conditions de température et d'état de la chaussée similaires.

- (b) Depuis 24 ans, un cultivateur note le rendement (en kg/hectare) de ses cultures de blé, la quantité de pluie reçue chaque mois ainsi que la température moyenne de chaque mois. Vous souhaitez utiliser ses données pour construire un modèle qui lui permettra de prédire le rendement de ses cultures de blé en fonction de la température moyenne des mois de juin et juillet, et de la quantité de pluie reçue en juin et en juillet.

- (c) Vous voulez vérifier l'effet de la profondeur du sol et l'effet de la topographie du site sur la quantité de phosphore dans le sol. Vous vous attendez à ce que l'effet de la profondeur varie selon la topographie, et vous tenez à ce que votre modèle en tienne compte. Vous sélectionnez 15 sites où la topographie est plane et 15 sites où la topographie est en pente.

- 5 sites planes sont choisis au hasard : sur chacun, vous prendrez un échantillon de sol à 5 cm de profondeur et en mesurerez le phosphore ;
- 5 autres sites planes sont choisis au hasard : sur chacun, vous prendrez un échantillon de sol à 10 cm de profondeur et en mesurerez le phosphore ;
- sur les 5 sites planes restants, vous prendrez un échantillon de sol à 20 cm de profondeur et en mesurerez le phosphore ;
- vous répéterez les 3 étapes ci-dessus pour les 15 sites en pente.
- Les 30 mesures de phosphore décrites ci-dessus seront prises dans un ordre aléatoire.

- (d) Un inspecteur en alimentation se demande si la quantité de pesticides sur les fruits et légumes que l'on retrouve sur le marché est associée à la taille des fermes maraîchères. En juillet, il visite 15 producteurs de fraises québécois choisis aléatoirement. Pour chacun, il analyse la quantité de pesticides dans un panier de fraises, et la met en relation avec les ventes de fraises de l'année précédente de ce producteur.

Question 2

On cherche à construire un modèle pour expliquer et prédire Y , la consommation d'électricité (en kWh), des maisons unifamiliales d'une région. Les variables explicatives disponibles sont X_1 , le nombre d'habitants; X_2 , la superficie habitable (en milliers de pieds carrés); X_3 , le revenu annuel du ménage (en milliers de dollars) et X_4 , le montant annuel de la taxe foncière (en milliers de dollars).

On recueille des données pour 25 maisons unifamiliales de cette région et on ajuste un modèle de régression linéaire multiple à nos observations. Après vérification, les postulats du modèle semblent raisonnablement respectés. Un extrait de la sortie R Commander obtenue est donné ci-dessous.

```
> summary(RegModel.2)
```


Coefficients:

	Estimate	Std. Error
(Intercept)	57.80968	9.92327
X1	6.61733	0.95758
X2	28.46419	8.40441
X3	0.05516	0.14109
X4	4.48517	8.30631

Residual standard error: 4.378 on 20 degrees of freedom

Multiple R-squared: 0.9072, Adjusted R-squared: 0.8886

F-statistic: 48.88 on 4 and 20 DF, p-value: 4.773e-10



- Peut-on conclure qu'au moins une des quatre variables explicatives est significative, au seuil de 5%?
- Donnez une estimation ponctuelle et un intervalle de confiance à 95% pour l'effet d'une hausse de la superficie habitable de 1 millier de pieds carrés sur la consommation d'électricité espérée, toute autre variable explicative restant inchangée.
- Le graphique de droite permet de sélectionner le meilleur sous-modèle selon le critère du R^2_{ajuste} produit par *R Commander*. Selon ce graphique, quelles variables explicatives sont retenues dans le meilleur sous-modèle selon le critère R^2_{ajuste} ?

Question 3

Pour estimer les stocks excédentaires de l'année courante, une entreprise fabriquant des pneus a tiré au hasard 6 détaillants chez qui elle vend ses produits; ceux-ci ont fourni les chiffres de l'inventaire de l'année passée à pareille date (X) et l'inventaire actuel (Y) reproduits dans le tableau suivant :

X	70	260	150	100	20	60
Y	60	320	230	120	50	60

On donne les sommes suivantes :

$$\sum_{i=1}^6 x_i = 660, \quad \sum_{i=1}^6 y_i = 840, \quad \sum_{i=1}^6 x_i^2 = 109\,000, \quad \sum_{i=1}^6 y_i^2 = 179\,400, \quad \sum_{i=1}^6 x_i y_i = 138\,500.$$

- (a) Trouver l'équation de la droite de régression et interpréter la valeur de $\hat{\beta}_1$ dans le contexte de ce problème.
 - (b) Construire la table d'analyse de la variance.
 - (c) Déterminer s'il existe une relation linéaire significative entre les inventaires de cette année et de l'année passée au seuil $\alpha = 5\%$.
 - (d) Calculer la proportion de variabilité de l'inventaire de cette année expliquée par celui de l'année passée.
-


Question 4

On a ajusté un modèle de régression linéaire simple pour le prix de vente d'une maison (en milliers de \$) en fonction de l'évaluation de cette maison (en milliers de \$) à l'aide d'un jeu de données de 25 observations. On a obtenu les valeurs suivantes :

$$\hat{\beta}_0 = 20,94 \quad \hat{\beta}_1 = 1,07 \quad \hat{\sigma}^2 = MS_E = 1075.$$

De plus, on vous indique que $\bar{x} = 201,75$, et $S_{xx} = 5\,209\,571$.

- (a) Quel est le prix de vente moyen pour les maisons évaluées à 200 000 \$?
- (b) Un ami vient de mettre sa maison en vente, évaluée à 280 000 \$. Construisez un intervalle à 95% pour le prix de vente de sa maison.
- (c) On veut maintenant vérifier la validité des postulats du modèle de régression. Parmi les graphiques ci-dessous, lequel permet de valider le postulat de normalité des erreurs ? Qu'en déduisez-vous ?



Question 5

On effectue une expérience afin de déterminer si le type de suspension a un effet sur la distance de freinage d'un prototype de voiture. Comme la distance de freinage peut varier beaucoup en fonction de la température et du niveau d'humidité, on décide de mener l'expérience sur 5 jours différents, toujours avec le même conducteur. À chaque jour, on testera les 3 types de suspension, une fois chacun, en amenant la voiture à 120 km/h, en appliquant les freins et en mesurant la distance de freinage.

- (a) Dites lequel parmi la distance de freinage, le jour, le conducteur et le type de suspension correspond au facteur, au bloc et à la variable réponse.

Les questions (b) à (d) portent sur l'extrait de sortie *R Commander* ci-dessous, qui donne les résultats d'une analyse de la variance avec blocs aléatoires faite sur les données décrites ci-dessus.

Anova Table (Type II tests)

Response: Distance

	Sum Sq	Df	F value	Pr(>F)
Suspension	169.41	AAAAA	DDDDD	0.02418 *
Jour	2338.66	BBBBB	EEEEE	1.984e-05 ***
Residuals	110.31	CCCCC		






- (b) Des valeurs ont été effacées dans la sortie et remplacées par AAAAA, BBBBB, etc. Trouvez ces valeurs manquantes.
- (c) Le type de suspension a-t-il un effet significatif sur la distance de freinage au seuil de 1 % ?
- (d) À la lumière des résultats obtenus, est-ce qu'utiliser une expérience par blocs aléatoires était une bonne idée ?
-

Question 6

Un kinésologue conduit une expérience visant à déterminer si la méthode d'entraînement (méthode A ou B) et le type de diète (diète 1 ou 2) a un impact sur le poids que des haltérophiles peuvent soulever. Il recrute 16 haltérophiles à peu près de même stature et qui soulèvent le même poids maximal. On les assigne aléatoirement à l'une des 4 combinaisons méthode-diète et on les soumet à l'entraînement et à la diète pendant une saison. À la fin de la saison, on mesure le poids maximal qu'ils sont capables de soulever.

Associez chacun des scénarios ci-dessous au graphique des moyennes qui lui correspond.

- (i) Ni la méthode d'entraînement, ni la diète n'ont un effet sur le poids soulevé.
- (ii) Seule la méthode d'entraînement a un effet sur le poids soulevé.
- (iii) Seule la diète a un effet sur le poids soulevé.
- (iv) La méthode d'entraînement et la diète ont un effet sur le poids soulevé, mais il n'y a pas d'interaction entre ces deux facteurs.
- (v) Il y a une interaction entre la diète et la méthode d'entraînement, donc forcément ces deux facteurs ont un effet sur le poids soulevé.



Question 7

Une étude est menée dans l'espoir de trouver la bonne quantité d'un catalyseur à ajouter à un procédé afin de maximiser la qualité du produit obtenu. On répète une expérience 20 fois et on obtient les résultats suivants :

- Y_i , un indice de qualité de produit final lors de l'expérience i (plus Y_i est élevé, meilleur est le produit),
- C_i , la quantité de catalyseur utilisée lors de l'expérience i et
- P_i , la quantité de pétrole utilisée dans l'expérience i .

Après discussion avec vos collègues et une revue de la littérature, vous ajustez le modèle de régression linéaire multiple ci-dessous à vos données, pour lequel les 4 postulats usuels s'avèrent raisonnables :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i, \quad i = 1, \dots, 20,$$

où $X_{i1} = C_i$, $X_{i2} = C_i^2$, $X_{i3} = P_i$ et les E_i sont des termes d'erreur i.i.d. $N(0, \sigma^2)$. Voici la sortie *R Commander*, où quelques valeurs sont remplacées par AAAAA, BBBBB, etc.

```
lm(formula = Y ~ X1 + X2 + X3, data = Qualite)
Residuals:
    Min       1Q   Median       3Q      Max
-7.5562 -2.7782  0.1606  4.1300  6.6078
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 113.13496   38.09154   2.970  0.00903 **
X1           8.86398    3.15453   2.810  0.01258 *
X2          -0.17704    0.06996  -2.531  0.02226 *
X3           9.99053    0.48986  20.395 7.08e-13 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.612 on 16 degrees of freedom
Multiple R-squared:  AAAAA, Adjusted R-squared:  BBBBB
F-statistic: CCCCC on DDDDD and EEEEE DF,  p-value: 3.415e-12
```







- Donnez une estimation de la quantité de catalyseur qui maximise l'indice de qualité espéré, lorsque la quantité de pétrole est égale à 3 unités.
- Avant l'expérience, un de vos collègues avait dit qu'une hausse d'une unité de la quantité de pétrole hausserait l'indice de qualité espéré d'au moins 9 unités. Les données supportent-elles l'hypothèse de votre collègue au seuil de 5% ?
- Sachant que $SS_T = 10\,701,3$, trouvez les valeurs manquantes AAAAA, BBBBB, etc.
- Le tableau ci-dessous donne la liste de tous les sous-modèles possibles (chacun incluant une ordonnée à l'origine), ainsi que leur R_{ajuste}^2 . Quel est le meilleur modèle selon ce critère ?

Sous-modèle	X_1, X_2, X_3	X_1, X_2	X_1, X_3	X_2, X_3	X_1	X_2	X_3
R_{ajuste}^2	0,962	0,041	0,955	0,950	0,0001	0,005	0,920

Question 8

Vous effectuez une expérience à un facteur et voulez vous assurer que les postulats émis sur les termes d'erreur sont raisonnablement respectés. Déterminez lequel/lesquels des graphiques correspond(ent) à chaque énoncé.







- (a) La variance des termes d'erreur n'est pas homogène :
- (b) La variance des termes d'erreur est homogène :
- (c) La normalité des termes d'erreur est respectée :
- (d) Les termes d'erreur ne suivent pas une loi normale :



Question 9

Vous effectuez une analyse de régression et voulez vous assurer que les postulats émis sur les termes d'erreur sont raisonnables. Déterminez lequel/lesquels des graphiques correspond(ent) à chaque énoncé. S'il s'agit d'un problème avec l'un des postulats, suggérez une solution.

- (a) La linéarité de la relation X-Y est respectée :
- (b) La linéarité de la relation X-Y n'est pas respectée :
- (c) Il y a homoscédasticité :
- (d) Il y a hétéroscédasticité :
- (e) La normalité des erreurs est respectée :
- (f) La normalité des erreurs n'est pas respectée :



Question 10

Déterminer si les énoncés suivants sont vrais ou faux.

- (a) Dans un modèle d'analyse de la variance à un facteur, le paramètre σ^2 représente la variance des Y_{ij} autour de la moyenne globale μ .
- (b) Si tous les points $(x_1, y_1), \dots, (x_9, y_9)$ sont parfaitement alignés selon une droite de pente positive, alors on sait que $\hat{\beta}_1 = 1$, $SS_E = 0$ et $r = 1$.
- (c) Dans un plan à blocs aléatoires, on considère que les observations d'un même bloc sont dépendantes, et que les observations de blocs différents sont indépendantes.
- (d) On pige $n = 5$ observations dans chacune des 3 populations suivantes : $N(12, 3)$, $N(15, 3)$, $N(18, 3)$. On calcule la statistique F_1 de la table d'anova. On pige $n = 5$ observations dans chacune des 3 populations suivantes : $N(12, 15)$, $N(15, 15)$, $N(18, 15)$. On calcule la statistique F_2 de la table d'anova. La valeur de F_1 aura tendance à être plus faible que F_2 .
- (e) Le meilleur modèle de régression à 3 variables explicatives est celui comprenant les 3 variables les plus corrélées avec la variable réponse Y .
- (f) Plus on ajoute de variables explicatives à un modèle de régression, plus la valeur de SS_E diminue.
- (g) Dans un modèle d'analyse de la variance à deux facteurs, si on obtient la table d'anova suivante, on conclura que seul le facteur A a un effet sur la valeur de Y .

Anova Table (Type II tests)

Response: Reponse

	Sum Sq	Df	F value	Pr(>F)
FacteurA	100.33	2	7.525	0.004216 **
FacteurB	13.50	1	2.025	0.171830
FacteurA:FacteurB	688.00	2	51.600	3.515e-08 ***
Residuals	120.00	18		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- (h) L'analyse de variance précédente a été faite à partir de 19 observations.
- (i) Supposons que le modèle $Y \sim N(\beta_0 + \beta_1 X, \sigma^2)$ décrit bien la relation entre Y et X . Alors les prédictions de Y pour $X = x_0$ seront plus précises si on choisit des x_i très dispersés, une grande taille d'échantillon, et une valeur x_0 assez proche de $\bar{x}$.