

STT-1900 — Méthodes statistiques pour ingénieurs

Exercices de révision

Université Laval
Département de mathématiques et de statistique

Table des matières

1	Introduction aux probabilités	2
2	Variables aléatoires	3
3	Loi normale et théorème central limite	4
4	Covariance et corrélation	5
5	Statistiques descriptives	6
6	Loi échantillonnale et estimation ponctuelle	7
7	Intervalles de confiance	8
8.1	Tests d'hypothèses : un échantillon	10
8.2	Tests d'hypothèses : deux échantillons	12
9	Analyse de la variance (ANOVA)	14
10	Régression linéaire simple	20
11	Régression linéaire multiple	23

Chapitre 1

Introduction aux probabilités

Exercice 1.1

Votre compagnie s'interroge sur le type de suspension qui devrait être installée sur ses prochains modèles de remorque. Une étude auprès de ses clients révèle que 50 % d'entre eux transportent des charges très lourdes. La même étude dit aussi que 15 % des clients fréquentent des routes accidentées mais ne transportent pas de charges très lourdes. Finalement, vous savez que les événements $L =$ « un client transporte des charges très lourdes » et $A =$ « un client fréquente des routes accidentées » sont indépendants.

- (a) Quelle proportion des clients ne transportent pas de charges très lourdes et ne fréquentent pas de routes accidentées ?
- (b) Quelle est la probabilité qu'un client transporte des charges très lourdes et fréquente des routes accidentées ?

Exercice 1.2

Dans une certaine région, 15 % des automnes sont secs, 50 % des automnes sont normaux et 35 % des automnes sont pluvieux. La probabilité que la rivière la plus importante de cette région atteigne son niveau critique au printemps qui suit est 10 % si l'automne est sec, 20 % si l'automne est normal et 80 % si l'automne est pluvieux.

- (a) Quelle est la probabilité que le prochain automne soit normal et que la rivière atteigne son niveau critique au printemps qui suivra ?
- (b) Si la rivière atteint son niveau critique lors d'un printemps donné, quelle est la probabilité que l'automne qui précède ait été pluvieux ?

Exercice 1.3

Une entreprise fabrique des pièces dont 1,8 % sont défectueuses. Un contrôle de fabrication ayant les caractéristiques suivantes est mis en place :

- il accepte une pièce qui est bonne dans 97 % des cas ;
- il refuse une pièce défectueuse dans 99 % des cas.

On contrôle la fabrication d'une pièce prise au hasard dans la production.

- (a) Quelle est la probabilité que la pièce contrôlée soit acceptée ?
- (b) Si la pièce contrôlée est refusée, quelle est la probabilité qu'elle soit défectueuse ?
- (c) Quelle est la probabilité de faire une erreur avec ce contrôle ?

Chapitre 2

Variables aléatoires

Exercice 2.1

Soit X , une des coordonnées de l'endroit où tombe un missile dans un champ de tir. On peut voir X comme une variable aléatoire continue dont la densité est donnée par

$$f(x) = \begin{cases} k(1-x^2) & \text{si } -1 < x < 1, \\ 0 & \text{sinon,} \end{cases}$$

k étant une constante positive.

- (a) Montrer que la valeur de k doit être égale à $3/4$.
- (b) Obtenir la fonction de répartition de X .
- (c) Calculer $E(X)$, $E(3X+5)$, $V(X)$ et $V(3X+5)$.
- (d) Que vaut $P(X \leq 0 | X \leq 1/2)$?

Exercice 2.2

Soit X_1 , une variable aléatoire dont la densité est donnée par $f_1(x)$ ci-dessous et X_2 , une variable aléatoire dont la densité est donnée par $f_2(x)$ ci-dessous :

$$f_1(x) = \begin{cases} e^{-x}, & x > 0 \\ 0, & \text{ailleurs;} \end{cases} \quad f_2(x) = \begin{cases} 2x, & 0 < x < 1 \\ 0, & \text{ailleurs.} \end{cases}$$

- (a) Quelle est la densité conjointe de X_1 et X_2 ? [Attention, il y a un piège dans cette question !!!]
- (b) Refaites la question (a) en supposant que X_1 et X_2 sont indépendantes.

Exercice 2.3

Soit X_1 et X_2 deux variables aléatoires dont la densité conjointe est donnée par

$$f(x_1, x_2) = \begin{cases} x_2 e^{-x_1 x_2}, & 0 < x_1 < \infty, 0 < x_2 < 1, \\ 0, & \text{ailleurs.} \end{cases}$$

- (a) X_1 et X_2 sont-elles des variables aléatoires indépendantes ?
- (b) Calculer $P(X_1 > 10 | X_2 = 1/2)$.

Chapitre 3

Loi normale et théorème central limite

Exercice 3.1

La chaîne Pizza Napoli affirme dans sa publicité que sa toute nouvelle pizza est servie en cinq minutes. Par souci d'intégrité et d'efficacité, le gérant d'une succursale a mené sa petite enquête dans son restaurant, et a fait les constatations suivantes :

- 1) On a autant de chances de servir une pizza en moins de 5 minutes qu'en plus de 5 minutes.
 - 2) Dans 20 % des cas, la pizza est servie en plus de 5,5 minutes ;
 - 3) On peut faire l'hypothèse que le temps de service X suit une distribution normale.
- (a) Déterminer l'espérance et la variance de X .
- (b) Quel devrait être le temps moyen de préparation pour que 80 % des pizzas soient servies en moins de 5 minutes ?

Chapitre 4

Covariance et corrélation

Exercice 4.1

Soit X_1 et X_2 , la concentration en azote aux points 1 et 2 d'un champ, respectivement. On vous dit que la distribution conjointe de ces variables est la loi normale bidimensionnelle $N_2(10, 20, 4, 25, 0, 20)$. On mesure la concentration au point 2 et on obtient une valeur de 15. Quelle est la probabilité que la concentration au point 1 soit inférieure à 9 ?

Exercice 4.2

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) Si $\text{Cov}(H, G) = 0$, alors $\text{Cov}(2H + 3, 5G) = 0$.
- (b) Si le profit qu'on tire de la vente d'un item est de 3 \$, alors la corrélation entre le nombre d'items vendus et le revenu net est égale à 1.
- (c) Si $P(X < 1 | Y = 2)$ est égale à $P(X < 1)$ pour une certaine distribution, alors on peut dire que les variables X et Y sont indépendantes.
- (d) Si $P(X < 1 | Y > 2)$ est égal à $P(X < 1)P(Y > 2)$ pour une certaine distribution, alors on peut dire que les événements $X < 1$ et $Y > 2$ sont indépendants.
- (e) Deux événements mutuellement exclusifs sont nécessairement indépendants.
- (f) Soit $[X, Y] \sim N_2(10, 30, 25, 64; -0, 8)$. On peut dire que la variance de $Y | X = 8$ est inférieure à la variance de $Y | X = 6$.
- (g) Soit $[X, Y] \sim N_2(10, 30, 25, 64; 0)$. On peut dire que l'espérance de $Y | X = 8$ est égale à l'espérance de $Y | X = 6$.
- (h) Soit $[X, Y] \sim N_2(10, 30, 25, 64; \rho)$. On peut dire que l'espérance de $Y | X = 8$ dépend de la valeur de ρ .

Chapitre 5

Statistiques descriptives

Exercice 5.1

On a mesuré, par un processus de vieillissement accéléré, la durée de vie (en mois) d'un échantillon de 24 composantes d'un certain type. Les résultats (ordonnés) sont les suivants.

1,0	2,0	3,0	5,0	5,5	6,0	6,2	6,8	7,5	7,7	8,0	9,0
10,0	11,0	13,0	14,0	14,5	14,6	14,8	14,9	15,0	17,0	18,0	19,0

- (a) Trouver la médiane, le premier quartile et le troisième quartile de ces données.
- (b) Construire le diagramme en boîte pour cet échantillon.
- (c) Compléter le tableau de distribution de fréquences ci-dessous.

Classe	Fréquence	Fréquence relative
[0, 4[		
[4, 8[		
[8, 12[		
[12, 16[		
[16, 20[		

- (d) Construire l'histogramme correspondant au tableau obtenu en (c), avec un axe vertical représentant la densité. Que vaut la surface totale des rectangles?
- (e) À la lumière des graphiques en (b) et (d), la loi normale semble-t-elle un bon modèle pour cet ensemble de données? *Utilisez la terminologie appropriée.*

Exercice 5.2

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) Si l'écart-type d'un échantillon est nul, c'est que toutes les observations valent 0.
- (b) L'écart-type, la variance et la covariance sont des mesures permettant d'évaluer la dispersion des valeurs dans une distribution.
- (c) Les valeurs minimale et maximale d'un jeu de données peuvent toujours être identifiées sur un diagramme en boîte.

Chapitre 6

Loi échantillonnale et estimation ponctuelle

Exercice 6.1

Soit $\{X_1, X_2, \dots, X_n\}$ des variables aléatoires indépendantes telles que $X_i \sim N(\mu, \sigma^2)$ pour $i = 1, 2, \dots, n$. Trouver la taille d'échantillon n requise pour avoir

$$P\left(|\bar{X} - \mu| < \frac{\sqrt{\sigma^2}}{4}\right) = 0,95,$$

où $\bar{X} = \sum_{i=1}^n X_i/n$.

Chapitre 7

Intervalles de confiance

Exercice 7.1

Vous recueillez 10 échantillons de l'eau rejetée par votre usine ABC. Soit $x_{ABC,1}, \dots, x_{ABC,10}$, les concentrations en plomb (en ppm) de ces échantillons. On vous dit que leur moyenne échantillonnale est 1,5 ppm et que leur variance échantillonnale est 0,25 ppm². On suppose que ces échantillons sont indépendants et identiquement distribués de loi normale de moyenne et de variance inconnues.

Donnez un intervalle de confiance à 99 % pour la concentration moyenne de l'eau rejetée par l'usine ABC.

Exercice 7.2

À la réception de colis, un responsable doute de l'exactitude des masses affichées sur les boîtes. Il prélève 25 boîtes au hasard, les pèse et soumet ses résultats à Rcmdr qui produit la sortie ci-dessous. On supposera que les masses des boîtes suivent une loi normale.

```
> numSummary(boite[, "masse", drop=FALSE], statistics=c("mean", "sd", "se(mean)",
  "IQR", "quantiles"), quantiles=c(0, .25, .5, .75, 1))
  mean      sd se(mean)  IQR  0% 25%  50%  75% 100%  n
1.9728  0.0912   0.0182 0.12 1.8 1.9 1.99 2.02 2.18 25

> with(boite, (t.test(masse, alternative='two.sided', mu=2, conf.level=.9)))

      One Sample t-test

data:  masse
t = -1.491, df = 24, p-value = 0.149
alternative hypothesis: true mean is not equal to 2
90 percent confidence interval:
 1.942    2.004
sample estimates:
mean of x
 1.973
```

- (a) Quelle est la marge d'erreur associée à l'estimation de la masse moyenne, pour un niveau de confiance de 90 % ?
- (b) Pour quel niveau de confiance a-t-on un intervalle de confiance pour l'écart-type des masses des boîtes de $[0,0712; 0,1269]$?

Exercice 7.3

La manufacture pour laquelle vous travaillez produit des essieux. La chaîne de production A produit présentement des essieux pour votre client qui exige que la variance du diamètre des essieux ne dépasse pas 1 mm². Votre client vient vous voir en se plaignant d'une trop grande variabilité dans le diamètre des derniers essieux livrés. Vous allez avec le client et sélectionnez 15 essieux au hasard à la sortie de la chaîne de production A. Vous mesurez les diamètres de ces essieux, que l'on suppose indépendants et distribués selon une loi normale de moyenne et de variance inconnues, et obtenez une variance échantillonnale de 1,75 mm².

Donnez un intervalle de confiance à 95 % pour la variance du diamètre des essieux produits.

Exercice 7.4

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) Lors d'une estimation par intervalle de confiance, les limites de l'intervalle sont des constantes de la population.
- (b) Dans une loi de Student, la médiane théorique est toujours inférieure à la moyenne théorique.
- (c) Une compagnie de transport a fait calculer un intervalle de confiance à 95 % pour le nombre moyen de kilomètres parcourus par ses véhicules en une semaine et a obtenu $[62\,050 ; 74\,110]$. On peut dire qu'il y a 95 % de chances que les véhicules de la compagnie parcourent entre 62 050 et 74 110 km la semaine prochaine.

Chapitre 8.1

Tests d'hypothèses : un échantillon

Exercice 8.1.1

On reprend le contexte de l'exercice 2 (masses de 25 boîtes, sortie Rcmdr reproduite ci-dessous).

```
> with(boite, (t.test(masse, alternative='two.sided', mu=2, conf.level=.9)))  
  
One Sample t-test  
  
data: masse  
t = -1.491, df = 24, p-value = 0.149  
alternative hypothesis: true mean is not equal to 2  
90 percent confidence interval:  
 1.942    2.004  
sample estimates:  
mean of x  
 1.973
```

- (a) Sachant que la masse affichée sur chaque boîte est de 2 kg, les doutes du responsable sont-ils justifiés, au seuil de 10 % ?
- (b) Comment le seuil observé du test ci-dessus a-t-il été calculé ? Écrivez précisément la probabilité en question.

Exercice 8.1.2

Un chercheur s'intéresse à la moyenne μ d'une certaine variable X distribuée suivant une loi normale de variance 4. Il veut tester les hypothèses suivantes :


$$H_0 : \mu = 5 \quad \text{contre} \quad H_1 : \mu > 5.$$

Il a prélevé un échantillon aléatoire de taille $n = 16$ et a obtenu une moyenne égale à 6,2.


- (a) La statistique de test et sa loi sous H_0 sont

$$\square \frac{\bar{X} - 5}{\sigma/\sqrt{n}} \sim N(0, 1) \quad \square \frac{\bar{X} - 5}{\sigma/\sqrt{n}} \sim t_{n-1} \quad \square \frac{\bar{X} - 5}{S/\sqrt{n}} \sim N(0, 1) \quad \square \frac{\bar{X} - 5}{S/\sqrt{n}} \sim t_{n-1}$$

- (b) Dans la figure ci-dessous, identifiez la valeur critique de la moyenne échantillonnale au seuil $\alpha = 10\%$ et hachurez la surface correspondant à ce seuil.



- (c) Évaluez la valeur P (seuil observé) et hachurez la zone correspondante sur la figure ci-dessus.
- (d) Supposons qu'en réalité, la vraie moyenne est égale à 6,5. Hachurez la zone associée à la puissance du test dans la figure ci-dessous.



Exercice 8.1.3

On reprend le contexte de l'exercice 3 (diamètres de 15 essieux, $s^2 = 1,75 \text{ mm}^2$; le client exige que la variance ne dépasse pas 1 mm^2).

- (a) Y a-t-il de l'évidence au seuil de 5 % que le client a raison et que la variance excède 1 mm^2 ?
- (b) Quel est le plus petit seuil à partir duquel on peut rejeter l'hypothèse nulle en (a) ?
- (c) Que vaut la probabilité d'erreur de type II si la vraie variance des diamètres est de 2 mm^2 ?

Exercice 8.1.4

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) Lors d'un test d'hypothèses, plus le seuil observé est faible, plus notre échantillon semble plausible sous H_0 .
- (b) La puissance d'un test d'hypothèses augmente lorsqu'on augmente la taille de l'échantillon (si rien d'autre ne change).
- (c) Dans un test d'hypothèses, on rejette toujours l'hypothèse nulle si le seuil observé (p-value) est plus grand que le seuil du test.
- (d) On teste l'hypothèse $H_0 : \sigma^2 = 4$ contre $H_1 : \sigma^2 \neq 4$ et on obtient un seuil observé de 0,1433. On peut dire que l'intervalle de confiance à 90 % pour la variance ne contient pas la valeur 4.
- (e) On construit un intervalle de confiance à 95 % pour la durée moyenne (en minutes) d'un appel au service à la clientèle et on obtient : $[6,3 ; 8,1]$. On peut dire qu'au seuil de 5 %, on rejette l'hypothèse que $\mu = 6$, au profit de l'hypothèse alternative $\mu \neq 6$.

Chapitre 8.2

Tests d'hypothèses : deux échantillons

Exercice 8.2.1

On reprend le contexte de l'exercice 1 (10 échantillons d'eau de l'usine ABC : $\bar{x}_{ABC} = 1,5$ ppm, $s_{ABC}^2 = 0,25$ ppm²).

- (a) Vous recueillez 10 échantillons d'eau de votre usine XYZ, disons $x_{XYZ,1}, \dots, x_{XYZ,10}$, dont la moyenne échantillonnale est 1,6 ppm et la variance échantillonnale est 0,22 ppm². On suppose aussi que ces échantillons proviennent d'une population normale de moyenne et de variance inconnues. Testez, au seuil de 5 %, si les variances des concentrations échantillonnées dans l'eau rejetée par les deux usines sont égales.
- (b) En supposant les variances égales, a-t-on suffisamment d'évidence, au seuil de 5 %, pour dire que la concentration en plomb dans l'eau rejetée par l'usine ABC est inférieure à celle de l'eau rejetée par l'usine XYZ en moyenne ?

Exercice 8.2.2

Nous avons mesuré des arbres debout par une méthode trigonométrique. Pour vérifier la fiabilité de la méthode, les mêmes arbres ont été à nouveau mesurés, mais au sol après abattage. Les tailles en mètres pour six arbres et pour les deux méthodes de mesure sont données dans le tableau suivant :

Arbre	1	2	3	4	5	6
Debout	20	25	25	25	26	28
Abattu	21	26	26	28	26	27

On admet que la variable étudiée est normalement distribuée.

- (a) Ces résultats permettent-ils de dire, au niveau de signification $\alpha = 0,01$, que la méthode trigonométrique sous-estime les longueurs des arbres par rapport à la mesure des arbres abattus ?
- (b) Quel est le seuil observé du test ?

Exercice 8.2.3


Vous voulez recruter dans votre équipe le golfeur dont la longueur des coups de départ est la moins variable entre Tiger et Rory. Vous pensez qu'il s'agit de Tiger mais pour être certain vous les mettez à l'essai : Tiger frappe 9 coups de départ alors que Rory en frappe 7. L'écart-type échantillonnal de la longueur des coups de départ frappés par Tiger est de 8 verges alors que l'écart-type échantillonnal des coups de départ frappés par Rory est de 10 verges. Au seuil de 5 %, peut-on conclure que les coups de départ de Tiger sont moins variables que ceux de Rory ?

Exercice 8.2.4

Pour la conception de nouveaux circuits électriques, on souhaite comparer les résistances de deux types de composants électriques. On prend alors un échantillon de composants de chaque type et on teste leurs résistances (en ohms, notés Ω). Voici un résumé de la collecte de données.

Échantillons	Taille	Moyenne	Écart-type
Type 1	10	404,6 Ω	9,23 Ω
Type 2	10	395,2 Ω	6,07 Ω

On a soumis les données aux commandes de la fenêtre de gauche ci-dessous, puis on a obtenu les résultats présentés dans la fenêtre de droite.



On considère que la loi normale est un modèle acceptable pour la résistance des composants. On choisit de faire toutes les analyses au seuil de 10 %.

- (a) Pour comparer statistiquement les résistances *moyennes* des composants de type 1 et de type 2, lequel des tests suivants serait le plus adéquat ? Pourquoi ?
- ☐ Le test de Student pour des données appariées (t_{n-1})
 - ☐ Le test de Student pour échantillons indépendants, où on considère que $\sigma_1^2 = \sigma_2^2$ ($t_{n_1+n_2-2}$)
 - ☐ Le test de Welch pour échantillons indépendants, où on considère que $\sigma_1^2 \neq \sigma_2^2$ (t_v^*)
 - ☐ Le test de Fisher pour échantillons indépendants (F_{n_1-1, n_2-1})

Justifiez votre choix, en précisant les valeurs numériques que vous interprétez (s'il y a lieu).

- (b) Au seuil de 10 %, peut-on dire que la résistance des composants de type 1 diffère de celle des composants de type 2 en moyenne ? Répondre à la question en détaillant toutes les étapes d'un test d'hypothèses.

Raccourcis de calculs selon le type d'analyse que vous avez choisi :

- Données appariées : utilisez la variance $s_D^2 = 9,51^2$
- Test de Student : utilisez la variance $s_p^2 = 7,81^2$
- Test de Welch : utilisez les degrés de liberté $v = 16$

- (c) Quelle est la valeur P (seuil observé) du test réalisé à la question précédente ? (Donnez un intervalle de valeurs le plus précis possible en fonction des tables de lois dont vous disposez. Écrivez clairement la probabilité calculée, ainsi que sa valeur.)

Exercice 8.2.5

Déterminez si l'énoncé suivant est vrai ou faux.

- (a) Il est avantageux d'utiliser l'appariement dans une expérience quand les unités expérimentales sont homogènes.

Chapitre 9

Analyse de la variance (ANOVA)

Exercice 9.1

Pour chacune des situations suivantes, choisissez le type d'analyse statistique approprié. Identifiez les variables (en considérant que toutes les variables spécifiées sont incluses dans le modèle), et le nombre de degrés de liberté associés à l'erreur.

- (a) Vous souhaitez comparer la consommation d'essence de 3 modèles de voiture. Vous n'êtes pas intéressé par la variation de la consommation d'essence entre les conducteurs, mais vous vous attendez à ce que le style de conduite ait un effet important sur la consommation d'essence. Vous planifiez une expérience où 5 personnes conduisent (une fois chacune) les voitures des trois modèles sur un circuit déterminé, dans un ordre aléatoire. Chaque essai est réalisé sur le même parcours dans des conditions de température et d'état de la chaussée similaires.
- (b) Depuis 24 ans, un cultivateur note le rendement (en kg/hectare) de ses cultures de blé, la quantité de pluie reçue chaque mois ainsi que la température moyenne de chaque mois. Vous souhaitez utiliser ses données pour construire un modèle qui lui permettra de prédire le rendement de ses cultures de blé en fonction de la température moyenne des mois de juin et juillet, et de la quantité de pluie reçue en juin et en juillet.
- (c) Vous voulez vérifier l'effet de la profondeur du sol et l'effet de la topographie du site sur la quantité de phosphore dans le sol. Vous vous attendez à ce que l'effet de la profondeur varie selon la topographie, et vous tenez à ce que votre modèle en tienne compte. Vous sélectionnez 15 sites où la topographie est plane et 15 sites où la topographie est en pente.
 - 5 sites planes sont choisis au hasard : sur chacun, vous prendrez un échantillon de sol à 5 cm de profondeur et en mesurerez le phosphore ;
 - 5 autres sites planes sont choisis au hasard : sur chacun, vous prendrez un échantillon de sol à 10 cm de profondeur et en mesurerez le phosphore ;
 - sur les 5 sites planes restants, vous prendrez un échantillon de sol à 20 cm de profondeur et en mesurerez le phosphore ;
 - vous répéterez les 3 étapes ci-dessus pour les 15 sites en pente ;
 - les 30 mesures de phosphore décrites ci-dessus seront prises dans un ordre aléatoire.
- (d) Un inspecteur en alimentation se demande si la quantité de pesticides sur les fruits et légumes que l'on retrouve sur le marché est associée à la taille des fermes maraîchères. En juillet, il visite 15 producteurs de fraises québécois choisis aléatoirement. Pour chacun, il analyse la quantité de pesticides dans un panier de fraises, et la met en relation avec les ventes de fraises de l'année précédente de ce producteur.

Exercice 9.2

Votre manufacture produit des tiges métalliques qui sont utilisées dans la confection de prothèses. La résistance de ces tiges à la torsion est une propriété très importante. Vous désirez savoir si le type d'alliage utilisé pour produire les tiges a un effet sur leur résistance à la torsion. À partir de chacun de trois types d'alliage (1, 2 et 3), vous produisez quatre tiges et les soumettez à un test de torsion. Soit Y_{ij} , la torsion (en Nm) menant à la rupture de la tige j produite avec l'alliage i . Le tableau ci-dessous vous donne la valeur observée y_{ij} pour chacune des 12 tiges testées.

Alliage i	Torsion de rupture (en Nm)				Somme $y_{i\bullet}$	Moyenne $\bar{y}_{i\bullet}$
	Tige 1	Tige 2	Tige 3	Tige 4		
1	510	490	520	480	2 000	500
2	500	510	540	530	2 080	520
3	500	490	470	460	1 920	480
Total					$y_{\bullet\bullet} = 6\,000$	$\bar{y}_{\bullet\bullet} = 500$

Supposons que le modèle d'analyse de la variance

$$(*) \quad Y_{ij} = \mu + \tau_i + E_{ij}, \quad i = 1, \dots, 3, \quad j = 1, \dots, 4,$$

avec les E_{ij} indépendantes de loi $N(0, \sigma^2)$ est un modèle adéquat.

(a) Dans le modèle (*) d'analyse de la variance ci-dessus, τ_2 représente

- ☐ la torsion de rupture moyenne des tiges produites avec l'alliage 2 ;
- ☐ la torsion de rupture moyenne de la deuxième tige produite avec les trois alliages ;
- ☐ la différence entre la torsion de rupture moyenne des tiges produites avec l'alliage 2 et la torsion de rupture moyenne de l'ensemble des tiges produites avec les trois alliages.

(b) Une estimation de la valeur de τ_2 est donnée par :

(c) En plus de l'information du tableau ci-dessus, on vous donne

$$\sum_{i=1}^3 \sum_{j=1}^4 y_{ij}^2 = 3\,006\,200 \quad \text{et} \quad SSE = 3\,000.$$

Construisez le tableau d'analyse de la variance. Au seuil de 5 %, est-ce que le type d'alliage a un effet significatif sur la torsion de rupture ?

(d) Supposons qu'à l'étape précédente, vous avez conclu qu'il existait des différences significatives entre les moyennes, en général. Pouvez-vous déterminer au seuil de 5 % quels alliages précisément diffèrent les uns des autres ?

Exercice 9.3

On effectue une expérience afin de déterminer si le type de suspension a un effet sur la distance de freinage d'un prototype de voiture. Comme la distance de freinage peut varier beaucoup en fonction de la température et du niveau d'humidité, on décide de mener l'expérience sur 5 jours différents, toujours avec le même conducteur. À chaque jour, on testera les 3 types de suspension, une fois chacun, en amenant la voiture à 120 km/h, en appliquant les freins et en mesurant la distance de freinage.

(a) Dites lequel parmi la distance de freinage, le jour, le conducteur et le type de suspension correspond au facteur, au bloc et à la variable réponse.

Les questions (b) à (d) portent sur l'extrait de sortie R Commander ci-dessous, qui donne les résultats d'une analyse de la variance avec blocs aléatoires faite sur les données décrites ci-dessus.

Anova Table (Type II tests)

Response: Distance

	Sum Sq	Df	F value	Pr(>F)
Suspension	169.41	AAAAA	DDDDD	0.02418 *
Jour	2338.66	BBBBB	EEEEEE	1.984e-05 ***
Residuals	110.31	CCCCC		





- (b) Des valeurs ont été effacées dans la sortie et remplacées par AAAAA,BBBBB, etc. Trouvez ces valeurs manquantes.
- (c) Le type de suspension a-t-il un effet significatif sur la distance de freinage au seuil de 1 % ?
- (d) À la lumière des résultats obtenus, est-ce qu'utiliser une expérience par blocs aléatoires était une bonne idée ?


Exercice 9.4

Un kinésologue conduit une expérience visant à déterminer si la méthode d'entraînement (méthode A ou B) et le type de diète (diète 1 ou 2) a un impact sur le poids que des haltérophiles peuvent soulever. Il recrute 16 haltérophiles à peu près de même stature et qui soulèvent le même poids maximal. On les assigne aléatoirement à l'une des 4 combinaisons méthode-diète et on les soumet à l'entraînement et à la diète pendant une saison. À la fin de la saison, on mesure le poids maximal qu'ils sont capables de soulever.

Associez chacun des scénarios ci-dessous au graphique des moyennes qui lui correspond.

- (i) Ni la méthode d'entraînement, ni la diète n'ont un effet sur le poids soulevé.
- (ii) Seule la méthode d'entraînement a un effet sur le poids soulevé.
- (iii) Seule la diète a un effet sur le poids soulevé.
- (iv) La méthode d'entraînement et la diète ont un effet sur le poids soulevé, mais il n'y a pas d'interaction entre ces deux facteurs.
- (v) Il y a une interaction entre la diète et la méthode d'entraînement, donc forcément ces deux facteurs ont un effet sur le poids soulevé.











Exercice 9.5

Vous effectuez une expérience à un facteur et voulez vous assurer que les postulats émis sur les termes d'erreur sont raisonnablement respectés. Déterminez lequel/lesquels des graphiques correspond(ent) à chaque énoncé.

- (a) La variance des termes d'erreur n'est pas homogène :
- (b) La variance des termes d'erreur est homogène :
- (c) La normalité des termes d'erreur est respectée :
- (d) Les termes d'erreur ne suivent pas une loi normale :





Exercice 9.6

Déterminez si les énoncés suivants sont vrais ou faux.

- Dans un modèle d'analyse de la variance à un facteur, le paramètre σ^2 représente la variance des Y_{ij} autour de la moyenne globale μ .
- Dans un plan à blocs aléatoires, on considère que les observations d'un même bloc sont dépendantes, et que les observations de blocs différents sont indépendantes.
- On pige $n = 5$ observations dans chacune des 3 populations suivantes : $N(12, 3)$, $N(15, 3)$, $N(18, 3)$. On calcule la statistique F_1 de la table d'anova. On pige $n = 5$ observations dans chacune des 3 populations suivantes : $N(12, 15)$, $N(15, 15)$, $N(18, 15)$. On calcule la statistique F_2 de la table d'anova. La valeur de F_1 aura tendance à être plus faible que F_2 .
- Dans un modèle d'analyse de la variance à deux facteurs, si on obtient la table d'anova suivante, on conclura que seul le facteur A a un effet sur la valeur de Y .

Anova Table (Type II tests)

Response: Reponse

Sum Sq	Df	F value	Pr(>F)
--------	----	---------	--------

FacteurA	100.33	2	7.525	0.004216	**
FacteurB	13.50	1	2.025	0.171830	
FacteurA:FacteurB	688.00	2	51.600	3.515e-08	***
Residuals	120.00	18			

(e) L'analyse de variance précédente a été faite à partir de 19 observations.

Chapitre 10

Régression linéaire simple

Exercice 10.1

Pour estimer les stocks excédentaires de l'année courante, une entreprise fabriquant des pneus a tiré au hasard 6 détaillants chez qui elle vend ses produits ; ceux-ci ont fourni les chiffres de l'inventaire de l'année passée à pareille date (X) et l'inventaire actuel (Y) reproduits dans le tableau suivant :

X	70	260	150	100	20	60
Y	60	320	230	120	50	60

On donne les sommes suivantes :

$$\sum_{i=1}^6 x_i = 660, \quad \sum_{i=1}^6 y_i = 840, \quad \sum_{i=1}^6 x_i^2 = 109\,000, \quad \sum_{i=1}^6 y_i^2 = 179\,400, \quad \sum_{i=1}^6 x_i y_i = 138\,500.$$

- (a) Trouver l'équation de la droite de régression et interpréter la valeur de $\hat{\beta}_1$ dans le contexte de ce problème.
- (b) Construire la table d'analyse de la variance.
- (c) Déterminer s'il existe une relation linéaire significative entre les inventaires de cette année et de l'année passée au seuil $\alpha = 5\%$.
- (d) Calculer la proportion de variabilité de l'inventaire de cette année expliquée par celui de l'année passée.


Exercice 10.2

On a ajusté un modèle de régression linéaire simple pour le prix de vente d'une maison (en milliers de \$) en fonction de l'évaluation de cette maison (en milliers de \$) à l'aide d'un jeu de données de 25 observations. On a obtenu les valeurs suivantes :

$$\hat{\beta}_0 = 20,94 \quad \hat{\beta}_1 = 1,07 \quad \hat{\sigma}^2 = MSE = 1075.$$

De plus, on vous indique que $\bar{x} = 201,75$ et $S_{xx} = 5\,209\,571$.



- (a) Quel est le prix de vente moyen pour les maisons évaluées à 200 000 \$?
- (b) Un ami vient de mettre sa maison en vente, évaluée à 280 000 \$. Construisez un intervalle à 95 % pour le prix de vente de sa maison.
- (c) On veut maintenant vérifier la validité des postulats du modèle de régression. Parmi les graphiques ci-dessous, lequel permet de valider le postulat de normalité des erreurs ? Qu'en déduisez-vous ?







Exercice 10.3

Vous effectuez une analyse de régression et voulez vous assurer que les postulats émis sur les termes d'erreur sont raisonnables. Déterminez lequel/lesquels des graphiques correspond(ent) à chaque énoncé. S'il s'agit d'un problème avec l'un des postulats, suggérez une solution.

- (a) La linéarité de la relation X - Y est respectée :
- (b) La linéarité de la relation X - Y n'est pas respectée :
- (c) Il y a homoscédasticité :
- (d) Il y a hétéroscédasticité :
- (e) La normalité des erreurs est respectée :
- (f) La normalité des erreurs n'est pas respectée :





Exercice 10.4

Déterminez si les énoncés suivants sont vrais ou faux.

- Si tous les points $(x_1, y_1), \dots, (x_9, y_9)$ sont parfaitement alignés selon une droite de pente positive, alors on sait que $\hat{\beta}_1 = 1$, $SSE = 0$ et $r = 1$.
- Supposons que le modèle $Y \sim N(\beta_0 + \beta_1 X, \sigma^2)$ décrit bien la relation entre Y et X . Alors les prédictions de Y pour $X = x_0$ seront plus précises si on choisit des x_i très dispersés, une grande taille d'échantillon, et une valeur x_0 assez proche de $\bar{x}$.

Chapitre 11

Régression linéaire multiple

Exercice 11.1

On cherche à construire un modèle pour expliquer et prédire Y , la consommation d'électricité (en kWh), des maisons unifamiliales d'une région. Les variables explicatives disponibles sont X_1 , le nombre d'habitants ; X_2 , la superficie habitable (en milliers de pieds carrés) ; X_3 , le revenu annuel du ménage (en milliers de dollars) et X_4 , le montant annuel de la taxe foncière (en milliers de dollars).

On recueille des données pour 25 maisons unifamiliales de cette région et on ajuste un modèle de régression linéaire multiple à nos observations. Après vérification, les postulats du modèle semblent raisonnablement respectés. Un extrait de la sortie R Commander obtenue est donné ci-dessous.

```
> summary(RegModel.2)
```

Coefficients:


	Estimate	Std. Error
(Intercept)	57.80968	9.92327
X1	6.61733	0.95758
X2	28.46419	8.40441
X3	0.05516	0.14109
X4	4.48517	8.30631

Residual standard error: 4.378 on 20 degrees of freedom

Multiple R-squared: 0.9072, Adjusted R-squared: 0.8886

F-statistic: 48.88 on 4 and 20 DF, p-value: 4.773e-10

- (a) Peut-on conclure qu'au moins une des quatre variables explicatives est significative, au seuil de 5 % ?
- (b) Donnez une estimation ponctuelle et un intervalle de confiance à 95 % pour l'effet d'une hausse de la superficie habitable de 1 millier de pieds carrés sur la consommation d'électricité espérée, toute autre variable explicative restant inchangée.
- (c) Le graphique ci-dessous permet de sélectionner le meilleur sous-modèle selon le critère du $R^2_{ajusté}$ produit par R Commander. Selon ce graphique, quelles variables explicatives sont retenues dans le meilleur sous-modèle selon le critère $R^2_{ajusté}$?



Exercice 11.2

Une étude est menée dans l'espoir de trouver la bonne quantité d'un catalyseur à ajouter à un procédé afin de maximiser la qualité du produit obtenu. On répète une expérience 20 fois et on obtient les résultats suivants :

- Y_i , un indice de qualité du produit final lors de l'expérience i (plus Y_i est élevé, meilleur est le produit),
- C_i , la quantité de catalyseur utilisée lors de l'expérience i et
- P_i , la quantité de pétrole utilisée dans l'expérience i .

Après discussion avec vos collègues et une revue de la littérature, vous ajustez le modèle de régression linéaire multiple ci-dessous à vos données, pour lequel les 4 postulats usuels s'avèrent raisonnables :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + E_i, \quad i = 1, \dots, 20,$$

où $X_{i1} = C_i$, $X_{i2} = C_i^2$, $X_{i3} = P_i$ et les E_i sont des termes d'erreur i.i.d. $N(0, \sigma^2)$. Voici la sortie R Commander, où quelques valeurs sont remplacées par AAAAAA, BBBBBB, etc.

```
lm(formula = Y ~ X1 + X2 + X3, data = Qualite)
Residuals:
    Min       1Q   Median       3Q      Max
-7.5562 -2.7782  0.1606  4.1300  6.6078
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 113.13496   38.09154   2.970  0.00903 **
X1           8.86398    3.15453   2.810  0.01258 *
X2          -0.17704    0.06996  -2.531  0.02226 *
X3           9.99053    0.48986  20.395 7.08e-13 ***
---
Residual standard error: 4.612 on 16 degrees of freedom
Multiple R-squared: AAAAAA,    Adjusted R-squared: BBBBBB
F-statistic: CCCCCC on DDDDD and EEEEE DF,  p-value: 3.415e-12
```

- (a) Donnez une estimation de la quantité de catalyseur qui maximise l'indice de qualité espéré, lorsque la quantité de pétrole est égale à 3 unités.
- (b) Avant l'expérience, un de vos collègues avait dit qu'une hausse d'une unité de la quantité de pétrole hausserait l'indice de qualité espéré d'au moins 9 unités. Les données supportent-elles l'hypothèse de votre collègue au seuil de 5 % ?
- (c) Sachant que $SST = 10\,701,3$, trouvez les valeurs manquantes AAAAA, BBBB, etc.
- (d) Le tableau ci-dessous donne la liste de tous les sous-modèles possibles (chacun incluant une ordonnée à l'origine), ainsi que leur $R^2_{ajusté}$. Quel est le meilleur modèle selon ce critère ?

Sous-modèle	X_1, X_2, X_3	X_1, X_2	X_1, X_3	X_2, X_3	X_1	X_2	X_3
$R^2_{ajusté}$	0,962	0,041	0,955	0,950	0,0001	0,005	0,920

Exercice 11.3

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) Le meilleur modèle de régression à 3 variables explicatives est celui comprenant les 3 variables les plus corrélées avec la variable réponse Y .
- (b) Plus on ajoute de variables explicatives à un modèle de régression, plus la valeur de SSE diminue.