

Introduction

Jusqu'à maintenant, nous avons calculé des probabilités en se basant sur des distributions considérées comme connues.

ex: la masse des oranges suit une loi normale de moyenne 204 et de variance 256.

En pratique, on connaît rarement la distribution exacte d'une variable.

Démarche générale

→ INDÉPENDANTES

- ① On tire un échantillon aléatoire de n mesures dans une population.
- ② On identifie (par expérience ou par statistique descriptive) une loi de probabilité qui s'appliquerait bien à notre phénomène aléatoire.
- ③ Ce modèle s'accompagne généralement de paramètres, constants mais **inconnus**: il faudra les **estimer** à partir de l'échantillon.

Exemples

- Le diamètre des cellules hépatiques pourrait suivre une loi $N(\mu, \sigma^2)$. On veut estimer les paramètres μ et σ^2 .
- Le nombre de spécimens infectés (parmi n) suit une loi Binomiale(n, p). On veut estimer le paramètre p .

Notation

PAR EXEMPLE
 μ, σ^2, p

TAILLE INFINIE

TAILLE FINIE / CE QUE J'OBSERVE

MAJUSCULES
VARIABLES ALÉATOIRES

- Population et échantillon
- Variables aléatoires de l'échantillon: $X_1, X_2, \dots, X_n$
- Valeurs observées de l'échantillon: $x_1, x_2, \dots, x_n$
- Paramètre: constante de la population à estimer
- Estimateur : Fonction des $X_1, X_2, \dots, X_n$ qui estime le paramètre
↳ V.A.
- Estimation ponctuelle : Fonction des $x_1, x_2, \dots, x_n$ (val. observée de l'estimateur)

MINUSCULES
CE SONT DES NOMBRES

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \bar{X} \text{ EST UNE V.A.}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \rightarrow \bar{x} \text{ EST UNE RÉALISATION DE } \bar{X}$$

Estimateur

L'estimateur est une fonction des données, c'est donc une variable aléatoire. . . avec une distribution, une espérance et une variance.

La racine carrée de cette variance s'appelle l'erreur type.

Paramètre	Estimateur	Estimation	Espérance	Erreur type
μ	$\bar{X}$	$\bar{x}$		
σ^2	S^2	s^2		
p	$\hat{p}$	$\hat{p}$ ou $\hat{p}_{obs}$		

Qualités d'une bonne estimation

Une bonne estimation est

- Sans biais
- Précise


• PARAMÈTRE

• ESTIMATIONS À
PARTIR DE PLUSIEURS
ÉCHANTILLONS




MOINS
PRÉCIS

PLUS
PRÉCIS

SANS
BIAS



AVEC BIAS



Le biais

Θ PEUT ÊTRE $\mu, \sigma^2, \rho, \dots$

- Point de vue, parfois un préjugé (pas en lien avec le cours)
- Biais de sélection (probablement le plus difficile à gérer en pratique)
- Biais de l'estimateur (celui des notes de cours p.83)

SOIT $\hat{\Theta}$ UN ESTIMATEUR DE Θ

$$\text{BIAS}(\hat{\Theta}, \Theta) = E[\hat{\Theta}] - \Theta$$

IDÉALEMENT $\text{BIAS}(\hat{\Theta}, \Theta) = 0 \rightarrow E[\hat{\Theta}] = \Theta$

$\bar{X}$ EST L'ESTIMATEUR DE μ
($\hat{\theta}$) (θ)

1: $X_1, \dots, X_n \rightarrow \bar{X}_1$

2: $X_1, \dots, X_n \rightarrow \bar{X}_2$

⋮

N: $X_1, \dots, X_n \rightarrow \bar{X}_N$

$E[\bar{X}]$ REPRÉSENTE
LA MOYENNE DE $\bar{X}_1, \dots, \bar{X}_N$
SI $N \rightarrow \infty$

La précision

En général, vous aurez deux façon d'intervenir sur la précision de vos estimations¹

- ① Choisir un estimateur de faible variance
- ② Augmenter la taille de l'échantillon

↳ RELIÉE À LA VARIANCE DE L'ESTIMATEUR
↳ IDÉALEMENT EN $\frac{1}{n}$

¹Du moins, pour les techniques vues dans ce cours.

Exemple 1

On peut supposer que la pression artérielle systolique (en mm Hg) suit une loi normale. On a recueilli chez 7 individus ~~normaux~~ les mesures suivantes:

EN SANTÉ

141, 130, 135, 138, 137, 122, 135

Estimateur de la moyenne μ

En général, on estime la moyenne μ avec la moyenne échantillonnale.

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

Pour l'exemple 1, on obtient une **estimation** de 134.

↳ $\bar{x}$

Retour sur l'exemple 1

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

On peut supposer que la pression artérielle systolique (en mm Hg) suit une loi normale. On a recueilli chez 7 individus normaux les mesures suivantes:

Répétition	x1	x2	x3	x4	x5	x6	x7	$\bar{x}$ Moyenne
1	141	130	135	138	137	122	135	134

7 RÉALISATION DE
 $X \sim \mathcal{N}(\mu, \sigma^2)$

↓
1 RÉALISATION
DE $\bar{X}$

11 FOIS 7 RÉALISATIONS DE $X \sim N(\mu, \sigma^2)$

Exemple 1 (suite)

11 FOIS 1 RÉALISATION DE $\bar{X}$


En supposant que la vraie moyenne soit de 133 et que la vraie variance soit de 6^2 . Si on avait choisi 7 autres personnes...

MOINS
DISPERSÉE
QUE LES
 X_i

Répétition	x1	x2	x3	x4	x5	x6	x7	Moyenne $\bar{X}_i$
1	141	130	135	138	137	122	135	134
2	132	128	139	133	132	127	138	133
3	140	125	122	126	136	128	131	130
4	131	137	136	130	140	134	124	133
5	143	125	131	121	139	150	131	134
6	132	140	128	136	141	135	140	136
7	135	143	134	133	138	123	134	134
8	139	144	120	127	138	137	140	135
9	133	139	136	137	135	133	140	136
10	140	136	131	133	128	143	134	135
11	126	134	139	141	132	143	135	136

Distribution de X


Toujours en supposant que la pression systolique suit vraiment une $\mathcal{N}(133, 6^2)$...



— 1 — Distribution des données

Distribution de $\bar{X}$

L'histogramme suivant présente la distribution de la moyenne de 1000 échantillons de taille 7.



— 1 – Distribution des données — 2 – Distribution de la moyenne

Espérance de l'estimateur de la moyenne

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

$$E[aX] = aE[X]$$

$$\begin{aligned}
 \mathbb{E}[\bar{X}] &= \mathbb{E}\left[\frac{X_1 + X_2 + \dots + X_n}{n}\right] \\
 &= \frac{1}{n} \mathbb{E}[X_1 + X_2 + \dots + X_n] \\
 &= \frac{1}{n} (\mathbb{E}[X_1] + \mathbb{E}[X_2] + \dots + \mathbb{E}[X_n]) \\
 &= \frac{1}{n} (\underbrace{\mu + \mu + \dots + \mu}_{n\mu}) = \mu
 \end{aligned}$$

$\bar{X}$ EST
SANS BIAIS
POUR μ

Variance de l'estimateur de la moyenne

$$X \sim N(\mu, \sigma^2)$$

$$\text{Var}[aX] = a^2 \text{Var}[X]$$

$$\begin{aligned} \text{Var}[\bar{X}] &= \text{Var}\left[\frac{X_1 + X_2 + \dots + X_n}{n}\right] \\ &= \frac{1}{n^2} \text{Var}[X_1 + X_2 + \dots + X_n] \\ &= \frac{1}{n^2} (\text{Var}[X_1] + \text{Var}[X_2] + \dots + \text{Var}[X_n]) \\ &= \frac{1}{n^2} (\underbrace{\sigma^2 + \sigma^2 + \dots + \sigma^2}_{n\sigma^2}) = \frac{\sigma^2}{n} \end{aligned}$$

LA VARIANCE
DE $\bar{X}$ ↓
QUAND n ↑

LA PRÉCISION
DE $\bar{X}$ ↑
QUAND n ↑

Hummm, nous avons un problème: nous ne connaissons pas σ^2 .

↓
TOUJOURS LE
TEMPS

→ ON VA L'ESTIMER

Estimation de la variance (σ^2)Estimateur de σ^2


$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

ESTIMATEUR DE σ : $\sqrt{S^2} = S$


Toujours en supposant que la pression systolique suit vraiment une $\mathcal{N}(133, 6^2)$...

Répétition	x1	x2	x3	x4	x5	x6	x7	Variance
1	141	130	135	138	137	122	135	39 = S_1^2
2	131	127	138	132	131	126	137	21 = S_2^2
3	138	124	121	125	135	127	130	37
4	130	136	135	129	138	133	123	24
5	141	124	130	121	138	149	130	95
6	131	139	127	135	140	134	138	21
7	134	141	133	132	137	123	133	31
8	138	142	120	127	137	136	138	61
9	132	138	135	136	134	132	139	8
10	139	135	130	132	128	142	133	26
11	126	133	138	140	131	142	134	31 = S_{11}^2

Distribution de S^2

EMPIRIQUE

L'histogramme suivant présente la distribution de la variance[↑] de 1000 échantillons de taille 7.



Espérance et variance de S^2

Espérance de l'estimateur ²

$$\mathbb{E}[S^2] = \sigma^2$$

S^2 EST SANS Biais
POUR σ^2

La variance et erreur type de l'estimateur

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

$$\sqrt{\text{Var}(S^2)} = \frac{\sqrt{2}\sigma^2}{\sqrt{n-1}}$$

PRÉCISION ↑
SI n ↑
↕
VARIANCE ↓
SI n ↑

²voir section 3.3 si vous souhaitez les détails

Retour à l'exemple 1

$$X \sim N(\mu, \sigma^2)$$

$$V[\bar{X}] = \frac{\sigma^2}{n} \rightarrow \text{ESTIMATEUR DE } V[\bar{X}]$$

$\downarrow$
ESTIMATEUR DE σ^2 : S^2

$\downarrow$
 $\frac{S^2}{n}$

On peut supposer que la pression artérielle systolique (en mm Hg) suit une loi normale. On a recueilli chez 7 individus normaux les mesures suivantes: 141, 130, 135, 138, 137, 122, 135

- ① Donnez une estimation de la pression moyenne dans cette population. (*Quelle est la pression moyenne?*) $\bar{x} = 134$
- ② Donnez une estimation de l'erreur type de l'estimation de la pression moyenne. (*Quelle est l'erreur-type?*) $\sqrt{\frac{S^2}{n}} = \sqrt{\frac{39}{7}}$
- ③ Donnez l'estimation de l'écart-type de la pression dans cette population. (*Quel est l'écart-type?*) $\sqrt{S^2} = \sqrt{39}$
- ④ Donnez une estimation de la variance de l'estimation de la variance. (*On ne m'a jamais posé cette question en pratique.*)

$$S^2$$

$$V[S^2] = \frac{2\sigma^4}{n-1}$$

$$\text{ESTIMATION DE } V[S^2]: \frac{2S^4}{n-1}$$

Exemple 2

Dans un récent sondage³, on a demandé à 1028 québécois: Quelle enjeu influencera le plus votre vote lors des prochaines élections fédérales? 216 personnes ont répondu que c'était l'environnement⁴.

On s'intéresse à la variable Y , le nombre de personnes qui ont choisi l'environnement.

Quelle est la distribution de Y ?

$$Y \sim \text{BIN}(n=1028; p=?)$$

³<https://www.ledevoir.com/politique/canada/563439/sondage-leger-le-devoir-le-portefeuille-avant-la-planete>

⁴La méthodologie du sondage n'est pas très précise.

Estimation d'une proportion p

→ SANS BIAIS POUR p

Estimateur

$\hat{p}$ = proportion de 1 dans l'échantillon

Espérance de l'estimateur

$$\mathbb{E}(\hat{p}) = \mathbb{E}\left(\frac{Y}{n}\right) = \frac{1}{n}\mathbb{E}(Y) = \frac{1}{n}np = p$$

Variance de l'estimateur

$$\mathbb{Var}(\hat{p}) = \mathbb{Var}\left(\frac{Y}{n}\right) = \frac{1}{n^2}\mathbb{Var}(Y) = \frac{1}{n^2}np(1-p) = \frac{p(1-p)}{n}$$

Erreur type de l'estimateur

$$\sqrt{\mathbb{Var}(\hat{p})} = \sqrt{\frac{p(1-p)}{n}}$$

→ $\mathbb{Var}(\hat{p}) \rightarrow 0$ QUAND $n \uparrow$

$$\hat{p} = \frac{y}{n}$$

y : NOMBRE DE
SUCCÈS OBSERVÉS

y EST UNE
RÉALISATION DE
LA V.A. Y

Retour à l'exemple 2

Rappel: 216 des 1028 répondants on répondu que l'environnement est le principal enjeu.

- Quelle est l'estimation de la proportion des personnes qui ont répondraient que l'environnement est le principal enjeu?

$$\hat{p} = \frac{y}{n} = \frac{216}{1028} = 0,21$$

- Que vaut l'erreur type associée à cette estimation?

$$\sqrt{\frac{p(1-p)}{n}} \rightarrow \text{ESTIMATION: } \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 0,0127$$

- Est-ce que cette estimation est biaisée?

$$\text{NON CAR } E[\hat{p}] = p$$

Calcul de probabilités

Une fois la loi identifiée et les paramètres estimés, vous êtes en mesure d'utiliser le matériel du chapitre 2 pour estimer des probabilités.