

Chapitre 3: Estimation et tests d'hypothèses

STT-1920 Méthodes statistiques

Véronique Tremblay

Département de mathématiques et de statistique


Intervalle de confiance pour une moyenne (section 3.5)

Exemple 1: simulation de 1000 échantillons de taille $n = 7$ provenant d'une distribution $N(\mu = 133, \sigma^2 = 6^2)$

Répétition	x_1	x_2	x_3	x_4	x_5	x_6	x_7	Moyenne
1	141	130	135	138	137	122	135	134
2	132	128	139	133	132	127	138	133
3	140	125	122	126	136	128	131	130
4	131	137	136	130	140	134	124	133
5	143	125	131	121	139	150	131	134
6	132	140	128	136	141	135	140	136
7	135	143	134	133	138	123	134	134
8	139	144	120	127	138	137	140	135
9	133	139	136	137	135	133	140	136
10	140	136	131	133	128	143	134	135
11	126	134	139	141	132	143	135	136

Distribution de X

Supposition: La pression systolique suit vraiment une $N(133, 6^2)$...




— 1 –Distribution des données

Distribution de $\bar{X}$

L'histogramme suivant illustre la distribution des 1000 moyennes des échantillons de taille $n = 7$.

La distribution théorique de ces moyennes est la loi $N(\mu = 133, \frac{\sigma^2}{n} = \frac{36}{7})$.



Intervalle de confiance

Puisqu'un estimateur ponctuel (comme $\bar{X}$) est une variable aléatoire, sa valeur peut changer d'un échantillon à l'autre.

Quelle confiance peut-on avoir en une estimation unique d'un paramètre, basée sur un seul échantillon?

On voudrait compléter par une valeur: Pour 90% des échantillons, la moyenne échantillonnale s'écarte de la vraie moyenne 133 par au plus. . .

Intervalle de confiance

$$P(L_1 \leq \mu \leq L_2) = 1 - \alpha$$

En se basant sur la loi de l'estimateur, on peut construire un intervalle $[L_1, L_2]$ tel que

$$P(L_1 \leq \text{Paramètre} \leq L_2) = 1 - \alpha$$


$$P(L_1 \leq \theta \leq L_2) = 1 - \alpha$$

On appelle $1 - \alpha$ le **niveau de confiance** de l'intervalle.

La **marge d'erreur** est la demi-longueur d'un intervalle de confiance (lorsque l'intervalle est symétrique, ce qui est le cas pour celui de μ).

Interprétation d'un IC

ÉCH.
1
2
3
⋮
k



Si on prenait plusieurs échantillons de même taille dans la population, et que chaque fois on construisait l'intervalle de confiance de niveau 95% pour le paramètre, alors environ 95% de ces intervalles contiendraient la vraie valeur du paramètre.

→ 5% DES IC DE NIVEAU 95%
NE CONTIENNENT PAS LE VRAI
PARAMÈTRE

Retour sur l'exemple 1.

$$W \sim \mathcal{N}(E[W], V[W])$$

$$Z = \frac{W - E[W]}{\sqrt{V[W]}} \sim \mathcal{N}(0, 1)$$

En réalité, nous ne connaissons pas les paramètres de la distribution, μ et σ . On a estimé la moyenne μ par $\bar{x} = 134$. On veut lui associer une marge d'erreur.

- On sait que $n = 7$ et que $s = 6,27$.
- On suppose que la pression systolique X suit une loi normale.
- Dans ce cas,

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$E[\bar{X}] = \mu$
 $V[\bar{X}] = \frac{\sigma^2}{n}$

et donc

$$Z = \frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$


COMME $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$


ON PEUT TROUVER a ET b T.Q.

$$P(a \leq Z \leq b) = 1 - \alpha$$

$$P(-b \leq Z \leq b) = 1 - \alpha$$


→ POUR UN IC POUR μ
ON DOIT PRENDRE
 $a = -b$





LA VALEUR DE b QUI A 2,5% À DROITE
EST LA MÊME QUE CELLE QUI A 97,5% À GAUCHE
DONC $b = 1,96$

AVEC $1-\alpha=95\%$



$$P(-1,96 \leq Z \leq 1,96) = 0,95$$

$$P\left(-1,96 \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq 1,96\right) = 0,95$$

$$P\left(\underbrace{\bar{X} - 1,96 \frac{\sigma}{\sqrt{n}}}_{L_1} \leq \mu \leq \underbrace{\bar{X} + 1,96 \frac{\sigma}{\sqrt{n}}}_{L_2}\right) = \underbrace{0,95}_{1-\alpha}$$

$1-\alpha$ EST GÉNÉRALEMENT 95%, 90%, 99%, ...

Construction de l'intervalle de confiance

On veut un intervalle de confiance à 90% pour la moyenne.

On cherche $[L_1, L_2]$ telles que $P(L_1 \leq \mu \leq L_2) = 0,90$.

Avec la table de la loi normale ou un logiciel comme R, on trouve

$$\mathbb{P} \left[-1,645 \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq 1,645 \right] = 0,90.$$

$$\mathbb{P} \left[\bar{X} - 1,645 \frac{\sigma}{\sqrt{7}} \leq \mu \leq \bar{X} + 1,645 \frac{\sigma}{\sqrt{7}} \right] = 0,90.$$

IC EST CENTRÉ
EN $\bar{X}$

IC: $\bar{X} \pm 1,645 \frac{\sigma}{\sqrt{7}}$
↓
MARGE D'ERREUR

Quel est le problème avec cet intervalle?

IC à 95% pour μ : $\bar{X} \pm 1,96 \frac{\sigma}{\sqrt{n}}$

90% pour μ : $\bar{X} \pm 1,645 \frac{\sigma}{\sqrt{n}}$

$\vdots$

$1-\alpha$ pour μ : $\bar{X} \pm z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$

où $z_{\frac{\alpha}{2}}$ EST LA VALEUR POUR LAQUELLE
LA PROBA QU'UNE $N(0,1)$ SOIT À DROITE
EST $\frac{\alpha}{2}$

William Gosset (1876-1937)



Gosset a trouvé que si $X_1, X_2, \dots, X_n$ sont indépendantes de loi $N(\mu, \sigma^2)$, alors

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

Autrement dit: la variable $\bar{X}$, une fois centrée avec μ et réduite avec son erreur-type **estimée** $S/\sqrt{n}$ suit une loi de Student à $n - 1$ degrés de liberté.




Loi de Student

Si X suit une loi de Student à k degrés de liberté, sa densité est la suivante:

$$f(x) = \frac{\Gamma((k+1)/2)}{\sqrt{k\pi}} \frac{1}{[1 + x^2/2]^{(k+1)/2}}$$

où k est un entier positif appelé le nombre de degrés de liberté.

Comparaison de la $N(0, 1)$ avec des lois de Student




Table de la loi de Student

v	α										
	0.25	0.20	0.15	0.10	0.05	0.025	0.010	0.005	0.0025	0.0010	0.0005
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82	63.66	127.3	318.3	636.6
2	0.816	1.061	1.386	1.886	2.920	4.303	6.965	9.925	14.09	22.33	31.60
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541	5.841	7.453	10.21	12.92
4	0.741	0.941	1.190	1.533	2.132	2.776	3.747	4.604	5.598	7.173	8.610
5	0.727	0.920	1.156	1.476	2.015	2.571	3.365	4.032	4.773	5.893	6.869
6	0.718	0.906	1.134	1.440	1.943	2.447	3.143	3.707	4.317	5.208	5.959
7	0.711	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.029	4.785	5.408
8	0.706	0.889	1.108	1.397	1.860	2.306	2.896	3.355	3.833	4.501	5.041
9	0.703	0.883	1.100	1.383	1.833	2.262	2.821	3.250	3.690	4.297	4.781
10	0.700	0.879	1.093	1.372	1.812	2.228	2.764	3.169	3.581	4.144	4.587
11	0.697	0.876	1.088	1.363	1.796	2.201	2.718	3.106	3.497	4.025	4.437
12	0.695	0.873	1.083	1.356	1.782	2.179	2.681	3.055	3.428	3.930	4.318
13	0.694	0.870	1.079	1.350	1.771	2.160	2.650	3.012	3.372	3.852	4.221
14	0.692	0.868	1.076	1.345	1.761	2.145	2.624	2.977	3.326	3.787	4.140
15	0.691	0.866	1.074	1.341	1.753	2.131	2.602	2.947	3.286	3.733	4.073
16	0.690	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015
17	0.689	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965

$$T \sim t_8$$

$$P(T > 1.397) = 0.1 \quad | \quad P(T > 1) \in]0.15; 0.2[$$

L'IC pour la moyenne

$$T \sim t_{n-1}$$

$$P(-t_{\frac{\alpha}{2}; n-1} \leq T \leq t_{\frac{\alpha}{2}; n-1}) = 1 - \alpha$$

$$\mathbb{P} \left[-t_{n-1, \alpha/2} \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{n-1, \alpha/2} \right] = 1 - \alpha.$$


$$\mathbb{P} \left[\underbrace{\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}}_{L_1} \leq \mu \leq \underbrace{\bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}}_{L_2} \right] = 1 - \alpha$$

Intervalle de confiance de niveau $1 - \alpha$ pour la moyenne d'une distribution normale:

$$\left[\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}} \right]$$

$$\bar{X} \pm t_{\frac{\alpha}{2}; n-1} \frac{S}{\sqrt{n}}$$

MARGE D'ERREUR



$$P(-t_{\frac{\alpha}{2}; n-1} \leq T \leq t_{\frac{\alpha}{2}; n-1}) = 1-\alpha$$

$$V(\bar{x}) = \frac{\sigma^2}{n}$$

Retour sur l'exemple 1.

On suppose que la pression systolique suit une loi normale. On sait que $n = 7$ et on a estimé $\bar{x} = 134$ et $s = 6,27$ à partir de l'échantillon.

$$\sqrt{V(\bar{x})} = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}$$

→ $\bar{x}$

ESTIMATION:

- ① Quelle est l'erreur-type associée à l'estimation de la moyenne?

$$\frac{s}{\sqrt{n}} = \frac{6,27}{\sqrt{7}} = 2,37$$

- ② Quelle est la marge d'erreur associée à l'estimation de la moyenne (à 90%)?

$$n=7$$

$$1-\alpha=0,9$$

$$\rightarrow \alpha=0,1 \rightarrow \frac{\alpha}{2}=0,05$$

$$\text{ou } t_{\frac{\alpha}{2}; n-1} = t_{0,05; 6} = 1,943$$

$$ME: 1,943 \cdot 2,37 = 4,6$$

- ③ Donnez un intervalle de confiance de niveau 90% pour la pression moyenne.


$$[134 - 4,6; 134 + 4,6] \rightarrow [129,4; 138,6]$$


Vrai ou faux ?

$$\rightarrow P(129,4 \leq X \leq 138,6) = 0,9$$

- ① 90% des gens de cette population ont une pression sanguine comprise entre 129,39 et 138,61.

L'IC PORTE SUR μ PAS SUR LES X
 $\rightarrow X \sim N(\mu, \sigma^2)$






Vrai ou faux ?

- ② 90% des gens de cet échantillon ont une pression sanguine comprise entre 129,39 et 138,61.

Vrai ou faux ?

- ③ Si on prenait des mesures sur 7 autres individus, il y a 90% des chances que la moyenne de ce nouvel échantillon soit comprise entre 129,39 et 138,61.

L'IC PORTE SUR μ PAS SUR $\bar{X}$



Vrai ou faux ?

- ④ Si on prenait 1000 échantillons de taille 7 dans cette population, et qu'on calculait pour chacun l'intervalle de confiance avec la formule précédente, environ 900 d'entre eux contiendraient la vraie pression sanguine moyenne de la population.

CAR
$$P\left(\bar{X} - t_{\frac{\alpha}{2}; n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}; n-1} \frac{S}{\sqrt{n}}\right) = 0.9$$

Vrai ou faux ?

ou plus

- ⑤ Avec un échantillon de taille 30, on peut utiliser les quantiles de la loi normale pour calculer l'intervalle de confiance.

$$\hookrightarrow \bar{X} \pm z_{\frac{\alpha}{2}} \frac{S}{\sqrt{n}} ?$$

EN UTILISANT LE TCL

MAIS! NOUS UTILISERONS TOUJOURS

LA LOI DE STUDENT QUAND
 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ET QUE σ^2 EST INCONNUE

Vrai ou faux ?

- ⑥ Avec un échantillon plus grand, on obtiendrait un intervalle de confiance plus long.

$$\bar{X} \pm t_{\frac{\alpha}{2}; n-1} \frac{S}{\sqrt{n}}$$

G.1 AVEC $S \uparrow$ IC $\uparrow$? VRAI

G.2 AVEC $(1-\alpha) \uparrow$ IC $\uparrow$? VRAI

Vrai ou faux ?

Supposons

- ⑦ ~~Étant donné~~ que la vraie moyenne est de 133, l'estimation obtenue pour la moyenne (134) est biaisée.

$\bar{X}$ EST S.B. POUR μ