

Chapitre 5 Analyse de la variance

STT-1920 Méthodes statistiques

Véronique Tremblay et Emmanuelle Reny-Nolin

Département de mathématiques et de statistique

Automne 2021

Introduction

Objectifs de l'analyse de la variance (Anova)

- Comparer les *moyennes* d'une variable dans plusieurs populations (normales de même variance);
- Déterminer si un *facteur* (variable discrète ou qualitative) a une influence sur une *variable réponse* (variable aléatoire continue).

Exemples

FACTEUR: TYPE DE PEINTURE
→ 7 NIVEAUX

- Un ingénieur aux transports veut comparer la durabilité moyenne de 7 mélanges de peinture pour asphalte.
- Un chercheur développe 3 traitements contre l'hypertension. Il désire savoir si l'un d'entre eux a un délai d'action plus court que les autres.
- Un agronome veut savoir si les 4 variétés de blé qui résistent le mieux à la moisissure donnent des rendements moyens égaux.
- Un directeur de magasin d'appareils électroniques est intéressé à comparer 5 méthodes de publicité. Il veut savoir si ces méthodes sont équivalentes ou si l'une d'elles amène plus de clients que les autres.

TRAITEMENT:

ANOVA: Décomposition de la variance

GROUPE, NIVEAU

L'analyse de variance consiste à identifier et à comparer les **sources de variation** d'une variable:


- la variabilité **inter-traitements** entre les moyennes des échantillons, que l'on associe au facteur (la caractéristique qui distingue les groupes à l'étude).
- la variabilité **intra-traitement** entre les observations d'un même échantillon, que l'on associe à l'erreur échantillonnale (non expliquée par le modèle);

Comparons 2 scénarios

Moyennes	Scénario 1	Scénario 2
Traitement A	15.32	15.32
Traitement B	9.61	9.61



Scénario 1: Décomposition de la variance




Scénario 1: Table d'analyse de la variance

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.27	65.27	7.543	0.0334 *
Residuals	6	51.91	8.65		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Scénario 2: Décomposition de la variance



Scénario 2: Table d'analyse de la variance

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.15	65.15	1.484	0.269
Residuals	6	263.45	43.91		

Mathématique de l'ANOVA

But: Comparer les moyennes $\mu_1, \dots, \mu_I$ de la variable Y dans I populations.

$$\begin{aligned} i &= 1, \dots, I \\ j &= 1, \dots, n \end{aligned}$$

$Y_{11}, Y_{12}, \dots, Y_{1n_1}$ sont issues d'une population $N(\mu_1, \sigma^2)$;

$Y_{21}, Y_{22}, \dots, Y_{2n_2}$ sont issues d'une population $N(\mu_2, \sigma^2)$;

$\dots Y_{i1}, Y_{i2}, \dots, Y_{in_i}$

$Y_{I1}, Y_{I2}, \dots, Y_{In_I}$ sont issues d'une population $N(\mu_I, \sigma^2)$.

PAS DE RESTRICTION
SUR LES VALEURS

→ TOUTES
→ ÉGALES

Hypothèses à confronter

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_I$$

H_1 : au moins 2 moyennes diffèrent

AU MOINS 1 DIFFÉRENTE
DES AUTRES

$$N = I \cdot n \rightarrow \text{NB TOTAL D'OBS.}$$

Le modèle à un facteur

RÉPONSE DE L'OBS. j DU NIVEAU i
 y_{23} : 3^e OBS. DU 2^e NIVEAU

$$Y_{ij} = \mu_i + \varepsilon_{ij} \quad \text{avec} \quad Y_{ij} \sim N(\mu_i, \sigma^2)$$

- μ_i : MOYENNE DU TRT i
- ε_{ij} : ERREUR ALÉATOIRE AVEC $\varepsilon_{ij} \sim N(0, \sigma^2)$,

Estimation des paramètres:

C'EST CE QUI VA DONNER LA DIFFÉRENCE ENTRE y_{ij} ET μ_i

- μ_i estimé par

$$\bar{y}_{i\cdot} = \frac{1}{n} \sum_{j=1}^n y_{ij} \quad \text{MOYENNE LOCALE DU TRT } i$$

- μ estimé par

$$\bar{y}_{\cdot\cdot}$$

- σ^2 estimé par

MOYENNE GLOBALE DE TOUTES LES OBS.

$$\hat{\sigma}^2 = \frac{1}{N-I} \sum_{i=1}^I \sum_{j=1}^n (y_{ij} - \bar{y}_{i\cdot})^2$$

SUPPOSONS $I=8$, $n_1=n_2=\dots=n_8=6=n$

$y_{11}, \dots, y_{16}$

$y_{21}, \dots, y_{26}$

$\vdots$

$y_{81}, \dots, y_{86}$

JE VEUX ESTIMER μ_3

$\rightarrow \bar{y}_{3\cdot}$ EST L'ESTIMATEUR DE μ_3

$$\bar{y}_{3\cdot} = \frac{1}{6} \sum_{j=1}^6 y_{3j} = \frac{1}{6} (y_{31} + y_{32} + \dots + y_{36})$$

$$N=8 \cdot 6=48$$

JE VEUX ESTIMER μ

$\rightarrow \bar{y}_{\cdot\cdot}$ EST L'ESTIMATEUR DE μ

$$\bar{y}_{\cdot\cdot} = \frac{1}{8 \cdot 6} \sum_{i=1}^8 \sum_{j=1}^6 y_{ij}$$

$$\hat{\sigma}^2 = \frac{1}{48-8} \sum_{i=1}^8 \sum_{j=1}^6 (y_{ij} - \bar{y}_{i\cdot})^2$$

Décomposition de la variance

VARIABILITÉ
TOTALE


VARIABILITÉ
DUE AU TRAITEMENT

VARIABILITÉ
DUE À L'ERREUR


$$SST = SS_{\text{TOT}} + SSE$$

$$\sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^I n_i (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2$$


Totale



Traitement



Résiduelle



Décomposition de la variance

$$SST = SST_R + SSE$$

$$\sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{\bullet\bullet})^2 = \sum_{i=1}^I n_i (\bar{y}_{i\bullet} - \bar{y}_{\bullet\bullet})^2 + \sum_{i=1}^I \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i\bullet})^2$$






Table d'anova

Source de variation	Somme de carrés	Degrés de liberté	Carrés moyens	F_{obs}
Traitements (inter-trt)	SS_{Trt}	$I - 1$	$MS_{\text{Trt}} = \frac{SS_{\text{Trt}}}{I - 1}$	$\frac{MS_{\text{Trt}}}{MSE}$
Erreur (intra-trt)	$\dagger SSE$	$\dagger N - I$ $I_n - I$	$MSE = \frac{SSE}{N - I}$	
Total	SST	$N - 1$		

$$\begin{aligned}
 \hookrightarrow \frac{SSE}{N-I} &= \frac{1}{N-I} \sum_{i=1}^I \sum_{j=1}^n (y_{ij} - \bar{y}_{i\cdot})^2 \\
 \rightarrow MSE &= \hat{\sigma}^2
 \end{aligned}$$

SS_{TRE} VA PRENDRE
UNE PLUS PETITE VALEUR
DANS SST DONC MST_{TRE} VA
ÊTRE «FAIBLE»

$$\mu_1 = \mu_2 = \dots = \mu_I = \mu$$



S'il n'y a pas de différence entre les traitements (H_0 est vraie),
 MST_R et MSE sont tous les deux de bons estimateurs de σ^2 .

Si l'effet des traitements est important, on aura

H_1 VRAIE

$$MST_R \gg MSE.$$

À partir de quand considère-t-on que MST_R est vraiment plus grand que MSE ?

Statistique de Fisher

Si


- les observations sont indépendantes (dans les groupes et entre les groupes)
- les données proviennent d'une distribution normale
- la variance est égale dans chaque groupe

et que

- H_0 est vraie (μ_i toutes égales)

alors

$$\frac{SST_R / (I - 1)}{SSE / (N - I)} = \frac{MST_R}{MSE} \sim F_{I-1, N-I}$$



On rejette H_0 au seuil α si $F_{obs} > F_{I-1, N-I, \alpha}$

Dans ce cas, on aurait un p-value inférieur à α .

Retour au scénario 1

	y1	y2	Traitement
1	14.72	6.3925	A
2	13.52	12.1425	A
3	14.54	20.0725	A
4	18.49	22.6625	A
5	9.98	12.7900	B
6	4.59	2.9100	B
7	12.82	7.1300	B
8	11.03	15.6100	B

A1moy	A1s	B1moy	B1s
15.32	2.18	9.61	3.54

$$\bar{y}_{..} = 12.465$$

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.27	65.27	7.543	0.0334 *
Residuals	6	51.91	8.65		

$$\text{d.d.l TRT: } I - 1 = 2 - 1 = 1$$

$$\text{d.d.l ERREUR: } N - I = 8 - 2 = 6$$

$$\text{d.d.l TOTAUX: } N - 1 = 8 - 1 = 7$$

$$SS_{\text{TRT}} = n \sum_{i=1}^2 (\bar{y}_{i.} - \bar{y}_{..})^2$$

$$= 4 \left[(15.32 - 12.465)^2 + (9.61 - 12.465)^2 \right]$$

$$= 65.27$$

$$MS_{\text{TRT}} = SS_{\text{TRT}} / (I - 1) = 65.27$$

$$SS_E = \sum_{i=1}^I \sum_{j=1}^n (y_{ij} - \bar{y}_{i\cdot})^2$$

SUPPOSONS $i=1$

$$\begin{aligned} \sum_{j=1}^n (y_{ij} - \bar{y}_{i\cdot})^2 &= \sum_{j=1}^n (y_{1j} - \bar{y}_{1\cdot})^2 \\ &= (n-1) S_1^2 \end{aligned}$$

$$\begin{aligned} \rightarrow SS_E &= \sum_{i=1}^I (n-1) S_i^2 = \sum_{i=1}^2 (4-1) S_i^2 = 3 \cdot S_1^2 + 3 \cdot S_2^2 \\ &= 3 \cdot 2,18^2 + 3 \cdot 3,54^2 = 51,9 \end{aligned}$$


$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$MSE = SSE / (N - I) = 51,9 / 6 = 8,65$$

$$F_{OBS} = \frac{MS_{121}}{MSE} = \frac{65,27}{8,65} = 7,543$$

$H_0: \mu_A = \mu_B$ $H_1: \mu_A \neq \mu_B$ Au seuil 5%

ON REJETTE H_0 SI $F_{OBS} > F_{\alpha; I-1; N-1} = F_{0,05; 1; 6} = 5,99$



ON REJETTE H_0 CAR
 $7,543 > 5,99$

ON PEUT DÉDUIRE QUE $\alpha^* < 5\%$


$$\alpha^* = P(F_{1;6} > 7,543) ?$$

$$P(F_{1;6} > 13,75) = 1\%$$

$$P(F_{1;6} > 8,81) = 2,5\%$$

$$P(F_{1;6} > 5,99) = 5\%$$

$$\alpha^* = P(F_{1;6} > 7,543) \in]0,025; 0,05[$$



Aurait-on pu faire un test de Student?

ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Traitement	1	65.27	65.27	7.543	0.0334 *
Residuals	6	51.91	8.65		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Test de student

Two Sample t-test

data: y1 by Traitement

t = 2.7464, df = 6, p-value = 0.03345

alternative hypothesis: true difference in means between group A and group B

95 percent confidence interval:

0.6230128 10.8019872

sample estimates:

mean in group A mean in group B

15.3175

9.6050

Student vs ANOVA

- Est-ce que c'est un hasard si les p-valeurs sont les mêmes?
- Pourquoi faire l'ANOVA?

Exemple: agent de conservation naturel pour la viande, à partir de sang de porc

<https://nouvelles.ulaval.ca/recherche/de-residu-a-source-dagents-de-conservation-naturels-0797d4c252cd98ac53f75a256e95624a?sourceOrganizationKey=ulaval>

- «Indeed, in 2016, 30 million litres of bovine and porcine blood were produced in the Quebec province.» (dans l'article)
- Une nouvelle méthode d'extraction (EDUF) permet une plus grande concentration de peptides bioactifs.
- «Les tests que nous avons effectués sur du bœuf haché ont révélé que ces extraits [de sang] sont aussi efficaces que le BHT, un additif chimique couramment utilisé par l'industrie alimentaire.» (sur le site de l'Université)

Nous avons simulé des données à partir des moyennes et écarts-types de la section 3.6 de l'article.

Contexte

$$I=3$$

- On veut comparer l'effet antioxydant de l'EDUF (la nouvelle méthode) au peptide original nommé " α 137 – 141" et à un contrôle.
- On crée un échantillon de taille 6 pour chaque traitement
- On mesure le TBARS (en mg MDA/kg de viande hachée) après 4 jours (une mesure de rancissement)

$$N=18$$

$$n=6$$

Test ANOVA

pour au moins
un (i, j)

$$\mu_i \neq \mu_j$$

1. Hypothèses

H_0 : Les trois moyennes sont égales

H_1 : Au moins une moyenne est différente d'une autre

$$\mu_1 = \mu_2 = \mu_3$$

2. Choix du test et définition de la zone de rejet

Si les données sont distribuées normalement et que les variances sont égales, on fait une analyse de variance à un facteur.

On choisit α . On rejette H_0 si la p-valeur est inférieure à α .

Choisissons arbitrairement $\alpha = 0,05$.

$$\text{ON REJETTE } H_0 \text{ SI } F_0 > F_{\alpha; I-1; N-I} = F_{0,05; 2; 15} \\ = 3,68$$

Test ANOVA

3. On fait le test avec un logiciel




Table d'anova à compléter

Source de variation	Somme de carrés	Degrés de liberté	Carrés moyens	F_{obs}	α^*
Traitements (inter-trt)	0,1411	2	0,0706	6,78	0,0079
Erreur (intra-trt)	0,156	15	0,0104	$\rightarrow = \frac{SSE}{N-I}$	
Total	0,2971	17			

Sortie R

```
              Df Sum Sq Mean Sq F value    Pr(>F)
Traitement    2 0.1412   0.0706    6.791 0.00794 **
Residuals    15 0.1559   0.0104
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4. Décision

ON REJETTE H_0 CAR $6,78 > 3,68$
ON REJETTE H_0 CAR $\alpha^* = 0,0079 < 0,05$

5. Conclusion

Contrastes

- Comment savoir quelles moyennes sont différentes? (section 5.8)
- Peut-on simplement faire plusieurs tests de Student 2 à 2?

Simultaneous Tests for General Linear Hypotheses


Multiple Comparisons of Means: Tukey Contrasts

Fit: aov(formula = TBARS ~ Traitement, data = conservation)

Linear Hypotheses:

	Estimate	Std. Error	t value	Pr(> t)	
Controle - a137_141 == 0	0.21658	0.05887	3.679	0.00599	**
EDUF - a137_141 == 0	0.09732	0.05887	1.653	0.25496	
EDUF - Controle == 0	-0.11926	0.05887	-2.026	0.14031	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Adjusted p values reported -- single-step method)



Vérification des postulats

Indépendance des observations: Structure de l'expérience

- Y a-t-il des liens entre les observations d'un même traitement?
de traitements différents?
- A-t-on pris plusieurs mesures sur une même unité
expérimentale?

Homogénéité des variances: Test de Bartlett

On veut tester les hypothèses:

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_I^2$$

H_1 : au moins 2 de ces variances sont inégales

On utilise une statistique B (appelée K-squared dans R-Commander):

- Si H_0 est vraie, B suit une loi χ_{I-1}^2 .
- Si H_1 est vraie, B prendra des valeurs plus élevées que celles attendues sous la χ_{I-1}^2 .
- Alors au seuil α , on rejette l'égalité des variances si...

Exemple

Bartlett test of homogeneity of variances

data: TBARS by Traitement

Bartlett's K-squared = 0.74383, df = 2, p-value = 0.6894

Vérification de la normalité des observations: Analyse des résidus

Rappel du modèle:

$$Y_{ij} = \mu_i + \varepsilon_{ij}$$

Puisque $Y_{ij} \sim N(\mu_i, \sigma^2)$, il suit que $\varepsilon_{ij} \sim N(0, \sigma^2)$.

Les erreurs échantillonales, ε_{ij} , sont estimées par les *résidus* du modèle:

$$\hat{\varepsilon}_{ij} = y_{ij} - \overline{y_{i\bullet}}$$

Au lieu d'analyser directement les observations, nous analyserons les résidus.

Test de normalité sur les résidus

Shapiro-Wilk normality test

data: AnovaModel.3\$residuals

W = 0.97151, p-value = 0.8255