

STT-1920 Méthodes statistiques

Chapitre 6 **Régression linéaire simple** **Première partie**

Département de mathématiques et de statistique
Université Laval

Chapitre 6 : Régression linéaire simple

6.1 Introduction (p. 199)

6.2 Modèle de régression linéaire simple (p. 202)

Modèle et postulats

6.3 Estimation des paramètres : β_0 , β_1 , σ^2 (p. 203)

6.7 Test de Fisher pour la régression (p. 210)

Hypothèses à tester

Décomposition de la variance

Table d'anova

6.1 Introduction

Objectifs

- Vérifier si une *relation linéaire* existe entre les variables aléatoires X (variable explicative) et Y (variable réponse).
- Mesurer la force du lien linéaire qui unit les variables.
- Trouver la meilleure droite exprimant la relation entre les 2 variables à partir de n paires d'observations indépendantes (X_i, Y_i) . Évaluer la précision des estimations de la pente et de l'ordonnée à l'origine.
- Prédire la valeur de Y pour un X donné, et évaluer la précision de ces prédictions.

Exemples d'application

- Un sociologue veut savoir s'il existe un lien linéaire entre le nombre d'années d'études et le salaire à l'embauche.
- Un médecin veut étudier la relation entre l'IMC des individus et le taux de cholestérol dans leur sang.
- Un ingénieur veut savoir si le taux d'humidité dans le papier est directement proportionnel à la température du séchoir.
- Un économiste veut savoir si le lien entre l'offre d'un produit et son prix est linéaire.

Exemple 1


On veut étudier l'effet du nombre d'heures d'ensoleillement sur la production (kg) de tomates. On mesure la production de 60 plants soumis à des temps d'ensoleillement de 3, 4, 5, 6, 7 ou 8 heures par jour.

Voici les résultats obtenus :

Soleil	Production (en kg)									
3 h	2.92	2.59	2.73	2.43	3.78	2.23	3.07	1.69	1.98	2.95
4 h	2.54	2.92	3.65	3.57	3.60	2.41	3.79	2.74	2.41	3.49
5 h	3.17	2.72	4.53	3.21	3.00	4.15	2.99	4.48	3.17	3.82
6 h	4.13	4.64	4.55	3.42	4.23	3.76	3.57	4.94	3.93	3.46
7 h	3.42	5.20	4.63	4.16	3.64	3.61	4.44	4.46	5.08	4.23
8 h	4.08	5.43	5.76	3.99	4.55	4.93	5.11	5.00	4.86	4.72

Exemple 1

Les 60 plants de tomate



Exemple 2

On cherche à démontrer qu'il existe un lien linéaire entre le poids d'une hirondelle (X) et l'étendue de ses ailes ouvertes (Y).


Pour ce faire, on mesure ces deux quantités sur 50 hirondelles choisies au hasard dans la population d'intérêt.


Oiseau	Poids	Étendue
1	52.29	14.10
2	39.05	8.94
3	40.23	8.79
4	43.69	9.59
5	50.23	10.60
6	57.44	13.12
7	42.18	10.51
8	43.54	11.13
9	41.59	8.62
10	52.38	12.81
11	45.35	11.18
12	52.30	12.32
13	45.91	9.38
14	47.19	10.86
15	45.94	10.99
16	58.26	14.22

Oiseau	Poids	Étendue
26	48.93	12.05
27	48.17	11.13
28	55.53	13.79
29	50.85	13.26
30	42.88	9.51
31	48.86	11.32
32	52.65	14.47
33	45.43	10.26
34	43.40	9.52
35	50.95	12.82
36	42.24	10.29
37	48.30	12.33
38	56.42	14.69
39	49.97	11.15
40	41.64	8.35
41	49.44	9.69

Exemple 2

Les 50 hirondelles





Le modèle

On suppose que X et Y sont reliées par la droite $Y = \beta_0 + \beta_1 X$, et que les observations dévient un peu de ce modèle par une erreur aléatoire ε , ce qui s'écrit (pour un point en particulier) :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad \text{où } i = 1, \dots, n,$$

$$Y_i = i^e \text{ mesure de la variable } Y,$$

$$\beta_0 = \text{ORDONNÉE À L'ORIGINE DE LA DROITE THÉORIQUE}$$

$$\beta_1 = \text{PENTE DE LA DROITE THÉORIQUE}$$

$$X_i = i^e \text{ mesure de la variable } X,$$

$$\varepsilon_i = \text{perturbation due au hasard ou à des variables autres que } X \\ \text{(erreur du modèle, différence entre } Y_i \text{ et la droite).}$$

$$\hookrightarrow \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$


$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

$$Y_i \sim \mathcal{N}(\beta_0 + \beta_1 x_i; \sigma^2)$$

σ^2 : VARIANCE AUTOUR DE
LA DROITE $\beta_0 + \beta_1 x$

$$\begin{aligned} E[Y_i] &= E[\beta_0 + \beta_1 x_i + \varepsilon_i] \\ &= \beta_0 + \beta_1 x_i + \cancel{E[\varepsilon_i]} \end{aligned}$$


$$\begin{aligned} V[Y_i] &= V[\beta_0 + \beta_1 x_i + \varepsilon_i] \\ &= V[\varepsilon_i] \end{aligned}$$



σ^2 EST LA
VARIANCE AUTOUR
DE LA DROITE

Les postulats

- Les observations (X_i, Y_i) sont indépendantes les unes des autres.
- Les variables X et Y sont associées par un lien linéaire.
- Les observations Y_i sont issues d'une loi normale pour chaque X_i fixé. $Y_i | x_i \sim \mathcal{N}$
- La variance des Y_i autour de la droite (notée σ^2) est constante pour toutes les valeurs de X .



6.3 Estimation des paramètres par les moindres carrés

Pour estimer β_0 et β_1 , on minimise la somme des carrés des erreurs, i.e. des écarts verticaux entre les observations Y_i et le point correspondant sur la droite de régression $\beta_0 + \beta_1 X_i$:

$$\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - \underbrace{[\beta_0 + \beta_1 X_i]}_{\substack{\text{VALEUR DE } Y_i \\ \text{SUR LA DROITE}}})^2$$

Il suffit donc de dériver cette équation successivement par rapport à β_0 et β_1 , d'égaliser les dérivées partielles à 0 et de résoudre le système obtenu pour trouver $\hat{\beta}_0 = b_0$ et $\hat{\beta}_1 = b_1$.

Estimateurs b_0 et b_1

$$(\hat{b}_0 \in \hat{b}_1)$$

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{XY}}{S_{XX}}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

La valeur de Y prédite par le modèle pour une valeur de X fixée est donc

$$\hat{y}_i = b_0 + b_1 x_i.$$

$(x_i, \hat{y}_i)$ EST SUR LA DROITE ESTIMÉE

$$\hat{y} = b_0 + b_1 \bar{x}$$

LA DROITE ESTIMÉE
PASSE TOUJOURS PAR
LE POINT $(\bar{x}, \bar{y})$

Notations

$$S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2 = (n-1)s_X^2$$

$$S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)s_Y^2$$

$$S_{XY} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}$$

6.4 Inférence sur les paramètres

Distribution de b_0 et b_1

b_0 et b_1 sont des variables aléatoires, car si on change d'échantillon (X_i, Y_i) , leurs valeurs changent.

On peut montrer que

$$\bullet E(b_0) = \beta_0$$

$$\bullet E(b_1) = \beta_1$$

$$\bullet V(b_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}} \right)$$

$$\bullet V(b_1) = \frac{\sigma^2}{S_{XX}}$$

• b_0 et b_1 suivent chacun une loi normale. Comme on connaît leur distribution, on peut construire des intervalles de confiance et des tests.

$$b_0 \sim \mathcal{N}\left(\beta_0; \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right) \quad b_1 \sim \mathcal{N}\left(\beta_1; \frac{\sigma^2}{S_{xx}}\right)$$

$$\frac{b_0 - \beta_0}{\sqrt{\sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} \sim \mathcal{N}(0,1)$$

$$\frac{b_1 - \beta_1}{\sqrt{\sigma^2/S_{xx}}} \sim \mathcal{N}(0,1)$$

Remarques

- b_0 ET b_1 SONT S.B. POUR β_0 ET β_1
- LEUR VARIANCE DIMINUE SI $n \uparrow$ (b_0)
 $\sigma^2 \downarrow$ (b_0 ET b_1)
 $S_{xx} \uparrow$ (b_0 ET b_1)
- σ^2 EST ESTIMÉE PAR


$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{SSE}{n-2} = MSE$$

$$b_0 \sim \mathcal{N}\left(\beta_0; \sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)\right) \quad b_1 \sim \mathcal{N}\left(\beta_1; \frac{\sigma^2}{S_{xx}}\right)$$


$$\frac{b_0 - \beta_0}{\sqrt{\sigma^2\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} \sim \mathcal{N}(0,1) \quad \frac{b_1 - \beta_1}{\sqrt{\sigma^2/S_{xx}}} \sim \mathcal{N}(0,1)$$

COMME σ^2 EST INCONNUE

$$\frac{b_0 - \beta_0}{\sqrt{MSE\left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}} \sim t_{n-2} \quad \frac{b_1 - \beta_1}{\sqrt{MSE/S_{xx}}} \sim t_{n-2}$$



R-Commander : Statistiques, Ajustement de modèle



```
> RegModel.1 <- lm(production~hrs_soleil, data=tomates)
> summary(RegModel.1)
```

Call:

$y \sim x$
lm(formula = production ~ hrs_soleil, data = tomates)

Residuals:

Min	1Q	Median	3Q	Max
-0.97619	-0.49213	0.00378	0.42100	1.11381

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.37242	0.24733	5.549	7.46e-07 ***
hrs_soleil	0.43126	0.04295	10.042	2.66e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5681 on 58 degrees of freedom

Multiple R-squared: 0.6348, Adjusted R-squared: 0.6285

F-statistic: 100.8 on 1 and 58 DF, p-value: 2.661e-14

$$\sqrt{V(b_0)} = 0,24733$$

$$\sqrt{V(b_1)} = 0,04295$$

→ PAGE SUIVANTE

t VALUE ET $P_r(>|t|)$ FONT RÉFÉRENCE AUX TESTS
DONT LES HYPOTHÈSES SONT

$$H_0: \beta_0 = 0$$

$$H_1: \beta_0 \neq 0$$

$$\frac{b_0 - \beta_0}{\sqrt{MSE \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim t_{n-2}$$

ON REJETTE H_0 SI
 $|t_0| = |t \text{ VALUE}| > t_{\frac{\alpha}{2}; n-2}$ AU SEUIL α


$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Sous H_0

$$\frac{b_1}{\sqrt{MSE/S_{xx}}} \sim t_{n-2}$$

ON REJETTE H_0 SI
 $|t_0| = |t \text{ VALUE}| > t_{\frac{\alpha}{2}; n-2}$ AU SEUIL α



ON REJETTE AUSSI H_0 AU SEUIL α SI $\alpha^* < \alpha$
 α^* CORRESPOND À $Pr(>|t|)$

Estimation des paramètres

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.37242	0.24733	5.549	7.46e-07 ***
hrs_soleil	0.43126	0.04295	10.042	2.66e-14 ***


Trouvez et interprétez les estimations des paramètres.

$b_1 = 0,43126 \rightarrow$ SI LES HEURES D'ENSOLEILLEMENT AUGMENTENT D'UNE UNITÉ LA PRODUCTION MOYENNE AUGMENTE DE 0,43126 kg

$b_0 = 1,37242 \rightarrow$ PRODUCTION MOYENNE SI LE NOMBRE D'HEURE EST DE 0

Les 60 plants de tomate





ON REJETTE AUSSI $H_0: \beta_0 = 0$ contre $H_1: \beta_0 \neq 0$ AU SEUIL α
SI L'IC(1- α) POUR β_0 NE CONTIENT PAS 0

ON REJETTE AUSSI $H_0: \beta_1 = 0$ contre $H_1: \beta_1 \neq 0$ AU SEUIL α
SI L'IC(1- α) POUR β_1 NE CONTIENT PAS 0

COMME $\alpha^* < 5\%$ POUR $H_0: \beta_0 = 0$, REJETTE H_0 AU SEUIL 5%
DONC L'IC(95%) POUR β_0 NE CONTIENT PAS 0
IDEM POUR β_1

Intervalles de confiance sur les paramètres

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.37242	0.24733	5.549	7.46e-07 ***
hrs_soleil	0.43126	0.04295	10.042	2.66e-14 ***

Calculez un intervalle de confiance à 95% sur la pente et sur l'ordonnée à l'origine.

$$b_0 \sim \mathcal{N}(\beta_0; V(b_0))$$

$$\frac{b_0 - \beta_0}{\sqrt{V(b_0)}} \sim \mathcal{N}(0,1)$$

$$b_1 \sim \mathcal{N}(\beta_1; V(b_1))$$

$$\frac{b_1 - \beta_1}{\sqrt{V(b_1)}} \sim \mathcal{N}(0,1)$$

$$\frac{b_0 - \beta_0}{\sqrt{\text{MSE} \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}} \sim t_{n-2}$$

$$IC(1-\alpha): b_0 \pm t_{\frac{\alpha}{2}; n-2} \sqrt{\text{MSE} \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}$$

$$b_0 \pm t_{0,025; 58} \sqrt{\text{MSE} \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right)}$$

$$1,37 \pm 2 \cdot 0,24733$$

$$\rightarrow [0,873; 1,863]$$

$$\frac{b_1 - \beta_1}{\sqrt{\text{MSE} / S_{xx}}} \sim t_{n-2}$$

$$IC(1-\alpha): b_1 \pm t_{\frac{\alpha}{2}; n-2} \sqrt{\text{MSE} / S_{xx}}$$

$$b_1 \pm t_{0,025; 58} \sqrt{\text{MSE} / S_{xx}}$$

$$0,43 \pm 2 \cdot 0,043$$

$$\rightarrow [0,345; 0,514]$$

Std. Error
DANS LA
SORTIE

R-Commander : *Modèles, Intervalles de confiance*

R Intervalles de confiance

Intervalles de confiance pour les coefficients

Niveau de confiance :

```
> Confint(RegModel.1, level=0.95)
              Estimate      2.5 %      97.5 %
(Intercept) 1.3724190 0.8773266 1.8675115
hrs_soleil   0.4312571 0.3452894 0.5172249
```

La relation linéaire entre les heures d'ensoleillement et la production est-elle significative, au seuil de 5% ?

$H_0: \beta_1 = 0$
 $H_1: \beta_1 \neq 0$

ON A REJETÉ H_0 AU SEUIL 5%

6.7 Table d'anova et test de Fisher pour la régression

Hypothèses à tester

Faire le test de la régression, c'est vérifier si la relation linéaire est significative. Bref, on veut savoir si la pente est nulle ou non.

$$H_0 : b_1 = 0$$

$$H_1 : b_1 \neq 0$$


On sait déjà vérifier si 0 est dans l'IC, et on sait interpréter le test de Student sur la pente. En mettant cette statistique au carré, on obtient un test de Fisher basé sur la décomposition de la variabilité des Y_i .

Décomposition de la variance

La variabilité totale dans les données (notée SST) peut être décomposée en deux sources :

- SSR : Somme des carrés de la régression ;
variabilité entre les valeurs prédites par le modèle linéaire, i.e. la variabilité expliquée par la variable X ;
- SSE : Somme des carrés des erreurs ;
la variabilité entre les données autour de la droite pour un x_i donné (source autre que X , que l'on associe à l'erreur échantillonnale non expliquée par le modèle).

Les 60 plants de tomate



Décomposition de la variance

$$SST = SSR + SSE$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n \underbrace{((b_0 + b_1 x_i) - \bar{y})^2}_{\hat{y}_i} + \sum_{i=1}^n \underbrace{(y_i - (b_0 + b_1 x_i))^2}_{\hat{y}_i}$$





Table d'anova

Source de variation	Somme de carrés	Deg. de liberté	Carrés moyens	Statistique F_0
Régression	SS_R	1	$MSR = \frac{SS_R}{1}$	$\frac{MSR}{MSE}$
Erreur	SS_E	$n-2$	$MSE = \frac{SS_E}{n-2}$	$\downarrow$ sous H_0
Total	SS_T	$n-1$	$F_0 = \frac{MSR}{MSE} \sim F_{1; n-2}$	

- σ^2 est la variance autour de la droite pour un X donné. On l'estime par le MSE .
- La proportion de variabilité des Y_i expliquée par X est $R^2 = \frac{SSR}{SST}$, c'est le carré du coefficient de corrélation.

↳ COEFFICIENT DE DÉTERMINATION

Au seuil α , ON REJETTE SI $F_0 = \frac{MS_R}{MS_E} > F_{\alpha; 1; n-2}$



```
> Anova(RegModel.1, type="II")
Anova Table (Type II tests)

Response: production
      Sum Sq Df F value    Pr(>F)
hrs_lumiere 32.547  1  100.83 2.661e-14 ***
Residuals   18.721 58
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Au seuil 5% , ON REJETTE H_0
 CAR $\alpha^* < \alpha$

ON POURRAIT UTILISER LA VALEUR CRITIQUE

$$F_{0,05;1;58} = 4,01$$

ON REJETTE H_0 CAR $F_0 = 100,83 > 4,01$

Conséquence

Si H_0 est vraie,

MS_R



F_0 ↓

Si H_0 est fausse (et donc H_1 est vraie), la statistique F_{obs} aura-t-elle tendance à être plus petite ou plus grande que sous H_0 ?

MS_R ↑

F_0 ↑

Exemple

Quel est le seuil observé du test effectué ?

Rejette-t-on H_0 au seuil de 5% ?

$$\alpha^* = P(\text{OBS. QUELQUE CHOSE D'AU MOINS} \\ \text{AUSSI EXTRÊME SOUS } H_0)$$

$$= P(F_{1;n-2} > F_0)$$