

STT-1920 Méthodes statistiques

Chapitre 6 **Régression linéaire simple** **Deuxième partie**

Département de mathématiques et de statistique
Université Laval

Chapitre 6 : Régression linéaire simple

Prédictions

6.4.4 Intervalle de confiance pour la moyenne de Y en x_*

6.8 Intervalle de prédiction pour une observation future

Qualité de l'ajustement

6.7 Coefficient de détermination R^2

6.9 Coefficient de corrélation r


6.11 Vérification des postulats

Normalité des erreurs

Homogénéité de la variance

6.4.4 IC pour la moyenne de Y en x_* : Exemple

On voudrait construire un intervalle de confiance à 95% pour la production moyenne attendue de tous les plants ayant reçu 6,5 heures d'ensoleillement par jour.



IC pour la moyenne de Y en x_*

La valeur **moyenne** de Y lorsque $X = x_*$ est le point sur la *vraie* droite en $x_* : \beta_0 + \beta_1 x_*$, estimé par $b_0 + b_1 x_*$.

On peut montrer que

$$b_0 + b_1 x_* \sim N \left(\beta_0 + \beta_1 x_* , \sigma^2 \left[\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}} \right] \right)$$

On estime σ^2 par le *MSE* et on obtient l'intervalle de confiance suivant, au niveau $1 - \alpha$;

$$(b_0 + b_1 x_*) \pm t_{n-2, \alpha/2} \sqrt{MSE \left(\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{XX}} \right)}$$

Exemple : IC pour la production moyenne à 6,5 h

$$\bar{x} = 5,5 \text{ h}, \quad s_x^2 = 2,966$$

```
> RegModel.1 <- lm(production~hrs_soleil, data=tomates)
> summary(RegModel.1)
Call:
lm(formula = production ~ hrs_soleil, data = tomates)

Residuals:
    Min       1Q   Median       3Q      Max
-0.97619 -0.45213  0.00378  0.42100  1.11381

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.37242    0.24733   5.549 7.46e-07 ***
hrs_soleil    0.43126    0.04295  10.042 2.66e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5681 on 58 degrees of freedom
Multiple R-squared:  0.6348, Adjusted R-squared:  0.6285
F-statistic: 100.8 on 1 and 58 DF,  p-value: 2.661e-14
```

```
> predict(RegModel.1, newdata=data.frame(hrs_soleil=6.5),
          interval="confidence", level=0.95)
      fit      lwr      upr
1 4.17559 4.005455 4.345725
```

$$\bar{x} = 5,5 \quad s_x^2 = 2,966 \quad b_0 = 1,37 \quad b_1 = 0,43$$

$$\hat{y}_* = b_0 + b_1 x_* = 1,37 + 0,43 \cdot 6,5 = 4,17$$

VARIANCE ESTIMÉE

$$\text{MSE} \left(\frac{1}{n} + \frac{(x_* - \bar{x})^2}{s_{xx}} \right)$$

$$\text{MSE} = 0,5681^2 \quad \left| \quad s_{xx} = 59 \cdot 2,966 = 174,994 \right.$$

$$n = 60$$

$$x_* = 6,5$$

$$\bar{x} = 5,5$$

$$IC(95\%) : 4,17 \pm t_{0,025;58} \cdot \sqrt{0,5681^2 \left(\frac{1}{60} + \frac{(6,5-5,5)^2}{114,994} \right)}$$


$$\rightarrow [4,00; 4,34]$$

Précision optimale ?

Question : Pour quelle valeur de x_* obtient-on la meilleure précision ?

$$(b_0 + b_1 x_*) \pm t_{n-2, \alpha/2} \sqrt{MSE \left(\frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{XX}} \right)}$$

$$x_* = \bar{x}$$

Bornes de confiance à 95 % pour la valeur moyenne de Y 

6.8 Intervalle de prédiction pour une observation future

Le producteur veut vendre des semis de cette variété de tomates, et indiquer des productions attendues dans des conditions similaires de terreau, arrosage, engrais, etc. pour diverses durées d'ensoleillement quotidien.

Selon notre modèle, le plant recevant 6,5 heures d'ensoleillement produira combien de kilos de tomates ?

Quelle est l'erreur-type associée à cette estimation ? Sera-t-elle plus grande ou plus petite que celle de la moyenne attendue avec 6,5 h de soleil ?

Ici, on n'estime plus une constante (la moyenne de la population au point x_*), mais une variable aléatoire (une nouvelle observation). Sa variance sera donc plus grande que celle de la moyenne.

On peut construire un **intervalle de prédiction** de niveau $1 - \alpha$ pour une valeur future de Y , en estimant σ^2 par le MSE :

$$(b_0 + b_1 x_*) \pm t_{n-2, \alpha/2} \sqrt{MSE \left(1 + \frac{1}{n} + \frac{(x_* - \bar{x})^2}{S_{xx}} \right)}$$

Exemple


Construire un intervalle de prédiction à 95% pour la production de tomates du plant ayant reçu 6,5 heures d'ensoleillement.

```
> predict(RegModel.1, newdata=data.frame(hrs_soleil=6.5),  
          interval="prediction", level=0.95)  
      fit      lwr      upr  
1 4.17559 3.025689 5.325492
```



$$b_0 + b_1 x_* = 4,17 \quad \rightarrow \quad t_{0,025;58} = 2,001$$

$$4,17 \pm t_{0,025;58} \sqrt{0,5681^2 \left(1 + \frac{1}{60} + \frac{(6,5-5,5)^2}{174,994} \right)}$$

$$\rightarrow [3,03; 5,33]$$

Bornes de prédiction à 95 % pour la valeur future de Y 

Qualité de l'ajustement




6.7 Coefficient de détermination R^2

On sait que $SSR + SSE = SST$.

R^2 = coefficient de détermination
= proportion de la variabilité totale de Y expliquée
par le modèle (par la variable X)

$$= \frac{SSR}{SST}$$



Propriétés :

- $0 \leq R^2 \leq 1$.
- $R^2 = 0$ si ... $SSR = 0 \rightarrow b_1 = 0$
- $R^2 = 1$ si ... $SSR = SST$

Exemple

```
> RegModel.1 <- lm(production~hrs_soleil, data=tomates)
> summary(RegModel.1)
Call:
lm(formula = production ~ hrs_soleil, data = tomates)

Residuals:
    Min       1Q   Median       3Q      Max
-0.97619 -0.45213  0.00378  0.42100  1.11381

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.37242    0.24733   5.549 7.46e-07 ***
hrs_soleil    0.43126    0.04295  10.042 2.66e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5681 on 58 degrees of freedom
Multiple R-squared:  0.6348, Adjusted R-squared:  0.6285
F-statistic: 100.8 on 1 and 58 DF, p-value: 2.661e-14
```

```
> Anova(RegModel.1, type="II")
Anova Table (Type II tests)

Response: production
      Sum Sq Df F value    Pr(>F)
hrs_lumiere 32.547  1  100.83 2.661e-14 ***
Residuals   18.721 58
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

6.9 Coefficient de corrélation r

Le coefficient de corrélation mesure le degré d'association linéaire entre X et Y .


$$r = \frac{S_{XY}}{\sqrt{S_{XX}S_{YY}}} = \left(\begin{array}{c} \text{signe} \\ \text{de } b_1 \end{array} \right) \times \sqrt{R^2}$$

$$R^2 = r^2$$


Propriétés de r

- $-1 \leq r \leq 1$
- $r > 0$ si $b_1 > 0 \rightarrow$ PENTE DE LA DROITE EST. POSI.
- $r < 0$ si $b_1 < 0 \rightarrow$ " " " " " NÉGATIVE
- $r = 1$ ou -1 si tous les points sont alignés
- $r = 0$ si la pente de la droite estimée est nulle
- Plus r est proche de 1 ou de -1 , plus la relation linéaire est forte
- Ne mesure PAS la causalité de la relation


Corrélation = 0.3




Corrélation = 0.6




Corrélation = 0.9




Corrélation = -0.3



Corrélation = -0.6



Corrélation = -0.9



Exemple

Quel est le coefficient de corrélation entre la production de tomates et le temps d'ensoleillement ?

$$r = \text{SIGNE}(b_1) \sqrt{R^2} = \text{SIGNE}(0,43) \sqrt{\frac{32,547}{32,547 + 18,721}}$$
$$= + \sqrt{0,635} = 0,797$$

```
> cor(tomates[,c("hrs_soleil","production")], use="complete")  
      hrs_soleil production  
hrs_soleil  1.0000000  0.7967679  
production  0.7967679  1.0000000
```

Pourquoi "Régression" ?

ANTHROPOLOGICAL MISCELLANEA.

REGRESSION *towards* MEDIOCRITY *in* HEREDITARY STATURE.


By FRANCIS GALTON, F.R.S., &c.

[WITH PLATES IX AND X.]


THIS memoir contains the data upon which the remarks on the Law of Regression were founded, that I made in my Presidential Address to Section H, at Aberdeen. That address, which will appear in due course in the Journal of the British Association, has already been published in "Nature," September 24th. I reproduce here the portion of it which bears upon regression, together with some amplification where brevity had rendered it obscure, and I have added copies of the diagrams suspended at the meeting, without which the letterpress is necessarily difficult to follow. My object is to place beyond doubt the existence of a simple and far-reaching law that governs the hereditary transmission of, I believe, every one of those simple qualities which all possess, though in unequal degrees. I once before ventured to draw attention to this law on far more slender evidence than I now possess.

It is some years since I made an extensive series of experiments on the produce of seeds of different size but of the same species. They yielded results that seemed very noteworthy, and I used them as the basis of a lecture before the Royal Institution on February 9th 1877. It appeared from these experiments that the offspring

Données de Galton (1886)



Données de Pearson (1903)



Vérification des postulats

6.11 Vérification des postulats

La construction de la statistique de Fisher et des intervalles de confiance/prédiction s'est basée sur les postulats suivants :

- L'indépendance des observations Y_i .
- La relation présumée entre X et Y est linéaire.
- La normalité des observations autour de la droite.
- La constance de la variance autour de la droite pour toutes les valeurs de X .

Normalité des observations

Analyse des résidus

Rappel du modèle : $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$

Puisque $Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$, il suit que $\varepsilon_i \sim N(0, \sigma^2)$.

Les erreurs échantillonnales, ε_i , sont estimées par les *résidus* du modèle :

$$\hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - (b_0 + b_1 x_i)$$

Au lieu d'analyser directement les observations, nous analyserons les résidus.



Calcul des résidus

Dans notre exemple, voici quelques calculs de résidus :

$$\hat{y} = 1,368 + 0,431 x$$

Donnée	i	1	12	24	51
Hrs soleil	x_i	3	4	5	8
Prod. observée	y_i	2,92	2,92	3,21	4,08
Prod. prédite	$b_0 + b_1 x_i$	2,67	3,10	3,53	
Résidu	$\hat{\varepsilon}_i$	0,25	-0,18	-0,32	

Normalité des erreurs



```
> with(tomates, shapiro.test(residuals.RegModel.1))
```

```
Shapiro-Wilk normality test
```

```
data: residuals.RegModel.1  
W = 0.96941, p-value = 0.1365
```

Homogénéité de la variance

Diagramme de dispersion des résidus en fonction des valeurs prédites

