

STT-1920 Méthodes statistiques

Chapitre 7 **Tableaux de fréquences et tests du khi-deux**

Département de mathématiques et de statistique
Université Laval

Chapitre 7 :

7.1 Test d'adéquation pour une variable discrète

7.2 Test d'homogénéité de I populations

7.3 Test d'indépendance de deux variables discrètes

7.1 Test d'adéquation pour une variable discrète

L'objet : une variable qualitative ou quantitative discrète ayant un nombre fini de valeurs possibles.

La question : le modèle théorique de probabilités est-il adéquat pour décrire la distribution de cette variable dans la population qui nous intéresse ?

Le but : comparer un ensemble d'observations avec les fréquences attendues sous le modèle théorique pour déterminer si ce modèle s'ajuste bien aux données.

Exemple 1

On croise des individus de génotype $AAbb$ avec des individus de génotype $aaBB$. Tous les hybrides seront de la forme $AaBb$.

- A et B sont des allèles dominants (qui s'expriment avec 1 ou 2 copies)
- a et b sont des allèles récessifs (s'expriment avec 2 copies seulement).

Si on croise des hybrides, il y a 16 génotypes possibles, mais seulement 4 expressions possibles des gènes (phénotypes) : AB, Ab, aB et ab.

Exemple 1

A: POILS NOIRS

B: PEUAGE UNI


Selon les lois de Mendel, qui supposent que les deux gènes ne sont pas liés entre eux, les quatre phénotypes devraient se retrouver dans la progéniture du croisement dans des proportions respectives de

AB : 9/16,

Ab : 3/16,

aB : 3/16, et

ab : 1/16.



Que penser de l'hypothèse mendélienne lorsqu'on la confronte aux observations ?

Exemple 1

On veut donc tester les hypothèses suivantes :

$$H_0 : p_1 = \frac{9}{16}, \quad p_2 = \frac{3}{16}, \quad p_3 = \frac{3}{16}, \quad p_4 = \frac{1}{16}$$

H_1 : au moins une des égalités n'est pas vérifiée.

Il faudra récolter des données dans une population (i.e. effectuer plusieurs croisements et noter le phénotype), et comparer les fréquences observées et théoriques pour décider si on rejette H_0 ou non au seuil α .

De façon générale, l'hypothèse nulle pourrait s'écrire :

$$H_0 : (p_1, p_2, \dots, p_J) = (p_1^*, p_2^*, \dots, p_J^*)$$

Tableau des fréquences observées

Le tableau de fréquences donne le nombre de cas observés ($O_1, O_2, \dots, O_J$) dans l'échantillon pour chaque valeur de cette variable ($v_1, v_2, \dots, v_J$).

Valeur	v_1	v_2	...	v_J	Total
Fréquence observée O_i	O_1	O_2		O_J	n

Fréquences espérées sous H_0

Les fréquences observées seront comparées aux fréquences attendues sous H_0 , donc avec le modèle théorique $(E_1, E_2, \dots, E_J)$.

Valeur	v_1	v_2	...	v_J	Total
Fréq. observée O_i	O_1	O_2	...	O_J	$= n$
Fréq. espérée E_i	E_1	E_2	...	E_J	n

Ces fréquences espérées se calculent comme suit :

$$E_i = p_i \times n$$

Exemple 1


Voici les résultats d'une expérience effectuée sur 1611 vaches.
Quelles sont les fréquences espérées sous H_0 , i.e. sous l'hypothèse de Mendel ?

Génotype	AB	Ab	aB	ab	Total
Fréq. obs. (O_i)	926	288	293	104	1611
Fréq. esp. (E_i)	906	302	302	101	1611

$$E_1 = p_1 \times n = \frac{9}{16} \cdot 1611 = 906$$

$$E_2 = p_2 \times n = \frac{3}{16} \cdot 1611 = 302$$

Exemple 1



"Distance" entre le modèle et les observations

Pour déterminer à quel point les données et le modèle sont en accord, il faut comparer les O_i et les E_i . Si l'écart est trop grand, on rejettera H_0 ~~on rejettera H_0~~

Comment mesure-t-on cet écart ?

$$O_i \approx \text{Poisson}(E_i)$$

$$E[O_i] \approx E_i$$

$$V[O_i] \approx E_i$$

COMME n EST SUFF. GRAND

$$\frac{O_i - E_i}{\sqrt{E_i}} \approx N(0,1)$$

$$\frac{(O_i - E_i)^2}{E_i} \approx \chi^2_1$$

Règle de décision


Si H_0 est vraie,

$$D = \sum_{i=1}^J \frac{(O_i - E_i)^2}{E_i} \sim \chi^2_{J-1}$$

On rejettera donc H_0 si...

AU SEUIL α

$$D_{OBS} > \chi^2_{\alpha; J-1}$$



Exemple 1

Au seuil de 5%, rejette-t-on l'hypothèse de Mendel ?

Génotype	AB	Ab	aB	ab	Total
Fréq. obs. (O_i)	926	288	293	104	1611
Fréq. esp. (E_i)	906	302	302	101	1611
Distance	0,442	0,649	0,268	0,089	1,448

$$D_1 = \frac{(926 - 906)^2}{906} = 0,442$$

$$\chi^2_{0,05;3} = 7,81$$

COMME $D_{OBS} = 1,448 < 7,81$
ON NE REJETTE PAS H_0

Exemple 1 : Conclusion

$$\alpha^* = P(\chi^2_3 > 1,448)$$

$$\in [0,5; 0,9]$$

Remarques

- Ce test est valide si les fréquences espérées sont toutes supérieures à 5
- Si le modèle théorique est une loi paramétrique (Normale, Poisson, etc.), la loi du χ^2 perd un degré de liberté supplémentaire pour chaque paramètre estimé.

7.2 Test d'homogénéité de I populations

On s'intéresse à la distribution d'une variable discrète dans I populations.

On veut savoir si cette **distribution est la même pour toutes les populations** ou non, i.e. si ces populations sont *homogènes* ou non.

- ▶ Distribution de la variable dans la pop. 1 : $(p_{11}, p_{12}, \dots, p_{1J})$
- ▶ Distribution de la variable dans la pop. 2 : $(p_{21}, p_{22}, \dots, p_{2J})$
- ▶ ...
- ▶ Distribution de la variable dans la pop. I : $(p_{I1}, p_{I2}, \dots, p_{IJ})$

Les hypothèses du test

On voudra tester les hypothèses suivantes :

$$\begin{aligned} p_{11} &= p_{21} = \dots = p_{I1} \\ p_{12} &= p_{22} = \dots = p_{I2} \\ &\vdots \end{aligned}$$

H_0 : les I distributions sont toutes les mêmes

H_1 : au moins une de ces distributions diffère des autres

- ▶ On tire un échantillon de taille n_1 dans la pop. 1 ;
- ▶ On tire un échantillon de taille n_2 dans la pop. 2 ;
- ▶ ...
- ▶ On tire un échantillon de taille n_I dans la pop. I ;

Tableau de fréquences

Population	Valeurs de la variable				Total
	v_1	v_2	...	v_J	
1	O_{11}	O_{12}	...	O_{1J}	$= n_1$
2	O_{21}	O_{22}	...	O_{2J}	$+ n_2$
...	...	...	...	...	$+ \dots$
I	O_{I1}	O_{I2}	...	O_{IJ}	$+ n_I$
Total	$O_{\bullet 1}$	$O_{\bullet 2}$	...	$O_{\bullet J}$	$= n$

OBSERVATION DE
LA 1^{re} VARIABLE
DANS LA POP. 2

SI LES LOIS
SONT LES MÊMES
DANS CHAQUE POP

$$\frac{O_{11}}{n_1} \approx \frac{O_{21}}{n_2} \approx \dots \approx \frac{O_{\bullet 1}}{n}$$

$$\frac{O_{12}}{n_1} \approx \dots \approx \frac{O_{\bullet 2}}{n}$$

$$O_{\bullet 1} = O_{11} + O_{21} + \dots + O_{I1}$$

Exemple 2



On veut comparer la capacité à vivre seul(e) des hommes et des femmes après le décès de leur conjoint(e). On obtient des données sur 150 personnes.

Population	Années vécues après le décès			Total
	< 5 ans	5 à 10 ans	> 10 ans	
Hommes (veufs)	25	42	33	100
Femmes (veuves)	19	20	11	50
Total	44	62	44	150

(Walpole et Myers, *Probability and Statistics for Engineers and Scientists*)

Exemple 2

Lequel des deux graphiques ci-dessous illustre le mieux les distributions que nous souhaitons comparer ?



Si H_0 était vraie...

Si H_0 est vraie, toutes les distributions théoriques sont homogènes, i.e. égales à une distribution commune (inconnue)

$p_1, p_2, \dots, p_J$.

$$\hat{p}_j = \frac{O_{\cdot j}}{n}$$

On pourra estimer ces proportions comme suit :

$$\hat{p}_1 = \frac{O_{\cdot 1}}{n} = \frac{44}{150}$$

$$\hat{p}_2 = \frac{O_{\cdot 2}}{n} = \frac{62}{150}$$

...

$$\hat{p}_J =$$

$$\hat{p}_3 = \frac{O_{\cdot 3}}{n} = \frac{44}{150}$$

Calcul des fréquences espérées

Si H_0 est vraie, on s'attend à ce que :

$$\frac{O_{11}}{n_1} \approx \frac{O_{\bullet 1}}{n} \Leftrightarrow O_{11} \approx n_1 \frac{O_{\bullet 1}}{n} = n_1 \cdot \hat{p}_1 = E_{11}$$

$$\frac{O_{21}}{n_2} \approx \frac{O_{\bullet 1}}{n} \Leftrightarrow O_{21} \approx n_2 \frac{O_{\bullet 1}}{n} = n_2 \cdot \hat{p}_1 = E_{21}$$

...

$$\frac{O_{ij}}{n_i} \approx \frac{O_{\bullet j}}{n} \Leftrightarrow O_{ij} \approx n_i \frac{O_{\bullet j}}{n} = n_i \cdot \hat{p}_j = E_{ij}$$

Règle de décision

Si H_0 est vraie,

$$D = \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(I-1)(J-1)}$$

→ AU SEUIL α

On rejettera donc H_0 si la "distance" entre le modèle d'homogénéité et les observations est trop grande, i.e. si...

$$D_{obs} > \chi^2_{\alpha; (I-1)(J-1)}$$

Exemple 2

Au seuil de 1%, peut-on dire que la distribution du nombre d'années de vie est la même chez les hommes et chez les femmes ?

Population	Années vécues après le décès			Total
	< 5 ans	5 à 10 ans	> 10 ans	
Hommes (veufs) E_{ij}	25 $\frac{44}{150} \cdot 100 = 29.3$	42 41.3	33 29.3	100
Femmes (veuves)	19 14.7	20 20.7	11 14.7	50
Total	44	62	44	150

Exemple 2

$$D = \frac{(O_{11} - E_{11})^2}{E_{11}} + \frac{(O_{12} - E_{12})^2}{E_{12}} + \dots$$

$$D_{\text{OBS}} = \frac{(25 - 29,3)^2}{29,3} + \dots + \frac{(11 - 14,7)^2}{14,7} = 3,33$$

LA VALEUR CRITIQUE EST $\chi^2_{0,01;2} = 9,21$

COMME $D_{\text{OBS}} = 3,33 < 9,21$

ON NE REJETTE PAS H_0 AU SEUIL 1%

Exemple 2 : Conclusion

7.3 Test d'indépendance de deux variables discrètes

On est ici en présence de deux variables, toutes les deux qualitatives ou quantitatives discrètes. On voudra tester les hypothèses

H_0 : les deux variables sont indépendantes

H_1 : les deux variables sont dépendantes.

Deux variables sont indépendantes si le fait de connaître la valeur de l'une des deux variables ne nous apprend rien sur la valeur de l'autre.

Exemple 3

Une étude est conduite en Virginie auprès de 1030 paires de femmes jumelles pour étudier un lien possible entre la génétique et l'alcoolisme. Une entrevue a permis de classer chaque femme comme ayant une consommation abusive d'alcool ou non. Voici les résultats.

Jumelles	Jumelles ayant un problème d'alcool			Total
	0	1	2	
Identiques	443	102	45	590
Fraternelles	301	113	26	440
Total	744	215	71	1030

K.S. Kendler et al, *A population-based twin study of alcoholism in women*, Journal of the American Medical Association, 268 (1992).

Exemple 3

Y a-t-il une relation significative entre le type de jumelles et la présence de problème d'alcool ? Si les variables étaient indépendantes :

- on devrait observer la même proportion de paires sans problème d'alcool parmi les jumelles identiques que parmi les jumelles fraternelles (i.e. 744 sur 1030 $\approx 0,72$) ;
- on devrait observer la même proportion de jumelles identiques parmi les paires sans problème d'alcool que parmi celles avec problème d'alcool (i.e. 590 sur 1030 $\approx 0,57$).

Exemple 3

Quelle est votre impression ?




Tableau de fréquences

Variable 1	Valeurs de la variable 2				Total
	v_1	v_2	...	v_J	
v_1	O_{11}	O_{12}	...	O_{1J}	$O_{1\bullet}$
v_2	O_{21}	O_{22}	...	O_{2J}	$O_{2\bullet}$
...	...	...	...	...	...
v_I	O_{I1}	O_{I2}	...	O_{IJ}	$O_{I\bullet}$
Total	$O_{\bullet 1}$	$O_{\bullet 2}$	...	$O_{\bullet J}$	n

Calcul des fréquences espérées

Si H_0 est vraie, on s'attend à ce que :


$$\begin{aligned}
 \frac{O_{11}}{O_{1\bullet}} &\approx \frac{O_{\bullet 1}}{n} &\Leftrightarrow O_{11} &\approx \frac{O_{1\bullet} \cdot O_{\bullet 1}}{n} = E_{11} \\
 \frac{O_{21}}{O_{2\bullet}} &\approx \frac{O_{\bullet 1}}{n} &\Leftrightarrow O_{21} &\approx \frac{O_{2\bullet} \cdot O_{\bullet 1}}{n} = E_{21} \\
 &\dots &&\vdots \\
 \frac{O_{ij}}{O_{i\bullet}} &\approx \frac{O_{\bullet j}}{n} &\Leftrightarrow O_{ij} &\approx \frac{O_{i\bullet} \cdot O_{\bullet j}}{n} = E_{ij}
 \end{aligned}$$

Règle de décision

Si H_0 est vraie,

$$D = \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(I-1)(J-1)}$$

On rejettera donc H_0 si la "distance" entre le modèle d'indépendance et les observations est trop grande, i.e. si...



Exemple 3

Peut-on dire au seuil de 5% que la relation entre le type de jumelles et la présence de problème d'alcool est significative ?

Jumelles	Problème d'alcool			Total
	0	1	2	
Identiques	443	102	45	590
E_{1j}	426.2	123.16	40.67	
D_{1j}	0.66	3.63	0.46	
Fraternelles	301	113	26	440
E_{2j}	317.8	91.8	30.3	
D_{2j}	0.89	4.87	0.62	
Total	744	115	71	1030

$$E_{13} = \frac{71 \cdot 590}{1030}$$

$$= 40.67$$

$$D_{13} = \frac{(45 - 40.67)^2}{40.67}$$

$$E_{23} = \frac{71 \cdot 440}{1030}$$

$$D_{23} = \frac{(26 - 30.3)^2}{30.3}$$

Exemple 3 Sous H_0 , $D \sim \chi^2_{(I-1)(J-1)}$
 $(I-1)(J-1) = 2$

ON REJETTE H_0 AU SEUIL 5%
 SI $D_{0.05} > \chi^2_{0.05; 2} = 5.99$

$$D_{0.05} = 0.66 + 3.63 + \dots + 0.62 = 11.14$$


ON REJETTE H_0 CAR $11.14 > 5.99$

Question

Si le but de l'étude est d'étudier l'existence d'un lien entre la génétique et l'alcoolisme, est-ce que le test d'indépendance sur ces données répondait à la question ?

Exemple 3 - revisité

Jumelles	Jumelles ayant un problème d'alcool		Total
	0 ou 2	1	
Identiques	488	102	590
Fraternelles	327	113	440
Total	815	215	1030



Remplissez la table à double entrées

Table Statistiques

Nombre de lignes : 2

Nombre de colonnes : 2

Entrez les dénombrements :

	1	2
1	488	102
2	327	113

Remplissez la table à double entrées

Table Statistiques

Calculer les pourcentages

☐ Pourcentages des lignes
☐ Pourcentage des colonnes
☐ Pourcentages du total
☒ Pas de pourcentages

Test d'hypothèse

☒ Test Chi-deux d'indépendance
☒ Composants de la statistique du Chi-deux
☒ Imprimer les fréquences attendues
☐ Test exact de Fisher

Dans R-commander

```

> .Table # Counts
      1      2
1 488 102
2 327 113

> .Test <- chisq.test(.Table, correct=FALSE)
> .Test
      Pearson's Chi-squared test
data:  .Table
X-squared = 10.751, df = 1, p-value = 0.001042

> .Test$expected # Expected Counts
      1      2
1 466.8447 123.15534
2 348.1553  91.84466

> round(.Test$residuals^2, 2) # Chi-square Components
      1      2
1 0.96 3.63
2 1.29 4.87

```