



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Examen 3 (25 %)
Méthodes statistiques (STT-1920)
26 avril 2022 de 10h30 à 12h20

Enseignant : Julien Miron

Directives de l'évaluation

- Matériel autorisé:
 - Calculatrice scientifique **autorisée par la faculté des sciences et de génie**;
 - Une seule feuille aide-mémoire **manuscrite** de format lettre (8.5"×11") recto-verso.
- Assurez-vous que cette évaluation comporte 11 questions (incluant 1 question bonus) réparties sur 13 pages, pour un total de 80 points et 6 points bonus.
- Veuillez ne pas débrocher votre examen.**
- Les tables de lois se trouvent à la fin du cahier d'examen aux pages 23 à 28. **Veuillez ne rien débrocher!**
- Veuillez déposer votre carte d'identité **admise** avec photo sur votre bureau.
- Vous devez justifier votre raisonnement, sauf pour les questions à choix de réponse et les questions vrai ou faux.
- Répondez aux questions sur le questionnaire dans les cases prévues à cet effet. **Seules les réponses écrites dans les encadrés correspondants seront corrigées.** Il en va de même pour les questions à choix multiples!
- Le verso des feuilles peut être utilisé comme brouillon, **mais ne sera pas corrigé.** Attention à ne rien débrocher.

Exercice 1 (3 points)

Soit la table d'ANOVA suivante obtenue à l'aide de Rcmdr :

```
>summary(AnovaModel)
      Df  Sum Sq  Mean Sq  F value    Pr(>F)
Saumons  4   926.12    231.53    238.72  0.0001
Residuals 48    46.55     0.97
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est vraie ?

- A) La proportion de la variance totale expliquée par le facteur Saumons est égale à 0,0001.
- B) Nous avons 4 niveaux différents pour le facteur Saumons.
- C) La variance du facteur Saumons est environ 20 fois plus grande que la variance du facteur Residuals.
- D) L'hypothèse nulle suppose que les moyennes des différents niveaux du facteur Saumons étaient toutes égales.

Exercice 2 (3 points)

Laquelle des affirmations suivantes est vraie ?

- A) Le modèle d'analyse de la variance à deux facteurs permet de contrôler la variabilité due à un facteur qui ne nous intéresse pas.
- B) Le modèle d'analyse de la variance à deux facteurs est $Y_{ijk} = \mu + \tau_i + \beta_j + E_{ijk}$
- C) Si de l'interaction est présente dans un modèle d'ANOVA à deux facteurs, cela veut dire que l'effet d'un facteur dépend du niveau de l'autre facteur.
- D) Pour que la conclusion d'une ANOVA à deux facteurs soit valide, au moins un des postulats doit être respecté.

Mise en situation - Questions 3 et 4

Un ingénieur souhaite comparer la performance de trois marques de freins à disque pour vélo de route. La variable d'intérêt sera donc la distance de freinage parcourue pour passer de 40km/h à 0km/h. L'expérience est répétée k fois pour chaque type de frein. Utilisez la table d'ANOVA suivante pour répondre aux questions 3 et 5.

	Df	Sum Sq	F value	Pr(>F)
disque	2	45.77	14.329	0.000001
Residuals	57	91.03		

Exercice 3 (3 points)

Laquelle des affirmations suivantes est vraie ?

- A) Nous savons que $k = 60$.
- B) L'estimateur de la variance σ^2 est environ 1,60.
- C) La variable réponse est la distance de freinage et le facteur est Residuals.
- D) Comme il s'agit d'une régression linéaire simple, il n'y a pas de facteur.

Exercice 4 (3 points)

Quelle conclusion peut-on tirer à partir de cette table d'ANOVA, au seuil de 1% ?

- A) La variance de la distance de freinage d'au moins une marque de frein est différente d'au moins une autre marque.
- B) La distance de freinage moyenne d'au moins une marque de frein est différente d'au moins une autre marque.
- C) Comme il y a de l'interaction, nous ne pouvons tirer aucune conclusion sur les facteurs individuels.

Exercice 5 (8 points)

Voici quatre sorties obtenues avec Rcmdr.

Sortie A

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
FacteurA	3	1049.94	349.98	300.29	0.00001
FacteurB	2	840.02	420.01	360.38	0.00001
FacteurA:FacteurB	6	1493.05	248.84	213.51	0.00001
Residuals	60	69.93	1.17		

Sortie B

	Df	Sum Sq.	Mean Sq	F value	Pr(>F)
FacteurA	3	1.62	0.54	0.4437	0.7226
FacteurB	2	751.54	375.77	308.4150	0.00001
FacteurA:FacteurB	6	4.26	0.71	0.5825	0.7428
Residuals	60	73.10	1.22		

Sortie C

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
FacteurA	3	990.23.	330.08	406.3890	0.00001
FacteurB	2	767.49	383.74	472.4639	0.00001
FacteurA:FacteurB	6	4.22	0.70	0.8651	0.5258
Residuals	60	48.73	0.81		

Sortie D

	Df	Sum Sq.	Mean Sq	F value	Pr(>F)
FacteurA	3	148.095	49.365	45.2107	0.00001
FacteurB	2	0.668	0.334	0.3059	0.7376
FacteurA:FacteurB	6	1.316	0.219	0.2009	0.9752
Residuals	60	65.513	1.092		

La page précédente (page 6) contient quatre figures représentant les moyennes des combinaisons de deux facteurs. Pour chacun des énoncés suivants, inscrivez le **numéro** de la figure correspondante dans la case.

(a) (2 points) La figure qui correspond à la **Sortie A** est la Figure

(b) (2 points) La figure qui correspond à la **Sortie B** est la Figure

(c) (2 points) La figure qui correspond à la **Sortie C** est la Figure

(d) (2 points) La figure qui correspond à la **Sortie D** est la Figure

Exercice 6 (12 points)

Pour chacune des mises en situation ci-bas, donnez la lettre du modèle qui correspond parmi les suivants :

A : **Régression linéaire simple**

B : **Analyse de la variance à un facteur**

C : **Analyse de la variance à deux facteurs**

- (a) (3 points) Alexis aimerait savoir si le nombre de minutes que ses amis et lui passent à jouer à l'ordinateur à chaque semaine a un impact sur leur note à l'examen final de mathématiques de secondaire 5. Il prévoit donc étudier l'effet des minutes à jouer à l'ordinateur sur la note de l'examen.
- (b) (3 points) Amandine aimerait comparer la performance de 8 types d'engrais. Elle utilise donc 5 plants de tomates pour chacun des types d'engrais (40 plants au total) et elle mesure la quantité de tomates produites.
- (c) (3 points) Benjamin veut savoir si le poids des hérissons est impacté par le type de régime de ceux-ci (parmi 3 régimes possibles) ainsi que par le milieu de vie (parmi 2 milieux de vie possibles). Pour chacune des combinaisons de type de régime et de milieu de vie, il soumet 3 hérissons à la combinaison et mesure le poids des hérissons.
- (d) (3 points) Émile et Léon veulent savoir si la puissance générée par un cycliste a un impact sur le temps d'ascension du fameux *Molard* de Gilly. Ils mesurent donc la puissance moyenne de 25 cyclistes pendant l'ascension ainsi que le temps d'ascension en secondes.

Exercice 7 (10 points)

Déterminez si les énoncés suivants sont vrais ou faux.

Inscrivez «Vrai» ou «Faux» dans les cases appropriées.

- (a) (2 points) Pour que l'analyse de la variance à 1 facteur soit valide, il faut qu'au moins un des postulats soit respecté.
- (b) (2 points) Lorsqu'un facteur a 2 niveaux, on peut utiliser l'analyse de la variance à un facteur ou un test de Student de comparaison de moyennes avec variances égales pour comparer les moyennes des niveaux.
- (c) (2 points) En faisant une analyse de la variance à deux facteurs, nous obtenons une *valeur-p* associée à la statistique observée du terme d'interaction égale à 0,001. Au seuil $\alpha = 0,05$, l'interaction est significative et nous n'interprétons pas les facteurs individuellement.
- (d) (2 points) Dans un modèle de régression linéaire simple, si l'intervalle de confiance à 95% pour β_0 est $[0.345; 12.765]$, nous sommes certain qu'une relation linéaire existe entre X et Y .
- (e) (2 points) Dans le contexte d'une régression linéaire simple, nous avons que $y_i = x_i$ pour $i = 1, \dots, n$. L'estimateur de β_0 et l'estimateur de β_1 valent tous deux 0.

Exercice 8 (12 points)

Une expérience est menée pour étudier l'effet de trois Types d'Essence (A, B et C) et de quatre Types d'Additifs pour essence (W, X, Y et Z) sur la consommation d'essence (en L par 100km) obtenue par un véhicule d'essai. On a évalué aléatoirement k consommations pour chacune des 12 combinaisons à l'aide d'un plan d'expérience complètement randomisé. On suppose que les postulats sont respectés. Voici une partie d'une sortie Rcmdr.

	Df	Sum Sq	F value	Pr(>F)
Additifs	3	52.028	21.1174	0.00004445
Types.d.essence	2	19.823	12.0690	0.001341
Additifs:Types.d.essence	6	37.693	7.6496	0.001503
Residuals	12	9.855		

- (a) (3 points) Donnez une estimation de la variance des termes d'erreur, σ^2 . Justifiez votre réponse.
 (b) (3 points) Trouvez la valeur de k , le nombre de consommations évaluées par combinaison des facteurs. Justifiez.
 (c) (3 points) Soit les hypothèses suivantes :

$$H_0 : (\tau\beta)_{ij} = 0 \text{ pour } i = 1, \dots, a, j = 1, \dots, b,$$

$$H_1 : \text{il existe au moins une paire } (i, j), \text{ pour laquelle } (\tau\beta)_{ij} \neq 0.$$

Parmi les décisions suivantes, choisissez celle qui est la bonne au seuil $\alpha = 5\%$:

- A) Nous rejetons H_0 au seuil $\alpha = 5\%$.
 B) Nous ne rejetons pas H_0 au seuil $\alpha = 5\%$.

- (d) (3 points) Parmi les conclusions suivantes, choisissez celle qui est la bonne au seuil $\alpha = 5\%$:

- A) L'interaction est significative et on peut tester les effets des facteurs individuels à partir de la table d'Anova.
 B) L'interaction est significative et on ne teste pas les effets des facteurs individuels à partir de la table d'Anova.
 C) Il n'y a pas d'interaction significative, donc on ne peut rien dire sur les facteurs individuels à partir de la table d'Anova.
 D) Il n'y a pas d'interaction significative et le facteur Types d'Essence est le seul qui est significatif.
 E) Il n'y a pas d'interaction significative et le facteur Types d'Additifs est le seul qui est significatif.
 F) Il n'y a pas d'interaction significative et les deux facteurs sont significatifs.

Exercice 9 (8 points)

Avant de procéder à une ANOVA à un facteur, on veut s'assurer que les conditions d'application du modèle d'analyse de la variance sont respectés. On produit les graphiques ci-dessous pour valider les postulats.

Nommez précisément deux postulats du modèle que vous devriez vérifier à partir des graphiques ci-haut. Pour chacun d'eux, identifiez les deux figures utiles à sa validation et dites s'il est respecté ou non. Des points seront accordés aux choix de figures et à la conclusion s'ils sont cohérents avec le postulat identifié.

• **Postulat :**

Fig. i ☐ Fig. ii ☐ Fig. iii ☐ Fig. iv ☐

Postulat respecté ?

Oui ☐ Non ☐

• **Postulat :**

Fig. i ☐ Fig. ii ☐ Fig. iii ☐ Fig. iv ☐

Postulat respecté ?

Oui ☐ Non ☐

Exercice 10 (18 points)

Pour des raisons de santé publique, on s'intéresse à la concentration d'ozone O_3 dans l'air (en microgrammes par millilitre). En particulier, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone de la journée par la température à midi donnée en degrés celsius. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, vous disposez des résultats suivants :

Residual standard error: 12.67 on 8 degrees of freedom

Multiple R-squared: 0.7041, Adjusted R-squared: 0.6671

F-statistic: 19.03 on 1 and 8 DF, p-value: 0.002403

$$\sum_{i=1}^{10} x_i = 219,1; \quad \sum_{i=1}^{10} x_i^2 = 5214,58; \quad \sum_{i=1}^{10} y_i = 1026,4; \quad \sum_{i=1}^{10} y_i^2 = 118446,6; \quad \sum_{i=1}^{10} x_i y_i = 23650,84.$$

Vous savez aussi que

$$S_{XY} = \sum_i^n x_i y_i - n \bar{x} \bar{y}; \quad S_{XX} = \sum_i^n x_i^2 - n \bar{x}^2.$$

- (a) (8 points) Donnez l'équation de la droite de régression permettant de prédire la concentration d'ozone O_3 dans l'air en fonction de la température à midi. Justifiez toutes les étapes de votre démarche.
- (b) (2 points) Donnez le pourcentage de la variabilité totale de la concentration d'ozone O_3 dans l'air qui est expliquée par la température à midi.

Suite de l'exercice 10 sur la feuille suivante

Suite de l'exercice 10

Suite de l'exercice 10

- (c) (3 points) Calculez la prévision ponctuelle de la concentration d'ozone O_3 dans l'air pour une température de 22 degrés. Justifiez toutes les étapes de votre démarche.
- (d) (2 points) Un chercheur aimerait estimer la concentration d'ozone O_3 dans l'air en une journée précise. Le midi de cette journée, la température est de 14 degrés. La prévision ponctuelle de la concentration d'ozone O_3 dans l'air en cette journée est environ de 81,83. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la concentration d'ozone O_3 dans l'air en cette journée.

$$A) 80,47 \pm t_{0,025,n-2} \sqrt{MSE \left[\frac{1}{n} + \frac{(14-\bar{x})^2}{S_{xx}} \right]}$$

$$B) 80,47 \pm t_{0,025,n-2} \sqrt{MSE \left[1 + \frac{1}{n} + \frac{(14-\bar{x})^2}{S_{xx}} \right]}$$

- (e) (1 point) Si la température à midi ce jour la était de 18 degrés, l'intervalle de valeurs calculé à la question précédente serait...
- A) plus court
 - B) de même longueur
 - C) plus long
- (f) (2 points) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?
- A) La concentration d'ozone O_3 dans l'air et la température à midi ne sont pas unis par une relation linéaire significative.
 - B) On ne peut pas prédire la concentration d'ozone O_3 dans l'air à partir de la température à midi.
 - C) La concentration d'ozone O_3 dans l'air et la température à midi sont indépendantes.
 - D) La relation linéaire entre la concentration d'ozone O_3 dans l'air et la température à midi est significative.

Exercice 11 BONUS (6 points)

Supposons un modèle de régression linéaire

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \text{ pour } i = 1, \dots, n$$

où $\epsilon_i \sim \mathcal{U}[-a, a]$, c'est-à-dire une loi uniforme sur $[-a, a]$. Nous avons les informations suivantes :

$$E(\epsilon) = 0$$

$$Var(\epsilon) = \frac{4a^2}{12}$$

(a) (3 points) Donnez $E(Y_i)$ et $Var(Y_i)$.

(b) (3 points) Quelle est la loi de Y ? Donnez autant de détails que possible.