



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Examen 3 (25 %)

Méthodes statistiques (STT-1920)

Enseignant : Julien Miron

Directives de l'évaluation

- Matériel autorisé:
 - Calculatrice scientifique **autorisée par la faculté des sciences et de génie**;
 - Une seule feuille aide-mémoire **manuscrite** de format lettre (8.5"×11") recto-verso.
 - Assurez-vous que cette évaluation comporte 9 exercices (incluant 1 question bonus) répartis sur 11 pages, pour un total de 94 points et 6 points bonus.
 - Veillez ne pas dégrafer votre examen.**
 - Vous devez **justifier toutes vos réponses** par une démarche claire, sauf pour les questions à choix de réponse.
 - Pour les questions à choix de réponse et les vrais ou faux, vous pouvez mettre un X, un crochet (✓) ou remplir la case.
 - Vous devez laisser tout ce qui ne servira pas durant l'examen à l'avant de la salle AVANT de rejoindre votre place.
 - Vous n'avez droit à AUCUN appareil électronique en votre possession durant l'examen.
 - Une fois assis à votre place, vous devez demander l'autorisation pour vous lever, même si l'examen n'est pas encore commencé.
 - Dans les 5 dernières minutes de l'examen, il sera interdit de se lever avant que TOUTES les copies n'aient été ramassées.
- Le non-respect des consignes 7-8-9 entraînera une pénalité de 10%.

Mise en situation – Exercices 1 et 2

Un ingénieur souhaite comparer la performance de trois marques de freins à disque pour vélo de route. La variable d'intérêt sera donc la distance de freinage parcourue pour passer de 40 km/h à 0 km/h. L'expérience est répétée n fois pour chaque type de frein. Utilisez la table d'ANOVA suivante pour répondre aux exercices 1 et 2.

	SS	DDL	MS	F0	valeur-p
Traitement	45.77	2	22.885	14.329	0.000001
Erreur	91.03	57	1.597		

Exercice 1 (3 points)

Laquelle des affirmations suivantes est vraie ?

- ☐ Nous savons que $n = 60$.
- ☒ **L'estimateur de la variance est 1,597.**
- ☐ La variable réponse est la distance de freinage et le facteur est Erreur.
- ☐ Comme il s'agit d'une régression linéaire simple, il n'y a pas de facteur.

Solution: B est vraie. $\hat{\sigma}^2 = MS_{\text{Residuals}} = SS_{\text{Residuals}}/DDL_{\text{Residuals}} = 91,03/57 \approx 1,597 \approx 1,60$.

A) $DDL_{\text{disque}} = I - 1 = 2$, donc $I = 3$ marques. $DDL_{\text{Residuals}} = n - I = 57$, donc $n = 60$. Avec $I = 3$ marques et $n = 60$ observations, $k = n/I = 20$ répétitions par marque (pas $k = 60$).

C) Le facteur est disque, pas Residuals.

D) Il s'agit d'une ANOVA, pas d'une régression.

Exercice 2 (3 points)

Quelle conclusion peut-on tirer à partir de cette table d'ANOVA, au seuil de 1% ?

- ☐ La variance de la distance de freinage d'au moins une marque de frein est différente d'au moins une autre marque.
- ☒ **La distance de freinage moyenne d'au moins une marque de frein est différente d'au moins une autre marque.**
- ☐ Toutes les moyennes sont égales.

Solution: B est vraie. La valeur- $p = 0,000001 < 0,01 = \alpha$, on rejette H_0 . Au moins une moyenne de distance de freinage diffère des autres.

A) L'ANOVA compare les moyennes, pas les variances.

C) Il s'agit d'une ANOVA à un seul facteur ; il n'y a pas de terme d'interaction.

Exercice 3 (12 points)

Pour chacune des mises en situation ci-bas, donnez la lettre du modèle qui correspond parmi les suivants :

A : **Régression linéaire simple**

B : **Analyse de la variance à un facteur**

C : **Test d'indépendance**

- (a) (3 points) Alexis aimerait savoir si le nombre de minutes que ses amis et lui passent à jouer à l'ordinateur à chaque semaine a un impact sur leur note à l'examen final de mathématiques de secondaire 5. Il prévoit donc étudier l'effet des minutes à jouer à l'ordinateur sur la note de l'examen.

Solution: A – Régression linéaire simple. La variable explicative (minutes de jeu) et la variable réponse (note) sont toutes deux quantitatives continues.

- (b) (3 points) Amandine aimerait comparer la performance de 8 types d'engrais. Elle utilise donc 5 plants de tomates pour chacun des types d'engrais (40 plants au total) et elle mesure la quantité de tomates produites.

Solution: B – Analyse de la variance à un facteur. Un seul facteur catégoriel (type d'engrais) à 8 niveaux ; la variable réponse est la quantité de tomates.

- (c) (3 points) Benjamin veut savoir s'il existe un lien entre le type de régime alimentaire (omnivore, végétarien, végétalien) et le niveau d'énergie ressenti (faible, moyen, élevé) chez les étudiants de son programme. Il sonde 150 étudiants et classe chacun d'eux selon son régime et son niveau d'énergie.

Solution: C – Test d'indépendance. Les deux variables (type de régime et niveau d'énergie) sont catégorielles. On cherche à déterminer s'il existe une association entre elles, ce qui correspond à un test d'indépendance du khi-carré.

- (d) (3 points) Émile et Léon veulent savoir si la puissance générée par un cycliste a un impact sur le temps d'ascension du fameux *Molard* de Gilly. Ils mesurent donc la puissance moyenne de 25 cyclistes pendant l'ascension ainsi que le temps d'ascension en secondes.

Solution: A – Régression linéaire simple. La variable explicative (puissance) et la variable réponse (temps d'ascension) sont toutes deux quantitatives continues.

Exercice 4 (10 points)

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) (2 points) Pour que l'analyse de la variance à 1 facteur soit valide, il faut qu'au moins un des postulats soit respecté.

☐ Vrai ✓ **Faux**

Solution: Faux. Pour que l'ANOVA soit valide, **tous** les postulats doivent être raisonnablement respectés (normalité des résidus, homogénéité des variances, indépendance des observations).

- (b) (2 points) Lorsqu'un facteur a 2 niveaux, on peut utiliser l'analyse de la variance à un facteur ou un test de Student de comparaison de moyennes avec variances égales pour comparer les moyennes des niveaux.

✓ **Vrai** ☐ Faux

Solution: Vrai. Quand $k = 2$, l'ANOVA à un facteur et le test t de Student (variances égales) sont équivalents : $F_0 = t_0^2$.

- (c) (2 points) En faisant une analyse de la variance à deux facteurs, nous obtenons une *valeur-p* associée à la statistique observée du terme d'interaction égale à 0,001. Au seuil $\alpha = 0,05$, l'interaction est significative et nous n'interprétons pas les facteurs individuellement.

✓ **Vrai** ☐ Faux

Solution: Vrai. La valeur- $p = 0,001 < 0,05 = \alpha$, donc l'interaction est significative. L'effet d'un facteur dépend du niveau de l'autre facteur, et on n'interprète pas les effets principaux séparément.

- (d) (2 points) Dans un modèle de régression linéaire simple, si l'intervalle de confiance à 95% pour β_0 est $[0,345; 12,765]$, nous sommes certain qu'une relation linéaire existe entre X et Y .

☐ Vrai ✓ **Faux**

Solution: Faux. Cet intervalle concerne β_0 (l'ordonnée à l'origine), pas β_1 (la pente). L'existence d'une relation linéaire dépend de β_1 , pas de β_0 . De plus, un intervalle de confiance ne donne jamais une certitude absolue.

- (e) (2 points) Dans le contexte d'une régression linéaire simple, nous avons que $y_i = x_i$ pour $i = 1, \dots, n$. L'estimateur de β_0 et l'estimateur de β_1 valent tous deux 0.

☐ Vrai ✓ **Faux**

Solution: Faux. Si $y_i = x_i$ pour tout i , alors $\bar{y} = \bar{x}$ et $S_{XY} = S_{XX}$. On obtient $\hat{\beta}_1 = S_{XY}/S_{XX} = 1$ et $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \bar{x} - \bar{x} = 0$. Donc $\hat{\beta}_0 = 0$ mais $\hat{\beta}_1 = 1 \neq 0$.

Exercice 5 (18 points)

Pour des raisons de santé publique, on s'intéresse à la concentration d'ozone O_3 dans l'air (en microgrammes par millilitre). En particulier, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone de la journée par la température à midi donnée en degrés celsius. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, vous disposez des résultats suivants :

Residual standard error: 12.67 on 8 degrees of freedom

Multiple R-squared: 0.7041, Adjusted R-squared: 0.6671

F-statistic: 19.03 on 1 and 8 DF, p-value: 0.002403

$$\sum_{i=1}^{10} x_i = 219,1; \quad \sum_{i=1}^{10} x_i^2 = 5214,58; \quad \sum_{i=1}^{10} y_i = 1026,4; \quad \sum_{i=1}^{10} y_i^2 = 118446,6; \quad \sum_{i=1}^{10} x_i y_i = 23650,84.$$

Vous savez aussi que

$$S_{XY} = \sum_i^n x_i y_i - n \bar{x} \bar{y}; \quad S_{XX} = \sum_i^n x_i^2 - n \bar{x}^2.$$

- (a) (8 points) Donnez l'équation de la droite de régression permettant de prédire la concentration d'ozone O_3 dans l'air en fonction de la température à midi. Justifiez toutes les étapes de votre démarche.

Solution: On a $n = 10$.

$$\bar{x} = \frac{219,1}{10} = 21,91 \quad \text{et} \quad \bar{y} = \frac{1026,4}{10} = 102,64.$$

$$S_{XX} = 5214,58 - 10(21,91)^2 = 5214,58 - 4800,48 = 414,10.$$

$$S_{XY} = 23650,84 - 10(21,91)(102,64) = 23650,84 - 22488,42 = 1162,42.$$

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{1162,42}{414,10} \approx 2,81.$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 102,64 - 2,81 \times 21,91 \approx 102,64 - 61,57 = 41,07.$$

L'équation de la droite de régression est : $\hat{y} = 41,07 + 2,81x$.

- (b) (2 points) Donnez le pourcentage de la variabilité totale de la concentration d'ozone O_3 dans l'air qui est expliquée par la température à midi.

Solution: Le coefficient de détermination $R^2 = 0,7041$ (donné dans la sortie). Donc 70,41 % de la variabilité totale de la concentration d'ozone est expliquée par la température à midi.

- (c) (3 points) Calculez la prévision ponctuelle de la concentration d'ozone O_3 dans l'air pour une température de 22 degrés. Justifiez toutes les étapes de votre démarche.

Solution: On substitue $x = 22$ dans l'équation de régression :

$$\hat{y}(22) = 41,07 + 2,81 \times 22 = 41,07 + 61,82 = 102,89.$$

La prévision ponctuelle est d'environ 102,89 microgrammes par millilitre.

- (d) (2 points) Un chercheur aimerait estimer la concentration d'ozone O_3 dans l'air en une journée précise. Le midi de cette journée, la température est de 14 degrés. La prévision ponctuelle de la concentration d'ozone O_3 dans l'air en cette journée est environ de 81,83. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la concentration d'ozone O_3 dans l'air en cette journée.

☐ $80,47 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

☒ $80,47 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

Solution: B est le bon choix. On cherche un **intervalle de prévision** pour une observation future individuelle (la concentration d'ozone « en une journée précise »). L'intervalle de prévision comporte le terme $1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$ sous la racine, alors que l'intervalle de confiance pour $E(Y | x_0)$ ne comporte que $\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$.

- (e) (1 point) Si la température à midi ce jour-là était de 18 degrés, l'intervalle de valeurs calculé à la question précédente serait...

☒ **plus court**

☐ de même longueur

☐ plus long

Solution: A est le bon choix. La largeur de l'intervalle dépend de $(x_0 - \bar{x})^2 / S_{XX}$. On a $\bar{x} \approx 21,91$. Avec $x_0 = 14$: $(14 - 21,91)^2 = 62,57$. Avec $x_0 = 18$: $(18 - 21,91)^2 = 15,29$. Puisque 18 est plus proche de $\bar{x}$, le terme $(x_0 - \bar{x})^2$ est plus petit, donc l'intervalle est **plus court**.

(f) (2 points) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?

- ☐ La concentration d'ozone O_3 dans l'air et la température à midi ne sont pas unis par une relation linéaire significative.
- ☐ On ne peut pas prédire la concentration d'ozone O_3 dans l'air à partir de la température à midi.
- ☐ La concentration d'ozone O_3 dans l'air et la température à midi sont indépendantes.
- ☒ **La relation linéaire entre la concentration d'ozone O_3 dans l'air et la température à midi est significative.**

Solution: D est le bon choix. La valeur- $p = 0,002403 < 0,01 = \alpha$. On rejette $H_0 : \beta_1 = 0$. La relation linéaire entre la concentration d'ozone et la température à midi est significative au seuil de 1%.

Exercice 6 (16 points)

Une chocolaterie prétend que ses sacs de 120 bonbons contiennent les saveurs suivantes dans les proportions indiquées : 30 % chocolat noir, 25 % chocolat au lait, 25 % caramel et 20 % noisette. Pour vérifier cette affirmation, un contrôleur de qualité prélève un sac au hasard et compte les bonbons de chaque saveur. Les résultats sont présentés ci-dessous.

Saveur	Noir	Lait	Caramel	Noisette	Total
Fréquence observée (O_i)	42	35	20	23	120

- (a) (1 point) Formulez les hypothèses nulle et alternative du test du khi-carré d'ajustement.

Solution: H_0 : La distribution des saveurs correspond aux proportions annoncées, c'est-à-dire $p_{\text{noir}} = 0,30$, $p_{\text{lait}} = 0,25$, $p_{\text{caramel}} = 0,25$, $p_{\text{noisette}} = 0,20$.

H_1 : La distribution des saveurs ne correspond pas aux proportions annoncées (au moins une proportion diffère).

- (b) (3 points) Calculez la statistique de test D_0 . Montrez vos calculs.

Solution: On calcule d'abord les fréquences espérées $E_i = n \times p_i$:

Saveur	Noir	Lait	Caramel	Noisette
E_i	$120 \times 0,30 = 36$	$120 \times 0,25 = 30$	$120 \times 0,25 = 30$	$120 \times 0,20 = 24$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$D_0 = \sum_{i=1}^4 \frac{(O_i - E_i)^2}{E_i} = \frac{(42 - 36)^2}{36} + \frac{(35 - 30)^2}{30} + \frac{(20 - 30)^2}{30} + \frac{(23 - 24)^2}{24}$$

$$= \frac{36}{36} + \frac{25}{30} + \frac{100}{30} + \frac{1}{24} = 1 + 0,833 + 3,333 + 0,042 = 5,208$$

- (c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = k - 1 = 4 - 1 = 3$ degrés de liberté ($k = 4$ catégories, aucun paramètre estimé à partir des données).

- (d) (2 points) Au seuil $\alpha = 0,05$, quelle est votre conclusion ? Justifiez. On donne $\chi_{0,05;3}^2 = 7,815$.

Solution: $D_0 = 5,208 < 7,815 = \chi_{0,05;3}^2$.

On ne rejette pas H_0 . Au seuil de 5 %, il n'y a pas suffisamment de preuves pour affirmer que la distribution des saveurs diffère des proportions annoncées par la chocolaterie.

Exercice 7 (16 points)

On souhaite savoir si la répartition des choix de transport (auto, transport en commun, vélo) est la même pour les étudiants de trois campus universitaires. Un échantillon aléatoire de 300 étudiants donne les résultats suivants.

	Auto	Transport en commun	Vélo	Total
Campus A	40	45	15	100
Campus B	30	50	20	100
Campus C	20	40	40	100
Total	90	135	75	300

(a) (1 point) Formulez les hypothèses nulle et alternative.

Solution: H_0 : La distribution des choix de transport est la même pour les trois campus.

H_1 : La distribution des choix de transport diffère pour au moins un campus.

(b) (3 points) Calculez la statistique de test D_0 . Montrez vos calculs.

Solution: Les fréquences espérées sous H_0 sont $E_{ij} = \frac{(\text{total ligne } i) \times (\text{total colonne } j)}{n}$.

	Auto	Transport en commun	Vélo
Campus A	$\frac{100 \times 90}{300} = 30$	$\frac{100 \times 135}{300} = 45$	$\frac{100 \times 75}{300} = 25$
Campus B	30	45	25
Campus C	30	45	25

Toutes les fréquences espérées sont ≥ 5 . ✓

$$\begin{aligned}
 D_0 &= \frac{(40-30)^2}{30} + \frac{(45-45)^2}{45} + \frac{(15-25)^2}{25} \\
 &\quad + \frac{(30-30)^2}{30} + \frac{(50-45)^2}{45} + \frac{(20-25)^2}{25} \\
 &\quad + \frac{(20-30)^2}{30} + \frac{(40-45)^2}{45} + \frac{(40-25)^2}{25} \\
 &= \frac{100}{30} + 0 + \frac{100}{25} + 0 + \frac{25}{45} + \frac{25}{25} + \frac{100}{30} + \frac{25}{45} + \frac{225}{25} \\
 &= 3,333 + 0 + 4 + 0 + 0,556 + 1 + 3,333 + 0,556 + 9 \\
 &= 21,778
 \end{aligned}$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = (r-1)(c-1) = (3-1)(3-1) = 4$ degrés de liberté ($r = 3$ lignes, $c = 3$ colonnes).

(d) (2 points) Au seuil $\alpha = 0,05$, quelle est votre conclusion ? Justifiez. On donne $\chi^2_{0,05;4} = 9,488$.

Solution: $D_0 = 21,778 > 9,488 = \chi^2_{0,05;4}$.

On rejette H_0 . Au seuil de 5 %, la distribution des choix de transport n'est pas la même pour les trois campus. En particulier, le campus C semble avoir une proportion de cyclistes nettement plus élevée.

Exercice 8 (16 points)

Une étude cherche à déterminer s'il existe un lien entre le niveau de stress (faible, modéré, élevé) et la qualité du sommeil (bonne, mauvaise) chez des adultes. Un échantillon de 200 personnes donne les résultats suivants.

	Bonne qualité	Mauvaise qualité	Total
Stress faible	50	10	60
Stress modéré	45	35	80
Stress élevé	15	45	60
Total	110	90	200

(a) (1 point) Formulez les hypothèses nulle et alternative.

Solution: H_0 : Le niveau de stress et la qualité du sommeil sont indépendants.

H_1 : Le niveau de stress et la qualité du sommeil ne sont pas indépendants (il existe une association).

(b) (3 points) Calculez la statistique de test D_0 . Montrez vos calculs.

Solution: Les fréquences espérées sous H_0 sont $E_{ij} = \frac{(\text{total ligne } i) \times (\text{total colonne } j)}{n}$.

	Bonne qualité	Mauvaise qualité
Stress faible	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$
Stress modéré	$\frac{80 \times 110}{200} = 44$	$\frac{80 \times 90}{200} = 36$
Stress élevé	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$\begin{aligned}
 D_0 &= \frac{(50-33)^2}{33} + \frac{(10-27)^2}{27} + \frac{(45-44)^2}{44} + \frac{(35-36)^2}{36} \\
 &\quad + \frac{(15-33)^2}{33} + \frac{(45-27)^2}{27} \\
 &= \frac{289}{33} + \frac{289}{27} + \frac{1}{44} + \frac{1}{36} + \frac{324}{33} + \frac{324}{27} \\
 &= 8,758 + 10,704 + 0,023 + 0,028 + 9,818 + 12,000 \\
 &= 41,331
 \end{aligned}$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = (r-1)(c-1) = (3-1)(2-1) = 2$ degrés de liberté ($r = 3$ niveaux de stress, $c = 2$ niveaux de qualité du sommeil).

(d) (2 points) Au seuil $\alpha = 0,01$, quelle est votre conclusion ? Justifiez. On donne $\chi^2_{0,01;2} = 9,210$.

Solution: $D_0 = 41,331 > 9,210 = \chi^2_{0,01;2}$.

On rejette H_0 . Au seuil de 1 %, il y a suffisamment de preuves pour conclure que le niveau de stress et la qualité du sommeil ne sont pas indépendants. Les données suggèrent qu'un stress plus élevé est associé à une mauvaise qualité du sommeil.

Exercice 9 BONUS (6 points)

Supposons un modèle de régression linéaire

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \text{ pour } i = 1, \dots, n$$

où $\epsilon_i \sim \mathcal{U}[-a, a]$, c'est-à-dire une loi uniforme sur $[-a, a]$. Nous avons les informations suivantes :

$$E(\epsilon) = 0$$

$$\text{Var}(\epsilon) = \frac{4a^2}{12}$$

(a) (3 points) Donnez $E(Y_i)$ et $\text{Var}(Y_i)$.

Solution: $E(Y_i) = E(\beta_0 + \beta_1 X_i + \epsilon_i) = \beta_0 + \beta_1 X_i + E(\epsilon_i) = \beta_0 + \beta_1 X_i$.

$$\text{Var}(Y_i) = \text{Var}(\beta_0 + \beta_1 X_i + \epsilon_i) = \text{Var}(\epsilon_i) = \frac{4a^2}{12} = \frac{a^2}{3}$$

(car $\beta_0 + \beta_1 X_i$ est une constante conditionnellement à X_i).

(b) (3 points) Quelle est la loi de Y ? Donnez autant de détails que possible.

Solution: Puisque $\epsilon_i \sim \mathcal{U}[-a, a]$ et que $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$, la loi de Y_i conditionnellement à X_i est une translation de la loi uniforme :

$$Y_i | X_i \sim \mathcal{U}[\beta_0 + \beta_1 X_i - a; \beta_0 + \beta_1 X_i + a].$$