



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Examen 3 (25 %)
Méthodes statistiques (STT-1920)
28 avril 2026
10 h 30 à 13 h 20
Enseignant : Julien Miron

Directives de l'évaluation

- Matériel autorisé:
 - Calculatrice scientifique **autorisée par la faculté des sciences et de génie**;
 - Une seule feuille aide-mémoire **manuscrite** de format lettre (8.5"×11") recto-verso.
 - Assurez-vous que cette évaluation comporte 9 exercices répartis sur 14 pages, pour un total de 90 points.
 - Veillez ne pas dégrafer votre examen.**
 - Vous devez **justifier toutes vos réponses** par une démarche claire, sauf pour les questions à choix de réponse.
 - Pour les questions à choix de réponse et les vrais ou faux, vous pouvez mettre un X, un crochet (✓) ou remplir la case.
 - Vous devez laisser tout ce qui ne servira pas durant l'examen à l'avant de la salle **AVANT** de rejoindre votre place.
 - Vous n'avez droit à **AUCUN** appareil électronique en votre possession durant l'examen.
 - Une fois assis à votre place, vous devez demander l'autorisation pour vous lever, même si l'examen n'est pas encore commencé.
 - Dans les 5 dernières minutes de l'examen, il sera interdit de se lever avant que **TOUTES** les copies n'aient été ramassées.
- Le non-respect des consignes 7-8-9 entraînera une pénalité de 10%.

Exercice 1 (6 points)

Un ingénieur souhaite comparer la performance de trois marques de freins à disque pour vélo de route. La variable d'intérêt sera donc la distance de freinage parcourue pour passer de 40 km/h à 0 km/h. L'expérience est répétée n fois pour chaque type de frein. Utilisez la table d'analyse de la variance suivante pour répondre aux deux questions.

	SS	DDL	MS	F0	valeur-p
Traitement	45.77	2	22.885	14.329	0.000001
Erreur	91.03	57	1.597		

(a) (3 points) Laquelle des affirmations suivantes est vraie ?

- ☐ Nous savons que $n = 60$.
☒ **L'estimateur de la variance est 1,597.**
☐ La variable réponse est la distance de freinage et le facteur est Erreur.
☐ Comme il s'agit d'une régression linéaire simple, il n'y a pas de facteur.

Solution: B est vraie. $\hat{\sigma}^2 = MS_{\text{Residuals}} = SS_{\text{Residuals}}/DDL_{\text{Residuals}} = 91,03/57 \approx 1,597 \approx 1,60$.

A) $DDL_{\text{disque}} = I - 1 = 2$, donc $I = 3$ marques. $DDL_{\text{Residuals}} = n - I = 57$, donc $n = 60$. Avec $I = 3$ marques et $n = 60$ observations, $k = n/I = 20$ répétitions par marque (pas $k = 60$).

C) Le facteur est disque, pas Residuals.

D) Il s'agit d'une ANOVA, pas d'une régression.

(b) (3 points) Quelle conclusion peut-on tirer à partir de cette table d'analyse de la variance, au seuil de 1% ?

- ☐ La variance de la distance de freinage d'au moins une marque de frein est différente d'au moins une autre marque.
☒ **La distance de freinage moyenne d'au moins une marque de frein est différente d'au moins une autre marque.**
☐ Toutes les moyennes sont égales.
☐ Toutes les moyennes sont différentes.
☐ Toutes les variances sont différentes.

Solution: B est vraie. La valeur- $p = 0,000001 < 0,01 = \alpha$, on rejette H_0 . Au moins une moyenne de distance de freinage diffère des autres.

A) L'ANOVA compare les moyennes, pas les variances.

C) Il s'agit d'une ANOVA à un seul facteur; il n'y a pas de terme d'interaction.

Exercice 2 (8 points)

Nous faisons un test pour confronter $H_0 : \mu = 15$ à $H_1 : \mu \neq 15$. La règle de décision est de rejeter H_0 si $\bar{X} < 10$ ou si $\bar{X} > 20$. Dans chacun des cas suivants, déterminez si une erreur est commise et déterminez de quel type, le cas échéant.

(a) (2 points) La vraie valeur de μ est 16 et nous obtenons $\bar{x} = 12$.

- ☐ Erreur de type I ☒ **Erreur de type II** ☐ Aucune erreur

Solution: La vraie valeur est $\mu = 16$, donc H_0 est fausse. Comme $\bar{x} = 12$ est dans la zone d'acceptation ($10 \leq \bar{x} \leq 20$), on ne rejette pas H_0 . Ne pas rejeter une hypothèse nulle fausse est une **erreur de type II**.

(b) (2 points) La vraie valeur de μ est 15 et nous obtenons $\bar{x} = 12$.

- ☐ Erreur de type I ☐ Erreur de type II ☒ **Aucune erreur**

Solution: La vraie valeur est $\mu = 15$, donc H_0 est vraie. Comme $\bar{x} = 12$ est dans la zone d'acceptation ($10 \leq \bar{x} \leq 20$), on ne rejette pas H_0 . La décision est correcte, donc **aucune erreur**.

(c) (2 points) La vraie valeur de μ est 15 et nous obtenons $\bar{x} = 21$.

☒ **Erreur de type I** ☐ Erreur de type II ☐ Aucune erreur

Solution: La vraie valeur est $\mu = 15$, donc H_0 est vraie. Comme $\bar{x} = 21 > 20$, on rejette H_0 . Rejeter une hypothèse nulle vraie est une **erreur de type I**.

(d) (2 points) La vraie valeur de μ est 18 et nous obtenons $\bar{x} = 21$.

☐ Erreur de type I ☐ Erreur de type II ☒ **Aucune erreur**

Solution: La vraie valeur est $\mu = 18$, donc H_0 est fausse. Comme $\bar{x} = 21 > 20$, on rejette H_0 . Rejeter une hypothèse nulle fausse est la bonne décision, donc **aucune erreur**.

Exercice 3 (12 points)

Une équipe en sciences biomédicales veut vérifier s'il existe une différence de réponse inflammatoire moyenne (score quantitatif) selon la concentration d'un agent actif dans une formulation.¹

Elle compare donc 8 concentrations différentes (10%, 20%, 25%, 30%, 35%, 40%, 45% et 50%) en réalisant 4 mesures indépendantes pour chaque concentration. La table d'analyse de la variance suivante est produite par le logiciel utilisé par l'équipe. Dans celle-ci, certaines quantités ont été remplacées par AAA, BBB et ??? . Nous considérons que les postulats du modèle sont respectés.

ANOVA

	SS	ddl	MS	F0
traitement	1154.3	???	???	AAA
erreur	141.4	???	???	
Total	BBB	???		

(a) (3 points) Que vaut AAA ?

- ☐ 164,9
☐ 8,163
☒ **27,989**
☐ 1154,3
☐ Il n'est pas possible de trouver la valeur de AAA avec les informations données.

$$\text{Solution: } AAA = F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{SS_{\text{trt}}/(a-1)}{SS_E/(N-a)} = \frac{1154,3/7}{141,4/24} = \frac{164,9}{5,892} \approx 27,989.$$

(b) (3 points) Que vaut BBB ?

- ☐ 8,163
☒ **1295,7**
☐ 1012,9
☐ 0,122
☐ Il n'est pas possible de trouver la valeur de BBB avec les informations données.

$$\text{Solution: } BBB = SS_{\text{total}} = SS_{\text{trt}} + SS_E = 1154,3 + 141,4 = 1295,7.$$

(c) (3 points) Quelle est l'estimation de σ^2 ?

- ☐ 141,4
☐ 24
☒ **5,89**
☐ 164,9
☐ Il n'est pas possible de donner une estimation de σ^2 avec les informations données.

$$\text{Solution: } \hat{\sigma}^2 = MS_E = \frac{SS_E}{DDL_E} = \frac{141,4}{24} = 5,89.$$

(d) (3 points) Au seuil de 5%, quelle conclusion pouvons-nous tirer de la table d'analyse de la variance ?

- ☐ Il n'est pas possible de tirer de conclusion car nous ne connaissons pas les valeurs remplacées par ???.
☐ Il faudrait répéter l'expérience plus de fois pour pouvoir conclure.
☐ Toutes les moyennes sont significativement différentes.

1. Merci à Claude pour la suggestion de mise en situation.

✓ **La réponse inflammatoire moyenne d'au moins une concentration est significativement différente de celle d'au moins une autre concentration.**

☐ Toutes les moyennes sont significativement égales.

☐ La variance de la réponse inflammatoire d'au moins une concentration est significativement différente de celle d'au moins une autre concentration.

Solution: La valeur- p associée au test F est très petite (dans la sortie complète : $4,6 \times 10^{-10}$), donc $p < 0,05$. On rejette H_0 et on conclut qu'au moins une moyenne de réponse inflammatoire diffère entre les concentrations.

Exercice 4 (10 points)

Soit $X_1, \dots, X_{16}$ qui proviennent d'une loi normale d'espérance μ et de variance σ^2 .

On fait le test d'hypothèses pour lequel $H_0 : \mu = 5$ et $H_1 : \mu > 5$ au seuil $\alpha = 1\%$.

Pour quelles valeurs de s^2 rejette-t-on H_0 si $\bar{x} = 6,301$?

Solution: Comme la variance est inconnue et que les données sont normales, on utilise la statistique

$$T_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \text{ sous } H_0.$$

Ici, $n = 16$, $\mu_0 = 5$ et $\bar{x} = 6,301$, donc

$$T_0 = \frac{6,301 - 5}{s/4} = \frac{5,204}{s}.$$

Au seuil $\alpha = 1\%$ pour un test unilatéral à droite, on rejette H_0 si

$$T_0 > t_{0,99;15} \approx 2,602.$$

Donc

$$\frac{5,204}{s} > 2,602 \iff s < \frac{5,204}{2,602} = 2 \iff s^2 < 4.$$

Région de rejet : on rejette H_0 pour $0 < s^2 < 4$.

Exercice 5 (10 points)

La concentration moyenne cible d'un principe actif est de 50 mg/mL. On prélève un échantillon aléatoire de $n = 12$ lots, supposé normal, et on observe $\bar{x} = 46,8$ et $s = 4,0$ mg/mL. Au seuil 1%, procédez au test dont les hypothèses sont

$$H_0 : \mu = 50 \quad \text{contre} \quad H_1 : \mu \neq 50.$$

Solution: Comme la variance de la population est inconnue et $n = 12$ (échantillon normal), on utilise un test t bilatéral.

Hypothèses :

$$H_0 : \mu = 50, \quad H_1 : \mu \neq 50.$$

Statistique de test :

$$t_0 = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{46,8 - 50}{4/\sqrt{12}} = \frac{-3,2}{1,1547} \approx -2,77.$$

Sous H_0 , $T \sim t_{11}$.

Règle de décision (bilatérale, $\alpha = 0,01$) : rejeter H_0 si $|t_0| > t_{0,995;11} \approx 3,106$.

Ici, $|t_0| = 2,77 < 3,106$, donc on ne rejette pas H_0 .

Équivalent par valeur- p : $p \approx 0,018 > 0,01$.

Conclusion : au seuil de 1%, il n'y a pas suffisamment de preuves pour conclure que la concentration moyenne diffère de 50 mg/mL.

Exercice 6 (12 points)

Pour des raisons de santé publique, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone O_3 de la journée par la température à midi donnée en degrés celsius. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, vous disposez des résultats suivants :

MSE: 160.529 sur 8 degrés de liberté

R-carré: 0.7041, R-carré ajusté: 0.6671

F0: 19.03 sur 1 et 8 degrés de liberté, valeur-p: 0.002403

$$\sum_{i=1}^{10} x_i = 219,1; \quad \sum_{i=1}^{10} x_i^2 = 5214,58; \quad \sum_{i=1}^{10} y_i = 1026,4; \quad \sum_{i=1}^{10} y_i^2 = 118446,6; \quad \sum_{i=1}^{10} x_i y_i = 23650,84; \quad s_X^2 = 46,01.$$

- (a) (7 points) Donnez l'équation de la droite de régression permettant de prédire la concentration d'ozone O_3 dans l'air en fonction de la température à midi. Justifiez toutes les étapes de votre démarche.

Solution: On a $n = 10$.

$$\bar{x} = \frac{219,1}{10} = 21,91 \quad \text{et} \quad \bar{y} = \frac{1026,4}{10} = 102,64.$$

$$S_{XX} = 5214,58 - 10(21,91)^2 = 5214,58 - 4800,48 = 414,10.$$

$$S_{XY} = 23650,84 - 10(21,91)(102,64) = 23650,84 - 22488,42 = 1162,42.$$

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{1162,42}{414,10} \approx 2,81.$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 102,64 - 2,81 \times 21,91 \approx 102,64 - 61,57 = 41,07.$$

L'équation de la droite de régression est : $\hat{y} = 41,07 + 2,81x$.

- (b) (2 points) Donnez le pourcentage de la variabilité totale de la concentration d'ozone O_3 dans l'air qui est expliquée par la température à midi.

Solution: Le coefficient de détermination $R^2 = 0,7041$ (donné dans la sortie). Donc 70,41 % de la variabilité totale de la concentration d'ozone est expliquée par la température à midi.

Suite de l'exercice 6 sur la feuille suivante

Suite de l'exercice 6

- (c) (1 point) Un chercheur aimerait estimer la concentration d'ozone O_3 dans l'air lors d'une journée précise. Le midi de cette journée, la température est de 14 degrés. La prévision ponctuelle de la concentration d'ozone O_3 dans l'air en cette journée est environ de 80,38. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la concentration d'ozone O_3 dans l'air en cette journée.

☐ $80,38 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

☒ $80,38 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

Solution: B est le bon choix. On cherche un **intervalle de prévision** pour une observation future individuelle (la concentration d'ozone « en une journée précise »). L'intervalle de prévision comporte le terme $1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$ sous la racine, alors que l'intervalle de confiance pour $E(Y | x_0)$ ne comporte que $\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$.

- (d) (1 point) Si la température à midi ce jour-là était de 18 degrés, l'intervalle de valeurs calculé à la question précédente serait...

☒ **plus court**

☐ de même longueur

☐ plus long

Solution: A est le bon choix. La largeur de l'intervalle dépend de $(x_0 - \bar{x})^2 / S_{XX}$. On a $\bar{x} \approx 21,91$. Avec $x_0 = 14$: $(14 - 21,91)^2 = 62,57$. Avec $x_0 = 18$: $(18 - 21,91)^2 = 15,29$. Puisque 18 est plus proche de $\bar{x}$, le terme $(x_0 - \bar{x})^2$ est plus petit, donc l'intervalle est **plus court**.

- (e) (1 point) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?

☐ La concentration d'ozone O_3 dans l'air et la température à midi ne sont pas unis par une relation linéaire significative.

☐ On ne peut pas prédire la concentration d'ozone O_3 dans l'air à partir de la température à midi.

☐ La concentration d'ozone O_3 dans l'air et la température à midi sont indépendantes.

☒ **La relation linéaire entre la concentration d'ozone O_3 dans l'air et la température à midi est significative.**

Solution: D est le bon choix. La valeur- $p = 0,002403 < 0,01 = \alpha$. On rejette $H_0 : \beta_1 = 0$. La relation linéaire entre la concentration d'ozone et la température à midi est significative au seuil de 1%.

Exercice 7 (11 points)

Une chocolaterie prétend que ses sacs de 120 bonbons contiennent les saveurs suivantes dans les proportions indiquées : 30 % chocolat noir, 25 % chocolat au lait, 25 % caramel et 20 % noisette. Pour vérifier cette affirmation, un contrôleur de qualité prélève un sac au hasard et compte les bonbons de chaque saveur. Les résultats sont présentés ci-dessous.

Saveur	Noir	Lait	Caramel	Noisette	Total
Fréquence observée (O_i)	42	35	20	23	120

(a) (2 points) Formulez les hypothèses nulle et alternative du test du khi-carré d'adéquation.

Solution: H_0 : La distribution des saveurs correspond aux proportions annoncées, c'est-à-dire $p_{\text{noir}} = 0,30$, $p_{\text{lait}} = 0,25$, $p_{\text{caramel}} = 0,25$, $p_{\text{noisette}} = 0,20$.

H_1 : La distribution des saveurs ne correspond pas aux proportions annoncées (au moins une proportion diffère).

(b) (4 points) Calculez la statistique de test D_0 . Vous pouvez utiliser le tableau dans votre démarche.

Solution: On calcule d'abord les fréquences espérées $E_i = n \times p_i$:

Saveur	Noir	Lait	Caramel	Noisette
E_i	$120 \times 0,30 = 36$	$120 \times 0,25 = 30$	$120 \times 0,25 = 30$	$120 \times 0,20 = 24$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$D_0 = \sum_{i=1}^4 \frac{(O_i - E_i)^2}{E_i} = \frac{(42 - 36)^2}{36} + \frac{(35 - 30)^2}{30} + \frac{(20 - 30)^2}{30} + \frac{(23 - 24)^2}{24}$$

$$= \frac{36}{36} + \frac{25}{30} + \frac{100}{30} + \frac{1}{24} = 1 + 0,833 + 3,333 + 0,042 = 5,208$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = k - 1 = 4 - 1 = 3$ degrés de liberté ($k = 4$ catégories, aucun paramètre estimé à partir des données).

(d) (3 points) Au seuil $\alpha = 0,05$, quelle est votre conclusion ?

Solution: $D_0 = 5,208 < 7,815 = \chi^2_{0,05;3}$.

On ne rejette pas H_0 . Au seuil de 5 %, il n'y a pas suffisamment de preuves pour affirmer que la distribution des saveurs diffère des proportions annoncées par la chocolaterie.

Exercice 8 (11 points)

Une étude cherche à déterminer s'il existe un lien entre le niveau de stress (faible, modéré, élevé) et la qualité du sommeil (bonne, mauvaise) chez des adultes. Un échantillon de 200 personnes donne les résultats suivants.

	Bonne qualité	Mauvaise qualité	Total
Stress faible			
O_{ij}	50	10	60
E_{ij}	33	27	
D_{ij}	8,758	10,704	
Stress modéré			
O_{ij}	45	35	80
E_{ij}	44	36	
D_{ij}	0,023	0,028	
Stress Élevé			
O_{ij}	15	45	60
E_{ij}	33	27	
D_{ij}	9,818	12	
Total observés	110	90	200

(a) (2 points) Formulez les hypothèses nulle et alternative du test d'indépendance.

Solution: H_0 : Le niveau de stress et la qualité du sommeil sont indépendants.

H_1 : Le niveau de stress et la qualité du sommeil ne sont pas indépendants (il existe une association).

(b) (4 points) Calculez la statistique de test D_0 .

Solution: Les fréquences espérées sous H_0 sont $E_{ij} = \frac{(\text{total ligne } i) \times (\text{total colonne } j)}{n}$.

	Bonne qualité	Mauvaise qualité
Stress faible	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$
Stress modéré	$\frac{80 \times 110}{200} = 44$	$\frac{80 \times 90}{200} = 36$
Stress élevé	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$\begin{aligned}
 D_0 &= \frac{(50 - 33)^2}{33} + \frac{(10 - 27)^2}{27} + \frac{(45 - 44)^2}{44} + \frac{(35 - 36)^2}{36} \\
 &\quad + \frac{(15 - 33)^2}{33} + \frac{(45 - 27)^2}{27} \\
 &= \frac{289}{33} + \frac{289}{27} + \frac{1}{44} + \frac{1}{36} + \frac{324}{33} + \frac{324}{27} \\
 &= 8,758 + 10,704 + 0,023 + 0,028 + 9,818 + 12,000 \\
 &= 41,331
 \end{aligned}$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = (r - 1)(c - 1) = (3 - 1)(2 - 1) = 2$ degrés de liberté ($r = 3$ niveaux de stress, $c = 2$ niveaux de qualité du sommeil).

(d) (3 points) Au seuil $\alpha = 0,01$, quelle est votre conclusion ?

Solution: $D_0 = 41,331 > 9,210 = \chi^2_{0,01;2}$.

On rejette H_0 . Au seuil de 1 %, il y a suffisamment de preuves pour conclure que le niveau de stress et la qualité du sommeil ne sont pas indépendants. Les données suggèrent qu'un stress plus élevé est associé à une mauvaise qualité du sommeil.

Exercice 9 (10 points)

- (a) (2 points) On teste $H_0 : \mu = 50$ contre $H_1 : \mu \neq 50$ et on obtient une valeur- p de 0,03. Au seuil $\alpha = 0,05$, quelle est la bonne décision ?

- ☐ On ne rejette pas H_0 .
☒ **On rejette H_0 .**
☐ Il est impossible de conclure sans la taille d'échantillon.

Solution: Comme $0,03 < 0,05$, on rejette H_0 .

- (b) (2 points) Quelle est l'hypothèse nulle du test F global en analyse de la variance ?

- ☒ **Toutes les moyennes de groupes sont égales.**
☐ Toutes les variances de groupes sont égales.
☐ Toutes les proportions de groupes sont égales.

Solution: En ANOVA à un facteur, H_0 est $\mu_1 = \mu_2 = \dots = \mu_d$.

- (c) (2 points) Dans le modèle $Y = \beta_0 + \beta_1 X + \varepsilon$, que signifie $\beta_1 \neq 0$?

- ☒ **En moyenne, Y change de β_1 unités quand X augmente d'une unité.**
☐ La variance de Y est positive.
☐ X et Y sont indépendantes.
☐ Quand X augment d'une unité, Y change de β_1 unités.

Solution: β_1 est la pente : si $\beta_1 > 0$, la relation linéaire moyenne est croissante.

- (d) (2 points) Pour un test d'ajustement avec $k = 5$ catégories, combien y a-t-il de degrés de liberté ?

- ☐ 3
☒ **4**
☐ 5

Solution: Pour un test d'ajustement sans paramètre estimé, $\nu = k - 1 = 5 - 1 = 4$.

- (e) (2 points) Un test d'indépendance donne une valeur- p de 0,002 au seuil 5%. Quelle conclusion est correcte ?

- ☐ On ne rejette pas l'indépendance.
☒ **On rejette l'indépendance : les variables sont associées.**
☐ Les variables sont causales.
☐ Il nous manque le nombre de degrés de liberté pour pouvoir conclure.

Solution: Comme $0,002 < 0,05$, on rejette l'hypothèse d'indépendance. Le test indique une association, pas une causalité.