



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Examen 3 (25 %)

Méthodes statistiques (STT-1920)

Enseignant : Julien Miron

Directives de l'évaluation

- Matériel autorisé:
 - Calculatrice scientifique **autorisée par la faculté des sciences et de génie**;
 - Une seule feuille aide-mémoire **manuscrite** de format lettre (8.5"×11") recto-verso.
 - Assurez-vous que cette évaluation comporte 7 exercices (incluant 1 question bonus) répartis sur 9 pages, pour un total de 49 points et 6 points bonus.
 - Veillez ne pas dégrafer votre examen.**
 - Vous devez **justifier toutes vos réponses** par une démarche claire, sauf pour les questions à choix de réponse.
 - Pour les questions à choix de réponse et les vrais ou faux, vous pouvez mettre un X, un crochet (✓) ou remplir la case.
 - Vous devez laisser tout ce qui ne servira pas durant l'examen à l'avant de la salle AVANT de rejoindre votre place.
 - Vous n'avez droit à AUCUN appareil électronique en votre possession durant l'examen.
 - Une fois assis à votre place, vous devez demander l'autorisation pour vous lever, même si l'examen n'est pas encore commencé.
 - Dans les 5 dernières minutes de l'examen, il sera interdit de se lever avant que TOUTES les copies n'aient été ramassées.
- Le non-respect des consignes 7-8-9 entraînera une pénalité de 10%.

Exercice 1 (3 points)

Soit la table d'ANOVA suivante obtenue à l'aide d'un logiciel :

```
>summary(AnovaModel)
              SS      DDL      MS      F0  valeur-p
Saumons    926.12      4    231.53    238.72    0.0001
Residuals   46.55     48      0.97
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est vraie ?

- ☐ La proportion de la variance totale expliquée par le facteur Saumons est égale à 0,0001.
- ☐ Nous avons 4 niveaux différents pour le facteur Saumons.
- ☐ La variance du facteur Saumons est environ 20 fois plus grande que la variance du facteur Residuals.
- ☒ **L'hypothèse nulle suppose que les moyennes des différents niveaux du facteur Saumons étaient toutes égales.**

Solution: D est vraie. En ANOVA à un facteur, $H_0: \mu_1 = \mu_2 = \dots = \mu_k$.

A) 0,0001 est la valeur- p , pas le R^2 . Le $R^2 = SS_{\text{Saumons}}/SS_{\text{Total}} = 926,12/(926,12 + 46,55) \approx 0,952$.

B) $DDL = k - 1 = 4$, donc $k = 5$ niveaux (pas 4).

C) $MS_{\text{Saumons}}/MS_{\text{Residuals}} = 231,53/0,97 \approx 238,7$, et non environ 20.

Mise en situation – Questions 2 et 3

Un ingénieur souhaite comparer la performance de trois marques de freins à disque pour vélo de route. La variable d'intérêt sera donc la distance de freinage parcourue pour passer de 40 km/h à 0 km/h. L'expérience est répétée k fois pour chaque type de frein. Utilisez la table d'ANOVA suivante pour répondre aux questions 2 et 3.

```

              SS      DDL      F0      valeur-p
disque       45.77      2    14.329    0.000001
Residuals    91.03     57
```

Exercice 2 (3 points)

Laquelle des affirmations suivantes est vraie ?

- ☐ Nous savons que $k = 60$.
- ☒ **L'estimateur de la variance σ^2 est environ 1,60.**
- ☐ La variable réponse est la distance de freinage et le facteur est Residuals.
- ☐ Comme il s'agit d'une régression linéaire simple, il n'y a pas de facteur.

Solution: B est vraie. $\hat{\sigma}^2 = MS_{\text{Residuals}} = SS_{\text{Residuals}}/DDL_{\text{Residuals}} = 91,03/57 \approx 1,597 \approx 1,60$.

A) $DDL_{\text{disque}} = I - 1 = 2$, donc $I = 3$ marques. $DDL_{\text{Residuals}} = n - I = 57$, donc $n = 60$. Avec $I = 3$ marques et $n = 60$ observations, $k = n/I = 20$ répétitions par marque (pas $k = 60$).

C) Le facteur est disque, pas Residuals.

D) Il s'agit d'une ANOVA, pas d'une régression.

Exercice 3 (3 points)

Quelle conclusion peut-on tirer à partir de cette table d'ANOVA, au seuil de 1% ?

- ☐ La variance de la distance de freinage d'au moins une marque de frein est différente d'au moins une autre marque.
- ☒ **La distance de freinage moyenne d'au moins une marque de frein est différente d'au moins une autre marque.**
- ☐ Comme il y a de l'interaction, nous ne pouvons tirer aucune conclusion sur les facteurs individuels.

Solution: B est vraie. La valeur- $p = 0,000001 < 0,01 = \alpha$, on rejette H_0 . Au moins une moyenne de distance de freinage diffère des autres.

A) L'ANOVA compare les moyennes, pas les variances.

C) Il s'agit d'une ANOVA à un seul facteur ; il n'y a pas de terme d'interaction.

Exercice 4 (12 points)

Pour chacune des mises en situation ci-bas, donnez la lettre du modèle qui correspond parmi les suivants :

A : **Régression linéaire simple**

B : **Analyse de la variance à un facteur**

C : **Analyse de la variance à deux facteurs**

- (a) (3 points) Alexis aimerait savoir si le nombre de minutes que ses amis et lui passent à jouer à l'ordinateur à chaque semaine a un impact sur leur note à l'examen final de mathématiques de secondaire 5. Il prévoit donc étudier l'effet des minutes à jouer à l'ordinateur sur la note de l'examen.

Solution: A – Régression linéaire simple. La variable explicative (minutes de jeu) et la variable réponse (note) sont toutes deux quantitatives continues.

- (b) (3 points) Amandine aimerait comparer la performance de 8 types d'engrais. Elle utilise donc 5 plants de tomates pour chacun des types d'engrais (40 plants au total) et elle mesure la quantité de tomates produites.

Solution: B – Analyse de la variance à un facteur. Un seul facteur catégoriel (type d'engrais) à 8 niveaux ; la variable réponse est la quantité de tomates.

- (c) (3 points) Benjamin veut savoir si le poids des hérissons est impacté par le type de régime de ceux-ci (parmi 3 régimes possibles) ainsi que par le milieu de vie (parmi 2 milieux de vie possibles). Pour chacune des combinaisons de type de régime et de milieu de vie, il soumet 3 hérissons à la combinaison et mesure le poids des hérissons.

Solution: C – Analyse de la variance à deux facteurs. Deux facteurs catégoriels : le type de régime (3 niveaux) et le milieu de vie (2 niveaux).

- (d) (3 points) Émile et Léon veulent savoir si la puissance générée par un cycliste a un impact sur le temps d'ascension du fameux *Molard* de Gilly. Ils mesurent donc la puissance moyenne de 25 cyclistes pendant l'ascension ainsi que le temps d'ascension en secondes.

Solution: A – Régression linéaire simple. La variable explicative (puissance) et la variable réponse (temps d'ascension) sont toutes deux quantitatives continues.

Exercice 5 (10 points)

Déterminez si les énoncés suivants sont vrais ou faux.

- (a) (2 points) Pour que l'analyse de la variance à 1 facteur soit valide, il faut qu'au moins un des postulats soit respecté.

☐ Vrai ✓ **Faux**

Solution: Faux. Pour que l'ANOVA soit valide, **tous** les postulats doivent être raisonnablement respectés (normalité des résidus, homogénéité des variances, indépendance des observations).

- (b) (2 points) Lorsqu'un facteur a 2 niveaux, on peut utiliser l'analyse de la variance à un facteur ou un test de Student de comparaison de moyennes avec variances égales pour comparer les moyennes des niveaux.

✓ **Vrai** ☐ Faux

Solution: Vrai. Quand $k = 2$, l'ANOVA à un facteur et le test t de Student (variances égales) sont équivalents : $F_0 = t_0^2$.

- (c) (2 points) En faisant une analyse de la variance à deux facteurs, nous obtenons une *valeur-p* associée à la statistique observée du terme d'interaction égale à 0,001. Au seuil $\alpha = 0,05$, l'interaction est significative et nous n'interprétons pas les facteurs individuellement.

✓ **Vrai** ☐ Faux

Solution: Vrai. La valeur- $p = 0,001 < 0,05 = \alpha$, donc l'interaction est significative. L'effet d'un facteur dépend du niveau de l'autre facteur, et on n'interprète pas les effets principaux séparément.

- (d) (2 points) Dans un modèle de régression linéaire simple, si l'intervalle de confiance à 95% pour β_0 est $[0,345; 12,765]$, nous sommes certain qu'une relation linéaire existe entre X et Y .

☐ Vrai ✓ **Faux**

Solution: Faux. Cet intervalle concerne β_0 (l'ordonnée à l'origine), pas β_1 (la pente). L'existence d'une relation linéaire dépend de β_1 , pas de β_0 . De plus, un intervalle de confiance ne donne jamais une certitude absolue.

- (e) (2 points) Dans le contexte d'une régression linéaire simple, nous avons que $y_i = x_i$ pour $i = 1, \dots, n$. L'estimateur de β_0 et l'estimateur de β_1 valent tous deux 0.

☐ Vrai ✓ **Faux**

Solution: Faux. Si $y_i = x_i$ pour tout i , alors $\bar{y} = \bar{x}$ et $S_{XY} = S_{XX}$. On obtient $\hat{\beta}_1 = S_{XY}/S_{XX} = 1$ et $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \bar{x} - \bar{x} = 0$. Donc $\hat{\beta}_0 = 0$ mais $\hat{\beta}_1 = 1 \neq 0$.

Exercice 6 (18 points)

Pour des raisons de santé publique, on s'intéresse à la concentration d'ozone O_3 dans l'air (en microgrammes par millilitre). En particulier, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone de la journée par la température à midi donnée en degrés celsius. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, vous disposez des résultats suivants :

Residual standard error: 12.67 on 8 degrees of freedom

Multiple R-squared: 0.7041, Adjusted R-squared: 0.6671

F-statistic: 19.03 on 1 and 8 DF, p-value: 0.002403

$$\sum_{i=1}^{10} x_i = 219,1; \quad \sum_{i=1}^{10} x_i^2 = 5214,58; \quad \sum_{i=1}^{10} y_i = 1026,4; \quad \sum_{i=1}^{10} y_i^2 = 118446,6; \quad \sum_{i=1}^{10} x_i y_i = 23650,84.$$

Vous savez aussi que

$$S_{XY} = \sum_i^n x_i y_i - n \bar{x} \bar{y}; \quad S_{XX} = \sum_i^n x_i^2 - n \bar{x}^2.$$

- (a) (8 points) Donnez l'équation de la droite de régression permettant de prédire la concentration d'ozone O_3 dans l'air en fonction de la température à midi. Justifiez toutes les étapes de votre démarche.

Solution: On a $n = 10$.

$$\bar{x} = \frac{219,1}{10} = 21,91 \quad \text{et} \quad \bar{y} = \frac{1026,4}{10} = 102,64.$$

$$S_{XX} = 5214,58 - 10(21,91)^2 = 5214,58 - 4800,48 = 414,10.$$

$$S_{XY} = 23650,84 - 10(21,91)(102,64) = 23650,84 - 22488,42 = 1162,42.$$

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{1162,42}{414,10} \approx 2,81.$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 102,64 - 2,81 \times 21,91 \approx 102,64 - 61,57 = 41,07.$$

L'équation de la droite de régression est : $\hat{y} = 41,07 + 2,81x$.

- (b) (2 points) Donnez le pourcentage de la variabilité totale de la concentration d'ozone O_3 dans l'air qui est expliquée par la température à midi.

Solution: Le coefficient de détermination $R^2 = 0,7041$ (donné dans la sortie). Donc 70,41 % de la variabilité totale de la concentration d'ozone est expliquée par la température à midi.

- (c) (3 points) Calculez la prévision ponctuelle de la concentration d'ozone O_3 dans l'air pour une température de 22 degrés. Justifiez toutes les étapes de votre démarche.

Solution: On substitue $x = 22$ dans l'équation de régression :

$$\hat{y}(22) = 41,07 + 2,81 \times 22 = 41,07 + 61,82 = 102,89.$$

La prévision ponctuelle est d'environ 102,89 microgrammes par millilitre.

- (d) (2 points) Un chercheur aimerait estimer la concentration d'ozone O_3 dans l'air en une journée précise. Le midi de cette journée, la température est de 14 degrés. La prévision ponctuelle de la concentration d'ozone O_3 dans l'air en cette journée est environ de 81,83. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la concentration d'ozone O_3 dans l'air en cette journée.

☐ $80,47 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

☒ $80,47 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

Solution: B est le bon choix. On cherche un **intervalle de prévision** pour une observation future individuelle (la concentration d'ozone « en une journée précise »). L'intervalle de prévision comporte le terme $1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$ sous la racine, alors que l'intervalle de confiance pour $E(Y | x_0)$ ne comporte que $\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$.

- (e) (1 point) Si la température à midi ce jour-là était de 18 degrés, l'intervalle de valeurs calculé à la question précédente serait...

☒ **plus court**

☐ de même longueur

☐ plus long

Solution: A est le bon choix. La largeur de l'intervalle dépend de $(x_0 - \bar{x})^2 / S_{XX}$. On a $\bar{x} \approx 21,91$. Avec $x_0 = 14$: $(14 - 21,91)^2 = 62,57$. Avec $x_0 = 18$: $(18 - 21,91)^2 = 15,29$. Puisque 18 est plus proche de $\bar{x}$, le terme $(x_0 - \bar{x})^2$ est plus petit, donc l'intervalle est **plus court**.

(f) (2 points) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?

- ☐ La concentration d'ozone O_3 dans l'air et la température à midi ne sont pas unis par une relation linéaire significative.
- ☐ On ne peut pas prédire la concentration d'ozone O_3 dans l'air à partir de la température à midi.
- ☐ La concentration d'ozone O_3 dans l'air et la température à midi sont indépendantes.
- ☒ **La relation linéaire entre la concentration d'ozone O_3 dans l'air et la température à midi est significative.**

Solution: D est le bon choix. La valeur- $p = 0,002403 < 0,01 = \alpha$. On rejette $H_0 : \beta_1 = 0$. La relation linéaire entre la concentration d'ozone et la température à midi est significative au seuil de 1%.

Exercice 7 BONUS (6 points)

Supposons un modèle de régression linéaire

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \text{ pour } i = 1, \dots, n$$

où $\epsilon_i \sim \mathcal{U}[-a, a]$, c'est-à-dire une loi uniforme sur $[-a, a]$. Nous avons les informations suivantes :

$$E(\epsilon) = 0$$

$$\text{Var}(\epsilon) = \frac{4a^2}{12}$$

(a) (3 points) Donnez $E(Y_i)$ et $\text{Var}(Y_i)$.

Solution: $E(Y_i) = E(\beta_0 + \beta_1 X_i + \epsilon_i) = \beta_0 + \beta_1 X_i + E(\epsilon_i) = \beta_0 + \beta_1 X_i$.

$$\text{Var}(Y_i) = \text{Var}(\beta_0 + \beta_1 X_i + \epsilon_i) = \text{Var}(\epsilon_i) = \frac{4a^2}{12} = \frac{a^2}{3}$$

(car $\beta_0 + \beta_1 X_i$ est une constante conditionnellement à X_i).

(b) (3 points) Quelle est la loi de Y ? Donnez autant de détails que possible.

Solution: Puisque $\epsilon_i \sim \mathcal{U}[-a, a]$ et que $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$, la loi de Y_i conditionnellement à X_i est une translation de la loi uniforme :

$$Y_i | X_i \sim \mathcal{U}[\beta_0 + \beta_1 X_i - a; \beta_0 + \beta_1 X_i + a].$$