



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Examen 3 (25 %)

Méthodes statistiques (STT-1920)

Enseignant : Julien Miron

Directives de l'évaluation

- Matériel autorisé:
 - Calculatrice scientifique **autorisée par la faculté des sciences et de génie**;
 - Une seule feuille aide-mémoire **manuscrite** de format lettre (8.5"×11") recto-verso.
 - Assurez-vous que cette évaluation comporte 6 exercices répartis sur 11 pages, pour un total de 70 points.
 - Veillez ne pas dégrafer votre examen.**
 - Vous devez **justifier toutes vos réponses** par une démarche claire, sauf pour les questions à choix de réponse.
 - Pour les questions à choix de réponse et les vrais ou faux, vous pouvez mettre un X, un crochet (✓) ou remplir la case.
 - Vous devez laisser tout ce qui ne servira pas durant l'examen à l'avant de la salle AVANT de rejoindre votre place.
 - Vous n'avez droit à AUCUN appareil électronique en votre possession durant l'examen.
 - Une fois assis à votre place, vous devez demander l'autorisation pour vous lever, même si l'examen n'est pas encore commencé.
 - Dans les 5 dernières minutes de l'examen, il sera interdit de se lever avant que TOUTES les copies n'aient été ramassées.
- Le non-respect des consignes 7-8-9 entraînera une pénalité de 10%.

Exercice 1 (6 points)

Un ingénieur souhaite comparer la performance de trois marques de freins à disque pour vélo de route. La variable d'intérêt sera donc la distance de freinage parcourue pour passer de 40 km/h à 0 km/h. L'expérience est répétée n fois pour chaque type de frein. Utilisez la table d'analyse de la variance suivante pour répondre aux deux questions.

	SS	DDL	MS	F0	valeur-p
Traitement	45.77	2	22.885	14.329	0.000001
Erreur	91.03	57	1.597		

(a) (3 points) Laquelle des affirmations suivantes est vraie ?

- ☐ Nous savons que $n = 60$.
- ☒ **L'estimateur de la variance est 1,597.**
- ☐ La variable réponse est la distance de freinage et le facteur est Erreur.
- ☐ Comme il s'agit d'une régression linéaire simple, il n'y a pas de facteur.

Solution: B est vraie. $\hat{\sigma}^2 = MS_{\text{Residuals}} = SS_{\text{Residuals}}/DDL_{\text{Residuals}} = 91,03/57 \approx 1,597 \approx 1,60$.

A) $DDL_{\text{disque}} = I - 1 = 2$, donc $I = 3$ marques. $DDL_{\text{Residuals}} = n - I = 57$, donc $n = 60$. Avec $I = 3$ marques et $n = 60$ observations, $k = n/I = 20$ répétitions par marque (pas $k = 60$).

C) Le facteur est disque, pas Residuals.

D) Il s'agit d'une ANOVA, pas d'une régression.

(b) (3 points) Quelle conclusion peut-on tirer à partir de cette table d'analyse de la variance, au seuil de 1% ?

- ☐ La variance de la distance de freinage d'au moins une marque de frein est différente d'au moins une autre marque.
- ☒ **La distance de freinage moyenne d'au moins une marque de frein est différente d'au moins une autre marque.**
- ☐ Toutes les moyennes sont égales.

Solution: B est vraie. La valeur- $p = 0,000001 < 0,01 = \alpha$, on rejette H_0 . Au moins une moyenne de distance de freinage diffère des autres.

A) L'ANOVA compare les moyennes, pas les variances.

C) Il s'agit d'une ANOVA à un seul facteur; il n'y a pas de terme d'interaction.

Exercice 2 (4 points)

Nous faisons un test pour confronter $H_0 : \mu = 15$ à $H_1 : \mu \neq 15$. La règle de décision est de rejeter H_0 si $\bar{X} < 10$ ou si $\bar{X} > 20$. Dans chacun des cas suivants, déterminez si une erreur est commise et déterminez de quel type, le cas échéant.

(a) (1 point) La vraie valeur de μ est 16 et nous obtenons $\bar{x} = 12$.

☐ Erreur de type I ✓ **Erreur de type II** ☐ Aucune erreur

(b) (1 point) La vraie valeur de μ est 15 et nous obtenons $\bar{x} = 12$.

☐ Erreur de type I ☐ Erreur de type II ✓ **Aucune erreur**

(c) (1 point) La vraie valeur de μ est 15 et nous obtenons $\bar{x} = 21$.

✓ **Erreur de type I** ☐ Erreur de type II ☐ Aucune erreur

(d) (1 point) La vraie valeur de μ est 18 et nous obtenons $\bar{x} = 21$.

☐ Erreur de type I ☐ Erreur de type II ✓ **Aucune erreur**

Exercice 3 (10 points)

Soit $X_1, \dots, X_{16}$ qui proviennent d'une loi normale d'espérance μ et de variance σ^2 .

On fait le test d'hypothèses pour lequel $H_0 : \mu = 5$ et $H_1 : \mu > 5$ au seuil $\alpha = 1\%$.

Pour quelles valeurs de s^2 rejette-t-on H_0 si $\bar{x} = 6,301$?

Solution: Comme la variance est inconnue et que les données sont normales, on utilise la statistique

$$T_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \quad \text{sous } H_0.$$

Ici, $n = 16$, $\mu_0 = 5$ et $\bar{x} = 6,301$, donc

$$T_0 = \frac{6,301 - 5}{s/4} = \frac{5,204}{s}.$$

Au seuil $\alpha = 1\%$ pour un test unilatéral à droite, on rejette H_0 si

$$T_0 > t_{0,99;15} \approx 2,602.$$

Donc

$$\frac{5,204}{s} > 2,602 \iff s < \frac{5,204}{2,602} = 2 \iff s^2 < 4.$$

Région de rejet : on rejette H_0 pour $0 < s^2 < 4$.

Exercice 4 (18 points)

Pour des raisons de santé publique, on cherche à savoir s'il est possible d'expliquer le taux maximal d'ozone O_3 de la journée par la température à midi donnée en degrés celsius. Afin d'étudier le modèle $Y_i = \beta_0 + \beta_1 X_i + E_i$, en supposant que les postulats de régression linéaire sont respectés, vous disposez des résultats suivants :

MSE: 160.529 sur 8 degrés de liberté

R-carré: 0.7041, R-carré ajusté: 0.6671

F0: 19.03 sur 1 et 8 degrés de liberté, valeur-p: 0.002403

$$\sum_{i=1}^{10} x_i = 219,1; \quad \sum_{i=1}^{10} x_i^2 = 5214,58; \quad \sum_{i=1}^{10} y_i = 1026,4; \quad \sum_{i=1}^{10} y_i^2 = 118446,6; \quad \sum_{i=1}^{10} x_i y_i = 23650,84; \quad s_X^2 = 46,01.$$

- (a) (8 points) Donnez l'équation de la droite de régression permettant de prédire la concentration d'ozone O_3 dans l'air en fonction de la température à midi. Justifiez toutes les étapes de votre démarche.

Solution: On a $n = 10$.

$$\bar{x} = \frac{219,1}{10} = 21,91 \quad \text{et} \quad \bar{y} = \frac{1026,4}{10} = 102,64.$$

$$S_{XX} = 5214,58 - 10(21,91)^2 = 5214,58 - 4800,48 = 414,10.$$

$$S_{XY} = 23650,84 - 10(21,91)(102,64) = 23650,84 - 22488,42 = 1162,42.$$

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{1162,42}{414,10} \approx 2,81.$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 102,64 - 2,81 \times 21,91 \approx 102,64 - 61,57 = 41,07.$$

L'équation de la droite de régression est : $\hat{y} = 41,07 + 2,81x$.

- (b) (2 points) Donnez le pourcentage de la variabilité totale de la concentration d'ozone O_3 dans l'air qui est expliquée par la température à midi.

Solution: Le coefficient de détermination $R^2 = 0,7041$ (donné dans la sortie). Donc 70,41 % de la variabilité totale de la concentration d'ozone est expliquée par la température à midi.

Suite de l'exercice 4 sur la feuille suivante

Suite de l'exercice 4

- (c) (3 points) Calculez la prévision ponctuelle de la concentration d'ozone O_3 dans l'air pour une température de 22 degrés. Justifiez toutes les étapes de votre démarche.

Solution: On substitue $x = 22$ dans l'équation de régression :

$$\hat{y}(22) = 41,07 + 2,81 \times 22 = 41,07 + 61,82 = 102,89.$$

La prévision ponctuelle est d'environ 102,89 microgrammes par millilitre.

- (d) (2 points) Un chercheur aimerait estimer la concentration d'ozone O_3 dans l'air lors d'une journée précise. Le midi de cette journée, la température est de 14 degrés. La prévision ponctuelle de la concentration d'ozone O_3 dans l'air en cette journée est environ de 80,38. Choisissez l'intervalle de valeurs ayant 95% de chances de contenir la concentration d'ozone O_3 dans l'air en cette journée.

☐ $80,38 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[\frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

☒ $80,38 \pm t_{0,025, n-2} \sqrt{\text{MSE} \left[1 + \frac{1}{n} + \frac{(14 - \bar{x})^2}{S_{XX}} \right]}$

Solution: B est le bon choix. On cherche un **intervalle de prévision** pour une observation future individuelle (la concentration d'ozone « en une journée précise »). L'intervalle de prévision comporte le terme $1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$ sous la racine, alors que l'intervalle de confiance pour $E(Y | x_0)$ ne comporte que $\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{XX}}$.

- (e) (1 point) Si la température à midi ce jour-là était de 18 degrés, l'intervalle de valeurs calculé à la question précédente serait...

☒ **plus court**

☐ de même longueur

☐ plus long

Solution: A est le bon choix. La largeur de l'intervalle dépend de $(x_0 - \bar{x})^2 / S_{XX}$. On a $\bar{x} \approx 21,91$. Avec $x_0 = 14$: $(14 - 21,91)^2 = 62,57$. Avec $x_0 = 18$: $(18 - 21,91)^2 = 15,29$. Puisque 18 est plus proche de $\bar{x}$, le terme $(x_0 - \bar{x})^2$ est plus petit, donc l'intervalle est **plus court**.

- (f) (2 points) Quelle affirmation parmi les suivantes est vraie au seuil 1% ?

☐ La concentration d'ozone O_3 dans l'air et la température à midi ne sont pas unis par une relation linéaire significative.

- ☐ On ne peut pas prédire la concentration d'ozone O_3 dans l'air à partir de la température à midi.
- ☐ La concentration d'ozone O_3 dans l'air et la température à midi sont indépendantes.
- ✓ **La relation linéaire entre la concentration d'ozone O_3 dans l'air et la température à midi est significative.**

Solution: D est le bon choix. La valeur- $p = 0,002403 < 0,01 = \alpha$. On rejette $H_0 : \beta_1 = 0$. La relation linéaire entre la concentration d'ozone et la température à midi est significative au seuil de 1 %.

Exercice 5 (16 points)

Une chocolaterie prétend que ses sacs de 120 bonbons contiennent les saveurs suivantes dans les proportions indiquées : 30 % chocolat noir, 25 % chocolat au lait, 25 % caramel et 20 % noisette. Pour vérifier cette affirmation, un contrôleur de qualité prélève un sac au hasard et compte les bonbons de chaque saveur. Les résultats sont présentés ci-dessous.

Saveur	Noir	Lait	Caramel	Noisette	Total
Fréquence observée (O_i)	42	35	20	23	120

(a) (1 point) Formulez les hypothèses nulle et alternative du test du khi-carré d'adéquation.

Solution: H_0 : La distribution des saveurs correspond aux proportions annoncées, c'est-à-dire $p_{\text{noir}} = 0,30$, $p_{\text{lait}} = 0,25$, $p_{\text{caramel}} = 0,25$, $p_{\text{noisette}} = 0,20$.

H_1 : La distribution des saveurs ne correspond pas aux proportions annoncées (au moins une proportion diffère).

(b) (3 points) Calculez la statistique de test D_0 . Vous pouvez utiliser le tableau plus haut dans votre démarche.

Solution: On calcule d'abord les fréquences espérées $E_i = n \times p_i$:

Saveur	Noir	Lait	Caramel	Noisette
E_i	$120 \times 0,30 = 36$	$120 \times 0,25 = 30$	$120 \times 0,25 = 30$	$120 \times 0,20 = 24$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$D_0 = \sum_{i=1}^4 \frac{(O_i - E_i)^2}{E_i} = \frac{(42 - 36)^2}{36} + \frac{(35 - 30)^2}{30} + \frac{(20 - 30)^2}{30} + \frac{(23 - 24)^2}{24}$$

$$= \frac{36}{36} + \frac{25}{30} + \frac{100}{30} + \frac{1}{24} = 1 + 0,833 + 3,333 + 0,042 = 5,208$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = k - 1 = 4 - 1 = 3$ degrés de liberté ($k = 4$ catégories, aucun paramètre estimé à partir des données).

(d) (2 points) Au seuil $\alpha = 0,05$, quelle est votre conclusion ?

Solution: $D_0 = 5,208 < 7,815 = \chi^2_{0,05;3}$.

On ne rejette pas H_0 . Au seuil de 5 %, il n'y a pas suffisamment de preuves pour affirmer que la distribution des saveurs diffère des proportions annoncées par la chocolaterie.

Exercice 6 (16 points)

Une étude cherche à déterminer s'il existe un lien entre le niveau de stress (faible, modéré, élevé) et la qualité du sommeil (bonne, mauvaise) chez des adultes. Un échantillon de 200 personnes donne les résultats suivants.

	Bonne qualité	Mauvaise qualité	Total
Stress faible			
O_{ij}	50	10	60
E_{ij}	33	27	
D_{ij}	8,758	10,704	
Stress modéré			
O_{ij}	45	35	80
E_{ij}	44	36	
D_{ij}	0,023	0,028	
Stress Élevé			
O_{ij}	15	45	60
E_{ij}	33	27	
D_{ij}	9,818	12	
Total observés	110	90	200

(a) (1 point) Formulez les hypothèses nulle et alternative du test d'indépendance.

Solution: H_0 : Le niveau de stress et la qualité du sommeil sont indépendants.

H_1 : Le niveau de stress et la qualité du sommeil ne sont pas indépendants (il existe une association).

(b) (3 points) Calculez la statistique de test D_0 .

Solution: Les fréquences espérées sous H_0 sont $E_{ij} = \frac{(\text{total ligne } i) \times (\text{total colonne } j)}{n}$.

	Bonne qualité	Mauvaise qualité
Stress faible	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$
Stress modéré	$\frac{80 \times 110}{200} = 44$	$\frac{80 \times 90}{200} = 36$
Stress élevé	$\frac{60 \times 110}{200} = 33$	$\frac{60 \times 90}{200} = 27$

Toutes les fréquences espérées sont ≥ 5 . ✓

$$\begin{aligned}
 D_0 &= \frac{(50 - 33)^2}{33} + \frac{(10 - 27)^2}{27} + \frac{(45 - 44)^2}{44} + \frac{(35 - 36)^2}{36} \\
 &\quad + \frac{(15 - 33)^2}{33} + \frac{(45 - 27)^2}{27} \\
 &= \frac{289}{33} + \frac{289}{27} + \frac{1}{44} + \frac{1}{36} + \frac{324}{33} + \frac{324}{27} \\
 &= 8,758 + 10,704 + 0,023 + 0,028 + 9,818 + 12,000 \\
 &= 41,331
 \end{aligned}$$

(c) (2 points) Combien de degrés de liberté possède la loi de référence sous H_0 ?

Solution: $\nu = (r - 1)(c - 1) = (3 - 1)(2 - 1) = 2$ degrés de liberté ($r = 3$ niveaux de stress, $c = 2$ niveaux de qualité du sommeil).

(d) (2 points) Au seuil $\alpha = 0,01$, quelle est votre conclusion ?

Solution: $D_0 = 41,331 > 9,210 = \chi^2_{0,01;2}$.

On rejette H_0 . Au seuil de 1 %, il y a suffisamment de preuves pour conclure que le niveau de stress et la qualité du sommeil ne sont pas indépendants. Les données suggèrent qu'un stress plus élevé est associé à une mauvaise qualité du sommeil.