



UNIVERSITÉ
LAVAL

Faculté des sciences et génie
Département de mathématiques et statistique

Prénom et nom

NI (9 chiffres)

Exercices supplémentaires — ANOVA à un facteur

Méthodes statistiques (STT-1920)

Enseignant : Julien Miron

Exercice

Une chercheuse en biochimie compare l'activité de la lactate déshydrogénase (LDH, en U/L) chez des patients répartis en $k = 4$ groupes selon leur pathologie hépatique. Elle mesure l'activité LDH chez $n = 5$ patients par groupe ($N = 20$ au total). La table d'analyse de la variance suivante est produite par Rcmdr :

```
> summary(ANOVAModel)
      Df  Sum Sq  Mean Sq  F value    Pr(>F)
Groupe   3   110.40    36.80    7.360    0.0024
Residuals 16    80.00     5.00
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est **vraie** ? Une seule réponse est bonne.

- ☐ L'activité LDH moyenne estimée pour le facteur Groupe vaut 36,80 U/L.
- ☐ Il y a 5 niveaux différents pour le facteur Groupe.
- ☐ Il y a 17 observations en tout dans le jeu de données.
- ☒ **Au seuil $\alpha = 0,05$, nous pouvons affirmer que l'activité LDH moyenne n'est pas la même dans tous les groupes.**
- ☐ Au seuil $\alpha = 0,01$, nous ne rejetons pas H_0 .
- ☐ La somme des carrés totale vaut 5,00.

Solution: Analyse des choix.

- **Faux.** 36,80 est le carré moyen (Mean Sq), pas la moyenne des observations.
- **Faux.** Il y a $Df_{\text{trt}} + 1 = 3 + 1 = 4$ groupes, pas 5.
- **Faux.** $N = k \times n = 4 \times 5 = 20$ observations ; $Df_{\text{total}} = N - 1 = 19$.
- **Vrai.** La valeur- $p = 0,0024 < 0,05 = \alpha$, donc on rejette H_0 au seuil 5%.
- **Faux.** $p = 0,0024 < 0,01$, donc on rejette aussi H_0 au seuil 1%.
- **Faux.** $SS_{\text{total}} = 110,40 + 80,00 = 190,40$.

Exercice

Un biochimiste étudie l'effet de $k = 5$ substrats différents sur l'activité d'une enzyme (en nmol/min/mg de protéine). Il réalise $n = 6$ mesures par substrat ($N = 30$ au total). La table d'ANOVA partielle suivante a été produite ; certaines quantités ont été remplacées par AAA, BBB et CCC. Nous considérons que les postulats du modèle sont respectés.

ANOVA

	SS	Ddl	MS	F0	Pr(>F)
Substrat	185.40	???	AAA	5.297	0.0037
Residuals	BBB	25	8.75		
Total	CCC	???			

(a) Que vaut AAA ?

- ☐ 185,40
☐ 37,08
☒ 46,35
☐ 92,70
☐ 8,75
☐ Il n'est pas possible de trouver la valeur de AAA avec les informations données.

Solution: $Dl_{\text{trt}} = k - 1 = 5 - 1 = 4$.

$$AAA = MS_{\text{trt}} = \frac{SS_{\text{trt}}}{Dl_{\text{trt}}} = \frac{185,40}{4} = 46,35.$$

(b) Que vaut BBB ?

- ☐ 25
☐ 8,75
☐ 46,35
☒ 218,75
☐ 404,15
☐ Il n'est pas possible de trouver la valeur de BBB avec les informations données.

Solution:

$$BBB = SS_E = MS_E \times Dl_E = 8,75 \times 25 = 218,75.$$

(c) Que vaut CCC ?

- ☐ 46,35
☐ 218,75
☒ 404,15
☐ 185,40
☐ Il n'est pas possible de trouver la valeur de CCC avec les informations données.

Solution:

$$CCC = SS_{\text{total}} = SS_{\text{trt}} + SS_E = 185,40 + 218,75 = 404,15.$$

(d) Au seuil de 5%, quelle conclusion pouvons-nous tirer de la table d'ANOVA ? Une seule réponse est bonne.

- ☐ Il n'est pas possible de tirer une conclusion car certaines valeurs sont remplacées par ???.
☐ Toutes les activités enzymatiques moyennes sont significativement égales.
☐ Toutes les activités enzymatiques moyennes sont significativement différentes.

✓ **L'activité enzymatique moyenne pour au moins un substrat est significativement différente de celle d'au moins un autre substrat.**

☐ Il faudrait davantage de mesures pour pouvoir conclure.

Solution: La valeur- $p = 0,0037 < 0,05 = \alpha$, donc on **rejette** H_0 . On conclut que l'activité enzymatique moyenne diffère significativement pour au moins un substrat. (L'ANOVA ne précise pas lesquels.)

Exercice

Un chercheur en nutrition clinique étudie l'effet de trois régimes alimentaires sur la glycémie à jeun (en mmol/L) de patients diabétiques de type 2. Il assigne $n = 8$ patients à chacun des $k = 3$ régimes ($N = 24$ au total). Les résultats sont résumés ci-dessous. On suppose que les postulats de l'ANOVA à un facteur sont satisfaits.

Régime	Moyenne $\bar{y}_i$ (mmol/L)	Variance s_i^2
Faible en glucides	12,0	4,0
Méditerranéen	15,0	5,0
Hyperprotéiné	18,0	3,0

(a) Calculez SS_{trt} , la somme des carrés des traitements. **Montrez votre démarche.**

Solution: La moyenne globale est $\bar{y}_{..} = \frac{12,0 + 15,0 + 18,0}{3} = 15,0$.

$$SS_{\text{trt}} = n \sum_{i=1}^k (\bar{y}_i - \bar{y}_{..})^2 = 8[(12,0 - 15)^2 + (15,0 - 15)^2 + (18,0 - 15)^2] = 8 \times 18 = 144.$$

(b) Calculez MS_E , le carré moyen des résidus. **Montrez votre démarche.**

Solution:

$$SS_E = \sum_{i=1}^k (n-1)s_i^2 = (8-1)(4,0 + 5,0 + 3,0) = 7 \times 12 = 84.$$

$$MS_E = \frac{SS_E}{N-k} = \frac{84}{21} = 4,0.$$

(c) Calculez la statistique de test F_0 . **Montrez votre démarche.**

Solution:

$$MS_{\text{trt}} = \frac{SS_{\text{trt}}}{k-1} = \frac{144}{2} = 72,0.$$
$$F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{72,0}{4,0} = 18,0.$$

- (d) En utilisant la valeur critique $F_{0,05;2;21} = 3,467$, quelle est la conclusion du test au seuil $\alpha = 0,05$? Rédigez votre conclusion en lien avec le contexte.

Solution: Comme $F_0 = 18,0 > 3,467 = F_{0,05;2;21}$, on **rejette** H_0 au seuil 5%. Il y a suffisamment de preuves pour affirmer que la glycémie à jeun moyenne n'est pas la même pour tous les régimes alimentaires.

Exercice

Un microbiologiste compare la zone d'inhibition (en mm) de $k = 4$ antibiotiques sur une souche de *Staphylococcus aureus*. Chaque antibiotique est testé sur $n = 10$ cultivations indépendantes ($N = 40$ au total). La table ci-dessous est obtenue :

```
> summary(ANOVAModel)
              Df    Sum Sq   Mean Sq    F value    Pr(>F)
Antibiotique   3     241.50     80.50     2.483     0.0763
Residuals    36    1167.48     32.43
```

Pour chaque énoncé qui suit, indiquez si l'énoncé est **vrai** ou **faux**.

- (a) L'hypothèse nulle du test est $H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4$, où μ_i désigne la zone d'inhibition moyenne de l'antibiotique i .

✓ **Vrai** ☐ Faux

Solution: Vrai. L'ANOVA à un facteur teste l'égalité de toutes les moyennes de groupe.

- (b) Au seuil $\alpha = 0,05$, on rejette H_0 .

☐ Vrai ✓ **Faux**

Solution: Faux. La valeur- $p = 0,0763 > 0,05 = \alpha$, donc on **ne rejette pas** H_0 au seuil 5%.

- (c) Au seuil $\alpha = 0,10$, on rejette H_0 .

✓ **Vrai** ☐ Faux

Solution: Vrai. La valeur- $p = 0,0763 < 0,10 = \alpha$.

- (d) Le nombre de degrés de liberté totaux est 39.

✓ **Vrai** ☐ Faux

Solution: Vrai. $Dl_{\text{total}} = N - 1 = 40 - 1 = 39$. On vérifie : $Dl_{\text{trt}} + Dl_E = 3 + 36 = 39$. ✓

Exercice

Un microbiologiste veut savoir si la teneur en protéines extracellulaires (en $\mu\text{g/mL}$) diffère selon la souche bactérienne. Ses données portent sur $k = 6$ souches de *Escherichia coli*, avec $n = 5$ réplicats par souche ($N = 30$ au total). Il obtient :

$$SS_{\text{total}} = 890,40, \quad SS_E = 540,00.$$

On suppose que les postulats du modèle sont satisfaits.

(a) Écrivez les hypothèses du test ANOVA correspondant à cette situation.

Solution: Soit μ_i la teneur moyenne en protéines de la souche i , pour $i = 1, \dots, 6$.

$$H_0 : \mu_1 = \dots = \mu_6 \quad \text{contre} \quad H_1 : \text{au moins deux moyennes sont différentes.}$$

(b) Calculez SS_{trt} , la somme des carrés des traitements. **Montrez votre démarche.**

Solution:

$$SS_{\text{trt}} = SS_{\text{total}} - SS_E = 890,40 - 540,00 = 350,40.$$

(c) Calculez MS_{trt} et MS_E . **Montrez votre démarche.**

Solution:

$$MS_{\text{trt}} = \frac{350,40}{k-1} = \frac{350,40}{5} = 70,08.$$

$$MS_E = \frac{540,00}{N-k} = \frac{540,00}{24} = 22,50.$$

(d) Calculez la statistique de test F_0 . **Montrez votre démarche.**

Solution:

$$F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{70,08}{22,50} = 3,114.$$

(e) En utilisant la valeur critique $F_{0,05;5;24} = 2,621$, concluez le test au seuil $\alpha = 0,05$ en lien avec le contexte.

Solution: Comme $F_0 = 3,114 > 2,621 = F_{0,05;5;24}$, on **rejette** H_0 au seuil 5%. Il y a suffisamment de preuves pour affirmer que la teneur moyenne en protéines n'est pas la même pour toutes les souches.

Exercice

Une oncologue compare le niveau d'expression d'un biomarqueur tumoral (en unités arbitraires) dans $k = 3$ types de cellules cancéreuses (MCF-7, MDA-MB-231 et T47D). Elle effectue $n = 7$ mesures par type cellulaire ($N = 21$ au total). La table d'analyse de la variance suivante est produite par Rcmdr :

```
> summary(ANOVAModel)
              Df    Sum Sq   Mean Sq    F value    Pr(>F)
TypeCellule    2     324.00    162.00     16.200    0.0001
Residuals     18     180.00     10.00
```

À partir de la table d'ANOVA, quelle affirmation parmi les suivantes est **vraie** ? Une seule réponse est bonne.

- ☐ Il y a 18 observations en tout dans le jeu de données.
- ☐ La valeur 162,00 est la moyenne du biomarqueur pour le facteur TypeCellule.
- ☐ La variance résiduelle est environ 16 fois plus grande que la variance entre groupes.
- ☒ **La somme des carrés totale vaut 504,00.**
- ☐ Au seuil $\alpha = 0,05$, nous ne rejetons pas H_0 .
- ☐ Il y a 2 types cellulaires différents dans l'étude.

Solution: Analyse des choix.

- **Faux.** $N = k \times n = 3 \times 7 = 21$ observations.
- **Faux.** 162,00 est le carré moyen des traitements, pas la moyenne.
- **Faux.** C'est l'inverse : la variance entre groupes (162,00) est 16,2 fois plus grande que la variance résiduelle (10,00).
- **Vrai.** $SS_{\text{total}} = SS_{\text{trt}} + SS_E = 324,00 + 180,00 = 504,00$. ✓
- **Faux.** $p = 0,0001 < 0,05$, donc on rejette H_0 .
- **Faux.** $DI_{\text{trt}} = k - 1 = 2$ implique $k = 3$ types cellulaires.

Exercice

Un néphrologue évalue l'effet de $k = 4$ protocoles de dialyse sur le pH sanguin de patients en insuffisance rénale chronique. Il administre chaque protocole à $n = 8$ patients ($N = 32$ au total). La table d'ANOVA partielle suivante a été produite ; certaines quantités ont été remplacées par AAA et BBB. Nous considérons que les postulats du modèle sont respectés.

ANOVA

	SS	Ddl	MS	F0	Pr(>F)
Protocole	6.72	???	AAA	5.600	0.0039
Residuals	BBB	28	0.40		
Total	???	???			

(a) Que vaut AAA ?

- ☐ 0,40
☐ 1,68
☒ 2,24
☐ 6,72
☐ 5,60
☐ Il n'est pas possible de trouver la valeur de AAA avec les informations données.

Solution: $Dl_{\text{trt}} = k - 1 = 4 - 1 = 3$.

$$AAA = MS_{\text{trt}} = \frac{SS_{\text{trt}}}{Dl_{\text{trt}}} = \frac{6,72}{3} = 2,24.$$

$$\text{Vérification : } F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{2,24}{0,40} = 5,60. \checkmark$$

(b) Que vaut BBB ?

- ☐ 0,40
☐ 6,72
☒ 11,20
☐ 28,00
☐ 17,92
☐ Il n'est pas possible de trouver la valeur de BBB avec les informations données.

Solution:

$$BBB = SS_E = MS_E \times Dl_E = 0,40 \times 28 = 11,20.$$

(c) Combien y a-t-il de patients au total dans l'étude ?

- ☐ 28
☐ 29
☐ 31
☒ 32
☐ Il n'est pas possible de répondre avec les informations données.

Solution: $Dl_E = N - k = 28$, donc $N = 28 + k = 28 + 4 = 32$. On vérifie : $k \times n = 4 \times 8 = 32$. $\checkmark$

(d) Au seuil de 1%, quelle conclusion pouvons-nous tirer de la table d'ANOVA ? Une seule réponse est bonne.

- ☐ Le pH sanguin moyen est le même pour tous les protocoles de dialyse.
☒ **Le pH sanguin moyen diffère significativement pour au moins un protocole.**

- ☐ Les postulats du modèle ne sont pas respectés.
- ☐ Il n'est pas possible de conclure car certaines valeurs sont manquantes.
- ☐ Il faudrait davantage de patients pour conclure.

Solution: La valeur- $p = 0,0039 < 0,01 = \alpha$, donc on **rejette** H_0 même au seuil 1%. Le pH sanguin moyen diffère significativement entre au moins deux protocoles de dialyse.

Exercice

Un hématologue compare le taux plasmatique de fibrinogène (en g/L) de patients traités avec $k = 3$ anticoagulants différents. Il assigne $n = 6$ patients à chaque traitement ($N = 18$ au total). Les résultats sont résumés ci-dessous. On suppose que les postulats de l'ANOVA à un facteur sont satisfaits.

Anticoagulant	Moyenne $\bar{y}_i$ (g/L)	Variance s_i^2
Héparine	2,4	0,36
Warfarine	3,0	0,25
Rivaroxaban	3,6	0,35

(a) Calculez SS_{trt} , la somme des carrés des traitements. **Montrez votre démarche.**

Solution: La moyenne globale est $\bar{y}_{..} = \frac{2,4 + 3,0 + 3,6}{3} = 3,0$.

$$SS_{\text{trt}} = n \sum_{i=1}^k (\bar{y}_i - \bar{y}_{..})^2 = 6[(2,4 - 3)^2 + (3,0 - 3)^2 + (3,6 - 3)^2] = 6 \times [0,36 + 0 + 0,36] = 6 \times 0,72 = 4,32.$$

(b) Calculez MS_E , le carré moyen des résidus. **Montrez votre démarche.**

Solution:

$$SS_E = \sum_{i=1}^k (n - 1) s_i^2 = (6 - 1)(0,36 + 0,25 + 0,35) = 5 \times 0,96 = 4,80.$$

$$MS_E = \frac{SS_E}{N - k} = \frac{4,80}{18 - 3} = \frac{4,80}{15} = 0,32.$$

(c) Calculez la statistique de test F_0 . **Montrez votre démarche.**

Solution:

$$MS_{\text{trt}} = \frac{SS_{\text{trt}}}{k-1} = \frac{4,32}{2} = 2,16.$$
$$F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{2,16}{0,32} = 6,75.$$

(d) En utilisant la valeur critique $F_{0,05;2;15} = 3,682$, concluez le test au seuil $\alpha = 0,05$ en lien avec le contexte.

Solution: Comme $F_0 = 6,75 > 3,682 = F_{0,05;2;15}$, on **rejette** H_0 au seuil 5%. Il y a suffisamment de preuves pour affirmer que le taux moyen de fibrinogène n'est pas le même pour les trois anticoagulants.

Exercice

Un cardiologue compare la réduction du cholestérol LDL (en mg/dL) obtenue par $k = 3$ statines différentes (atorvastatine, rosuvastatine, simvastatine). Il assigne $n = 12$ patients à chaque statine ($N = 36$ au total). La table ci-dessous est obtenue :

```
> summary(ANOVAModel)
      Df    Sum Sq   Mean Sq    F value    Pr(>F)
Statine  2     540.00   270.00    10.800    0.0003
Residuals 33     825.00    25.00
```

Pour chaque énoncé qui suit, indiquez si l'énoncé est **vrai** ou **faux**.

- (a) Il y a 36 patients au total dans l'étude.

✓ **Vrai** ☐ Faux

Solution: Vrai. $DI_{\text{total}} = N - 1 = 35$, donc $N = 36$. On vérifie : $DI_{\text{trt}} + DI_E + 1 = (2 + 33) + 1 = 36$. ✓

- (b) Au seuil $\alpha = 0,01$, on rejette H_0 .

✓ **Vrai** ☐ Faux

Solution: Vrai. La valeur- $p = 0,0003 < 0,01 = \alpha$.

- (c) Le carré moyen des résidus $MS_E = 25,00$ est un estimateur sans biais de la variance commune σ^2 , que H_0 soit vraie ou non.

✓ **Vrai** ☐ Faux

Solution: Vrai. MS_E est toujours un estimateur sans biais de σ^2 , quelle que soit la validité de H_0 .

- (d) Le carré moyen des traitements $MS_{\text{trt}} = 270,00$ est un estimateur sans biais de la variance commune σ^2 , que H_0 soit vraie ou non.

☐ Vrai ✓ **Faux**

Solution: Faux. MS_{trt} estime $\sigma^2 + n \frac{\sum(\mu_i - \mu)^2}{k - 1}$. Il n'est sans biais pour σ^2 que lorsque H_0 est vraie (toutes les moyennes égales).

Exercice

Une nutritionniste clinique étudie l'effet de $k = 5$ types de suppléments en fer sur le taux d'hémoglobine (en g/dL) de patientes anémiantes. Elle assigne $n = 6$ patientes à chaque supplément ($N = 30$ au total) et obtient :

$$SS_{\text{total}} = 180,00, \quad SS_E = 120,00.$$

On suppose que les postulats du modèle sont satisfaits.

(a) Écrivez les hypothèses du test ANOVA correspondant à cette situation.

Solution: Soit μ_i le taux moyen d'hémoglobine sous le supplément i , pour $i = 1, \dots, 5$.

$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5$ contre $H_1 : \text{au moins deux moyennes sont différentes.}$

(b) Calculez SS_{trt} , MS_{trt} et MS_E . **Montrez votre démarche.**

Solution:

$$SS_{\text{trt}} = SS_{\text{total}} - SS_E = 180,00 - 120,00 = 60,00.$$

$$MS_{\text{trt}} = \frac{60,00}{k-1} = \frac{60,00}{4} = 15,00.$$

$$MS_E = \frac{120,00}{N-k} = \frac{120,00}{25} = 4,80.$$

(c) Calculez la statistique de test F_0 . **Montrez votre démarche.**

Solution:

$$F_0 = \frac{MS_{\text{trt}}}{MS_E} = \frac{15,00}{4,80} = 3,125.$$

(d) En utilisant la valeur critique $F_{0,05;4;25} = 2,759$, concluez le test au seuil $\alpha = 0,05$ en lien avec le contexte.

Solution: Comme $F_0 = 3,125 > 2,759 = F_{0,05;4;25}$, on **rejette** H_0 au seuil 5%. Il y a suffisamment de preuves pour affirmer que le taux moyen d'hémoglobine n'est pas le même pour tous les types de suppléments en fer.