

Échantillonnage

Le matériel de ce chapitre est tiré des notes de cours d'Anne-Sophie Charest et d'Emmanuelle Reny-Nolin.

Table des matières

1	Introduction	3
1.1	Population et échantillon	3
2	Types d'études	3
2.1	Étude observationnelle	3
2.2	Expérience (étude expérimentale)	4
3	Méthodes d'échantillonnage	4
3.1	Échantillonnage non probabiliste	4
3.1.1	Échantillon de convenance	5
3.1.2	Échantillon raisonné (ou de jugement)	5
3.2	Échantillonnage probabiliste	5
3.2.1	Échantillonnage aléatoire simple (EAS)	5
3.2.2	Échantillonnage systématique	5
3.2.3	Échantillonnage stratifié	6
3.2.4	Échantillonnage par grappes	6
3.3	Résumé comparatif	7
4	Sources de biais	7
4.1	Biais de couverture	7
4.2	Biais de sélection	7
4.3	Biais de non-réponse	7
4.4	Biais de mesure	8

5	Quand peut-on généraliser et conclure à la causalité ?	8
5.1	Généraliser à la population	8
5.2	Conclure à la causalité	8
5.3	Tableau récapitulatif	9

1 Introduction

Avant de pouvoir analyser des données, il faut les collecter. La qualité de toute analyse statistique dépend en grande partie de la façon dont les données ont été recueillies. Un échantillon mal conçu ou entaché d'un biais peut mener à des conclusions erronées, peu importe la rigueur des méthodes statistiques appliquées par la suite.

Ce chapitre présente les principaux concepts liés à la collecte de données : les types d'études statistiques, les méthodes d'échantillonnage et les sources de biais à éviter.

1.1 Population et échantillon

Définition. La **population** est l'ensemble de tous les individus sur lesquels porte l'étude. Un **échantillon** est un sous-ensemble de la population qui est effectivement observé.

En pratique, il est rarement possible d'observer toute la population (recensement). On se contente donc d'un échantillon, à partir duquel on cherche à tirer des conclusions sur la population entière.

Définition. La **base de sondage** est la liste (ou la description) de tous les individus de la population à partir de laquelle on sélectionne l'échantillon. Idéalement, la base de sondage correspond exactement à la population cible.

Exemple. Si l'on souhaite étudier la consommation de boissons énergisantes chez les étudiants de l'Université Laval, la population cible est l'ensemble des étudiants inscrits. La base de sondage pourrait être la liste des étudiants fournie par le bureau du registraire.

2 Types d'études

On distingue deux grands types d'études statistiques : les **études observationnelles** et les **expériences**.

2.1 Étude observationnelle

Définition. Dans une **étude observationnelle**, le chercheur observe les individus sans intervenir sur les variables mesurées. Les individus ne sont pas assignés à des groupes par le chercheur : on mesure les variables telles qu'elles se présentent naturellement.

Par conséquent, une étude observationnelle ne permet pas de conclure à un lien de **causalité** entre deux variables. D'autres variables non mesurées, appelées **variables confondantes**, pourraient en effet expliquer la relation observée.

Exemple. On observe que les étudiants de la faculté de médecine consomment davantage de boissons énergisantes que ceux d'autres facultés. On ne peut pas conclure que le fait d'être inscrit en médecine *cause* une plus grande consommation : il se peut que les étudiants en médecine aient un horaire

plus chargé, ce qui expliquerait les deux phénomènes simultanément.

2.2 Expérience (étude expérimentale)

Définition. Dans une **expérience**, le chercheur impose délibérément un traitement à certains individus afin d'en observer l'effet. L'**attribution aléatoire** des individus aux groupes de traitement est la caractéristique essentielle d'une expérience bien conçue.

Grâce à l'attribution aléatoire, les variables confondantes tendent à se répartir uniformément entre les groupes. On peut alors attribuer les différences observées au traitement lui-même, et ainsi conclure à un lien de causalité.

Éléments d'une expérience bien conçue :

- **Groupe traitement** : reçoit le traitement étudié.
- **Groupe témoin (contrôle)** : ne reçoit pas le traitement, ou reçoit un placebo.
- **Attribution aléatoire** : les individus sont assignés aux groupes de façon aléatoire, indépendamment de leurs caractéristiques.
- **Effet placebo** : amélioration observée chez un individu qui croit recevoir un traitement actif alors qu'il reçoit un placebo. C'est pourquoi les essais médicaux sont souvent conçus en double aveugle.
- **Simple aveugle** : les sujets ne savent pas à quel groupe ils appartiennent.
- **Double aveugle** : ni les sujets ni les évaluateurs ne connaissent l'appartenance de chaque sujet à un groupe.

Remarque. Pour pouvoir généraliser les conclusions d'une expérience à l'ensemble de la population, les individus doivent avoir été sélectionnés de façon représentative (par exemple, par un échantillonnage probabiliste). L'attribution aléatoire permet de conclure à la causalité ; l'échantillonnage aléatoire permet de généraliser.

3 Méthodes d'échantillonnage

Il existe deux grandes familles de méthodes d'échantillonnage : les méthodes **non probabilistes** et les méthodes **probabilistes**.

3.1 Échantillonnage non probabiliste

Dans un échantillonnage non probabiliste, les individus de la population n'ont pas tous une probabilité connue et non nulle d'être sélectionnés. Ces méthodes sont généralement plus faciles et

moins coûteuses à mettre en oeuvre, mais elles introduisent un risque de biais et ne permettent pas d'appliquer rigoureusement les méthodes d'inférence statistique.

3.1.1 Échantillon de convenance

On sélectionne les individus les plus facilement accessibles : par exemple, demander à ses amis ou recruter des étudiants volontaires dans un cours. Ce type d'échantillon n'est généralement pas représentatif de la population, car les individus facilement accessibles peuvent différer de façon systématique du reste de la population.

3.1.2 Échantillon raisonné (ou de jugement)

Le chercheur sélectionne lui-même les individus qu'il juge représentatifs de la population, en se basant sur son expertise. Bien que cette méthode puisse sembler raisonnable, elle est subjective et peut introduire des biais difficiles à détecter.

3.2 Échantillonnage probabiliste

Définition. Dans un **échantillonnage probabiliste**, chaque individu de la population a une probabilité *connue et non nulle* d'être sélectionné. Ces probabilités ne doivent pas nécessairement être égales.

L'échantillonnage probabiliste est la condition nécessaire pour utiliser les méthodes d'inférence statistique et pour généraliser les conclusions à la population.

3.2.1 Échantillonnage aléatoire simple (EAS)

On sélectionne n individus parmi les N individus de la population de façon entièrement aléatoire, sans remise (chaque individu a donc la même probabilité n/N d'être choisi). En pratique, on numérote les individus de la base de sondage et on utilise un générateur de nombres aléatoires pour effectuer la sélection.

Avantages : simple à comprendre et à mettre en oeuvre ; sert de référence théorique pour les autres méthodes.

Inconvénients : nécessite une base de sondage complète et à jour ; peut être inefficace si la population est hétérogène.

3.2.2 Échantillonnage systématique

On choisit un individu de départ au hasard parmi les k premiers, où $k = N/n$ (arrondi au nombre entier le plus proche), puis on sélectionne tous les k^e individus suivants.

Exemple. On souhaite interroger 200 étudiants parmi 10 000. Le pas de sélection est $k = 10\,000/200 = 50$. On tire un nombre aléatoire r entre 1 et 50, puis on sélectionne les individus $r, r + 50, r + 100, \dots, r + 9\,950$.

Avantages : facile à mettre en oeuvre une fois la base de sondage établie.

Inconvénients : risque de biais si la liste présente une périodicité qui coïncide avec le pas de sélection.

3.2.3 Échantillonnage stratifié

On divise la population en sous-groupes homogènes appelés **strates**, puis on effectue un EAS indépendant dans chaque strate. La taille de l'échantillon dans chaque strate peut être proportionnelle à la taille de la strate (**stratification proportionnelle**) ou non (**stratification disproportionnelle**).

Exemple. Pour étudier la consommation de boissons énergisantes par faculté, on pourrait stratifier par faculté et sélectionner un nombre d'étudiants proportionnel à la taille de chaque faculté.

Avantages : plus précis que l'EAS lorsque les strates sont homogènes en elles-mêmes mais hétérogènes entre elles ; garantit une représentation de chaque strate dans l'échantillon.

Inconvénients : nécessite de connaître l'appartenance de chaque individu à une strate avant d'échantillonner.

3.2.4 Échantillonnage par grappes

On divise la population en sous-groupes appelés **grappes**, on en sélectionne quelques-unes aléatoirement, puis on interroge tous les individus des grappes sélectionnées (plan à une phase) ou un sous-échantillon dans chaque grappe retenue (plan à deux phases).

Exemple. Une université comporte 20 facultés divisées en 10 départements chacune. On pourrait sélectionner 3 départements au hasard et interroger tous les étudiants de ces départements.

Avantages : très pratique lorsqu'il n'existe pas de liste complète de la population, mais qu'il est facile d'identifier des groupes naturels ; réduit les coûts de collecte.

Inconvénients : moins précis que l'EAS, car les individus d'une même grappe tendent à se ressembler ; l'information apportée par chaque individu est donc partiellement redondante.

3.3 Résumé comparatif

Méthode	Avantages principaux	Inconvénients principaux
EAS	Référence théorique, équitable	Nécessite une liste complète
Systématique	Simple à mettre en oeuvre	Risque de biais périodique
Stratifié	Très précis, représentatif par strate	Nécessite la connaissance des strates
Par grappes	Pratique, économique	Moins précis, dépend de l'homogénéité intra-grappe

4 Sources de biais

Un **biais** est une erreur *systématique* qui fait que les données recueillies ne représentent pas fidèlement la population cible. Il est important de distinguer les biais des erreurs d'échantillonnage : l'erreur d'échantillonnage est une variation aléatoire inhérente à tout processus d'échantillonnage, tandis qu'un biais est une déviation constante et orientée.

4.1 Biais de couverture

Le biais de couverture survient lorsque la base de sondage ne correspond pas exactement à la population cible : certains individus sont absents de la liste et ne peuvent pas être sélectionnés.

Exemple. Utiliser un annuaire téléphonique de lignes fixes comme base de sondage pour étudier la population québécoise en général exclut toutes les personnes sans ligne fixe (notamment les jeunes adultes). Si l'âge est lié à la variable d'intérêt, cela introduit un biais dans les estimations.

4.2 Biais de sélection

Le biais de sélection survient lorsque le mécanisme de sélection des individus favorise systématiquement certains sous-groupes de la population. Il est particulièrement fréquent dans les échantillonnages non probabilistes.

Exemple. Un sondage en ligne ne peut rejoindre que les personnes ayant accès à Internet et habituées à ce mode de communication, ce qui exclut une partie de la population.

4.3 Biais de non-réponse

Le biais de non-réponse survient lorsque les individus qui ne répondent pas au sondage ont des caractéristiques systématiquement différentes de ceux qui y répondent.

Remarque. Un taux de non-réponse élevé n'entraîne pas *nécessairement* un biais. Un biais apparaît seulement si les non-répondants diffèrent *systématiquement* des répondants quant à la variable d'intérêt. Cependant, un taux de non-réponse élevé augmente le risque de biais et rend difficile la vérification de cette hypothèse.

4.4 Biais de mesure

Le biais de mesure survient lorsque la façon de mesurer une variable – notamment la formulation des questions – influence les réponses obtenues.

Sources courantes de biais de mesure :

- **Questions orientées (ou suggestives) :** une question formulée de façon à suggérer une réponse.

Formulation biaisée : « Êtes-vous d'accord que les boissons énergisantes sont nuisibles à la santé ? »

Formulation neutre : « Quelle est votre opinion sur les boissons énergisantes ? »

- **Désirabilité sociale :** les répondants ont tendance à donner des réponses socialement acceptables plutôt que leurs vraies opinions (par exemple, sous-déclarer leur consommation d'alcool).
- **Effet de l'intervieweur :** la présence, le ton ou l'apparence de l'intervieweur peut influencer les réponses.
- **Ordre des questions :** l'ordre dans lequel les questions sont posées peut influencer les réponses aux questions subséquentes.

5 Quand peut-on généraliser et conclure à la causalité ?

5.1 Généraliser à la population

On peut généraliser les résultats d'un échantillon à l'ensemble de la population lorsque l'échantillon a été sélectionné par **échantillonnage probabiliste**. Un échantillon non probabiliste (de convenance ou raisonné) ne permet pas de généraliser de façon rigoureuse.

5.2 Conclure à la causalité

On peut conclure à un lien de causalité entre une variable explicative et une variable réponse uniquement lorsque les individus ont été **assignés aléatoirement** aux groupes de traitement. Cette condition est remplie dans une expérience bien conçue.

Dans une étude observationnelle, la présence d’une association statistique entre deux variables ne suffit pas à conclure à la causalité, car des variables confondantes pourraient être à l’origine de la relation observée.

5.3 Tableau récapitulatif

Condition	Généraliser à la population	Conclure à la causalité
Échantillonnage probabiliste uniquement	Oui	Non
Attribution aléatoire uniquement	Non*	Oui
Les deux réunies	Oui	Oui
Aucune des deux	Non	Non

* À moins que l’expérience ait été menée sur un échantillon probabiliste de la population.

Remarque. Ces deux dimensions – généralisation et causalité – sont indépendantes. Une expérience réalisée sur des étudiants volontaires d’une seule université peut permettre de conclure à la causalité (grâce à l’attribution aléatoire), sans que ces résultats puissent être généralisés à l’ensemble de la population (faute d’un échantillonnage probabiliste).