

STT-2902 – Modélisation statistique

Recueil d'exercices

Statistiques descriptives et échantillonnage

Exercice 1 (20 points)

Une municipalité souhaite connaître le temps moyen de déplacement domicile-travail de ses **30 000 résidents actifs**. Le bureau du transport vous fournit le tableau suivant :

Identifiant	Nom, Prénom	Quartier	Mode de transport	Temps (min)
1	Tremblay, Xavier	Centre-ville	Vélo	12
2	Lavoie, Marie	Banlieue Nord	Auto	35
3	Gagnon, Pierre	Banlieue Sud	Autobus	48
...	...	...	...	...

Supposez qu'il y a 6 quartiers, chacun contenant 5 000 résidents. Chaque quartier a 5 secteurs de 1 000 résidents. Vous souhaitez interroger **300 résidents**.

- (a) (3 points) Expliquez précisément comment vous procéderiez pour utiliser un échantillonnage par grappes.
- (b) (5 points) Proposez une stratification et expliquez dans quelle situation elle serait avantageuse.
- (c) (4 points) On vous dit que la distribution de la variable Temps (min) est fortement asymétrique à droite. Devrait-on utiliser la médiane plutôt que la moyenne pour résumer cette variable ? **Expliquez.**
- (d) (3 points) De quel type est la variable Mode de transport ?
- (e) (3 points) Votre collègue propose de calculer la corrélation entre la variable Quartier et la variable Temps (min). Qu'en pensez-vous ?
- (f) (2 points) Est-il pertinent de calculer le coefficient de variation de la variable Temps (min) ?

Exercice 2 (10 points)

Soit les 15 valeurs suivantes représentant le nombre d'heures d'étude par semaine d'un groupe d'étudiants :

2 4 5 7 8
8 10 10 12 14
15 18 22 30 45

- (a) (3 points) Calculez les quartiles Q_1 , Q_2 (médiane) et Q_3 .
- (b) (3 points) Y a-t-il des valeurs aberrantes selon la règle de $1,5 \times \text{EIQ}$? **Justifiez.**
- (c) (2 points) Quelle est la forme de cette distribution ?
- (d) (2 points) Laquelle de la moyenne ou de la médiane sera la plus grande ?

Exercice 3 (12 points)

Dites si chacun des énoncés suivants est vrai ou faux. *Justifiez brièvement.*

- (a) (2 points) La corrélation de Spearman et la corrélation de Pearson donnent toujours le même résultat.
- (b) (2 points) Si $X_1, \dots, X_n$ sont mesurés en kg, alors la variance est en kg^2 et l'écart-type est en kg.
- (c) (2 points) Dans un échantillonnage probabiliste, tous les individus de la population doivent avoir la même probabilité d'être sélectionnés.
- (d) (2 points) Si je constate que les variables X et Y sont fortement corrélées, il est certain que X cause Y ou que Y cause X .
- (e) (4 points) L'utilisation d'un diagramme en secteurs est toujours appropriée pour représenter les fréquences relatives d'une variable qualitative nominale.

Exercice 4 (10 points)

Un propriétaire de vignoble mesure le rendement (en kg par hectare) de ses 20 parcelles. Voici un résumé des données :

$$\sum_{i=1}^{20} x_i = 160\,000 \quad \text{et} \quad \sum_{i=1}^{20} x_i^2 = 1\,312\,000\,000.$$

- (a) (2 points) Calculez la moyenne échantillonnale.
- (b) (3 points) Calculez la variance échantillonnale (S^2) et l'écart-type échantillonnal (S).

- (c) (2 points) Calculez le coefficient de variation.
- (d) (3 points) Le vignoble voisin a un rendement moyen de 7 500 kg/ha avec un écart-type de 1 500 kg/ha. Lequel des deux vignobles présente la plus grande variabilité relative ?

Exercice 5 (9 points)

On interroge 1 000 résidents d'une ville sur leur satisfaction envers les transports en commun. On obtient 600 réponses.

- (a) (3 points) Le taux de non-réponse est de 40%. La non-réponse induit-elle nécessairement un biais ? **Expliquez.**
- (b) (3 points) Parmi les répondants, on souhaite comparer la satisfaction entre les 6 quartiers de la ville. Quel outil graphique serait approprié ?
- (c) (3 points) Un collègue affirme que l'utilisation de la liste téléphonique comme base de sondage est problématique. Donnez deux raisons.

Exercice 6 (10 points)

Soit les données de concentration d'un polluant (en ppm) mesurées dans 12 échantillons d'eau :

3, 5, 6, 7, 7, 8, 9, 10, 12, 15, 22, 35.

- (a) (3 points) Calculez les quartiles et l'étendue interquartile.
- (b) (3 points) Identifiez les valeurs aberrantes selon la règle de $1,5 \times \text{EIQ}$.
- (c) (2 points) Quelle est la forme de cette distribution ?
- (d) (2 points) La loi normale modélise-t-elle bien ces données ? **Expliquez.**

Exercice 7 (9 points)

Une population de 10 000 employés est répartie dans 4 usines. L'usine A compte 4 000 employés, l'usine B en compte 3 000, l'usine C en compte 2 000 et l'usine D en compte 1 000. Vous devez interroger 200 employés.

- (a) (3 points) Proposez un échantillonnage stratifié proportionnel. Combien d'employés devez-vous sélectionner dans chaque usine ?
- (b) (3 points) Décrivez comment faire un échantillonnage systématique.
- (c) (3 points) Vous constatez que l'usine D a le plus grand taux d'absentéisme. Pouvez-vous conclure que travailler à l'usine D cause un taux d'absentéisme plus élevé ? **Expliquez.**

Exercice 8 (7 points)

Dites de quel type est chacune des variables suivantes.

- (a) (1 point) Le nombre d'enfants dans un ménage.
- (b) (1 point) La couleur des yeux.
- (c) (1 point) Le niveau de satisfaction (Très insatisfait, Insatisfait, Neutre, Satisfait, Très satisfait).
- (d) (1 point) La température en degrés Celsius.
- (e) (1 point) Le revenu annuel en dollars.
- (f) (2 points) Pour laquelle de ces variables est-il **inapproprié** de calculer le coefficient de variation ? **Expliquez.**

Exercice 9 (7 points)

On considère deux populations d'étudiants dont les notes à un examen sont :

- Population A : 55, 60, 65, 70, 75, 80, 85
- Population B : 40, 50, 60, 70, 80, 90, 100

- (a) (2 points) Calculez la médiane de chaque population.
- (b) (2 points) Sans calculer, quelle population a la plus grande variance ? **Expliquez.**
- (c) (3 points) Les deux populations ont la même médiane. Un étudiant affirme qu'elles ont donc la même distribution. A-t-il raison ? **Expliquez.**

Variables aléatoires

Exercice 10 (9 points)

Soit la variable aléatoire X dont la fonction de probabilité est donnée par :

x	0	3	5
$P(X=x)$	0,2	0,5	0,3

- (a) (3 points) Calculez $E(X)$.
- (b) (3 points) Calculez $V(X)$.
- (c) (3 points) Soit $Y = 2X - 4$. Calculez $E(Y)$ et $V(Y)$.

Exercice 11 (9 points)

Soit X et Y , deux variables aléatoires indépendantes avec $E(X) = 5$, $V(X) = 4$, $E(Y) = 2$ et $V(Y) = 9$.

- (a) (3 points) Calculez $E(3X + 2Y - 7)$.
 (b) (3 points) Calculez $V(3X + 2Y - 7)$.
 (c) (3 points) Calculez $V(X - Y)$.

Exercice 12 (10 points)

Soit les variables aléatoires X et Y dont la fonction de probabilité conjointe est donnée par :

$p(x,y)$		y		
		0	1	2
x	1	$\frac{2}{20}$	$\frac{3}{20}$	a
	3	$\frac{4}{20}$	b	$\frac{1}{20}$
	5	$\frac{1}{20}$	$\frac{2}{20}$	$\frac{3}{20}$

On sait que $P(X = 1) = \frac{7}{20}$ et $P(Y = 1) = \frac{6}{20}$.

- (a) (3 points) Que valent a et b ?
 (b) (4 points) Est-ce que X et Y sont indépendantes ? *Justifiez.*
 (c) (3 points) Calculez $P(Y = 2 | X = 3)$.

Exercice 13 (0 points)

Parmi les expressions suivantes, cochez celles qui sont des expressions valides de la variance pour une variable aléatoire X .

- ☐ $V(X) = E[(X - \mu)^2]$
☐ $V(X) = E(X^2) - [E(X)]^2$
☐ $V(X) = E(X) - E(X)^2$
☐ $V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dx$
☐ $V(X) = \sum_{\mathbb{R}_X} (x - \mu)^2$

Exercice 14 (8 points)

Soit la variable aléatoire X avec la fonction de probabilité suivante :

x	-2	0	1	4
$P(X = x)$	0,1	0,3	0,4	0,2

- (a) (2 points) Calculez $E(X)$.
 (b) (3 points) Calculez $E(X^2)$ et $V(X)$.
 (c) (3 points) Calculez $E(3X^2 - 2X + 5)$.

Exercice 15 (6 points)

Soit X_1, X_2, X_3 trois variables aléatoires indépendantes et identiquement distribuées avec $E(X_i) = 10$ et $V(X_i) = 6$.

- (a) (3 points) Calculez $E(\bar{X})$ et $V(\bar{X})$.
 (b) (3 points) Calculez $V(X_1 - X_2 + 2X_3)$.

Exercice 16 (8 points)

Soit X une variable aléatoire dont la fonction de probabilité est :

x	1	2	3
$P(X = x)$	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{3}{6}$

- (a) (2 points) Calculez $E(X)$.
 (b) (3 points) Calculez $V(X)$.
 (c) (3 points) L'espérance de X est-elle un résultat possible de X ? Est-ce problématique ?

Exercice 17 (8 points)

Soit X et Y deux variables aléatoires. On sait que $E(X) = 3$, $E(Y) = 7$, $V(X) = 2$, $V(Y) = 5$ et $\text{Cov}(X, Y) = -1$.

- (a) (3 points) Calculez $V(X + Y)$.
 (b) (3 points) Calculez $V(2X - 3Y + 1)$.
 (c) (2 points) X et Y sont-ils indépendants ? *Justifiez.*

Exercice 18 (7 points)

Soit (X, Y) un couple de variables aléatoires dont la fonction de probabilité conjointe est :

$p(x,y)$	y	
	0	1
x		
0	$1/4$	$1/4$
1	$1/4$	$1/4$

- (a) (2 points) Calculez les lois marginales de X et de Y .
 (b) (3 points) X et Y sont-elles indépendantes ? **Justifiez.**
 (c) (2 points) Calculez $\text{Cov}(X,Y)$.

Exercice 19 (0 points)

L'espérance d'une variable aléatoire est invariante par translation, mais sa variance n'est pas invariante par translation.

☐ Vrai ☐ Faux

Intervalles de confiance

Exercice 20 (15 points)

Dites si chacun des énoncés suivants est vrai ou faux.

- (a) (3 points) L'intervalle de confiance pour la variance n'est pas symétrique autour de S^2 .
☐ Vrai ☐ Faux
 (b) (3 points) L'intervalle de confiance pour μ est symétrique autour de μ .
☐ Vrai ☐ Faux
 (c) (3 points) Si un intervalle de confiance à 95% pour μ est $[12,34; 17,10]$, alors $\bar{x} = 14,72$.
☐ Vrai ☐ Faux
 (d) (3 points) Plus un intervalle de confiance est large, plus il est précis.
☐ Vrai ☐ Faux
 (e) (3 points) Toutes choses étant égales par ailleurs, un intervalle de confiance construit avec la variance connue (et $\sigma^2 = s^2$) est plus court qu'un intervalle construit avec la variance inconnue.
☐ Vrai ☐ Faux

Exercice 21 (8 points)

Soit un échantillon de taille $n = 16$ provenant d'une variable aléatoire normale d'espérance μ et de variance $\sigma^2 = 4$. La moyenne échantillonnale est $\bar{x} = 25$.

- (a) (5 points) Construisez un intervalle de confiance de niveau 95% pour μ .
 (b) (3 points) Comment l'intervalle changerait-il si σ^2 était inconnue mais que $s^2 = 4$?

Exercice 22 (0 points)

Sachant que $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ et $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$, montrez que l'intervalle de confiance de niveau $1 - \alpha$ pour σ^2 est

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2}; \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2} \right].$$

Exercice 23 (11 points)

Soit un échantillon de taille $n = 25$ provenant d'une loi normale avec $\bar{x} = 50$ et $s^2 = 16$.

- (a) (4 points) Construisez un intervalle de confiance de niveau 90% pour μ .
 (b) (4 points) Construisez un intervalle de confiance de niveau 95% pour σ^2 .
 (c) (3 points) L'intervalle pour σ^2 est-il symétrique autour de $s^2 = 16$? **Expliquez.**

Exercice 24 (9 points)

On veut estimer la proportion p d'étudiants favorables à un changement d'horaire. Sur 400 étudiants interrogés, 240 sont favorables.

- (a) (3 points) Calculez un intervalle de confiance de niveau 95% pour p .
 (b) (3 points) Peut-on affirmer au seuil de 5% que la majorité des étudiants sont favorables ?
 (c) (3 points) Quelle taille d'échantillon faudrait-il pour que la marge d'erreur soit au plus de 2% avec un niveau de confiance de 95% ?

Exercice 25 (9 points)

On souhaite construire un IC de niveau 99% pour la moyenne μ avec un échantillon de taille $n = 10$ provenant d'une loi normale.

- (a) (3 points) Si σ^2 est connue, quelle loi utilise-t-on pour le quantile ?
 (b) (3 points) Si σ^2 est inconnue, quelle loi utilise-t-on ?
 (c) (3 points) L'intervalle avec σ^2 inconnue est-il plus long ou plus court ? Pourquoi ?

Exercice 26 (0 points)

Cochez le ou les énoncés qui sont vrais.

- ☐ La probabilité que μ soit dans l'intervalle de confiance est $1 - \alpha$.
☐ Avant d'observer les données, la probabilité que l'intervalle aléatoire $[L; U]$ contienne μ est $1 - \alpha$.
☐ Augmenter α augmente la longueur de l'intervalle.
☐ Augmenter n diminue la longueur de l'intervalle (toutes choses étant égales par ailleurs).
☐ Un IC de 99% est plus précis qu'un IC de 95%.

Exercice 27 (7 points)

Un échantillon de $n = 36$ pièces usinées a un diamètre moyen de $\bar{x} = 5,02$ mm et un écart-type $s = 0,10$ mm. La spécification est $\mu_0 = 5,00$ mm.

- (a) (4 points) Construisez un intervalle de confiance de niveau 95% pour μ .
 (b) (3 points) La valeur $\mu_0 = 5,00$ fait-elle partie de l'IC ? Qu'est-ce que cela implique pour un test $H_0 : \mu = 5$ contre $H_1 : \mu \neq 5$ au seuil de 5% ?

Exercice 28 (0 points)

Expliquez pourquoi augmenter le niveau de confiance de 95% à 99% n'est pas toujours souhaitable.

Tests d'hypothèses

Exercice 29 (6 points)

Cochez l'énoncé qui décrit correctement chaque type d'erreur.

- (a) (3 points) L'erreur de type I est :

- ☐ La probabilité de ne pas rejeter H_0 alors que H_0 est fausse.
☐ La probabilité de rejeter H_0 alors que H_0 est vraie.
☐ La décision de rejeter H_0 alors que H_0 est vraie.
☐ La décision de ne pas rejeter H_0 alors que H_0 est fausse.

- (b) (3 points) L'erreur de type II est :

- ☐ La probabilité de ne pas rejeter H_0 alors que H_0 est fausse.
☐ La probabilité de rejeter H_0 alors que H_0 est vraie.
☐ La décision de rejeter H_0 alors que H_0 est vraie.
☐ La décision de ne pas rejeter H_0 alors que H_0 est fausse.

Exercice 30 (12 points)

Vous faites un test sur 25 observations pour confronter les hypothèses $H_0 : \mu = 10$ et $H_1 : \mu > 10$. Vous obtenez un seuil observé (valeur-p) de 0,03.

- (a) (3 points) Quelle est la décision du test au seuil de 5% ?
 (b) (3 points) Quelle est la décision du test au seuil de 1% ?
 (c) (3 points) La moyenne échantillonnale est-elle supérieure ou inférieure à 10 ?
 (d) (3 points) Vous refaites l'expérience avec 50 observations et obtenez la même moyenne échantillonnale. Le seuil observé sera-t-il plus petit ou plus grand que 0,03 ?

Exercice 31 (0 points)

Cochez l'énoncé qui est vrai.

- ☐ Si $\hat{\theta}$ est un estimateur sans biais pour θ , la valeur calculée de $\hat{\theta}$ à partir d'un échantillon sera toujours très proche de θ .
☐ Toutes choses étant égales par ailleurs, pour passer d'un IC de 95% à un IC de 99%, il suffit d'augmenter n .
☐ L'erreur quadratique moyenne d'un estimateur sans biais est égale à sa variance au carré.
☐ Dans un test au seuil α , quand H_0 est vraie, la probabilité de ne pas commettre d'erreur est $1 - \alpha$.

Exercice 32 (15 points)

Soit un échantillon provenant d'une variable aléatoire normale d'espérance μ et de variance $\sigma^2 = 1,44$:

4, 5, 5, 6, 6, 6, 7, 7, 8,

pour lequel $\sum_{i=1}^9 x_i = 54$ et $\sum_{i=1}^9 x_i^2 = 336$.

(a) On souhaite faire un test d'hypothèses unilatéral à droite de seuil 5% avec $H_0 : \mu = 5,5$.

i. (2 points) Quelle est l'hypothèse alternative ?

ii. (3 points) Quelle est la valeur critique du test ?

iii. (5 points) Calculez la statistique de test et prenez une décision.

(b) (5 points) Construisez un intervalle de confiance de niveau 95% pour μ .

Exercice 33 (0 points)

La loi de Student de $n - 1$ degrés de liberté a une espérance égale à 0.

☐ Vrai ☐ Faux

Exercice 34 (0 points)

Soit $X \sim \text{Bin}(n; \theta)$. On teste $H_0 : \theta = 0,5$ contre $H_1 : \theta > 0,5$. La règle de décision est de rejeter H_0 si $X = n$ (c'est-à-dire aucun échec). Trouvez la plus petite valeur de n telle que $\alpha \leq 0,05$.

Exercice 35 (9 points)

Vous testez $H_0 : \mu = 100$ contre $H_1 : \mu \neq 100$ au seuil de 5% avec un échantillon de taille $n = 20$ provenant d'une loi normale de variance inconnue. Vous obtenez $\bar{x} = 103$ et $s = 6$.

(a) (3 points) Calculez la statistique de test.

(b) (3 points) Quelle est la décision du test ?

(c) (3 points) La valeur-p est-elle inférieure ou supérieure à 5% ?

Exercice 36 (8 points)

On teste $H_0 : \mu = 50$ contre $H_1 : \mu < 50$ avec $n = 15$, $\bar{x} = 47$, $s = 5$ et σ^2 inconnue.

(a) (2 points) Quelle est la statistique de test ?

(b) (3 points) Prenez votre décision au seuil de 5%.

(c) (3 points) L'intervalle de confiance de niveau 90% pour μ contient-il la valeur 50 ? **Expliquez.**

Exercice 37 (9 points)

Dites si chacun des énoncés suivants est vrai ou faux. *Justifiez brièvement.*

(a) (3 points) Si la valeur-p est de 0,001, cela signifie qu'il y a 0,1% de chances que H_0 soit vraie.

☐ Vrai ☐ Faux

(b) (3 points) Si on ne rejette pas H_0 , cela signifie que H_0 est vraie.

☐ Vrai ☐ Faux

(c) (3 points) Augmenter la taille d'échantillon n diminue la probabilité de commettre une erreur de type II.

☐ Vrai ☐ Faux

Exercice 38 (9 points)

Vous faites un test avec $n = 50$ observations. La valeur-p est de 0,046.

(a) (2 points) Votre décision au seuil de 5% : _____

(b) (2 points) Votre décision au seuil de 1% : _____

(c) (2 points) Votre décision au seuil de 10% : _____

(d) (3 points) Un collègue obtient une valeur-p de 0,046 et dit que son résultat est «très significatif». Commentez.

Régression linéaire simple**Exercice 39** (6 points)

Dans un modèle de régression linéaire simple $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$:

(a) (3 points) Si $\beta_0 = 0$, quel est l'interprétation de β_1 ?

(b) (3 points) Pour faire de l'inférence sur β_1 , quelles hypothèses doit-on supposer ?

☐ Les Y_i sont des variables aléatoires normales indépendantes d'espérance nulle et de variance constante.

☐ Les ϵ_i sont des variables aléatoires normales indépendantes d'espérance nulle et de variance constante.

☐ X doit suivre une loi normale.

☐ Toutes les valeurs de X doivent être distinctes.

Exercice 40 (3 points)

D'au moins combien de paires d'observations avons-nous besoin pour pouvoir utiliser chacune des méthodes suivantes ?

(a) (1 point) Méthode de Mayer

☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

(b) (1 point) Méthode Med-Med


☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

(c) (1 point) Méthode des moindres carrés (estimation et inférence incluses)

☐ 0 ☐ 1 ☐ 2 ☐ 3 ☐ 4+

Exercice 41 (26 points)

Soit le graphique suivant qui représente les observations $(x_1, y_1), \dots, (x_8, y_8)$.



(a) (3 points) Estimez la droite de régression avec la méthode de Mayer.

(b) (3 points) Estimez la droite de régression avec la méthode Med-Med.

(c) (5 points) En utilisant les informations suivantes, estimez la droite par les moindres carrés :

$$\sum_{i=1}^8 x_i = 36$$

$$\sum_{i=1}^8 x_i^2 = 204$$

$$\sum_{i=1}^8 y_i = 36$$

$$\sum_{i=1}^8 x_i y_i = 199$$

(d) (4 points) En utilisant la droite estimée en c), complétez le tableau suivant.

x_i	y_i	$\hat{y}_i$	$\hat{\epsilon}_i$
1	1		
2	3		
3	2		
4	4		
5	5		
6	6		
7	7		
8	8		

- (e) (4 points) Calculez MSE .
- (f) (4 points) Donnez l'intervalle de confiance à 95% pour β_1 .
- (g) (3 points) Donnez une interprétation de l'intervalle de confiance.

Exercice 42 (4 points)

Soit l'intervalle de confiance de niveau 95% pour $\beta_1 : [1,3; 4,7]$.

- (a) (1 point) $\hat{\beta}_1 = 3,0$.
☐ Vrai ☐ Faux
- (b) (1 point) On rejette $H_0 : \beta_1 = 0$ au profit de $H_1 : \beta_1 \neq 0$ au seuil de 5%.
☐ Vrai ☐ Faux
- (c) (1 point) On rejette $H_0 : \beta_1 = 0$ au profit de $H_1 : \beta_1 \neq 0$ au seuil de 10%.
☐ Vrai ☐ Faux
- (d) (1 point) On rejette $H_0 : \beta_1 = 2$ au profit de $H_1 : \beta_1 \neq 2$ au seuil de 5%.
☐ Vrai ☐ Faux

Exercice 43 (12 points)

On ajuste un modèle de régression linéaire simple à $n = 12$ observations et on obtient $\hat{\beta}_0 = 2,5$, $\hat{\beta}_1 = 1,8$ et $MSE = 3,6$.

- (a) (3 points) Donnez la valeur prédite $\hat{y}$ lorsque $x = 5$.
- (b) (3 points) Calculez le résidu si l'observation correspondante est $y = 13$.
- (c) (3 points) Que vaut SSE (somme des carrés des résidus) ?
- (d) (3 points) Interprétez la valeur $\hat{\beta}_1 = 1,8$ dans le contexte de la régression.

Exercice 44 (9 points)

On dispose de $n = 20$ paires d'observations. Le coefficient de détermination est $R^2 = 0,85$.

- (a) (3 points) Interprétez $R^2 = 0,85$.
- (b) (3 points) Quelle est la valeur de la corrélation linéaire r si la pente $\hat{\beta}_1$ est positive ?
- (c) (3 points) Si $SST = 200$, que vaut SSE ?

Exercice 45 (11 points)

On ajuste un modèle de régression linéaire simple avec $n = 15$ observations. On obtient $\hat{\beta}_1 = 0,75$, $S_{xx} = 40$ et $MSE = 2,5$.

- (a) (4 points) Calculez l'erreur-type de $\hat{\beta}_1$.
- (b) (4 points) Testez $H_0 : \beta_1 = 0$ contre $H_1 : \beta_1 \neq 0$ au seuil de 5%.
- (c) (3 points) Construisez un IC à 95% pour β_1 .

Exercice 46 (10 points)

Dites si chacun des énoncés suivants est vrai ou faux.

- (a) (2 points) $\hat{\beta}_0$ représente toujours la valeur de Y quand $X = 0$.
☐ Vrai ☐ Faux
- (b) (2 points) La somme des résidus dans une régression par moindres carrés est toujours nulle.
☐ Vrai ☐ Faux
- (c) (2 points) Si R^2 est proche de 1, cela prouve que la relation entre X et Y est causale.
☐ Vrai ☐ Faux
- (d) (2 points) La méthode de Mayer est plus robuste aux valeurs aberrantes que les moindres carrés.
☐ Vrai ☐ Faux

- (e) (2 points) Pour la méthode des moindres carrés, on minimise $\sum_{i=1}^n |\hat{\epsilon}_i|$.

☐ Vrai ☐ Faux

Exercice 47 (8 points)

Avec $n = 30$, on effectue un test pour confronter $H_0 : \beta_1 = 0$ et $H_1 : \beta_1 \neq 0$.

- (a) (2 points) Sous H_0 , quelle loi suit la statistique de test ?
- (b) (3 points) On obtient $t_{obs} = 2,8$. La valeur critique au seuil de 5% est $t_{0,025;28} = 2,048$. Quelle est la décision ?
- (c) (3 points) Le même test est-il significatif au seuil de 1% ? ($t_{0,005;28} = 2,763$)

Association entre variables catégoriques

Exercice 48 (0 points)

La statistique du khi-carré pour tester l'indépendance compare :

- ☐ Les lois marginales entre elles
- ☐ Les fréquences observées aux fréquences attendues
- ☐ Les moyennes conditionnelles
- ☐ La variance de Y pour chaque valeur de X

Exercice 49 (9 points)

Un chercheur veut savoir si le choix de boisson chaude est associé à la saison. Il obtient le tableau suivant auprès de 200 personnes :

Saison \ Boisson	Hiver	Été	Automne
Café	40	30	25
Thé	20	35	15
Chocolat chaud	25	5	5

- (a) (4 points) Calculez les fréquences attendues sous l'hypothèse d'indépendance.
 (b) (5 points) Effectuez le test d'indépendance au seuil de 5%.

Exercice 50 (10 points)

Un hôpital examine si le groupe sanguin (A, B, AB, O) est associé à la présence d'une certaine complication post-opératoire (Oui/Non). On observe 200 patients :

Complic. \ Groupe	Oui	Non
A	15	55
B	10	30
AB	5	15
O	20	50

- (a) (3 points) Combien de degrés de liberté a le test du khi-carré pour ce problème ?
 (b) (4 points) Calculez les fréquences attendues pour la première ligne (groupe A).
 (c) (3 points) Quelles sont les hypothèses du test ?

Exercice 51 (9 points)

On observe 300 individus et on s'intéresse à la relation entre le statut tabagique (Fumeur, Non-fumeur) et la pratique d'activité physique (Active, Inactive).

Sport \ Tabac	Active	Inactive
Fumeur	30	70
Non-fumeur	120	80

- (a) (4 points) Calculez les fréquences attendues sous H_0 d'indépendance.

(b) (5 points) Effectuez le test du χ^2 au seuil de 5%.

Exercice 52 (8 points)

Pour un test d'indépendance du khi-carré, dites si les énoncés suivants sont vrais ou faux.

(a) (2 points) Le test du χ^2 mesure la force de l'association entre deux variables.

☐ Vrai ☐ Faux

(b) (2 points) Les fréquences attendues doivent toutes être supérieures à 5 pour que le test soit valide.

☐ Vrai ☐ Faux

(c) (2 points) H_0 dans le test du χ^2 d'indépendance est que les proportions marginales sont égales.

☐ Vrai ☐ Faux

(d) (2 points) Le test du χ^2 ne peut pas être unilatéral.

☐ Vrai ☐ Faux

Exercice 53 (5 points)

On étudie la relation entre le type de logement (Appartement, Maison, Condo) et la possession d'un animal (Oui, Non) chez 150 personnes. On obtient $\chi^2_{obs} = 3,2$.

(a) (2 points) Combien de degrés de liberté a le test ?

(b) (3 points) Prenez une décision au seuil de 5% sachant que $\chi^2_{0,05;2} = 5,991$.

Exercice 54 (9 points)

On observe le tableau de contingence suivant chez $n = 120$ étudiants :

Moyen \ Niveau	Bus	Vélo	Auto
Bacc.	20	15	25
Maîtrise	12	18	10
Doctorat	8	7	5

(a) (4 points) Calculez toutes les fréquences attendues.

(b) (5 points) Calculez χ^2_{obs} et prenez une décision au seuil de 5%.

Exercice 55 (7 points)

On vous donne la formule de la statistique du khi-carré :

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

(a) (2 points) Que représentent O_{ij} et E_{ij} ?

(b) (2 points) Que se passe-t-il si $O_{ij} = E_{ij}$ pour toutes les cellules ?

(c) (3 points) Comment calcule-t-on E_{ij} ?

Exercice 56 (8 points)

On observe 400 personnes à qui on demande leur couleur préférée (Rouge, Bleu, Vert) et leur saison préférée (Hiver, Été). On obtient $\chi^2_{obs} = 12,4$.

(a) (2 points) Quels sont les degrés de liberté ?

(b) (3 points) Prenez une décision au seuil de 1% sachant que $\chi^2_{0,01;2} = 9,210$.

(c) (3 points) La valeur-p est-elle inférieure à 5% ? à 1% ?

Exercices supplémentaires

Exercice 57 (11 points)

Soit $X_1, \dots, X_m$ des variables aléatoires iid d'une loi Bernoulli de paramètre p , c'est-à-dire $P(X_i = 1) = p$ et $P(X_i = 0) = 1 - p$. On sait que $E(X_i) = p$ et $V(X_i) = p(1 - p)$. L'estimateur naturel de p est $\hat{p} = \bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$.

(a) (3 points) Montrez que $\hat{p}$ est un estimateur sans biais pour p .

(b) (4 points) Calculez la variance de $\hat{p}$.

(c) (4 points) Quelle est la longueur maximale de la marge d'erreur d'un intervalle de confiance à 95% pour p lorsque $m = 100$?

Exercice 58 (0 points)

Soit deux échantillons indépendants $X_1, \dots, X_n \sim \mathcal{N}(\mu_X, \sigma_X^2)$ et $Y_1, \dots, Y_m \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$. On sait que

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n-1; m-1}.$$

Donnez un intervalle de confiance de niveau $1 - \alpha$ pour le ratio $\frac{\sigma_Y^2}{\sigma_X^2}$.

Exercice 59 (10 points)

Soit $X_1, \dots, X_n$ un échantillon aléatoire simple d'une loi de moyenne μ et de variance σ^2 . On considère l'estimateur $\hat{\mu} = \alpha X_1 + (1 - \alpha)\bar{X}$ où $\alpha \in [0, 1]$ est une constante et $\bar{X}$ est la moyenne échantillonnale.

(a) (3 points) Montrez que $\hat{\mu}$ est un estimateur sans biais pour μ .

(b) (4 points) Calculez $V(\hat{\mu})$ en supposant que $n \geq 2$.

(c) (3 points) Pour quelle valeur de α la variance est-elle minimale ? Interprétez.

Exercice 60 (10 points)

L'erreur quadratique moyenne (EQM) d'un estimateur $\hat{\theta}$ pour θ est définie par $\text{EQM}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$.

(a) (3 points) Montrez que $\text{EQM}(\hat{\theta}) = V(\hat{\theta}) + [\text{biais}(\hat{\theta})]^2$.

(b) (4 points) Soit $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$. On considère l'estimateur $\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$. On sait que $E(\tilde{\sigma}^2) = \frac{n-1}{n} \sigma^2$ et $V(\tilde{\sigma}^2) = \frac{2(n-1)}{n^2} \sigma^4$. Calculez l'EQM de $\tilde{\sigma}^2$.

(c) (3 points) Comparez avec l'estimateur sans biais $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ dont on sait que $V(S^2) = \frac{2\sigma^4}{n-1}$. Lequel a la plus petite EQM ?

Exercice 61 (10 points)

Soit $X \sim \mathcal{N}(100, 25)$. Un échantillon de taille $n = 50$ est prélevé.

(a) (3 points) En utilisant le théorème central limite, donnez la distribution approximative de $\bar{X}$.

(b) (4 points) Calculez $P(\bar{X} > 101)$.

(c) (3 points) On observe $\bar{x} = 101,2$ et $s = 5,3$. Construisez un intervalle de confiance à 95% pour μ .

Exercice 62 (10 points)

Un sondage est effectué auprès de $n = 600$ personnes pour connaître la proportion p de gens favorables à une nouvelle politique. On obtient $\hat{p} = 0,52$.

(a) (3 points) Construisez un intervalle de confiance à 95% pour p .

(b) (4 points) Peut-on conclure que plus de la moitié de la population est favorable ? Effectuez un test au seuil $\alpha = 0,05$.

(c) (3 points) Quelle taille d'échantillon minimale faudrait-il pour que la marge d'erreur soit au plus de 2% à 95% de confiance ?

Exercice 63 (13 points)

Un chercheur mesure la résistance Y (en MPa) d'un matériau en fonction de la température X (en °C). À partir de $n = 15$ observations, il obtient :

$$\sum x_i = 750, \quad \sum y_i = 300, \quad \sum x_i^2 = 42\,500, \quad \sum x_i y_i = 13\,500, \quad \sum y_i^2 = 6\,500.$$

(a) (3 points) Calculez $\bar{x}$, $\bar{y}$, S_{xx} , S_{xy} et S_{yy} .

(b) (3 points) Estimez $\hat{\beta}_1$ et $\hat{\beta}_0$. Interprétez $\hat{\beta}_1$.

(c) (3 points) Calculez R^2 et interprétez.

(d) (4 points) Testez $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$ au seuil $\alpha = 0,05$.

Exercice 64 (10 points)

Vrai ou faux. Justifiez chaque réponse.

(a) (2 points) Si un estimateur $\hat{\theta}$ est sans biais et consistant, alors son EQM tend vers 0 lorsque $n \rightarrow \infty$.

(b) (2 points) La distribution de Student converge vers la loi normale lorsque $n \rightarrow \infty$.

(c) (2 points) Si le coefficient de détermination R^2 est élevé, cela prouve un lien de causalité entre X et Y .

(d) (2 points) Le théorème central limite s'applique uniquement lorsque la population suit une loi normale.

(e) (2 points) Dans un test bilatéral, la valeur-p est toujours le double de la valeur-p du test unilatéral correspondant.

Exercice 65 (10 points)

On effectue un contrôle de qualité dans une usine. En temps normal, le poids des pièces suit une loi $\mathcal{N}(500, 16)$ (en grammes). On prélève un échantillon de $n = 25$ pièces et on obtient $\bar{x} = 497,5$ et $s^2 = 20$.

- (a) (3 points) Testez si le poids moyen a changé au seuil $\alpha = 0,05$.
- (b) (3 points) Construisez un IC à 95% pour μ en utilisant $\sigma^2 = 16$.
- (c) (4 points) Testez si la variance a augmenté au seuil $\alpha = 0,05$ en utilisant la loi khi-deux.

Exercice 66 (10 points)

Soit X et Y deux variables aléatoires discrètes avec la distribution conjointe suivante :

$X \backslash Y$	0	1	2	Total
0	0,10	0,15	0,05	0,30
1	0,20	a	0,10	
2	0,05	0,10	b	
Total				1

- (a) (3 points) Trouvez les valeurs de a et b .
- (b) (4 points) Avec $a = 0,15$ et $b = 0,10$, calculez $E(X)$, $E(Y)$ et $\text{Cov}(X, Y)$.
- (c) (3 points) X et Y sont-elles indépendantes ?