

STT-2902

Modélisation statistique

Notes de cours rédigées par
Anne-Sophie CHAREST

avec certaines sections basées sur un document de
Emmanuelle RENY-NOLIN

Document mis à jour en juillet 2024

Département de mathématiques et de statistique



Table des matières

Préface	1
Introduction	2
1 Collecte des données	5
1.1 Sondage	7
1.1.1 Échantillonnage probabiliste	8
1.1.2 Échantillonnage aléatoire simple (ÉAS)	9
1.1.3 Échantillonnage systématique	10
1.1.4 Échantillonnage en grappes	11
1.1.5 Échantillonnage stratifié	13
1.1.6 Méthodes plus complexes d'échantillonnage probabiliste . .	15
1.1.7 Impact des probabilités de sélection	17
1.1.8 Méthodes d'échantillonnage non probabiliste	18
1.1.9 Cas particulier : recensement	19
1.1.10 Erreur d'échantillonnage	19
1.2 Expérience	20
1.2.1 Association versus causalité	20
1.2.2 Expérience (randomisée)	21
1.2.3 Planifier une expérience	22
1.2.4 Limites	23
1.3 Sources de biais	25
1.3.1 Erreur de couverture	26
1.3.2 Erreur de mesure	27
1.3.3 Erreur de non-réponse	28
2 Statistiques descriptives	32
2.1 Types de variables	32
2.1.1 Variables catégoriques (ou qualitatives)	33
2.1.2 Variables numériques (ou quantitatives)	33
2.2 Résumés numériques pour une variable catégorique ou numérique discrète	34
2.2.1 Fréquences	34
2.2.2 Mode	34
2.3 Résumés numériques pour une variable numérique	35
2.3.1 Mesures de localisation	36
2.3.2 Mesures de variabilité	42

2.3.3	Mesures de forme	50
2.4	Résumés numériques pour deux variables	52
2.4.1	Deux variables catégoriques ou numériques discrètes	53
2.4.2	Une variable catégorique et une variable numérique	56
2.4.3	Deux variables numériques	57
2.5	Représentations graphiques - principes généraux	60
2.6	Représentations graphiques pour une variable	62
2.6.1	Une variable catégorique ou numérique discrète	62
2.6.2	Une variable numérique	66
2.7	Représentations graphiques illustrant le lien entre des variables	73
2.7.1	Deux variables catégoriques ou numériques discrètes	73
2.7.2	Une variable catégorique et une variable numérique	78
2.7.3	Deux variables numériques	80
2.7.4	Trois variables et plus	82
2.8	Statistiques trompeuses ?	85
2.9	Effet des probabilités de sélection inégales	86
3	Inférence	93
3.1	Rappel de quelques définitions et résultats	93
3.1.1	Espérance	93
3.1.2	Variance	94
3.1.3	La loi binomiale	95
3.1.4	La loi normale et ses propriétés	96
3.1.5	Le théorème central limite	97
3.2	Estimation de paramètres	98
3.2.1	Qualité d'un estimateur	98
3.3	Intervalles de confiance	101
3.3.1	Définition	101
3.3.2	Interprétation	102
3.3.3	Quelques intervalles de confiance connus	102
3.3.4	Utilisation en pratique	106
3.3.5	Contrôler la marge d'erreur	107
3.4	Tests d'hypothèses	108
3.4.1	Énoncer des hypothèses	109
3.4.2	Choisir une statistique de test	109
3.4.3	Prendre une décision	110
3.4.4	Valeur p (seuil observé)	112
3.4.5	Faire un test d'hypothèse en pratique	113
3.4.6	Quelques résultats connus	117
3.5	Inférence à partir de données de sondage	119
3.5.1	Inférence sur la moyenne pour un ÉAS sans remise	121

3.5.2	Inférence pour l'échantillonnage stratifié	124
3.5.3	Post-stratification	127
4	Régression linéaire simple	132
4.1	Covariance et corrélation	133
4.1.1	Covariance théorique	133
4.1.2	Covariance échantillonnale	133
4.1.3	Corrélation théorique	134
4.1.4	Corrélation échantillonnale	134
4.2	Contexte et objectifs	135
4.2.1	La régression	135
4.2.2	Régression déterministe ou stochastique	135
4.2.3	Régression linéaire simple	136
4.3	Modèle de régression linéaire simple	137
4.3.1	Interprétation des paramètres	138
4.4	Trois méthodes d'estimation des paramètres	139
4.4.1	Méthode de Mayer	139
4.4.2	Méthode médiane-médiane (Med-Med)	142
4.4.3	Méthode des moindres carrés	144
4.4.4	Comparaison des trois méthodes	148
4.5	Inférence - méthode des moindres carrés	151
4.5.1	Conditions pour l'inférence	151
4.5.2	Inférence sur les paramètres β_0 et β_1	152
4.5.3	Prévision à partir de la droite estimée	154
4.5.4	Anova pour la RLS	156
4.5.5	Exemple d'inférence pour la régression linéaire simple	158
4.5.6	Validation des conditions nécessaires à l'inférence	162
5	Inférence sur l'association entre deux variables catégoriques	172
5.1	Rappels concernant deux variables catégoriques	172
5.1.1	Loi conjointe	172
5.1.2	Lois marginales	174
5.1.3	Lois conditionnelles	175
5.1.4	Indépendance de deux variables catégoriques	176
5.2	Test d'indépendance à partir d'observations	177
5.2.1	Tableau de contingence (tableau de fréquences)	177
5.2.2	Test statistique	178
	Bibliographie	183
A	Preuve de l'équation 3.9	184

B Tables de lois**186**

Préface

Quelle belle responsabilité que d'enseigner les mathématiques aux jeunes du secondaire ! Je me sens privilégiée de vous accompagner dans votre approfondissement de la statistique, confiante que vous pourrez ensuite partager à votre tour vos connaissances avec vos élèves.

Ces notes de cours ont été rédigées spécifiquement pour le cours STT-2902 Modélisation statistique. On y prend pour acquis la réussite préalable du cours STT-1000 Probabilités et statistique, notamment la maîtrise des concepts de probabilités et de variables aléatoires. On prend toutefois le temps de revoir et d'approfondir plusieurs notions de STT-1000, notamment en ce qui concerne l'inférence avec des intervalles de confiance et des tests d'hypothèses.

J'espère que ces notes vous accompagneront comme référence tout au long de votre enseignement. Dans cet optique, je vous invite à les annoter tout au long de la session, de sorte qu'elles vous soient facilement compréhensibles même dans quelques années lorsque vous voudrez vous y référer. J'ai d'ailleurs inclus quelques pages de notes supplémentaires à la fin de chaque chapitre.

Et si le coeur vous en dit, n'hésitez pas à m'écrire avec des questions statistiques, des suggestions pour améliorer la formation initiale en statistique aux enseignants, ou même simplement pour me partager des idées intéressantes que vous avez utilisées dans vos classes. Que ce soit dans quelques mois, quelques années ou une décennie, il me fera toujours plaisir de vous lire et de vous conseiller si possible.

Anne-Sophie
anne-sophie.charest@mat.ulaval.ca

Introduction


La statistique

Qu'est-ce que la statistique ? Il n'y a pas vraiment de consensus sur une définition simple de la statistique en tant que discipline. On la définit parfois comme l'étude de la variabilité, ou de l'incertitude. On passe toutefois alors un peu sous silence les apports de la statistique descriptive. On la décrit d'autres fois à travers les divers champs d'étude de la statistique, notamment la collecte de données, leur traitement et leur analyse et l'interprétation et la présentation des résultats, mais c'est un peu fastidieux.

Voici plutôt une définition courte, mais éloguente, choisie comme titre d'un manuel d'introduction à la statistique¹ : ***Statistics : The Art and Science of Learning from Data.***

Elle indique bien que la statistique, c'est autant une science qu'un ensemble de savoir-faire et que l'objectif de la statistique est toujours d'apprendre quelque chose à partir de données.

C'est de cette façon qu'on pensera la statistique tout au long de ces notes de cours.



1. Agresti, A., Christine A. F., and Bernhard K., Alan T. *Statistics : The Art and Science of Learning from Data*. 4th Edition, Pearson (2017).

Modélisation statistique

Il reste maintenant à définir ce qu'on entend par modélisation statistique. Pour ce faire, il est utile de la distinguer de la modélisation mathématique.

La **modélisation mathématique** est utilisée pour représenter des phénomènes déterministes, dont l'issue est connue avec certitude et sans variation. Par exemple, on peut modéliser l'aire (A) d'une sphère en fonction du rayon (r) de celle-ci à l'aide de la formule $A = 4\pi r^2$. De même, on peut modéliser mathématiquement le coût d'un emprunt selon le montant initial, la durée de l'emprunt et le taux d'intérêt ou encore la position de la lune en fonction du temps.

La **modélisation statistique** permet quant à elle de représenter des phénomènes aléatoires, c'est-à-dire des phénomènes dont l'issue dépend du hasard². On se basera généralement sur des données observées pour identifier le modèle approprié. La modélisation statistique permet aussi de représenter des phénomènes déterministes dont le modèle mathématique est à établir, ou pour lequel le modèle mathématique est trop complexe pour être connu complètement. Ainsi, un modèle statistique est utile pour représenter un jeu de hasard comme la loterie, les crues annuelles d'un fleuve, la durée de vie d'une ampoule ou encore le temps d'attente dans un service téléphonique.

Généralement, un modèle statistique utilise un modèle mathématique (une fonction) dont certains paramètres sont inconnus et lui ajoute une quantité aléatoire pour tenir compte de la partie aléatoire du modèle. Un modèle statistique a donc la forme générale suivante :

Donnée = signal + bruit

Observation = fonction mathématique
aux paramètres inconnus + erreur
aléatoire

L'objectif général sera alors d'utiliser les données observées pour estimer les paramètres inconnus du modèle, ce qui nous permettra de mieux comprendre le phénomène et de faire des prévisions.

Le processus statistique qui permet d'apprendre à partir de données est toutefois plus vaste que la modélisation statistique. On le décrit en détail à la section suivante.

2. Il est intéressant de noter que *hasard* vient de l'arabe *az-zahr* qui veut dire *le dé*.

Processus statistique

On peut diviser la démarche derrière une étude statistique en cinq étapes :

1. Identifier le problème

Formuler une question statistique est une première étape très importante. Cette question doit être très précise, pour qu'on puisse y répondre objectivement à l'aide de la statistique. Par exemple, on ne pourrait pas simplement se demander s'il est mieux d'utiliser le traitement A ou B en cas de cancer du sein. Il faut préciser si on s'intéresse à augmenter les probabilités de guérison, ou bien la survie, ou encore à diminuer les douleurs, etc. On devra également identifier une population cible, en excluant peut-être certains types de cancer, ou encore les individus avec certaines autres maladies.

2. Planifier la collecte de données

Il faut déterminer un mode de collecte de données ou identifier des données déjà collectées qu'on peut utiliser pour répondre à la question. On doit choisir avec soin les détails de la collecte de données, incluant la taille d'échantillon et les instruments de mesure utilisés.

3. Collecter et nettoyer les données

Il s'agit ici d'appliquer exactement le plan de collecte établi. Il est généralement nécessaire de nettoyer les données, pour identifier, corriger ou éliminer les données incomplètes ou incorrectes.

4. Analyser les données

L'analyse des données comprend les analyses descriptives ainsi que toutes les procédures d'inférence statistique, notamment la construction d'intervalles de confiance et de tests d'hypothèses. On doit identifier les outils appropriés pour répondre à la question statistique à l'aide des données collectées, et les utiliser correctement.

5. Conclure

On peut enfin conclure au sujet de la question statistique de départ. La conclusion doit être justifiée à l'aide des résultats obtenus lors de l'analyse des données. Il est aussi important d'inclure des commentaires sur le seuil de signification des tests, la qualité des données et les limites de l'étude.

Les chapitres suivants des notes de cours explorent plus en détails différents aspects de ces étapes.

Chapitre 1

Collecte des données

Les données constituent la matière première de toute analyse statistique. Par conséquent, si on travaille avec des données de mauvaise qualité, on risque fort d'obtenir des résultats de peu de valeur. Voici un exemple célèbre qui illustre ceci. En 1936, la revue américaine *Literary Digest* a procédé à un gigantesque sondage électoral en postant 10 millions de coupons de participation. La revue a reçu 2,3 millions de réponses, dont 57% en faveur du républicain Alf Landon. Pourtant, c'est le démocrate Franklin D. Roosevelt qui a gagné, avec 63% des voix !

Comment le sondage a-t-il pu commettre une erreur de 20 points de pourcentage avec un échantillon si grand ? Les avis sur la question sont partagés¹, mais on sait qu'il y avait deux sources de biais potentielles. D'abord, les individus étaient choisis au hasard parmi des bottins téléphoniques et listes d'immatriculation, ce qui a favorisé la présence d'électeurs aux revenus élevés dans l'échantillon (ceux possédant un téléphone et/ou une automobile en 1936). Il est donc probable que davantage de sympathisants républicains faisaient partie de la base de sondage. De plus, il y a eu un faible taux de réponse. Il est probable que les partisans de Landon aient été plus enclins à répondre que les partisans de Roosevelt.

Notons qu'à la même élection, le statisticien George H. Gallup a réussi à prédire la victoire de Roosevelt avec un échantillon de seulement 50 000 individus ! La collecte des intentions de vote et le calcul de la prédiction étaient alors basés sur des principes d'échantillonnage probabiliste, d'où une estimation plus fiable. Ce succès consacra la crédibilité de l'*American Institute of Public Opinion*. Et Gallup fonda en 1947 la firme *Gallup International*, une pionnière dans la méthodologie des sondages.

1. Voir l'article Lusinchi, D. (2012). "President" Landon and the 1936 Literary Digest Poll : Were Automobile and Telephone Owners to Blame ? *Social Science History*, 36(1), 23-54.

On voit donc qu'il est important de planifier la collecte de données judicieusement pour obtenir des données de qualité, qui permettent de répondre à la question statistique d'intérêt.

On peut distinguer trois méthodes de collecte de données :

1. Faire un sondage

Dans un sondage, on mesure une caractéristique sur un échantillon appartenant à une population plus grande, dans le but d'estimer une caractéristique de la population à l'aide d'un échantillon d'individus de celle-ci.

Ex. : Dans un sondage sur les intentions de vote, on souhaite estimer la proportion des voteurs dans la population qui choisiront un certain candidat, et ce en posant la question à un échantillon de voteurs.

2. Réaliser une expérience (statistique)

Permet de déterminer l'effet causal d'une variable sur une autre variable.

Ex. : Dans un essai clinique pour un nouveau médicament, on souhaite valider l'effet de ce médicament sur la survie des patients.

3. Utiliser des données observationnelles

Il s'agit de tirer profit d'un ensemble de données déjà collectées pour un autre usage, notamment des données administratives.

Ex. : On peut utiliser des données de la RAMQ pour étudier l'état de santé des personnes de 65 ans et plus.

Selon la question d'intérêt, un sondage ou une expérience devrait pouvoir fournir des données de qualité pour y . Toutefois, faire un sondage ou une expérience demande beaucoup de temps, d'effort et d'argent. Le recours aux données observationnelles est donc très fréquent, et souvent nécessaire. Il faut toutefois faire attention à la représentativité et la qualité des données dans ce cas. Des données collectées correctement pour un usage pourraient ne pas être adaptées à une autre situation.

Remarque 1.1. *On considère parfois les données de sondage comme des données observationnelles, par opposition aux données d'expérience, pour indiquer qu'elles ne peuvent pas servir à établir un lien de causalité. On reviendra sur cette limitation à la section 1.2.*

Dans ce chapitre, on présente certains aspects importants de la planification et de l'exécution d'un sondage et d'une expérience. On étudie également différentes sources de biais auxquels porter attention lors de la collecte de données.

1.1 Sondage

Nous avons dit qu'un sondage permet d'inférer sur une population à l'aide d'un échantillon de celle-ci. Définissons quelques termes.

Population : L'ensemble de référence sur lequel porte l'étude.

Individu : Un élément de la population.

L'ensemble des individus constitue la population. On utilise parfois plutôt le terme *unité d'échantillonnage*, car il ne s'agit pas toujours d'individus. On pourrait par exemple avoir une population d'objets. L'unité d'échantillonnage est celle sur laquelle les mesures sont prises, si elle est sélectionnée.

Échantillon : Un sous-groupe de la population, composé des unités statistiques sélectionnées pour la prise de mesures. Si des mesures ont été prises pour toutes les unités statistiques de la population, on parle de **recensement**.

Variable : Une caractéristique mesurée sur un individu.

Exemple 1.1. *Je souhaite connaître la proportion d'étudiants de deuxième cycle à l'Université Laval ayant un enfant. La population, ici, c'est l'ensemble des étudiants de deuxième cycle à l'Université Laval. Chacun des étudiants de deuxième cycle à l'Université Laval constitue un individu, et la variable d'intérêt est si oui ou non l'individu a un enfant. L'échantillon est un sous-ensemble de tous les étudiants de deuxième cycle à l'Université Laval.*

Maintenant, si j'observe que 7 % des étudiants de l'échantillon ont un enfant, puis-je en conclure que exactement 7 % des étudiants de deuxième cycle à l'Université Laval ont un enfant ? À moins d'avoir vraiment interrogé tous les étudiants de deuxième cycle, la réponse est non. Puisque je n'ai interrogé qu'un échantillon de la population, j'ai une incertitude sur le pourcentage d'étudiants ayant un enfant dans la population. Toutefois, si l'échantillonnage satisfait certaines conditions, il est possible de quantifier cette incertitude pour généraliser de l'échantillon vers la population.

Un élément essentiel pour ce faire est que l'échantillon soit **représentatif** de la population, c'est-à-dire que les individus dans l'échantillon doivent être similaires à ceux du reste de la population, du moins sur les variables mesurées. Par exemple, si mon échantillon d'étudiants de deuxième cycle est constitué d'étudiants rencontrés à un party sur le campus un jeudi soir, il risque de ne pas être représentatif de la population pour ma question d'intérêt. La meilleure façon d'avoir un échantillon représentatif, c'est de procéder à un échantillonnage probabiliste.

1.1.1 Échantillonnage probabiliste

Définition

Une méthode d'échantillonnage est dite probabiliste si

1. tous les individus de la population ont une probabilité non nulle d'être sélectionnés dans l'échantillon, et
2. la probabilité de sélection de chaque individu de la population est connue.

Il **n'est pas nécessaire** que les probabilités de sélection de tous les individus soient égales. On verra d'ailleurs des méthodes pour lesquelles ce n'est pas le cas.

Avantages

1. Un échantillonnage probabiliste favorise la probabilité d'obtenir un échantillon représentatif de la population, permettant ainsi de généraliser de l'échantillon à la population.
2. Un échantillonnage probabiliste permettra par la suite de quantifier l'incertitude sur la quantité qui nous intéresse sous la forme d'une marge d'erreur.

Méthodes d'échantillonnage probabiliste

Il existe une panoplie de méthodes d'échantillonnage probabiliste. Elles requièrent en général d'avoir une liste de tous les individus de la population, nommée la **base de sondage**, qui sera utilisée pour sélectionner l'échantillon. On présentera :

1. L'échantillonnage aléatoire simple (ÉAS)
La méthode d'échantillonnage la plus simple, faite avec ou sans remise.
2. L'échantillonnage systématique
Une autre méthode simple où tous les individus ont la même probabilité de sélection, mais qui ne requiert pas de base de sondage explicite.
3. L'échantillonnage en grappes
Permet de simplifier le processus en présence de groupes « naturels » d'individus dans la population. Cette méthode est toutefois moins efficace que l'ÉAS, c'est-à-dire que pour une même taille d'échantillon elle donnera généralement une estimation avec une marge d'erreur plus grande que l'ÉAS.
4. L'échantillonnage stratifié
Une variante plus efficace que l'ÉAS, mais qui requiert certaines informations additionnelles sur les unités d'échantillonnage.


On présentera aussi quelques méthodes plus complexes souvent utilisées en pratique : l'échantillonnage à plusieurs degrés, l'échantillonnage à plusieurs phases et l'échantillonnage proportionnel à la taille.

1.1.2 Échantillonnage aléatoire simple (ÉAS)

Il s'agit de la méthode la plus simple et la plus courante. Elle requiert une base de sondage, mais aucune autre information sur les individus.

Méthode

On fait simplement un tirage aléatoire de n individus dans la base de sondage. Le tirage peut être fait avec remise, un individu pouvant être sélectionné plus d'une fois dans l'échantillon, ou sans remise.



Caractéristiques

- Chaque individu a la même probabilité de sélection.
- Chaque échantillon de taille n a la même probabilité de sélection.
- Il faut absolument posséder une base de sondage avec tous les individus de la population pour procéder à un ÉAS.

Remarque 1.2. *L'ÉAS sans remise est plus pratique que celui avec remise et permet une estimation plus précise de la quantité d'intérêt. On y reviendra au chapitre 3.*


1.1.3 Échantillonnage systématique

Une autre méthode très simple avec des propriétés similaires à l'AÉS, mais qui s'applique dans certains cas même en l'absence d'une base de sondage.

Méthode

L'idée est de choisir n individus à intervalles réguliers à partir d'une liste numérotée. Soit n la taille d'échantillon désirée, et N la taille de la population.

1. Calculer le pas d'échantillonnage $K = N/n$.
Si K n'est pas un entier, on peut l'arrondir à l'entier le plus près, ou à l'entier inférieur. Dans ce deuxième cas, on s'assure de piger un échantillon de taille supérieure ou égale à n .
2. Inclure dans l'échantillon un individu choisit aléatoirement entre le 1er et le K^e individu dans la liste ordonnée.
3. Inclure tous les les K^e individus après le premier choisi.



Ici, $N = 50$, $n = 12$.

Donc, $K = N/n = 4,1\bar{6}$.

On arrondit à $K = 4$.

On doit tirer au hasard un chiffre de 1 à 4. Ici, on a tiré le 4, et échantillonné de haut en bas et de gauche à droite.

Caractéristiques


- Chaque individu a la même probabilité de sélection.
- Tous les échantillons n'ont pas la même probabilité de sélection.
Certains sont d'ailleurs impossibles.
- Applicable dans certains cas même si une base de sondage explicite n'est pas disponible *a priori*. Par exemple, on peut échantillonner de manière systématique sur une chaîne de production en industrie.
- Peut générer un échantillon qui n'est pas représentatif de la population s'il y a un cycle dans l'ordre des observations dans la liste et qu'il coïncide avec l'échantillonnage.

1.1.4 Échantillonnage en grappes

L'échantillonnage en grappes est une alternative intéressante à l'ÉAS en présence de groupes « naturels » dans la population. Cette méthode permet de diminuer les coûts, notamment pour la construction de la base de sondage et le transport des enquêteurs.

Méthode

- 1) On partitionne la population en groupes « naturels » (grappes).
- 2) On sélectionne un certain nombre de grappes, et tous les individus de ces grappes (et seulement ceux-ci) font partie de l'échantillon.



Exemple 1.2. *Disons qu'on s'intéresse aux habitudes de vie des élèves de 3e secondaire du Québec. Il peut être difficile de produire la liste de tous les élèves de 3e secondaire du Québec, et il serait coûteux d'en sélectionner 500 au hasard dans toute la province et de se déplacer pour aller les interroger un par un. Mais les élèves de 3e secondaire sont regroupés dans des écoles et la liste des écoles est facile à obtenir. Si on décide de sélectionner des écoles au lieu de sélectionner des élèves, la base de sondage sera beaucoup plus facile à construire. En plus, il est moins coûteux d'envoyer les enquêteurs seulement dans quelques écoles sélectionnées.*


Cette méthode d'échantillonnage n'est toutefois pas aussi efficace que l'ÉAS. En effet, les membres d'une même grappe sont souvent plus similaires entre eux que des individus choisis au hasard dans la population. Un échantillon obtenu par un échantillonnage en grappes est donc en général moins informatif qu'un échantillon de même taille obtenu par ÉAS, c'est-à-dire qu'il fournira un estimateur moins précis (avec une plus grande marge d'erreur).

Caractéristiques

- Selon la taille des grappes et la méthode de sélection des grappes, les individus n'ont pas tous la même probabilité de sélection.
- La taille finale de l'échantillon peut être inconnue avant la sélection des grappes.
- Permet de diminuer les coûts, par exemple de construction de la base de sondage ou de transport des enquêteurs.
- Perte d'efficacité. En effet, une même taille d'échantillon mène à une plus petite précision qu'un ÉAS, car des unités d'une même grappe auront souvent une valeur plus similaire de la variable d'intérêt que des individus choisis au hasard dans la population.
- L'inférence est plus complexe, particulièrement le calcul de la marge d'erreur.

Remarque 1.3. Les grappes peuvent être sélectionnées par ÉAS, ou par un échantillonnage systématique, proportionnelle à la taille, etc.

Remarque 1.4. On peut également décider de ne pas sélectionner tous les individus de la grappe dans l'échantillon. On fait alors un **échantillonnage à plusieurs degrés**. On peut ainsi tirer un échantillon à l'intérieur de chacune des grappes choisies (2 degrés), ou des sous-groupes à l'intérieur desquels on pigera des individus (3 degrés).




1.1.5 Échantillonnage stratifié

Cette méthode est un peu l'inverse de l'échantillonnage en grappes, en ce sens qu'elle requiert plus d'informations sur les individus de la population, et est donc souvent plus coûteuse, mais qu'elle permet souvent d'avoir un estimateur plus précis de la valeur d'intérêt.

Méthode

- 1) On partitionne la population en groupes homogènes (strates).
- 2) Dans chaque strate, on tire un échantillon indépendant.
Il existe plusieurs façons de choisir comment répartir les n individus à échantillonner dans les différentes strates. On y reviendra bientôt.



Caractéristiques

- Requiert une base de sondage incluant une variable de stratification.
- Gain d'efficacité si la variable de stratification est bien choisie, c'est-à-dire si elle est corrélée avec la variable d'intérêt. On aura alors besoin de moins d'observations que dans l'ÉAS pour obtenir la même précision globale sur l'estimation.
- Permet une précision intéressante dans chaque strate. En effet, on peut estimer non seulement la moyenne globale dans la population, mais également les moyennes dans les strates. Il suffit de s'assurer d'échantillonner assez d'individus par strate pour obtenir la marge d'erreur désirée.
- Selon le choix du nombre d'observations par groupe les observations auront, ou pas, la même probabilité de sélection.

Remarque 1.5. Les échantillons dans chacune des strates peuvent être tirés de façon aléatoire, systématique, à plusieurs degrés ou phases, etc. On peut également tirer des grappes à l'intérieur des strates.

Choix de la variable de stratification

- On doit connaître la variable de stratification pour tous les individus de la population avant même de tirer l'échantillon.
- La variable de stratification devrait être corrélée avec la variable d'intérêt. Dans ce cas, la stratification favorisera la représentativité de l'échantillon, mais elle permettra aussi d'obtenir un estimateur plus précis. C'est qu'il est plus facile d'estimer la moyenne d'une variable quand la variance de celle-ci est plus faible, ce qui sera le cas à l'intérieur des strates si la variable de stratification est corrélée avec la variable d'intérêt. On y reviendra à la section 3.5.

Exemple 1.3. *On veut estimer le nombre d'heures de travail rémunéré hebdomadaire moyen des étudiants de premier cycle de l'université Laval. Le registraire peut nous fournir une base de sondage, soit la liste de tous ces étudiants. Pour un échantillonnage stratifié, cette liste doit inclure une variable de stratification pour tous. Par exemple, elle pourrait indiquer la faculté du programme auquel est inscrit l'étudiant. Ce serait une bonne variable de stratification si le nombre d'heures de travail rémunéré hebdomadaire varie selon les facultés, ce qui peut être le cas. La base de sondage pourrait également contenir le mois de naissance de chaque étudiant. Ce ne serait sûrement pas un aussi bon choix de variable de stratification car la corrélation entre le mois de naissance d'un étudiant et son nombre d'heures de travail rémunéré est probablement faible.*

Choix du nombre d'observations par strate

La stratégie la plus simple est l'allocation proportionnelle. Dans ce cas, le nombre d'unités échantillonnées dans chaque strate est proportionnel au poids de la strate dans la population. Mathématiquement, on aura alors

$$\frac{n_k}{n} = \frac{N_k}{N} \implies n_k = \frac{N_k n}{N}.$$

où N est la taille de la population, n est la taille souhaitée pour l'échantillon, N_k est le nombre d'observations de la strate k dans la population et n_k est le nombre d'observations qu'on doit tirer dans la strate k pour un échantillonnage stratifié avec allocation proportionnelle. Si n_k n'est pas un entier, on peut arrondir à la hausse ou à la baisse pour obtenir la taille d'échantillon n souhaitée.

Exemple 1.4. *Supposons une population qui compte 30, 50 et 20 unités respectivement dans les strates 1, 2 et 3, c'est-à-dire que $N = 100$ avec $N_1 = 30$, $N_2 = 50$ et $N_3 = 20$. Si on souhaite obtenir un échantillon de 30 unités, l'allocation proportionnelle suggèrera de prendre*

$$n_1 = \frac{N_1 * n}{N} = \frac{30 * 30}{100} = 9 \quad n_2 = \frac{50 * 30}{100} = 15 \text{ et } n_3 = \frac{20 * 30}{100} = 6.$$

Un avantage important de l'allocation proportionnelle est que la probabilité de sélection sera identique pour toutes les unités de la population. On reviendra sur l'intérêt de cette caractéristique à la section 2.9.

Deux alternatives à l'allocation proportionnelles sont parfois utilisées :

1. Pour des estimés précis dans les strates

On souhaite parfois obtenir non seulement une estimation de la moyenne de la population, mais également une estimation de la moyenne dans une ou plusieurs des strates. On peut alors vouloir s'assurer que n_k soit assez grand dans ces strates pour fournir une estimation avec une marge d'erreur raisonnable. On reviendra à la section 3.3.5 sur le choix de la taille d'échantillon en fonction de la marge d'erreur désirée.


2. Pour optimiser la variance de l'estimateur

Si on a de l'information supplémentaire, soit la variance de la variable d'intérêt pour chacune des strates de la population, alors on peut choisir les $n_1, \dots, n_K$ de façon à minimiser la marge d'erreur de l'estimateur de la moyenne dans la population. On y reviendra à la section 3.5.2.

1.1.6 Méthodes plus complexes d'échantillonnage probabiliste

Échantillonnage à plusieurs phases

On sélectionne un premier échantillon, et on collecte quelques informations sur les individus, puis un sous-échantillon pour lequel on collecte des données plus détaillées. C'est utile si une partie de l'enquête est plus coûteuse, longue ou invasive. Ainsi, l'enquête NHANES sur la santé des citoyens américains sélectionne un sous-échantillon de répondants pour lesquels une infirmière va à domicile prendre des mesures (taille, poids, prise de sang, etc.) La méthode peut aussi être utilisée si on a besoin d'une variable pour la suite de l'enquête mais qu'elle n'est pas dans la base de sondage, par exemple pour interroger seulement des cyclistes.




Échantillonnage avec probabilité proportionnelle à la taille

On associe d'abord une certaine mesure de taille à chacune des unités d'échantillonnage dans la population. Les probabilités d'inclusion des observations sont proportionnelles à cette taille, les plus grandes observations ayant une probabilité plus grande d'être incluses dans l'échantillon. L'objectif de la méthode est de s'assurer que les unités qui ont un grand impact sur la mesure d'intérêt aient une plus grande probabilité d'être sélectionnées dans l'échantillon.

Méthode

- 1) On identifie une variable correspondant à la taille de chaque unité de la population. Elle doit être connue pour toutes les unités avant le sondage.
- 2) On tire un échantillon aléatoire de telle sorte que la probabilité de chaque unité d'être pigée est proportionnelle à sa taille.



Exemple 1.5. On s'intéresse au profit moyen des entreprises québécoises. La base de sondage serait le registre des entreprises du Québec. Pour s'assurer d'inclure les plus grandes entreprises dans l'échantillon, on doit avoir une mesure de taille pour toutes les entreprises du registre. On peut par exemple utiliser le nombre d'employés qui y travaillent. Ensuite, on sélectionnera avec une plus grande probabilité les entreprises ayant plus d'employés.

Caractéristiques

- La probabilité de sélection n'est pas la même pour toutes les observations. Puisqu'elle est connue, on pourra toutefois en tenir compte lors de l'analyse pour obtenir un estimateur non biaisé. On y reviendra à la section 2.9.
- Plus efficace si la taille est bien mesurée et reliée au paramètre d'intérêt.
- L'inférence est plus complexe, notamment le calcul de la marge d'erreur.

1.1.7 Impact des probabilités de sélection

On a vu dans les sections précédentes plusieurs méthodes d'échantillonnage. Dans certains cas, on a remarqué que les probabilités de sélection dans l'échantillon étaient identiques pour toutes les unités, Ce n'est toutefois pas toujours le cas. Il se trouve qu'il est très important de prendre cet aspect en compte quand on planifie la collecte de données, et surtout lors de l'analyse des données collectées.

Avec des probabilités de sélection égales pour toutes les unités, l'échantillon obtenu sera directement représentatif de la population.

Voyons un petit exemple.

Exemple 1.6. *Considérez la population et l'échantillon décrits ci-dessous.*

	Strate 1	Strate 2
Population	1,2,3,4,5,6,7,8,9,10	20,30,40,50,60
Échantillon	3,6,7	20,50,60

La moyenne dans l'échantillon est $\frac{1}{6}(3 + 6 + 7 + 20 + 50 + 60) = 24,33$. On peut voir que cette valeur est supérieure à la moyenne dans la population, qui est $\frac{255}{15} = 17$. Il semble que les unités avec de grandes valeurs aient été sur-représentées.

En effet, on a choisi $n_1 = n_2 = 3$, mais la strate 1 est deux fois plus grande que la strate 2. Ainsi, les unités de la strate 2 ont une plus grande probabilité de sélection, et celles-ci sont plus grandes que celles de la strate 1. L'échantillon obtenu ne sera donc pas nécessairement représentatif de la population.

Utiliser une méthode d'échantillonnage probabiliste avec des probabilités égales pour toutes les unités favorise l'obtention d'un échantillon représentatif de la population, qu'on pourra analyser facilement. Il reste qu'il est parfois utile, ou nécessaire, de faire autrement. Par exemple, si on fait un échantillonnage par grappes et qu'on ne connaît pas la taille des grappes à l'avance on ne pourra pas s'assurer que toutes les unités aient la même probabilité de sélection.

Mais même si les probabilités de sélection des unités ne sont pas égales, le fait d'utiliser une méthode d'échantillonnage probabiliste nous permettra tout de même d'extrapoler de l'échantillon vers la population. En effet, tant qu'on connaît la probabilité de sélection de chaque individu, ce qui est toujours le cas dans un échantillonnage probabiliste, on pourra assez facilement appliquer une correction pour obtenir des statistiques descriptives représentatives de la population. On verra comment le faire pour une moyenne à la section 2.9, et comment obtenir une marge d'erreur pour cet estimateur à la section 3.5.

1.1.8 Méthodes d'échantillonnage non probabiliste

Les statisticiens recommandent en général l'utilisation de méthodes d'échantillonnage probabiliste. En pratique toutefois, des méthodes non probabilistes sont souvent choisies, car avantageuses en termes de coûts et de facilité d'utilisation.

On présente quelques méthodes ici pour que vous puissiez les identifier. Mais rappelez-vous que ces méthodes peuvent mener à des échantillons très peu représentatifs de la population, et qu'elles ne permettent pas aisément de faire de l'inférence à partir des données collectées.

- Échantillonnage volontaire
 - Des volontaires sont sollicités à l'aide d'annonces / d'affiches pour participer à une étude, avec ou sans rémunération.
 - La taille d'échantillon est limitée par le nombre de volontaires ou par des aspects économiques, mais non statistiques.
 - Parfois nécessaire en raison de la nature de l'enquête (tests pharmaceutiques, études invasives ou exigeantes).
- Échantillonnage de commodité ou à l'aveuglette
 - Le choix des individus et de la taille d'échantillon est arbitraire, et dépend majoritairement de la facilité d'accès.
 - Dans ce cas-ci aussi les répondants sont des volontaires, c'est-à-dire qu'on n'oblige personne à participer au sondage, mais ici on approche directement les individus pour les inviter à participer au sondage.
- Échantillonnage par quotas
 - Échantillonnage quelconque (non aléatoire) jusqu'à ce qu'un nombre prédéterminé d'individus soit atteint dans chaque catégorie (sous-population).
 - Similaire à l'échantillonnage stratifié, mais le choix des individus n'est pas vraiment aléatoire.
- Échantillonnage « boule de neige »
 - On choisit d'abord arbitrairement un petit groupe d'individus ayant les caractéristiques recherchées. Puis, on leur demande de trouver d'autres individus de leur entourage qui ont ces mêmes caractéristiques et de les encourager à rejoindre l'échantillon. Et ainsi de suite.
 - Parfois appelé échantillon par réseaux.
 - Particulièrement utile pour une population difficile à rejoindre (ex. sans-abris, immigrants illégaux, utilisateurs de drogues par injection).
 - Produit généralement un échantillon biaisé, mais il existent certaines techniques plus complexes pour régler ce problème, du moins en partie.

1.1.9 Cas particulier : recensement

Par définition, on nomme **recensement** un sondage pour lequel l'échantillon est la population entière. Ou encore pour lequel on interroge toute la base de sondage, même si celle-ci ne couvre pas entièrement la population.

L'avantage d'un recensement est qu'il permet en théorie d'obtenir exactement la valeur d'intérêt. Par exemple, si j'interroge tous les étudiants de deuxième cycle de l'Université Laval, je pourrai connaître exactement la proportion d'étudiants de deuxième cycle à l'Université Laval qui ont un enfant (si bien sûr chacun accepte de répondre à ma question!).

Pourquoi donc ne pas toujours faire un recensement ? Il y a quelques raisons :

- Un recensement peut être trop long, ou trop cher.
- Un recensement est parfois impossible.
Par exemple, disons qu'on veut mesurer la durée de vie moyenne des ampoules de la compagnie Lumière afin de l'inscrire sur l'emballage. Dans un recensement, on devrait allumer chaque ampoule et prendre en note combien de temps elle éclaire avant de s'éteindre. Ainsi, il ne resterait aucune ampoule intacte à vendre aux clients ! Utiliser un échantillon d'ampoules est une bien meilleure option.
- Un recensement peut être moins précis, pour un budget fixé.
Sélectionner moins d'individus dans l'échantillon permet d'allouer un plus grand budget à chacun de ceux-ci, et ainsi de mieux mesurer les variables d'intérêt. Par exemple, on aura une meilleure mesure du poids d'une personne si on se déplace pour le mesurer que si on demande simplement à l'individu de déclarer son poids.

1.1.10 Erreur d'échantillonnage

L'erreur d'échantillonnage est inévitable si on utilise un sondage pour la collecte des données. Elle est causée par le fait que l'échantillon n'est pas la population, c'est-à-dire que les données de l'échantillon peuvent nous donner un mauvais portrait de la population puisque ce ne sont pas tous les individus qui ont été interrogés. Cette erreur n'est pas présente dans un recensement, et décroît avec la taille de l'échantillon.

L'erreur d'échantillonnage n'est pas problématique pour un échantillonnage probabiliste car elle ne devrait pas biaiser les résultats. En outre, on peut l'estimer statistiquement dans ce cas et on peut donc en tenir compte lorsqu'on souhaite faire de l'inférence, comme on le verra au chapitre 3.

1.2 Expérience

1.2.1 Association versus causalité

Effectuer un sondage peut nous apprendre bien des choses sur une population. Toutefois, une limite importante d'un sondage est qu'il ne peut pas établir un lien de causalité entre deux variables. Il peut simplement nous informer sur la corrélation entre celles-ci. En effet,

association ne veut pas nécessairement dire causalité !

Une association, ou corrélation, détectée entre une variable X et une variable Y correspond généralement à l'une des situations suivantes :

1. La variable X cause la variable Y .
2. La variable Y cause la variable X .
3. Les variables X et Y ont une cause commune.
4. La variable X cause une variable Z qui cause une variable Y .
5. Simple coïncidence

Remarque 1.6. *Une variable Z qui est associée aux deux variables d'intérêt X et Y et qui cause une corrélation entre ces deux variables alors qu'il n'y a pas de lien de causalité entre X et Y est souvent appelée une variable confondante.*

Exemple 1.7. *On a pu établir qu'une augmentation de la sudation est associée à des températures ambiantes plus élevées. On pourrait vouloir en conclure que les gens qui suent causent une augmentation de la température. Évidemment, si relation causale il y a, elle est fort probablement dans l'autre direction.*

Exemple 1.8. *On a pu établir que les enfants ayant de plus grands pieds ont en général un vocabulaire plus riche. On pourrait vouloir en conclure qu'avoir des grands pieds cause une augmentation du vocabulaire des enfants. Ou encore qu'enrichir notre vocabulaire permet de faire grandir nos pieds ! Mais en fait ici, la variable confondante âge est à l'origine de la corrélation observée : les enfants plus vieux ont de plus grands pieds en général, et les enfants plus vieux ont un vocabulaire plus riche en général.*

Une association entre deux variables est donc nécessaire mais pas suffisante pour conclure à une relation de cause à effet. Il faut en fait avoir recours à une expérience randomisée pour tirer des conclusions causales.

1.2.2 Expérience (randomisée)

Disons qu'on s'intéresse à l'effet d'une variable X , un traitement, sur une autre variable Y , la variable réponse. Dans une **expérience randomisée** (simplement dénotée expérience pour la suite), il faut **attribuer à chaque participant un traitement de façon aléatoire** au début de l'expérience.

Remarque 1.7. *Le terme traitement est utilisé ici car ce genre d'expérience est fréquent en contexte médical, mais il s'agit plus généralement de la variable pour laquelle on veut établir un effet causal.*

On appelle l'attribution aléatoire du traitement aux individus la **randomisation**. Le rôle de la randomisation est d'équilibrer les caractéristiques des individus dans les deux groupes de façon à ce que globalement la seule différence entre les individus des deux groupes soit le traitement subi. On balance ainsi les variables connues pour influencer la réponse, ainsi que tous les autres variables confondantes inconnues. Toute différence au niveau de la variable réponse entre les deux groupes pourra ainsi être attribuée au traitement.

Exemple 1.9. *Supposons que je veux identifier lequel de deux manuels scolaires permet aux étudiants de mieux réussir à un examen.*

1. *Je peux laisser les étudiants choisir leur manuel et faire un sondage à la fin de la session en demandant à tous le manuel qu'ils ont utilisé et leur note à l'examen final.*
2. *Je peux piger au hasard au début du cours quel manuel chaque étudiant doit utiliser.*

Disons que je choisis la première option, et que les étudiants utilisant le manuel A ont en moyenne de meilleures notes que les autres. Je ne pourrai pas conclure que c'est vraiment le manuel A qui a causé les meilleures notes, car plusieurs autres variables ont pu entrer en jeu. Peut-être le manuel A est-il plus long, et seuls les étudiants les plus motivés l'ont-ils choisi ? Peut-être le manuel A est-il plus technique et seuls les étudiants avec de meilleures connaissances préalables l'ont-ils choisi ? Bref, on ne peut pas savoir ce qui a causé les meilleurs notes chez les étudiants qui ont utilisé le manuel A...

Par contre, avec le deuxième scénario, les caractéristiques des étudiants dans les deux groupes seront semblables ; on pourra donc attribuer au manuel toute différence entre les notes des étudiants.

1.2.3 Planifier une expérience

Dans une expérience, la règle de base est que, outre la ou les variables randomisées, **les conditions expérimentales doivent autant que possible être identiques pour toutes les unités**. En effet, tout ce qui varie entre les unités pourrait causer des différences dans la variable réponse et fausser les résultats. En particulier, ce principe a deux conséquences importantes :

1. Un individu ne devrait idéalement pas savoir quel traitement il reçoit.

En effet, des études ont établi que le fait de savoir qu'un traitement spécifique nous a été attribué aléatoirement peut avoir un impact sur l'effet du traitement lui-même. En particulier, le fait de recevoir un traitement, peu importe lequel, a en général un effet positif sur les individus. On nomme ceci **l'effet placebo**. Si les individus ne savent pas quel traitement leur a été attribué, l'effet placebo s'applique de manière égale à tous les groupes et ne biaise pas les résultats.

2. Aucun des chercheurs ou autres individus impliqués dans la prise de mesures ne devrait savoir quel traitement chaque unité reçoit.

En effet, cela pourrait influencer leur comportement, et par conséquent les résultats de l'expérience. Par exemple, un médecin pourrait être plus disponible pour les patients recevant le traitement auquel il croit le plus.

Une expérience dans laquelle ni les individus ni les expérimentateurs ne connaissent l'attribution des traitements se nomme une **expérience en double aveugle**. Évidemment, il est parfois impossible de satisfaire ces deux conditions en pratique. Pour tester l'effet de l'exercice physique sur la santé, il faudra bien faire de l'exercice physique et il est plutôt difficile de ne pas s'en rendre compte. Il s'agit simplement d'être prudent quand on interprète les résultats de l'expérience.

Une autre façon de s'assurer que les variables confondantes soient similaires pour les différents traitements est d'attribuer tous les traitements à chaque sujet, si c'est possible. Par exemple, on testera deux marques de gouttes pour les yeux en mettant les gouttes A dans un oeil d'un sujet et les gouttes B dans l'autre oeil du même sujet. Le sujet étant identique, les variables confondantes seront identiques pour les deux traitements. Attention toutefois, il faudrait ici randomiser dans quel oeil (gauche ou droit) on met les gouttes pour chaque sujet pour éviter un biais causé par une différence entre les yeux gauches et droits des sujets. De même, si deux traitements sont appliqués l'un après l'autre aux sujets, il faudra alors randomiser l'ordre d'application pour ne pas qu'un effet temporel puisse influencer les résultats.

Remarque 1.8. *Les réponses d'un même sujet à plusieurs traitements ne seront pas indépendantes; il faudra en tenir compte lors de l'inférence. Dans le cas de deux traitements attribués à chacun des sujets, on peut notamment utiliser le test de comparaison de deux moyennes provenant d'échantillons appariés (voir section 3.4.6). Les méthodes d'analyse pour des plans d'expérience plus complexes ne seront pas couvertes ici.*

Taille d'échantillon

Il est essentiel de prévoir assez d'unités dans chaque groupe expérimental pour que les méthodes d'inférence statistique puissent attribuer les différences observées entre les groupes aux traitements, et non simplement au hasard.

Le traitement devrait être appliqué de manière indépendante pour chaque unité expérimentale. Ainsi, on s'assure que les réponses des unités sont réellement indépendantes. On peut devoir appliquer le traitement simultanément sur plusieurs unités. Par exemple, si le traitement est une méthode d'enseignement alors tous les élèves d'une même classe auront le même traitement. Il faudra tenir compte de la corrélation entre les unités lors de l'analyse des données. Nous n'aborderons pas ces méthodes d'analyse plus complexes dans le cours. On pourra plus simplement considérer la classe comme l'unité expérimentale, et utiliser le score moyen des élèves de la classe, mais la taille d'échantillon sera alors réduite.

1.2.4 Limites

Expérience non applicable

Il peut être difficile, impossible ou non éthique d'assigner la ou les variables explicatives de façon aléatoire. Par exemple, disons qu'on souhaite étudier l'effet de fumer un certain nombre de cigarettes par jours sur la santé. L'effet ne sera pas immédiat, et donc il faudrait assigner au hasard plusieurs participants à fumer quotidiennement pendant plusieurs mois ou années. Puisqu'on se doute déjà des dangers de la cigarette sur la santé il ne serait pas éthique d'agir ainsi.

Des méthodes statistiques plus complexes peuvent parfois être utilisées pour mettre en évidence un lien de causalité avec des données non expérimentales. Une stratégie est de mesurer le plus de variables confondantes possibles et d'en tenir compte dans l'analyse. Ces méthodes ne seront toutefois pas discutées dans le cours.

Généralisation des résultats d'une expérience

Dans tous les cas, il faut noter que les conclusions de l'expérience ne seront valides que pour les individus à l'étude. S'ils sont représentatifs d'une plus grande population, on peut alors généraliser les résultats à la population en précisant la marge d'erreur, mais sinon il faut être prudent sur la portée de nos résultats.

Par exemple, on a parfois de la difficulté à reproduire dans la population générale des résultats d'expériences sur des étudiants universitaires, volontaires fréquents pour la recherche. De même, on a observé que certains médicaments et protocoles testés lors d'expériences sur des hommes n'avaient pas le même effet chez les femmes.

On note qu'un échantillonnage probabiliste est une excellente façon d'obtenir un échantillon représentatif de la population, mais cela peut être très difficile à obtenir si les individus sélectionnés devront ensuite participer à une expérience.

Généralisation des résultats hors des conditions expérimentales

Il arrive qu'une relation de cause à effet validée lors d'une expérience randomisée soit difficile à reproduire hors du contexte expérimental. Un exemple intéressant concerne l'utilisation de la crème solaire pour prévenir les coups de soleil ².

La question était de savoir s'il y avait un avantage à utiliser une crème solaire avec FPS 100+ au lieu d'un FPS 50+ pour se protéger des coups de soleil. Pour ce faire, on a appliqué une des crèmes sur la partie gauche du visage de 200 participants, et l'autre sur la partie droite de leur visage. Ils ont ensuite passé une journée à skier ou faire de la planche à neige au Colorado, puis on a comparé l'intensité des coups de soleil sur leur visage. On a mesuré que 55,3% des participants avaient plus de coups de soleil sur la moitié du visage protégée avec la crème FPS 50+, que 5% des participants avaient plus de coups de soleil sur celle protégée par la crème FPS 100+ et qu'il n'y avait pas de différence entre les deux côtés pour les autres. Ces résultats laissent croire qu'il serait avantageux d'utiliser une crème FPS 100+.

Toutefois, d'autres études ont montré qu'en général les gens auront tendance à moins se protéger du soleil s'ils ont utilisé une crème solaire avec une meilleure protection. Se sentant mieux protégés, ils auront moins tendance à porter aussi des vêtements, à rechercher l'ombre, etc. Au final, encourager les gens à utiliser une crème FPS 100+ pourrait donc avoir pour effet d'augmenter les coups de soleil, même si on a pu démontré que l'inverse se produit dans des conditions contrôlées.

2. L'exemple décrit ici provient de Catherine Handfield, Faut-il (parfois) opter pour un FPS 100?, La Presse, en ligne, 4 septembre 2017. Disponible au <https://www.lapresse.ca/vivre/sante/201709/01/01-5129638-faut-il-parfois-opter-pour-un-fps-100.php>

1.3 Sources de biais

Rappelons qu'on peut définir formellement le biais d'un estimateur, associé à la fonction mathématique utilisée pour calculer sa valeur échantillonnale. Soit θ le paramètre d'intérêt et $\hat{\theta}$ l'estimateur de ce paramètre. Le biais est donné par

$$E(\hat{\theta}) - \theta,$$

l'espérance étant calculée avec la distribution échantillonnale de l'estimateur.³

Lorsqu'on s'intéresse aux sources potentielles de biais dans une étude, on souhaite vérifier si des caractéristiques de l'étude font en sorte qu'on a tendance à surestimer, ou à sous-estimer, le paramètre qu'on tente d'estimer. On risque alors de tirer de fausses conclusions de l'étude. On peut distinguer un grand nombre de sources de biais. On en présentera ici trois qui concernent la collecte de données :

- Erreur de couverture
- Erreur de mesure
- Erreur de non-réponse

La première touche spécifiquement la collecte de données par sondage, alors que les deux autres s'appliquent à tous les types de collectes de données.

Remarque 1.9. *En plus des sources de biais au moment de la collecte des données, d'autres sources d'erreur peuvent venir fausser les conclusions d'une étude statistique. Voici quelques exemples.*

Au moment de l'analyse des données :

- *Erreur de l'analyste*
(mauvais choix d'analyse, mauvaise interprétation, code erroné,...)
- *Manipulation frauduleuse des données*
- *Élimination subjective de données aberrantes*

Lors de la communication des résultats :

- *Graphique trompeur*
- *Extrapolation exagérée*
- *Présentation partielle des résultats*
- *Présentation sensationnaliste des résultats (par exemple dans un titre)*

On abordera de nouveau certains de ces aspects dans les chapitres suivants. Pour le moment, on se concentre sur le biais lors de la collecte de données.

3. On revient plus en détail sur ces concepts au chapitre 3.

1.3.1 Erreur de couverture

Utiliser un échantillonnage non probabiliste peut conduire à un échantillon non représentatif de la population. Un problème de couverture peut faire la même chose.

L'erreur de couverture est causée par une base de sondage qui ne permet pas d'obtenir un échantillon représentatif de la population.

La figure 1.1 illustre les deux types d'erreur de couverture, soit la surcouverture et la sous-couverture.




FIGURE 1.1 – Illustration de deux types d'erreur de couverture

La sur-couverture survient quand la base de sondage inclut des individus ne faisant pas partie de la population. Par exemple, si la population visée est l'ensemble des étudiants de troisième année dans un programme d'étude et que j'utilise la liste des étudiants admis dans ce programme pour tirer l'échantillon, je risque d'inclure des individus qui ont changé de programme depuis leur admission.

À l'inverse, on parle de sous-couverture si certains individus ne sont pas dans la base de sondage et donc n'ont aucune chance de faire partie de l'échantillon. Par exemple, les personnes sans domicile fixe n'ont aucune chance de faire partie d'un échantillon élaboré à partir de la liste des habitations sur un territoire.

1.3.2 Erreur de mesure

L'erreur de mesure survient si ce que je mesure n'est pas ce que je souhaitais mesurer.

Cette erreur est souvent causée par un instrument de mesure inadéquat ou utilisé dans de mauvaises conditions. Ici, le terme instrument de mesure doit être compris au sens large, et inclut notamment tout questionnaire utilisé pour l'étude.

Parmi les causes d'erreur de mesure, on note :

- Erreur de saisie
(par distraction, à cause de l'utilisation d'une langue étrangère, ...)
- Manque de temps
(mesure prise trop rapidement, répondant répond trop vite,...)
- Instrument de mesure inexact ou mal calibré
- Un répondant qui ne connaît pas la réponse à une question
- Un répondant qui décide de mentir

En ce qui concerne le questionnaire lui-même, une erreur de mesure peut notamment apparaître dans les cas suivants :

- Question tendancieuse
Exemple : Sachant que 2 millions d'enfants souffrent de la faim au Soudan, devrait-on augmenter l'aide internationale à ce pays ?
- Question vague
Exemple : Quel est votre revenu ?
- Choix de réponses non exhaustif
Exemple : Quel moyen de transport utilisez-vous pour venir travailler : la marche, le vélo, l'autobus ou l'automobile ?
- Question trop complexe
Exemple : Êtes-vous membres de l'ASSQ ?
Exemple : Quelle proportion de votre temps libre passez-vous à l'extérieur ?
- Question double
Exemple : Êtes-vous satisfait de votre salaire et de vos conditions de travail ?

En outre, d'autres caractéristiques du questionnaire peuvent influencer les réponses aux questions : longueur du questionnaire, ordre des questions, ordre et choix des choix de réponse, espace laissé libre pour la réponse,... La construction d'un bon questionnaire est un domaine de recherche en soi, et plusieurs articles et livres sont publiés sur le sujet.

1.3.3 Erreur de non-réponse

Dans le cadre d'un sondage, on parle de **non-réponse** si un individu sélectionné dans l'échantillon ne peut pas être contacté ou refuse de répondre à un sondage ou à une question. Une conséquence évidente de la non-réponse est de diminuer le nombre d'individus dans l'échantillon, et donc d'augmenter l'erreur d'échantillonnage. On pourrait donc croire qu'il suffit de recruter de nouveaux individus pour remplacer ceux qui ne peuvent être inclus dans l'échantillon.

En fait, l'impact de la non-réponse peut être beaucoup plus important. **Si les répondants diffèrent des non-répondants sur la ou les variables d'intérêt, l'échantillon des répondants ne sera plus représentatif de la population.** Par exemple, si les personnes avec des salaires plus élevés refusent de répondre à un sondage sur leurs revenus, ou sont simplement plus difficiles à rejoindre, on risque de sous-estimer le revenu moyen dans la population.

Que faire ?

- La meilleure façon d'éviter l'erreur de non-réponse est de prévenir la non-réponse, par exemple à l'aide d'un questionnaire court et simple, ou en expliquant clairement l'importance pour le participant de répondre.
- On peut également tenter d'augmenter le taux de réponse, notamment à l'aide de rappels ou en variant les méthodes de contact (téléphone, courriel, texto,...).
- Il existe de plus des méthodes statistiques qui peuvent corriger les biais causés par la non-réponse, du moins en partie, mais elles sont relativement complexes et ne s'appliquent pas toujours

Notons qu'on peut également avoir un problème de non-réponse, ou de données manquantes, dans une expérience, par exemple si un patient ne se présente pas à un rendez-vous de suivi, ou dans les données administratives, par exemple si les données d'une école ne sont pas dans la banque de données de sa commission scolaire.

Dans tous les cas, il est important de réfléchir à la cause des données manquantes, et aux biais potentiels causés par l'absence de ces données.

AUTRES NOTES

AUTRES NOTES

AUTRES NOTES

Chapitre 2

Statistiques descriptives

La statistique descriptive est un ensemble d'outils pour décrire des jeux de données et dégager l'essentiel de l'information qu'ils contiennent. Elle utilise des résumés numériques et des représentations graphiques, auxquels on fait référence globalement sous le nom de statistiques descriptives. Bien que les statistiques descriptives ne permettent généralement pas de faire d'inférence statistique formelle, elles sont essentielles pour illustrer des tendances et bien analyser un jeu de données. Les statistiques calculables sur une ou des variables dépendent du type de variables (qualitatives ou quantitatives) en jeu.

2.1 Types de variables

Les variables rencontrées en statistique peuvent être séparées en plusieurs grands types, déterminés par l'ensemble des valeurs possibles de la variable. Ces types de variables sont illustrés à la figure 2.1 et expliqués par la suite.




FIGURE 2.1 – Types de variables

2.1.1 Variables catégoriques (ou qualitatives)

Les valeurs possibles (ou modalités) d'une variable catégorique sont des catégories que l'on notera $C_1, \dots, C_K$. Les modalités d'une variable catégorique ne peuvent être mesurées numériquement, bien qu'elles peuvent être représentées par des chiffres. Par exemple, un niveau de satisfaction peut être représenté par un chiffre de 1 à 5. Cette variable n'en demeure pas moins catégorique. Ainsi, par exemple, le chiffre 1 représente la catégorie « très insatisfait », le chiffre 2 la catégorie « insatisfait » et ainsi de suite.

On peut définir deux types de variables catégoriques :

- **Variables nominales** : Les variables catégoriques nominales ayant des modalités qui ne peuvent être ordonnées.
Ex : le sexe d'une personne, son pays de naissance, la couleur de ses cheveux.
- **Variables ordinales** : Les variables catégoriques dont les modalités peuvent être classées dans un ordre spécifique.
Ex : un niveau de satisfaction, un niveau de scolarité.

2.1.2 Variables numériques (ou quantitatives)

Les variables numériques, tel que leur nom l'indique, peuvent être mesurées numériquement. Les variables numériques se subdivisent en deux types :

- **Variables discrètes** : Variables ne pouvant prendre qu'un nombre fini de valeurs, ou bien une infinité de valeurs si ces valeurs peuvent s'écrire sous la forme d'une suite $a_1, a_2, a_3, \dots$.
Ex : variable dont les valeurs possibles sont dans $\{0, \frac{1}{5}, \frac{2}{5}, \frac{3}{5}, \frac{4}{5}, 1\}$;
le résultat du lancer d'un dé (valeurs 1, 2, 3, 4, 5, 6) ;
le nombre de personnes frappées par la méningite dans une grande ville sur une période d'une année (valeurs 0, 1, 2, 3, ...).
- **Variables continues** : Variables pouvant prendre comme valeurs tous les points d'un intervalle de nombres réels (par exemple $[0, 10]$).
Ex : le temps, le poids, la taille, la distance, la vitesse.
Bien sûr, en raison de la précision limitée des instruments de mesure, on n'observe en pratique qu'un nombre fini de valeurs de ces variables.

2.2 Résumés numériques pour une variable catégorique ou numérique discrète

Pour une variable catégorique ou une variable numérique discrète prenant un nombre limité de valeurs on peut calculer les statistiques suivantes :

1. les fréquences absolues et relatives,
2. le mode

2.2.1 Fréquences

Soit $C_1, \dots, C_K$ les modalités de la variable et n le nombre total d'observations dans l'échantillon. On distingue deux types de fréquences.

- **Fréquences (absolues) :** La fréquence de la modalité C_j est notée n_j .

n_j est le nombre d'observations dans l'échantillon appartenant à C_j

$$\text{On a alors } n = n_1 + n_2 + \dots + n_K = \sum_{j=1}^K n_j.$$

Remarque 2.1. *Si certaines modalités sont associées à de trop petites fréquences, on peut les regrouper pour alléger la présentation des résultats. Par exemple, si on étudie la variable nombre d'enfants par famille au Québec, on pourrait observer dans l'échantillon tous les entiers entre 0 et 10, mais les familles de 5 enfants et plus seraient peu nombreuses. On pourrait alors calculer les fréquences pour les catégories : 0, 1, 2, 3, 4 et « 5 et plus ».*

- **Fréquences relatives :** Pour la modalité C_j , il s'agit de la proportion

$$f_j = \frac{n_j}{n}$$

Les fréquences relatives permettent de comparer plus facilement l'importance de chacune des classes dans le jeu de données.

$$\text{On note que } \sum_{j=1}^K f_j = \sum_{j=1}^K \frac{n_j}{n} = 1.$$

2.2.2 Mode

La modalité apparaissant avec la fréquence la plus grande se nomme le mode. Le mode peut ne pas être unique.

Exemple 2.1. *Considérons une variable catégorique X = la couleur des yeux. On interroge sept individus sélectionnés aléatoirement, dont les valeurs observées de X seront notées $x_1, \dots, x_7$:*

$x_1 = \text{verts}$ $x_2 = \text{bleus}$ $x_3 = \text{bleus}$ $x_4 = \text{noirs}$
 $x_5 = \text{noirs}$ $x_6 = \text{verts}$ $x_7 = \text{bleus}$

Il y a trois modalités différentes : bleus, noirs et verts. Le tableau de fréquences est donné par :

j	Modalité C_j	Fréquence n_j	Fréquence relative f_j
1	bleus	3	3/7
2	noirs	2	2/7
3	verts	2	2/7
	Total	$n = 7$	1

Dans cet exemple, le mode est bleus. Si un huitième individu était observé et qu'il avait les yeux noirs alors il y aurait deux modes : bleus et noirs.

Remarque 2.2. Extension à une variable numérique.

Lorsque la variable est numérique, on peut tout de même définir des classes de valeurs dans lesquelles on dénombre les observations. Les classes peuvent être du format $[v_{\inf}, v_{\sup}[$ ou encore $]v_{\inf}, v_{\sup}]$. Les fréquences peuvent être représentées sous forme absolue (n_j) ou relative (f_j). On peut aussi identifier la classe avec la plus grande fréquence et on la nomme la classe modale.

2.3 Résumés numériques pour une variable numérique

Il existe pour un échantillon d'une variable numérique une grande variété de statistiques descriptives. On s'intéressera notamment à trois caractéristiques :

1. la localisation
2. la variabilité (ou dispersion)
3. la forme.

On examine ces caractéristiques dans les trois prochaines sections.

2.3.1 Mesures de localisation

Celles-ci peuvent être vues comme décrivant la position de l'échantillon sur l'axe des nombres réels. Nous en présenterons ici quatre :

1. la moyenne,
2. la médiane,
3. la moyenne tronquée,
4. les quantiles.

Notons que les trois premières sont aussi appelées des *mesures de tendance centrale*, en ce sens qu'elles définissent une notion de « centre » de l'échantillon.

Moyenne d'un échantillon

C'est la moyenne arithmétique bien connue :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + \dots + x_n}{n}$$

Si les données sont situées de façon relativement symétrique autour du « centre » de l'échantillon, la moyenne permet d'obtenir une notion satisfaisante de ce centre. Cette mesure a cependant l'inconvénient d'être très sensible aux valeurs extrêmes. En fait, un seul x_i extrême peut suffire pour rendre $\bar{x}$ très grande (ou très petite). On dit donc que la moyenne n'est pas une mesure de localisation robuste relativement aux observations extrêmes.

Exemple 2.2. Voici les salaires de sept joueurs de hockey choisis au hasard (en milliers de dollars) :

x_1	x_2	x_3	x_4	x_5	x_6	x_7
900	1020	1550	1200	750	1350	4500

La moyenne dépasse les 6 plus petites observations, en raison d'une valeur extrême très influente. En effet,

$$\bar{x} = \frac{900 + 1020 + \dots + 4500}{7} = \frac{11\,270}{7} = 1610 > x_i, \quad \text{pour } i = 1, \dots, 6$$

On peut concevoir la moyenne comme le salaire que chaque joueur recevrait si le total des salaires était réparti également entre les joueurs de l'échantillon. On peut voir qu'en présence de valeurs extrêmes ce n'est pas une bonne représentation des salaires que reçoivent effectivement les joueurs.

Médiane d'un échantillon

La médiane est la valeur centrale de l'échantillon au sens où environ 50% des observations lui sont inférieures, et environ 50% des observations lui sont supérieures.

Pour la calculer, on ordonne les éléments de l'échantillon en ordre croissant. En terme de notation, on placera les indices entre parenthèses pour indiquer les observations ont été ordonnées :

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

La médiane de l'échantillon est définie comme suit :

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})} & \text{si } n \text{ est impair} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{si } n \text{ est pair} \end{cases}$$

Contrairement à la moyenne de l'échantillon, $\tilde{x}$ est insensible aux valeurs extrêmes. On la qualifie en ce sens de mesure de localisation robuste. En fait, on peut constater que $\tilde{x}$ reste inchangée lorsqu'on modifie un peu moins de 50% des x_i à chaque extrémité de l'échantillon.

Exemple 2.3. *Considérons de nouveau les salaires des joueurs de hockey de l'exemple 2.2. On les ordonne pour calculer la médiane.*

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$
750	900	1020	1200	1350	1550	4500

$n = 7$ est impair, donc $\tilde{x} = x_{(\frac{7+1}{2})} = x_{(4)} = 1200$ milliers de dollars. La médiane semble ici plus représentative des salaires de ces sept joueurs.

Notons qu'on peut modifier toutes les observations, sauf la quatrième en ordre de grandeur et conserver la même médiane. Par exemple, le jeu de données suivant a lui aussi une médiane de 1200 milliers de dollars :

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$
10	20	30	1200	10000	20000	30000

La médiane indique toujours que la moitié des salaires sont inférieurs à 1200 milliers de dollars, et que l'autre moitié des salaires est supérieure à cette valeur. Néanmoins, elle semble ici moins bien résumer les données, à cause de la grande variabilité dans les observations. Nous verrons comment quantifier cette variabilité à la section 2.3.2.

Moyenne tronquée d'un échantillon

On a indiqué que la moyenne est sensible aux valeurs extrêmes de l'échantillon. La moyenne tronquée permet de calculer une moyenne plus robuste. Il s'agit simplement de la moyenne calculée après avoir éliminé une même proportion p des données à chaque extrémité de l'échantillon ($0 < p < 0,5$). Si pn n'est pas entier, on arrondit à l'entier inférieur, c'est-à-dire à $\lfloor pn \rfloor$.

On définit donc la moyenne tronquée d'ordre p comme suit :

$$\bar{x}_p = \frac{1}{n - 2\lfloor pn \rfloor} \sum_{i=\lfloor pn \rfloor+1}^{n-\lfloor pn \rfloor} x_i$$

Une moyenne tronquée peut être vue comme une mesure de localisation intermédiaire entre la moyenne et la médiane. En effet, lorsque $p = 0$, on calcule la moyenne habituelle $\bar{x}$, et lorsque $p = 0,5$, on calcule la médiane.

Exemple 2.4. On considère toujours les salaires des joueurs de hockey de l'exemple 2.2.

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$
750	900	1020	1200	1350	1550	4500

Si on veut calculer la moyenne tronquée à 20%, on calcule

$$\lfloor pn \rfloor = \lfloor 0.2 \times 7 \rfloor = \lfloor 1.4 \rfloor = 1$$

On retranchera une unité à chaque extrémité de l'échantillon ordonné.

$$\bar{x}_{0.2} = \frac{900 + 1020 + 1200 + 1350 + 1550}{5} = \frac{6020}{5} = 1204$$

Cette mesure est représentative d'un plus grand nombre d'observations que la moyenne arithmétique complète, même si moins d'observations participent au calcul.

Remarque 2.3. La moyenne tronquée est fréquemment utilisée dans la vie courante, sans nécessairement qu'on y réfère sous ce nom. Par exemple, dans les jurys de compétitions sportives (gymnastique, plongeon, patinage artistique), on retranche souvent les deux notes les plus extrêmes avant de comptabiliser le score de l'athlète.

Quantiles d'ordre p d'un échantillon

Le quantile d'ordre p est un nombre q_p tel qu'une proportion p (environ) des x_i sont inférieurs à q_p et une proportion $(1 - p)$ des x_i sont supérieurs à q_p .

Il existe plusieurs façons de définir précisément les quantiles d'ordre p ($0 < p < 1$). La plupart d'entre elles sont une combinaison linéaire des deux observations les plus proches de $x_{(p(n+1))}$. Nous présentons ici une seule définition¹.

Soit $0 < p < 1$. On définit le *quantile échantillonnal d'ordre p* par

$$q_p = x_{(pn+0,5)}$$

Si le rang $pn + 0,5$ n'est pas entier, on utilise les observations les plus proches de ce rang pour calculer le quantile. Plus précisément, on arrondit ce rang à l'entier inférieur et à l'entier supérieur, et on calcule simplement la moyenne des deux valeurs. On pourrait aussi faire une interpolation entre les deux valeurs.

Exemple 2.5. Soit un échantillon de $n = 100$ observations.

- On souhaite calculer le quantile d'ordre $p = 1/3$. Selon la définition, $q_{1/3} = x_{(\frac{1}{3} \cdot 100 + 0,5)} = x_{(33,8)}$. Ainsi, on calcule la moyenne entre la 33^e et la 34^e observations en ordre croissant : $\frac{x_{(33)} + x_{(34)}}{2}$.
- On souhaite calculer le quantile d'ordre $p = 0,7$. Selon la définition, $q_{0,7} = x_{(0,7 \cdot 100 + 0,5)} = x_{(70,5)}$. On calcule donc la moyenne des 70^e et 71^e observations en ordre croissant.

Quelques cas particuliers

- La médiane est simplement le quantile d'ordre 0,5.
- Les quantiles d'ordre $p = 1/4 = 0,25$ et $p = 3/4 = 0,75$ correspondent au premier quartile, dénoté Q_1 et au troisième quartile, dénoté Q_3 , respectivement.
- Les valeurs $p = t/10$ pour $t = 1, 2, \dots, 9$ définissent les déciles.
- Les centiles sont obtenus en prenant $p = t/100$, où $t = 1, 2, \dots, 99$.

1. Il s'agit de celle du livre Probabilités et statistique pour ingénieurs 3e édition, par Hines et al. ISBN : 9782765051886

Impact d'une transformation linéaire des données

Les mesures de localisation présentées ont en commun deux propriétés.

1. Si l'on additionne une même constante à chacune des données, chacune des mesures est augmentée de la même constante.
2. Si l'on multiplie chacune des données par la même constante chacune des mesures est multipliée par la même constante. Exception : la multiplication des données par une constante *négative* va inverser l'ordre des données, donc inverser aussi l'ordre des quantiles.

Exemple 2.6. *Un petit exemple illustre les conclusions énoncées plus haut. La première ligne donne les statistiques descriptives de l'échantillon initial. Les autres lignes sont toutes des transformations linéaires des données, tel qu'indiqué dans la première colonne.*

Transf. linéaire	Données	$\bar{x}$	$\tilde{x}$	$\bar{x}_{1/5}$	Q_1	Q_3
$x_i = y_i$	{ 25, 8, 14, 33, 16 }	19,2	16	18,33	14	25
$x_i = y_i - 14$	{ 11, -6, 0, 19, 2 }	5,2	2	4,33	0	11
$x_i = y_i - 19,2$	{ 5,8, -11,2, -5,2, 13,8, -3,2 }	0	-3,2	-0,87	-5,2	5,8
$x_i = 3y_i$	{ 75, 24, 42, 99, 48 }	57,6	48	55	42	75
$x_i = -3y_i$	{ -75, -24, -42, -99, -48 }	-57,6	-48	-55	-75	-42

Remarque 2.4. Mesures de position

On peut être tenté d'inclure dans les mesures de localisation certaines mesures telles le rang cinquième, le rang centile ou la cote Z . Toutefois, celles-ci attribuent un rang à chaque individu d'un jeu de données, dans le but d'indiquer la position de l'individu parmi tous les autres. Il ne s'agit donc pas de statistiques qui décrivent la distribution d'une variable aléatoire, mais plutôt de mesures de position. Voici tout de même un peu d'information à leur sujet.

1. Le rang cinquième, $R_5(x)$, prend des valeurs dans $\{1, 2, 3, 4, 5\}$. On sépare l'échantillon ordonné en ordre décroissant en 5 sous-groupes de fréquence égale, et le rang cinquième d'un individu est le rang du sous-groupe auquel il appartient. Ainsi, une valeur appartenant à l'intervalle $[q_{0,6}, q_{0,8}]$ aura un rang cinquième égal à 2. On peut aussi le calculer avec la formule

$$R_5(x) = \frac{(nb \text{ données} > x) + \left(\frac{nb \text{ données} = x}{2}\right)}{n} \times 5$$

Les observations ayant les plus grandes valeurs observées dans l'échantillon auront un petit rang cinquième.

2. Le rang centile est similaire du rang cinquième mais on utilise 100 sous-groupes et les observations avec des valeurs élevées ont un rang centile plus élevé. Le rang centile correspond donc (presque !) au pourcentage de données inférieures ou égales à celle qu'on tente de positionner dans la distribution.

$$R_{100}(x) = \frac{(nb \text{ données} < x) + \left(\frac{nb \text{ données} = x}{2}\right)}{n} \times 100$$

Lorsqu'on obtient un rang centile qui n'est pas entier, on doit l'arrondir à l'entier supérieur.

3. La cote Z pour l'individu i d'un jeu de données est définie par

$$Z_i = \frac{x_i - \bar{x}}{s}$$

où x_i est la valeur de la variable pour l'individu i , $\bar{x}$ est la moyenne de cette variable pour l'échantillon et s est l'écart-type de cette variable, qui sera défini dans la prochaine section. On comprendra plus tard comment interpréter précisément cette valeur, mais notons pour le moment qu'elle indique à quel point la valeur d'un individu diffère de la moyenne des autres valeurs.

2.3.2 Mesures de variabilité

Les mesures de variabilité quantifient la dispersion des valeurs d'un échantillon. On en étudiera sept :

1. étendue,
2. écart interquartile,
3. écart-moyen,
4. déviation absolue médiane,
5. variance,
6. écart-type,
7. coefficient de variation.

Étendue d'un échantillon

C'est une mesure très simple, définie par

$$R = x_{(n)} - x_{(1)}$$

La lettre R vient du terme anglais *range*. L'étendue est toutefois très sensible à la taille d'échantillon n ainsi qu'aux données extrêmes, car elle ne fait intervenir que les deux plus extrêmes. On parlera davantage du minimum et du maximum, sans utiliser la distance qui les sépare comme une mesure de variabilité.

Écart interquartile d'un échantillon

On le définit par

$$EIQ = Q_3 - Q_1$$

où Q_1 et Q_3 sont respectivement le premier et le troisième quartiles. L' EIQ est simplement l'étendue de l'intervalle $[Q_1, Q_3]$, qu'on nomme **l'intervalle interquartile**, et qui a la propriété de contenir environ 50% des données de l'échantillon (25% de chaque côté de la médiane).

Un petit nombre de valeurs extrêmes ($< n/4$ à chaque extrémité) n'influence pas l' EIQ . En ce sens, c'est une mesure de variabilité plutôt robuste.

Remarque 2.5. Étendues des quarts

L' EIQ est l'étendue de la moitié centrale des données. On calcule parfois également l'étendue des quatre quarts de l'échantillon, soit $Q_1 - x_{(1)}$, $\tilde{x} - Q_1$, $Q_3 - \tilde{x}$ et $x_{(n)} - Q_4$. Nommés respectivement étendue du premier, deuxième, troisième et quatrième quart, ces valeurs informent aussi sur la variabilité des données.

Écart-moyen

Voici une première mesure de dispersion qui s'intéresse à la distance entre chaque valeur de l'échantillon et le centre de celui-ci. En fait, l'écart-moyen est simplement la moyenne des écarts à la moyenne des valeurs de l'échantillon :

$$EM = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

La valeur absolue est nécessaire ici puisqu'on s'intéresse à la grandeur des écarts.

Pour les mêmes raisons que la moyenne elle-même, l'écart-moyen n'est pas une mesure robuste aux données extrêmes.

Déviatiion absolue médiane

La déviatiion absolue médiane (ou *MAD*, pour *Median Absolute Deviation*) est similaire à l'écart-moyen, mais c'est une mesure plus robuste de la variabilité. Il s'agit de la médiane des écarts à la médiane :

$$MAD = \text{median} |x_i - \tilde{x}|.$$

Ainsi, 50% des observations ont un écart à la médiane supérieur au *MAD*, et 50% des observations ont un écart à la médiane inférieur à celle-ci.

Exemple 2.7. *Voici quelques exemples qui montrent que le MAD, tout comme la médiane d'ailleurs, n'est pas influencé par les données extrêmes, alors que l'écart-moyen et la moyenne le sont.*

Données	$\bar{x}$	$\tilde{x}$	EM	MAD
{0 1 2 3 4 5}	2,5	2,5	1,5	1,5
{0 1 2 3 4 10}	3,33	2,5	2,44	1,5
{0 1 2 3 4 100}	18,33	2,5	27,22	1,5

Variance et écart-type d'un échantillon

Ce sont probablement les deux mesures de variabilité les plus couramment utilisées. L'idée est encore de mesurer les écarts entre les observations et le centre de l'échantillon, mais les mesures sont un peu plus compliquées à interpréter que celles qu'on a déjà présentées.

En gros, la variance échantillonnale est la moyenne des carrés des différences entre chaque x_i et la moyenne $\bar{x}$. Nous la définissons de manière précise par

$$\text{variance} = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Par définition, une variance d'échantillon est donc toujours positive ou nulle, et il est facile de voir qu'elle s'annule seulement dans le cas extrême où tous les x_i sont égaux à $\bar{x}$, autrement dit lorsque les x_i sont tous égaux.

Notez que l'unité de mesure de la variance sera le carré de l'unité de mesure des observations. Ainsi, si les x_i s'expriment en kg, la variance échantillonnale s^2 s'exprimera en kg^2 . Il peut donc être plus facile d'interpréter la racine carrée de la variance, qui s'exprimera alors dans les mêmes unités que les x_i . Cette mesure de dispersion se nomme **écart-type** de l'échantillon, et est dénotée s .

$$\text{écart-type} = s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Si une seule observation x_i est extrême, la moyenne est affectée, certains $(x_i - \bar{x})^2$ deviennent très grands et donc s et s^2 également. L'écart-type et la variance d'échantillon sont donc sensibles aux données extrêmes. En ce sens, ce sont des mesures de variabilité peu robustes.

Remarque 2.6. Choix du dénominateur Dans le calcul de la variance on divise la somme des carrés des écarts à la moyenne par $n-1$, et non par n , comme on aurait pu s'y attendre. La raison pour laquelle on utilise $n-1$ est que s^2 ainsi défini sera un estimateur sans biais pour la variance de la population σ^2 . C'est-à-dire que si les observations forment un échantillon aléatoire d'une distribution de moyenne μ et de variance σ^2 alors $E(s^2) = \sigma^2$, alors que si on divisait par n on sous-estimerait légèrement σ^2 en moyenne. La preuve n'est pas très compliquée, mais un peu longue et sera omise ici. Notez que si n est grand, la différence entre diviser par n ou $n-1$ ne sera pas très importante en pratique.

Remarque 2.7. Interprétation de l'écart-type On a indiqué que l'écart-type est plus facile à interpréter que la variance car ses unités sont les mêmes que celles des x_i . Mais l'écart-type n'est pas toujours simple à interpréter non plus.

Un point de repère pour interpréter l'écart-type est le cas où les observations suivent une loi normale (voir rappel à la section XXX au besoin). Pour une loi normale d'écart-type σ , on peut calculer qu'environ 68% des observations seront à plus ou moins un écart-type de la moyenne, qu'environ 95% des observations seront à plus ou moins deux écarts-types de la moyenne et que presque toutes les observations seront à plus ou moins trois écarts-types de la moyenne. On illustre ce résultat ci-dessous.




FIGURE 2.2 – Proportion des observations qui se retrouvent à différentes distances de la moyenne, la distance étant mesurée en multiples de l'écart-type, pour une loi Normale. (Source : Wikipedia)

Ainsi, si on me parle d'une loi normale de moyenne 15 et d'écart-type 2, je peux facilement savoir que les observations seront concentrées autour de 15, avec environ 68% de celles-ci entre 13 et 17, qu'il y aura environ 14% des observations entre 11 et 13 et un autre 14% entre 17 et 19, et que très peu d'observations seront plus petites que 9 ou plus grandes que 23.

L'interprétation de l'écart-type n'est toutefois pas aussi simple si les observations ne suivent pas une loi normale. La figure suivante illustre ceci. On y représente trois échantillons de 5000 observations, tirés de distribution ayant des moyennes et des écarts-types identiques.

Dans le premier cas, les données viennent d'une loi normale et on retrouve bien l'interprétation donnée ci-dessus. Dans le deuxième cas, la distribution a une forte asymétrie à droite. On voit qu'une plus grande proportion des données est située à moins d'un écart-type de la moyenne que pour une loi normale (87% au lieu de 68%). On note aussi qu'aucune observation n'est inférieure à zéro, ce qui correspond à la moyenne moins un écart-type. Dans le troisième cas, on a une distribution bimodale mais symétrique. Bien que la moyenne soit égale à 1, il y a très peu d'observations situées près de cette valeur, et l'écart-type nous renseigne peu sur la distribution des données.




FIGURE 2.3 – Exemples de jeux de données pour lesquels l'écart-type s'interprète plus ou moins clairement.

Remarque 2.8. On peut montrer que la variance échantillonnale se calcule aussi avec la formule suivante :

$$s^2 = \frac{1}{n-1} \left[\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right]$$

Cette formule peut simplifier les calculs si on doit les faire à la main, ou avec une calculatrice sans option statistique. On démontre ce résultat comme suit :

$$\begin{aligned} s^2 &= \frac{1}{n-1} \left[\sum_1^n (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \right] \\ &= \frac{1}{n-1} \left[\sum_1^n x_i^2 - 2\bar{x} \sum_1^n x_i + n\bar{x}^2 \right] \\ &= \frac{1}{n-1} \left[\sum_1^n x_i^2 - 2\bar{x}n\bar{x} + n\bar{x}^2 \right] \\ &= \frac{1}{n-1} \left[\sum_1^n x_i^2 - n\bar{x}^2 \right]. \end{aligned}$$

Exemple 2.8. Voici quelques exemples de calculs pour les données de l'exemple 2.7.

<i>Données</i>										$\bar{x}$	$\sum x_i^2$	s^2	s	
{	0	0	0	0	0	1	2	3	4	5}	1,5	55	3,6	1,9
{	0	0	0	0	0	1	2	3	4	10}	2,0	130	10,0	3,16
{	0	0	0	0	0	1	2	3	4	100}	11	10 030	980	31,30

On note que la variance et l'écart-type sont très sensibles aux données extrêmes, et même davantage que l'écart-moyen calculé à l'exemple précédent.

Coefficient de variation d'un échantillon

L'écart-moyen, la *MAD*, la variance et l'écart-type sont indépendants de la localisation. Dans certains cas, il peut être intéressant de relativiser la mesure de variabilité par rapport à la moyenne. Par exemple, une variation de poids de quelques kg dans un échantillon de baleines n'a pas la même signification que la même variation observée dans un échantillon de poulets !

Le **coefficient de variation** est un exemple de mesure de variabilité relative. Pour un échantillon $x_1, \dots, x_n$ de valeurs d'une variable numérique X , on le définit comme suit :

$$CV = \frac{s}{\bar{x}}$$

Le coefficient de variation n'a pas d'unité. Il s'utilise pour comparer la variabilité de deux variables possédant des moyennes différentes ou des unités différentes, ou encore provenant de jeux de données différents. Notons que si la moyenne est autour de 0, le CV aura tendance à être très grand, et très sensible aux petites variations de $\bar{x}$.

On exprime parfois le coefficient de variation en pourcentage. Ainsi, un CV de 0,35 signifie que l'écart-type est égal à 35% de la moyenne.

Exemple 2.9. *Évolution de la taille en cm chez les filles de 1 à 18 ans*²

Groupe typique	$\bar{x}$	s	CV
4 ans	103	3,8	3,7%
8 ans	125	5,3	4,2%
12 ans	152	7,2	4,7%
15 ans	161	4,8	3,0%
18 ans	163	6,2	3,8%

Les écarts-types indiquent que la taille est plus variable chez les filles de 12 ans. Le coefficient de variation est également supérieur dans ce groupe d'âge, cet écart-type représentant 4,7% de la taille moyenne à cet âge. Les deux mesures de variabilité indiquent donc que la taille est plus variable chez les filles de 12 ans. La conclusion est plus nuancée en ce qui concerne le groupe le moins variable. D'après l'écart-type, les tailles sont les moins variables dans le groupe des filles de 4 ans, avec $s = 3,8$. Le coefficient de variation indique quant à lui que la variabilité est la plus faible chez les filles de 15 ans. C'est qu'en proportion un écart-type de 3,8 cm sur une moyenne de 103 cm est plus petit qu'un écart-type de 4,8 cm sur une moyenne de 161 cm.

2. Exemple tiré de *Statistical Methods*, 6e édition par G. W. Snedecor et W. G. Cochran, Oxford, 1967.

Impact d'une transformation linéaire des données

Un changement de localisation de toutes les observations par l'addition d'une même constante n'a aucun effet sur les mesures de variabilité, sauf sur le coefficient de variation. En effet, celui-ci est modifié puisque la moyenne est affectée par l'ajout d'une constante alors que l'écart-type ne l'est pas.

Un changement d'échelle par la multiplication d'une constante c a pour effet de multiplier la variance par c^2 et les autres mesures par $|c|$, sauf pour le coefficient de variation qui est simplement multiplié par le signe de la constante c , et donc inchangé si $c > 0$.

Exemple 2.10. On reprend les données de l'exemple 2.6.

Transf. linéaire	Données	s^2	s	mad	$C.V.$	EIQ	R
$x_i = y_i$	{ 25, 8, 14, 33, 16 }	96,7	9,8	11,9	0,51	11	25
$x_i = y_i - 14$	{ 11, -6, 0, 19, 2 }	96,7	9,8	11,9	1,89	11	25
$x_i = y_i - 19.2$	{ 5,8, -11,2, -5,2, 13,8, -3,2 }	96,7	9,8	11,9	1.4×10^{16}	11	25
$x_i = 3y_i$	{ 75, 24, 42, 99, 48 }	870,3	29,5	35,6	0,51	33	75
$x_i = -3y_i$	{ -75, -24, -42, -99, -48 }	870,3	29,5	35,6	-0,51	33	75

Notez la très grande valeur du coefficient de variation sur la troisième ligne. Elle est causée par une moyenne très près de zéro pour ces données.

2.3.3 Mesures de forme

Quant on parle de mesures de forme, on fait généralement référence au coefficient d'asymétrie et au coefficient d'aplatissement. On ne présentera ici que le premier.

Coefficient d'asymétrie d'un échantillon

Le **coefficient d'asymétrie** (en anglais : *skewness coefficient*) mesure à quel point la distribution des valeurs échantillonnelles s'éloigne de la symétrie parfaite. Il existe plusieurs définitions mathématiques de ce coefficient échantillonnal ; voici la définition utilisée dans le logiciel SAS :

$$b_1 = \frac{n}{(n-1)(n-2)} \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

Ce nombre peut être positif ou négatif, le signe étant fortement déterminé par les grandes déviations de la forme $x_i - \bar{x}$.

Une forte asymétrie à gauche, c'est-à-dire une plus grande dispersion du côté gauche de la médiane, se traduit généralement par un coefficient négatif. En effet, lorsque les observations sont plus concentrées du côté droit, la moyenne sera plus petite que ces valeurs tout en étant proche de celles-ci, ce qui donnera plusieurs petites valeurs positives de $(x_i - \bar{x})^3$, en même temps que quelques très grandes valeurs négatives de $(x_i - \bar{x})^3$. Comme ces valeurs négatives seront dominantes, l'ensemble produira généralement un coefficient d'asymétrie négatif.

De la même façon, une asymétrie à droite entraînera généralement un coefficient d'asymétrie positif.

Par ailleurs, un échantillon présentant une forte symétrie par rapport à $\bar{x}$ aura un coefficient d'asymétrie proche de 0, puisque les valeurs négatives de $(x_i - \bar{x})^3$ ont alors tendance à être équilibrées par les valeurs positives de $(x_i - \bar{x})^3$.

Tableau récapitulatif :

signe de b_1	asymétrie	distribution	$\bar{x}$ vs $\tilde{x}$
≈ 0	aucune		$\bar{x} \approx \tilde{x}$
positif	à droite		$\bar{x} > \tilde{x}$
négatif	à gauche		$\bar{x} < \tilde{x}$

On s'entend souvent pour dire qu'une valeur échantillonnale du coefficient d'asymétrie comprise entre -0,7 et 0,7 est un signe d'une distribution assez symétrique dans la population.

Exemple 2.11. Soient les observations 1, 1, 1, 1, 2, 6 (asymétrie à droite). Alors $\bar{x} = 2$, $s^2 = 4$ et les $(x_i - \bar{x})^3$ valent respectivement -1, -1, -1, -1, 0, 64, et donc

$$b_1 = \frac{n}{(n-1)(n-2)} \frac{\sum_i (x_i - \bar{x})^3}{s^3} = \frac{6}{5,4} \times \frac{60}{2^3} = 2,25.$$

On pourra vérifier que l'échantillon -1, -1, -1, -1, -2, -6, identique au précédent sauf une multiplication par -1, a le coefficient d'asymétrie $b_1 = -2,25$.

Remarque 2.9. Sans nécessairement calculer la valeur du coefficient d'asymétrie, ce qui peut être compliqué si on n'a pas accès à la technologie appropriée, il est intéressant d'analyser la symétrie de la distribution, ce qu'on pourra faire à l'aide de graphiques présentés à la section 2.6.2.

Impact d'une transformation linéaire des données

On notera que le fait d'ajouter une même constante à tous les points d'un échantillon n'a aucun effet sur le coefficient d'asymétrie ; il en est de même si on multiplie tous les points d'un échantillon par la même constante positive. La multiplication des données par une constante négative va changer le signe du coefficient d'asymétrie.

2.4 Résumés numériques pour deux variables

Pour décrire la relation entre deux variables, on utilisera des statistiques descriptives bivariées. Différentes statistiques peuvent être utilisées ; on les présentera ici séparément selon le type de variables en jeu :

- Deux variables catégoriques ou numériques discrètes
 - Fréquences croisées
 - Fréquences marginales
 - Fréquences conditionnelles
 - Fréquences relatives
- Une variable catégorique ou numérique discrète et une variable numérique
 - Statistiques conditionnelles
- Deux variables numériques
 - Coefficient de corrélation de Pearson
 - Coefficient de corrélation de Spearman

Ces statistiques nous permettront d'étudier la relation entre les deux variables. Si les valeurs de la première variable semblent affectées par les valeurs de la seconde variable, nous dirons que les variables semblent **dépendantes**. À l'inverse, si on n'observe pas de lien entre les deux variables, nous dirons qu'elles semblent **indépendantes**.

Remarque 2.10. *Attention ! Il faut bien distinguer ce qu'on peut dire sur la dépendance entre des variables aléatoires à partir de leurs distributions, et ce qu'on peut dire sur la dépendance entre des variables aléatoires à partir d'observations réalisées sur celles-ci. Considérons par exemple deux variables aléatoires discrètes X et Y . Si on connaît la distribution conjointe $p(x, y)$ et les distributions marginales $p(x)$ et $p(y)$, alors on peut vérifier mathématiquement si les deux variables aléatoires sont indépendantes. En effet, on se rappelle que ce sera le cas si $P(X = x, Y = y) = P(X = x)P(Y = y)$ pour tout (x, y) , ou encore si $P(X = x|Y = y) = P(X = x)$ pour tout x, y . Si on a seulement des observations de ces deux variables aléatoires, alors la conclusion ne sera pas si simple. On pourra regarder les fréquences relatives conditionnelles (voir section XXX), mais celles-ci pourraient par hasard sembler montrer une dépendance alors que les variables aléatoires sous-jacentes sont indépendantes. Des tests statistiques pourront être utilisés pour conclure sur les distribution des variables aléatoires à partir de données observées. On y reviendra à la section XXX.*

2.4.1 Deux variables catégoriques ou numériques discrètes

Nous décrivons d'abord les quatre types de fréquences. Un exemple suivra.

Fréquences croisées

Pour un couple de variables catégoriques ou numériques discrètes possédant un nombre limité de modalités, on calcule des *fréquences croisées*. Soit $A_1, \dots, A_I$ les modalités de la première variable (X) et $B_1, \dots, B_J$ les modalités de la deuxième variable (Y). Les fréquences croisées sont la plupart du temps représentées dans un tableau comme suit :

$X \backslash Y$	B_1	$\dots$	B_j	$\dots$	B_J	Total
A_1	n_{11}	$\dots$	n_{1j}	$\dots$	n_{1J}	$n_{1\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
A_i	n_{i1}	$\dots$	n_{ij}	$\dots$	n_{iJ}	$n_{i\bullet}$
$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
A_I	n_{I1}	$\dots$	n_{Ij}	$\dots$	n_{IJ}	$n_{I\bullet}$
Total	$n_{\bullet 1}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet J}$	$n_{\bullet\bullet}$

Pour $i = 1, \dots, I$ et $j = 1, \dots, J$, la fréquence n_{ij} est le nombre d'observations dans l'échantillon pour lesquelles X appartient à la classe A_i et Y appartient à la classe B_j simultanément.

Le nombre total d'observations dans l'échantillon est égal à

$$n = n_{\bullet\bullet} = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$$

Fréquences marginales

Les *fréquences marginales* apparaissent également dans le tableau présenté plus haut. Il s'agit des valeurs dans la ligne et la colonne « Total » du tableau. Il s'agit en fait des fréquences univariées vues à la section 2.2.1, soit le nombre d'observations dans l'échantillon appartenant à chacune des modalités, et ce séparément pour chacune des deux variables.

Dans un cadre bivarié, les fréquences marginales peuvent se calculer à partir des fréquences croisées :

$$n_{i\bullet} = \sum_{j=1}^J n_{ij} \text{ et } n_{\bullet j} = \sum_{i=1}^I n_{ij}$$

Fréquences conditionnelles

La *fréquence conditionnelle* est la fréquence d'une variable lorsque l'autre variable est fixée à une certaine modalité. Par exemple, les fréquences de X lorsque $Y = B_2$ sont $n_{12}, n_{22}, \dots, n_{I2}$. Une ligne ou une colonne à l'intérieur du tableau de fréquences croisées représente donc un groupe de fréquences conditionnelles.

Fréquences relatives

Pour une seule variable, on avait les fréquences et les fréquences relatives. On a maintenant des *fréquences relatives croisées, marginales et conditionnelles*.

- Les fréquences relatives croisées sont définies par

$$f_{ij} = n_{ij}/n \text{ pour } i = 1, \dots, I \text{ et } j = 1, \dots, J.$$

La fréquence relative croisée f_{ij} donne la proportion d'observations dans l'échantillon pour lesquelles la variable X prend la valeur A_i et la variable Y prend la valeur B_j .

- Les fréquences relatives marginales se calculent par

$$f_{i\bullet} = n_{i\bullet}/n \text{ pour } i = 1, \dots, I$$

et

$$f_{\bullet j} = n_{\bullet j}/n \text{ pour } j = 1, \dots, J.$$

Il s'agit des fréquences relatives univariées pour chacune des deux variables.

- Les fréquences relatives conditionnelles de X lorsque $Y = B_j$ sont définies par

$$f_{i,Y=B_j} = n_{ij}/n_{\bullet j} \text{ pour } i = 1, \dots, I$$

et les fréquences relatives conditionnelles de Y lorsque $X = A_i$ par

$$f_{X=A_i,j} = n_{ij}/n_{i\bullet} \text{ pour } j = 1, \dots, J.$$

La valeur $f_{i,Y=B_j}$ est la proportion des observations de l'échantillon pour lesquelles la variable X prend la valeur A_i , parmi celles pour lesquelles la variable Y prend la valeur B_j . Les $f_{X=A_i,j}$ s'interprètent similairement, en échangeant le rôle des variables X et Y .

Indépendance

Les fréquences relatives conditionnelles nous informent sur la dépendance entre les deux variables. En effet, on dira que deux variables nous semblent indépendantes si les fréquences relatives conditionnelles d'une variable ne varient pas beaucoup selon la valeur de l'autre variable. C'est-à-dire que les fréquences $f_{i,Y=B_1}$ sont semblables aux fréquences $f_{i,Y=B_2}$, et aux fréquences $f_{i,Y=B_3}$ et ainsi de suite jusqu'à $f_{i,Y=B_J}$, ou encore que les fréquences $f_{X=A_1,j}$ sont semblables aux fréquences $f_{X=A_2,j}$, et aux fréquences $f_{X=A_3,j}$ et ainsi de suite jusqu'à $f_{X=A_I,j}$. On verra au chapitre 5 comment valider la dépendance entre deux variables catégoriques à l'aide d'un test statistique.

Exemple 2.12. *Considérons 7 individus ayant participé à une étude où certains prenaient des vitamines durant l'hiver, d'autres non. On a noté si les individus avaient attrapé la grippe durant l'hiver.*

Observations :			Fréquences croisées et marginales :			
Patient	État	Vitamines	État \ Vitamines	oui	non	total
1	malade	oui	malade	1	2	3
2	malade	non	santé	3	1	4
3	santé	oui	total	4	3	7
4	malade	non				
5	santé	non				
6	santé	oui				
7	santé	oui				

Fréquences relatives conditionnelles :

- En conditionnant par rapport à l'état du patient :
 3/4 des patients en santé ont pris des vitamines, 1/4 n'en ont pas pris ;
 1/3 des patients malades ont pris des vitamines, 2/3 n'en ont pas pris.
- Ou encore, en conditionnant par rapport à la prise de vitamines :
 1/4 des patients prenant des vitamines sont malades, 3/4 sont en santé ;
 2/3 des patients ne prenant pas de vitamines sont malades, 1/3 en santé.

Puisque les fréquences relatives d'une variable changent beaucoup selon la modalité que prend l'autre variable, il y a possiblement une dépendance entre les variables. Mais avec 7 observations seulement, il sera difficile d'établir même avec le test qui sera présenté au chapitre 5 si cela est dû au hasard, ou s'il y a vraiment une dépendance entre les variables.

2.4.2 Une variable catégorique et une variable numérique

Afin de décrire le lien entre une variable catégorique et une variable numérique, il suffit de calculer des statistiques descriptives univariées sur la variable numérique pour chacune des modalités de la variable catégorique. Il s'agit en fait de *statistiques conditionnelles* puisque la modalité de la variable catégorique est fixée. Par exemple, si un jeu de données contient les variables sexe et grandeur, il serait pertinent de calculer des moyennes, des écarts-types et des coefficients de variation sur la variable grandeur pour les hommes et les femmes séparément.

Indépendance : Si les statistiques calculées sur la variable numérique sont assez semblables entre les différentes modalités de la variable catégorique, nous dirons que les deux variables semblent indépendantes. Des investigations plus poussées devraient être menées pour se prononcer plus objectivement. Si la variable catégorique ne contient que deux catégories, on pourrait par exemple utiliser un test de comparaison de moyennes, dont on reparlera au chapitre 3. Pour une variable avec plus de catégories, une analyse appropriée est l'analyse de la variance, que nous ne verrons toutefois pas dans le cours.

Exemple 2.13. *On a mesuré la taille de quelques arbres d'espèces différentes et situés à des emplacements différents. La mesure de taille est leur diamètre à hauteur de poitrine, dénoté dhp . Données brutes :*

<i>Espèce</i>	<i>Emplacement</i>	<i>dhp (cm)</i>
<i>érable</i>	<i>A</i>	<i>50,1</i>
<i>sapin</i>	<i>A</i>	<i>13,2</i>
<i>érable</i>	<i>B</i>	<i>42,5</i>
<i>érable</i>	<i>A</i>	<i>37,3</i>
<i>sapin</i>	<i>B</i>	<i>20,4</i>
<i>sapin</i>	<i>B</i>	<i>15,6</i>

Statistiques conditionnelles :

<i>Espèce</i>	$\bar{x}$	s	C.V.	<i>Emplacement</i>	$\bar{x}$	s	C.V.
<i>érable</i>	43,3	6,44	0,15	<i>A</i>	33,53	18,74	0,55
<i>sapin</i>	16,4	3,66	0,22	<i>B</i>	26,16	14,35	0,54

On observe moins de différences pour le dhp entre les emplacements qu'entre les espèces. Il y a donc une dépendance potentielle entre l'espèce et le dhp (en terme de moyennes surtout). Par contre, la dépendance entre l'emplacement et le dhp semble très faible, surtout lorsqu'on note que l'écart-type représente plus de 50% de la moyenne. Notez qu'ici un autre échantillon pourrait nous donner des résultats très différents, le nombre d'observations étant très petit.

2.4.3 Deux variables numériques

On peut caractériser le lien entre deux variables numériques X et Y par des mesures bivariées, comme la corrélation. Nous présentons ici le coefficient de corrélation (linéaire) de Pearson et le coefficient de corrélation (par les rangs) de Spearman. Il existe d'autres coefficients de corrélation, par exemple le tau de Kendall, dont nous ne parlerons pas ici.

Coefficient de corrélation de Pearson

La *corrélation de Pearson* se définit par :

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{(n-1)s_x s_y}$$

où x_i et y_i sont les valeurs des variables X et Y pour chacune des observations d'un jeu de données ($i = 1, \dots, n$), et $\bar{x}$, $\bar{y}$, s_x et s_y sont les moyennes et écarts-types échantillonnaires des x_i et y_i respectivement.

Le coefficient de corrélation r peut prendre des valeurs entre -1 et 1. Plus la valeur de r est proche de 1 en valeur absolue, plus la relation **linéaire** entre les variables est forte. À l'opposé, une corrélation nulle désigne une absence de relation linéaire entre les variables. Le signe de r décrit le type de relation entre les variables. Si r est positif et près de 1, nous dirons que les variables sont associées positivement. Cela signifie que plus la valeur d'une variable est grande, plus la valeur de l'autre variable tend à être grande aussi. Une association négative, représentée par un r négatif, signifie plutôt que plus la valeur d'une variable est grande, plus la valeur de l'autre variable tend à être petite.

Impact d'une transformation linéaire des données

Le coefficient de corrélation de Pearson reste inchangé lors de l'addition d'une constante, positive ou négative, à toutes les valeurs d'une variable ou même des deux variables. De même, la multiplication des valeurs par une constante positive n'affecte pas le coefficient. Par contre, si une seule des deux variables est multipliée par une constante négative, le coefficient changera de signe.

Exemple 2.14. Voici un jeu de données fictives de six observations. Pour chaque individu, on a le nombre d'années d'expérience, son salaire, et une mesure de motivation sur une échelle de 1 à 10.

Individu i	X =Expérience (ans)	Y =Salaire (\$)	Z =Motivation (1 à 10)	Exp *Salaire $x_i \times y_i$	Exp *Motiv $x_i * z_i$
1	10	46 000	7	460 000	70
2	2	35 000	8	70 000	16
3	5	40 000	10	200 000	50
4	20	58 000	4	116 000	80
5	15	47 000	6	705 000	90
6	31	62 000	5	1 922 000	155
Total	83	288 000	40	4 517 000	461

Expérience (X) par rapport au salaire (Y) :

$$\bar{x} = 13,83, s_x = 10,65, \bar{y} = 48000, s_y = 10334,11, \sum_{i=1}^n x_i y_i = 4\,517\,000$$

$$r = \frac{4\,517\,000 - 6 \cdot 13,83 \cdot 48000}{5 \cdot 10,65 \cdot 10334,41} = 0,969$$

Expérience (X) par rapport à la motivation (Z) :

$$\bar{x} = 13,83, s_x = 10,65, \bar{z} = 6,670, s_z = 2,16, \sum_{i=1}^n x_i z_i = 461$$

$$r = \frac{461 - 6 \cdot 13,82 \cdot 6,67}{5 \cdot 10,65 \cdot 2,16} = -0,803$$

Ces corrélations semblent indiquer que le salaire augmente linéairement en fonction de l'expérience, mais que la motivation diminue linéairement avec l'expérience.

Remarque 2.11. Méthode du rectangle Le calcul du coefficient de corrélation peut être long à faire à la main. Bien que plusieurs calculatrices et logiciels puissent le calculer rapidement, on suggère dans plusieurs manuels destinés à l'enseignement au secondaire de l'estimer à l'aide de la méthode du rectangle. Cette méthode d'estimation du coefficient de corrélation de Pearson est toutefois imprécise, et largement influencée par les données aberrantes et le choix des axes du graphique.

Coefficient de corrélation de Spearman

Le coefficient de corrélation de Spearman mesure si deux variables ont tendance à augmenter et diminuer simultanément, sans que le lien entre les deux variables ne soit nécessairement linéaire. On le calcule simplement en utilisant la formule de Pearson, mais en remplaçant les observations par leur rang. Si plusieurs observations ont la même valeur pour une même variable, on attribuera à ces observations leur rang moyen.

La notion de relation mesurée par le coefficient de corrélation de Spearman est plus générale que le coefficient de Pearson, mais il existe d'autres coefficients de corrélation qui mesurent encore plus généralement la dépendance entre deux variables.

Exemple 2.15. Reprenons l'exemple 2.14.

Individu i	$\text{rang}(\text{Expér.})$ (rx_i)	$\text{rang}(\text{Sal.})$ (ry_i)	$\text{rang}(\text{Motiv.})$ (rz_i)	$rx_i \times ry_i$	$rx_i \times rz_i$
1	3	3	4	9	12
2	1	1	5	1	5
3	2	2	6	4	12
4	5	5	1	25	5
5	4	4	3	16	12
6	6	6	2	36	12
Total	21	21	21	91	58

Expérience (X) par rapport au salaire (Y) :

$$\bar{rx} = 3,5, s_{rx} = 1,87, \bar{ry} = 3,5, s_{ry} = 1,87, \sum_{i=1}^n rx_i ry_i = 91$$

$$r_{\text{spearman}} = \frac{91 - 6 \cdot 3,5 \cdot 3,5}{5 \cdot 1,87 \cdot 1,87} = 1,00$$

Expérience (X) par rapport à la motivation (Z) :

$$\bar{rx} = 3,5, s_{rx} = 1,87, \bar{rz} = 3,5, s_{rz} = 1,87, \sum_{i=1}^n rx_i rz_i = 58$$

$$r_{\text{spearman}} = \frac{58 - 6 \cdot 3,5 \cdot 3,5}{5 \cdot 1,87 \cdot 1,87} = -0,889$$

La corrélation de Spearman montre une relation monotone parfaite entre l'expérience et le salaire et une très forte relation négative entre l'expérience et la motivation.

2.5 Représentations graphiques - principes généraux

Le calcul des mesures numériques de localisation, de variabilité et de forme fait partie d'une analyse statistique standard de données. Une telle analyse est cependant incomplète si on ne l'accompagne pas d'une représentation visuelle des données à l'aide de graphiques. Les graphiques ont l'avantage de faire ressortir simultanément plusieurs caractéristiques d'un échantillon, de manière simple et très directe. L'éventail des graphiques est considérable. Le choix d'un graphique dépend du type de variables étudiées ainsi que du genre d'analyse que l'on souhaite faire.

Selon Jacoby (1997)³, la représentation graphique a quatre utilités principales en statistique :

1. l'exploration du contenu d'un jeu de données ;
2. la recherche de structures dans des données ;
3. la vérification des postulats d'un modèle ;
4. la communication des résultats d'une analyse statistique.

À partir des graphiques, on peut remarquer des structures dans les données, telles une certaine distribution ou encore une forme particulière de relation entre deux variables (linéaire, quadratique, exponentielle, etc.). Ces structures vont guider le choix de méthodes statistiques à employer pour analyser les données. En ce sens, il est toujours pertinent de faire une étude exploratoire de données avant de mener une analyse statistique.

De plus, si nous ajustons un modèle aux données, il sera toujours prudent de vérifier les postulats de ce modèle. Les représentations graphiques sont alors un outil incontournable.

3. Jacoby, W. G. (1997). *Statistical Graphics for Univariate and Bivariate Data*, Quantitative applications in the social sciences, Vol 117. Sage Publications, Inc.

Principes de base de la conception de graphiques

Pour faire de bons graphiques, il faut d'abord savoir identifier l'information importante à présenter et choisir le bon type de graphique pour mettre en lumière cette information. Les sections suivantes présentent différents types de graphiques, qui dépendent notamment du type de variables à représenter. Présentons d'abord les éléments clés composant tout graphique, peu importe son type.

Région graphique : C'est dans la région graphique que se retrouve le diagramme à proprement parler. Si le graphique comporte des axes, ce sont eux qui délimitent la région graphique. Notons que certaines informations importantes peuvent se retrouver en marge de cette région, par exemple un titre ou une légende.

Titre : Tout graphique doit comporter un titre informatif. Un bon titre ne devrait pas nommer le type du graphique (histogramme, diagramme à bandes, etc.), mais plutôt ce qu'il cherche à représenter (distribution de X , relation entre X et Y , etc.). Le titre se retrouve parfois au-dessus du graphique et parfois en-dessous.

Axes : À quelques exceptions près (ex. diagrammes en secteurs), toute représentation graphique comporte un ou des axes. Ces axes doivent toujours être identifiés par un nom informatif. Ils doivent toujours comporter une échelle, la plus claire possible. Une échelle trop grande dépassant l'intervalle des valeurs possibles d'une variable produira un graphique dans lequel l'information sera trop condensée en une sous-région pour être lisible. Si deux graphiques sont placés côte à côte à des fins de comparaison, ces derniers doivent généralement être basés sur la même échelle.

Légende : Pour certains graphiques, il est nécessaire d'inclure une légende pour identifier des groupes de données. Cette légende est parfois intégrée dans la région graphique mais elle se retrouve parfois en marge du graphique.

Le choix d'éléments de mise en forme d'un graphique, tels les couleurs, les symboles utilisés pour représenter des points, les types de ligne (pleine, pointillée, etc.), la police, la taille et l'orientation des caractères des différents éléments textuels, n'est pas à négliger si l'on veut produire un graphique clair. Par contre, nous n'énoncerons pas ici de règles strictes concernant ces éléments. Les meilleurs choix varient en fonction de la situation et demeurent subjectifs, mais notons qu'un excès de fioritures camoufle souvent l'essentiel. En ce sens, produire un bon graphique est un art. Il faut toujours utiliser son gros bon sens et garder en tête le but visé par le graphique.

2.6 Représentations graphiques pour une variable

2.6.1 Une variable catégorique ou numérique discrète

Les deux types de graphiques les plus utilisés pour les variables catégoriques ou numériques discrètes comprenant un petit nombre de valeurs possibles sont

1. le diagramme en secteurs
(ou diagramme en Camembert ou en pointes de tarte), et
2. le diagramme en bâtons (ou diagramme à bandes)

Les deux jeux de données suivants seront utilisés pour illustrer ces types de graphiques, l'un montrant une variable catégorique, l'autre une variable numérique discrète.

Jeu de données 1. Moyens de transport d'un groupe d'étudiants pour se rendre à l'université

Modalité C_j	Fréquence n_j	Fréquence relative f_j
Auto	51	0,23
Autobus	64	0,29
Marche	92	0,40
Moto	6	0,03
Vélo	11	0,05
Total	$n = 224$	$\sum f_j = 1$

Jeu de données 2. On lance un groupe de 5 dés à 100 reprises. Pour chaque lancer, on mesure la variable X définie par le nombre de 2 obtenus. Les valeurs possibles de X sont 0, 1, 2, 3, 4, 5.

Valeur x_j	Fréquence n_j	Fréquence relative f_j
0	32	0,32
1	42	0,42
2	18	0,18
3	3	0,03
4	3	0,03
5	2	0,02
Total	$n = 100$	$\sum f_j = 1$

Nous présenterons également un autre diagramme qui peut être utilisé pour ce type de données, soit le diagramme à pictogrammes.

Diagramme en secteurs

Dans un diagramme en secteurs, chaque modalité est représentée par un secteur circulaire dont **l'angle au centre est proportionnel à la fréquence** de cette modalité. Les exemples de la figure 2.4 montrent qu'on peut indiquer les noms des modalités directement sur le graphique ou dans une légende, et qu'on peut inclure ou pas les fréquences (absolues ou relatives) des différentes modalités.




FIGURE 2.4 – Exemples de (plus ou moins bons) diagrammes en secteurs

Ce type de graphique devrait toutefois être utilisé avec parcimonie. Il est difficile à lire si la variable a plus de quelques modalités. Les exemples ci-dessus sont d'ailleurs déjà un peu surchargés. De plus, il n'est pas approprié si on peut ordonner naturellement les modalités de la variable, auquel cas le diagramme à bâtons permet de plus facilement mettre cet ordre en évidence. Plus généralement, le diagramme en secteurs est à éviter car il a été prouvé que l'oeil est bon pour juger des mesures linéaires, mais mauvais pour comparer des aires.

Remarque 2.12. *Certains artifices nuisent encore davantage à l'interprétation, notamment l'effet 3D, la séparation des pointes de tartes ou les secteurs représentés par des tons d'une même couleur. Voici deux exemples :*




FIGURE 2.5 – Exemples de mauvais diagrammes en secteurs

Diagramme en bâtons, ou diagramme à bandes

Le diagramme en bâtons est le diagramme à privilégier pour une variable catégorique ou numérique discrète. Chaque modalité est représentée par un rectangle (ou bâton) dont **la hauteur est proportionnelle à la fréquence** (ou fréquence relative) de cette modalité et dont la largeur est la même pour toutes les modalités. Les bâtons doivent être disjoints pour ne pas confondre ce diagramme avec un histogramme, utilisé pour représenter la distribution d'une variable continue.

Les deux graphiques de la figure 2.6 montrent que les rectangles peuvent être placés verticalement ou horizontalement, être très séparés ou peu, que l'axe peut représenter les fréquences absolues ou relatives, et que les bâtons peuvent être de couleurs différentes ou non. Il est toutefois mieux d'utiliser une seule couleur, sauf si les couleurs ont un sens particulier, par exemple les couleurs associées à différents partis politiques dans un graphique représentant les intentions de vote.




FIGURE 2.6 – Exemples de diagrammes en bâtons

Notons toutefois que l'axe des fréquences doit absolument commencer à 0, pour éviter des distorsions dans l'interprétation. En effet, la longueur des rectangles doit être proportionnelle à la fréquence (absolue ou relative). Ainsi, une bande deux fois plus grande qu'une autre indiquera une fréquence deux fois plus grande.

Notons aussi que l'ordre dans lequel les différentes modalités sont présentées peut influencer l'interprétation du graphique. Il vaut donc la peine d'y réfléchir. On devrait utiliser l'ordre naturel des modalités si applicable. Sinon, l'ordre alphabétique est souvent approprié, mais on peut aussi vouloir placer côte à côte les catégories plus similaires. L'important est de faciliter la lecture du graphique.

Diagramme à pictogrammes

En statistique, on parle de diagramme à pictogrammes (ou simplement de pictogramme) quand on représente graphiquement une ou des variables aléatoires à l'aide de signes ou de dessins. Par exemple, à la figure 2.7 on présente la variable catégorique *Marque du véhicule* dans un graphique qui ressemble à un diagramme à bâtons mais dans lequel les bâtons sont remplacés par une série de petites voitures.




FIGURE 2.7 – Exemple de pictogramme

Un dessin, ou pictogramme, peut représenter plus d'une unité, comme c'est le cas ici. Cela permet d'illustrer des nombres assez grands sans surcharger le graphique. Toutefois, il devient plus complexe de présenter des valeurs qui ne sont pas des multiples de la valeur représentée par le pictogramme. Ainsi, s'il y avait 12 voitures de marque Honda dans le stationnement, il aurait fallu ajouter un dessin de $2/5 = 40\%$ d'une voiture suite aux deux déjà présentes.

Remarque 2.13. *Le diagramme à bandes se prête particulièrement bien à une représentation à l'aide de pictogrammes, mais on voit parfois d'autres types de graphiques statistiques créés à l'aide de pictogrammes. Il n'y a pas vraiment de règles sur ce qu'on peut faire ou pas, mais dans tous les cas il faut s'assurer que le diagramme est une représentation juste de la ou des variables statistiques. Par exemple, il faut s'assurer que les dessins sont proportionnels aux valeurs qu'ils représentent.*

2.6.2 Une variable numérique

Pour la représentation d'une variable continue ou d'une variable discrète ayant un grand nombre de valeurs possibles, nous présentons trois types de graphiques :

1. l'histogramme,
2. le diagramme à tiges et à feuilles, et
3. le diagramme en boîte (*boxplot*).

Histogramme

Le graphique le plus utilisé pour représenter des variables continues est l'*histogramme*, qui est similaire au diagramme à bandes, mais avec des rectangles collés. C'est un outil très flexible permettant de se faire une bonne idée de la localisation et de la variabilité de la distribution des observations, et illustrant la forme approximative de la fonction de densité de la variable représentée.

Pour créer un histogramme on divise l'ensemble des valeurs de la variable en intervalles disjoints contigus recouvrant la totalité de cet ensemble. Toutes les valeurs appartenant à un même intervalle sont alors regroupées, faisant ainsi de chaque intervalle une modalité.

Le nombre d'intervalles (K) et leur longueur sont généralement arbitraires. Leur choix influence toutefois de manière importante la représentation graphique.

Après avoir choisi les intervalles et calculé pour chacun la fréquence, on ramène les données brutes à un tableau de fréquences de la forme suivante :

Classe	Intervalle	Fréquence n_j	Fréquence relative f_j
1	$[a_0, a_1)$	n_1	f_1
2	$[a_1, a_2)$	n_2	f_2
...	...	...	...
K	$[a_{K-1}, a_K)$	n_K	f_K
		$n = \sum_j n_j$	$\sum f_j = 1$

L'histogramme est ensuite construit de telle sorte que la **surface d'un rectangle est proportionnelle à la fréquence de la classe** qu'il représente. La hauteur de chaque rectangle dépend donc de la fréquence de la classe qu'il représente, et de la largeur de la classe. Si les classes sont de même largeur, la hauteur du rectangle sera simplement proportionnelle à la fréquence de la classe. On verra sous peu comment gérer les classes de largeurs inégales. Notons qu'ici aussi l'axe des y doit obligatoirement commencer à 0.

Exemple 2.16. Échantillon ordonné du poids (en mg) de 34 pucerons adultes

0,781	0,956	1,016	1,056	1,149	1,388	1,619
0,917	0,984	1,021	1,081	1,162	1,428	1,700
0,945	0,994	1,030	1,086	1,171	1,493	1,768
0,953	0,996	1,049	1,105	1,199	1,519	1,794
0,954	0,996	1,049	1,131	1,244	1,595	

On peut construire un histogramme en répartissant les données en 6 intervalles de largeur égale :

Poids des pucerons	Fréquence n_j
$[0,6, 0,8)$	1
$[0,8, 1,0)$	9
$[1,0, 1,2)$	14
$[1,2, 1,4)$	2
$[1,4, 1,6)$	4
$[1,6, 1,8]$	4




FIGURE 2.8 – Exemple de tableau de fréquences et d’histogramme

On pourrait aussi subdiviser les observations en 11 intervalles allant de $[0,7, 0,8)$ à $[1,7, 1,8]$. La figure 2.9 montre l’histogramme obtenu. On voit par cet exemple l’importance du choix du nombre d’intervalles sur l’information fournie par l’histogramme.




FIGURE 2.9 – Résultat d’un changement du nombre d’intervalles

Classes de largeurs inégales

Pour certains types de données, il est souhaitable de définir des intervalles de longueurs inégales, par exemple lorsqu'il y a de fortes concentrations de valeurs autour de certains points. Ou encore si on n'a pas accès aux données brutes, mais seulement au nombre d'observations dans différents intervalles et que ceux-ci sont inégaux. Il faut alors faire attention pour que la surface des rectangles soit proportionnelle à la fréquence des classes.

Mathématiquement, si on pose $b_j = (a_j - a_{j-1})$ comme la base du rectangle j , l'histogramme est construit en élevant au-dessus du j^e intervalle un rectangle de hauteur h_j tel que l'aire $b_j h_j$ est proportionnelle à la fréquence n_j . Cela signifie qu'on choisit une constante c propre à chaque histogramme telle que

$$b_j h_j = c n_j.$$

On a alors

$$h_j = \frac{c n_j}{b_j}.$$

Peu importe le choix de la constante de proportionnalité c , toutes ces représentations ont la même apparence et sont donc équivalentes. Seule l'échelle de l'axe vertical varie. Voici quelques exemples fréquents.

1. Histogrammes avec la fréquence absolue sur l'axe vertical

Pour la plupart des classes, on veut $h_j = n_j$. Si les classes sont de largeur égale ($b_j = b$), on aura $b h_j = b n_j = c n_j$ et donc $c = b$. Sinon, on choisira la largeur la plus fréquente pour déterminer la valeur de c .

2. Histogrammes avec la fréquence relative sur l'axe vertical

Pour la plupart des classes, on veut $h_j = n_j/n$. Si les classes sont de largeur égale ($b_j = b$), on aura $b h_j = b n_j/n = c n_j$ et donc $c = b/n$. Sinon, on choisira la largeur la plus fréquente et on divisera sa fréquence par n pour déterminer la valeur de c .

3. Histogrammes avec la densité sur l'axe vertical

Si on veut représenter approximativement la fonction de densité avec un histogramme, on veut que la surface totale des rectangles soit de 1, c'est-à-dire $\sum_{j=1}^K b_j h_j = \sum_{j=1}^K c n_j = 1$. Puisque $\sum_{j=1}^K n_j/n = 1$, il suit que $c = 1/n$ et $h_j = \frac{n_j b_j}{n}$.

Exemple 2.17. Reprenons l'exemple précédent, mais en combinant les deux dernières classes en une classe plus grande. La table ci-dessous donne les hauteurs à utiliser pour les trois différentes versions d'histogrammes présentées pour des classes inégales. Le détail des calculs suit, puis les graphiques.

Poids des pucerons	Fréquence n_j	Largeur b_j	Hauteur fréq. absolue	Hauteur fréq. relative	Hauteur densité
[0,6 , 0,8)	1	0,2	1	1/34	5/34
[0,8 , 1,0)	9	0,2	9	9/34	45/34
[1,0 , 1,2)	14	0,2	14	14/34	70/34
[1,2 , 1,4)	2	0,2	2	2/34	10/34
[1,4 , 1,8)	8	0,4	4	4/34	20/34

TABLE 2.1 – Hauteurs des bandes pour les trois variantes d'histogramme

Histogramme avec la fréquence absolue sur l'axe vertical

La largeur la plus fréquente est 0,2. On choisit donc la constante $c = 0,2$, ce qui donne $h_j = 0,2 \frac{n_j}{b_j}$. On voit que la hauteur est égale à la fréquence pour toutes les classes de largeur 0,2 car dans ce cas $0,2/b_j = 1$. La dernière classe étant deux fois plus large, sa hauteur est deux fois plus petite que la fréquence dans cette classe pour que la surface du rectangle soit proportionnelle à la fréquence de la classe.

Histogramme avec la fréquence relative sur l'axe vertical

On utilise toujours $b = 0,2$, mais ici $c = b/n = 0,2/34 = 1/170 \approx 0,00588$. On peut alors calculer la hauteur de chacune des bandes par $h_j = \frac{0,2}{34} \frac{n_j}{b_j}$. Pour toutes les classes avec $b_j = 0,2$, on a $h_j = n_j/34$, soit la fréquence relative. La dernière classe étant deux fois plus large, sa hauteur est deux fois plus petite que la fréquence relative dans cette classe pour que la surface du rectangle soit proportionnelle à la fréquence de la classe.

Histogramme avec la densité sur l'axe vertical

Dans ce cas, $c = 1/n = 1/34$. On a donc $h_j = \frac{1}{34} \frac{n_j}{b_j}$. La hauteur de la bande est donc égale à la fréquence relative de la classe divisée par la largeur de celle-ci, toujours pour s'assurer que la surface du rectangle soit proportionnelle à la fréquence de la classe. On peut vérifier dans ce cas qu'on a bien une surface totale unitaire :

$$\sum_{j=1}^K b_j h_j = \frac{2}{10} \frac{5}{34} + \frac{2}{10} \frac{45}{34} + \frac{2}{10} \frac{70}{34} + \frac{2}{10} \frac{10}{34} + \frac{4}{10} \frac{20}{34} = \frac{1}{34} (1 + 9 + 14 + 2 + 8) = 1.$$

Voici maintenant les trois graphiques associés :




FIGURE 2.10 – Trois versions de l’histogramme avec les mêmes classes inégales

On voit que les trois histogrammes sont visuellement identiques, sauf pour ce qui est de l’échelle de l’axe vertical. Cela est normal car dans les trois cas il faut que la surface de chaque rectangle soit proportionnelle à la fréquence de la classe.

Pour les deux premiers graphiques, on a inclut Corrigée dans le nom de l’axe des abscisses pour rappeler que puisque les classes sont inégales ce ne sont pas les fréquences absolues ou relatives exactes qui sont indiquées pour toutes les classes. Par exemple, la fréquence absolue de la dernière classe est 8, bien que la hauteur du rectangle correspondant dans le premier graphique soit de 4.

Si on avait une plus grande variabilité dans les tailles des classes, il serait encore plus dur de lire les échelles des fréquences absolues et relatives. Un histogramme représentant les densités est alors recommandé.

Diagramme à tiges et à feuilles

L'histogramme permet de bien visualiser la distribution d'une variable, mais il ne permet pas de connaître les valeurs individuelles de l'échantillon. Une variante de l'histogramme qui permet de le faire est le diagramme à tiges et à feuilles.

En effet, un diagramme à tiges et à feuilles ne résume pas vraiment les données, mais présente graphiquement toutes les valeurs de l'échantillon, de façon à voir la distribution de la variable d'intérêt. La figure 2.11 montre un exemple. La colonne de gauche s'appelle la tige, et tous les chiffres à droite de celle-ci sont les feuilles. Chaque observation correspond à la combinaison d'une feuille avec la tige à laquelle elle est rattachée. Par exemple, ici la plus petite observation est un spectateur de 17 ans. La première tige indique en fait qu'il y a deux individus de 17 ans, deux de 18 ans et un de 19 ans. La deuxième tige donne les observations dans la vingtaine, et ainsi de suite. Un peu comme le ferait un histogramme, la figure montre que la distribution des âges est unimodale, et asymétrique à droite.

Âges des spectateurs (en années)

```
1 7 7 8 8 9
2 0 0 0 1 1 1 1 2 4 5 5 6 8 8 9
3 3 3 3 5 5 7 8
4 0 1 1
5 4 5 5 6 6
6
7 4 5
```

FIGURE 2.11 – Exemple d'un diagramme à tiges et à feuilles

Dans l'exemple, la tige donne les dizaines et les feuilles les unités, mais ceci peut être modifiée. La feuille doit nécessairement ne contenir qu'un chiffre, mais la tige peut en contenir davantage, si par exemple on souhaite montrer des nombres dans les centaines. On peut également visualiser des nombres à virgule, en indiquant simplement à quelle décimale les feuilles correspondent.

Le diagramme à tiges et à feuille devient toutefois difficile à visualiser si le nombre d'observations total, ou dans une même classe, est trop grand. Bien qu'il soit peut utilisé en statistique en général, il peut être utile pour jeter un coup d'oeil aux données avant de procéder à des analyses, ou encore s'il est nécessaire de visualiser les valeurs exactes des observations.

Diagramme en boîte (boxplot, diagramme de quartiles)

Ce graphique permet de représenter simultanément les trois quartiles et les observations extérieures à l'intervalle interquartile $[Q_1, Q_3]$. Il permet de bien décrire la localisation, la variabilité, l'asymétrie, et fait aussi ressortir les observations extrêmes. On s'en sert beaucoup pour comparer la distribution d'une variable numérique dans plusieurs échantillons, en plaçant les diagrammes côte à côte.

Le centre de ce graphique est une boîte délimitée par la position des quartiles relativement à un axe gradué (vertical ou horizontal), et coupée en deux par un segment placé à la hauteur de la médiane. De chaque côté de la boîte, on trace ensuite une "moustache" (un segment de droite) :

1. à gauche jusqu'à l'observation immédiatement supérieure à $Q_1 - 1,5 \text{ EIQ}$,
2. à droite jusqu'à l'observation immédiatement inférieure à $Q_3 + 1,5 \text{ EIQ}$.

Toutes les observations à l'extérieur des moustaches sont considérées comme extrêmes et sont indiquées individuellement par un symbole comme $\circ$ ou $*$.

La figure 2.12 montre le diagramme en boîte pour les poids des 34 pucerons et un diagramme en boîte pour 1000 observations provenant d'une distribution normale de moyenne 0 et de variance 1.




FIGURE 2.12 – Diagrammes en boîte pour le poids des pucerons et pour 1000 observations d'une $N(0, 1)$

La symétrie de la distribution normale est bien visible, les deux moitiés de la boîte étant de taille similaire, et de même pour les deux moustaches. Dans le cas des poids des pucerons, on voit que la distribution est asymétrique à droite, ce qui était un peu moins évident dans les histogrammes, surtout celui avec seulement six intervalles.

2.7 Représentations graphiques illustrant le lien entre des variables

On présentera ici plusieurs représentations graphiques, selon le type de variables qu'elles permettent de représenter : deux variables catégoriques ou numériques discrètes, une variable catégorique ou numérique discrète et une variable continue, et deux variables continues.

2.7.1 Deux variables catégoriques ou numériques discrètes

On a déjà dit qu'un échantillon de deux variables catégoriques ou numériques discrètes ayant peu de modalités est résumé par un tableau de fréquences croisées. Il est souvent intéressant de l'illustrer également par un diagramme.

Ce tableau peut être représenté par

1. un diagramme en bâtons empilés,
2. un diagramme en bâtons groupés, ou
3. un diagramme en mosaïque.

Ces trois types de graphiques seront illustrés à l'aide des données ci-dessous.

Âge \ Sexe	Homme	Femme	Total
0 à 14 ans	38 140 (0,072)	36 945 (0,069)	75 085 (0,141)
15 à 64 ans	173 185 (0,326)	174 050 (0,327)	347 235 (0,653)
65 ans et plus	46 155 (0,087)	63 415 (0,119)	109 570 (0,206)
Total	257 480 (0,485)	274 410 (0,515)	531 890 (1)

TABLE 2.2 – Population en fréquences absolues (et relatives) de la ville de Québec répartie selon l'âge et le sexe (Statistique Canada, recensement 2016).

Diagramme en bâtons empilés

Dans un diagramme en bâtons empilés, de grands bâtons illustrent la fréquence marginale d'une des deux variables. Ils sont ensuite partitionnés en sections proportionnelles aux fréquences conditionnelles de l'autre variable. Ici aussi, les bâtons peuvent être présentés à la verticale ou à l'horizontale.

La figure 2.13 présente deux diagrammes en bâtons empilés créés à partir des données de l'exemple. Bien qu'ils soient construits à partir du même tableau de fréquences, et fournissent les mêmes informations, les deux graphiques ne mettent pas en évidence les mêmes aspects des données.




FIGURE 2.13 – Exemples de diagrammes en bâtons empilés

Dans le graphique de gauche :

- Les deux bâtons principaux mettent en évidence la distribution marginale du sexe. On voit qu'il y a plus de femmes que d'hommes à Québec.
- Chaque bâton est partitionné selon la distribution conditionnelle de l'âge pour chaque sexe. On remarque qu'il y a une plus grande proportion d'ânés chez les femmes que chez les hommes.

Dans le graphique de droite :

- Les trois bâtons principaux mettent en évidence la distribution marginale de l'âge. On voit que la tranche d'âge la plus peuplée est celle des 15-64 ans (normal vu l'étendue de la classe !) et qu'il y a à peine plus d'ânés que d'enfants de moins de 15 ans.
- Chaque bâton est partitionné selon la distribution conditionnelle de sexe pour chaque âge. On voit que la proportion de femmes chez les ânés est plus grande que pour les autres tranches d'âge.

Diagramme basé sur la fréquence relative conditionnelle -

Pour étudier de façon exploratoire la dépendance possible entre deux variables catégoriques ou numériques discrètes ayant peu de modalités, un bon outil est le diagramme en bâtons empilés sur l'échelle des fréquences relatives conditionnelles. La figure 2.14 reprend les diagrammes de la figure 2.13 en changeant l'échelle des fréquences par l'échelle des fréquences relatives conditionnelles.




FIGURE 2.14 – Exemples de diagrammes en bâtons empilés

Dans ce type de graphique, la longueur des grands bâtons est toujours de 1. On perd donc l'information sur les fréquences marginales.

Par contre, il devient plus facile de juger de la dépendance possible entre les variables. En effet, pour deux variables indépendantes, les grands bâtons devraient être tous subdivisés environ aux mêmes endroits. Au contraire, si les subdivisions ne sont pas à la même hauteur dans les grands bâtons, c'est un signe de dépendance entre les variables.

Dans l'exemple de la population de la ville de Québec selon l'âge et le sexe, on observe que plus la population est âgée, plus la proportion de femmes est grande (particulièrement visible dans le diagramme de droite). Il semble donc y avoir une certaine dépendance entre les variables âge et sexe.

Nous étudierons plus loin les diagrammes en mosaïque, qui permettent d'illustrer les fréquences marginales ET les fréquences relatives conditionnelles à la fois. Quand on sait comment les interpréter, ils sont plus informatifs que les diagrammes à bâtons.

Diagramme en bâtons groupés

Dans un diagramme en bâtons groupés, les bâtons sont mis côte-à-côte plutôt que d'être empilés. Ces graphiques sont pertinents si on veut mettre l'accent sur les fréquences croisées conditionnelles sans trop se soucier des fréquences marginales.

La figure 2.15 présente les diagrammes en bâtons groupés équivalents aux diagrammes de la figure 2.13.




FIGURE 2.15 – Exemples de diagrammes en bâtons groupés

Le graphique de gauche est utile pour comparer les groupes d'âge pour chaque sexe. On voit entre autres qu'il y a un peu plus d'aînés que d'enfants chez les hommes, alors qu'il y a beaucoup plus d'aînés que d'enfants chez les femmes.

Le graphique de droite permet de comparer les sexes à l'intérieur des groupes d'âge. On voit bien que plus l'âge augmente, plus la proportion d'hommes diminue.

Diagramme en mosaïque

Une autre façon de représenter les fréquences croisées de deux variables catégoriques est le diagramme en mosaïque. Ces diagrammes sont carrés, et **la surface de chaque sous-section rectangulaire est proportionnelle à la fréquence croisée des modalités concernées**.

Les lignes verticales délimitent les fréquences marginales de la variable placée en abscisse. Chaque colonne est ensuite subdivisée selon les fréquences conditionnelles de la variable placée en ordonnée. Puisqu'il s'agit de proportions, il n'est pas nécessaire de graduer les axes, mais on peut le faire si on le désire.

Ce diagramme est très similaire au diagramme en bâtons empilés sur les fréquences conditionnelles relatives (figure 2.14), mais ici l'épaisseur des "bâtons" est proportionnelle aux fréquences marginales de la variable sur laquelle on conditionne.

La figure 2.16 montre deux diagrammes en mosaïque basés sur les données du recensement de la population de Québec. Le diagramme de gauche conditionne sur l'âge, celui de droite sur le sexe.




FIGURE 2.16 – Exemples de diagrammes en mosaïque

Dans notre exemple, les lignes horizontales ne sont pas parfaitement droites, indiquant que les fréquences conditionnelles de la variable en ordonnée varient d'une modalité à l'autre de la variable en abscisse. On a donc une indication que le sexe et l'âge sont des variables dépendantes dans la population de résidents de la ville de Québec en 2016.

2.7.2 Une variable catégorique et une variable numérique

Avec un échantillon contenant une variable catégorique et une variable numérique, il est pertinent d'étudier la distribution de la variable numérique selon les groupes formés par la variable catégorique. Une représentation graphique d'un tel échantillon va donc mettre côte-à-côte des graphiques univariés pour une variable numérique comme des histogrammes ou, plus souvent, des diagrammes en boîte.

Exemple 2.18. *On utilise ici des données rendues publiques par Gapminder, une organisation suisse indépendante qui produit et partage des données statistiques sur le monde (voir <https://www.gapminder.org/about-gapminder/>).⁴*

Voici d'abord des histogrammes juxtaposés, qui comparent la distribution de l'espérance de vie en 2007 dans les pays d'Asie et ceux d'Europe. Notez que les axes sont identiques pour les deux histogrammes, ce qui est nécessaire pour bien comparer les distributions.




FIGURE 2.17 – Exemple d'histogrammes juxtaposés

On voit que l'espérance de vie est en général plus grande en Europe et que la distribution des espérances en vie en Asie est asymétrique à gauche. On voit moins bien la forme de la distribution univariée en Europe car elle est très concentrée dans une région des valeurs observées pour l'ensemble des pays.

4. Plus particulièrement, on utilise les données de l'objet `gapminder` de la librairie `gapminder` de R.

Voici maintenant des diagrammes en boîtes juxtaposés pour les même données.




FIGURE 2.18 – Exemple de diagrammes en boîtes juxtaposés

On voit ici aussi que l'espérance de vie est en général plus grande en Europe et que la distribution des espérances en vie en Asie est asymétrique à gauche. On peut également observer que l'espérance de vie en Europe est elle aussi asymétrique à gauche, ce qui n'était pas visible dans les histogrammes. On peut aussi voir les minimums et maximums dans chaque groupe, et faire des interprétations plus précises, par exemple que presque tous les pays européens ont une espérance de vie supérieure à la médiane en Asie.

Notez que ces types de graphique s'appliquent également à des variables catégoriques avec plus de deux catégories, comme à la figure ci-dessous.




FIGURE 2.19 – Autre exemple de diagrammes en boîtes juxtaposés

2.7.3 Deux variables numériques

Pour représenter deux variables numériques, on peut utiliser

1. un diagramme de dispersion, ou
2. un diagramme temporel.

Le diagramme de dispersion est le graphique à utiliser par défaut pour deux variables numériques. Le diagramme temporel est utile seulement si une de ces deux variables est une mesure de temps, par exemple une année.

Diagramme de dispersion (scatterplot)

Dans un diagramme de dispersion, chaque observation du jeu de données est représentée par un point dont la valeur en abscisse correspond à la valeur de l'une des variables, et celle en ordonnée correspond à celle de l'autre variable. Ce type de graphique permet d'analyser la dépendance entre les deux variables numériques : si les deux variables sont indépendantes, les points du graphique seront répartis au hasard, c'est-à-dire selon un nuage de points sans tendance particulière.

La figure 2.20 montre un exemple, toujours avec les données de *Gapminder*. On voit qu'il y a une relation entre le PIB par *capita* et l'espérance de vie en 2007 : les pays ayant un plus grand PIB ayant en général de plus grandes espérances de vie. On note toutefois qu'il y a une très grande variabilité en terme d'espérance de vie parmi les pays avec les plus petits PIB par *capita*.





FIGURE 2.20 – Exemple de diagramme de dispersion

Diagramme temporel (time series)

Si dans un diagramme de dispersion une des variables mesure le temps, il est souvent pertinent de placer cette variable sur l'axe des abscisses (axe des X) et de relier les points par des segments de droite. Par exemple, la figure 2.21 contient un diagramme temporel présentant l'évolution du PIB par *capita* entre 1952 et 2007, toujours selon les données fournies par Gapminder. Notez que le PIB est en dollars américains corrigés pour l'inflation, ce qui est important pour pouvoir interpréter l'évolution.



2.21

FIGURE 2.21 – Exemple de diagramme temporel

Notons qu'on peut couper les axes sans déformer les statistiques seulement si l'objectif est de montrer les hausses ou baisses successives. Par contre, il faut être conscient qu'une variation temporelle a toujours l'air plus importante lorsque l'axe est tronqué.

Notons aussi que les données présentées à la figure 2.21 ont été mesurées aux quatre ans. Les hausses et baisses visibles dans le graphique pourraient avoir l'air différentes si on incluait les données à toutes les années. C'est un détail qu'il faut garder en tête quand on lit un diagramme temporel.

2.7.4 Trois variables et plus

Quelques graphiques présentés dans les sections précédentes peuvent se généraliser au cas à trois variables ou plus. Voici quelques exemples, toujours avec les mêmes données.

Diagramme de dispersion groupé

Il s'agit simplement d'ajouter de l'information sur une variable catégorique directement dans le diagramme de dispersion, soit à l'aide de symboles différents, soit en utilisant des couleurs différentes. Par exemple, voici une variante de la figure 2.20 sur laquelle on a également indiqué le continent associé à chacune des observations.




FIGURE 2.22 – Exemple de diagramme de dispersion groupé

Diagramme temporel groupé

Il s'agit ici d'ajouter une variable catégorique sur le diagramme temporel. Pour ce faire, on peut varier la couleur et/ou le type de ligne dans le diagramme.

La figure 2.23 généralise la figure 2.21 en ajoutant la variable pays avec deux modalités. On y présente en effet le PIB par capita en fonction de l'année, et du pays pour le Brésil et le Pérou. Il est intéressant de constater que les patrons d'évolution sont relativement similaires pour les deux pays, bien qu'avant les années 1980 le Brésil avait un PIB par *capita* inférieur à celui du Pérou et que la situation se soit inversée par la suite.




FIGURE 2.23 – Exemple de diagramme temporel groupé

Notez qu'ici aussi on peut utiliser une variable catégorique avec plus de 2 catégories. Toutefois, il se peut que le graphique devienne rapidement surchargé si les séries temporelles des différentes modalités de la variable catégoriques se croisent fréquemment.

Diagramme à bulles (*Bubble plot ou bubble chart*)

Ce type de graphique est utile si on veut illustrer simultanément trois variables continues. Il s'agit d'un diagramme de dispersion dans lequel l'aire des points est proportionnelle à la valeur d'une troisième variable continue. Par exemple, on peut ajouter la variable population au diagramme de dispersion de l'espérance de vie en fonction du PIB par *capita*. Il s'agit d'utiliser des points dont la taille est proportionnelle à la population du pays qu'ils représentent. Le résultat est présenté à la figure suivante.




FIGURE 2.24 – Exemple de diagramme à bulles

Notez qu'on pourrait même ajouter une quatrième variable, catégorique cette fois, en colorant les points différemment selon le continent !

2.8 Statistiques trompeuses ?

On a vu dans ce chapitre une panoplie de représentations numériques et graphiques pour décrire un jeu de données de une ou plusieurs variables. Lorsqu'on construit ces représentations nous mêmes, et surtout lorsqu'elles nous sont fournies par une autre personne (par exemple dans un article de journal) il faut être très prudent pour bien interpréter ce qui est représenté. Voici trois aspects importants à garder en tête :

1. **Chaque représentation numérique ou graphique fournit une information précise au sujet de la ou des variables en jeu, mais ne résume pas tout ce qui est intéressant au sujet de cette variable.** Il faut donc faire attention à ne pas interpréter les résultats au delà de ce qu'ils permettent de conclure. Par exemple, si on observe que la moyenne des résultats dans un groupe A est supérieure à celle d'un groupe B, ce n'est pas suffisant pour conclure que « les résultats dans le groupe A sont supérieurs à ceux du groupe B ».
2. **Certains détails sur le choix de la représentation numérique ou graphique peuvent avoir un gros impact sur le résultat obtenu**, et donc sur notre interprétation. Que ce soit intentionnel ou pas, certains choix peuvent nous induire en erreur, notamment
 - une coupure d'axe inappropriée,
 - une modification de l'échelle d'un graphique,
 - l'usage de trois dimensions,
 - une élimination subjective de valeurs aberrantes,
 - une présentation partielle des résultats.
3. **À moins qu'on travaille à partir d'un recensement, toutes les statistiques descriptives sont des mesures échantillonales et non de la population.** Même si l'échantillon vient d'une méthode de collecte probabiliste et devrait être représentatif de la population, il est aléatoire, et donc on aurait pu obtenir des statistiques différentes avec un autre échantillon. Il faut donc faire attention avant d'inférer de l'échantillon à la population, particulièrement si l'échantillon est petit. En fait, des méthodes d'inférence sont nécessaires pour généraliser les résultats à la population. On en présentera plusieurs dans les prochains chapitres.

2.9 Effet des probabilités de sélection inégales

Les statistiques descriptives ont pour objectif de décrire un jeu de données. Mais ce jeu de données représente parfois un échantillon d'une population plus large, et on sera tenté de généraliser à la population les caractéristiques observées à l'aide des statistiques descriptives sur l'échantillon. On a dit qu'il faut dans ce cas faire attention au fait que le jeu de données observé est lui-même aléatoire, et qu'on aurait pu obtenir des résultats différents avec un autre échantillon. Mais on doit aussi porter attention à la façon avec laquelle cet échantillon a été obtenu.

En effet, on a présenté au chapitre 1 certaines méthodes d'échantillonnage probabiliste pour lesquelles les individus de la population n'ont pas tous une probabilité de sélection identique. **Dans de tels cas, les représentations numériques et graphiques décrites jusqu'à présent offriront un bon résumé de l'échantillon, mais risquent de ne pas bien représenter la population.**

Il faut donc être vigilant dans le cas de statistiques descriptives sur un échantillon obtenu avec des probabilités de sélection inégales. Un traitement complet de ce problème ne sera pas présenté ici, mais on présente une statistique descriptive qui fournit une meilleure estimation de la moyenne de la population.

Cas de l'échantillonnage stratifié

On avait illustré le problème dans le cas de l'échantillonnage stratifié à l'exemple 1.6. On avait alors les données suivantes :

	Strate 1	Strate 2
Population	1,2,3,4,5,6,7,8,9,10	20,30,40,50,60
Échantillon	3,6,7	20,50,60

Les trois observations dans l'échantillon de la strate 1 représentent 10 observations dans la population, alors que les trois observations dans l'échantillon de la strate 2 ne représentent que 5 observations. Les observations tirées de la strate 1 devraient donc avoir un poids plus important dans le calcul de la moyenne.

Pour obtenir une moyenne plus représentative de la moyenne dans la population à l'aide de l'échantillon obtenu, on n'a qu'à utiliser une moyenne pondérée, pour tenir compte du nombre d'observation dans les deux strates. On utilisera ainsi :

$$\hat{\mu}_{strat} = \bar{x}_{strat} = \sum_{k=1}^K \frac{N_k}{N} \bar{x}_k \quad (2.1)$$

où $\bar{x}_k$ est la moyenne échantillonnale pour la strate k . Rappelons que N_k est la taille de la strate k dans la population et N la taille totale de la population.

Exemple 2.19. On reprend les données de l'exemple 1.6. L'estimateur naïf pour la moyenne était

$$\bar{x} = \frac{1}{6}(3 + 6 + 7 + 20 + 50 + 60) = 24,33.$$

On devrait plutôt utiliser

$$\begin{aligned}\bar{x}_{strat} &= \sum_{k=1}^K \frac{N_k}{N} \bar{x}_k \\ &= \frac{10}{15} \times \frac{1}{3} (3 + 6 + 7) + \frac{5}{15} \times \frac{1}{3} (20 + 50 + 60) \\ &= \frac{1}{15} \left(\frac{10}{3} (3 + 6 + 7) + \frac{5}{3} (20 + 50 + 60) \right) \\ &= 18\end{aligned}$$

qui est beaucoup plus proche de 17, la moyenne dans la population.

Regardez attentivement la dernière ligne du calcul dans l'exemple précédent. La fraction $1/15$ correspond à $1/N$, comme si on faisait une moyenne sur l'ensemble des unités de la population. En fait, la moyenne ne se fait que sur les six observations tirées dans l'échantillon, mais chacune a un poids correspondant au nombre d'observations de la population qu'elle représente, soit $10/3$ pour les observations de la strate 1 et $5/3$ pour les observations de la strate 2. Notez que ces poids correspondent à l'inverse de la probabilité de sélection pour chacune des observations. Cette stratégie s'applique plus largement que dans le cas de l'échantillonnage stratifié, à l'aide de ce qu'on appelle l'estimateur de Horvitz-Thompson.

Estimateur d'Horvitz-Thompson

Considérons des observations $x_1, \dots, x_n$ obtenues à l'aide d'un échantillonnage probabiliste. Soit $p_1, \dots, p_n$ les probabilités de sélection pour chacune des ces observations, lesquelles doivent être connues mais pas nécessairement égales. Alors, un estimateur approprié pour la moyenne de la population, et donc une statistique descriptive à utiliser pour la moyenne, est

$$\hat{\mu}_{HT} = \bar{x}_{HT} = \frac{1}{N} \sum_{i=1}^n \frac{1}{p_i} x_i = \frac{1}{N} \sum_{i=1}^n w_i x_i \quad (2.2)$$

où $w_i = 1/p_i$ est un poids associé à chaque observation, égal à l'inverse de sa probabilité de sélection. Ce poids peut s'interpréter comme le nombre d'unités de la population représentées par cette observation.

Remarque 2.14. Notez que dans le cas d'un échantillonnage probabiliste où toutes les unités ont la même probabilité de sélection, on a $p_i = n/N$ pour $i = 1, \dots, N$. On a donc que

$$\bar{x}_{HT} = \frac{1}{N} \sum_{i=1}^n \frac{1}{p_i} x_i = \frac{1}{N} \sum_{i=1}^n \frac{N}{n} x_i = \frac{1}{n} \sum_{i=1}^n x_i$$

c'est-à-dire que l'estimateur de Horvitz-Thompson se réduit à la moyenne arithmétique des observations sélectionnées dans l'échantillon. De même, cet estimateur est équivalent à l'estimateur 2.1 donné pour le cas d'un échantillonnage stratifié.

Exemple 2.20. Reprenons l'exemple précédent avec l'estimateur d'Horvitz-Thompson. Dans la strate 1, on choisit 3 observations parmi 10 et donc la probabilité de sélection de chaque observation est $3/10$. Les trois premières observations ayant été tirées de cette strate, on a $p_1 = p_2 = p_3 = 3/10$. On peut de la même façon obtenir $p_4 = p_5 = p_6 = 3/5$. On a donc

$$\bar{x}_{HT} = \frac{1}{N} \sum_{i=1}^n \frac{1}{p_i} x_i = \frac{1}{15} \left(\frac{10}{3} (3 + 6 + 7) + \frac{5}{3} (20 + 50 + 60) \right) = 18.$$

exactement tel que calculé auparavant.

Exemple 2.21. Supposons un échantillonnage par grappes, avec les données suivantes :

	Nombre d'observations	Valeurs observées
Grappe 1	10	7, 15
Grappe 2	5	-
Grappe 3	8	5, 8, 11
Grappe 4	15	6, 14, 15, 18, 20
Grappe 5	12	-

Il y a donc cinq grappes dans la population, avec une population de taille $N = 50$. On a sélectionné par ÉAS trois des cinq grappes, puis ensuite, toujours par ÉAS, un certain nombre d'observations dans chaque grappe.

On peut calculer la probabilité de sélection pour chacune des 10 observations tirées dans l'échantillon en multipliant la probabilité de sélection de la grappe par la probabilité de sélection de l'observation dans la grappe. Les observations d'une même grappe ont donc toutes la même probabilité de sélection.

On peut calculer les probabilités de sélection et les poids pour toutes les observations sélectionnées :

Grappe	Valeur observée	Probabilité de sélection (p_i)	Poids (w_i)
1	7	$3/5 \times 2/10 = 6/50 = 3/25$	25/3
1	15	$3/5 \times 2/10 = 6/50 = 3/25$	25/3
3	5	$3/5 \times 3/8 = 9/40$	40/9
3	8	$3/5 \times 3/8 = 9/40$	40/9
3	11	$3/5 \times 3/8 = 9/40$	40/9
4	6	$3/5 \times 5/15 = 1/5$	5
4	14	$3/5 \times 5/15 = 1/5$	5
4	15	$3/5 \times 5/15 = 1/5$	5
4	18	$3/5 \times 5/15 = 1/5$	5
4	20	$3/5 \times 5/15 = 1/5$	5

Notre estimation de la moyenne sera alors

$$\begin{aligned}
 \bar{x}_{HT} &= \frac{1}{N} \sum_{i=1}^n \frac{1}{p_i} x_i \\
 &= \frac{1}{50} \left(\frac{25}{3} (7 + 15) + \frac{40}{9} (5 + 8 + 11) + 5 \times (6 + 14 + 15 + 18 + 20) \right) \\
 &= 13,1
 \end{aligned}$$

Notez que la moyenne arithmétique des 10 valeurs observées est plutôt

$$\bar{x} = \frac{1}{10} (7 + 15 + 5 + 8 + 11 + 6 + 14 + 15 + 18 + 20) = 11,9$$

Remarque 2.15. Notez que si on ne connaît pas le nombre d'observations dans les grappes non sélectionnées on ne pourra pas calculer cet estimateur de la moyenne. On pourra toutefois estimer le total dans la population ; celui-ci sera simplement $\sum_{i=1}^n \frac{1}{p_i} x_i$.

Remarque 2.16. On peut montrer que cet estimateur est sans biais pour la vraie moyenne de la population. La preuve est omise, mais notez que dans celle-ci on considère les x_i fixes, pour $i = 1, \dots, N$ et on fixe des probabilités de sélection $p_1, \dots, p_N$. L'appartenance à l'échantillon pour chaque observation est ce qui est considéré aléatoire. En moyenne sur les tirages de l'échantillon on trouvera que $\hat{\mu}_{HT} = \mu = \frac{1}{N} \sum_{i=1}^N x_i$.

AUTRES NOTES

AUTRES NOTES

AUTRES NOTES

Chapitre 3

Inférence

On a vu au chapitre précédent plusieurs représentations numériques et graphiques pour décrire une variable ou la relation entre plusieurs variables d'un jeu de données. L'inférence tente de répondre à la question suivante : **Est-ce que ce que j'ai observé dans les données est simplement dû au hasard, ou est-ce que c'est une caractéristique de la population ou du système à l'étude ?**

L'inférence statistique comporte deux grandes parties : l'estimation de paramètres, notamment à l'aide d'intervalles de confiance, et les tests d'hypothèses. Dans ce chapitre, on rappelle les principes de base de ces techniques, en commençant par des définitions et résultats théoriques qui seront utilisés pour construire les intervalles de confiance et les tests d'hypothèses.

3.1 Rappel de quelques définitions et résultats

3.1.1 Espérance

Soit X une variable aléatoire discrète, et R_X l'ensemble des valeurs possibles de celle-ci. Son espérance est alors donnée par

$$\mu = \sum_{i: x_i \in R_X} x_i P(X = x_i)$$

Soit X une variable aléatoire continue avec densité f_X . Son espérance est alors donnée par

$$\mu = \int_{-\infty}^{\infty} x f_X(x) dx$$

Remarque 3.1. On utilise généralement le terme *espérance* pour parler de la *moyenne théorique* d'une variable aléatoire, calculée à partir de sa distribution et le mot *moyenne* pour une valeur calculée pour un échantillon. On dira toutefois souvent X suit une loi normale de *moyenne* μ , où la valeur de μ correspond en fait à l'espérance de la variable aléatoire X .

Soit a et b des constantes et X une variable aléatoire. Alors,

$$E(aX + b) = aE(X) + b$$

Considérons maintenant $X_1, \dots, X_n$ des variables aléatoires. On a que

$$E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n)$$

3.1.2 Variance

Pour toute variable aléatoire X , la variance de celle-ci est donnée par

$$V(X) = E[(X - E(X))^2] = E[(X - \mu)^2]$$

Il est important de comprendre qu'il s'agit de la variance théorique, qui se calcule à partir de la distribution d'une variable aléatoire. C'est différent de la variance échantillonnale, présentée à la section 2.3.2, laquelle se calcule pour un ensemble de données. On dénote généralement par σ^2 la variance théorique, et par s^2 la variance échantillonnale.

En combinant cette définition de la variance aux définitions d'espérance données plus haut, on a que pour une variable discrète X la variance sera donnée par

$$\mu = \sum_{i: x_i \in R_X} (x_i - \mu)^2 P(X = x_i)$$

alors que pour une variable continue ce sera

$$\mu = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x)$$

où μ représente dans les deux cas l'espérance de X .

Remarque 3.2. Notez qu'il est parfois plus simple de calculer la variance en utilisant le fait que $V(X) = E(X^2) - E(X)^2 = E(X^2) - \mu^2$. La preuve que cette expression est équivalente à la définition est relativement simple, mais on l'omet ici.

Les propriétés de la variance sont un peu différentes de celles de l'espérance.

Soit a et b des constantes et X une variable aléatoire. Alors,

$$V(aX + b) = a^2V(X)$$

Le terme b disparaît complètement car la variance d'une constante est nulle. Le fait que le coefficient a apparaisse au carré devrait être évident de la définition de la variance.

Considérons maintenant $X_1, \dots, X_n$ des variables aléatoires. Comme pour l'espérance, on a que

$$V(X_1 + \dots + X_n) = V(X_1) + \dots + V(X_n)$$

mais seulement si les variables aléatoires sont toutes indépendantes.

Dans le cas où les X_i ne sont pas indépendantes, la variance de la somme dépendra des covariances entre celles-ci. On ne donnera ici que l'expression pour deux variables aléatoires :

$$V(aX_1 + bX_2) = a^2V(X_1) + b^2V(X_2) + 2ab\text{Cov}(X_1, X_2)$$

Rappelons que $\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$.

3.1.3 La loi binomiale

Si X suit une loi binomiale avec n tentatives et probabilité de succès p , ce qu'on dénote $X \sim \text{Binomiale}(n, p)$, alors

$$p_X(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x}, & x = 0, 1, \dots, n, \\ 0, & \text{sinon.} \end{cases}$$

L'espérance de X est alors np et sa variance $np(1-p)$.

Rappelons que si $n = 1$, alors on parle d'une loi de Bernoulli de paramètre p .

3.1.4 La loi normale et ses propriétés

La loi normale est définie par sa moyenne et sa variance. Si X suit une loi normale de moyenne μ et de variance σ^2 , ce que l'on dénote $X \sim N(\mu, \sigma^2)$, alors

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad -\infty < x < \infty. \quad (3.1)$$

Standardisation

Toute loi normale de moyenne μ et de variance σ^2 peut être ramenée à une loi normale standard, c'est-à-dire une loi normale de moyenne nulle et de variance unitaire, par un processus de standardisation :

$$X \sim N(\mu, \sigma^2) \implies Z = \frac{(X - \mu)}{\sigma} \sim N(0, 1)$$

Additivité

Une combinaison linéaire de variables aléatoires indépendantes suivant des lois normales suivra elle aussi une loi normale. En effet, si $X_1, X_2, \dots, X_n$ sont des v.a. indépendantes et que $X_i \sim N(\mu_i, \sigma_i^2)$, alors on a que

$$W = a_1 X_1 + \dots + a_n X_n \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right) \quad (3.2)$$

Lien avec d'autres distributions

- Si $Z \sim N(0, 1)$ alors

$$Z^2 \sim \chi_1^2,$$

où χ_1^2 dénote la loi chi-carrée avec 1 degré de liberté.

Rappelons que si X suit une loi χ_v^2 , alors $E(X) = v$ et $V(X) = 2v$.

- Si $Z \sim N(0, 1)$ et $V \sim \chi_v^2$, alors

$$T = \frac{Z}{\sqrt{V/v}} \sim t_v$$

où t_v dénote une loi de Student, aussi appelée loi t , avec v degrés de liberté.

Rappelons que la loi de Student est une loi symétrique aux queues plus lourdes que la loi normale, et que plus v augmente plus la Student ressemble à la loi normale, de telle sorte que si $v = \infty$ alors on obtient une loi normale standard.

Distributions échantillonnales

On utilise souvent les résultats suivants qui concernent respectivement la distribution de la moyenne et de la variance échantillonnales pour un échantillon de variables aléatoires i.i.d de loi normale :

- Si $X_1, \dots, X_n$ sont i.i.d. $N(\mu, \sigma^2)$, alors

$$\frac{\bar{X} - \mu}{\sqrt{S^2/n}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1} \quad (3.3)$$

- Si $X_1, \dots, X_n$ sont i.i.d. $N(\mu, \sigma^2)$, alors

$$Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2, \quad (3.4)$$

où $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, la variance échantillonnale, et χ_{n-1}^2 dénote la loi chi-carrée avec $n-1$ degrés de liberté.

3.1.5 Le théorème central limite

Ce théorème indique qu'une somme de n v.a. indépendantes se comporte approximativement comme une loi normale si n est suffisamment grand, peu importe la distribution de chacune de ces variables aléatoires.

Soit $X_1, \dots, X_n$ des v.a. indépendantes telles que $E(X_i) = \mu_i$ et $V(X_i) = \sigma_i^2$. Alors, lorsque n est suffisamment grand

$$\sum_{i=1}^n X_i \approx N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

Dans le cas particulier où $X_1, \dots, X_n$ sont i.i.d. $N(\mu, \sigma^2)$, alors

$$\sum_{i=1}^n X_i \approx N(n\mu, n\sigma^2) \text{ et donc } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

Remarque 3.3. La taille d'échantillon n nécessaire pour le TCL soit valide dépend de la distribution des variables qui composent la somme. Plus la distribution de chacun des X_i ressemble à une loi normale (symétrique, unimodale, faibles queues), plus la convergence sera rapide. D'ailleurs, si chacun des X_i suit une loi normale, alors la somme est une combinaison linéaire de lois normales et donc la somme suit une loi normale pour tout $n \geq 1$!

3.2 Estimation de paramètres

Un **paramètre** est un nombre qui décrit une des caractéristique d'une population ou d'un modèle statistique. En statistique classique, on considère le paramètre comme une valeur fixe, mais inconnue, que l'on souhaite estimer à l'aide d'observations tirées de la population ou du modèle statistique.

Pour estimer le paramètre, on utilise un **estimateur**. Un estimateur n'est pas un nombre. On peut y penser plutôt comme une fonction qui associe une estimation du paramètre à chaque réalisation possible de l'échantillon. L'échantillon étant aléatoire, l'estimateur est donc une variable aléatoire également. Pour un échantillon donné, l'estimateur prend une valeur numérique que l'on nomme l'**estimation** du paramètre.

Exemple 3.1. Soit $X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2)$ des variables aléatoires de loi normale avec moyenne μ et variance σ^2 . Disons qu'on souhaite estimer le paramètre μ . Un estimateur intuitif pour ce faire est la moyenne échantillonnale :

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

La moyenne échantillonnale $\bar{X}$ est une variable aléatoire, qui est une fonction des variables aléatoires $X_1, \dots, X_n$. Après avoir observé des données $x_1, \dots, x_n$, on pourra calculer la valeur observée de $\bar{X}$, soit

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

qui constituera notre estimation de μ . Notez qu'on utilise ici des majuscules pour les variables aléatoires, et des minuscules pour leurs valeurs observées.

3.2.1 Qualité d'un estimateur

Toute fonction d'un échantillon $X_1, \dots, X_n$ peut être considérée comme un estimateur d'un paramètre. Certains estimateurs sont toutefois meilleurs que d'autres. Pour mesurer la qualité d'une statistique en tant qu'estimateur d'un paramètre, on utilise le biais, la variance et l'écart quadratique moyen, présentés ci-dessous.

Pour la suite, on dénotera par θ le paramètre qu'on souhaite estimer, et par $\hat{\theta}$ l'estimateur de celui-ci.

Biais

Le biais mesure si les valeurs prises par l'estimateur sont en moyenne égales au paramètre à estimer. On le définit ainsi :

$$\text{Biais}(\hat{\theta}) = E(\hat{\theta}) - \theta. \quad (3.5)$$

La valeur optimale du biais est 0. On dira dans ce cas que l'estimateur $\hat{\theta}$ est non biaisé pour le paramètre θ .

Exemple 3.2. Revenons à l'exemple 3.1. Le paramètre à estimer est μ , que l'on dénotera ici θ . Notre estimateur est $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i$. On connaît la distribution des X_i ($X_1, \dots, X_n \stackrel{iid}{\sim} N(\theta, \sigma^2)$), donc on peut calculer l'espérance de l'estimateur et en déduire le biais.

$$\begin{aligned} E(\hat{\theta}) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \theta \\ &= \frac{1}{n} n\theta \\ &= \theta \end{aligned}$$

On peut enfin calculer

$$\text{Biais}(\hat{\theta}) = E(\hat{\theta}) - \theta = \theta - \theta = 0$$

L'estimateur $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i$ est donc non biaisé pour estimer la moyenne d'une loi normale de variance σ^2 .

Remarque 3.4. Dans le calcul à l'exemple 3.2, on n'utilise pas le fait que les données suivent une loi normale. En fait, on peut montrer que si $X_1, \dots, X_n$ est un échantillon iid de n'importe quelle loi d'espérance $\mu < \infty$ alors $\bar{X}$ est un estimateur non biaisé de μ .

Remarque 3.5. Notez que l'espérance de $\hat{\theta}$ dépend de θ pour l'exemple 3.2. Ce sera généralement le cas. En effet, si l'espérance d'un l'estimateur ne dépend pas de la valeur du paramètre, cet estimateur risque de ne pas être très utile pour estimer le paramètre...

Variance

Le biais mesure si en moyenne l'estimateur tombera sur la valeur du paramètre. Mais en pratique, on n'obtient qu'une seule estimation du paramètre. Il est donc important de savoir si cette valeur a de bonnes chances d'être proche du vrai paramètre. Pour ce faire, on peut utiliser la variance de l'estimateur. Entre deux estimateurs non biaisés, l'estimateur le moins variable est préférable.

Exemple 3.3. *Considérons toujours l'exemple 3.1. Soit les deux estimateurs suivants de θ :*

$$\hat{\theta}_1 = \frac{1}{n} \sum_{i=1}^n X_i \quad \hat{\theta}_2 = \frac{X_1 + X_n}{2}$$

Le premier utilise toutes les données pour estimer θ , alors que le deuxième n'utilise que la première et la dernière observation. On a déjà montré que $\hat{\theta}_1$ est sans biais pour θ . On peut faire de même pour $\hat{\theta}_2$.

On peut également calculer la variance des deux estimateurs.

$$\begin{aligned} \text{Var}(\hat{\theta}_1) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) && \text{puisque les } X_i \text{ sont indépendants} \\ &= \frac{1}{n^2} \sum_{i=1}^n \sigma^2 && \text{car chaque } X_i \text{ a une variance de } \sigma^2 \\ &= \frac{1}{n} \sigma^2 \end{aligned}$$

$$\begin{aligned} \text{Var}(\hat{\theta}_2) &= \text{Var}\left(\frac{X_1 + X_n}{2}\right) \\ &= \frac{1}{4} (\text{Var}(X_1) + \text{Var}(X_n)) && \text{puisque } X_1 \text{ et } X_n \text{ sont indépendants} \\ &= \frac{1}{4} (\sigma^2 + \sigma^2) \\ &= \frac{1}{2} \sigma^2 \end{aligned}$$

Pour $n > 2$, l'estimateur $\hat{\theta}_1$ a une plus petite variance que l'estimateur $\hat{\theta}_2$.

Puisque les deux estimateurs sont sans biais, et que $\hat{\theta}_1$ est moins variable que $\hat{\theta}_2$, alors $\hat{\theta}_1$ est un meilleur estimateur pour θ .

Remarque 3.6. Erreur quadratique moyenne (EQM)

Il est parfois avantageux de permettre un petit biais à un estimateur pour diminuer sa variabilité. Aussi, on veut parfois comparer deux estimateurs qui ne sont pas tous les deux non biaisés. Pour ce faire, on peut utiliser l'écart quadratique moyen, dénoté EQM. Il est défini par

$$EQM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] \quad (3.6)$$

qu'on peut ré-écrire sous la forme

$$EQM(\hat{\theta}) = \left(\text{Biais}(\hat{\theta}) \right)^2 + V(\hat{\theta}) \quad (3.7)$$

On préférera en général l'estimateur avec le plus petit EQM. Notez que pour un estimateur non biaisé, l'EQM est simplement la variance de l'estimateur.

3.3 Intervalles de confiance

À l'aide du biais, de la variance et de l'EQM, on peut choisir un estimateur de qualité pour estimer un paramètre. Ces mesures nous renseignent sur la distribution de l'estimateur, qui est une variable aléatoire.

Une fois les données observées, et l'estimation calculée, on aimerait aussi avoir une idée de la précision de notre estimation. La construction d'un intervalle de confiance pour accompagner l'estimation du paramètre nous donne un peu plus d'information à ce sujet.

3.3.1 Définition

Un intervalle de confiance est défini par ses deux bornes, une borne inférieure souvent dénotée L pour *Lower* et une borne supérieure dénotée U pour *Upper*. Les bornes L et U sont toutes les deux des fonctions des données de l'échantillon, et donc des variables aléatoires. Voici la définition précise :

Un **intervalle de confiance** à $100(1 - \alpha)\%$ pour θ est de la forme $[L, U]$, où L et U sont des statistiques telles que

$$P(L \leq \theta \leq U) = 1 - \alpha. \quad (3.8)$$

Notez qu'on écrit parfois $[L(X_1, \dots, X_n), U(X_1, \dots, X_n)]$ pour mettre en évidence le fait que les bornes sont des fonctions de l'échantillon.

3.3.2 Interprétation

Il faut comprendre que l'intervalle de confiance ne contiendra pas nécessairement la vraie valeur du paramètre d'intérêt. En effet, la garantie d'un intervalle de confiance est probabiliste, telle que définie à l'équation 3.8. Elle indique que si on tirait de la population ou du modèle un grand nombre d'échantillons, et qu'on utilisait chacun d'eux pour créer un intervalle de confiance $[L, U]$ pour θ , alors $100(1 - \alpha)\%$ de ces intervalles renfermeraient le vrai paramètre θ .

On nomme $100(1 - \alpha)\%$ le **niveau de confiance** de l'intervalle de confiance. Plus le niveau de confiance d'un intervalle de confiance est élevé, plus la probabilité que l'intervalle obtenu contienne le paramètre θ est grande.

Il peut sembler optimal d'utiliser un niveau de confiance plus élevé. Toutefois, pour s'assurer que le niveau de confiance soit élevé il faudra construire un intervalle de confiance plus long, qui fournira donc moins d'information sur la valeur de θ . Par exemple, $(-\infty, \infty)$ est un intervalle de confiance à 100% pour une moyenne, mais il ne nous donne aucune information sur la valeur de la moyenne. On recherche en général un bon compromis entre la **longueur** de l'intervalle de confiance et le niveau de confiance de celui-ci.

Remarque 3.7. Marge d'erreur

Plusieurs intervalles de confiance sont de la forme

$$\hat{\theta} \pm M$$

*où M est une variable aléatoire fonction des données de l'échantillon. Autrement dit, l'intervalle de confiance est donnée par $[\hat{\theta} - M, \hat{\theta} + M]$. Dans ce cas, on nomme **marge d'erreur** la valeur observée de M .*

3.3.3 Quelques intervalles de confiance connus

Construire un intervalle de confiance pour un paramètre θ n'est pas toujours une tâche facile. On doit faire des postulats sur la distribution de l'échantillon $X_1, \dots, X_n$ et les utiliser pour trouver des bornes $L(X_1, \dots, X_n)$ et $U(X_1, \dots, X_n)$ telles que l'équation 3.8 soit vérifiée.

On pourra parfois construire un intervalle exact, mais dans d'autres cas l'intervalle sera approximatif, dans le sens que l'équation 3.8 sera vérifiée seulement approximativement.

On donne ici la forme de plusieurs intervalles de confiance couramment utilisés. On prouvera dans l'exemple suivant la forme de celui pour la moyenne d'une loi normale de variance connue. On omet ici le détail des autres preuves. Celles pour un seul paramètre sont relativement similaires, mais utilisent d'autres résultats de la section 3.1, notamment les distributions échantillonales et le théorème central limite. Dans le cas d'une différence de paramètres, certaines preuves sont plus complexes et nécessitent d'autres notions de statistique mathématique.

Intervalles de confiance à $100(1-\alpha)\%$ pour une moyenne

La forme de l'intervalle de confiance pour une moyenne dépend des postulats qu'on peut faire sur la distribution des observations. Dans tous les cas, on suppose $X_1, \dots, X_n$ tirées indépendamment d'une distribution de moyenne $\mu < \infty$.

Postulats	Intervalle
Loi normale, variance connue	$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
Loi normale, variance inconnue	$\bar{X} \pm t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}$
Loi inconnue, n grand	$\bar{X} \pm z_{\alpha/2} \frac{S}{\sqrt{n}}$

où $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, et $\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

Les valeurs $z_{\alpha/2}$ et $t_{n-1, \alpha/2}$ sont des quantiles de la loi $N(0,1)$ et de la loi Student avec $n-1$ degrés de liberté, respectivement. En général, si X suit une loi F quelconque, alors $f_{\alpha/2}$ est défini tel que $P(F \geq f_{\alpha/2}) = \frac{\alpha}{2}$.

Notez que le dernier intervalle est un intervalle asymptotique, dans le sens que l'équation 3.8 est vérifiée lorsque n tend vers l'infini.

Intervalle de confiance à $100(1-\alpha)\%$ pour la variance d'une loi normale

On suppose ici $X_1, \dots, X_n$ tirées indépendamment d'une loi normale de moyenne $\mu < \infty$ et de variance $\sigma^2 < \infty$. L'intervalle est donné par

$$\left[\frac{(n-1)S^2}{\chi_{n-1, \alpha/2}^2}, \frac{(n-1)S^2}{\chi_{n-1, 1-\alpha/2}^2} \right]$$

Intervalle de confiance à $100(1-\alpha)\%$ pour une proportion

On suppose ici $X_1, \dots, X_n$ tirées indépendamment d'une loi Bernoulli de probabilité $0 \leq p \leq 1$. L'intervalle (asymptotique) est donné par

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \text{ où } \hat{p} \text{ est la proportion échantillonnale.}$$

Intervalles de confiance à $100(1-\alpha)\%$ pour une différence de moyennes :

Situation	Intervalle
Lois normales, variances connues	$\bar{X}_1 - \bar{X}_2 \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
Lois normales, variances inconnues, égales	$\bar{X}_1 - \bar{X}_2 \pm t_{\alpha/2; n_1+n_2-2} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$
Lois normales, variances inconnues, inégales	$\bar{X}_1 - \bar{X}_2 \pm t_{\alpha/2; \nu} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$ avec $\nu = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{s_1^2/n_1}{n_1+1} + \frac{s_2^2/n_2}{n_2+1}} - 2$

avec

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

Intervalle de confiance à $100(1-\alpha)\%$ pour une différence de proportions :

$$\hat{p}_1 - \hat{p}_2 \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

Exemple 3.4. Dérivation de l'intervalle de confiance pour la moyenne d'une loi normale de variance connue

On suppose $X_1, \dots, X_n$ tirés indépendamment d'une loi normale de moyenne inconnue μ et de variance σ^2 connue. On doit trouver des fonctions $L(X_1, \dots, X_n)$ et $U(X_1, \dots, X_n)$ telles que

$$P(L(X_1, \dots, X_n) \leq \theta \leq U(X_1, \dots, X_n)) = 1 - \alpha.$$

On sait que $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. On a donc $\bar{X} \sim N(\mu, \sigma^2/n)$. Par standardisation, on obtient

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

Pour tout $0 \leq \alpha \leq 1$, on peut donc écrire

$$P\left(z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

où par convention z_b est la valeur telle que $P(Z \geq z_\alpha) = \alpha$ si $Z \sim N(0, 1)$.

Il suffit d'un peu d'algèbre pour obtenir une équation de la forme d'un intervalle de confiance. En effet, puisque σ , et n sont des constantes positives, on a

$$P\left(z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \bar{X} - \mu \leq z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

qu'on peut ré-écrire

$$P\left(-\bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \leq -\mu \leq -\bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

On multiplie par -1 , ce qui inverse les inégalités et donne

$$P\left(\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \geq \mu \geq \bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

L'intervalle $\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}\right]$ est donc un intervalle de confiance à $100(1-\alpha)\%$ pour μ . En utilisant la symétrie de la loi normale, on le ré-écrit habituellement sous la forme

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right].$$

3.3.4 Utilisation en pratique

En pratique, il n'est souvent pas nécessaire de construire nous même un intervalle de confiance à l'aide de résultats théoriques de statistique mathématique. Il suffit plutôt d'identifier un intervalle de confiance déjà connu qui convient à la situation, en fonction de nos postulats sur les données, puis de calculer les bornes observées à partir des données de l'échantillon.

Il faudra également choisir le niveau de confiance $100(1 - \alpha)\%$ pour l'intervalle de confiance. Les valeurs de $\alpha = 0,05$ et $\alpha = 0,1$ sont les plus couramment utilisées, mais d'autres valeurs peuvent être appropriées selon le contexte.

Exemple 3.5. *On souhaite obtenir un intervalle de confiance pour la moyenne d'une loi normale de variance connue égale à 0,81 à partir d'un échantillon i.i.d. d'observations provenant de cette loi.*

Étant donné qu'on suppose que les données suivent une loi normale et que la variance est connue, la forme appropriée est celle-ci :

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

et dans notre cas $\sigma = 0,9$.

Disons qu'on a l'échantillon de 9 observations suivant : 1, 1, 1, 2, 2, 2, 3, 3, 3. On a alors, $\bar{x} = 2$. Notre intervalle de confiance sera donc de la forme

$$\left[2 - z_{\alpha/2} \frac{0.9}{3}, 2 + z_{\alpha/2} \frac{0.9}{3} \right]$$

Disons qu'on souhaite un niveau de confiance de 90%. À l'aide d'une table de la loi normale, ou d'un logiciel, on peut obtenir que $z_{\alpha/2} = 1,645$. Ainsi, notre intervalle de confiance à 90% pour la moyenne est donné par

$$\left[2 - 1,645 \frac{0.9}{3}, 2 + 1,645 \frac{0.9}{3} \right]$$

ce qui donne

$$[1,5065, 2,4935].$$

Si on avait choisi un niveau de confiance plus élevé, à 95%, on aurait $z_{\alpha/2} = 1,96$ et donc l'intervalle de confiance

$$[1,412, 2,588],$$

qui est sans surprise plus long que le précédent.

3.3.5 Contrôler la marge d'erreur

On a vu que la longueur d'un intervalle de confiance diminue lorsque la taille d'échantillon augmente. On souhaite parfois choisir la taille d'échantillon de façon à s'assurer que l'intervalle construit avec les données ait une marge d'erreur plus petite qu'une certaine valeur. C'est relativement facile à faire pour certains des intervalles donnés plus haut. Il suffit de fixer la marge d'erreur et d'isoler n dans la formule.

Exemple 3.6. *Considérons de nouveau l'exemple 3.5. On souhaitait y obtenir un intervalle de confiance pour la moyenne d'une loi normale de variance connue et égale à 0,81. Avec notre échantillon de 9 observations, et notre choix $\alpha = 0,5$, l'intervalle a une longueur de 1,176, et donc une marge d'erreur de 0,588. Disons qu'on souhaite plutôt obtenir un intervalle de confiance avec une marge d'erreur de 0,5, quelle devrait être la taille d'échantillon ?*

Puisqu'on veut diminuer la marge d'erreur, il faut nécessairement augmenter la taille de l'échantillon. Pour avoir une marge d'erreur de 0,5, il faut que

$$z_{\alpha/2} \frac{\sigma}{\sqrt{n}} = 0,5$$

On peut remplacer les valeurs connues dans la formule

$$1,96 \frac{0,9}{\sqrt{n}} = 0,5$$

Il ne reste qu'à isoler n :

$$n = \left(\frac{1,96 * 0,9}{0,5} \right)^2 = 12,44$$

Pour avoir une marge d'erreur inférieure à 0,5, il suffit donc de choisir $n = 13$.

On peut utiliser la même approche en général, mais il faudra parfois faire certaines hypothèses pour être en mesure de calculer la taille d'échantillon requise. Par exemple, si on souhaite choisir la taille d'échantillon pour contrôler la marge d'erreur dans l'estimation d'une proportion, il faudra décider d'une valeur pour p , qui est inconnue. Puisque la marge d'erreur sera plus grande pour $p = 0,5$, c'est la valeur qu'on utilisera en pratique.

3.4 Tests d'hypothèses

Tout comme les intervalles de confiance, les tests d'hypothèses ont pour but de vérifier si ce qui est observé dans un échantillon reflète une réalité de la population ou du système à l'étude. Mais ils s'énoncent en termes d'une décision au sujet d'une caractéristique de la population ou du système.

En guise d'introduction, considérons un petit exemple.

Exemple 3.7. Lancer d'une pièce de monnaie

On lance une pièce de monnaie 5 fois. Elle tombe du côté pile à chaque fois. Est-ce un hasard, ou la pièce est-elle biaisée, c'est-à-dire fabriquée de façon à tomber plus souvent du côté pile que du côté face ?

Et si elle tombe du côté pile 20 fois sur 20 lancers ? 65 fois sur 100 lancers ?

Comment savoir si la vraie probabilité d'obtenir un pile est supérieure à 50%, ou si elle est en fait égale à 50% mais que par hasard mon échantillon contenait beaucoup de piles ?

Intuitivement, moins les données observées sont vraisemblables pour une pièce non biaisée, plus on aura tendance à croire que la pièce est biaisée. Par exemple, la probabilité d'obtenir 5 piles sur 5 lancers avec une pièce non biaisée est de 0,03125, soit un peu plus de 3% alors que la probabilité de 20 piles sur 20 lancers est 0,000000953674. On sera donc plus prêt à accepter que la pièce était non biaisée dans le premier cas que dans le deuxième.

C'est exactement cette intuition qui est à la base des tests d'hypothèses.

L'idée d'un test d'hypothèse est donc de tester si une caractéristique de la population ou du système est vraie en regardant si les données observées sont plausibles si cette caractéristique est vraie. On peut résumer un test d'hypothèse en trois grandes étapes que nous décortiquerons dans les sections suivantes.

1. **Énoncer des hypothèses H_0 et H_1 .**

Celles-ci concernent un ou des paramètres de la population ou du système.

2. **Observer les données et calculer une statistique pour le test.**

Il s'agit de résumer les données en une statistique de test qui permettra de tester les hypothèses.

3. **Prendre une décision concernant les hypothèses.**

Si la statistique de test observée est peu probable sous H_0 , on rejettera H_0 au profit de l'hypothèse H_1 .

3.4.1 Énoncer des hypothèses

Les hypothèses H_0 et H_1 sont des énoncés au sujet d'un ou de plusieurs paramètres d'une population finie ou d'un modèle statistique.

Par exemple, pour un test sur un paramètre θ , les hypothèses s'énoncent habituellement $H_0 : \theta = \theta_0$ versus l'une des trois hypothèses alternatives $H_1 : \theta \neq \theta_0$, $H_1 : \theta < \theta_0$ ou $H_1 : \theta > \theta_0$, où θ_0 est une constante choisie.

On nomme H_0 l'hypothèse nulle et H_1 l'hypothèse alternative.

Exemple 3.8. Revenons à l'exemple 3.7. Chaque lancer de la pièce de monnaie peut être considérée une réalisation d'une loi de Bernoulli avec probabilité de succès p . Pour tester si la pièce est non biaisée, on utilisera les hypothèses $H_0 : p = 0,5$ versus $H_1 : p \neq 0,5$. On pourrait également tester plus spécifiquement si la pièce a une probabilité supérieure à 0,5 de tomber sur pile. On utiliserait alors $H_0 : p = 0,5$ versus $H_1 : p > 0,5$.

3.4.2 Choisir une statistique de test

La statistique de test est une fonction des données observées, et donc une variable aléatoire. La valeur numérique de la statistique calculée pour un échantillon se nomme la **statistique de test observée**, et est dénotée T_{obs} .

Exemple 3.9. Dans l'exemple 3.7, on a implicitement identifié une statistique de test, soit le nombre de piles parmi tous les lancers effectués. On aurait pu considérer d'autres statistiques par exemple la longueur de la plus longue série de piles obtenue, le nombre de lancers nécessaires pour obtenir $\lceil n/2 \rceil$ piles, ou même la séquence complète des piles ou faces.

En théorie n'importe quelle statistique calculée à partir de l'échantillon peut être utilisée pour faire un test d'hypothèse. Toutefois, le choix de la statistique de test a un impact important sur la construction du test. En effet, pour prendre une décision concernant les hypothèses, on voudra calculer certaines probabilités au sujet de la statistique de test sous H_0 , un peu comme on a fait à l'exemple 3.7. Il faut donc pouvoir calculer la distribution de la statistique de test sous H_0 , ce qui sera beaucoup plus facile pour un choix judicieux de la statistique.

De plus, la performance du test d'hypothèses dépendra également du choix de la statistique de test. On verra bientôt comment mesurer précisément la performance d'un test d'hypothèse, mais pour le moment il semble par exemple logique que pour vérifier si une pièce est biaisée ou non, on fera mieux d'utiliser le nombre de piles parmi tous les lancers que seulement le résultat du huitième lancer, même si la construction du test pourrait être plus simple dans ce deuxième cas.

3.4.3 Prendre une décision

La partie clé de la construction d'un test d'hypothèses est d'identifier pour quelles valeurs de la statistique de test on rejettera l'hypothèse nulle H_0 . Par exemple, si on lance une pièce de monnaie 20 fois, est-ce qu'on va conclure qu'elle est biaisée si on observe plus de 10 piles ? plus de 15 ?

Pour choisir ce qu'on nomme la **zone de rejet** du test, on considère les erreurs potentielles, illustrées à la figure 3.1.

		Vérité	
		H_0 vraie	H_0 fausse
Décision du test statistique	Ne pas rejeter H_0	Bonne décision	Erreur de type 2
	Rejeter H_0	Erreur de type 1	Bonne décision

FIGURE 3.1 – Erreurs possibles pour un test d'hypothèse

On nomme le **seuil du test** la probabilité d'erreur de type 1, et on le dénote par le symbole α .

On nomme la **puissance du test** la probabilité de réussir à rejeter H_0 si H_0 est effectivement fausse. On la dénote $1 - \beta$. Notez que la puissance du test correspond à 1 moins la probabilité d'erreur de type 2.

On voudrait de petites probabilités d'erreur, et donc un petit seuil et une grande puissance. Toutes choses étant égales par ailleurs, plus la probabilité d'erreur de type 1 diminue, plus la probabilité d'erreur de type 2 augmente. Il faudrait donc faire un compromis entre ces deux erreurs dans le choix de la zone de rejet.

En pratique, on considère en général plutôt que l'erreur de type 1 est la plus grave, et on choisit la zone de rejet de façon à ce que le seuil du test soit inférieur à une certaine limite. On ne contrôle alors pas la puissance du test, mais on pourra la calculer si on le souhaite.

Remarque 3.8. *En ce sens, le test d'hypothèse est peu comme un système de justice où on considère un individu non coupable jusqu'à preuve du contraire, c'est-à-dire qu'on considère l'hypothèse nulle vraie jusqu'à ce les données nous fournissent une preuve suffisamment convaincante du contraire.*

Choix du seuil

Choisir un seuil plus grand permettra de rejeter plus facilement H_0 , mais on risque alors de rejeter H_0 même si l'hypothèse nulle est vraie. À l'opposé, choisir un seuil plus petit diminue les chances de rejeter incorrectement H_0 mais peut nous empêcher de rejeter H_0 même si on le devrait. Un seuil de $\alpha = 0,05$ est souvent utilisé en pratique, mais d'autres valeurs sont parfois plus appropriées.

Exemple 3.10. Revenons encore à l'exemple 3.7 et disons qu'on effectue 20 lancers. On souhaite tester $H_0 : p = 0,5$ versus $H_1 : p > 0,5$, où p est la probabilité pour la pièce de tomber sur pile. On utilise X , le nombre de piles parmi les 20 lancers, comme statistique de test. On peut facilement calculer la distribution échantillonnale si H_0 est vraie. En effet, dans ce cas X suit une loi Binomiale avec $n = 20$ et $p = 0,5$.

Il faut maintenant déterminer la zone de rejet. Puisque l'hypothèse de test est que $p > 0,5$ on décide de rejeter H_0 si $X > m$ pour une constante m . Le choix de m dépend du seuil désiré, lequel est donné par

$$\begin{aligned} P(\text{rejeter } H_0 | H_0 \text{ vraie}) &= P(X > m | X \sim \text{Bin}(20, p)) \\ &= \sum_{i=m+1}^{20} \binom{20}{i} 0,5^m 0,5^{20-m} \end{aligned}$$

Par exemple, le seuil, donc la probabilité d'erreur de type I, sera de 41% si on choisit $m = 10$, de 5,7% si $m = 13$ et de 0,000095% si $m = 19$.

Calcul de la puissance

Généralement la puissance d'un test statistique dépend de «comment» H_0 est fausse. Plus précisément, plus la vraie valeur d'un paramètre s'éloigne de celle qui est supposée vraie sous H_0 , plus la puissance risque d'être grande pour un même seuil, et une même taille d'échantillon.

Exemple 3.11. Disons qu'on choisit $m = 12$ à l'exemple précédent. Sous H_1 , X suit une loi Binomiale avec $n = 20$ et paramètre p inconnu. La puissance est alors donnée par

$$\begin{aligned} P(\text{rejeter } H_0 | H_0 \text{ fausse}) &= P(X > 12 | X \sim \text{Bin}(20, p)) \\ &= \sum_{m=13}^{20} \binom{20}{m} p^m (1-p)^{20-m} \end{aligned}$$

Par exemple, si la vraie probabilité que la pièce tombe sur un pile est 0,9 la puissance sera excellente à 99,9%, mais si celle-ci est de seulement 0,6 alors la puissance ne sera que 41,6%. Pour augmenter la puissance sans modifier le seuil il faudrait augmenter la taille d'échantillon.

3.4.4 Valeur p (seuil observé)

En plus de donner la valeur de la statistique de test et d'indiquer si on rejette ou non l'hypothèse nulle, on calcule parfois une autre information nommée la valeur p , ou le seuil observé. Celle-ci peut donner un peu plus d'information sur un test d'hypothèse que simplement indiquer si on rejette H_0 ou non pour un seuil de test donné. En fait, elle permettra au lecteur d'utiliser le seuil qu'il désire pour le test d'hypothèse. Voici la définition de la valeur- p :

La valeur p est la probabilité d'observer une statistique de test aussi extrême ou plus extrême que celle observée si H_0 est vraie.

Une très petite valeur p indique que la statistique observée est très peu probable sous H_0 et nous amène donc à rejeter H_0 en faveur de H_1 .

En pratique, rejeter H_0 si la valeur- p est inférieure à un seuil donné, disons 0,05, équivaut à faire un test d'hypothèse à ce seuil. **La valeur p est donc le plus petit seuil α pour lequel on aurait rejeté H_0 .** On la nomme d'ailleurs également le **seuil observé**.

Remarque 3.9. Interpréter la valeur p

La valeur p est souvent mal interprétée. Notez que

- La valeur p n'est pas la probabilité que H_0 soit vraie.
- La valeur p n'est pas la probabilité de faire une erreur en rejetant l'hypothèse nulle.
- Une plus petite valeur p ne veut pas dire que la vérité est plus loin de l'hypothèse nulle.

Exemple 3.12. Considérons toujours notre exemple avec la loi Binomiale. On avait décidé de rejeter $H_0 : p = 0,5$ si X , le nombre de piles, était plus grand qu'une constante m . Disons qu'on observe la valeur $X = 16$. On rejetterait H_0 pour $m \leq 15$. Parmi ces choix de m , celui qui donne le test avec le plus petit seuil, soit la plus petite probabilité d'erreur de type I, est le choix $m = 15$. Le seuil observé, ou la valeur- p , est donc le seuil de ce test, et on peut le calculer :

$$\begin{aligned} P(\text{rejeter } H_0 | H_0 \text{ vraie}) &= P(X > 15 | X \sim \text{Bin}(20, 0,5)) \\ &= \sum_{i=16}^{20} \binom{20}{i} 0,5^i 0,5^{20-i} \\ &= 0,0059 \end{aligned}$$

On rejetterait donc H_0 avec ces données pour tout seuil supérieur à 0,0059, et donc en particulier pour $\alpha = 0,05$.

3.4.5 Faire un test d'hypothèse en pratique

Pour calculer une zone de rejet avec seuil de test de α , ou la valeur p d'un test statistique, il faut connaître la distribution sous H_0 de la statistique de test. On peut l'obtenir à l'aide de calculs théoriques en faisant des hypothèses sur la distribution des données. Il faut en outre choisir une statistique de test telle que sa distribution sous H_0 ne dépende pas de paramètres inconnus de la population ou du modèle.

Dans ces notes de cours, on ne s'attardera pas sur les techniques fréquemment utilisées pour obtenir des statistiques de test appropriées. On donnera plutôt à la prochaine section la distribution sous H_0 de plusieurs statistiques de test fréquemment utilisées. Comme pour les intervalles de confiance à la section précédente, on ne prouvera pas la forme de toutes ces distributions ici. Plusieurs découlent toutefois assez facilement de résultats présentés au début du chapitre.

Une fois qu'on a la distribution sous H_0 de la statistique de test, il est facile d'identifier la zone de rejet pour un seuil donné. Celle-ci s'écrit en terme des quantiles de la distribution en question, et tiendra compte du caractère unilatéral ou bilatéral du test. Il s'agit de garder en tête qu'on veut rejeter H_0 avec probabilité α si H_0 est vraie.

On peut également calculer la valeur p du test à l'aide de la table de la loi de la statistique de test sous H_0 , du moins pour plusieurs tests simples étudiés dans le cours.

Le calcul de la puissance est quant à lui possible facilement seulement dans certains cas très simples puisque calculer la puissance requiert la distribution de la statistique de test sous H_1 et non pas seulement sous H_0 .

On donne ci-dessous un exemple complet d'utilisation de la distribution sous H_0 d'une statistique de test.

Remarque 3.10. Lien avec les intervalles de confiance Les intervalles de confiance et les tests d'hypothèses sont deux façons de faire de l'inférence, et ils sont étroitement liés. Ainsi, on peut faire un test d'hypothèse en utilisant un intervalle de confiance. En effet, si $[L, U]$ est un intervalle de confiance de niveau $1 - \alpha$ pour un paramètre θ , alors tester au seuil α l'hypothèse $\theta = \theta_0$ versus $\theta \neq \theta_0$ est équivalent à rejeter H_0 si l'intervalle $[L, U]$ ne contient pas la valeur θ_0 .

Exemple 3.13. Exemple de test d'hypothèses

Une enseignante veut savoir si son deuxième examen était d'une difficulté similaire à son premier examen. Plus précisément, elle veut comparer les moyennes des résultats aux deux examens. Voici les données qu'elle a collectées pour ses 25 étudiants :

	Examen 1	Examen 2	Examen 1	Examen 2
1	71	74	82	79
2	86	74	69	73
3	78	79	63	72
4	75	79	77	77
5	68	70	79	76
6	72	85	76	75
7	77	70	78	91
8	81	81	72	69
9	78	78	85	73
10	77	73	86	77
11	81	82	76	82
12	86	76	84	79
13	82	75		

On peut calculer la note moyenne pour chacun des deux examens. On obtient 75,44% pour le premier et 78,88% pour le deuxième. Il semble donc que le deuxième examen ait été mieux réussi. Mais la différence n'est pas très grande et pourrait être simplement due au hasard. On peut utiliser un test d'hypothèse pour répondre plus rigoureusement à la question.

Modélisation :

Soit $X_{i,j}$ la note de l'étudiant i à l'examen j pour $i = 1, 2, \dots, 25$ et $j = 1, 2$. On suppose que les $X_{i,j}$ sont tirées de distributions de moyennes μ_1 pour l'examen 1 et μ_2 pour l'examen 2. On veut vérifier si $\mu_1 = \mu_2$.

Hypothèses sur les données :


Selon les hypothèses qu'on est prêt à faire sur les données, on peut utiliser l'un des quatre tests donnés à la section suivante pour comparer deux moyennes. Regardons plus en détails ces hypothèses :

- Indépendance à l'intérieur des échantillons

Pour tous les tests, on suppose l'indépendance des observations à l'intérieur de chaque population, c'est-à-dire que $X_{1,1}, X_{2,1}, \dots, X_{25,1}$ sont indépendantes et que $X_{1,2}, X_{2,2}, \dots, X_{25,2}$ sont indépendantes. Cette hypothèse devrait être valide ici si les élèves ont fait les examens individuellement, sans tricherie.

- Normalité des observations

Tous les tests donnés à la section suivante pour comparer deux moyennes font l'hypothèse que les données viennent de distributions normales, c'est-à-dire qu'on suppose que $X_{i,1}$ suit une loi normale de moyenne μ_1 et $X_{i,2}$ suit une loi normale de moyenne μ_2 . Les histogrammes ci-dessous montrent que cette hypothèse semble valide pour les données observées (en fait, je peux vous confirmer qu'elle est valide car les données ont été simulées de lois normales !). Sachez qu'il existe d'autres méthodes d'inférence que celles données dans ces notes qui peuvent comparer les moyennes de deux distributions même si les données ne suivent pas des loi normales.



- Indépendance des échantillons

Les trois premiers tests donnés supposent que les échantillons sont indépendants, c'est-à-dire que les $X_{i,1}$ sont indépendants des $X_{i,2}$. Ici, ce n'est sûrement pas le cas, puisque ce sont les mêmes étudiants qui ont fait les deux examens.

- Variances des échantillons

Les tests font également certaines hypothèses sur la variance des notes aux deux examens, σ_1^2 et σ_2^2 . Ici, les deux variances sont inconnues (elles le sont en fait rarement). Peuvent-elles être supposées égales ? On peut calculer que la variance échantillonnale des notes à l'examen 1 est de 26,92 et celle à l'examen 2 est de 28,69. Ces valeurs sont plutôt similaires, donc je serais prête à faire l'hypothèse que $\sigma_1^2 = \sigma_2^2$. (Et en effet, le test de comparaison de variances donné à la section suivante ne rejette pas l'égalité des variances).

Choix du test d'hypothèse :

Étant donné nos conclusions au sujet des hypothèses sur les données, le test approprié dans ce cas est celui pour deux échantillons appariés, utilisant la statistique de test $t_0 = \frac{\bar{D}}{S_D/\sqrt{n}}$ qui suit une loi t_{n-1} sous $H_0 : \mu_1 = \mu_2$. On note que ce test ne suppose pas l'égalité des variances, mais ce n'est pas grave : le test reste valide si $\sigma_1^2 = \sigma_2^2$.

Calcul de la statistique de test :

La statistique de test est

$$t_0 = \frac{\bar{D}}{S_D/\sqrt{n}}$$

où $D_j = X_{1j} - X_{2j}$ ($j=1, \dots, n$), $\bar{D} = \frac{1}{n} \sum_{j=1}^n D_j$ et $S_D = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (D_j - \bar{D})^2}$.

Par exemple, $D_1 = -3$, l'étudiant 1 ayant obtenu une note inférieure de 3 points de pourcentage à l'examen 2. Les calculs sont un peu long à la main, mais on peut trouver

$$t_0 = \frac{-3,44}{21.25667/5} = -0,8091579$$

Identification de la zone de rejet :

Les notes indiquent que la statistique de test suit une loi t_{n-1} , et donc une loi t_{24} dans ce cas, sous H_0 . On veut savoir si les examens sont de même niveau, ce qui veut dire que nos hypothèses sont $H_0 : \mu = \mu_2$ versus $H_0 : \mu \neq \mu_2$. Ainsi, on rejettera H_0 si la statistique de test est très grande ou très petite. Pour un test de seuil α , on rejettera donc H_0 si t_0 est inférieure à $t_{24,\alpha/2} =$ ou supérieure à $t_{24,1-\alpha/2}$.

Décision :

La décision dépendra du seuil choisi. Pour $\alpha = 0,05$, on doit rejeter si t_0 est inférieure à $t_{24,0.0025} = -2,06$ ou supérieure à $t_{24,0.975} = 2,06$, les valeurs exactes pouvant être obtenues dans les tables de loi ou à l'aide d'un logiciel statistique. Puisque $-0,8091579 > -2,06$, on ne rejette pas l'hypothèse nulle.

Conclusion :

Au seuil $\alpha = 0.05$, on ne rejette pas H_0 et on conclut que les moyennes des deux examens sont identiques.

Calcul de la valeur p :

Il s'agit ici de trouver le plus petit seuil pour lequel on aurait rejeté H_0 . On peut trouver dans une table de la loi t ou à l'aide d'un logiciel que la probabilité qu'une variable aléatoire de loi t_{24} soit inférieure à $t_0 = -0,8091579$ est 0,2319. Puisque notre test est bilatéral, la valeur p du test est donc $2 \times 0,2319 = 0.4638$, qui est sans surprise supérieure à 0,05.

3.4.6 Quelques résultats connus

Tests d'hypothèses sur une moyenne μ

Situation	Distribution de la statistique du test sous $H_0 : \mu = \mu_0$
$X_1, \dots, X_n$ indép. $N(\mu, \sigma^2)$ où σ^2 est connue	$Z_0 = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$
$X_1, \dots, X_n$ indép. $N(\mu, \sigma^2)$ où σ^2 est inconnue	$t_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}$
$X_1, \dots, X_n$ indép., loi quelconque, où σ^2 est inconnue et n est grand	$Z_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim N(0, 1)$ approximativement

Test d'hypothèse sur une variance σ^2

Situation	Distribution de la statistique du test sous $H_0 : \sigma^2 = \sigma_0^2$
$X_1, \dots, X_n$ indép. $N(\mu, \sigma^2)$ μ est inconnue	$\chi_0^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$

Test d'hypothèse sur une proportion p

Situation	Distribution de la statistique du test sous $H_0 : p = p_0$
$X_1, \dots, X_n$ indép. Bernoulli(p) où n est grand	$Z_0 = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim N(0, 1)$ approximativement où $\hat{p} = \sum_{i=1}^n X_i/n$

Notez qu'on pourrait également faire un test exact comme dans les exemples de ce chapitre en utilisant le fait que $X = \sum_{i=1}^n X_i \sim \text{Bin}(n, p)$ sous H_0 .

Comparaison de deux moyennes

Échantillons indépendants	
Situation	Distribution de la statistique du test sous $H_0 : \mu_1 = \mu_2$
$X_{1,1}, \dots, X_{1,n_1}$ indép. $N(\mu_1, \sigma_1^2)$ $X_{2,1}, \dots, X_{2,n_2}$ indép. $N(\mu_2, \sigma_2^2)$ où σ_1^2 et σ_2^2 sont connues	$Z_0 = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$
$X_{1,1}, \dots, X_{1,n_1}$ indép. $N(\mu_1, \sigma_1^2)$ $X_{2,1}, \dots, X_{2,n_2}$ indép. $N(\mu_2, \sigma_2^2)$ où σ_1^2 et σ_2^2 sont inconnues mais égales ($\sigma_1^2 = \sigma_2^2$)	$t_0 = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$ où $S_p = \sqrt{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}}$
$X_{1,1}, \dots, X_{1,n_1}$ indép. $N(\mu_1, \sigma_1^2)$ $X_{2,1}, \dots, X_{2,n_2}$ indép. $N(\mu_2, \sigma_2^2)$ où σ_1^2 et σ_2^2 sont inconnues et inégales ($\sigma_1^2 \neq \sigma_2^2$)	$t_0 = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim t_v$ où $v = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1+1} + \frac{(S_2^2/n_2)^2}{n_2+1}} - 2$
Échantillons appariés	
Situation	Distribution de la statistique de test sous $H_0 : \mu_1 = \mu_2$
$X_{1,1}, \dots, X_{1,n}$ indép. $N(\mu_1, \sigma_1^2)$ $X_{2,1}, \dots, X_{2,n}$ indép. $N(\mu_2, \sigma_2^2)$ $D_j = X_{1j} - X_{2j} \ (j=1, \dots, n)$ où σ_D^2 est inconnue	$t_0 = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t_{n-1}$ $\bar{D} = \frac{1}{n} \sum_{j=1}^n D_j \quad , \quad S_D = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (D_j - \bar{D})^2}$

Comparaison de deux variances

Situation	Distribution de la statistique de test sous $H_0 : \sigma_1^2 = \sigma_2^2$
$X_{1,1}, \dots, X_{1,n_1}$ indép. $N(\mu_1, \sigma_1^2)$ $X_{2,1}, \dots, X_{2,n_2}$ indép. $N(\mu_2, \sigma_2^2)$ où σ_1^2 et σ_2^2 sont inconnues	$F_0 = \frac{s_1^2}{s_2^2} \sim F_{n_1-1, n_2-1}$

Comparaison de deux proportions

Situation	Distribution de la statistique de test sous $H_0 : p_1 = p_2$
X_1 : nombre de "succès" parmi n_1 ($n_1 \geq 30$) X_2 : nombre de "succès" parmi n_2 ($n_2 \geq 30$)	$Z_0 = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} \stackrel{\text{app}}{\sim} N(0, 1)$ où $\hat{p} = \frac{(X_1 + X_2)}{n_1 + n_2}$

3.5 Inférence à partir de données de sondage

Les procédures d'inférence des sections précédentes ne s'appliquent pas nécessairement à des données de sondage dans une population finie. Deux raisons :

1. On doit tenir compte des probabilités de sélection
Tel que discuté aux sections 1.1.7 et 2.9, on ne peut pas simplement estimer la moyenne de la population par la moyenne échantillonnale si on utilise une méthode d'échantillonnage pour laquelle les individus n'ont pas tous la même probabilité de sélection. Il faut prendre en compte ces probabilités pour obtenir un estimateur sans biais de la moyenne dans la population.
2. On doit tenir compte de la taille finie de la population
Dans le cas extrême où on a un échantillon de taille n égale à N la taille de la population, on connaît la valeur de la variable d'intérêt pour tous les individus. On n'a donc aucune incertitude sur la moyenne de la population. Plus généralement, la précision de notre estimation de la moyenne dépend non seulement de n mais de la taille relative de N par rapport à n .

Notez que la dérivation des estimateurs et intervalles de confiance dans le présent chapitre s'appuie toujours sur un modèle statistique pour les observations. Plus précisément, dans le cas d'un seul échantillon on suppose toujours que les observations sont indépendantes et identiquement distribuées, $X_1, \dots, X_n \stackrel{iid}{\sim} F_X$ pour une loi F_X . Quand on s'intéresse à un échantillon d'une population finie, ce modèle n'est pas toujours approprié.

Un élément clé est que **les valeurs de l'échantillon sont tirées d'une population finie, et cette population est considérée fixe**. On ne tente donc pas d'estimer un paramètre de modèle, par exemple la moyenne d'une loi normale de laquelle les observations auraient été tirées, mais bien une valeur, par exemple une moyenne, qu'on pourrait connaître exactement en effectuant un recensement.

Par conséquent les observations ne peuvent pas être considérées indépendantes pour un échantillonnage sans remise. En effet, disons que la population est l'ensemble $\{1, 2, 3, 4, 5\}$ et qu'on tire un échantillon de taille deux de celle-ci, X_1, X_2 , par échantillonnage aléatoire simple (ÉAS) sans remise. Si on obtient $x_1 = 3$, c'est-à-dire qu'on pige un 3 au premier tour, on sait qu'il est impossible que $x_2 = 3$. Les variables aléatoires X_1 et X_2 ne sont donc pas indépendantes. De plus, on ne peut pas supposer que X_1 et X_2 sont tirées d'une même distribution F_X , comme on le fait habituellement.

On voit donc que le modèle $X_1, \dots, X_n \stackrel{iid}{\sim} F_X$ n'est pas approprié pour un ÉAS sans remise d'une population de taille finie.

En fait, les intervalles de confiance et tests d'hypothèse présentés plus tôt dans ce chapitre ne sont valides que dans les trois cas suivants :

1. Population "vraiment" infinie (c'est-à-dire un modèle)
2. $n \ll N$
3. Population finie, mais échantillonnage avec remise

Pour tout autre méthode d'échantillonnage d'une population finie, l'inférence classique n'est pas appropriée, et on doit utiliser d'autres techniques. Bien que des cours entiers soient dédiés à l'inférence dans le contexte d'une population finie, on ne verra ici que comment obtenir un intervalle de confiance pour la moyenne pour un ÉAS sans remise et pour un échantillonnage stratifié.

3.5.1 Inférence sur la moyenne pour un ÉAS sans remise

Dans un ÉAS, les probabilités de sélection sont identiques pour toutes les unités. La moyenne échantillonnale est donc un estimateur sans biais, comme quand l'échantillon ne vient pas d'une population finie. Mathématiquement, on a

$$E(\bar{X}) = \mu, \quad (3.9)$$

La preuve est toutefois complètement différente que dans le cas d'observations tirées d'un modèle, car ce ne sont pas les observations qui sont des variables aléatoires, mais l'appartenance de chaque observation à l'échantillon. La preuve est disponible à l'annexe 3.9.

L'intervalle de confiance classique basé sur le théorème limite central $\bar{X} \pm z_{\alpha/2} S/\sqrt{n}$ n'est toutefois pas valide dans ce cas. En effet, il ne tient pas compte du fait que la population est finie et on doit en dériver un nouveau.

D'abord, on peut montrer que

$$Var(\bar{X}) = \frac{\sigma^2}{n} \left(1 - \frac{n-1}{N-1}\right) = \frac{\sigma^2}{n} \left(\frac{N-n}{N-1}\right) \quad (3.10)$$

au lieu du classique $Var(\bar{X}) = \frac{\sigma^2}{n}$ avec un ÉAS avec remise. La preuve de 3.10 utilise une technique similaire à celle de 3.9, mais est un peu plus complexe, et elle est omise.

Il est important de noter que puisque $\frac{N-n}{N-1} < 1$, une moyenne de n observations tirées sans remise d'une population finie de taille N est moins variable que si elle est tirée d'une population infinie, ou avec remise. Plus n est grand par rapport à N , plus la différence de variance est grande. À la limite, si $n = N$, chaque échantillon tiré sans remise contient les mêmes individus et la variance est nulle.

Maintenant, en pratique on ne connaît pas σ^2 ; il faut donc l'estimer. Notons que σ^2 , la variance dans la population, est ici

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2. \quad (3.11)$$

Comme à l'habitude, on considère la variance échantillonnale pour estimer σ^2 . On peut montrer que pour un ÉAS sans remise d'une population finie,

$$E(S^2) = \frac{N}{N-1} \sigma^2 \quad (3.12)$$

Un estimateur non biaisé de σ^2 serait donc

$$\widehat{\sigma^2} = \frac{N-1}{N} S^2 \quad (3.13)$$

En combinant 3.10 et 3.13, on obtient

$$\begin{aligned} \widehat{Var(\bar{X})} &= \frac{\widehat{\sigma^2}}{n} \left(\frac{N-n}{N-1} \right) \\ &= \frac{N-1}{N} S^2 \frac{1}{n} \left(\frac{N-n}{N-1} \right) \\ &= \left(\frac{N-n}{N} \right) \frac{S^2}{n} \\ &= \left(1 - \frac{n}{N} \right) \frac{S^2}{n} \end{aligned}$$

Notre estimateur pour la variance de la moyenne échantillonnale dans un ÉAS sans remise d'une population finie est donc $\widehat{Var(\bar{X})} = \left(1 - \frac{n}{N} \right) \frac{S^2}{n}$, qu'on ré-écrit souvent sous la forme

$$\widehat{Var(\bar{X})} = (1-f) \frac{S^2}{n} \quad (3.14)$$

où

$$f = \frac{n}{N}$$

est nommée la fraction de sondage, ou parfois le taux d'échantillonnage. On voit que plus f augmente, plus $\widehat{Var(\bar{X})}$ diminue, car les échantillons sont moins variables.

On souhaiterait maintenant obtenir un intervalle de confiance pour la moyenne. Les intervalles de confiance exacts basés sur la loi normale (où σ^2 est connu) ou sur la loi t (où σ^2 est estimé), et même l'intervalle de confiance approximatif basé sur le TLC, ne sont plus valides car la population est finie et l'échantillonnage se fait sans remise. On peut toutefois montrer que si les données proviennent d'une loi normale approximative ou si n est grand, alors un IC approximatif de niveau $1 - \alpha$ pour μ est donné par

$$\bar{X} \pm z_{\alpha/2} \sqrt{(1-f) \frac{S^2}{n}} \quad (3.15)$$

Exemple 3.14.

(Source : Alalouf, S., *Introduction à la statistique appliquée*, 2^e éd., 1990, p. 282.)

D'une population de 8427 comptes à recevoir, on prélève un échantillon de taille 30 afin d'estimer la valeur moyenne d'un compte. Voici les résultats :

$$\bar{x} = 165,62 \$ \quad s^2 = 35\,930,59 \2$

On souhaite construire un intervalle de confiance à 95% pour le véritable montant moyen d'un compte. Il s'agit simplement de remplacer les quantités dans l'équation 3.18. On a l'intervalle approximatif suivant

$$\begin{aligned} & \bar{x} \pm z_{\alpha/2} \sqrt{(1-f) \frac{s^2}{n}} \\ & 165,62 \pm 1,96 \sqrt{\left(1 - \frac{30}{8427}\right) \frac{35930,59}{30}} \\ & 165,62 \pm 1,96 * 34,55 \\ & 165,62 \pm 67,71 \end{aligned}$$

L'intervalle de confiance est donc

$$(97,90 \$, 233,34 \$).$$

L'erreur-type dans ce cas est de 34,55, la marge d'erreur étant de 67,71.

Notez que l'intervalle aurait été plus grand si on n'avait pas tenu compte du fait que la population est finie. En effet, on aurait obtenu

$$\begin{aligned} & \bar{x} \pm z_{\alpha/2} \sqrt{\frac{s^2}{n}} \\ & 165,62 \pm 1,96 \sqrt{\frac{35930,59}{30}} \\ & 165,62 \pm 1,96 * 34,61 \\ & 165,62 \pm 67,83 \end{aligned}$$

La différence ici n'est pas très grande entre les deux intervalles de confiance puisque $\frac{30}{8427}$ n'est pas une grande fraction de sondage.

3.5.2 Inférence pour l'échantillonnage stratifié

Pour l'échantillonnage aléatoire stratifié, on doit tenir compte du fait que les observations n'ont peut-être pas toutes la même probabilité de sélection, en plus de l'impact de la population finie. On a déjà présenté à la section 2.9 un estimateur sans biais pour la moyenne dans le cas de l'échantillonnage stratifié. On verra maintenant comment obtenir une marge d'erreur pour cet estimateur.

On aura besoin d'un peu de notation additionnelle, et on en profite pour rappeler la notation déjà vue au sujet de l'échantillonnage stratifié. Pour chaque strate k , on définit

N_k : la taille de la strate k dans la population

μ_k : la moyenne de la strate k dans la population

σ_k^2 : la variance de la strate k dans la population

n_k : la taille de l'échantillon tiré de la strate k

$f_k = \frac{n_k}{N_k}$: la fraction de sondage dans la strate k

$\bar{X}_k$: la moyenne échantillonnale pour la strate k

S_k^2 : la variance échantillonnale pour la strate k

$\bar{x}_k$: la moyenne échantillonnale observée pour la strate k

s_k^2 : la variance échantillonnale observée pour la strate k

Rappelons qu'un estimateur sans biais pour la moyenne est donné par

$$\hat{\mu}_{strat} = \bar{x}_{strat} = \sum_{k=1}^K \frac{N_k}{N} \bar{X}_k \quad (3.16)$$

Puisque cet estimateur est une combinaison linéaire d'estimateurs simples, les $\bar{X}_k$, et que ceux-ci sont indépendants, on peut facilement sa variance.

$$\begin{aligned}
 \text{Var}(\hat{\mu}_{strat}) &= \text{Var}\left(\sum_{k=1}^K W_k \bar{X}_k\right) \\
 &= \sum_{k=1}^K \text{Var}(W_k \bar{X}_k) \\
 &= \sum_{k=1}^K W_k^2 \text{Var}(\bar{X}_k) \\
 &= \sum_{k=1}^K W_k^2 \left(\frac{N_k - n_k}{N_k - 1}\right) \frac{\sigma_k^2}{n_k}
 \end{aligned}$$

Rappelons que la dernière ligne se justifie par l'équation 3.10, selon laquelle $\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \left(\frac{N-n}{N-1}\right)$.

En pratique, on doit estimer les σ_k^2 et on obtient

$$\widehat{\text{Var}(\hat{\mu}_{strat})} = \sum_{k=1}^K W_k^2 (1 - f_k) \frac{S_k^2}{n_k} \quad (3.17)$$

Si les données proviennent de lois normales approximatives, que la taille d'échantillon est assez grande dans chaque strate, ou qu'on utilise un grand nombre de strates, alors un IC approximatif de niveau $1 - \alpha$ pour μ est donné par

$$\hat{\mu}_{strat} \pm z_{\alpha/2} \sqrt{\sum_{k=1}^K W_k^2 (1 - f_k) \frac{S_k^2}{n_k}} \quad (3.18)$$

On voit que la variance de l'estimateur de la moyenne pour un échantillonnage stratifié est plutôt complexe, et dépend de plusieurs propriétés des strates, et du nombre d'observations tirées dans chaque strate.

On a dit au chapitre 1 que l'échantillonnage stratifié permet d'augmenter la précision de l'estimateur, c'est-à-dire d'obtenir une variance inférieure qu'avec un ÉAS, et donc des intervalles de confiance plus étroits, pour une même taille globale d'échantillon. Pour obtenir ce gain d'efficacité, il faut d'abord que la variable de stratification ait été choisie judicieusement, de sorte que les S_k^2 soient petits. Il faut également attribuer judicieusement les n observations à tirer parmi les K strates.

Allocation optimale de l'échantillon dans les strates

La formule de variance obtenue à l'équation 3.17 nous permet en fait d'identifier dans quelles circonstances la variance, et donc la marge d'erreur pour l'intervalle de confiance associé, sera minimale. Plus précisément, pour des strates déjà définies, on peut trouver comment allouer de façon optimale l'échantillon dans les strates, c'est-à-dire comment choisir $n_1, \dots, n_K$. Il se trouve que les strates ayant des observations plus variables devront avoir de plus grandes tailles d'échantillons.

En effet, on peut montrer que pour minimiser la variance globale de $\hat{\mu}_{strat}$, il faut choisir

$$\frac{n_k}{n} = \frac{N_k \sigma_k}{\sum_k N_k \sigma_k}$$

et donc

$$n_k = n \frac{W_k \sigma_k}{\sum_k W_k \sigma_k} = n \frac{N_k \sigma_k}{\sum_k N_k \sigma_k}.$$

La preuve de l'optimalité de cette allocation utilise les multiplicateurs de Lagrange et est omise ici.

Le nombre d'unités échantillonnées dans chaque strate est donc proportionnel à l'écart-type pondéré de cette strate par rapport à l'écart-type pondéré global. Évidemment, on ne connaît pas toujours la variance dans une strate. Mais si on peut l'estimer à partir d'études précédentes ou d'études pilotes, cela nous permettra de mieux choisir les tailles d'échantillons.

Exemple 3.15. *On veut planifier un sondage pour estimer une moyenne en stratifiant à l'aide de trois strates. Voici ce que nous savons de la population.*

Strate k	N_k	σ_k
1	50 000	5
2	100 000	10
3	200 000	5

Supposons qu'on souhaite sélectionner globalement $n = 600$ individus, et qu'on souhaite utiliser l'allocation optimale, combien doit-on en choisir dans chaque strate ? Dans ce cas, on obtient

$$n_1 = n \frac{N_1 \sigma_1}{\sum_k N_k \sigma_k} = 600 \times \frac{50\,000 \times 5}{50\,000 \times 5 + 100\,000 \times 10 + 200\,000 \times 5} = 600 \times \frac{25}{225} \approx 66,67$$

$$n_2 = n \frac{N_2 \sigma_2}{\sum_k N_k \sigma_k} = 600 \times \frac{100\,000 \times 10}{50\,000 \times 5 + 100\,000 \times 10 + 200\,000 \times 5} = 600 \times \frac{100}{225} \approx 266,67$$

$$n_3 = n \frac{N_3 \sigma_3}{\sum_k N_k \sigma_k} = 600 \times \frac{200\,000 \times 5}{50\,000 \times 5 + 100\,000 \times 10 + 200\,000 \times 5} = 600 \times \frac{100}{225} \approx 266,67$$

Pour respecter $n = 600$, on pourrait prendre $n_1 = 66, n_2 = 267, n_3 = 267$.

Notez que $n_2 = n_3$, bien que $N_3 = 2N_2$. C'est parce que l'écart-type dans la strate 3 est deux fois plus petit que dans la strate 2, et donc on a besoin d'autant d'observations pour obtenir une estimation de même précision.

Voyons ce que l'allocation proportionnelle aurait donné :

$$n_1 = \frac{N_1}{N} n = \frac{50\,000}{350\,000} \times 600 \approx 85,7$$

$$n_2 = \frac{N_2}{N} n = \frac{100\,000}{350\,000} \times 600 \approx 171,4$$

$$n_3 = \frac{N_3}{N} n = \frac{200\,000}{350\,000} \times 600 \approx 342,8$$

Pour respecter $n = 600$, on prendrait $n_1 = 86, n_2 = 171, n_3 = 343$. On n'aurait probablement pas une marge d'erreur optimale, mais les poids de toutes les observations seraient identiques, ce qui simplifierait les calculs.

3.5.3 Post-stratification

On complète la section sur l'inférence à partir de données de sondage en présentant la technique de post-stratification, fréquemment utilisée pour améliorer l'inférence dans ce contexte.

Rappelons que la stratification peut aider à l'obtention d'un échantillon représentatif, mais qu'il n'est pas toujours possible de stratifier, car il faut alors connaître une variable reliée à la variable d'intérêt pour tous les individus de la population.

L'idée de la post-stratification est d'apporter une correction *a posteriori* au calcul de la moyenne et de son erreur-type. Pour ce faire, on doit mesurer lors du sondage la variable qu'on aurait aimé utiliser pour stratifier. Puis, on attribue un poids à chaque individu de l'échantillon en fonction de la strate à laquelle il appartient. On va donner un poids plus grand dans l'estimation de la moyenne aux observations faisant partie des strates qui ont été sous-représentées dans l'échantillonnage aléatoire.

L'estimateur de la moyenne avec post-stratification est le même que celui pour un échantillonnage stratifié :

$$\hat{\mu}_{PS} = \sum_{k=1}^K W_k \bar{X}_k = \sum_{k=1}^K \frac{N_k}{N} \bar{X}_k \quad (3.19)$$

Exemple 3.16. Supposons qu'on procède à un échantillonnage aléatoire simple sans remise de 100 individus dans une population comprenant 40% de femmes. On demande leur sexe aux individus qu'on interroge. Par hasard, on obtient la répartition et les résultats suivants :

Groupe	N	n	Moyenne	Variance
Hommes	60 000	45	20	4
Femmes	40 000	55	30	9
Total	100 000	100		

Quelle serait l'estimation de la moyenne avec l'échantillonnage aléatoire simple ?

$$\hat{\mu}_{EAS} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{100} (45 \times 20 + 55 \times 30) = 25,50$$

Quelle serait l'estimation de la moyenne avec une stratification a posteriori ?

$$\hat{\mu}_{PS} = \sum_{k=1}^K W_k \bar{x}_k = \frac{6}{10} \times 20 + \frac{4}{10} \times 30 = 24.$$

Remarque 3.11. Estimer la variance de $\hat{\mu}_{PS}$ est plus complexe. Si n_k est assez grand (plus que 30 environ) pour toutes les post-strates et que n est grand (disons plus que 200), la variance de l'estimation de la moyenne pour l'échantillonnage stratifié avec allocation proportionnelle en est une bonne estimation.

AUTRES NOTES

AUTRES NOTES

AUTRES NOTES

Chapitre 4

Régression linéaire simple

On a déjà vu au chapitre 2 qu'on peut visualiser la relation entre deux variables continues à l'aide d'un diagramme de dispersion ou d'un diagramme temporel. On a également défini le coefficient de corrélation de Pearson et le coefficient de corrélation de Spearman, deux mesures empiriques de la corrélation entre deux variables aléatoires continues.

On s'intéresse ici spécifiquement à la relation linéaire entre deux variables aléatoires, que nous modéliserons à l'aide d'un modèle de régression linéaire simple.

Ce chapitre renferme plusieurs sections, notamment

1. Des rappels sur la covariance et la corrélation
2. Une description du contexte et des objectifs de la régression
3. La description du modèle de régression linéaire simple
4. La présentation de trois méthodes d'estimation des paramètres
5. Plusieurs méthodes d'inférence pour la méthode des moindres carrés, incluant des informations sur la vérification des conditions pour l'inférence

4.1 Covariance et corrélation

4.1.1 Covariance théorique

La covariance théorique entre deux variables aléatoires X et Y est une **mesure d'association linéaire** définie comme suit :

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X\mu_Y \quad (4.1)$$

On peut **interpréter** le signe de la covariance :

- Si $Cov(X, Y) > 0$, alors la relation est croissante.
- Si $Cov(X, Y) < 0$, alors la relation est décroissante.
- Si $Cov(X, Y) = 0$, alors il n'y a aucune relation linéaire entre les variables.

Notez qu'une covariance nulle implique l'absence de relation linéaire entre les variables, et non pas l'indépendance des variables. Toutefois, deux variables aléatoires indépendantes auront nécessairement une covariance nulle.

La covariance peut prendre n'importe quelle valeur réelle et ses unités sont le produit des unités de la variable X et des unités de la variable Y . Cela en fait une mesure relativement difficile à interpréter, contrairement à la corrélation qui sera présentée à la prochaine section.

Il est bon de rappeler **quelques propriétés de la covariance théorique** :

- 1) $Cov(X, X) = Var(X)$
- 2) $Cov(X, Y) = Cov(Y, X)$
- 3) $Cov(aX, Y) = aCov(X, Y)$ pour une constante a
- 4) $Cov(X + b, Y) = Cov(X, Y)$ pour une constante b
- 5) $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

4.1.2 Covariance échantillonnale

Soit un échantillon (x_i, y_i) de paires de valeurs observées sur n individus. On peut l'utiliser pour estimer la covariance théorique par la covariance échantillonnale :

$$\widehat{Cov}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1} = \frac{S_{XY}}{n - 1} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{n - 1} \quad (4.2)$$

4.1.3 Corrélation théorique

Pour régler le problème des unités de la covariance, on utilise plus souvent le coefficient de corrélation entre X et Y pour mesurer la relation entre ces variables. Il est défini ainsi :

$$\rho = \frac{Cov(X, Y)}{\sqrt{Var(X) Var(Y)}} \quad (4.3)$$

Ce coefficient n'a aucune unité, et sera toujours compris entre -1 et 1 . Son signe s'interprète comme celui de la covariance. En outre, plus le coefficient de corrélation est proche de 1 plus la corrélation entre les deux variables est grande.

4.1.4 Corrélation échantillonnale

On estime la corrélation par le coefficient de corrélation échantillonnal r . Ce coefficient a déjà été défini au chapitre 2, mais on rappelle la formule ici :

$$r = \frac{\widehat{Cov}(X, Y)}{S_x S_y} = \frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \cdot \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{S_{XY}}{\sqrt{S_{XX} S_{YY}}} \quad (4.4)$$

Rappelons que ce coefficient n'a aucune unité, qu'il prend des valeurs entre -1 et 1 et qu'il est invariable sous transformation linéaire de l'une ou l'autre des variables X et Y (ou les deux). La figure suivante montre quelques exemples.




FIGURE 4.1 – Illustration de corrélations de 0,3, 0,6 et 0,9 et -0,3, -0,6 et -0,9

4.2 Contexte et objectifs

4.2.1 La régression

L'origine du mot *régression* vient de Sir Francis Galton (1822–1911), homme de science britannique. En 1886, en travaillant sur l'hérédité, il s'est intéressé à la taille des enfants par rapport à leurs parents. Il constata que lorsque les parents étaient plus grands que la moyenne, leurs enfants avaient tendance à être plus petits qu'eux et que, inversement, lorsque les parents étaient plus petits que la moyenne leurs enfants tendaient à être plus grands qu'eux. Il publia sa découverte dans l'article *Regression towards mediocrity in hereditary stature*. Il utilisa le terme régression dans le sens où les parents de taille extrême (petits et grands) voient en moyenne la taille de leurs enfants régresser vers la moyenne.

Par extension, on utilise maintenant le terme analyse de régression pour désigner l'étude des relations qui existent entre des variables mesurables à partir d'observations (données) prises sur ces variables. Plus précisément, c'est une technique de modélisation qui vise à expliquer une variable Y en fonction d'une ou de plusieurs variables $x_1, \dots, x_p$. Cela peut s'exprimer mathématiquement par

$$Y = f(x_1, \dots, x_p). \quad (4.5)$$

La variable Y est appelée **variable endogène**. Ce terme signifie, selon le Larousse, « qui est produit par la structure elle-même en dehors de tout apport extérieur ». On appelle également la variable Y variable réponse ou variable dépendante.

À l'opposé, les variables $x_1, \dots, x_p$ se sont pas expliquées par le modèle et on les nomme donc **variables exogènes**, qui signifie « qui provient du dehors, de l'extérieur du phénomène, par opposition à endogène ». On utilise également les termes prédicteurs, variables explicatives, facteurs, covariables et variables indépendantes pour faire référence aux variables $x_1, \dots, x_p$. Je préfère le premier terme, prédicteur, car il clarifie que ces variables ne sont pas nécessairement causales pour la variable réponse, et qu'elles ne sont pas nécessairement indépendantes les unes des autres.

4.2.2 Régression déterministe ou stochastique

Dans certains cas, la relation entre les variables est exacte et donc la valeur de Y est uniquement déterminée par les valeurs de $x_1, \dots, x_p$. Le modèle de régression est alors un modèle dit **déterministe**. On peut imaginer par exemple que la variable exogène x soit la longueur de l'arête d'un carré, et que la variable endogène Y soit l'aire de ce carré. On aurait alors $Y = f(x) = x^2$ exactement, et ce peut importe la valeur de x .

Il est aussi possible que les données soient entachées d'une erreur de mesure (expérimentale) ou que les facteurs utilisés dans le modèle ne permettent pas d'expliquer complètement la variable réponse. Les valeurs de $x_1, \dots, x_p$ expliquent dans ce cas une partie de Y , alors que l'autre partie demeure inexpliquée. On parle alors de modèle **stochastique**. Par exemple, on peut vouloir prédire le poids d'un bébé à la naissance en fonction du nombre de jours de gestation. Bien qu'il y ait une relation entre ces deux variables, deux bébés nés avec la même durée de gestation n'auront pas nécessairement exactement le même poids à la naissance.

Dans plusieurs domaines où on s'intéresse à l'effet des variables les unes sur les autres, le modèle stochastique est le plus approprié. Pensons par exemple au lien entre le revenu moyen d'un pays et l'espérance de vie de sa population, ou encore à l'effet de la température en hiver sur l'achalandage dans une station de ski. Dans ce cours, on s'intéressera uniquement aux modèles de régression stochastique.

4.2.3 Régression linéaire simple

Avec un nombre fini d'observations, on doit faire des hypothèses sur la fonction de régression $f(x_1, \dots, x_p)$ pour pouvoir l'estimer. On supposera ici une fonction linéaire. La contrainte de linéarité limite le type de relations qu'on pourra modéliser entre les variables. La régression linéaire est toutefois suffisante pour plusieurs situations, et largement utilisée en pratique.

De plus, nous nous limiterons au cas où un seul prédicteur (variable exogène) est considérée. Ce modèle est alors appelé **régression linéaire simple**.

Les objectifs possibles d'une analyse de régression linéaire simple sont les suivants :

- Vérifier si une relation linéaire existe entre les variables aléatoires continues Y (variable réponse) et X (prédicteur).
- Mesurer la force du lien linéaire qui unit les variables X et Y .
- Trouver la « meilleure droite » exprimant la relation entre les 2 variables à partir de n paires d'observations indépendantes (X_i, Y_i) .
- Prédire la valeur de Y pour un X donné, et évaluer la précision de ces prédictions.

4.3 Modèle de régression linéaire simple

Le modèle de régression linéaire simple s'exprime comme suit :

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad 1 \leq i \leq n. \quad (4.6)$$

où $Y_1, \dots, Y_n$ sont n observations de la variable endogène (variable réponse) ;

$x_1, \dots, x_n$ sont n observations du prédicteur (variable explicative) ;

β_0 est le paramètre associé à l'ordonnée à l'origine de la droite ;

β_1 est le paramètre associé à la pente de la droite ;

ε_i est un terme d'erreur ;

et n est le nombre d'observations.

Notez que la présence du terme d'erreur est requise à cause de l'aspect stochastique du modèle. Afin de pouvoir interpréter plus facilement les paramètres du modèles, nous faisons toujours l'hypothèse que l'espérance du terme d'erreur est égale à zéro pour toutes les observations.

Le modèle peut convenir aux données obtenues selon deux scénarios :

1. Les valeurs de X sont fixées d'avance

Par exemple, disons qu'un chimiste veut mesurer l'effet de la température sur la vitesse de réaction lors du mélange de deux liquides. Il peut réaliser son expérience à plusieurs reprises et contrôler la température des liquides, en la fixant à différentes valeurs. Il mesure chaque fois la vitesse de réaction.

2. Les valeurs de X et de Y sont aléatoires

Par exemple, disons qu'une chercheuse en obstétrique veut étudier le lien entre le poids de la mère et le poids du nouveau-né. Elle sélectionnera des femmes enceintes au hasard, et mesurera le poids du bébé et de la mère au moment de l'accouchement.

Pour le cours, on considèrera toutefois toujours que les valeurs de X sont fixes et connues, et que seule la variable Y est aléatoire. Cela facilitera beaucoup le traitement théorique du modèle et des estimateurs. Notez toutefois que la plupart des résultats que nous énoncerons et prouverons sont également valides si les deux variables sont aléatoires.

Remarque 4.1. *Il est important de comprendre quelles grandeurs sont supposées constantes ou aléatoires dans le modèle (4.6), à savoir*

- $Y_i, \dots, Y_n$ sont les réalisations connues d'une variable aléatoire ;
- $x_1, \dots, x_n$ sont des valeurs connues et considérées constantes ;
- β_0 et β_1 , les paramètres du modèle, sont constants, mais inconnus, et il faudra par conséquent les estimer ;
- $\varepsilon_1, \dots, \varepsilon_n$ sont les réalisations inconnues d'une variable aléatoire.

4.3.1 Interprétation des paramètres

La figure 4.2 illustre le modèle de régression linéaire simple. La ligne droite représente la valeur attendue de Y en fonction de la valeur de x . Les valeurs observées de Y sont distribuées de façon aléatoire autour de cette droite. Les termes d'erreur sont les différences entre les valeurs observées de Y et la droite.

On interprète donc β_0 comme la valeur moyenne de Y lorsque x vaut zéro et β_1 comme l'accroissement moyen de Y lorsque x augmente d'une unité. Si $\beta_0 = 0$, l'espérance de Y est nulle lorsque x vaut zéro, et le modèle ne comporte pas d'ordonnée à l'origine. Si $\beta_1 = 0$, l'espérance de Y ne dépend pas de x , du moins pas de façon linéaire.




FIGURE 4.2 – Illustration du modèle de régression linéaire simple. La droite représente l'espérance de la variable endogène, Y , en fonction de la valeur de la variable exogène, x . Le paramètre β_0 constitue l'ordonnée à l'origine de la droite et le paramètre β_1 est égal à la pente de la droite.

4.4 Trois méthodes d'estimation des paramètres

Le modèle

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad 1 \leq i \leq n.$$

est un modèle théorique qui relie les deux variables aléatoires d'intérêt. En pratique, on observe des observations $\{(X_i, Y_i), i = 1, \dots, n\}$. L'objectif est alors d'estimer les coefficients β_0 et β_1 . Nous verrons ici trois méthodes pour ce faire :

1. Méthode de Mayer
2. Méthode médiane-médiane (Med-Med)
3. Méthode des moindres carrés

La méthode des moindres carrés est celle qui est utilisée presque exclusivement en pratique. Les deux autres méthodes sont toutefois souvent enseignées dans les écoles secondaires au Québec. On présente donc ici en détails les trois méthodes. On verra par la suite comment elles se comparent d'un point de vue pratique et statistique.

4.4.1 Méthode de Mayer

La méthode de Mayer est la plus ancienne. Elle a été proposée par Tobias Mayer (1723-1762), un astronome allemand en charge de l'Observatoire de Göttingen. Professeur de mathématiques à l'Université de Göttingen, il a notamment travaillé à modéliser l'oscillation de la Lune autour de sa position moyenne, à partir d'observations précises sur les mouvements de l'astre. À l'aide de connaissances en physique, il avait établi un modèle :

$$\beta - (90^\circ - h) = \alpha \sin(g - h) - \alpha \sin \theta \cos(g - k)$$

où

- g et h sont des valeurs de position observées
- α , β et θ sont des constantes inconnues à estimer
- k est une constante disponible à l'aide d'une table lunaire.

Pour estimer α, β, θ , il a mesuré la position du cratère Manilius sur la Lune à 27 reprises. Il se retrouvait donc avec 27 équations et 3 inconnues. À cause d'erreurs de mesure sur les positions, il n'était toutefois pas possible de résoudre le système d'équations. La solution ingénieuse de Mayer fut de se ramener à un système avec 3 équations et 3 inconnues. Il commença par diviser les 27 observations en trois groupes de 9. Il décida de le faire en regroupant les observations avec des valeurs similaires de $g - k$. Puis, il somma les 9 équations dans chaque groupe pour obtenir 3 équations au final. Il ne lui restait alors qu'à résoudre le système d'équations à trois équations et trois inconnues pour estimer α, β et θ !


Cette même idée s'applique facilement au cas de la régression linéaire simple, pour donner ce qu'on appelle la droite de Mayer. Puisqu'on a alors que deux paramètres à estimer, on doit résumer les données en seulement deux équations. La stratégie utilisée est simplement de d'ordonner les observations selon leur valeur en abscisse et de séparer cet échantillon en deux. On résume ensuite chaque sous-groupe par son point moyen pour résoudre le système d'équations.

Étapes de la méthode de Mayer :

1. Partitionner l'échantillon ordonné selon x en deux parties égales.
Si n est impair, alors la médiane appartient aux deux sous-ensembles.
2. Calculer le *point moyen* dans chacun de ces deux sous-ensembles.
On calcule simplement indépendamment la moyenne des x et la moyenne des y dans chacun des sous-ensembles.
3. Relier ces points moyens pour obtenir la droite de Mayer.
On peut facilement déduire l'équation de la droite.

Remarque 4.2. Si on omet un instant les détails de la méthode, l'idée est de résumer les observations à deux points qui résument bien les données observées et de les relier pour obtenir une droite de régression, et donc des valeurs pour $\hat{\beta}_0$ et $\hat{\beta}_1$. On pourrait ainsi imaginer des variations sur la méthode, par exemple utiliser les médianes au lieu des moyennes.

Exemple 4.1. On veut mettre en relation le nombre de buts qu'un joueur du Canadien compte en une saison avec le nombre de tirs au buts qu'il a effectués. On utilise pour ce faire les données de l'hiver 2012-2013, illustrées ci-dessous.



Voici les données complètes :

Joueur	Tirs	Buts	Joueur	Tirs	Buts
1 Greg Pateryn	0	0	16 Josh Gorges	40	2
2 Yannick Weber	3	0	17 Erik Cole	41	3
3 Mike Blunden	5	0	18 Francis Bouillon	46	1
4 Jarred Tinordi	5	0	19 Michael Ryder	59	10
5 Nathan Beaulieu	8	0	20 Rene Bourque	63	7
6 Davis Drewiske	8	1	21 David Desharnais	66	10
7 Tomas Kaberle	11	0	22 Alex Galchenyuk	79	9
8 Jeff Halpern	13	1	23 Andrei Markov	79	10
9 Ryan White	16	1	24 Lars Eller	84	8
10 Gabriel Dumont	20	1	25 Brian Gionta	112	14
11 Travis Moen	32	2	26 Brendan Gallagher	117	15
12 Colby Armstrong	33	2	27 P.K. Subban	126	11
13 Alexei Emelin	33	3	28 Tomas Plekanec	133	14
14 Raphael Diaz	34	1	29 Max Pacioretty	163	15
15 Brandon Prust	39	5			

Appliquons la méthode :

- On a $n = 29$ observations, et elles sont déjà ordonnées selon la variable X , soit le nombre de tirs au but. Le premier groupe est donc constitué des observations 1 à 15, et le deuxième des observations 16 à 29.
- On calcule pour chacun des deux groupes la moyenne des x et des y . On obtient $(\bar{x}_1 = 17,33, \bar{y}_1 = 1,113)$ et $(\bar{x}_2 = 83,13, \bar{y}_2 = 8,93)$.
- À l'aide des deux points obtenus, on peut d'abord calculer la pente :

$$\hat{\beta}_1 = \frac{\Delta y}{\Delta x} = \frac{8,93 - 1,113}{83,13 - 17,33} = 0,1185$$

On utilise ensuite un point de la droite pour obtenir l'ordonnée à l'origine :

$$\hat{\beta}_0 = 1,113 - 0,1185 \times 17,33 = -0,9214$$

La droite de régression estimée à l'aide de la méthode de Mayer est donc

$$\hat{y}_i = -0,9214 + 0,1185x_i.$$

4.4.2 Méthode médiane-médiane (Med-Med)

La méthode Med-Med a été proposée en 1971 par le statisticien John Tukey. Comme pour la méthode de Mayer, on tente encore de résumer les données à quelques points, à partir desquels on calculera une droite de régression, mais il y a deux différences. Premièrement, on utilise des médianes au lieu de moyennes, dans le but de limiter l'impact de données aberrantes. Deuxièmement, on divise les données en trois sous-ensembles au lieu de deux.

Pourquoi utiliser trois sous-ensemble ? C'est un compromis. Si on veut bien estimer la pente, l'idéal est de prendre des points avec des valeurs en abscisses très différentes. On souhaite donc utiliser plus de deux groupes. De l'autre côté, il faut avoir plusieurs observations dans chaque groupe pour que les résultats ne dépendent pas trop des variations aléatoires des réalisations observées. Tukey décide donc d'utiliser trois groupes.

L'idée est donc de résumer le jeu de données à l'aide de trois points, lesquels sont ensuite utilisés pour estimer une droite de régression. Les points extrêmes servent à calculer une pente, puis le point milieu est utilisé pour obtenir l'ordonnée à l'origine. On donne les détails ci-dessous.

Étapes de la méthode Med-Med :

1. L'échantillon est partitionné en trois sous-ensembles à peu près égaux, suivant les valeurs de x , de telle sorte que le premier et le dernier groupe contiennent le même nombre de points.
2. On calcule le *point médian* de chacun des trois sous-ensembles.
3. On relie les points médians des deux parties extrêmes, pour obtenir une droite. La pente de cette droite sera notre estimé de la pente de la droite de régression.
4. On déplace cette droite de façon parallèle jusqu'à ce qu'elle passe par le *point moyen des trois couples de médianes*.

Remarque 4.3. *En fait, ce qu'on nomme la méthode médiane-médiane se trouve à être la première itération dans le calcul de la droite robuste de Tukey. Pour obtenir la droite robuste de Tukey, d'autres étapes sont nécessaires par la suite, mais on omet ces détails ici.*

Exemple 4.2. *On utilise les mêmes données qu'à l'exemple précédent.*

1. *On a $n = 29$ observations, et elles sont déjà ordonnées selon la variable X , soit le nombre de tirs au but. Le premier groupe est donc constitué des observations 1 à 10, le deuxième des observations 11 à 19 et le troisième des observations 20 à 30.*
2. *On calcule séparément la médiane des x et la médiane des y pour chacun des trois groupes. Dans les groupes à 10 observations, il s'agit de la moyenne de la 5e et de la 6e valeur ordonnée, alors que dans le groupe de 9 observations c'est la 5e valeur ordonnée. On obtient :*

$$(\tilde{x}_1 = 8, \tilde{y}_1 = 0), (\tilde{x}_2 = 39, \tilde{y}_2 = 2) \text{ et } (\tilde{x}_3 = 98, \tilde{y}_3 = 10,5).$$

3. *En reliant les points médians des deux groupes extrêmes, on obtient la pente :*

$$\hat{\beta}_1 = \frac{\Delta y}{\Delta x} = \frac{10,5 - 0}{98 - 8} = 0,1167.$$

4. *Le point moyen des trois couples de médianes est*

$$\left(\bar{x}_m = \frac{1}{3}(8 + 39 + 98) = 48,33, \bar{y}_m = \frac{1}{3}(0 + 2 + 10,5) = 4,17 \right)$$

On utilise ce point pour calculer l'ordonnée à l'origine :

$$\hat{\beta}_0 = 4,17 - 0,1167 \times 48,33 = -1,4722.$$

La droite estimée à l'aide de la méthode Med-Med est donc

$$\hat{y}_i = -1,4722 + 0,1167x_i.$$

4.4.3 Méthode des moindres carrés

Cette méthode est généralement attribuée au mathématicien français Adrien-Marie Legendre (1752-1833). Plusieurs autres mathématiciens de l'époque ont aussi publié des travaux sur le sujet, notamment Carl Friedrich Gauss (1777-1855) et Robert Adrain (1775-1843). Il s'agit de loin de la méthode la plus utilisée en pratique ; elle est implémentée dans Geogebra, Excel et tous les autres logiciels statistiques.

Cette méthode diffère grandement de celles qu'on vient de présenter : on ne tente pas de résumer les observations en quelques points, et la méthode n'est pas définie par une série d'étapes à accomplir. Il s'agit plutôt de définir un critère mathématique à optimiser. Plus précisément, comme son nom l'indique en partie, on souhaite minimiser le carré des erreurs entre la droite de régression estimée et les observations collectées.

On a besoin d'un peu de notation pour présenter la méthode.

On utilisera $\hat{Y}_i$ pour indiquer la prévision du modèle pour l'observation i , c'est-à-dire la position de Y_i s'il était exactement sur la droite de régression. On a donc

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i. \quad (4.7)$$

On appelle résidu la différence entre Y_i , la vraie valeur observée de la variable réponse, et cette prévision $\hat{Y}_i$:

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i. \quad (4.8)$$

On le dénote $\hat{\varepsilon}_i$, puisque c'est une estimation du terme d'erreur ε_i .

Avec la méthode des moindres carrés, on cherche à choisir $\hat{\beta}_0$ et $\hat{\beta}_1$ de façon à minimiser la somme des carrés de ces résidus. On veut donc minimiser

$$g(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n \left\{ Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right\}^2. \quad (4.9)$$

Remarque 4.4. *Pourquoi ne pas simplement minimiser la somme des résidus ? C'est que les valeurs positives et négatives s'annuleraient ! On pourrait toutefois minimiser la somme des valeurs absolues des résidus, et c'est parfois fait en pratique. Mais c'est plus complexe numériquement, et il n'y a pas autant de résultats théoriques sur les estimateurs obtenus. C'est pourquoi minimiser la somme des carrés des résidus est beaucoup plus utilisé.*

Puisque la fonction $g(\hat{\beta}_0, \hat{\beta}_1)$ définie en 4.9 possède de bonnes propriétés (entre autres, elle est lisse et convexe), elle peut être minimisée en la dérivant par rapport à $\hat{\beta}_0$ et $\hat{\beta}_1$, puis en posant ces dérivées égales à zéro. On doit donc résoudre le système d'équations à deux inconnues suivant :

$$\begin{cases} \frac{\partial}{\partial \hat{\beta}_0} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 0 \\ \frac{\partial}{\partial \hat{\beta}_1} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 0 \end{cases} \quad (4.10)$$

Estimation de β_0

On dérive d'abord par rapport à β_0 :

$$\begin{aligned} \frac{\partial}{\partial \beta_0} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-1) \\ &= -2(n\bar{Y} - n\beta_0 - n\beta_1 \bar{x}) \end{aligned}$$

On pose ensuite cette dérivée égale à zéro

$$\begin{aligned} -2(n\bar{Y} - n\beta_0 - n\beta_1 \bar{x}) &= 0 \\ \bar{Y} - \beta_0 - \beta_1 \bar{x} &= 0 \end{aligned} \quad (4.11)$$

On déduit de (4.11) que l'estimateur de β_0 est

$$\boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}} \quad (4.12)$$

Remarque 4.5. Il est à noter que l'équation (4.11) signifie que la droite de régression passe nécessairement par le point de coordonnées $(\bar{x}, \bar{Y})$.

Estimation de β_1

On dérive maintenant par rapport à β_1 :

$$\begin{aligned}\frac{\partial}{\partial \beta_1} \left\{ \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2 \right\} &= \sum_{i=1}^n 2(Y_i - \beta_0 - \beta_1 x_i)(-x_i) \\ &= -2 \left(\sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \beta_0 x_i - \sum_{i=1}^n \beta_1 x_i^2 \right).\end{aligned}$$

En posant cette dérivée égale à zéro et en utilisant (4.12), on a

$$\begin{aligned}-2 \left(\sum_{i=1}^n x_i Y_i - \sum_{i=1}^n \beta_0 x_i - \sum_{i=1}^n \beta_1 x_i^2 \right) &= 0 \\ \sum_{i=1}^n x_i Y_i &= \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i Y_i &= (\bar{Y} - \beta_1 \bar{x}) \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n x_i Y_i &= \bar{Y} \sum_{i=1}^n x_i + \beta_1 \left(\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i \right)\end{aligned}$$

On obtient donc l'estimateur suivant :

$$\boxed{\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i Y_i - \bar{Y} \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2 - \bar{x} \sum_{i=1}^n x_i}}. \quad (4.13)$$

Autres formes des estimateurs

Il est possible ensuite de réécrire $\hat{\beta}_1$ sous les formes équivalentes suivantes :

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i Y_i - n \bar{x} \bar{Y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x}) Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Chacune pourra être utile pour calculer $\hat{\beta}_1$ selon le type d'information que nous avons sur les données.

On simplifie parfois davantage la notation en écrivant simplement

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} \quad (4.14)$$

où

$$S_{xy} = \sum_{i=1}^n Y_i(x_i - \bar{x}) = \sum_{i=1}^n x_i Y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n Y_i \right) \quad (4.15)$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2 \quad (4.16)$$

Il est à noter que S_{xy} et S_{xx} sont appelés respectivement la somme des produits croisés corrigé de x et y et la somme des carrés corrigée de x .

En somme, les estimateurs des moindres carrés pour la RLS sont

$$\boxed{\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}} \quad \boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}} \quad (4.17)$$

Exemple 4.3. Toujours pour les données de l'exemple de hockey, on peut calculer $S_{xx} = 55809$ $S_{yy} = 783$ $S_{xy} = 6253$ et $\bar{x} = 50,62$ $\bar{y} = 5,03$.

On obtient donc

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{6253}{55809} = 0,1120$$

$$\hat{\beta}_0 = 5,03 - 0,1120 \times 50,62 = -0,6376$$

La droite estimée à l'aide de la méthode des moindres carrés est donc

$$\hat{y}_i = -0,6376 + 0,1120x_i.$$

4.4.4 Comparaison des trois méthodes

Les trois exemples précédents ont montré que les droites estimées par les trois méthodes de régression ne sont pas identiques pour un exemple donné. La figure ci-dessous montre simultanément les trois droites obtenues.




FIGURE 4.3 – Comparaison des droites des 3 méthodes pour les données des exemples précédents.

Plus généralement, les méthodes se différencient sur quelques points :

- **Difficulté des calculs**

Les méthodes Mayer et Med-Med sont plus simples à faire à la main que la méthode des moindres carrés. C'est d'ailleurs pourquoi elles figurent au programme de mathématiques du secondaire. Toutefois, c'est la méthode des moindres carrés qui est utilisée dans la très grande majorité des analyses de régression, et c'est la méthode par défaut dans tous les logiciels statistiques, incluant Excel et Geogebra, et plusieurs calculatrices.

- **Robustesse de l'estimation**

Les points milieux utilisés dans la méthode de Mayer sont sensibles aux valeurs extrêmes. De même, la méthode des moindres carrés est relativement sensible aux données aberrantes. Toutefois, il existe de nombreux outils statistiques pour étudier et limiter l'impact des données extrêmes sur les coefficients estimés par cette méthode. La méthode Med-Med est quant à elle peu sensible aux valeurs extrêmes, puisqu'elle utilise des médianes.

Les figures suivantes illustrent cette sensibilité aux valeurs extrêmes.




FIGURE 4.4 – Effet de l'ajout d'une valeur aberrante au centre : La droite de Mayer est la plus affectée à cause du calcul du 2e point moyen. La droite Med-Med n'est pas affectée car le changement n'affecte pas le calcul des médianes. La pente de la droite des moindres carrés est peu affectée, mais l'ordonnée à l'origine augmente.

$$\begin{aligned}\hat{Y}_{i-Mayer} &= -1,0619 + 0,1266x_i & (\text{avant : } \hat{Y}_i &= -0,9214 + 0,1185x_i) \\ \hat{Y}_{i-Med-Med} &= -1,4722 + 0,1167x_i & (\text{avant : } \hat{Y}_i &= -1,4722 + 0,1167x_i) \\ \hat{Y}_{i-MC} &= -0,4225 + 0,1133x_i & (\text{avant : } \hat{Y}_i &= -0,6376 + 0,1120x_i)\end{aligned}$$




FIGURE 4.5 – Effet de l'ajout de deux valeurs aberrantes à droite : Les trois pentes diminuent, mais la droite Med-Med est la moins affectée.

$$\begin{aligned}\hat{Y}_{i-Mayer} &= -0,5701 + 0,0983x_i & (\text{avant : } \hat{Y}_i &= -0,9214 + 0,1185x_i) \\ \hat{Y}_{i-Med-Med} &= -1,2685 + 0,1056x_i & (\text{avant : } \hat{Y}_i &= -1,4722 + 0,1167x_i) \\ \hat{Y}_{i-MC} &= 0,4393 + 0,0772x_i & (\text{avant : } \hat{Y}_i &= -0,6376 + 0,1120x_i)\end{aligned}$$

• Résultats théoriques sur la qualité de l'estimation

On a vu au chapitre 3 qu'on évalue habituellement la qualité d'un estimateur en étudiant son biais et sa variance. Pour la méthode des moindres carrés, on peut montrer que si les Y_i sont centrés autour de la vraie droite de régression les estimateurs sont sans biais pour les coefficients β_0 et β_1 . On peut également montrer que les estimateurs convergent (en probabilité) vers les paramètres sous certaines conditions, si la taille d'échantillon tend vers l'infini. On peut même montrer que parmi une grande classe d'estimateurs, et sous certaines conditions, les estimateurs des moindres carrés sont ceux qui ont la plus petite variance. On n'a pas de tels résultats pour la méthode de Mayer ni la méthode médiane-médiane, quoique sous certaines conditions on peut montrer que les estimateurs de la droite robuste de Tukey, dont la méthode médiane-médiane est la première itération, convergent eux aussi vers les paramètres du modèle.

• Possibilité d'inférence

Peu importe la méthode avec laquelle ils sont calculés, les estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ sont des variables aléatoires, puisque les Y_i sont aléatoires.

Obtenir seulement une estimation des coefficients de la vraie droite de régression n'est pas suffisant ; on voudrait également pouvoir faire de l'inférence sur ces coefficients, par exemple obtenir un intervalle de confiance pour β_0 , ou faire un test d'hypothèse pour vérifier si $\beta_1 = 2$.

Pour la méthode de Mayer et la méthode Med-Med, il y a peu de résultats théoriques sur la distribution échantillonnale de $\hat{\beta}_0$ et $\hat{\beta}_1$, ce qui complique la construction d'intervalles de confiance ou de tests d'hypothèses. Il est tout de même possible de faire de l'inférence dans ces cas, notamment à l'aide de techniques de rééchantillonnage comme le *bootstrap* ou le *jack-knife*. Toutefois, celles-ci nécessitent beaucoup de temps de calcul et ne sont pas couvertes dans ce cours.

Une différence majeure entre les trois méthodes est que dans le cas de la méthode des moindres carrés, il est facile de calculer la distribution échantillonnale exacte des estimateurs si certaines conditions sont respectées.

Cela permet de faire de l'inférence sur les quantités suivantes :

- la pente de la droite : β_1 ,
- l'ordonnée à l'origine de la droite : β_0 ,
- la valeur moyenne de Y de toutes les observations ayant $X = x_0$,
- la valeur éventuelle de Y d'une future, observation ayant $X = x_0$

notamment à l'aide d'intervalles de confiance et de tests d'hypothèses. Les détails sont dans la prochaine section du chapitre.

4.5 Inférence - méthode des moindres carrés

On a dit qu'un avantage important de la méthode des moindres carrés par rapport aux deux autres méthodes d'estimation d'une droite de régression linéaire simple est qu'on peut facilement faire de l'inférence sur plusieurs quantités d'intérêt, notamment les coefficients de la droite, et les valeurs prédites de la variable réponse.

Pour ce faire, il faut toutefois que certaines conditions concernant la distribution des observations soient respectées, comme c'était le cas dans les exemples du chapitre 3.

Nous présentons d'abord ces conditions, puis les différentes méthodes d'inférences, ainsi qu'un exemple complet avec un petit jeu de données.

4.5.1 Conditions pour l'inférence

Pour pouvoir faire de l'inférence paramétrique sur les coefficients et les valeurs prédites, il faut que les quatre conditions suivantes soient respectées :

- relation **linéaire** entre les deux variables ($E(\varepsilon_i) = 0$)
- **indépendance** des observations Y_i
- **Normalité** de Y_i autour de la droite ($\varepsilon_i \sim N$)
- **Var(Y_i) constante** autour de la droite (ne dépend pas des x)

On peut résumer ces conditions ainsi :

$$Y_i \stackrel{\text{indép.}}{\sim} N(\beta_0 + \beta_1 X_i, \sigma^2) \quad (4.18)$$

ou encore

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \text{ où } \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2) \quad (4.19)$$

Il est évidemment possible que ces 4 conditions ne soient pas vérifiées en pratique. Nous verrons à la section 4.5.6 comment tester si chacune des conditions est vérifiée et comment modifier le modèle au besoin.

Notez toutefois que les méthodes d'inférences qui seront présentées sont relativement robustes à certaines violations des conditions, notamment à la condition de normalité des erreurs.

4.5.2 Inférence sur les paramètres β_0 et β_1

On commence par la distribution échantillonnale des estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$.

- Notons d'abord que si la linéarité est respectée, on peut montrer que

$$E(\hat{\beta}_0) = \beta_0 \quad \text{et} \quad E(\hat{\beta}_1) = \beta_1 \quad (4.20)$$

c'est-à-dire que les estimateurs des moindres carrés sont sans biais pour les vrais paramètres de la droite de régression.

- De plus, s'il y a effectivement indépendance et variance constante, alors on a également

$$V(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) \quad \text{et} \quad V(\hat{\beta}_1) = \frac{\sigma^2}{S_{xx}} \quad (4.21)$$

- Enfin, notons que $\hat{\beta}_1$ peut s'écrire comme une combinaison linéaire des Y_i :

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{\sum[(x_i - \bar{x})(Y_i - \bar{Y})]}{\sum(x_i - \bar{x})^2} = \frac{\sum[(x_i - \bar{x})Y_i]}{\sum(x_i - \bar{x})^2}$$

Rappelons qu'on considère les x_i fixés (non aléatoires). Ainsi, si les erreurs suivent vraiment une loi normale alors $\hat{\beta}_1$ est simplement une combinaison linéaire de variables aléatoires normales, et donc suit lui-même une loi normale. Il en est de même pour $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$.

On obtient donc les distributions échantillonnales suivantes :

$$\boxed{\hat{\beta}_0 \sim N \left(\beta_0, \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right] \right)} \quad (4.22)$$

et

$$\boxed{\hat{\beta}_1 \sim N \left(\beta_1, \frac{\sigma^2}{S_{xx}} \right)} \quad (4.23)$$

On peut utiliser ces résultats pour obtenir des intervalles de confiance.

Intervalle de confiance pour β_1

On a établi que

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

En pratique, on ne connaît pas σ^2 et on l'estime par le *mean square error*

$$\hat{\sigma}^2 = MSE = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2}. \quad (4.24)$$

On peut montrer que

$$\boxed{\frac{\hat{\beta}_1 - \beta_1}{\sqrt{MSE/S_{xx}}} \sim t_{n-2}} \quad (4.25)$$

et donc un intervalle de confiance de niveau $(1 - \alpha)$ pour β_1 est donné par

$$\boxed{\hat{\beta}_1 \pm t_{\alpha/2, n-2} \sqrt{\frac{MSE}{S_{xx}}}} \quad (4.26)$$

Intervalle de confiance pour β_0

On peut également montrer que

$$\boxed{\frac{\hat{\beta}_0 - \beta_0}{\sqrt{MSE \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}} \sim t_{n-2}}, \quad (4.27)$$

ce qui implique que l'intervalle de confiance de niveau $(1 - \alpha)$ pour β_0 est

$$\boxed{\hat{\beta}_0 \pm t_{\alpha/2, n-2} \sqrt{MSE \left[\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right]}} \quad (4.28)$$

Remarque 4.6. *Tel que discuté au chapitre 3, on peut utiliser ces intervalles de confiance pour faire des tests d'hypothèses sur les valeurs des paramètres.*

4.5.3 Prédiction à partir de la droite estimée

En général, on estime

$$E(Y|X = x_0) = \beta_0 + \beta_1 x_0 \quad (\text{le point sur la vraie droite})$$

par

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0 \quad (\text{le point sur la droite estimée}).$$

Pour obtenir un intervalle de confiance, on doit distinguer deux situations : l'estimation de la moyenne à $X = x_0$ (l'espérance de Y au point x_0) et la prédiction d'une observation future à $X = x_0$. Dans le premier cas il s'agit d'estimer une constante alors que dans le deuxième cas on souhaite prédire une variable aléatoire. Cette dernière étant une valeur plus variable, notre intervalle de confiance devra être plus grand.

Intervalle de confiance pour la moyenne à $X = x_0$

On peut montrer que

$$\hat{Y}_0 \sim N \left(\beta_0 + \beta_1 x_0, \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \right) \quad (4.29)$$

On estime σ^2 par MSE et on obtient l'intervalle de confiance suivant, au niveau $1 - \alpha$ pour la valeur moyenne de Y au point x_0 :

$$\boxed{\hat{Y}_0 \pm t_{n-2, \alpha/2} \sqrt{MSE \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}} \quad (4.30)$$

Intervalle de confiance pour une observation spécifique avec $X = x_0$

La variance utilisée pour construire l'intervalle est celle de l'erreur de prédiction, soit $Var(Y_0 - \hat{Y}_0)$, où Y_0 est la valeur de Y pour une observation avec $X = x_0$, et $\hat{Y}_0$ est calculé à partir des n observations du jeu de données. Puisque Y_0 et $\hat{Y}_0$ sont des variables aléatoires indépendantes, on a

$$Var(Y_0 - \hat{Y}_0) = Var(Y_0) + Var(\hat{Y}_0) = \sigma^2 + \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right] \quad (4.31)$$

On peut construire un intervalle de prédiction de niveau $1 - \alpha$ pour Y_0 , une valeur non observée de Y , en estimant σ^2 par le MSE :

$$\boxed{\hat{Y}_0 \pm t_{n-2, \alpha/2} \sqrt{MSE \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right)}} \quad (4.32)$$

La figure 4.6 illustre la différence entre les deux types d'intervalles. On peut y observer que

- Dans les deux cas, les intervalles sont plus courts pour des x_0 plus proche de la moyenne $\bar{x}$.
- Pour un même x_0 , les intervalles de prévision pour une nouvelle observation sont plus grands que les intervalles de confiance pour la valeur moyenne en x_0 .




FIGURE 4.6 – Comparaison des intervalles de confiance pour une moyenne, et des intervalles de confiance pour une nouvelle prévision pour un modèle de régression linéaire simple.

4.5.4 Anova pour la RLS

On présente ici une autre méthode d'inférence pour la régression linéaire, qu'on nomme l'analyse de variance. Dans le cas d'un seul prédicteur, elle donnera peu d'information supplémentaire à l'inférence sur $\hat{\beta}_1$, mais elle se généralise bien à la régression avec plus d'une variable. En outre, il s'agit d'une analyse fournie automatiquement avec l'estimation des paramètres de régression dans certains logiciels, notamment Excel, donc il est bon de savoir l'interpréter.

L'idée est de tester l'utilité du modèle et d'en mesurer la qualité en partitionnant la variabilité des données. En effet, les valeurs de la variable réponse ne seront pas toutes identiques dans le jeu de données. Une partie de la différence entre les Y_i peut être expliquée par la différence entre les x_i , la variable réponse étant expliquée en partie par le prédicteur. Il reste toutefois une partie de la variabilité des Y_i qui n'est pas expliquée par les différences des x_i . On peut écrire

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y})$$

Il se trouve que la même relation est vraie au niveau de la somme des carrés :

$$\begin{aligned} \sum_{i=1}^n (Y_i - \bar{Y})^2 &= \sum_{i=1}^n (Y_i - \hat{Y}_i + \hat{Y}_i - \bar{Y})^2 \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}) \\ &= \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2. \end{aligned}$$

On écrira plus simplement

$$\boxed{SC_{tot} = SC_{reg} + SC_{res}} \quad (4.33)$$

$SC_{tot} = \sum_{i=1}^n (Y_i - \bar{Y})^2$ **Somme des carrés totale.** Quantifie la variabilité des Y_i autour de leur valeur moyenne.

$SC_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ **Somme des carrés de la régression.** Quantifie la variabilité des prévisions $\hat{Y}_i$. Étant donné que les $\hat{Y}_i$ ne varient qu'avec les x_i , cette somme de carrés est la partie de la variabilité dans les Y_i expliquée par la variabilité x_i .

$SC_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$ **Somme des carrés résiduelle** Quantifie la variabilité des $(Y_i - \hat{Y}_i)$. Cette variabilité est induite par le fait que la valeur de Y_i n'est pas expliquée parfaitement par le modèle de régression.

Test statistique

Intuitivement, plus la proportion de la variabilité expliquée par le modèle est grande par rapport à la variabilité totale, plus le modèle est utile pour prédire Y , et donc plus la relation entre x et Y explique les valeurs de Y .

On utilise cette idée pour effectuer un test global de la régression.
Les hypothèses sont

$$H_0 : Y_i = \beta_0 + \varepsilon_i \text{ vs } H_1 : Y_i = \beta_0 + \beta_1 x + \varepsilon_i$$

Une statistique pour le test pourrait être SC_{reg}/SC_{tot} . Toutefois, la distribution de cette statistique n'est pas facile à trouver sous H_0 . On utilisera plutôt la statistique

$$F_0 = CM_{reg}/CM_{res}.$$

On peut montrer que sous H_0 $F_0 \sim F_{1,n-2}$. Si H_1 est vraie, on s'attend à observer de grandes valeurs de F_0 . Pour un test de niveau α , on va donc rejeter H_0 au seuil α si $F_0 \geq F_{1,n-2,1-\alpha}$.

On résume généralement les résultats de l'anova à l'aide d'un tableau de l'analyse de la variance, tel qu'illustré à la table 4.1.

TABLE 4.1 – Tableau d'anova dans le cas de la régression linéaire.

Source	Degrés de liberté	Somme des carrés	Carrés moyens	F
Modèle	$ddl_1 = p = 1$	$SC_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$	$CM_{reg} = \frac{SC_{reg}}{ddl_1}$	CM_{reg}/CM_{res}
Erreur Résiduelle	$ddl_2 = n - 2$	$SC_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$	$CM_{res} = \frac{SC_{res}}{ddl_2}$	
Totale	$n - 1$	$SC_{tot} = \sum_{i=1}^n (Y_i - \bar{Y})^2$		

Remarque 4.7. Notez que

$$CM_{res} = \frac{SC_{res}}{ddl_2} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - 2} = \frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{n - 2} = MSE, \text{ l'estimateur de } \sigma^2$$

Coefficient de détermination

On peut également calculer un coefficient de détermination

$$R^2 = \frac{SC_{reg}}{SC_{tot}} = 1 - \frac{SC_{res}}{SC_{tot}}$$

Il s'interprète comme la proportion de la variance de Y qui est expliquée par X . Il prend des valeurs entre 0 et 1, une plus grande valeur indiquant un modèle qui explique davantage la valeur des Y .

4.5.5 Exemple d'inférence pour la régression linéaire simple

Voici un petit exemple pour illustrer les différentes procédures d'inférence pour la RLS avec la méthode des moindres carrés. Les données sont tirées du livre *Probabilités et statistiques pour ingénieurs*, à l'exemple 13.1 de l'édition 2005.

Exemple 4.4. *Un ingénieur chimiste a analysé l'effet de la température de fonctionnement d'un procédé sur le rendement du produit. Les valeurs obtenues sont résumées ci-dessous.*

TABLE 4.2 – Mesures du rendement en % en fonction de la température en °C

Température [°C]	100	110	120	130	140	150	160	170	180	190
Rendement [%]	45	51	54	61	66	70	74	78	85	89




FIGURE 4.7 – Diagramme de dispersion du rendement en fonction de la température

On peut constater sur la figure 4.7 qu'il existe une relation forte entre le rendement et la température. On va supposer que cette relation est linéaire et donc modéliser ces données à l'aide de l'équation (4.6).

Estimation des paramètres

On calcule d'abord

$$\sum_{i=1}^{10} x_i = 1450$$

$$\sum_{i=1}^{10} y_i = 673$$

$$\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = 145$$

$$\bar{y} = \frac{1}{10} \sum_{i=1}^{10} y_i = 67,3$$

$$\sum_{i=1}^{10} x_i^2 = 218\,500$$

$$\sum_{i=1}^{10} Y_i x_i = 101\,570$$

On obtient alors

$$S_{xx} = 218\,500 - (1450)^2/10 = 8250$$

$$S_{xy} = 101\,570 - 1450 \times 673/10 = 3985$$

Et donc

$$\hat{\beta}_1 = 3985/8250 = 0,483$$

$$\hat{\beta}_0 = 67,3 - 0,483 \times 145 = -2,739$$

Le modèle de régression linéaire simple ajusté devient alors

$$\hat{y}_i = -2,739 + 0,483x_i.$$

Ainsi, une augmentation de un degré Celsius de la température du procédé est associée à une augmentation moyenne de 0,483 points de pourcentage du rendement du produit. Le modèle indique aussi qu'à une température nulle, le rendement attendu est de -2,739%.

Intervalles de confiance pour les paramètres

Calculons maintenant un intervalle de confiance pour β_0 et β_1 . La plupart des quantités nécessaires ont déjà été calculées. Il ne manque que MSE , l'estimation de σ^2 . Il faut d'abord calculer la valeur prédite et le résidu pour chacune des observations, comme au Tableau 4.3.

TABLE 4.3 – Tableau résumant Y_i , $\hat{Y}_i$ et $\hat{\varepsilon}_i$, $i = 1, \dots, 10$ pour le calcul de $\hat{\sigma}^2$

i	Y_i	$\hat{Y}_i$	$\hat{\varepsilon}_i$
1	45	45,561	-0,561
2	51	50,391	0,609
3	54	55,221	-1,221
4	61	60,051	0,949
5	66	64,881	1,119
6	70	69,711	0,289
7	74	74,541	-0,541
8	78	79,371	-1,371
9	85	84,201	0,799
10	89	89,031	-0,031

L'équation (4.24) livre alors

$$MSE = \frac{1}{10-2} \sum_{i=1}^{10} \hat{\varepsilon}_i^2 = \frac{7,224}{8} = 0,903.$$

Si on fixe $\alpha = 5\%$, il faut calculer $t_{n-2;0,975}$. On peut trouver dans une table que ce quantile est $t_{8;0,975} = 2,306$.

On obtient alors les intervalles suivants :

$$[\hat{\beta}_0 \pm 2,306\sqrt{0,903(1/10 + 145^2/8250)}] = [\hat{\beta}_0 \pm 3,566] = [-6,305; 0,827]$$

$$[\hat{\beta}_1 \pm 2,306\sqrt{0,903/8250}] = [\hat{\beta}_1 \pm 0,024] = [0,459; 0,507]$$

Prévision

On désire calculer un intervalle de confiance à 95 % pour le rendement moyen du produit lorsque la température de fonctionnement est de 150 °C et pour le rendement d'un produit spécifique lorsque la température est de 150 °C.

Dans les deux cas, la prévision est

$$\hat{\beta}_0 + 150 \times \hat{\beta}_1 = -2,739 + 0,483 \times 150 = 69,711\%.$$

On sait déjà que $\bar{x} = 145$, $S_{xx} = 8250$, $MSE = 0,903$ et que $t_{8;0,975} = 2,306$. Il nous reste seulement à calculer

$$(x_0 - \bar{x})^2 = (150 - 145)^2 = 25.$$

L'intervalle de confiance du rendement moyen à une température de 150 °C est donc

$$[69,711 \pm 2,306 \times \sqrt{0,903(1/10 + 25/8250)}] = [69,711 \pm 0,703] = [69,008; 70,414].$$

L'intervalle de confiance du rendement d'un produit quelconque, ou intervalle de prévision, est quant à lui

$$[69,711 \pm 2,306 \times \sqrt{0,903(1 + 1/10 + 25/8250)}] = [69,711 \pm 2,301] = [67,410; 72,012].$$

Comme on l'a déjà signalé l'intervalle de prévision est plus large que l'intervalle de confiance pour la moyenne.

Analyse de variance

On peut calculer que

$$SS_{tot} = \sum_{i=1}^n (Y_i - \bar{Y})^2 = 1931,2$$

$$SS_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = (n - 2) * MSE = 7,224$$

$$SS_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = 1924,876$$

On vérifie alors que $SS_{tot} = SS_{reg} + SS_{res}$. On peut d'ailleurs calculer plus simplement $SC_{reg} = SC_{tot} - SC_{res} = 1932,1 - 7,224 = 1924,876$ au lieu de faire le calcul au long.

On note que la température à elle seule ne peut pas expliquer en totalité pourquoi toutes les expériences ne possèdent pas le même rendement. On peut également obtenir le tableau d'analyse de la variance :

Source	Degrés de liberté	Somme des carrés	Carrés moyens	F
Modèle	$ddl_1 = 1$	1924,876	1924,876	2131,574
Erreur résiduelle	$ddl_2 = 8$	7,224	0,903	
Totale	$n - 1 = 9$	1931,1		

Puisque $F_0 = 2131,574 > F_{1,8,1-\alpha} = 5,32$, on rejette l'hypothèse nulle et on en conclut que le modèle de régression linéaire est adapté. On peut arriver à la même conclusion à l'aide de notre intervalle de confiance sur β_1 : puisqu'il ne contient pas la valeur 0, on peut rejeter l'hypothèse nulle $\beta_1 = 0$.

De plus, on peut calculer

$$R^2 = \frac{1924,876}{1931,1} = 0,9967$$

ce qui indique que la température prédit presque parfaitement le rendement de l'expérience. Des valeurs aussi grandes sont plutôt rares en pratique !

4.5.6 Validation des conditions nécessaires à l'inférence

On a déjà énoncé les quatre conditions nécessaires pour l'inférence :

- **linéarité** de la relation entre les deux variables ($E(\varepsilon_i) = 0$)
- **indépendance** des observations Y_i
- **Normalité** de Y_i autour de la droite ($\varepsilon_i \sim N$)
- **Var(Y_i) constante** autour de la droite (ne dépend pas des x)

Il est important de toujours tester si ces conditions sont présentes dans notre modèle de régression linéaire simple. La linéarité est l'aspect le plus critique : si elle n'est pas respectée le modèle linéaire n'est pas approprié et l'interprétation des coefficients estimés sera erroné. Les autres conditions sont nécessaires pour s'assurer que les inférences sont valides. Notez que la normalité des erreurs est moins critique que les autres. En effet, les procédures d'inférence présentées dans ce chapitre sont relativement robustes aux écarts de normalité.

Nous présentons ci-dessous quelques méthodes simples pour tester les quatre conditions. Si les conditions ne sont pas respectées, il se peut que transformer le prédicteur, ou la variable réponse règle le problème. D'autres méthodes statistiques sont également possibles (e.g. *bootstrap*, régression non-linéaire) mais ne seront pas présentées ici.

Linéarité

Pour vérifier la linéarité de la relation, on peut utiliser les graphiques suivants :

1. Un nuage de points de Y_i en fonction de x_i
On devrait alors voir une droite. La figure 4.8 présente six exemples de diagrammes de dispersion de la variable endogène en fonction de la variable exogène. Seuls les diagrammes a) et b) présentent une relation linéaire.
2. Un nuage de points de $\hat{\varepsilon}_i$ en fonction de $\hat{Y}_i$
Ce graphique devrait montrer un nuage de points centré verticalement en 0 et exhiber une allure complètement aléatoire, c'est-à-dire qu'il ne devrait exister aucune tendance discernable (par exemple résidus croissants ou décroissants en fonction de Y_i , graphique à l'allure quadratique, etc.). Ce graphique est à privilégier car il peut montrer des problèmes qui ne seraient pas visibles dans le graphique de y en fonction de x . La figure 4.9 illustre quatre diagrammes de dispersion des résidus en fonction de la variable prédite. Seul le premier diagramme résulte d'une relation linéaire. Les vraies relations desquelles sont issues les données sont indiquées dans les titres.




FIGURE 4.8 – Diagramme de dispersion des la variable endogène en fonction de la variable exogène




FIGURE 4.9 – Exemples de quatre diagrammes de dispersion des résidus en fonction des valeurs prédites.

Homoscédasticité (variance constante)

Le graphique des résidus en fonction des valeurs prédites permet également de juger de l'homoscédasticité ($\text{Var}[\epsilon_i] = \sigma^2 \quad 1 \leq i \leq n$). L'hétéroscédasticité signifie que la variance des résidus n'est pas constante. Un graphique pour lequel la variabilité des résidus semble différente pour différentes valeurs des valeurs prédites indique un tel problème. La figure 4.10 illustre de façon schématique divers problèmes d'hétéroscédasticité.




FIGURE 4.10 – Exemples d'hétéroscédasticité illustrée avec le graphique des résidus

Indépendance

L'indépendance des observations est plus difficile à tester. C'est la structure de la collecte des données qui permet de croire ou non en l'indépendance des observations. Par exemple, il se peut que les erreurs des individus d'une même classe ou d'une même famille ne soient pas indépendantes.

Si cette condition n'est pas respectée, ça pourrait également causer des erreurs d'interprétation si par exemple il existe des sous-groupes pour lesquels la relation linéaire n'est pas la même, ou si chaque donnée est fortement dépendante de la précédente (auto-corrélation).

Normalité

On peut utiliser un histogramme pour tester la normalité. Il permet notamment de vérifier la symétrie et l'unimodalité. À la figure 4.11, seule la distribution (a) est jugée acceptable.




FIGURE 4.11 – Histogramme présentant la distribution des résidus.

Le diagramme à moustache permet aussi de vérifier la symétrie, et d'identifier la présence de valeurs extrêmes. Trop de valeurs extrêmes indique un problème de normalité ou un problème de linéarité ou alors la présence de deux populations distinctes. La figure 4.12 montre trois diagrammes à moustache des résidus. Le diagramme de gauche est typique d'une distribution normale, celui du centre illustre la présence de valeurs extrêmes, alors que le diagramme de droite reflète une asymétrie des résidus.




FIGURE 4.12 – Exemple de diagrammes à moustache représentant les résidus.

Remarque 4.8. Différents types de résidus

Nos hypothèses sur les erreurs se résument par :

$$\epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \dots, n.$$

On a précédemment défini les résidus

$$\hat{\epsilon}_i = Y_i - \hat{Y}_i$$

et on vient de proposer d'utiliser ceux-ci pour valider les hypothèses sur les erreurs. On pourrait donc croire que les résidus suivront également des lois normales indépendantes de moyenne 0 et de variance σ^2 . Ce n'est toutefois pas le cas. On peut en fait montrer que

$$\hat{\epsilon}_i \sim N \left\{ 0, (1 - h_{jj})\sigma^2 \right\} \text{ où } h_{jj} = \frac{1}{n} + \frac{(\bar{x} - x_j)^2}{S_{xx}}$$

On peut voir par exemple que même si on avait une variance constante pour les erreurs on n'obtiendrait pas des résidus avec une variance constante. Il est à noter également que la somme des résidus est toujours exactement égale à zéro, ce qui implique que ce sont des variables aléatoires dépendantes.

Au lieu d'utiliser les résidus bruts $\hat{\epsilon}_i$, il est donc généralement préférable d'utiliser d'autres types de résidus pour valider les hypothèses.

On définit donc un **résidu standardisé** :

$$r_i = \frac{\hat{\epsilon}_i}{s\sqrt{1 - h_{ii}}}$$

Les résidus standardisés permettent d'éliminer la non-homogénéité de la variance des résidus. Ils sont distribués selon une loi normale centrée et réduite. Leur interprétation dans un graphique est donc beaucoup plus directe.

On peut également définir un **résidu studentisé** :

$$t_i = \frac{\hat{\epsilon}_i}{\hat{\sigma}_{(i)}\sqrt{1 - h_{ii}}}$$

La notation $\hat{\sigma}_{(i)}$ indique que l'estimation de σ est ici obtenue sans l'observation i . On peut prouver que les t_i sont i.i.d T_{n-2} .

Attention : ces termes ne sont pas utilisés de la même façon partout dans la littérature. Il est donc important de vérifier la définition mathématique du résidu pour savoir exactement à quel type de résidu on a affaire.

Remarque 4.9. Données aberrantes

Un aspect important de l'ajustement d'un modèle de régression est la gestion des données aberrantes.

On dira qu'une observation est aberrante si elle ne cadre pas avec le modèle. Dans le cas de la RLS, il s'agira d'une observation dont la valeur Y est très loin de la droite estimée.

La présence de données aberrantes n'est pas toujours problématique. On doit plutôt faire attention aux données influentes. On dira qu'une observation est influyente si, à elle seule, elle peut avoir un impact sérieux sur les conclusions d'une analyse de régression, que ce soit modifier grandement l'estimation d'un paramètre, ou l'inférence sur celui-ci.


Il est important de noter qu'une donnée aberrante n'est pas nécessairement influente, tel qu'illustré à la figure 4.13 de la page suivante.

En présence d'une donnée influente, on commencera d'abord par vérifier s'il n'y a pas d'erreur dans les valeurs observées. On peut choisir d'enlever une ou des données influentes d'un modèle, mais il est important de le dire et de le justifier. Idéalement, on fournira les résultats de l'analyse avec et sans ces données pour que le lecteur puisse voir l'impact de cette décision.


Remarque 4.10. Données de sondage

Un traitement de la régression linéaire dans le contexte d'un échantillon tiré d'une population finie, avec potentiellement des probabilités de sélection inégales, dépasse largement le cadre de notre cours.


Notons toutefois qu'on pourrait décider d'ignorer le plan de sondage, et le fait que la population soit finie. Le fait que l'échantillon ne soit pas directement représentatif de la population ne sera pas trop problématique si le modèle d'intérêt est valide pour l'ensemble de la population. En effet, toute la théorie présentée ici est basée sur un modèle pour Y_i en considérant les x_i fixes. Tant que le modèle est valide pour les x_i observés dans l'échantillon, on peut décider d'approcher le problème d'un point de vue de modélisation des Y_i et les résultats obtenus ici devraient s'appliquer.




(a) Jeu de données original et droite de régression estimée par les moindres carrés.



(b) Ajout d'une observation aberrante (carré rouge) ayant une très faible influence sur la droite estimée.



(c) Ajout d'une observation avec une très petite valeur en x par rapport au jeu de données. Cette observation n'est pas aberrante car elle cadre dans le modèle et a peu d'effet sur la droite estimée.



(d) Si on déplace cette observation pour qu'elle ne cadre plus dans le modèle, elle devient aberrante et influente.

FIGURE 4.13 – Quelques graphiques pour montrer qu'une observation aberrante n'est pas nécessairement influente.

AUTRES NOTES

AUTRES NOTES

AUTRES NOTES

Chapitre 5

Inférence sur l'association entre deux variables catégoriques

On a vu au chapitre 2 différentes représentations numériques et graphiques pour deux variables catégoriques. On avait alors mentionné que si les valeurs d'une variable semblent affectées par les valeurs de l'autre variable, cela indique une dépendance entre les variables. On verra ici comment établir statistiquement s'il y a effectivement une relation entre deux variables catégoriques. Mais d'abord, on fait quelques rappels concernant la distribution de variables catégoriques.

5.1 Rappels concernant deux variables catégoriques

5.1.1 Loi conjointe de X et Y

Soit X une variable aléatoire pouvant prendre les valeurs $\{x_1, x_2, \dots, x_I\}$.

Soit Y une variable aléatoire pouvant prendre les valeurs $\{y_1, y_2, \dots, y_J\}$.

La *loi conjointe* de X et Y est l'ensemble des probabilités p_{ij} telles que

$$p_{ij} = P(X = x_i \cap Y = y_j)$$

pour $i = 1, \dots, I$ et $j = 1, \dots, J$.

Puisque X et Y sont qualitatives, il s'agit d'une *fonction de masse conjointe*, qu'on appelle aussi *distribution conjointe*.

On représente souvent une fonction de masse conjointe dans un tableau :

$X \backslash Y$	y_1	$\dots$	y_j	$\dots$	y_J	Total
x_1	p_{11}	$\dots$	p_{1j}	$\dots$	p_{1J}	$p_{1\bullet}$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
x_i	p_{i1}	$\dots$	p_{ij}	$\dots$	p_{iJ}	$p_{i\bullet}$
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
x_I	p_{I1}	$\dots$	p_{Ij}	$\dots$	p_{IJ}	$p_{I\bullet}$
Total	$p_{\bullet 1}$	$\dots$	$p_{\bullet j}$	$\dots$	$p_{\bullet J}$	1

FIGURE 5.1 – Fonction de masse conjointe de X et Y

Exemple 5.1. Soit une urne contenant cinq boules : deux boules rouges numérotées 1 et 2 et trois boules bleues numérotées 1, 2 et 3.

On pige une boule dans l'urne et on s'intéresse aux deux variables suivantes :

X : la couleur de la boule tirée

Y : la parité du numéro tiré

Ces deux variables sont catégoriques. La variable X peut prendre deux valeurs : bleue ou rouge. La variable Y peut également prendre deux valeurs : pair ou impair. On a donc $I = J = 2$.

La distribution conjointe de X et Y est alors donnée par

$X \backslash Y$	pair	impair	Total
rouge	0,2	0,2	0,4
bleue	0,2	0,4	0,6
Total	0,4	0,6	1

5.1.2 Lois marginales

La **fonction de masse marginale de X** est l'ensemble des probabilités $p_{i\bullet}$ telles que

$$p_{i\bullet} = P(X = x_i) = \sum_{j=1}^J p_{ij}$$

pour $i = 1, \dots, I$. Elle apparaît à la dernière colonne de la figure 5.1.

Similairement, la **fonction de masse marginale de Y** est l'ensemble des probabilités $p_{\bullet j}$ telles que

$$p_{\bullet j} = P(Y = y_j) = \sum_{i=1}^I p_{ij}$$

pour $j = 1, \dots, J$. Elle apparaît à la dernière ligne de la figure 5.1.

Notez que ce sont toutes deux des fonctions de masse en bonne et due forme, et donc on a

$$\sum_{i=1}^I p_{i\bullet} = \sum_{j=1}^J p_{\bullet j} = 1.$$

Exemple 5.2. *Considérons de nouveau l'exemple 5.1. La distribution conjointe est*

$X \backslash Y$	Y		Total
	<i>pair</i>	<i>impair</i>	
<i>rouge</i>	0,2	0,2	0,4
<i>bleue</i>	0,2	0,4	0,6
Total	0,4	0,6	1

La fonction de masse marginale de X est donnée dans la colonne Total :

x	<i>bleue</i>	<i>rouge</i>
$P(X = x)$	0,6	0,4

La fonction de masse marginale de Y est donnée dans la ligne Total :

y	<i>pair</i>	<i>impair</i>
$P(Y = y)$	0,4	0,6

5.1.3 Lois conditionnelles

La fonction de masse *conditionnelle* de X sachant que Y prend la valeur y_j est l'ensemble des probabilités $p_{i|Y=y_j}$ telles que

$$p_{i|Y=y_j} = P(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{\bullet j}}$$

La fonction de masse conditionnelle de X sachant Y se calcule donc en conditionnant sur une colonne de la fonction de masse, tel qu'illustré ci-dessous.

$X \backslash Y$	y_1 ...		y_j	...		y_J
	y_1	...	y_j	...	y_J	
x_1	p_{11}	...	p_{1j}	...	p_{1J}	
...	...	...	...	...	...	
x_i	p_{i1}	...	p_{ij}	...	p_{iJ}	
...	...	...	...	...	...	
x_I	p_{I1}	...	p_{Ij}	...	p_{IJ}	
Total	$p_{\bullet 1}$	...	$p_{\bullet j}$	...	$p_{\bullet J}$	

À l'inverse, la fonction de masse conditionnelle de Y sachant X se calcule en conditionnant sur une ligne de la fonction de masse :

$$p_{j|X=x_i} = P(Y = y_j | X = x_i) = \frac{p_{ij}}{p_{i\bullet}}$$

Exemple 5.3. Toujours pour l'exemple 5.1, on peut trouver plusieurs distributions conditionnelles. Voici quelques exemples.

La distribution de la couleur X sachant que le numéro Y est pair est

x	<i>bleue</i>	<i>rouge</i>
$P(X = x Y = \text{pair})$	$0,2/0,4 = 0,5$	$0,2/0,4 = 0,5$

La distribution de X sachant que Y est impair est

x	<i>bleue</i>	<i>rouge</i>
$P(X = x Y = \text{impair})$	$0,2/0,6 = 1/3$	$0,4/0,6 = 2/3$

La distribution de Y sachant que X est bleue est

y	<i>pair</i>	<i>impair</i>
$P(Y = y X = \text{bleue})$	$0,2/0,6 = 1/3$	$0,4/0,6 = 2/3$

5.1.4 Indépendance de deux variables catégoriques

On dira que deux variables sont indépendantes si le fait de connaître la valeur de l'une des deux variables ne nous apprend rien sur la distribution de probabilité de l'autre variable.

Plus rigoureusement, X et Y sont indépendantes si et seulement si toutes les probabilités conjointes sont égales au produit des probabilités marginales :

$$p_{ij} = p_{i\bullet} p_{\bullet j} \quad \forall i, j \quad (5.1)$$

Conséquences de l'indépendance de X et Y

Si X est indépendant de Y , alors :

- Y est indépendant de X
- les lois conditionnelles de X sont toutes égales à la loi marginale de X (et de même pour Y)
- la covariance et la corrélation entre X et Y sont nulles (Mais, l'inverse n'est pas toujours vrai, c'est-à-dire que la corrélation peut être nulle sans que les variables soient indépendantes.)

Exemple 5.4. *La couleur est-elle indépendante de la parité dans l'exemple 5.1 ? Non ! On peut arriver à cette conclusion de plusieurs façons.*

- On peut vérifier que

$$\frac{1}{5} = p_{11} \neq p_{1\bullet} p_{\bullet 1} = \frac{2}{5} \times \frac{2}{5} = \frac{4}{25}$$

- On a vu à l'exemple 5.3 que la loi conditionnelle de X sachant que Y est pair n'est pas égale à la loi conditionnelle de X sachant que Y est impair. Ainsi, il est impossible que les lois conditionnelles de X soit toutes deux égales à la loi marginale de X , ce qui serait le cas si X et Y étaient indépendantes.
- La loi conditionnelle de Y sachant que X est bleue trouvée à l'exemple 5.3 n'est pas égale à la loi marginale de Y trouvée à l'exemple 5.2. Si Y et X étaient indépendantes, ces deux loi seraient identiques.

5.2 Test d'indépendance à partir d'observations

5.2.1 Tableau de contingence (tableau de fréquences)

La distribution conjointe exacte n'est connue que si un recensement est effectué ou si un modèle théorique est accepté d'emblée. Dans les faits, on procède très souvent à un échantillonnage pour étudier la relation entre deux variables qualitatives.

On présente alors les observations sous forme de tableau de fréquences à deux dimensions, souvent appelé *tableau à double entrée* ou *tableau de contingence*, ou encore *tableau croisé*, tel que présenté au chapitre 2, et rappelé ci-dessous.

$X \backslash Y$	y_1	y_2	...	y_J	Total
x_1	O_{11}	O_{12}	...	O_{1J}	$O_{1\bullet}$
x_2	O_{21}	O_{22}	...	O_{2J}	$O_{2\bullet}$
...	...	...	...	...	...
x_I	O_{I1}	O_{I2}	...	O_{IJ}	$O_{I\bullet}$
Total	$O_{\bullet 1}$	$O_{\bullet 2}$	...	$O_{\bullet J}$	n


Exemple 5.5. Une étude cas-témoins est conduite auprès de 224 femmes pour déterminer le lien entre la prise de contraceptifs oraux et l'avènement d'un infarctus du myocarde avant 45 ans. On observe les données suivantes :

Contraceptifs	Infarctus		Total
	Oui	Non	
Oui	23	34	57
Non	35	132	167
Total	58	166	224

Notez que pour la collecte de données, 58 femmes traitées pour un infarctus ont été jumelées chacune avec 3 patientes témoins du même hôpital. C'est ce qu'on appelle une étude rétrospective cas-témoins.

(Source des données : Agresti, A., *Categorical Data Analysis*, 1990, p. 12)

On peut représenter graphiquement les données :



Il semble y avoir une relation entre les deux variables, c'est-à-dire que parmi les femmes ayant pris un contraceptif on observe une plus grande proportion d'infarctus que chez les femmes n'ayant pas pris de contraceptif. On souhaite tester rigoureusement la relation entre les variables pour voir si elle est statistiquement significative.

5.2.2 Test statistique

On veut tester les hypothèses

H_0 : les deux variables sont indépendantes

H_1 : les deux variables sont dépendantes.

La statistique de test se base sur la comparaison des fréquences observées à celles attendues sous H_0 . Plus précisément, voici les étapes du test :

1. déterminer les fréquences attendues sous l'indépendance (notées E_{ij} , pour la fréquence espérée dans la cellule (i, j) sous H_0);
2. calculer une « distance » entre les fréquences observées et les fréquences espérées (c'est notre statistique de test);
3. déterminer la distribution échantillonnale de la « distance » sous H_0 ;
4. établir si la distance entre les observations et le modèle d'indépendance est significative statistiquement au seuil α , ou si elle relève plutôt du hasard.

Calcul des fréquences espérées

On considère ici les distributions marginales fixes. Sous l'hypothèse nulle, les variables sont indépendantes et donc les probabilités conjointes sont égales aux produits des probabilités marginales correspondantes. Ainsi, si H_0 est vraie, on s'attend à ce que :

$$\frac{O_{ij}}{O_{i\bullet}} \approx \frac{O_{\bullet j}}{n} \Rightarrow O_{ij} \approx \frac{O_{\bullet j} O_{i\bullet}}{n}$$

Les fréquences espérées sous H_0 sont donc

$$E_{ij} = \frac{O_{\bullet j} O_{i\bullet}}{n}$$

Calcul de la distance

Si les E_{ij} sont très différents des O_{ij} , cela laisse croire que l'hypothèse nulle n'est pas vraie. Pour mesurer la différence entre les E_{ij} et les O_{ij} , on utilise

$$D = \sum_{i=1}^I \sum_{j=1}^J \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Le choix de cette distance peut sembler arbitraire, mais il se trouve que si H_0 est vraie, et que n est assez grand alors D suit approximativement une loi du khi-carré avec $(I - 1)(J - 1)$ degrés de liberté. Que veut dire n assez grand ici ? On dit généralement que l'approximation est valide si les fréquences espérées (E_{ij}) sont toutes plus grandes ou égales à 5.

Puisqu'on peut approximer la distribution de la statistique de test sous H_0 , on peut facilement utiliser cette statistique pour créer un test d'hypothèse.

Règle de décision

Sous H_0 ,

$$D \stackrel{approx}{\sim} \chi_{(I-1)(J-1)}^2$$

De grandes valeurs de D sont peu probables sous H_0 , et laissent plutôt croire que H_1 est vraie. On rejettera donc H_0 au seuil α si

$$D_{obs} > \chi_{(I-1)(J-1), \alpha}^2$$

Exemple 5.6. Revenons à l'exemple 5.5. On rappelle les données :

Contraceptifs	Infarctus		Total
	Oui	Non	
Oui	23	34	57
Non	35	132	167
Total	58	166	224

Si les variables étaient indépendantes :

- on devrait observer environ la même proportion d'infarctus parmi les utilisatrices de contraceptifs oraux que parmi les non utilisatrices, c'est-à-dire 58 sur 224 $\approx 0,26$;
- on devrait observer environ la même proportion d'utilisatrices de contraceptifs parmi les femmes ayant eu un infarctus que parmi celles n'en ayant pas eu, c'est-à-dire 57 sur 224 $\approx 0,25$.

Peut-on dire au seuil de 5% que la prise de contraceptifs oraux est liée au risque de faire un infarctus ?

On commence par calculer les fréquences espérées :

Contraceptifs	Infarctus	
	Oui	Non
Oui	$\frac{57 \times 58}{224} \approx 14,76$	$\frac{57 \times 166}{224} \approx 42,24$
Non	$\frac{167 \times 58}{224} \approx 43,24$	$\frac{167 \times 166}{224} \approx 123,75$

On peut maintenant calculer la statistique de test

$$D_{obs} = \frac{(23 - 14,76)^2}{14,76} + \frac{(34 - 42,24)^2}{42,24} + \frac{(35 - 43,24)^2}{43,24} + \frac{(132 - 123,75)^2}{123,75} = 8,33$$

On trouve que

$$D_{obs} > \chi_{(I-1)(J-1);\alpha}^2 = \chi_{1;0,05}^2 = 3,83.$$

On rejette donc H_0 et on conclut qu'au seuil $\alpha = 0,05$, la prise de contraceptifs oraux est liée au risque de faire un infarctus.

Quelques notes sur le test du χ^2

- Dans notre exemple, on avait seulement deux catégories dans chacune des variables. Les calculs sont alors moins longs. Toutefois, le test s'applique à des variables avec plus de catégories. Il suffit de faire attention aux degrés de liberté de la loi χ^2 à utiliser pour trouver la zone de rejet.
- Pour une hypothèse avec deux variables ayant chacune seulement deux catégories, le test du χ^2 est en fait identique à un test de différence entre deux proportions! Ainsi, dans notre exemple, on aurait eu exactement les mêmes conclusions si on avait plutôt testé directement si la proportion d'infarctus était la même chez les femmes prenant un contraceptif que chez celles n'en prenant pas.
- Il existe également des façons de tester l'association entre plus de deux variables. Ces méthodes sont abordées dans un cours sur l'analyse de tableaux de fréquences.
- Il faut être prudent quand on utilise le test χ^2 dans plusieurs sous-groupes d'une même population. Il arrive parfois qu'une association entre deux variables soit détectée dans plusieurs groupes, mais qu'on retrouve l'association inverse lorsqu'on agrège les données de ces groupes. C'est ce qu'on nomme le paradoxe de Simpson.

AUTRES NOTES

Annexe A

Preuve de l'équation 3.9

On veut montrer que

$$E(\bar{X}) = \mu, \quad (\text{A.1})$$

et donc qu'on peut donc simplement utiliser la moyenne échantillonnale pour estimer la moyenne de la population, même si les observations sont obtenues sans remise d'une population finie. On aura besoin de nouvelle notation.

Notation :

Soit x_i la valeur d'intérêt pour l'individu i de la population, pour $i = 1, \dots, N$. Notez l'usage d'une minuscule ici : la valeur de l'individu i est considérée fixe.

Soit C_i l'indicateur que l'individu i est sélectionné dans l'échantillon, c'est-à-dire que

$$C_i = \begin{cases} 1 & \text{si l'individu } i \text{ est dans l'échantillon} \\ 0 & \text{sinon} \end{cases}$$

Notez l'usage de la majuscule ici, puisque C_i est une variable aléatoire.

La moyenne de la population finie est alors

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i. \quad (\text{A.2})$$

La moyenne échantillonnale pour un ÉAS sans remise s'écrit quant à elle

$$\bar{X} = \frac{1}{n} \sum_{i=1}^N C_i x_i. \quad (\text{A.3})$$

Démonstration :

On note qu'il n'y a que les C_i qui sont aléatoires dans l'expression de $\bar{X}$. Pour calculer l'espérance de $\bar{X}$, il faut donc connaître leur distribution.

On a calculé au chapitre 1 que pour un ÉAS sans remise tous les individus ont la même probabilité d'être sélectionnés, et que celle-ci est égale à $\frac{n}{N}$. Les C_i sont donc des variables aléatoires distribuées identiquement suivant une loi Bernoulli de probabilité $p = \frac{n}{N}$:

$$C_i \sim \text{Bernoulli}(n/N) \text{ pour } i = 1, \dots, N.$$

Notez toutefois que les C_i ne sont pas indépendantes puisqu'on procède sans remise. L'indépendance n'est toutefois pas nécessaire pour la démonstration.

Sachant la distribution des C_i , on peut calculer

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{n} \sum_{i=1}^N C_i x_i\right) \\ &= \frac{1}{n} \sum_{i=1}^N E(C_i x_i) \\ &= \frac{1}{n} \sum_{i=1}^N x_i E(C_i) \\ &= \frac{1}{n} \sum_{i=1}^N x_i \frac{n}{N} \\ &= \frac{1}{n} \frac{n}{N} \sum_{i=1}^N x_i \\ &= \frac{1}{N} \sum_{i=1}^N x_i \\ &= \mu \end{aligned}$$

ce qui prouve le résultat espéré.

Notez qu'on a utilisé ici la linéarité de l'espérance, ainsi que le fait que les x_i sont considérés fixes.

Annexe B

Tables de lois

On donne aux pages suivantes les tables suivantes :

- Fonction de répartition de la loi normale centrée réduite
- Quantiles de la loi du khi-carré
- Quantiles de la loi t de Student
- Quantiles de la loi de Fisher


Ces pages proviennent du livre suivant :

Hines, W. W., Montgomery, D. C., Montgomery, D. C., Goldsman, D. M., Borror, C. M., Reny-Nolin, E., (2017). Probabilités et statistique pour ingénieurs (3e édition). Chenelière éducation. ISBN : 9782765051886

et sont reproduites en vertu de l'entente entre l'Université Laval et Copibec.

Table II Les valeurs de la fonction de répartition de la loi normale centrée réduite*


$\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$										
Deuxième décimale de z										
z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
Première décimale de z	0,0	0,500 00	0,503 99	0,507 98	0,511 97	0,515 95	0,519 94	0,523 92	0,527 90	0,531 88
	0,1	0,539 83	0,543 79	0,547 76	0,551,72	0,555 67	0,559 62	0,563 56	0,567 49	0,571 42
	0,2	0,579 26	0,583 17	0,587 06	0,590 95	0,594 83	0,598 71	0,602 57	0,606 42	0,610 26
	0,3	0,617 91	0,621 72	0,625 51	0,629 30	0,633 07	0,636 83	0,640 58	0,644 31	0,648 03
	0,4	0,655 42	0,659 10	0,662 76	0,666 40	0,670 03	0,673 64	0,677 24	0,680 82	0,684 38
	0,5	0,691 46	0,694 97	0,698 47	0,701 94	0,705 40	0,708 84	0,712 26	0,715 66	0,719 04
	0,6	0,725 75	0,729 07	0,732 37	0,735 65	0,738 91	0,742 15	0,745 37	0,748 57	0,751 75
	0,7	0,758 03	0,761 15	0,764 24	0,767 30	0,770 35	0,773 37	0,776 37	0,779 35	0,782 30
	0,8	0,788 14	0,791 03	0,793 89	0,796 73	0,799 54	0,802 34	0,805 10	0,807 85	0,810 57
	0,9	0,815 94	0,818 59	0,821 21	0,823 81	0,826 39	0,828 94	0,831 47	0,833 97	0,836 46
	1,0	0,841 34	0,843 75	0,846 13	0,848 49	0,850 83	0,853 14	0,855 43	0,857 69	0,859 93
	1,1	0,864 33	0,866 50	0,868 64	0,870 76	0,872 85	0,874 93	0,876 97	0,879 00	0,881 00
	1,2	0,884 93	0,886 86	0,888 77	0,890 65	0,892 51	0,894 35	0,896 16	0,897 96	0,899 73
	1,3	0,903 20	0,904 90	0,906 58	0,908 24	0,909 88	0,911 49	0,913 08	0,914 65	0,916 21
	1,4	0,919 24	0,920 73	0,922 19	0,923 64	0,925 06	0,926 47	0,927 85	0,929 22	0,930 56
	1,5	0,933 19	0,934 48	0,935 74	0,936 99	0,938 22	0,939 43	0,940 62	0,941 79	0,942 95
	1,6	0,945 20	0,946 30	0,947 38	0,948 45	0,949 50	0,950 53	0,951 54	0,952 54	0,953 52
	1,7	0,955 43	0,956 37	0,957 28	0,958 18	0,959 07	0,959 94	0,960 80	0,961 64	0,962 46
	1,8	0,964 07	0,964 85	0,965 62	0,966 37	0,967 11	0,967 84	0,968 56	0,969 26	0,969 95
Première décimale de z	1,9	0,971 28	0,971 93	0,972 57	0,973 20	0,973 81	0,974 41	0,975 00	0,975 58	0,976 15
	2,0	0,977 25	0,977 78	0,978 31	0,978 82	0,979 32	0,979 82	0,980 30	0,980 77	0,981 24
	2,1	0,982 14	0,982 57	0,983 00	0,983 41	0,983 82	0,984 22	0,984 61	0,985 00	0,985 37
	2,2	0,986 10	0,986 45	0,986 79	0,987 13	0,987 45	0,987 78	0,988 09	0,988 40	0,988 70
	2,3	0,989 28	0,989 56	0,989 83	0,990 10	0,990 36	0,990 61	0,990 86	0,991 11	0,991 34
	2,4	0,991 80	0,992 02	0,992 24	0,992 45	0,992 66	0,992 86	0,993 05	0,993 24	0,993 43
	2,5	0,993 79	0,993 96	0,994 13	0,994 30	0,994 46	0,994 61	0,994 77	0,994 92	0,995 06
	2,6	0,995 34	0,995 47	0,995 60	0,995 73	0,995 85	0,995 98	0,996 09	0,996 21	0,996 32
	2,7	0,996 53	0,996 64	0,996 74	0,996 83	0,996 93	0,997 02	0,997 11	0,997 20	0,997 28
	2,8	0,997 44	0,997 52	0,997 60	0,997 67	0,997 74	0,997 81	0,997 88	0,997 95	0,998 01
	2,9	0,998 13	0,998 19	0,998 25	0,998 31	0,998 36	0,998 41	0,998 46	0,998 51	0,998 56
	3,0	0,998 65	0,998 69	0,998 74	0,998 78	0,998 82	0,998 86	0,998 89	0,998 93	0,998 97
	3,1	0,999 03	0,999 06	0,999 10	0,999 13	0,999 16	0,999 18	0,999 21	0,999 24	0,999 26
	3,2	0,999 31	0,999 34	0,999 36	0,999 38	0,999 40	0,999 42	0,999 44	0,999 46	0,999 48
	3,3	0,999 52	0,999 53	0,999 55	0,999 57	0,999 58	0,999 60	0,999 61	0,999 62	0,999 64
	3,4	0,999 66	0,999 68	0,999 69	0,999 70	0,999 71	0,999 72	0,999 73	0,999 74	0,999 75
	3,5	0,999 77	0,999 78	0,999 78	0,999 79	0,999 80	0,999 81	0,999 81	0,999 82	0,999 83
	3,6	0,999 84	0,999 85	0,999 85	0,999 86	0,999 86	0,999 87	0,999 87	0,999 88	0,999 88
	3,7	0,999 89	0,999 90	0,999 90	0,999 90	0,999 91	0,999 91	0,999 92	0,999 92	0,999 92
	3,8	0,999 93	0,999 93	0,999 93	0,999 94	0,999 94	0,999 94	0,999 94	0,999 95	0,999 95
	3,9	0,999 95	0,999 95	0,999 96	0,999 96	0,999 96	0,999 96	0,999 96	0,999 96	0,999 97



*Les valeurs figurant dans cette table sont celles de $\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$, où $Z \sim N(0, 1)$. La première décimale de z est indiquée dans la 1^{re} colonne, et sa deuxième décimale est indiquée sur la 1^{re} ligne. Par exemple, $\Phi(1,23) = 0,890\ 65$.

Table III Les quantiles de la loi du khi-carré*

$\alpha \backslash v$		Probabilité										
		0,995	0,990	0,975	0,950	0,900	0,500	0,100	0,050	0,025	0,010	0,005
Degrés de liberté	1	0,00+	0,00+	0,00+	0,00+	0,02	0,45	2,71	3,84	5,02	6,63	7,88
	2	0,01	0,02	0,05	0,10	0,21	1,39	4,61	5,99	7,38	9,21	10,60
	3	0,07	0,11	0,22	0,35	0,58	2,37	6,25	7,81	9,35	11,34	12,84
	4	0,21	0,30	0,48	0,71	1,06	3,36	7,78	9,49	11,14	13,28	14,86
	5	0,41	0,55	0,83	1,15	1,61	4,35	9,24	11,07	12,83	15,09	16,75
	6	0,68	0,87	1,24	1,64	2,20	5,35	10,65	12,59	14,45	16,81	18,55
	7	0,99	1,24	1,69	2,17	2,83	6,35	12,02	14,07	16,01	18,48	20,28
	8	1,34	1,65	2,18	2,73	3,49	7,34	13,36	15,51	17,53	20,09	21,96
	9	1,73	2,09	2,70	3,33	4,17	8,34	14,68	16,92	19,02	21,67	23,59
	10	2,16	2,56	3,25	3,94	4,87	9,34	15,99	18,31	20,48	23,21	25,19
	11	2,60	3,05	3,82	4,57	5,58	10,34	17,28	19,68	21,92	24,72	26,76
	12	3,07	3,57	4,40	5,23	6,30	11,34	18,55	21,03	23,34	26,22	28,30
	13	3,57	4,11	5,01	5,89	7,04	12,34	19,81	22,36	24,74	27,69	29,82
	14	4,07	4,66	5,63	6,57	7,79	13,34	21,06	23,68	26,12	29,14	31,32
	15	4,60	5,23	6,27	7,26	8,55	14,34	22,31	25,00	27,49	30,58	32,80
	16	5,14	5,81	6,91	7,96	9,31	15,34	23,54	26,30	28,85	32,00	34,27
	17	5,70	6,41	7,56	8,67	10,09	16,34	24,77	27,59	30,19	33,41	35,72
	18	6,26	7,01	8,23	9,39	10,87	17,34	25,99	28,87	31,53	34,81	37,16
	19	6,84	7,63	8,91	10,12	11,65	18,34	27,20	30,14	32,85	36,19	38,58
	20	7,43	8,26	9,59	10,85	12,44	19,34	28,41	31,41	34,17	37,57	40,00
	21	8,03	8,90	10,28	11,59	13,24	20,34	29,62	32,67	35,48	38,93	41,40
	22	8,64	9,54	10,98	12,34	14,04	21,34	30,81	33,92	36,78	40,29	42,80
	23	9,26	10,20	11,69	13,09	14,85	22,34	32,01	35,17	38,08	41,64	44,18
	24	9,89	10,86	12,40	13,85	15,66	23,34	33,20	36,42	39,36	42,98	45,56
	25	10,52	11,52	13,12	14,61	16,47	24,34	34,28	37,65	40,65	44,31	46,93
	26	11,16	12,20	13,84	15,38	17,29	25,34	35,56	38,89	41,92	45,64	48,29
	27	11,81	12,88	14,57	16,15	18,11	26,34	36,74	40,11	43,19	46,96	49,65
	28	12,46	13,57	15,31	16,93	18,94	27,34	37,92	41,34	44,46	48,28	50,99
	29	13,12	14,26	16,05	17,71	19,77	28,34	39,09	42,56	45,72	49,59	52,34
	30	13,79	14,95	16,79	18,49	20,60	29,34	40,26	43,77	46,98	50,89	53,67
40	20,71	22,16	24,43	26,51	29,05	39,34	51,81	55,76	59,34	63,69	66,77	
50	27,99	29,71	32,36	34,76	37,69	49,33	63,17	67,50	71,42	76,15	79,49	
60	35,53	37,48	40,48	43,19	46,46	59,33	74,40	79,08	83,30	88,38	91,95	
70	43,28	45,44	48,76	51,74	55,33	69,33	85,53	90,53	95,02	100,42	104,22	
80	51,17	53,54	57,15	60,39	64,28	79,33	96,58	101,88	106,63	112,33	116,32	
90	59,20	61,75	65,65	69,13	73,29	89,33	107,57	113,14	118,14	124,12	128,30	
100	67,33	70,06	74,22	77,93	82,36	99,33	118,50	124,34	129,56	135,81	140,17	




*Les valeurs figurant dans cette table sont les quantiles $\chi^2_{\alpha;v}$ tels que $P(U > \chi^2_{\alpha;v}) = \alpha$, où $U \sim \chi^2_v$.

Table IV Les quantiles de la loi t de Student*

α v	Probabilité									
	0,40	0,25	0,10	0,05	0,025	0,01	0,005	0,0025	0,001	0,0005
1	0,325	1,000	3,078	6,314	12,706	31,821	63,657	127,32	318,31	636,62
2	0,289	0,816	1,886	2,920	4,303	6,965	9,925	14,089	23,326	31,598
3	0,277	0,765	1,638	2,353	3,182	4,541	5,841	7,453	10,213	12,924
4	0,271	0,741	1,533	2,132	2,776	3,747	4,604	5,598	7,173	8,610
5	0,267	0,727	1,476	2,015	2,571	3,365	4,032	4,773	5,893	6,869
6	0,265	0,718	1,440	1,943	2,447	3,143	3,707	4,317	5,208	5,959
7	0,263	0,711	1,415	1,895	2,365	2,998	3,499	4,029	4,785	5,408
8	0,262	0,706	1,397	1,860	2,306	2,896	3,355	3,833	4,501	5,041
9	0,261	0,703	1,383	1,833	2,262	2,821	3,250	3,690	4,297	4,781
10	0,260	0,700	1,372	1,812	2,228	2,764	3,169	3,581	4,144	4,587
11	0,260	0,697	1,363	1,796	2,201	2,718	3,106	3,497	4,025	4,437
12	0,259	0,695	1,356	1,782	2,179	2,681	3,055	3,428	3,930	4,318
13	0,259	0,694	1,350	1,771	2,160	2,650	3,012	3,372	3,852	4,221
14	0,258	0,692	1,345	1,761	2,145	2,624	2,977	3,326	3,787	4,140
15	0,258	0,691	1,341	1,753	2,131	2,602	2,947	3,286	3,733	4,073
16	0,258	0,690	1,337	1,746	2,120	2,583	2,921	3,252	3,686	4,015
17	0,257	0,689	1,333	1,740	2,110	2,567	2,898	3,222	3,646	3,965
18	0,257	0,688	1,330	1,734	2,101	2,552	2,878	3,197	3,610	3,922
19	0,257	0,688	1,328	1,729	2,093	2,539	2,861	3,174	3,579	3,883
20	0,257	0,687	1,325	1,725	2,086	2,528	2,845	3,153	3,552	3,850
21	0,257	0,686	1,323	1,721	2,080	2,518	2,831	3,135	3,527	3,819
22	0,256	0,686	1,321	1,717	2,074	2,508	2,819	3,119	3,505	3,792
23	0,256	0,685	1,319	1,714	2,069	2,500	2,807	3,104	3,485	3,767
24	0,256	0,685	1,318	1,711	2,064	2,492	2,797	3,091	3,467	3,745
25	0,256	0,684	1,316	1,708	2,060	2,485	2,787	3,078	3,450	3,725
26	0,256	0,684	1,315	1,706	2,056	2,479	2,779	3,067	3,435	3,707
27	0,256	0,684	1,314	1,703	2,052	2,473	2,771	3,057	3,421	3,690
28	0,256	0,683	1,313	1,701	2,048	2,467	2,763	3,047	3,408	3,674
29	0,256	0,683	1,311	1,699	2,045	2,462	2,756	3,038	3,396	3,659
30	0,256	0,683	1,310	1,697	2,042	2,457	2,750	3,030	3,385	3,646
40	0,255	0,681	1,303	1,684	2,021	2,423	2,704	2,971	3,307	3,551
60	0,254	0,679	1,296	1,671	2,000	2,390	2,660	2,915	3,232	3,460
120	0,254	0,677	1,289	1,658	1,980	2,358	2,617	2,860	3,160	3,373
∞	0,253	0,674	1,282	1,645	1,960	2,326	2,576	2,807	3,090	3,291


Source : E. S. Pearson et H. O. Hartley, 1966, *Biometrika Tables for Statisticians*, 3e éd., Cambridge : Cambridge University Press, vol. 1. Table adaptée avec l'autorisation des administrateurs de Biometrika.



*Les valeurs figurant dans cette table sont les quantiles $t_{\alpha;v}$ tels que $P(T > t_{\alpha;v}) = \alpha$, où $T \sim t_v$.

Table V Les quantiles de la loi de Fisher*


$F_{0,01;v_1,v_2}$																				
$\begin{matrix} v_1 \\ \backslash \\ v_2 \end{matrix}$	Nombre de degrés de liberté du numérateur (v_1)																			
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞	
Nombre de degrés de liberté du dénominateur (v_2)	1	4052	4999,5	5403	5625	5764	5859	5928	5982	6022	6056	6106	6157	6209	6235	6261	6287	6313	6339	6366
	2	98,50	99,00	99,17	99,25	99,30	99,33	99,36	99,37	99,39	99,40	99,42	99,43	99,45	99,46	99,47	99,47	99,48	99,49	99,50
	3	34,12	30,82	29,46	28,71	28,24	27,91	27,67	27,49	27,35	27,23	27,05	26,87	26,69	26,60	26,50	26,41	26,32	26,22	26,13
	4	21,20	18,00	16,69	15,98	15,52	15,21	14,98	14,80	14,66	14,55	14,37	14,20	14,02	13,93	13,84	13,75	13,65	13,56	13,46
	5	16,26	13,27	12,06	11,39	10,97	10,67	10,46	10,29	10,16	10,05	9,89	9,72	9,55	9,47	9,38	9,29	9,20	9,11	9,02
	6	13,75	10,92	9,78	9,15	8,75	8,47	8,26	8,10	7,98	7,87	7,72	7,56	7,40	7,31	7,23	7,14	7,06	6,97	6,88
	7	12,25	9,55	8,45	7,85	7,46	7,19	6,99	6,84	6,72	6,62	6,47	6,31	6,16	6,07	5,99	5,91	5,82	5,74	5,65
	8	11,26	8,65	7,59	7,01	6,63	6,37	6,18	6,03	5,91	5,81	5,67	5,52	5,36	5,28	5,20	5,12	5,03	4,95	4,86
	9	10,56	8,02	6,99	6,42	6,06	5,80	5,61	5,47	5,35	5,26	5,11	4,96	4,81	4,73	4,65	4,57	4,48	4,40	4,31
	10	10,04	7,56	6,55	5,99	5,64	5,39	5,20	5,06	4,94	4,85	4,71	4,56	4,41	4,33	4,25	4,17	4,08	4,00	3,91
	11	9,65	7,21	6,22	5,67	5,32	5,07	4,89	4,74	4,63	4,54	4,40	4,25	4,1	4,02	3,94	3,86	3,78	3,69	3,60
	12	9,33	6,93	5,95	5,41	5,06	4,82	4,64	4,50	4,39	4,30	4,16	4,01	3,86	3,78	3,70	3,62	3,54	3,45	3,36
	13	9,07	6,70	5,74	5,21	4,86	4,62	4,44	4,30	4,19	4,10	3,96	3,82	3,66	3,59	3,51	3,43	3,34	3,25	3,17
	14	8,86	6,51	5,56	5,04	4,69	4,46	4,28	4,14	4,03	3,94	3,80	3,66	3,51	3,43	3,35	3,27	3,18	3,09	3,00
	15	8,68	6,36	5,42	4,89	4,36	4,32	4,14	4,00	3,89	3,80	3,67	3,52	3,37	3,29	3,21	3,13	3,05	2,96	2,87
	16	8,53	6,23	5,29	4,77	4,44	4,20	4,03	3,89	3,78	3,69	3,55	3,41	3,26	3,18	3,10	3,02	2,93	2,84	2,75
	17	8,40	6,11	5,18	4,67	4,34	4,10	3,93	3,79	3,68	3,59	3,46	3,31	3,16	3,08	3,00	2,92	2,83	2,75	2,65
	18	8,29	6,01	5,09	4,58	4,25	4,01	3,84	3,71	3,60	3,51	3,37	3,23	3,08	3,00	2,92	2,84	2,75	2,66	2,57
	19	8,18	5,93	5,01	4,50	4,17	3,94	3,77	3,63	3,52	3,43	3,30	3,15	3,00	2,92	2,84	2,76	2,67	2,58	2,59
Nombre de degrés de liberté du dénominateur (v_2)	20	8,10	5,85	4,94	4,43	4,10	3,87	3,70	3,56	3,46	3,37	3,23	3,09	2,94	2,86	2,78	2,69	2,61	2,52	2,42
	21	8,02	5,78	4,87	4,37	4,04	3,81	3,64	3,51	3,40	3,31	3,17	3,03	2,88	2,80	2,72	2,64	2,55	2,46	2,36
	22	7,95	5,72	4,82	4,31	3,99	3,76	3,59	3,45	3,35	3,26	3,12	2,98	2,83	2,75	2,67	2,58	2,50	2,40	2,31
	23	7,88	5,66	4,76	4,26	3,94	3,71	3,54	3,41	3,30	3,21	3,07	2,93	2,78	2,70	2,62	2,54	2,45	2,35	2,26
	24	7,82	5,61	4,72	4,22	3,90	3,67	3,50	3,36	3,26	3,17	3,03	2,89	2,74	2,66	2,58	2,49	2,40	2,31	2,21
	25	7,77	5,57	4,68	4,18	3,85	3,63	3,46	3,32	3,22	3,13	2,99	2,85	2,70	2,62	2,54	2,45	2,36	2,27	2,17
	26	7,72	5,53	4,64	4,14	3,82	3,59	3,42	3,29	3,18	3,09	2,96	2,81	2,66	2,58	2,50	2,42	2,33	2,23	2,13
	27	7,68	5,49	4,60	4,11	3,78	3,56	3,39	3,26	3,15	3,06	2,93	2,78	2,63	2,55	2,47	2,38	2,29	2,20	2,10
	28	7,64	5,45	4,57	4,07	3,75	3,53	3,36	3,23	3,12	3,03	2,90	2,75	2,60	2,52	2,44	2,35	2,26	2,17	2,06
	29	7,60	5,42	4,54	4,04	3,73	3,50	3,33	3,20	3,09	3,00	2,87	2,73	2,57	2,49	2,41	2,33	2,23	2,14	2,03
	30	7,56	5,39	4,51	4,02	3,70	3,47	3,30	3,17	3,07	2,98	2,84	2,70	2,55	2,47	2,39	2,30	2,21	2,11	2,01
	40	7,31	5,18	4,31	3,83	3,51	3,29	3,12	2,99	2,89	2,80	2,66	2,52	2,37	2,29	2,20	2,11	2,02	1,92	1,80
	60	7,08	4,98	4,13	3,65	3,34	3,12	2,95	2,82	2,72	2,63	2,50	2,35	2,20	2,12	2,03	1,94	1,84	1,73	1,60
	120	6,85	4,79	3,95	3,48	3,17	2,96	2,79	2,66	2,56	2,47	2,34	2,19	2,03	1,95	1,86	1,76	1,66	1,53	1,38
	∞	6,63	4,61	3,78	3,32	3,02	2,80	2,64	2,51	2,41	2,32	2,18	2,04	1,88	1,79	1,70	1,59	1,47	1,32	1,00



*Les valeurs figurant dans cette table sont les quantiles $F_{0,01;v_1,v_2}$ tels que $P(F > F_{0,01;v_1,v_2}) = 0,01$, où $F \sim F_{v_1,v_2}$.

Table V Les quantiles de la loi de Fisher* (suite)


$F_{0,025 : v_1, v_2}$																				
$v_1 \backslash v_2$		Nombre de degrés de liberté du numérateur (v_1)																		
		1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
Nombre de degrés de liberté du dénominateur (v_2)	1	647,8	799,5	864,2	899,6	921,8	937,1	948,2	956,7	963,3	968,6	976,7	984,9	993,1	997,2	1001	1006	1010	1014	1018
	2	38,51	39,00	39,17	39,25	39,30	39,33	39,36	39,37	39,39	39,40	39,41	39,43	39,45	39,46	39,46	39,47	39,48	39,49	39,50
	3	17,44	16,04	15,44	15,10	14,88	14,73	14,62	14,54	14,47	14,42	14,34	14,25	14,17	14,12	14,08	14,04	13,99	13,95	13,90
	4	12,22	10,65	9,98	9,60	9,36	9,20	9,07	8,98	8,90	8,84	8,75	8,66	8,56	8,51	8,46	8,41	8,36	8,31	8,26
	5	10,01	8,43	7,76	7,39	7,15	6,98	6,85	6,76	6,68	6,62	6,52	6,43	6,33	6,28	6,23	6,18	6,12	6,07	6,02
	6	8,81	7,26	6,60	6,23	5,99	5,82	5,70	5,60	5,52	5,46	5,37	5,27	5,17	5,12	5,07	5,01	4,96	4,90	4,85
	7	8,07	6,54	5,89	5,52	5,29	5,12	4,99	4,90	4,82	4,76	4,67	4,57	4,47	4,42	4,36	4,31	4,25	4,20	4,14
	8	7,57	6,06	5,42	5,05	4,82	4,65	4,53	4,43	4,36	4,30	4,20	4,10	4,00	3,95	3,89	3,84	3,78	3,73	3,67
	9	7,21	5,71	5,08	4,72	4,48	4,32	4,20	4,10	4,03	3,96	3,87	3,77	3,67	3,61	3,56	3,51	3,45	3,39	3,33
	10	6,94	5,46	4,83	4,47	4,24	4,07	3,95	3,85	3,78	3,72	3,62	3,52	3,42	3,37	3,31	3,26	3,20	3,14	3,08
	11	6,72	5,26	4,63	4,28	4,04	3,88	3,76	3,66	3,59	3,53	3,43	3,33	3,23	3,17	3,12	3,06	3,00	2,94	2,88
	12	6,55	5,10	4,47	4,12	3,89	3,73	3,61	3,51	3,44	3,37	3,28	3,18	3,07	3,02	2,96	2,91	2,85	2,79	2,72
	13	6,41	4,97	4,35	4,00	3,77	3,60	3,48	3,39	3,31	3,25	3,15	3,05	2,95	2,89	2,84	2,78	2,72	2,66	2,60
	14	6,30	4,86	4,24	3,89	3,66	3,50	3,38	3,29	3,21	3,15	3,05	2,95	2,84	2,79	2,73	2,67	2,61	2,55	2,49
	15	6,20	4,77	4,15	3,80	3,58	3,41	3,29	3,20	3,12	3,06	2,96	2,86	2,76	2,70	2,64	2,59	2,52	2,46	2,40
	16	6,12	4,69	4,08	3,73	3,50	3,34	3,22	3,12	3,05	2,99	2,89	2,79	2,68	2,63	2,57	2,51	2,45	2,38	2,32
	17	6,04	4,62	4,01	3,66	3,44	3,28	3,16	3,06	2,98	2,92	2,82	2,72	2,62	2,56	2,50	2,44	2,38	2,32	2,25
	18	5,98	4,56	3,95	3,61	3,38	3,22	3,10	3,01	2,93	2,87	2,77	2,67	2,56	2,50	2,44	2,38	2,32	2,26	2,19
Nombre de degrés de liberté du dénominateur (v_2)	19	5,92	4,51	3,90	3,56	3,33	3,17	3,05	2,96	2,88	2,82	2,72	2,62	2,51	2,45	2,39	2,33	2,27	2,20	2,13
	20	5,87	4,46	3,86	3,51	3,29	3,13	3,01	2,91	2,84	2,77	2,68	2,57	2,46	2,41	2,35	2,29	2,22	2,16	2,09
	21	5,83	4,42	3,82	3,48	3,25	3,09	2,97	2,87	2,80	2,73	2,64	2,53	2,42	2,37	2,31	2,25	2,18	2,11	2,04
	22	5,79	4,38	3,78	3,44	3,22	3,05	2,93	2,84	2,76	2,70	2,60	2,50	2,39	2,33	2,27	2,21	2,14	2,08	2,00
	23	5,75	4,35	3,75	3,41	3,18	3,02	2,90	2,81	2,73	2,67	2,57	2,47	2,36	2,30	2,24	2,18	2,11	2,04	1,97
	24	5,72	4,32	3,72	3,38	3,15	2,99	2,87	2,78	2,70	2,64	2,54	2,44	2,33	2,27	2,21	2,15	2,08	2,01	1,94
	25	5,69	4,29	3,69	3,35	3,13	2,97	2,85	2,75	2,68	2,61	2,51	2,41	2,30	2,24	2,18	2,12	2,05	1,98	1,91
	26	5,66	4,27	3,67	3,33	3,10	2,94	2,82	2,73	2,65	2,59	2,49	2,39	2,28	2,22	2,16	2,09	2,03	1,95	1,88
	27	5,63	4,24	3,65	3,31	3,08	2,92	2,80	2,71	2,63	2,57	2,47	2,36	2,25	2,19	2,13	2,07	2,00	1,93	1,85
	28	5,61	4,22	3,63	3,29	3,06	2,90	2,78	2,69	2,61	2,55	2,45	2,34	2,23	2,17	2,11	2,05	1,98	1,91	1,83
	29	5,59	4,20	3,61	3,27	3,04	2,88	2,76	2,67	2,59	2,53	2,43	2,32	2,21	2,15	2,09	2,03	1,96	1,89	1,81
	30	5,57	4,18	3,59	3,25	3,03	2,87	2,75	2,65	2,57	2,51	2,41	2,31	2,20	2,14	2,07	2,01	1,94	1,87	1,79
40	5,42	4,05	3,46	3,13	2,90	2,74	2,62	2,53	2,45	2,39	2,29	2,18	2,07	2,01	1,94	1,88	1,80	1,72	1,64	
60	5,29	3,93	3,34	3,01	2,79	2,63	2,51	2,41	2,33	2,27	2,17	2,06	1,94	1,88	1,82	1,74	1,67	1,58	1,48	
120	5,15	3,80	3,23	2,89	2,67	2,52	2,39	2,30	2,22	2,16	2,05	1,94	1,82	1,76	1,69	1,61	1,53	1,43	1,31	
∞	5,02	3,69	3,12	2,79	2,57	2,41	2,29	2,19	2,11	2,05	1,94	1,83	1,71	1,64	1,57	1,48	1,39	1,27	1,00	



*Les valeurs figurant dans cette table sont les quantiles $F_{0,025; v_1, v_2}$ tels que $P(F > F_{0,025; v_1, v_2}) = 0,025$, où $F \sim F_{v_1, v_2}$.

Table V Les quantiles de la loi de Fisher* (suite)


		$F_{0,05 ; v_1, v_2}$																		
v_2	v_1	Nombre de degrés de liberté du numérateur (v_1)																		
		1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
Nombre de degrés de liberté du dénominateur (v_2)	1	161,4	199,5	215,7	224,6	230,2	234	236,8	238,9	240,5	241,9	243,9	245,9	248,0	249,1	250,1	251,1	252,2	253,3	254,3
	2	18,51	19,00	19,16	19,25	19,30	19,33	19,35	19,37	19,38	19,40	19,41	19,43	19,45	19,45	19,46	19,47	19,48	19,49	19,50
	3	10,13	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79	8,74	8,70	8,66	8,64	8,62	8,59	8,57	8,55	8,53
	4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,91	5,86	5,80	5,77	5,75	5,72	5,69	5,66	5,63
	5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74	4,68	4,62	4,56	4,53	4,50	4,46	4,43	4,40	4,36
	6	5,99	5,14	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06	4,00	3,94	3,87	3,84	3,81	3,77	3,74	3,70	3,67
	7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64	3,57	3,51	3,44	3,41	3,38	3,34	3,30	3,27	3,23
	8	5,32	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,35	3,28	3,22	3,15	3,12	3,08	3,04	3,01	2,97	2,93
	9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14	3,07	3,01	2,94	2,90	2,86	2,83	2,79	2,75	2,71
	10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,98	2,91	2,85	2,77	2,74	2,70	2,66	2,62	2,58	2,54
	11	4,84	3,98	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,85	2,79	2,72	2,65	2,61	2,57	2,53	2,49	2,45	2,40
	12	4,75	3,89	3,49	3,26	3,11	3,00	2,91	2,85	2,80	2,75	2,69	2,62	2,54	2,51	2,47	2,43	2,38	2,34	2,30
	13	4,67	3,81	3,41	3,18	3,03	2,92	2,83	2,77	2,71	2,67	2,60	2,53	2,46	2,42	2,38	2,34	2,30	2,25	2,21
	14	4,60	3,74	3,34	3,11	2,96	2,85	2,76	2,70	2,65	2,60	2,53	2,46	2,39	2,35	2,31	2,27	2,22	2,18	2,13
	15	4,54	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,59	2,54	2,48	2,40	2,33	2,29	2,25	2,20	2,16	2,11	2,07
	16	4,49	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,42	2,35	2,28	2,24	2,19	2,15	2,11	2,06	2,01
	17	4,45	3,59	3,20	2,96	2,81	2,70	2,61	2,55	2,49	2,45	2,38	2,31	2,23	2,19	2,15	2,10	2,06	2,01	1,96
	18	4,41	3,55	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,34	2,27	2,19	2,15	2,11	2,06	2,02	1,97	1,92
Nombre de degrés de liberté du dénominateur (v_2)	19	4,38	3,52	3,13	2,90	2,74	2,63	2,54	2,48	2,42	2,38	2,31	2,23	2,16	2,11	2,07	2,03	1,98	1,93	1,88
	20	4,35	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,39	2,35	2,28	2,20	2,12	2,08	2,04	1,99	1,95	1,90	1,84
	21	4,32	3,47	3,07	2,84	2,68	2,57	2,49	2,42	2,37	2,32	2,25	2,18	2,10	2,05	2,01	1,96	1,92	1,87	1,81
	22	4,30	3,44	3,05	2,82	2,66	2,55	2,46	2,40	2,34	2,30	2,23	2,15	2,07	2,03	1,98	1,94	1,89	1,84	1,78
	23	4,28	3,42	3,03	2,80	2,64	2,53	2,44	2,37	2,32	2,27	2,20	2,13	2,05	2,01	1,96	1,91	1,86	1,81	1,76
	24	4,26	3,40	3,01	2,78	2,62	2,51	2,42	2,36	2,30	2,25	2,18	2,11	2,03	1,98	1,94	1,89	1,84	1,79	1,73
	25	4,24	3,39	2,99	2,76	2,60	2,49	2,40	2,34	2,28	2,24	2,16	2,09	2,01	1,96	1,92	1,87	1,82	1,77	1,71
	26	4,23	3,37	2,98	2,74	2,59	2,47	2,39	2,32	2,27	2,22	2,15	2,07	1,99	1,95	1,90	1,85	1,80	1,75	1,69
	27	4,21	3,35	2,96	2,73	2,57	2,46	2,37	2,31	2,25	2,20	2,13	2,06	1,97	1,93	1,88	1,84	1,79	1,73	1,67
	28	4,20	3,34	2,95	2,71	2,56	2,45	2,36	2,29	2,24	2,19	2,12	2,04	1,96	1,91	1,87	1,82	1,77	1,71	1,65
	29	4,18	3,33	2,93	2,70	2,55	2,43	2,35	2,28	2,22	2,18	2,10	2,03	1,94	1,90	1,85	1,81	1,75	1,70	1,64
	30	4,17	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,21	2,16	2,09	2,01	1,93	1,89	1,84	1,79	1,74	1,68	1,62
	40	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,12	2,08	2,00	1,92	1,84	1,79	1,74	1,69	1,64	1,58	1,51
	60	4,00	3,15	2,76	2,53	2,37	2,25	2,17	2,10	2,04	1,99	1,92	1,84	1,75	1,70	1,65	1,59	1,53	1,47	1,39
	120	3,92	3,07	2,68	2,45	2,29	2,17	2,09	2,02	1,96	1,91	1,83	1,75	1,66	1,61	1,55	1,55	1,43	1,35	1,25
	∞	3,84	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,88	1,83	1,75	1,67	1,57	1,52	1,46	1,39	1,32	1,22	1,00



*Les valeurs figurant dans cette table sont les quantiles $F_{0,05 ; v_1, v_2}$ tels que $P(F > F_{0,05 ; v_1, v_2}) = 0,05$, où $F \sim F_{v_1, v_2}$.

Table V Les quantiles de la loi de Fisher* (suite)

		$F_{0,10; v_1, v_2}$																		
v_2	v_1	Nombre de degrés de liberté du numérateur (v_1)																		
		1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
Nombre de degrés de liberté du dénominateur (v_2)	1	39,86	49,5	53,59	55,83	57,24	58,2	58,91	59,44	59,86	60,19	60,71	61,22	61,74	62,00	62,26	62,53	62,79	63,06	63,33
	2	8,53	9,00	9,16	9,24	9,29	9,33	9,35	9,37	9,38	9,39	9,41	9,42	9,44	9,45	9,46	9,47	9,47	9,48	9,49
	3	5,54	5,46	5,39	5,34	5,31	5,28	5,27	5,25	5,24	5,23	5,22	5,20	5,18	5,18	5,17	5,16	5,15	5,14	5,13
	4	4,54	4,32	4,19	4,11	4,05	4,01	3,98	3,95	3,94	3,92	3,9	3,87	3,84	3,83	3,82	3,8	3,79	3,78	3,76
	5	4,06	3,78	3,62	3,52	3,45	3,40	3,37	3,34	3,32	3,30	3,27	3,24	3,21	3,19	3,17	3,16	3,14	3,12	3,10
	6	3,78	3,46	3,29	3,18	3,11	3,05	3,01	2,98	2,96	2,94	2,90	2,87	2,84	2,82	2,80	2,78	2,76	2,74	2,72
	7	3,59	3,26	3,07	2,96	2,88	2,83	2,78	2,75	2,72	2,7	2,67	2,63	2,59	2,58	2,56	2,54	2,51	2,49	2,47
	8	3,46	3,11	2,92	2,81	2,73	2,67	2,62	2,59	2,56	2,54	2,50	2,46	2,42	2,40	2,38	2,36	2,34	2,32	2,29
	9	3,36	3,01	2,81	2,69	2,61	2,55	2,51	2,47	2,44	2,42	2,38	2,34	2,30	2,28	2,25	2,23	2,21	2,18	2,16
	10	3,29	2,92	2,73	2,61	2,52	2,46	2,41	2,38	2,35	2,32	2,28	2,24	2,20	2,18	2,16	2,13	2,11	2,08	2,06
	11	3,23	2,86	2,66	2,54	2,45	2,39	2,34	2,30	2,27	2,25	2,21	2,17	2,12	2,10	2,08	2,05	2,03	2,00	1,97
	12	3,18	2,81	2,61	2,48	2,39	2,33	2,28	2,24	2,21	2,19	2,15	2,10	2,06	2,04	2,01	1,99	1,96	1,93	1,90
	13	3,14	2,76	2,56	2,43	2,35	2,28	2,23	2,20	2,16	2,14	2,10	2,05	2,01	1,98	1,96	1,93	1,90	1,88	1,85
	14	3,10	2,73	2,52	2,39	2,31	2,24	2,19	2,15	2,12	2,1	2,05	2,01	1,96	1,94	1,91	1,89	1,86	1,83	1,80
	15	3,07	2,70	2,49	2,36	2,27	2,21	2,16	2,12	2,09	2,06	2,02	1,97	1,92	1,90	1,87	1,85	1,82	1,79	1,76
	16	3,05	2,67	2,46	2,33	2,24	2,18	2,13	2,09	2,06	2,03	1,99	1,94	1,89	1,87	1,84	1,81	1,78	1,75	1,72
	17	3,03	2,64	2,44	2,31	2,22	2,15	2,10	2,06	2,03	2,00	1,96	1,91	1,86	1,84	1,81	1,78	1,75	1,72	1,69
	18	3,01	2,62	2,42	2,29	2,20	2,13	2,08	2,04	2,00	1,98	1,93	1,89	1,84	1,81	1,78	1,75	1,72	1,69	1,66
	19	2,99	2,61	2,40	2,27	2,18	2,11	2,06	2,02	1,98	1,96	1,91	1,86	1,81	1,79	1,76	1,73	1,70	1,67	1,63
	20	2,97	2,59	2,38	2,25	2,16	2,09	2,04	2,00	1,96	1,94	1,89	1,84	1,79	1,77	1,74	1,71	1,68	1,64	1,61
Nombre de degrés de liberté du dénominateur (v_2)	21	2,96	2,57	2,36	2,23	2,14	2,08	2,02	1,98	1,95	1,92	1,87	1,83	1,78	1,75	1,72	1,69	1,66	1,62	1,59
	22	2,95	2,56	2,35	2,22	2,13	2,06	2,01	1,97	1,93	1,90	1,86	1,81	1,76	1,73	1,70	1,67	1,64	1,60	1,57
	23	2,94	2,55	2,34	2,21	2,11	2,05	1,99	1,95	1,92	1,89	1,84	1,80	1,74	1,72	1,69	1,66	1,62	1,59	1,55
	24	2,93	2,54	2,33	2,19	2,10	2,04	1,98	1,94	1,91	1,88	1,83	1,78	1,73	1,70	1,67	1,64	1,61	1,57	1,53
	25	2,92	2,53	2,32	2,18	2,09	2,02	1,97	1,93	1,89	1,87	1,82	1,77	1,72	1,69	1,66	1,63	1,59	1,56	1,52
	26	2,91	2,52	2,31	2,17	2,08	2,01	1,96	1,92	1,88	1,86	1,81	1,76	1,71	1,68	1,65	1,61	1,58	1,54	1,50
	27	2,90	2,51	2,30	2,17	2,07	2,00	1,95	1,91	1,87	1,85	1,80	1,75	1,70	1,67	1,64	1,60	1,57	1,53	1,49
	28	2,89	2,50	2,29	2,16	2,06	2,00	1,94	1,90	1,87	1,84	1,79	1,74	1,69	1,66	1,63	1,59	1,56	1,52	1,48
	29	2,89	2,50	2,28	2,15	2,06	1,99	1,93	1,89	1,86	1,83	1,78	1,73	1,68	1,65	1,62	1,58	1,55	1,51	1,47
	30	2,88	2,49	2,28	2,14	2,03	1,98	1,93	1,88	1,85	1,82	1,77	1,72	1,67	1,64	1,61	1,57	1,54	1,50	1,46
	40	2,84	2,44	2,23	2,09	2,00	1,93	1,87	1,83	1,79	1,76	1,71	1,66	1,61	1,57	1,54	1,51	1,47	1,42	1,38
	60	2,79	2,39	2,18	2,04	1,95	1,87	1,82	1,77	1,74	1,71	1,66	1,60	1,54	1,51	1,48	1,44	1,40	1,35	1,29
	120	2,75	2,35	2,13	1,99	1,90	1,82	1,77	1,72	1,68	1,65	1,60	1,55	1,48	1,45	1,41	1,37	1,32	1,26	1,19
	∞	2,71	2,30	2,08	1,94	1,85	1,77	1,72	1,67	1,63	1,60	1,55	1,49	1,42	1,38	1,34	1,30	1,24	1,17	1,00




*Les valeurs figurant dans cette table sont les quantiles $F_{0,10; v_1, v_2}$ tels que $P(F > F_{0,10; v_1, v_2}) = 0,10$ où $F \sim F_{v_1, v_2}$.

Table V Les quantiles de la loi de Fisher*

		$F_{0,25; v_1, v_2}$																		
$v_2 \backslash v_1$		Nombre de degrés de liberté du numérateur (v_1)																		
		1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
Nombre de degrés de liberté du dénominateur (v_2)	1	5,83	7,50	8,20	8,58	8,82	8,98	9,1	9,19	9,26	9,32	9,41	9,49	9,58	9,63	9,67	9,71	9,76	9,8	9,85
	2	2,57	3,00	3,15	3,23	3,28	3,31	3,34	3,35	3,37	3,38	3,39	3,41	3,43	3,43	3,44	3,45	3,46	3,47	3,48
	3	2,02	2,28	2,36	2,39	2,41	2,42	2,43	2,44	2,44	2,44	2,45	2,46	2,46	2,46	2,47	2,47	2,47	2,47	2,47
	4	1,81	2,00	2,05	2,06	2,07	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08	2,08
	5	1,69	1,85	1,88	1,89	1,89	1,89	1,89	1,89	1,89	1,89	1,89	1,89	1,88	1,88	1,88	1,88	1,87	1,87	1,87
	6	1,62	1,76	1,78	1,79	1,79	1,78	1,78	1,78	1,77	1,77	1,77	1,76	1,76	1,75	1,75	1,75	1,74	1,74	1,74
	7	1,57	1,70	1,72	1,72	1,71	1,71	1,70	1,70	1,70	1,69	1,68	1,68	1,67	1,67	1,66	1,66	1,65	1,65	1,65
	8	1,54	1,66	1,67	1,66	1,66	1,65	1,64	1,64	1,63	1,63	1,62	1,62	1,61	1,60	1,60	1,59	1,59	1,58	1,58
	9	1,51	1,62	1,63	1,63	1,62	1,61	1,60	1,60	1,59	1,59	1,58	1,57	1,56	1,56	1,55	1,54	1,54	1,53	1,53
	10	1,49	1,60	1,60	1,59	1,59	1,58	1,57	1,56	1,56	1,55	1,54	1,53	1,52	1,52	1,51	1,51	1,50	1,49	1,48
	11	1,47	1,58	1,58	1,57	1,56	1,55	1,54	1,53	1,53	1,52	1,51	1,50	1,49	1,49	1,48	1,47	1,47	1,46	1,45
	12	1,46	1,56	1,56	1,55	1,54	1,53	1,52	1,51	1,51	1,50	1,49	1,48	1,47	1,46	1,45	1,45	1,44	1,43	1,42
	13	1,45	1,55	1,55	1,53	1,52	1,51	1,50	1,49	1,49	1,48	1,47	1,46	1,45	1,44	1,43	1,42	1,42	1,41	1,40
	14	1,44	1,53	1,53	1,52	1,51	1,50	1,49	1,48	1,47	1,46	1,45	1,44	1,43	1,42	1,41	1,41	1,40	1,39	1,38
	15	1,43	1,52	1,52	1,51	1,49	1,48	1,47	1,46	1,46	1,45	1,44	1,43	1,41	1,41	1,40	1,39	1,38	1,37	1,36
	16	1,42	1,51	1,51	1,50	1,48	1,47	1,46	1,45	1,44	1,44	1,43	1,41	1,40	1,39	1,38	1,37	1,36	1,35	1,34
	17	1,42	1,51	1,50	1,49	1,47	1,46	1,45	1,44	1,43	1,43	1,41	1,40	1,39	1,38	1,37	1,36	1,35	1,34	1,33
	18	1,41	1,50	1,49	1,48	1,46	1,45	1,44	1,43	1,42	1,42	1,40	1,39	1,38	1,37	1,36	1,35	1,34	1,33	1,32
	19	1,41	1,49	1,49	1,47	1,46	1,44	1,43	1,42	1,41	1,41	1,40	1,38	1,37	1,36	1,35	1,34	1,33	1,32	1,30
	20	1,40	1,49	1,48	1,47	1,45	1,44	1,43	1,42	1,41	1,40	1,39	1,37	1,36	1,35	1,34	1,33	1,32	1,31	1,29
Nombre de degrés de liberté du dénominateur (v_2)	21	1,40	1,48	1,48	1,46	1,44	1,43	1,42	1,41	1,40	1,39	1,38	1,37	1,35	1,34	1,33	1,32	1,31	1,30	1,28
	22	1,40	1,48	1,47	1,45	1,44	1,42	1,41	1,40	1,39	1,39	1,37	1,36	1,34	1,33	1,32	1,31	1,30	1,29	1,28
	23	1,39	1,47	1,47	1,45	1,43	1,42	1,41	1,40	1,39	1,38	1,37	1,35	1,34	1,33	1,32	1,31	1,30	1,28	1,27
	24	1,39	1,47	1,46	1,44	1,43	1,41	1,40	1,39	1,38	1,38	1,36	1,35	1,33	1,32	1,31	1,30	1,29	1,28	1,26
	25	1,39	1,47	1,46	1,44	1,42	1,41	1,40	1,39	1,38	1,37	1,36	1,34	1,33	1,32	1,31	1,29	1,28	1,27	1,25
	26	1,38	1,46	1,45	1,44	1,42	1,41	1,39	1,38	1,37	1,37	1,35	1,34	1,32	1,31	1,30	1,29	1,28	1,26	1,25
	27	1,38	1,46	1,45	1,43	1,42	1,40	1,39	1,38	1,37	1,36	1,35	1,33	1,32	1,31	1,30	1,28	1,27	1,26	1,24
	28	1,38	1,46	1,45	1,43	1,41	1,40	1,39	1,38	1,37	1,36	1,34	1,33	1,31	1,30	1,29	1,28	1,27	1,25	1,24
	29	1,38	1,45	1,45	1,43	1,41	1,40	1,38	1,37	1,36	1,35	1,34	1,32	1,31	1,30	1,29	1,27	1,26	1,25	1,23
	30	1,38	1,45	1,44	1,42	1,41	1,39	1,38	1,37	1,36	1,35	1,34	1,32	1,30	1,29	1,28	1,27	1,26	1,24	1,23
	40	1,36	1,44	1,42	1,40	1,39	1,37	1,36	1,35	1,34	1,33	1,31	1,30	1,28	1,26	1,25	1,24	1,22	1,21	1,19
	60	1,35	1,42	1,41	1,38	1,37	1,35	1,33	1,32	1,31	1,30	1,29	1,27	1,25	1,24	1,22	1,21	1,19	1,17	1,15
	120	1,34	1,40	1,39	1,37	1,35	1,33	1,31	1,30	1,29	1,28	1,26	1,24	1,22	1,21	1,19	1,18	1,16	1,13	1,10
	∞	1,32	1,39	1,37	1,35	1,33	1,31	1,29	1,28	1,27	1,25	1,24	1,22	1,19	1,18	1,16	1,14	1,12	1,08	1,00

Source : E. S. Pearson et H. O. Hartley, 1966. *Biometrika Tables for Statisticians*. 3^e éd., Cambridge : Cambridge University Press, vol. 1. Adaptation autorisée.



*Les valeurs figurant dans cette table sont les quantiles $F_{0,25; v_1, v_2}$ tels que $P(F > F_{0,25; v_1, v_2}) = 0,25$ où $F \sim F_{v_1, v_2}$.