

Chapitre 4: Modèles de régression pour données binaires

Les modèles vus dans les deux chapitres précédents ne permettent de considérer que les cas où la variable réponse Y_i est continue, puisqu'on supposait que Y_i suivait une loi normale. Cependant, dans plusieurs situations, on a une variable réponse discrète qui ne peut prendre qu'un nombre fini (ou dénombrable) de valeurs possibles. Dans ce chapitre, on s'intéresse au cas où Y_i suit une loi de Bernoulli ou une loi binomiale. Voici quatre exemples:

- Ex 1:** Considérons le jeu de données `quilpie` de la library `GLMsData` du logiciel R. Ce jeu de données contient des observations de 1921 à 1988 de la quantité de pluie mesurée durant le mois de juillet à Quilpie en Australie. Le jeu de données contient des variables explicatives qui concernent la pression atmosphérique. La variable réponse ne peut prendre que 2 valeurs: 1 si la quantité de pluie mesurée est supérieure à 10 millimètres et 0 sinon.
- Ex 2:** Considérons le jeu de données `nminer` de la library `GLMsData` du logiciel R. Ce jeu de données contient 31 observations de 9 variables. La variable réponse `Mminers` ne peut prendre que 2 valeurs: 1 si un mineur bruyant est détecté dans la parcelle de terre et 0 sinon.
- Ex 3:** Considérons le jeu de données `deposit` de la library `GLMsData` du logiciel R. Ce jeu de données contient 18 observations avec deux variables explicatives : type (A , B ou C) et dose d'insecticide. La variable réponse Y_i est le nombre d'insectes tués parmi les m_i insectes vivants au début de l'expérience.
- Ex 4:** Considérons le jeu de données `turbines` de la library `GLMsData` du logiciel R. Ce jeu de données contient 11 observations avec une variable explicative : nombre d'heures de fonctionnement. La variable réponse Y_i est le nombre machines qui présentent des fissures parmi les m_i machines neuves au début de l'expérience.

1 Données et modèle

1.1 Données Binaires

Dans les deux premiers exemples, la variable réponse Y_i ne peut prendre que deux valeurs possibles: 0 et 1. Les données sont donc sous la forme

$\{(Y_i, X_i), i = 1, \dots, n\}$; où n est nombre d'observations, $Y_i \in \{0, 1\}$ est la variable réponse et $X_i = (X_{i1}, \dots, X_{ip})^\top$ est l'ensemble des variables explicatives pour l'observation i . On dit que Y_i suit une loi de Bernoulli avec un paramètre $\pi_i \in [0, 1]$. On pose alors $P(Y_i = 1) = \pi_i$ et $P(Y_i = 0) = 1 - P(Y_i = 1) = 1 - \pi_i$ et on a

$$\begin{aligned} P(Y_i = y_i) &= \pi_i^{y_i} (1 - \pi_i)^{1-y_i}, \quad y_i \in \{0, 1\} \\ E[Y_i] &= \mu_i = \pi_i \\ Var[Y_i] &= \sigma_i^2 = \pi_i(1 - \pi_i). \end{aligned}$$

D'autres part, on pose $\eta_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}, i = 1, \dots, n$. Ici p est le nombre de variables explicatives considérées et $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ est un vecteur de $p + 1$ coefficient de régression. à estimer à parti des données. Finalement, on a $\eta_i = g(\pi_i)$; où $g(\cdot)$ est une fonction de lien, supposée connue. La fonction de lien la plus populaire est

$$g(u) = \text{logit}(u) = \log \left(\frac{u}{1-u} \right).$$

Avec cette fonction de lien, on a

$$\pi_i = P(Y_i = 1) = \frac{e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}}{1 + e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}}.$$

Et donc, si $\beta_j > 0$, une hausse de X_{ij} avec toutes les autres variables explicatives maintenues constantes augmentera la probabilité $P(Y_i = 1)$. Si $\beta_j < 0$, une hausse de X_{ij} avec toutes les autres variables explicatives maintenues constantes diminuera la probabilité $P(Y_i = 1)$. Finalement, si $\beta_j = 0$, alors X_{ij} n'a pas d'effets sur la probabilité $P(Y_i = 1)$.

1.2 Données groupées

Dans les deux derniers exemples, la variable réponse Y_i peut prendre n'importe quelle valeur dans l'ensemble $\{0, 1, \dots, m_i\}$, où m_i est un entier connu à l'avance et qui varie d'une observation à une autre. 'A toute fin pratique, m_i peut être considéré comme un nombre total d'expériences indépendantes ayant deux résultats possibles (succès ou échec) et Y_i est interprété comme le nombre de succès parmi les m_i expériences. Les données sont donc sous la forme $\{(Y_i, m_i, X_i), i = 1, \dots, n\}$. On dit que Y_i suit une loi Binomiale de

paramètres m_i et $\pi_i \in [0, 1]$ et on écrit $Y_i \sim \text{Bin}(m_i, \pi_i)$. Selon cette loi, on a:

$$\begin{aligned} P(Y_i = y_i) &= \binom{m_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{m_i - y_i}, \quad y_i \in \{0, 1, \dots, m_i\} \\ E[Y_i] &= \mu_i = m_i \pi_i \\ \text{Var}[Y_i] &= \sigma_i^2 = m_i \pi_i (1 - \pi_i). \end{aligned}$$

Pour relier la variable réponse aux variables explicative, on pose $\eta_i = g(\pi_i)$, $i = 1, \dots, n$. Ce choix est motivé par le fait que π_i doit appartenir à l'intervalle $[0, 1]$.

Si on a $m_1 = m_2 = \dots = m_n = 1$, on retrouve la loi de Bernoulli des deux premiers exemples. La loi de Bernoulli est un cas particulier de la loi binomiale. Dans la suite de ce chapitre, on se contentera de présenter les développements pour la loi binomiale.

2 Inférence statistique

2.1 Estimation des paramètres β

Le vecteur des paramètres du modèle est $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$. La fonction de log-vraisemblance est

$$\begin{aligned} \sum_{i=1}^n \log [P(Y_i = y_i)] &= \sum_{i=1}^n \log \left[\binom{m_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{m_i - y_i} \right] \\ &= \sum_{i=1}^n \left\{ \log \left[\binom{m_i}{y_i} \right] + y_i \log(\pi_i) + (m_i - y_i) \log(1 - \pi_i) \right\}. \end{aligned}$$

Cette fonction dépend du vecteur de paramètres β à travers π_i , puisqu'on a

$$\pi_i = g^{-1}(\eta_i) = g^{-1}(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}).$$

En remplaçant π_i par μ_i/m_i dans l'expression précédente, on montre que cette fonction log-vraisemblance est égale à

$$l(\beta; y, \mu) = \sum_{i=1}^n \{y_i \log(\mu_i) + (m_i - y_i) \log(m_i - \mu_i)\} + K$$

où

$$K = \sum_{i=1}^n \left\{ \log \left[\binom{m_i}{y_i} \right] - m_i \log(m_i) \right\}$$

est une constante qui ne dépend pas de β . L'estimateur de maximum de vraisemblance de β , disons $\hat{\beta}$, est la valeur de β qui maximise $l(\beta; y, \mu)$. On calcule par la suite la matrice d'information de Fisher I . L'élément à la position (j, k) de la matrice I est égal à

$$-\frac{\partial^2 l(\beta; y, \mu)}{\partial \beta_j \partial \beta_k}$$

évaluée à $\beta = \hat{\beta}$. La matrice de variance-covariance de $\hat{\beta}$ est alors estimée par $v(\hat{\beta}) = I^{-1}$. Par la théorie générale de l'estimation par maximum de vraisemblance, la distribution asymptotique de $\hat{\beta}$ est approximée par la loi normale multivariée $\mathcal{N}\{\beta, v(\hat{\beta})\}$.

On montre que $v(\hat{\beta}) = (X^\top W X)^{-1}$ où X est une matrice $n \times (p+1)$ contenant les variables explicatives, incluant l'intercepte et W est une matrice diagonale de taille n avec les entrées $w_i = \hat{\mu}_i(m_i - \hat{\mu}_i)/m_i, i = 1, \dots, n$ sur la diagonale. Ici, on a

$$\hat{\mu}_i = m_i \hat{\pi}_i = m_i g^{-1}(\hat{\eta}_i) = m_i g^{-1}(\hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip})$$

2.2 Inférence statistique concernant les β_j

Les intervalles de confiances et les tests d'hypothèses concernant les β_j sont obtenus par la méthode de Wald.

Ainsi, un intervalle de confiance à $100 \times (1 - \alpha)\%$ pour β_j est donné par

$$[\hat{\beta}_j - z_{\alpha/2} \sqrt{v(\hat{\beta}_j)}; \hat{\beta}_j + z_{\alpha/2} \sqrt{v(\hat{\beta}_j)}],$$

où z_γ est le quantile de la loi normale standard défini par $P(Z > z_\gamma) = \gamma$, $\gamma \in (0, 1)$, $Z \sim \mathcal{N}(0, 1)$ et $v(\hat{\beta}_j)$ est l'élément $(j+1, j+1)$ de la matrice $v(\hat{\beta})$, $j = 0, 1, \dots, p$.

Considérant maintenant le test d'hypothèse $H_0 : \beta_j = 0$ versus $H_1 : \beta_j \neq 0$.

On rejette H_0 au seuil α si $|z_{obs}| > z_{\alpha/2}$, avec $z_{obs} = \hat{\beta}_j / \sqrt{v(\hat{\beta}_j)}$. Le seuil observé (p -valeur ou p -value) est $\alpha^* = P(|Z| > |z_{obs}|) = 2P(Z > |z_{obs}|)$, $Z \sim \mathcal{N}(0, 1)$.

2.3 Déviance

Considérons maintenant un modèle, dit saturé, avec n paramètres $\{\tilde{\mu}_1, \dots, \tilde{\mu}_n\}$ et sans variables explicatives. Sous ce modèle, on a

$$P(Y_i = y_i) = \binom{m_i}{y_i} \frac{\tilde{\mu}_i^{y_i} (m_i - \tilde{\mu}_i)^{m_i - y_i}}{m_i^{m_i}}$$

et on montre que les estimateurs de maximum de vraisemblance de $\{\tilde{\mu}_1, \dots, \tilde{\mu}_n\}$ sont $\{y_1, \dots, y_n\}$. La statistique de test de rapport de vraisemblance entre ce modèle saturé et celui considéré dans les sections précédentes est

$$D = 2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) + (m_i - y_i) \log \left(\frac{m_i - y_i}{m_i - \hat{\mu}_i} \right) \right\} = 2 \sum_{i=1}^n d_i.$$

Cette statistique de test est appelée la déviance du modèle. Elle joue le même rôle que la somme des carrés des résidus pour la régression linéaire. La déviance est utilisée pour évaluer l'ajustement et adéquation du modèle et effectuer des tests d'hypothèses.