

Chapitre 5: Modèles linéaires généralisés

Jusqu'à maintenant, on a vu la régression linéaire (Chapitre 2 et 3) et la régression logistique (Chapitre 4). On constate que plusieurs concepts comme l'inférence statistique concernant les coefficients de régression β , la sélection de modèles et la détection sont identiques pour les deux situations, même si chaque modèle peut avoir des particularités qui requièrent des procédures spécifiques comme la courbe ROC pour la régression linéaire. Dans ce chapitre, on considère une présentation unifiée pour ces modèles. On suppose que la variable réponse Y_i suit une distribution qui appartient à la famille exponentielle qui inclut la loi normale, la loi de Bernoulli et la loi binomiale.

1 Famille exponentielle

1.1 Définition et exemples

Cette famille de lois contient la vaste majorité des lois couramment utilisées en pratique. On dit que la distribution de la variable aléatoire Y appartient à la famille exponentielle si la fonction de probabilité de Y s'écrit sous la forme:

$$f_Y(y) = a(y, \phi) \exp \left\{ \frac{y\theta - b(\theta)}{\phi} \right\}.$$

Ici, $f_Y(y)$ est la fonction de densité si Y est continue et la fonction de masse $P(Y = y)$ si Y est discrète.

La distribution est paramétrée avec deux paramètres: le paramètre canonique θ et le paramètre de dispersion ϕ . On montre que $E[Y] = \mu b'(\theta)$, où $b'(u) = db(u)/du$ est la dérivée de $b(u)$ par rapport à u . Par conséquent, le paramètre canonique est directement lié à l'espérance de Y . On montre aussi que $Var(Y) = \phi b''(\theta)$, où $b''(u) = d^2b(u)/du^2$ est la dérivée seconde de $b(u)$ par rapport à u . On en déduit que $Var[Y] = \phi V(\mu)$, avec $V(u) = b''[b'^{-1}(u)]$. Le paramètre de dispersion ϕ modélise donc la variance de Y .

Les distributions de la famille exponentielle possèdent, en général, deux paramètres θ et ϕ . Cependant, pour certaines distributions, le paramètre de dispersion est fixé à 1 et on a ainsi un seul paramètre.

Voici quelques exemples de ces distributions:

- **Loi normale:** Soit $Y \sim \mathcal{N}(\mu, \sigma^2)$. La fonction de densité de Y s'écrit:

$$\begin{aligned} F_Y(y) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y-\mu)^2}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ \frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} \right\} \end{aligned}$$

Cette fonction de densité est un cas particulier d'une fonction de probabilité d'une loi appartenant à la famille exponentielle avec $\theta = \mu$, $\phi = \sigma^2$,

$$a(\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{y^2}{2\sigma^2} \right\}$$

et $b(\theta) = \theta^2/2$. Plus encore, on a $E(Y) = b'(\theta) = \theta = \mu$ et $Var(Y) = \phi b''(\theta) = \sigma^2$ puisque $b''(u) = 1$. On en déduit que $V(\mu) = 1$.

- **Loi binomiale:** Soit $Y \sim \text{Bin}(m, \pi)$. On a alors pour $y = 0, 1, \dots, m$:

$$\begin{aligned} P(Y = y) &= \binom{m}{y} \pi^y (1 - \pi)^{m-y} \\ &= \binom{m}{y} \left(\frac{\pi}{1 - \pi} \right)^y (1 - \pi)^m \\ &= \binom{m}{y} \exp \left\{ y \log \left(\frac{\pi}{1 - \pi} \right) + m \log(1 - \pi) \right\} \end{aligned}$$

On reconnaît la fonction de probabilité d'une famille exponentielle avec:

$$\begin{aligned} \theta &= \log \left\{ \frac{\pi}{1 - \pi} \right\} \\ \pi &= \frac{e^\theta}{1 + e^\theta} \\ \phi &= 1 \\ a(y, \phi) &= \binom{m}{y} \\ b(\theta) &= -m \log(1 - \pi) = m \log(1 + e^\theta). \end{aligned}$$

On en déduit que $E[Y] = b'(\theta) = me^\theta/(1 + e^\theta) = m\pi$, $Var[Y] = \phi b''(\theta) = me^\theta/(1 + e^\theta)^2 = m\pi(1 - \pi)$ et $V(\mu) = \mu(m - \mu)/m$.

- **Loi de Poisson:** Soit $Y \sim \text{Poisson}(\lambda)$. On a alors pour $y = 0, 1, \dots$, on a

$$P(Y = y) = e^{-\lambda} \frac{\lambda^y}{y!} = \frac{1}{y!} \exp \{y \log(\lambda) - \lambda\}.$$

On reconnaît la fonction de probabilité d'une famille exponentielle avec: $\theta = \log(\lambda)$, $\phi = 1$, $a(y, \phi) = 1/y!$ et $b(\theta) = \lambda = e^\theta$. On en déduit que $E[Y] = b'(\theta) = e^\theta = \lambda = \mu$, $\text{Var}[Y] = \phi b''(\theta) = e^\theta = \lambda = \mu$ et $V(\mu) = \mu$.

- **Loi Gamma:** Soit $Y \sim \text{Gamma}(\alpha, \beta)$. La fonction de densité de Y est donnée par

$$f_Y(y) = \begin{cases} \frac{y^{\alpha-1} e^{-y/\beta}}{\Gamma(\alpha) \beta^\alpha} & \text{si } y \geq 0 \\ 0 & \text{si } y < 0 \end{cases}$$

où $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$. Avec cette paramétrisation, on a $E[Y] = \alpha\beta$ et $\text{Var}[Y] = \alpha\beta^2$. Pour montrer que la loi Gamma appartient à la famille exponentielle, on reparamétrise la fonction de densité comme suit. On pose $\mu = \alpha\beta$ et $\phi = 1/\alpha$ et on obtient

$$\begin{aligned} f_Y(y) &= \left(\frac{y}{\phi\mu}\right)^{1/\phi} \frac{1}{y} \frac{1}{\Gamma(1/\phi)} \exp\left\{-\frac{y}{\phi\mu}\right\} \\ &= \left(\frac{y}{\mu}\right)^{1/\phi} \frac{1}{y} \frac{1}{\Gamma(1/\phi)} \exp\left\{-\frac{y}{\phi\mu} - \frac{\log(\mu)}{\phi}\right\}. \end{aligned}$$

On reconnaît la fonction de probabilité d'une famille exponentielle avec:

$$\begin{aligned} \theta &= -1/\mu \\ a(y, \phi) &= \left(\frac{y}{\mu}\right)^{1/\phi} \frac{1}{y} \frac{1}{\Gamma(1/\phi)} \\ b(\theta) &= \log(\mu) = \log(-1/\theta) = -\log(-\theta) \end{aligned}$$

On en déduit que $E[Y] = b'(\theta) = -1/\theta = \mu$, $\text{Var}[Y] = \phi b''(\theta) = \phi/\theta^2 = \phi\mu^2$ et $V(\mu) = \mu^2$.

1.2 Déviance

Soit Y une variable aléatoire qui suit une distribution appartenant à la famille exponentielle. On pose $t(y, \mu) = y\theta - b(\theta)$ et $d(y, \mu) = 2\{t(y, y) - t(y, \mu)\}$.

On a alors

$$\begin{aligned}\frac{\partial d(y, \mu)}{\partial \theta} &= -\{y - b'(\theta)\} \\ \frac{\partial^2 d(y, \mu)}{\partial \theta^2} &= b''(\theta) = V(\mu) > 0\end{aligned}$$

On en déduit que $\partial d(y, \mu)/\partial \theta$ est égale à 0 lorsque $\mu = y$. Par conséquent, $d(y, \mu)$ est toujours positive et ne s'annule que lorsque $\mu = y$.

Pour la loi normale $\mathcal{N}(\mu, \sigma^2)$, on a $t(y, \mu) = y\mu - \mu^2/2$ et $d(y, \mu) = (y - \mu)^2$. À la table 5.1 du livre *Generalized linear models with examples in R*, on trouve les expressions de $d(y, \mu)$ pour plusieurs distributions usuelles.

On montre que lorsque Y suit une distribution appartenant à la famille exponentielle, $d(Y, \mu)/\phi$ suit approximativement une distribution de Khi-deux à 1 degré de liberté χ_1^2 . Supposons maintenant qu'on a un ensemble de variables aléatoires indépendantes $\{Y_1, \dots, Y_n\}$ qui suivent une distribution appartenant à la famille exponentielle. On suppose que pour $i = 1, \dots, n$, les paramètres de la distributions de Y_i sont (μ_i, ϕ) . Ainsi, chaque variable aléatoire possède son propre paramètre canonique mais le paramètre de dispersion ϕ est commun à l'ensemble des variables. La déviance et la déviance standardisée de $\{Y_1, \dots, Y_n\}$ sont définies respectivement par $D(y, \mu) = \sum_{i=1}^n d(y_i, \mu_i)$ et $D^*(y, \mu) = D(y, \mu)/\phi$. On en déduit que $D^*(y, \mu)$ suit approximativement une distribution de Khi-deux à n degrés de liberté χ_n^2 .

2 Modèles linéaires généralisés

2.1 Données et modèle

Considérons les données $\Delta = \{(Y_i, X_i), i = 1, \dots, n\}$. Pour $i = 1, \dots, n$, Y_i est la variable réponse et $X_i = (X_{i1}, \dots, X_{ip})^\top$ est un ensemble de p variables explicatives pour l'observation i . Un modèle linéaire généralisé est composé de 3 composantes:

- **Composante aléatoire:** On spécifie une distribution pour Y_i . Explicitement, on suppose que Y_i suit une distribution qui appartient à la famille exponentielle et que les paramètres de cette distribution sont θ_i et ϕ . Encore une fois, On suppose que chaque observation possède son propre paramètre canonique θ_i mais que le paramètre de dispersion ϕ est commun à l'ensemble des variables. Ainsi, on a $E[Y_i] = \mu_i = b'(\theta_i)$ et $Var[Y_i] = \phi b''(\theta_i) = \phi V(\mu_i)$.

- **Composante systématique:** On spécifie une composante systématique $\eta_i = f_\beta(X_{i1}, \dots, X_{ip})$ où f_β est une fonction connue paramétrée par un ensemble de paramètres β . La composante systématique la plus populaire prend la forme linéaire $\eta_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip}$.
- **Fonction de lien:** La fonction de lien relie la composante aléatoire à la composante systématique $g(\mu_i) = \eta_i$. On en déduit que $\eta_i = g[b'(\theta_i)]$. La fonction de lien $g(\cdot)$ est dite fonction de lien *canonique* si $g[b'(u)] = u, \forall u \in \Re$, autrement dit, si elle assure que $\eta_i = \theta_i$.

Les paramètres du modèle considéré sont β et ϕ .

2.2 Estimation des paramètres

La fonction log-vraisemblance des données $\Delta = \{(Y_i, X_i), i = 1, \dots, n\}$ s'écrit:

$$\begin{aligned}
l(\beta, \phi | \Delta) &= \sum_{i=1}^n \log [f_Y(y_i)] \\
&= \sum_{i=1}^n \left\{ \log [a(y_i, \phi)] + \frac{y_i \theta_i - b(\theta_i)}{\phi} \right\} \\
&= \sum_{i=1}^n \log [a(y_i, \phi)] + \frac{1}{\phi} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] \\
&= l_1(\phi) + \frac{1}{\phi} l_2(\beta),
\end{aligned}$$

où $l_1(\phi) = \sum_{i=1}^n \log [a(y_i, \phi)]$ et $l_2(\beta) = \sum_{i=1}^n [y_i \theta_i - b(\theta_i)]$

On calcule $\hat{\beta}$ l'estimateur de maximum de vraisemblance $\hat{\beta}$ en maximisant $l_2(\beta)$. On montre que la distribution asymptotique de cet estimateur est

$$\hat{\beta} \sim \mathcal{N} \{ \beta, \phi (X^\top W X)^{-1} \},$$

où $W = \text{diag}\{W_1, W_2, \dots, W_n\}$ est une matrice diagonale de dimension n ,

$$W_i = \frac{1}{V(\hat{\mu}_i) [g'(\hat{\mu}_i)]^2},$$

et $\hat{\mu}_i = g^{-1}(\hat{\eta}_i)$ et $\hat{\eta}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip}$ sont les valeurs prédites pour μ_i et η_i , respectivement.

Si ϕ est fixé, comme c'est le cas pour la régression logistique ou la régression Poisson, alors la procédure d'estimation s'arrête ici.

Si ϕ est inconnu, comme c'est le cas pour la régression linéaire avec une distribution normale ou Gamma, alors on doit l'estimer. L'estimateur de maximum de vraisemblance de ϕ est obtenu en maximisant $l_1(\phi) + l_2(\hat{\beta})/\phi$. Cependant, l'estimateur obtenu est biaisé pour les petites tailles d'échantillon. C'est pour cette raison qu'on lui préfère des estimateurs obtenus par la méthode des moments.

À cette fin, on calcule les statistiques

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)}$$

et

$$D(y, \hat{\mu}).$$

On montre que X^2/ϕ et $D(y, \hat{\mu})/\phi$ sont approximativement distribuées selon $\chi^2_{n-(p+1)}$. On en déduit les estimateurs de Pearson et déviance définis respectivement par

$$\tilde{\phi}_P = \frac{X^2}{n - (p + 1)}$$

et

$$\tilde{\phi}_D = \frac{D(y, \hat{\mu})}{n - (p + 1)}.$$

Les deux estimateurs $\tilde{\phi}_P$ et $\tilde{\phi}_D$ sont faciles à calculer et possèdent de bonnes propriétés théoriques. L'estimateur Pearson possède un biais négligeable et est robuste lorsque la distribution est mal spécifiée. C'est l'estimateur par défaut de la fonction `glm` du logiciel R. L'estimateur déviance possède une faible variance. Cependant, cet estimateur peut être sensible lorsque certaines valeurs de y sont proches des limites de leur support. C'est pour cette raison que $\tilde{\phi}_P$ est plus populaire.

2.3 Inférence statistique avec ϕ fixé

Si ϕ est fixé, comme c'est le cas pour la régression logistique ou la régression Poisson, alors un intervalle de confiance à $(1 - \alpha)100\%$ pour β_j est construit comme suit:

$$\left[\hat{\beta}_j - z_{\alpha/2} \sqrt{\phi v_j}, \hat{\beta}_j + z_{\alpha/2} \sqrt{\phi v_j} \right],$$

où v_j est $(j + 1)^{\text{ème}}$ élément de la diagonale de la matrice $(X^\top W X)^{-1}$, $j = 0, 1, \dots, p$.

Considérons maintenant une observation future $X^* = (1, X_1^*, X_2^*, \dots, X_p^*)^\top$ et posons $\eta^* = \beta_0 + \beta_1 X_1^* + \dots + \beta_p X_p^* = X^{*\top} \beta$ et $\mu^* = g^{-1}(\eta^*)$. La valeur

prédite de μ pour cette observation est $\hat{\mu}^* = g^{-1}(\hat{\eta}^*)$, où $\hat{\eta}^* = X^{*\top} \hat{\beta}$. On alors $Var[\hat{\eta}^*] = X^{*\top} Var[\hat{\beta}] X^* = \phi X^{*\top} (X^\top W X)^{-1} X^*$.

Des intervalles de confiance à $(1 - \alpha)100\%$ pour η^* et μ^* sont donc donnés par

$$\left[X^{*\top} \hat{\beta} - z_{\alpha/2} \sqrt{\phi X^{*\top} (X^\top W X)^{-1} X^*}, X^{*\top} \hat{\beta} + z_{\alpha/2} \sqrt{\phi X^{*\top} (X^\top W X)^{-1} X^*} \right]$$

et

$$\left[g^{-1} \left(X^{*\top} \hat{\beta} - z_{\alpha/2} \sqrt{\phi X^{*\top} (X^\top W X)^{-1} X^*} \right), g^{-1} \left(X^{*\top} \hat{\beta} + z_{\alpha/2} \sqrt{\phi X^{*\top} (X^\top W X)^{-1} X^*} \right) \right],$$

respectivement.

Supposons maintenant que l'on veuille comparer deux modèles emboîtés: un modèle réduit A et un modèle complet B . On construit la statistique de test

$$X_{obs} = \frac{D_A(y, \hat{\mu}) - D_B(y, \hat{\mu})}{\phi}.$$

Cette statistique suit une loi de Khi-deux à d degrés de liberté lorsque le modèle réduit est vrai. Ici, d est la différence entre les nombres de paramètres entre les deux modèles. On rejette au seuil α l'hypothèse que le modèle réduit est valide si $X_{obs} > \chi_{d,\alpha}^2$. Le seuil observé est $\alpha^* = P(\chi_d^2 > X_{obs})$.

2.4 Inférence statistique avec ϕ inconnu

Lorsque le paramètre ϕ est inconnu, on le remplace par son estimateur $\tilde{\phi}_P$. En faisant cette modification, on doit aussi remplacer les quantiles de la loi normale standard $\mathcal{N}(0, 1)$ par les quantiles d'une loi t de Student à $n - (p + 1)$ degrés de liberté dans les expressions des bornes des intervalles de confiance de β_j , η^* et μ^* . Par exemple, l'intervalle de confiance pour β_j devient

$$\left[\hat{\beta}_j - t_{\alpha/2, n-(p+1)} \sqrt{\tilde{\phi}_P v_j}, \hat{\beta}_j + t_{\alpha/2, n-(p+1)} \sqrt{\tilde{\phi}_P v_j} \right],$$

De la même manière, l'expression de X_{obs} pour comparer deux modèles emboîtés devient

$$X_{obs} = \frac{\{D_A(y, \hat{\mu}) - D_B(y, \hat{\mu})\}/d}{\tilde{\phi}_P}.$$

La distribution de X_{obs} lorsque le modèle réduit est valide devient $F_{d, n-(p+1)}$. On rejette au seuil α l'hypothèse que le modèle réduit est valide si $X_{obs} > F_{d, n-(p+1), \alpha}$. Le seuil observé devient $\alpha^* = P[F_{d, n-(p+1)} > X_{obs}]$.

3 Sélection et validation de modèles

Les principes des procédures pas à pas *backward*, *forward* et *stepwise* vues pour la régression linéaire et régression logistique demeurent valides pour n'importe quel modèle linéaire généralisé. Ces modèles se basent sur le *AIC* et le *BIC* définis par:

$$\begin{aligned} AIC &= -2l(\hat{\beta}, \tilde{\phi}_P | \Delta) + 2(p + 1) \\ BIC &= -2l(\hat{\beta}, \tilde{\phi}_P | \Delta) + \log(n)(p + 1) \end{aligned}$$

Pareillement, les outils de validation de modèles et de détection d'observations aberrantes et influentes tels que les résidus, les DFBETAS et les DFFITS vus dans les chapitres précédents dans le cadre de régression linéaire et/ou régression logistique restent valides pour l'ensemble des modèles linéaires généralisés.

4 Exemple: régression Poisson

Considérons les données $\Delta = \{(Y_i, X_i), i = 1 \dots, n\}$. La variable réponse Y_i dénote un dénombrement. Par exemple, Y_i peut être le nombre de nouveaux cas d'une maladie dans une ville durant une année ou le nombre d'absences d'un élève durant la session. Par conséquent, on suppose que $Y_i \in \mathbb{N}$. D'autre part, $X_i = (X_{i1}, X_{i2}, \dots, X_{ip})^\top$ est un ensemble de p variables explicatives. La régression Poisson suppose que la variable réponse Y_i suit une loi Poisson avec un paramètre μ_i . Pour $y_i \in \mathbb{N}$, on a

$$P(Y_i = y_i) = e^{-\mu_i} \frac{\mu_i^{y_i}}{y_i!}.$$

En plus, on a $E[Y_i] = \text{Var}[Y_i] = \mu_i$.

Comme on l'a vu plus haut, la famille exponentielle inclut la loi Poisson. Dans ce qui suit, on utilise la fonction de lien canonique $g(\mu_i) = \eta_i = \log(\mu_i)$. Avec cette fonction de lien, on a

$$\begin{aligned} \mu_i &= e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}} \\ &= e^{\beta_0} \times \left\{ e^{\beta_1} \right\}^{X_{i1}} \times \dots \times \left\{ e^{\beta_p} \right\}^{X_{ip}} \end{aligned}$$

Ainsi, si X_{ij} augmente de 1, μ_i est multiplié par e^{β_j} . Si $\beta_j > 0$, alors $e^{\beta_j} > 1$ et μ_i croît s'il est multiplié par e^{β_j} .

Les paramètres de ce modèles sont donc les coefficients de régression $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$. L'estimateur de maximum de vraisemblance est obtenu en maximisant la fonction log-vraisemblance

$$l(\beta) = \sum_{i=1}^n \left\{ y_i(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}) - e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}} \right\} + K,$$

où $K = -\sum_{i=1}^n \log(y_i!)$ est une constante qui ne dépend pas de β .

La distribution asymptotique de $\hat{\beta}$ vérifie

$$\hat{\beta} \sim \mathcal{N} \{ \beta, (X^\top W X)^{-1} \},$$

où W est une matrice diagonale de taille n avec les éléments $w_i = \hat{\mu}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip}$, $i = 1, \dots, n$ sur la diagonale.

La déviance de ce modèle est

$$d(y, \mu) = 2 \left\{ y \log\left(\frac{y}{\mu}\right) - (y - \mu) \right\}$$

et on vérifie l'adéquation de ce modèle à un ensemble de données à l'aide des statistiques d'ajustement

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \quad \text{et} \quad D = \sum_{i=1}^n d(y_i, \hat{\mu}_i).$$

Ces deux statistiques suivent approximativement une loi de Khi-deux à $n - (p + 1)$ degrés de liberté si le modèle de Poisson est bien adapté aux données. Les procédures d'inférence statistique et de sélection et validation de modèles sont conduites en suivant la méthodologie générale pour les modèles linéaires généralisés présentée plus haut.

Dans ce qui suit, on s'intéresse à deux aspects spécifiques 'a la régression Poisson: les variables explicatives *offset* et l'extra-variabilité, aussi appelée variabilité extra-Poissonnière.

Pour ces illustrer ces aspects, on considère le jeu de données **danishlc** de la library **GLMsData** du logiciel R. Ce jeu de données contient deux variables explicatives : la ville et la tranche d'âge. En effet, les données sont collectées dans 4 villes différentes et concernent 6 tranches d'âge. La variable réponse est le nombre de nouveaux cas de cancer des poumons entre 1968 et 1971. La base de données contient une autre variable intéressante: la population de chaque tranche d'âge dans chaque ville.

4.1 Variables explicatives *offset*

La variable réponse Y_i est le nombre de nouveaux cas de cancer des poumons parmi m_i qui représente la population d'une tranche d'âge dans une ville donnée. Normalement, on aurait eu une régression logistique avec $Y_i \sim \text{Bin}(m_i, \pi_i)$, où π_i est la probabilité qu'un individu développe le cancer en question. Une estimation empirique de π_i est donnée par $\tilde{\pi}_i = Y_i/m_i$. Selon les données qu'on a, $\tilde{\pi}_{i1} = 11/3059 \approx 3.6 \times 10^{-3}$. Cette probabilité est très petite et une régression logistique ne semble pas être appropriée pour analyser ces données.

Une alternative est de modéliser l'espérance du ratio Y_i/m_i en fonction des variables explicatives. Autrement dit, on écrit que Y_i suit une loi de Poisson avec un paramètre μ_i qui vérifie

$$\log\left(\frac{\mu_i}{m_i}\right) = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

Cette dernière égalité s'écrit aussi:

$$\log(\mu_i) = \beta_0 + \log(m_i) + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

Ainsi, le terme $\log(m_i)$ peut être considéré comme une variable explicative avec un coefficient β_j fixé à 1. On parle d'une variable explicative *offset*. Dans une régression Poisson avec un lien log, un terme *offset* est utile lorsqu'on pense que l'espérance de la variable Y_i est proportionnelle à une autre variable qu'on veut inclure dans le modèle.

```
> if (!require("GLMsData")) install.packages("GLMsData")
> library("GLMsData")#### Installer la librairie GLMsData
>
> data(danishlc) #### Rendre le jeu de donnees danishlc disponible
>
> modele.additif<-glm(Cases~offset(log(Pop))+City+Age,family=poisson,data=danishlc)
> modele.City<-glm(Cases~offset(log(Pop))+City,family=poisson,data=danishlc)
> modele.Age<-glm(Cases~offset(log(Pop))+Age,family=poisson,data=danishlc)
>
> Q1 <- deviance(modele.City)-deviance(modele.additif)
> Q2 <- deviance(modele.Age)-deviance(modele.additif)
>
> df1 <- summary(modele.City)$df[2]-summary(modele.additif)$df[2]
> df2 <- summary(modele.Age)$df[2]-summary(modele.additif)$df[2]
>
```

```
> 1-pchisq(Q1,df=df1)
[1] 0
> 1-pchisq(Q2,df=df2)
[1] 0.182414
```

Il y a une différence significative entre les incidences du cancer des poumons des différentes tranches d'âge. Cependant, ces incidences par tranche d'âge semblent être les mêmes pour les différentes villes.

4.2 Variabilité extra-Poissonnière

Avec une variable réponse Y_i qui suit une distribution Poisson, on doit avoir $E[Y_i] = Var[Y_i] = \mu_i$. Dans la pratique, il arrive qu'on ait $E[Y_i] > Var[Y_i]$. Dans ce qui suit, on présente deux stratégies pour remédier à ce problème.

4.2.1 Approche Quasi-Poisson

La première stratégie consiste à considérer un modèle Quasi-Poisson. Avec ce modèle, on spécifie seulement les deux premiers moment de la distribution de Y_i : $E[Y_i] = \mu_i$ et $Var[Y_i] = \phi\mu_i$. Avec cette approche, on obtient les mêmes estimateurs $\hat{\beta}$ qu'un modèle de Poisson mais la matrice $Var(\hat{\beta})$ est multiplié par $\tilde{\phi}_P = X^2/(n - (p + 1))$.

```
> #####
> ## Approche Quasi-Poisson ##
> #####
>
> modele.Age.Quasi <- glm(Cases~offset(log(Pop))+Age,
+                          family=quasipoisson,data=danishlc)
> Pearson <- sum((danishlc$Cases-fitted(modele.Age))^2/fitted(modele.Age))
> phi.P.tilde <- Pearson/(n-(p+1)); phi.P.tilde
[1] 1.447135
> summary(modele.Age.Quasi)
```

Call:

```
glm(formula = Cases ~ offset(log(Pop)) + Age, family = quasipoisson,
    data = danishlc)
```

Deviance Residuals:

Min	1Q	Median	3Q	Max
-2.8520	-0.6424	-0.1067	0.7853	1.5468

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-4.45397	0.21606	-20.615	5.71e-14	***
Age40-54	-1.40828	0.30089	-4.680	0.000186	***
Age55-59	-0.32594	0.30316	-1.075	0.296511	
Age60-64	0.09339	0.28344	0.330	0.745574	
Age65-69	0.34201	0.28079	1.218	0.238937	
Age70-74	0.43894	0.28785	1.525	0.144669	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for quasipoisson family taken to be 1.447135)

Null deviance: 129.908 on 23 degrees of freedom
 Residual deviance: 28.307 on 18 degrees of freedom
 AIC: NA

Number of Fisher Scoring iterations: 5

```
> cbind(coef(modele.Age),coef(modele.Age.Quasi))
```

	[,1]	[,2]
(Intercept)	-4.45397213	-4.45397213
Age40-54	-1.40828068	-1.40828068
Age55-59	-0.32593887	-0.32593887
Age60-64	0.09339483	0.09339483
Age65-69	0.34200597	0.34200597
Age70-74	0.43894138	0.43894138

```
> phi.P.tilde*vcov(modele.Age)
```

	(Intercept)	Age40-54	Age55-59	Age60-64	Age65-69	Age70-74
(Intercept)	0.04668176	-0.04668176	-0.04668176	-0.04668176	-0.04668176	-0.04668176
Age40-54	-0.04668176	0.09053432	0.04668176	0.04668176	0.04668176	0.04668176
Age55-59	-0.04668176	0.04668176	0.09190471	0.04668176	0.04668176	0.04668176
Age60-64	-0.04668176	0.04668176	0.04668176	0.08033605	0.04668176	0.04668176
Age65-69	-0.04668176	0.04668176	0.04668176	0.04668176	0.07884030	0.04668176
Age70-74	-0.04668176	0.04668176	0.04668176	0.04668176	0.04668176	0.08286012

```
> vcov(modele.Age.Quasi)
```

	(Intercept)	Age40-54	Age55-59	Age60-64	Age65-69	Age70-74
(Intercept)	0.04668176	-0.04668176	-0.04668176	-0.04668176	-0.04668176	-0.04668176
Age40-54	-0.04668176	0.09053432	0.04668176	0.04668176	0.04668176	0.04668176

Age55-59	-0.04668176	0.04668176	0.09190471	0.04668176	0.04668176	0.04668176
Age60-64	-0.04668176	0.04668176	0.04668176	0.08033605	0.04668176	0.04668176
Age65-69	-0.04668176	0.04668176	0.04668176	0.04668176	0.07884030	0.04668176
Age70-74	-0.04668176	0.04668176	0.04668176	0.04668176	0.04668176	0.08286012

Cette approche permet de calculer $\hat{\beta}$ et $Var[\hat{\beta}]$, de contruire des intervalles de confiance et d'effectuer des tests d'hypothèses sur les coefficients β . Cependant, il est primordial de préciser que cette approche n'implique pas de distribution et donc ne permet pas de calculer des quantités comme *AIC* ou *BIC* car on ne définit pas de fonction de log-vraisemblance.

4.2.2 Modèle avec la loi binomiale négative

On dit que Y_i suit une loi binomiale négative avec les paramètres μ_i et α si

$$P(Y_i = y_i) = \frac{\Gamma(y_i + 1/\alpha)}{\Gamma(y_i + 1)\Gamma(1/\alpha)} \left(\frac{1/\alpha}{\mu_i + 1/\alpha} \right)^{1/\alpha} \left(\frac{\mu_i}{\mu_i + 1/\alpha} \right)^{y_i}, \quad y_i = 0, 1, 2, \dots, \quad \text{et } \alpha > 0.$$

Avec cette loi, on a $E[Y_i] = \mu_i$ et $Var[Y_i] = \mu_i + \alpha\mu_i^2$. On retrouve la loi de Poisson de paramètre μ_i lorsque $\alpha \rightarrow 0$.

Pour définir un modèle de régression, on pose $\mu_i = e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}}$. Avec cette fonction de lien, les coefficients β gardent la même interprétation que dans une régression Poisson.

Les paramètres de ce modèles sont donc β et α et on retrouve la régression Poisson lorsque $\alpha \rightarrow 0$. Le principal inconvénient de ce modèle est qu'on doit estimer α et β simultanément. Ceci peut causer des problèmes au niveau numérique.

Un avantage intéressant pour ce modèle est qu'il nous permet de tester l'hypothèse nulle $H_0 : \alpha = 0$. À cet effet, on ajuste le modèle Poisson et le modèle avec une loi binomiale négative et on calcule les déviations des deux modèles, disons D_0 et D_1 . La statistique du test sera alors $Q_{obs} = D_0 - D_1$. Sous l'hypothèse nulle $H_0 : \alpha = 0$, on a

$$Q \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$$

car on teste α sur la limite de son domaine de définition. Le seuil observé est alors égal à $\alpha^* = P(\chi_1^2 > Q_{obs})/2$.

```
> #####
> ## Approche binomiale negative ##
> #####
```

```

>
> library(MASS)
>
> modele.Age.NB <- glm.nb(formula = Cases~offset(log(Pop))+Age,link="log",data=danish)
>
> summary(modele.Age.NB)

```

```

Call:
glm.nb(formula = Cases ~ offset(log(Pop)) + Age, data = danishlc,
       link = "log", init.theta = 195.5841968)

```

```

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-2.8126  -0.6293  -0.1091   0.7648   1.5098

```

```

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -4.45209     0.18300 -24.328 < 2e-16 ***
Age40-54     -1.41012     0.25510  -5.528 3.25e-08 ***
Age55-59     -0.32639     0.25689  -1.271  0.2039
Age60-64      0.09184     0.24089   0.381  0.7030
Age65-69      0.34153     0.23871   1.431  0.1525
Age70-74      0.43705     0.24449   1.788  0.0738 .
---

```

```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

(Dispersion parameter for Negative Binomial(195.5842) family taken to be 1)

```

```

Null deviance: 122.207 on 23 degrees of freedom
Residual deviance: 27.168 on 18 degrees of freedom
AIC: 138.67

```

```

Number of Fisher Scoring iterations: 1

```

```

              Theta: 196
Std. Err.: 1364

```

```

2 x log-likelihood: -124.673
>

```

```
> Q.obs <- deviance(modele.Age)-deviance(modele.Age.NB)
>
> pvalue <- (1-pchisq(Q.obs,df=1))/2
>
> pvalue
[1] 0.1429792
```

On ne rejette pas l'hypothèse nulle $H_0 : \alpha = 0$. On peut donc supposer qu'il n'y a pas de variabilité extra-Poissonnière dans les données.