

Introduction et motivation

« Statistics is often wrongly perceived as a set of tools instead of a set of problems »

tiré de J. H. Friedman (2001) “The Role of Statistics in Data Revolution”
International Statistical Review, 69, 5–10.

Exemple 1 – Boston Housing

Les données *Boston Housing* ont été utilisées pour décrire la relation entre la valeur des logements dans les banlieues de Boston et différents attributs.

La taille de l'échantillon est de 506.

Les données proviennent à l'origine de HARRISON et RUBINFELD (1978), utilisées dans BELSLEY, KUH et WELSCH (1980), disponibles depuis l'archive [StatLib](#).

medv	valeur médiane des maisons occupées par le propriétaire en \$1000
crim	taux de criminalité par habitant par ville
zn	proportion de terrains résidentiels zonés pour lots de plus de 25 000 pi ²
indus	proportion d'acres commerciales non liées au commerce de détail par ville
nox	concentration d'oxydes nitriques (parties par 10 millions)
rm	nombre moyen de pièces par logement
age	proportion de logements occupés par le propriétaire construits avant 1940
dis	distances pondérées vers cinq centres d'emploi de Boston
rad	indice d'accessibilité aux autoroutes radiales
tax	taux de taxe foncière à pleine valeur par \$10 000
ptratio	ratio élèves-enseignant par ville
b	$1000(B_k - 0.63)^2$, où B_k est la proportion de personnes noires par ville
lstat	proportion de la population de statut inférieur
chas	variable indicatrice de la rivière Charles (=1 si le secteur borde la rivière; 0 sinon)

Modèle (1) :





$$\begin{aligned}\log(\text{medv}) = & \beta_0 + \beta_1 \text{crim} + \beta_2 \text{zn} + \beta_3 \text{indus} + \\ & + \beta_4 \text{nox} + \beta_5 \text{rm} + \beta_6 \text{age} + \beta_7 \text{dis} + \beta_8 \text{rad} \\ & + \beta_9 \text{tax} + \beta_{10} \text{ptratio} + \beta_{11} \text{b} + \beta_{12} \text{lstat} \\ & + \beta_{13} \text{chas} + \epsilon.\end{aligned}\tag{1}$$

```
> linearfit <- lm(log(medv) ~ chas+crim+zn+indus+nox+rm+age+dis+ rad+tax+ptratio+b+lstat,data=BostonHousing) >  
summary(linearfit)
```

Coefficients : Estimate Std. Error t value Pr(>|t|) (Intercept) 4.1020423 0.2042726 20.081 < 2e-16 *** chas 0.1008876
 0.0344859 2.925 0.003598 ** crim -0.0102715 0.0013155 -7.808 3.52e-14 *** zn 0.0011725 0.0005495 2.134 0.033349 * indus
 0.0024668 0.0024614 1.002 0.316755 nox -0.7783993 0.1528902 -5.091 5.07e-07 *** rm 0.0908331 0.0167280 5.430 8.87e-08 ***
 age 0.0002106 0.0005287 0.398 0.690567 dis -0.0490873 0.0079834 -6.149 1.62e-09 *** rad 0.0142673 0.0026556 5.373 1.20e-07
 *** tax -0.0006258 0.0001505 -4.157 3.80e-05 *** ptratio -0.0382715 0.0052365 -7.309 1.10e-12 *** b 0.0004136 0.0001075
 3.847 0.000135 *** lstat -0.0290355 0.0020299 -14.304 < 2e-16 *** — Signif. codes : 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error : 0.1899 on 492 degrees of freedom Multiple R-squared : 0.7896, Adjusted R-squared : 0.7841

F-statistic : 142.1 on 13 and 492 DF, p-value : < 2.2e-16



Modèle (2) (inspiré de BELSLEY, KUH et WELSCH 1980) :

$$\begin{aligned}\log(\text{medv}) = & \beta_0 + \beta_1 \text{crim} + \beta_2 \text{zn} + \beta_3 \text{indus} + \\ & + \beta_4 \text{nox}^2 + \beta_5 \text{rm}^2 + \beta_6 \text{age} + \beta_7 \log(\text{dis}) + \beta_8 \log(\text{rad}) \\ & + \beta_9 \text{tax} + \beta_{10} \text{ptratio} + \beta_{11} \text{b} + \beta_{12} \log(\text{lstat}) \\ & + \beta_{13} \text{chas} + \epsilon.\end{aligned}\tag{2}$$

```
> linearfit2 <-
```

```
lm(log(medv) ~ chas+crim+zn+indus+I(nox2) + I(rm2) + age + log(dis) + log(rad) + tax + ptratio + b + log(lstat), data =  
BostonHousing) > summary(linearfit2)
```

Coefficients : Estimate Std. Error t value Pr(>|t|) (Intercept) 4.558e+00 1.544e-01 29.512 < 2e-16 *** chas 9.140e-02 3.320e-02 2.753 0.006129 ** crim -1.186e-02 1.245e-03 -9.532 < 2e-16 *** zn 8.016e-05 5.056e-04 0.159 0.874105 indus 2.395e-04 2.364e-03 0.101 0.919318

$l(\text{nox}^2) - 6.380e - 011.131e - 01 - 5.6392.88e - 08$ *** $l(\text{rm}^2) 6.328e - 031.312e - 034.8231.89e - 06$ ***

$\text{age} 9.074e - 055.263e - 040.1720.863179 \log(\text{dis}) - 1.913e - 013.339e - 02 - 5.7271.78e - 08$ ***







$\log(\text{rad}) 9.571e - 021.913e - 025.0027.91e - 07$ *** $\text{tax} - 4.203e - 041.227e - 04 - 3.4260.000664$ ***

$\text{ptratio} - 3.112e - 025.013e - 03 - 6.2081.14e - 09$ *** $b 3.637e - 041.031e - 043.5270.000460$ ***

$\log(\text{lstat}) - 3.712e - 012.501e - 02 - 14.841 < 2e - 16$ *** -- -- Signif. codes : 0' ***' 0.001' **' 0.01' *' 0.05' . '0.1''1

Residual standard error : 0.1825 on 492 degrees of freedom Multiple R-squared : 0.8059, Adjusted R-squared : 0.8008

F-statistic : 157.1 on 13 and 492 DF, p-value : < 2.2e-16




Modèle (3), non paramétrique :

$$\begin{aligned}\log(\text{medv}) = & \alpha + f_1(\text{crim}) + f_2(\text{zn}) + f_3(\text{indus}) + \\ & + f_4(\text{nox}) + f_5(\text{rm}) + f_6(\text{age}) + f_7(\text{dis}) + \\ & + f_8(\text{rad}) + f_9(\text{tax}) + f_{10}(\text{ptratio}) \\ & + f_{11}(\text{b}) + f_{12}(\text{lstat}) + \beta \text{chas} + \epsilon.\end{aligned}$$

```
> library(mgcv) > BHnpfit.new <- gam(log(medv) chas+s(crim)+s(zn)+s(indus)+ s(nox,k=20)+  
s(rm)+s(age)+s(dis,k=20)+s(rad,k=8)+s(tax)+s(ptratio)+ s(b)+s(lstat), data=BostonHousing) > plot(BHnpfit.new, scale=0,  
page=1)
```

★ Sélection de variables par garrote non négatif (nonnegative garrote), voir BREIMAN (1995) et CANTONI, FLEMMING et RONCHETTI (2011).



Exemple 2 : Diagnostic du cancer du sein

Diagnostic du cancer du sein par cytologie mammaire (aspiration à l'aiguille fine plutôt que chirurgie invasive).

Données Breast cancer Wisconsin, disponibles depuis le University of California at Irvine Repository Of Machine Learning Database

www.ics.uci.edu/~mlern/MLRepository.html.

Variable réponse : 2 classes : bénigne (codée 0) ou maligne (codée 1).


Il y a 699 patientes dans l'étude, dont 16 ont une ou plusieurs valeur(s) manquante(s) dans les prédictors.

Prédicteurs disponibles :

- Épaisseur de l'amas (Clump Thickness) (1–10)
- Uniformité de la taille des cellules (Uniformity of Cell Size) (1–10)
- Uniformité de la forme des cellules (Uniformity of Cell Shape) (1–10)
- Adhésion marginale (Marginal Adhesion) (1–10)
- Taille des cellules épithéliales simples (Single Epithelial Cell Size) (1–10)
- Noyaux nus (Bare Nuclei) (1–10)
- Chromatine fade (Bland Chromatin) (1–10)
- Nucléoles normaux (Normal Nucleoli) (1–10)
- Mitoses (1–10)

On considère un modèle logistique linéaire.

```
> breast.fit <- glm(status clump+cellsize+cellshape+adhesion+  
singlesize+nuclei+chromatin+nucleoli+mitoses,data=breast, family=binomial,na.action=na.omit) > fitted.breast <-  
predict(breast.fit,type="response") > plot(fitted.breast,na.omit(breast)$status,xlab =  $\epsilon$ Fittedvalues $\epsilon$ , ylab =  $\epsilon$ Status $\epsilon$ )
```



Exemple 3 : Étude sur la pollution de l'air

Données provenant de la base National Morbidity, Mortality and Air Pollution Study (NMMAPS) disponible à <http://www.ihapss.jhsph.edu> pour les 88 plus grandes régions métropolitaines des États-Unis.

La variable réponse est le nombre de décès par jour (`death`), que l'on modélise comme une variable de Poisson.

Variables explicatives potentiellement intéressantes :

- matière particulaire de moins de $10\text{ }\mu\text{m}$ de diamètre aérodynamique, moyenne tronquée à 10% sur tous les moniteurs d'un comté ($\text{pm}_{10}\text{tmean}$)
- température moyenne (sur 24 heures) (tmean)
- temps (day)
- température du point de rosée (dptp)
- jour de la semaine (dow : 1=sam, 2=dim, ...)

L'intérêt principal porte sur l'effet de $\text{pm}_{10}\text{tmean}$ (pollution), qui entre linéairement dans le modèle.




San Francisco, 1^{er} janv. 1987 au 31 déc. 2000, $n = 15342$


```
sanFfit <- gam(death pm10tmean+s(tmean)+s(day)+s(dptp)+factor(dow), data=sanF,family=poisson)
```

```
Parametric coefficients : Estimate Std. Error z value Pr(>|z|) (Intercept) 1.7820648 0.0245328 72.640 < 2e-16 *** pm10tmean  
0.0017404 0.0005446 3.196 0.00139 ** factor(dow)2 -0.0261762 0.0349350 -0.749 0.45369 factor(dow)3 0.0194925 0.0343809  
0.567 0.57074 factor(dow)4 -0.0207042 0.0348386 -0.594 0.55232 factor(dow)5 -0.0013170 0.0346407 -0.038 0.96967  
factor(dow)6 -0.0002978 0.0346081 -0.009 0.99314 factor(dow)7 -0.0140022 0.0345012 -0.406 0.68486 — Signif. codes : 0 '***'  
0.001 '***' 0.01 '**' 0.05 '.' 0.1 ' ' 1
```

Approximate significance of smooth terms : edf Ref.df Chi.sq p-value s(tmean) 1.973 2.568 7.642 0.0388 * s(day) 2.241 2.796
 24.476 2.14e-05 *** s(dptp) 1.003 1.006 0.494 0.4830 — Signif. codes : 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

R-sq.(adj) = 0.0145 Deviance explained = 2.03 UBRE = 0.74149 Scale est. = 1 n = 1986





Questions ouvertes :

- Tous les termes sont-ils significatifs ?
- Autres facteurs influençant le nombre de décès.
(R^2 et déviance expliquée faibles car peu de variables explicatives.)
- ★ Modèles différents pour différents groupes d'âge (voir DOMINICI, SAMET et ZEGER 2000).

Exemple 4 : Coût de séjour pour problèmes de dos

100 patients hospitalisés au *Centre Hospitalier Universitaire Vaudois (CHUV)* à Lausanne (Suisse) durant 1999 pour « problèmes médicaux de dos » (APDRG 243).

Données fournies par A. Marazzi, voir MARONNA et YOHAI ([2004](#)).


La variable réponse est le coût du séjour (CouTot en francs suisses).

Variables explicatives :

- durée de séjour (LOS, en jours)
- type d'admission (Typadm : 0=planifiée, 1=urgence)
- type d'assurance (TypASS : 0=régulière, 1=privée)
- âge en années (age)
- sexe (Sexe : 0=femme, 1=homme)
- destination à la sortie (dest : 1=domicile, 0=autre établissement de santé)


Objectifs :

- Identifier les facteurs influençant le coût du séjour
- Prédiction



Modèle gamma avec lien logarithmique.

Coefficients : Estimate Std. Error t value Pr(>|t|) (Intercept) 7.2338121 0.1468364 49.264 < 2e-16 *** log(LOS) 0.8222203
0.0279641 29.403 < 2e-16 *** Typadm 0.2136148 0.0500028 4.272 4.67e-05 *** Typass 0.0932763 0.0791100 1.179 0.2414 age
-0.0005335 0.0012852 -0.415 0.6790 Sexe 0.0951009 0.0499814 1.903 0.0602 . dest -0.1043560 0.0692713 -1.506 0.1353 — Signif.
codes : 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
(Dispersion parameter for Gamma family taken to be 0.04961642)
Null deviance : 47.9536 on 99 degrees of freedom Residual deviance : 5.0718 on 93 degrees of freedom AIC : 1817.9
Number of Fisher Scoring iterations : 5



Valeurs aberrantes! (voir chapitre ??)

Exemple 5 : Étude CARDIA

Données de l'étude CARDIA (Coronary Artery Risk Development in young Adults), disponibles depuis les archives de données du JASA à <http://lib.stat.cmu.edu/jasadata/>, voir PREISSER et al. (2000).

5 115 adultes âgés de 18 à 30 ans ont été suivis et examinés jusqu'à 5 fois de 1986 à 1996, aux années 0, 2, 5, 7 et 10.

On considère le sous-échantillon de 3693 individus pour lesquels l'information complète est disponible pour les 4 premières visites (aucune valeur manquante).

Variable réponse (à chaque visite) : statut tabagique autodéclaré (oui/non, codé 1/0).

Prédicteurs (à chaque visite) :

- âge (dépendant du temps)
- cohorte de naissance (1955–1962, 1963–1967) (indépendant du temps)
- éducation (secondaire ou moins, études collégiales partielles, diplôme universitaire) (dépendant/(in)dépendant du temps)
- race-sexe (hommes noirs, femmes noires, hommes blancs, femmes blanches) (indépendant du temps)

★ Problèmes de données manquantes (missingness), voir PREISSER et al. (2000).

Summary of Residuals : Min 1Q Median 3Q Max -0.5506120 -0.3121130
-0.1189440 0.4816228 0.9095992

Coefficients : Estimate Naive S.E. Naive z Robust S.E. Robust z (Intercept)
-1.33707777 0.54231807 -2.465486 0.54510289 -2.452891 age 0.06480087 0.02646754
2.448315 0.02669744 2.427231 factor(birth)2 -0.19856466 0.14606724 -1.359406
0.14563751 -1.363417 factor(birth)3 -0.40380459 0.23689643 -1.704562 0.23858001
-1.692533 factor(education)2 -0.68712005 0.08313860 -8.264754 0.08490269
-8.093030 factor(education)3 -1.96140806 0.10016299 -19.582164 0.10054908
-19.506972 factor(racesex)2 -0.17668132 0.09763816 -1.809552 0.09900202
-1.784623 factor(racesex)3 -0.13445604 0.10634023 -1.264395 0.10833799 -1.241079
factor(racesex)4 -0.12730906 0.10530815 -1.208919 0.10599195 -1.201120

Estimated Scale Parameter : 1.000362 Number of Iterations : 1

Working Correlation [1] [2] [3] [4] [1,] 1.000000 0.727139 0.727139 0.727139 [2,]
0.727139 1.000000 0.727139 0.727139 [3,] 0.727139 0.727139 1.000000 0.727139 [4,]

0.727139 0.727139 0.727139 1.000000


Exemple 6 : Abondance d'oiseaux

Les dénombrements d'oiseaux sont-ils en déclin ? Abondance d'espèces animales.

L'exemple de 5 espèces de Seal Island (Nouvelle-Écosse, Canada) qui hivernent principalement dans le sud des États-Unis : Northern Flicker, Red-wing Blackbird, Rusty Blackbird, Ruby-crowned Kinglet, Yellow-rumped Warbler.

Données fournies par le prof. I. MacLaren, Dalhousie University.

2245 observations (saison automnale, entre le 1^{er} août et le 14 novembre, sur 40 ans depuis 1963), soit 449 jours d'observations pour chaque espèce d'oiseau.



Variable réponse : nombre d'oiseaux observés (décomptes, NUMBER).


Prédicteurs :

- année (YEAR) – **Intérêt principal.**
- jour (DAY)
- nombre d'observateurs sur l'île (NO . OBS)
- direction du vent à minuit la veille (WIND . 0)
- direction du vent à midi la veille (WIND . 1)
- direction du vent à minuit deux jours avant (WIND . 2)
- direction du vent à midi deux jours avant (WIND . 3)
- vitesse du vent ce jour-là (WINDSPD)
- condition du ciel (1=dégagé, 2=nuageux, 3=brouillard, 4=pluie) (SKY)
- proportion de lune illuminée (MOON)
- espèce d'oiseau (1-5) (BIRD)

Modèle de Poisson avec lien logarithmique :

$$\begin{aligned}\text{NUMBER} \sim & \alpha + f_1(\text{YEAR}) + f_2(\text{DAY}) + f_3(\text{NO.OBS}) \\ & + f_4(\text{WIND.0}) + f_5(\text{WIND.1}) + f_6(\text{WIND.2}) \\ & + f_7(\text{WIND.3}) + f_8(\text{WINDSPD}) + \text{factor}(\text{SKY}) \\ & + f_9(\text{MOON}) + \text{factor}(\text{BIRD})\end{aligned}$$

```
> require(mgcv) > GrA.fit <- gam(NUMBER s(YEAR,k=20)+s(DAY,k=20)+s(NO.OBS,k=8)+  
s(WIND.0,k=20)+s(WIND.1,k=20)+s(WIND.2,k=20)+s(WIND.3,k=20)+  
s(WINDSPD,k=20)+factor(SKY)+s(MOON,k=20)+factor(BIRD), family=poisson,data=GrA,na.action=na.omit) >  
plot(GrA.fit,scale=0,pages=1,pers=T,all.terms=T,cex.lab=2)
```



★ Excès de zéros possible. Revue : RIDOUT, DEMETRIO et HINDE (1998)

Qu'ont en commun les exemples 1 à 6?

Même formulation générale du modèle :

$$\begin{aligned} g(E(Y_i)) &= g(\mu_i) = \\ &= \eta_i = \begin{cases} \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} \\ \alpha + f_1(x_{i1}) + \dots + f_p(x_{ip}) \end{cases} \end{aligned}$$

g est appelée la fonction de lien (link function).

η_i est appelé le prédicteur linéaire (additif).

Notation

Variable réponse :

observations $y_1, \dots, y_n$ pour n individus (ou sujets) correspondant aux variables aléatoires $Y_1, \dots, Y_n$.

y_i (resp. Y_i) peut être multidimensionnel, auquel cas on notera ses éléments y_{it} avec $t = 1, \dots, n_i$.

Propriétés distributionnelles de Y_i :

Y_i issu d'une distribution F_{θ_i} :

$$Y_i \sim F_{\theta_i}$$

On note l'espérance $E(Y_i) = \mu_i$ et la variance $Var(Y_i) = v_i$.

Variables explicatives (prédicteurs) :

- pour y_i unidimensionnel :

$$x_i = (x_{i0}, x_{i1}, \dots, x_{ip})^T$$

est un vecteur de dimension $(p + 1)$. x_{i0} est habituellement égal à 1 (ordonnée à l'origine). Information combinée :

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} = \begin{pmatrix} x_{10} & x_{11} & \cdots & x_{1p} \\ x_{20} & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n0} & x_{n1} & \cdots & x_{np} \end{pmatrix}$$

- pour y_i multidimensionnel :

$$X_i = \begin{pmatrix} x_{i10} & x_{i11} & \cdots & x_{i1p} \\ x_{i20} & x_{i21} & \cdots & x_{i2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{in_i0} & x_{in_i1} & \cdots & x_{in_ip} \end{pmatrix}$$

Information combinée :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix}$$

Connaissances préalables

Familiarité avec les concepts suivants :

- Estimation (maximum de vraisemblance, moindres carrés, méthode des moments, etc.)
- Intervalles de confiance.
- Distributions d'échantillonnage.
- Tests d'hypothèses (hypothèse nulle et alternative, statistique de test et sa distribution, valeur- p , seuil de signification, etc.).
- Régression linéaire.
- Calcul différentiel et notation matricielle.
- ...

Principes de la modélisation statistique I

Une analyse statistique devrait comprendre les étapes suivantes :

1. **Analyse exploratoire des données** pour vérifier la qualité des données et aider à la formulation du modèle. Considérer chaque variable séparément et se poser les questions suivantes :
 - Quelle est l'échelle de mesure ?
 - Quelle est la forme de la distribution ?
 - Comment est-elle associée aux autres variables ?
2. **Formulation du modèle** :
 - Distribution de probabilité de Y.
 - Lien avec les variables explicatives.
3. **Estimation des paramètres** : quelle méthode ? (maximum de vraisemblance, moindres carrés, méthode des moments, etc.)

Principes de la modélisation statistique II

4. Résidus et vérification du modèle :

- Inspection graphique des résidus (indépendance, normalité approximative, moyenne nulle, variance constante).
- Tests d'adéquation (goodness of fit).

5. Inférence et interprétation :

Tester les hypothèses sur les paramètres pour obtenir un modèle parcimonieux. Puis (et seulement alors) interpréter les paramètres.