

Notes de cours — STT-4300

Rappels de régression linéaire, modèles linéaires généralisés,
régression non-linéaire et non-paramétrique, modèles additifs
généralisés

Table des matières

1	Rappels de régression linéaire	4
1.1	Le modèle linéaire	4
1.2	Estimation par moindres carrés	4
1.3	Inférence statistique	4
1.3.1	Intervalle de confiance et tests sur les coefficients	4
1.3.2	Test F et comparaison de modèles emboîtés	5
1.3.3	Coefficient de détermination	5
1.4	Prédiction	5
1.5	Diagnostics du modèle	5
1.5.1	Résidus	5
1.5.2	Observations aberrantes et influentes	6
1.6	Sélection de variables : AIC et BIC	6
1.7	Limites du modèle linéaire	6
2	Modèles de régression pour données binaires	7
2.1	Données et modèle	7
2.1.1	Données individuelles (Bernoulli)	7
2.1.2	Données groupées (binomiale)	7
2.1.3	Fonctions de lien	8
2.2	Inférence statistique	8
2.2.1	Estimation des paramètres β	8
2.2.2	Tests d'hypothèses et intervalles de confiance	8
2.2.3	Intervalle de confiance pour une probabilité prédite	9
2.3	Sélection de modèles	9
2.3.1	Déviance	9
2.3.2	Comparaison de modèles emboîtés	9
2.3.3	Comparaison de modèles non emboîtés : AIC et BIC	10
2.3.4	Sélection automatique	10
2.4	Validation et diagnostic de modèles	10
2.4.1	Résidus	10
2.4.2	Tests d'adéquation globale	10
2.4.3	Graphiques et extra-variabilité	10

2.4.4	Observations aberrantes et valeurs influentes	11
2.5	Spécificité, sensibilité et courbe ROC	11
3	Modèles linéaires généralisés	12
3.1	Famille exponentielle	12
3.1.1	Définition	12
3.1.2	Exemples	12
3.1.3	Déviance	13
3.2	Définition d'un MLG	13
3.3	Estimation des paramètres	13
3.3.1	Estimation de ϕ	14
3.4	Inférence statistique	14
3.4.1	Cas ϕ fixé	14
3.4.2	Cas ϕ inconnu	14
3.5	Sélection et validation de modèles	15
3.6	Exemple détaillé : la régression Poisson	15
3.6.1	Variables explicatives <i>offset</i>	15
3.6.2	Variabilité extra-Poissonienne	16
4	Prédiction, mesures de performance et validation croisée	17
4.1	Adéquation versus précision de prédiction	17
4.2	Validation croisée	17
4.2.1	Approche par ensemble de validation	17
4.2.2	Validation croisée avec exclusion d'une observation (LOOCV)	17
4.2.3	Validation croisée à K blocs	18
4.3	Mesures de performance pour la classification	18
5	Sélection de variables et régularisation	19
5.1	Sélection de variables : rappel	19
5.2	Régression régularisée	19
5.2.1	Régression ridge	19
5.2.2	Régression lasso	20
5.2.3	Sélection du paramètre λ	20
6	Régression non-paramétrique : k plus proches voisins et estimateur de noyau	21
6.1	Estimateur des k plus proches voisins	21
6.1.1	Définition	21
6.1.2	Compromis biais-variance et choix de k	21
6.1.3	Plusieurs variables explicatives et distance de Mahalanobis	22
6.2	Estimateur de noyau (Nadaraya-Watson)	22
6.2.1	Des voisins aux noyaux	22
6.2.2	Choix du paramètre de fenêtre h	22
6.3	Régression non-paramétrique et classification	23
7	Régression non-linéaire : polynômes, fonctions par morceaux et splines	24
7.1	Régression polynomiale	24
7.2	Régression avec des fonctions constantes par morceaux	24
7.3	Régression avec des splines	25
7.3.1	Splines de régression	25

7.3.2	Base des puissances tronquées	25
7.3.3	B-splines	25
7.3.4	Splines naturelles	26
7.3.5	Splines de lissage (splines pénalisées)	26
8	Modèles additifs et modèles additifs généralisés (GAM)	27
8.1	Motivation	27
8.2	Estimation par moindres carrés pénalisés	27
8.2.1	Matrice d'influence et degrés de liberté effectifs	27
8.2.2	Choix des paramètres de lissage	28
8.2.3	Inférence	28
8.3	Modèles additifs généralisés	28
8.3.1	Algorithme d'ajustement (moindres carrés pondérés itératifs pénalisés)	28
8.3.2	Choix des paramètres de lissage et comparaison de modèles	29
8.3.3	En pratique avec R	29
8.4	Synthèse du cours	29

1 Rappels de régression linéaire

1.1 Le modèle linéaire

On dispose de données $\{(Y_i, X_i), i = 1, \dots, n\}$, où Y_i est la variable réponse (continue) et $X_i = (X_{i1}, \dots, X_{ip})^\top$ est un vecteur de p variables explicatives. Le modèle de régression linéaire multiple s'écrit :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \epsilon_i, \quad i = 1, \dots, n,$$

où $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ est le vecteur des coefficients de régression et les erreurs ϵ_i sont indépendantes et identiquement distribuées selon $\mathcal{N}(0, \sigma^2)$.

En écriture matricielle, on a $Y = X\beta + \epsilon$, où X est la matrice de plan (*design matrix*) de dimension $n \times (p+1)$ dont la première colonne ne contient que des 1 (ordonnée à l'origine) :

$$X = \begin{pmatrix} 1 & X_{11} & \dots & X_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{pmatrix}.$$

Sous ces hypothèses, on a $E[Y_i] = \mu_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$ et $Var[Y_i] = \sigma^2$ (homoscédasticité).

1.2 Estimation par moindres carrés

On estime β en minimisant la somme des carrés des écarts :

$$l(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip})\}^2 = (Y - X\beta)^\top (Y - X\beta).$$

La solution explicite est

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y$$

et l'estimateur obtenu vérifie

$$\hat{\beta} \sim \mathcal{N}\left\{\beta, \sigma^2(X^\top X)^{-1}\right\}.$$

Sous l'hypothèse de normalité des erreurs, l'estimateur des moindres carrés coïncide avec l'estimateur du maximum de vraisemblance. Il est sans biais et de variance minimale parmi les estimateurs linéaires sans biais (théorème de Gauss-Markov).

Les valeurs prédites sont $\hat{Y} = X\hat{\beta} = HY$, où $H = X(X^\top X)^{-1}X^\top$ est la **matrice chapeau** (*hat matrix*). Les éléments diagonaux $h_i = H_{ii}$ sont les **leviers** (*leverage*) des observations. L'estimateur usuel de σ^2 est

$$\hat{\sigma}^2 = \frac{SSE}{n - (p+1)}, \quad SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$

1.3 Inférence statistique

1.3.1 Intervalles de confiance et tests sur les coefficients

Un intervalle de confiance à $100 \times (1 - \alpha)\%$ pour β_j est donné par

$$\left[\hat{\beta}_j - t_{\alpha/2, n-(p+1)} se(\hat{\beta}_j); \hat{\beta}_j + t_{\alpha/2, n-(p+1)} se(\hat{\beta}_j) \right],$$

où $se(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 [(X^\top X)^{-1}]_{j+1,j+1}}$ et $t_{\gamma,\nu}$ est le quantile d'ordre $1 - \gamma$ de la loi de Student à ν degrés de liberté.

Pour tester $H_0 : \beta_j = 0$ contre $H_1 : \beta_j \neq 0$, on utilise la statistique $t_{obs} = \hat{\beta}_j / se(\hat{\beta}_j)$, qui suit une loi $t_{n-(p+1)}$ sous H_0 . On rejette H_0 au seuil α si $|t_{obs}| > t_{\alpha/2, n-(p+1)}$.

1.3.2 Test F et comparaison de modèles emboîtés

Deux modèles sont **emboîtés** si l'un est un cas particulier de l'autre. Pour comparer un modèle réduit (à $q + 1$ paramètres) à un modèle complet (à $p + 1$ paramètres, $q < p$), on utilise la statistique

$$F_{obs} = \frac{(SSE_{réduit} - SSE_{complet}) / (p - q)}{SSE_{complet} / (n - (p + 1))},$$

qui suit une loi $F_{p-q, n-(p+1)}$ sous l'hypothèse nulle que le modèle réduit est adéquat.

1.3.3 Coefficient de détermination

Le coefficient de détermination

$$R^2 = 1 - \frac{SSE}{SST}, \quad SST = \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

mesure la proportion de la variabilité de Y expliquée par le modèle. Comme R^2 augmente mécaniquement avec le nombre de variables, on utilise aussi le R^2 ajusté :

$$R_{adj}^2 = 1 - \frac{SSE / (n - (p + 1))}{SST / (n - 1)}.$$

1.4 Prédiction

Pour une nouvelle observation $X^* = (1, X_1^*, \dots, X_p^*)^\top$, la valeur prédite est $\hat{Y}^* = X^{*\top} \hat{\beta}$ et $Var[\hat{Y}^*] = \sigma^2 X^{*\top} (X^\top X)^{-1} X^*$. On distingue :

— l'**intervalle de confiance pour la moyenne** $E[Y^*]$:

$$X^{*\top} \hat{\beta} \pm t_{\alpha/2, n-(p+1)} \hat{\sigma} \sqrt{X^{*\top} (X^\top X)^{-1} X^*};$$

— l'**intervalle de prédiction** pour une observation individuelle Y^* :

$$X^{*\top} \hat{\beta} \pm t_{\alpha/2, n-(p+1)} \hat{\sigma} \sqrt{1 + X^{*\top} (X^\top X)^{-1} X^*}.$$

1.5 Diagnostics du modèle

1.5.1 Résidus

Les **résidus** sont $e_i = Y_i - \hat{Y}_i$. Les **résidus standardisés** sont $r_i = e_i / (\hat{\sigma} \sqrt{1 - h_i})$ et les **résidus studentisés** sont calculés en excluant l'observation i de l'estimation de σ . L'inspection graphique des résidus permet de vérifier :

- la **linéarité** (résidus vs valeurs ajustées : aucune tendance) ;
- l'**homoscédasticité** (dispersion constante des résidus) ;
- la **normalité** (diagramme quantile-quantile) ;
- l'**indépendance** (résidus dans l'ordre des observations).

1.5.2 Observations aberrantes et influentes

Le **levier** h_i mesure le potentiel d'influence de l'observation i ; une valeur dépassant $2(p+1)/n$ mérite examen. La **distance de Cook**,

$$D_i = \frac{r_i^2}{p+1} \cdot \frac{h_i}{1-h_i},$$

mesure l'influence globale de l'observation i sur les coefficients estimés. Les **DFBETAS** et **DFITS** mesurent respectivement l'effet du retrait de l'observation i sur chaque coefficient et sur la valeur ajustée $\hat{Y}_i$.

1.6 Sélection de variables : AIC et BIC

Pour comparer des modèles (emboîtés ou non), on utilise les critères d'information

$$\begin{aligned} AIC &= -2l(\hat{\beta}; y) + 2(p+1), \\ BIC &= -2l(\hat{\beta}; y) + \log(n)(p+1), \end{aligned}$$

où $l(\hat{\beta}; y)$ est la log-vraisemblance maximisée. Le modèle ayant le plus petit *AIC* (ou *BIC*) est préférable. Le *BIC* pénalise plus fortement les modèles complexes dès que $n \geq 8$.

Les procédures de sélection automatique *forward* (ajout progressif), *backward* (retrait progressif) et *stepwise* (mixte) explorent l'espace des modèles en se basant sur ces critères ; en R, on utilise la fonction **step**.

1.7 Limites du modèle linéaire

Le modèle linéaire classique repose sur deux hypothèses restrictives :

1. la variable réponse est continue et normalement distribuée ;
2. la relation entre $E[Y]$ et les variables explicatives est linéaire.

Dans de nombreuses applications, la réponse est binaire (défaut de paiement, présence d'une maladie), un dénombrement (nombre de cas de cancer), ou la relation est fortement non linéaire. Les chapitres suivants présentent des extensions qui lèvent ces restrictions : les modèles linéaires généralisés (chapitres 2 et 3), puis les méthodes non-paramétriques et additives (chapitres 6 à 8).

2 Modèles de régression pour données binaires

Les modèles de régression linéaire ne permettent de considérer que les cas où la variable réponse Y_i est normale. Cependant, dans plusieurs situations, on a une variable réponse discrète qui ne peut prendre qu'un nombre fini (ou dénombrable) de valeurs possibles. Dans ce chapitre, on s'intéresse au cas où Y_i suit une loi de Bernoulli ou une loi binomiale.

Exemple 2.1. *Quatre exemples tirés de la librairie `GLMsData` de R :*

1. *quilpie* : observations de 1921 à 1988 de la quantité de pluie mesurée en juillet à Quilpie (Australie). La réponse vaut 1 si la quantité de pluie dépasse 10 mm et 0 sinon ; les variables explicatives concernent la pression atmosphérique (SOI).
2. *nminer* : 31 observations ; la réponse vaut 1 si un mineur bruyant (oiseau) est détecté dans la parcelle et 0 sinon.
3. *deposit* : 18 observations ; la réponse Y_i est le nombre d'insectes tués parmi les m_i insectes exposés, avec deux variables explicatives (type d'insecticide A, B ou C, et dose).
4. *turbines* : 11 observations ; la réponse Y_i est le nombre de machines présentant des fissures parmi m_i machines, en fonction du nombre d'heures de fonctionnement.

2.1 Données et modèle

2.1.1 Données individuelles (Bernoulli)

Dans les deux premiers exemples, la variable réponse $Y_i \in \{0, 1\}$. Les données sont sous la forme $\{(Y_i, X_i), i = 1, \dots, n\}$. On dit que Y_i suit une loi de Bernoulli de paramètre $\pi_i \in [0, 1]$:

$$\begin{aligned} P(Y_i = y_i) &= \pi_i^{y_i} (1 - \pi_i)^{1-y_i}, \quad y_i \in \{0, 1\}, \\ E[Y_i] &= \mu_i = \pi_i, \\ \text{Var}[Y_i] &= \pi_i(1 - \pi_i). \end{aligned}$$

On pose $\eta_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$ (le **prédicteur linéaire**) et on relie π_i à η_i par une **fonction de lien** g supposée connue : $\eta_i = g(\pi_i)$, c'est-à-dire

$$\pi_i = P(Y_i = 1) = g^{-1}(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}).$$

2.1.2 Données groupées (binomiale)

Dans les deux derniers exemples, $Y_i \in \{0, 1, \dots, m_i\}$, où m_i est un entier connu représentant le nombre total d'expériences indépendantes ; Y_i est le nombre de succès. On écrit $Y_i \sim \text{Bin}(m_i, \pi_i)$:

$$\begin{aligned} P(Y_i = y_i) &= \binom{m_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{m_i - y_i}, \quad y_i \in \{0, 1, \dots, m_i\}, \\ E[Y_i] &= \mu_i = m_i \pi_i, \\ \text{Var}[Y_i] &= m_i \pi_i (1 - \pi_i) = \frac{\mu_i(m_i - \mu_i)}{m_i}. \end{aligned}$$

On pose de nouveau $\eta_i = g(\pi_i)$. Si $m_1 = \dots = m_n = 1$, on retrouve la loi de Bernoulli : celle-ci est un cas particulier de la loi binomiale, et les développements qui suivent couvrent les deux situations.

2.1.3 Fonctions de lien

La fonction de lien doit assurer que $\pi_i = g^{-1}(\eta_i) \in [0, 1]$. Trois choix sont courants :

Logit : $g(u) = \text{logit}(u) = \log\left(\frac{u}{1-u}\right)$, d'où $\pi_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$. En R : `link="logit"` dans `glm`.

Probit : $g(u) = \Phi^{-1}(u)$, où Φ est la fonction de répartition de la $\mathcal{N}(0, 1)$, d'où $\pi_i = \Phi(\eta_i)$. En R : `link="probit"`.

C-log-log : $g(u) = \log\{-\log(1-u)\}$, d'où $\pi_i = 1 - e^{-e^{\eta_i}}$. En R : `link="cloglog"`.

Dans les trois cas, $g^{-1}(\cdot)$ est une fonction de répartition. En pratique, les trois liens donnent souvent des résultats très similaires.

Remarque 2.1 (Interprétation du lien logit). Avec le lien logit, les quantités $o_i = \pi_i/(1 - \pi_i)$ sont les *cotes* (odds). Une augmentation unitaire de X_j multiplie la cote par e^{β_j} ; e^{β_j} est le **rapport de cotes** (odds ratio).

2.2 Inférence statistique

2.2.1 Estimation des paramètres β

La fonction de log-vraisemblance est

$$\sum_{i=1}^n \log [P(Y_i = y_i)] = \sum_{i=1}^n \left\{ \log \binom{m_i}{y_i} + y_i \log(\pi_i) + (m_i - y_i) \log(1 - \pi_i) \right\}.$$

Cette fonction dépend de β à travers $\pi_i = g^{-1}(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip})$. En remplaçant π_i par μ_i/m_i , on montre qu'elle s'écrit

$$l(\mu; y) = \sum_{i=1}^n \{y_i \log(\mu_i) + (m_i - y_i) \log(m_i - \mu_i)\} + K,$$

où K est une constante ne dépendant pas de β . L'estimateur du maximum de vraisemblance $\hat{\beta}$ maximise cette fonction ; il n'a pas de forme fermée et est obtenu numériquement (moindres carrés pondérés itératifs).

On calcule ensuite la matrice d'information de Fisher I dont l'élément (j, k) est $-\partial^2 l / \partial \beta_j \partial \beta_k$ évalué en $\hat{\beta}$. La matrice de variance-covariance de $\hat{\beta}$ est estimée par $v(\hat{\beta}) = I^{-1}$ et la distribution asymptotique de $\hat{\beta}$ est approximée par $\mathcal{N}\{\beta, v(\hat{\beta})\}$.

On montre que $v(\hat{\beta}) = (X^\top W X)^{-1}$, où W est une matrice diagonale d'entrées $w_i = \hat{\mu}_i(m_i - \hat{\mu}_i)/m_i$, avec

$$\hat{\mu}_i = m_i \hat{\pi}_i = m_i g^{-1}(\hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip}).$$

2.2.2 Tests d'hypothèses et intervalles de confiance

Les intervalles de confiance et tests concernant les β_j sont obtenus par la méthode de **Wald**. Un intervalle de confiance à $100 \times (1 - \alpha)\%$ pour β_j est

$$\left[\hat{\beta}_j - z_{\alpha/2} \sqrt{v(\hat{\beta}_j)}; \hat{\beta}_j + z_{\alpha/2} \sqrt{v(\hat{\beta}_j)} \right],$$

où z_γ est le quantile de la $\mathcal{N}(0, 1)$ défini par $P(Z > z_\gamma) = \gamma$.

Pour tester $H_0 : \beta_j = 0$ contre $H_1 : \beta_j \neq 0$, on rejette H_0 au seuil α si $|z_{obs}| > z_{\alpha/2}$, avec $z_{obs} = \hat{\beta}_j / \sqrt{v(\hat{\beta}_j)}$. Le seuil observé (p -valeur) est $\alpha^* = 2P(Z > |z_{obs}|)$.

2.2.3 Intervalle de confiance pour une probabilité prédite

Pour $X^* = (1, X_1^*, \dots, X_p^*)^\top$, on estime π^* par $\hat{\pi}^* = g^{-1}(X^{*\top} \hat{\beta})$. Deux approches :

1. **Transformation de l'intervalle sur η^*** : un IC pour $X^{*\top} \beta$ est

$$\left[X^{*\top} \hat{\beta} \pm z_{\alpha/2} \sqrt{v(X^{*\top} \hat{\beta})} \right], \quad v(X^{*\top} \hat{\beta}) = X^{*\top} v(\hat{\beta}) X^*,$$

et on applique g^{-1} aux deux bornes. Cet intervalle respecte toujours $[0, 1]$.

2. **Règle du delta** : $v(\hat{\pi}^*) = h(X^{*\top} \hat{\beta}) v(X^{*\top} \hat{\beta})$ avec $h(u) = \{\partial g^{-1}(u) / \partial u\}^2$, d'où l'IC approximatif $\left[\hat{\pi}^* \pm z_{\alpha/2} \sqrt{v(\hat{\pi}^*)} \right]$.

Les deux méthodes donnent en pratique des résultats très similaires.

Exemple 2.2 (Jeu de données turbines). *On ajuste le modèle avec les trois fonctions de lien :*

```
modele.logit <- glm(cbind(Fissures,Turbines-Fissures)~Hours,
                    data=turbines, family=binomial(link="logit"))
modele.probit <- glm(cbind(Fissures,Turbines-Fissures)~Hours,
                    data=turbines, family=binomial(link="probit"))
modele.cloglog <- glm(cbind(Fissures,Turbines-Fissures)~Hours,
                    data=turbines, family=binomial(link="cloglog"))
```

Les trois liens mènent à des coefficients significatifs et à des courbes prédites $\hat{\pi}^$ très similaires. Les intervalles de confiance se calculent avec `predict(..., se.fit=TRUE)` sur l'échelle du lien (méthode 1) ou avec `type="response"` (méthode 2).*

2.3 Sélection de modèles

2.3.1 Déviance

Considérons le **modèle saturé** avec n paramètres $\{\tilde{\mu}_1, \dots, \tilde{\mu}_n\}$ et sans variables explicatives ; ses estimateurs du maximum de vraisemblance sont $\{y_1, \dots, y_n\}$. La statistique du rapport de vraisemblance entre le modèle saturé et le modèle considéré est

$$D = 2 \{l(y, y) - l(\hat{\mu}, y)\} = 2 \sum_{i=1}^n \left\{ y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) + (m_i - y_i) \log \left(\frac{m_i - y_i}{m_i - \hat{\mu}_i} \right) \right\} = \sum_{i=1}^n d_i.$$

D est la **déviance** du modèle et d_i la déviance individuelle de l'observation i . La déviance joue le même rôle que la somme des carrés des résidus en régression linéaire : elle sert à évaluer l'adéquation du modèle et à comparer des modèles.

2.3.2 Comparaison de modèles emboîtés

Pour comparer deux modèles emboîtés de déviances D_1 (complet) et D_2 (réduit), la statistique de test est $\chi^2 = D_2 - D_1$. Sous H_0 (le modèle réduit est adéquat), χ^2 suit une loi du khi-deux à d degrés de liberté, où d est la différence du nombre de paramètres.

Exemple 2.3 (turbines, termes quadratique et cubique). *On teste $H_0 : \beta_2 = \beta_3 = 0$ (modèle avec Hours seulement contre modèle avec termes en Hours² et Hours³) :*

```
stat.test <- deviance(modele.reduit) - deviance(modele.complet)
p.valeur <- 1 - pchisq(stat.test, df=2) # 0.4767
```

On ne rejette pas H_0 : le modèle réduit est adéquat.

2.3.3 Comparaison de modèles non emboîtés : AIC et BIC

Comme pour les modèles linéaires, on utilise

$$AIC = -2l(\hat{\mu}; y) + 2(p + 1), \quad BIC = -2l(\hat{\mu}; y) + \log(n)(p + 1).$$

Le modèle ayant le plus petit *AIC* (ou *BIC*) est préférable. En R : `extractAIC(modele)` et `extractAIC(modele, k=log(n))`.

2.3.4 Sélection automatique

Les méthodes pas à pas *forward*, *backward* et *stepwise* fonctionnent exactement comme pour les modèles linéaires (fonction `step` avec l'argument `direction`). Sur le jeu de données `deposit`, les trois procédures retiennent le modèle incluant le type d'insecticide, la dose et le terme quadratique de la dose.

2.4 Validation et diagnostic de modèles

2.4.1 Résidus

On distingue deux types de résidus :

— **Résidus déviance** : $r_{D,i} = \text{signe}(y_i - \hat{\mu}_i)\sqrt{d_i}$, avec

$$d_i = 2 \left\{ y_i \log\left(\frac{y_i}{\hat{\mu}_i}\right) + (m_i - y_i) \log\left(\frac{m_i - y_i}{m_i - \hat{\mu}_i}\right) \right\}.$$

— **Résidus de Pearson** :

$$r_{P,i} = \frac{y_i - m_i \hat{\pi}_i}{\sqrt{m_i \hat{\pi}_i (1 - \hat{\pi}_i)}} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\mu}_i (m_i - \hat{\mu}_i) / m_i}}.$$

2.4.2 Tests d'adéquation globale

Deux statistiques permettent de tester l'adéquation globale : la déviance $D = \sum_i r_{D,i}^2$ et la statistique du khi-deux de Pearson

$$\chi_P^2 = \sum_{i=1}^n r_{P,i}^2 = \sum_{i=1}^n \frac{m_i (y_i - \hat{\mu}_i)^2}{\hat{\mu}_i (m_i - \hat{\mu}_i)}.$$

Lorsque tous les $m_i \rightarrow \infty$, D et χ_P^2 convergent en loi vers une $\chi_{n-(p+1)}^2$ si le modèle est bien spécifié.

Remarque 2.2. Ces tests ne sont valides que pour des **données groupées** avec des m_i élevés, car ils reposent sur un résultat asymptotique en m_i . Ils sont inutilisables pour des données individuelles (Bernoulli).

2.4.3 Graphiques et extra-variabilité

Les graphiques des résidus en fonction des numéros d'observations ne doivent montrer aucune tendance. Si plusieurs résidus dépassent 3 en valeur absolue, cela peut suggérer une **extra-variabilité** (*overdispersion*) : $E[Y_i] = m_i \pi_i$ mais $\text{Var}[Y_i] > m_i \pi_i (1 - \pi_i)$. On pose alors $\text{Var}[Y_i] = \phi m_i \pi_i (1 - \pi_i)$ et on estime ϕ par $\chi_P^2 / (n - (p + 1))$. En cas d'extra-variabilité, on spécifie `family=quasibinomial()` au lieu de `family=binomial()` dans `glm`.

Pour vérifier la linéarité du prédicteur, on trace le nuage de points $\{(\hat{\pi}_i, \tilde{\pi}_i)\}$, où $\hat{\pi}_i = g^{-1}(\hat{\eta}_i)$ et $\tilde{\pi}_i = y_i / m_i$: si le modèle est bien spécifié, les points doivent être autour de la droite $y = x$.

2.4.4 Observations aberrantes et valeurs influentes

Le principe est identique à la régression linéaire. Les définitions des leviers, résidus standardisés et studentisés diffèrent, mais ces quantités ont la même interprétation. Il en va de même pour la distance de Cook, les DFBETAS et les DFFITS.

2.5 Spécificité, sensibilité et courbe ROC

Pour des données individuelles, l'adéquation est difficile à évaluer, mais on peut mesurer la **capacité prédictive** du modèle. On ajuste le modèle et on calcule les probabilités prédites $\hat{\pi}_i = g^{-1}(\hat{\eta}_i)$.

Fixons un seuil $u \in [0, 1]$ (souvent $u = 1/2$). On classe $\hat{y}_i = 1$ si $\hat{\pi}_i > u$ et $\hat{y}_i = 0$ sinon. On mesure la capacité prédictive par :

Spécificité (taux de vrais négatifs) : $Spec = P(\hat{y} = 0 \mid y = 0)$,

Sensibilité (taux de vrais positifs) : $Sens = P(\hat{y} = 1 \mid y = 1)$.

Pour un u fixé, on les estime par

$$\widehat{Spec}(u) = \frac{\sum_{i=1}^n \mathbf{1}_{\{(\hat{\pi}_i < u) \& (y_i=0)\}}}{\sum_{i=1}^n \mathbf{1}_{\{y_i=0\}}}, \quad \widehat{Sens}(u) = \frac{\sum_{i=1}^n \mathbf{1}_{\{(\hat{\pi}_i > u) \& (y_i=1)\}}}{\sum_{i=1}^n \mathbf{1}_{\{y_i=1\}}}.$$

En faisant varier u sur une grille $\{u_1 = 0, u_2, \dots, u_B = 1\}$ et en traçant les points $\{(1 - \widehat{Spec}(u_b), \widehat{Sens}(u_b))\}$, on obtient la **courbe ROC**. L'**aire sous la courbe** (AUC) quantifie la capacité prédictive :

$$AUC \in \begin{cases} [0.9, 1] & \text{modèle excellent,} \\ [0.8, 0.9] & \text{modèle bon,} \\ [0.7, 0.8] & \text{modèle moyen,} \\ [0.6, 0.7] & \text{modèle mauvais,} \\ [0.5, 0.6] & \text{modèle très faible.} \end{cases}$$

Exemple 2.4 (quilpie). Avec la variable explicative SOI et le lien logit :

```
modele <- glm(y ~ SOI, family=binomial, data=quilpie)
library(clinfun)
courbe.roc <- roc.curve(marker=as.vector(fitted(modele)),
                        status=quilpie$y, method=c("empirical"))
# AUC = 0.784, s.e. = 0.057
```

L'aire sous la courbe est de 0.78 : le modèle est bon.

3 Modèles linéaires généralisés

La régression linéaire et la régression logistique partagent plusieurs concepts : inférence sur les coefficients β , sélection de modèles, diagnostics. Ce chapitre en donne une présentation unifiée : on suppose que la distribution de la variable réponse appartient à la **famille exponentielle**, qui inclut notamment les lois normale, de Bernoulli, binomiale, de Poisson et gamma.

3.1 Famille exponentielle

3.1.1 Définition

Définition 3.1. La distribution de la variable aléatoire Y appartient à la famille exponentielle si sa fonction de probabilité (densité si Y est continue, fonction de masse si Y est discrète) s'écrit

$$f_Y(y) = a(y, \phi) \exp \left\{ \frac{y\theta - b(\theta)}{\phi} \right\},$$

où θ est le **paramètre canonique** et ϕ le **paramètre de dispersion**.

Propriété 3.1. Si Y appartient à la famille exponentielle, alors

$$E[Y] = \mu = b'(\theta) \quad \text{et} \quad \text{Var}[Y] = \phi b''(\theta) = \phi V(\mu),$$

où $V(u) = b''[(b')^{-1}(u)]$ est la **fonction de variance**.

Le paramètre canonique est donc directement lié à l'espérance de Y , et le paramètre de dispersion module la variance. Pour certaines distributions (Bernoulli, binomiale, Poisson), ϕ est fixé à 1.

3.1.2 Exemples

— **Loi normale** $Y \sim \mathcal{N}(\mu, \sigma^2)$:

$$f_Y(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ \frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} \right\},$$

d'où $\theta = \mu$, $\phi = \sigma^2$, $b(\theta) = \theta^2/2$, $a(y, \phi) = (2\pi\sigma^2)^{-1/2} e^{-y^2/(2\sigma^2)}$. On vérifie $E[Y] = \theta = \mu$, $\text{Var}[Y] = \sigma^2$ et $V(\mu) = 1$.

— **Loi binomiale** $Y \sim \text{Bin}(m, \pi)$:

$$P(Y = y) = \binom{m}{y} \exp \left\{ y \log \left(\frac{\pi}{1 - \pi} \right) + m \log(1 - \pi) \right\},$$

d'où $\theta = \log\{\pi/(1 - \pi)\}$ (donc $\pi = e^\theta/(1 + e^\theta)$), $\phi = 1$, $a(y, \phi) = \binom{m}{y}$ et $b(\theta) = m \log(1 + e^\theta)$. On vérifie $E[Y] = m\pi$, $\text{Var}[Y] = m\pi(1 - \pi)$ et $V(\mu) = \mu(m - \mu)/m$.

— **Loi de Poisson** $Y \sim \mathcal{P}(\lambda)$:

$$P(Y = y) = \frac{1}{y!} \exp \{ y \log(\lambda) - \lambda \},$$

d'où $\theta = \log(\lambda)$, $\phi = 1$, $a(y, \phi) = 1/y!$ et $b(\theta) = e^\theta$. On vérifie $E[Y] = \text{Var}[Y] = \lambda$ et $V(\mu) = \mu$.

— **Loi gamma** $Y \sim \text{Gamma}(\alpha, \beta)$, reparamétrisée avec $\mu = \alpha\beta$ et $\phi = 1/\alpha$: on obtient $\theta = -1/\mu$, $b(\theta) = -\log(-\theta)$, d'où $E[Y] = -1/\theta = \mu$, $\text{Var}[Y] = \phi\mu^2$ et $V(\mu) = \mu^2$.

Le tableau suivant résume ces résultats :

Distribution	θ	ϕ	$b(\theta)$	$V(\mu)$
$\mathcal{N}(\mu, \sigma^2)$	μ	σ^2	$\theta^2/2$	1
$\text{Bin}(m, \pi)$	$\log\{\pi/(1-\pi)\}$	1	$m \log(1+e^\theta)$	$\mu(m-\mu)/m$
$\mathcal{P}(\lambda)$	$\log(\lambda)$	1	e^θ	μ
$\text{Gamma}(\mu, \phi)$	$-1/\mu$	ϕ	$-\log(-\theta)$	μ^2

3.1.3 Déviance

Posons $t(y, \mu) = y\theta - b(\theta)$ et $d(y, \mu) = 2\{t(y, y) - t(y, \mu)\}$. On a

$$\frac{\partial d(y, \mu)}{\partial \theta} = -\{y - b'(\theta)\} \quad \text{et} \quad \frac{\partial^2 d(y, \mu)}{\partial \theta^2} = b''(\theta) = V(\mu) > 0.$$

La dérivée s'annule lorsque $\mu = y$: la quantité $d(y, \mu)$ est donc toujours positive et ne s'annule que si $\mu = y$. Pour la loi normale, $d(y, \mu) = (y - \mu)^2$: la déviance généralise la somme des carrés des résidus.

On montre que $d(Y, \mu)/\phi$ suit approximativement une χ_1^2 . Pour des variables indépendantes $\{Y_1, \dots, Y_n\}$ de paramètres (μ_i, ϕ) (dispersion commune), la **déviance** et la **déviance standardisée** sont

$$D(y, \mu) = \sum_{i=1}^n d(y_i, \mu_i) \quad \text{et} \quad D^*(y, \mu) = \frac{D(y, \mu)}{\phi} \stackrel{\text{approx.}}{\sim} \chi_n^2.$$

3.2 Définition d'un MLG

Un modèle linéaire généralisé est composé de **trois composantes** :

1. **Composante aléatoire** : Y_i suit une distribution de la famille exponentielle de paramètres (θ_i, ϕ) ; chaque observation possède son propre paramètre canonique θ_i , mais le paramètre de dispersion ϕ est commun. Ainsi $E[Y_i] = \mu_i = b'(\theta_i)$ et $\text{Var}[Y_i] = \phi V(\mu_i)$.
2. **Composante systématique** : $\eta_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$ (prédicteur linéaire).
3. **Fonction de lien** : $g(\mu_i) = \eta_i$, avec g monotone et dérivable. La fonction de lien est dite **canonique** si $g[b'(u)] = u$ pour tout u , c'est-à-dire si elle assure $\eta_i = \theta_i$.

Les paramètres du modèle sont β et ϕ . Cas particuliers : régression linéaire (normale, lien identité), régression logistique (binomiale, lien logit), régression Poisson (Poisson, lien log).

3.3 Estimation des paramètres

La log-vraisemblance des données $\Delta = \{(Y_i, X_i)\}$ s'écrit

$$l(\beta, \phi \mid \Delta) = \sum_{i=1}^n \log[a(y_i, \phi)] + \frac{1}{\phi} \sum_{i=1}^n [y_i \theta_i - b(\theta_i)] = l_1(\phi) + \frac{1}{\phi} l_2(\beta).$$

L'estimateur du maximum de vraisemblance $\hat{\beta}$ maximise $l_2(\beta)$ (il ne dépend pas de ϕ). Sa distribution asymptotique est

$$\hat{\beta} \sim \mathcal{N}\left\{\beta, \phi (X^\top W X)^{-1}\right\},$$

où $W = \text{diag}\{W_1, \dots, W_n\}$ avec

$$W_i = \frac{1}{V(\hat{\mu}_i) [g'(\hat{\mu}_i)]^2},$$

$$\hat{\mu}_i = g^{-1}(\hat{\eta}_i) \text{ et } \hat{\eta}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip}.$$

3.3.1 Estimation de ϕ

Si ϕ est fixé (logistique, Poisson), la procédure s'arrête ici. Sinon (normale, gamma), on doit estimer ϕ . L'EMV de ϕ est biaisé en petits échantillons; on lui préfère des estimateurs par la méthode des moments. On calcule

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \quad \text{et} \quad D(y, \hat{\mu}),$$

qui, divisées par ϕ , suivent approximativement une $\chi^2_{n-(p+1)}$. On en déduit les estimateurs de **Pearson** et de **déviance** :

$$\tilde{\phi}_P = \frac{X^2}{n - (p + 1)}, \quad \tilde{\phi}_D = \frac{D(y, \hat{\mu})}{n - (p + 1)}.$$

L'estimateur de Pearson possède un biais négligeable et est robuste à une mauvaise spécification de la distribution; c'est l'estimateur par défaut de la fonction `glm` de R. L'estimateur déviance a une faible variance, mais peut être sensible lorsque des valeurs de y sont proches des limites de leur support.

3.4 Inférence statistique

3.4.1 Cas ϕ fixé

Un intervalle de confiance à $(1 - \alpha)100\%$ pour β_j est

$$\left[\hat{\beta}_j - z_{\alpha/2} \sqrt{\phi v_j}; \hat{\beta}_j + z_{\alpha/2} \sqrt{\phi v_j} \right],$$

où v_j est le $(j + 1)^{\text{ème}}$ élément diagonal de $(X^\top W X)^{-1}$.

Pour une observation future X^* , avec $\eta^* = X^{*\top} \beta$ et $\mu^* = g^{-1}(\eta^*)$, on a $\text{Var}[\hat{\eta}^*] = \phi X^{*\top} (X^\top W X)^{-1} X^*$, d'où l'IC pour η^* :

$$\left[X^{*\top} \hat{\beta} \pm z_{\alpha/2} \sqrt{\phi X^{*\top} (X^\top W X)^{-1} X^*} \right],$$

et l'IC pour μ^* obtenu en appliquant g^{-1} aux deux bornes.

Pour comparer deux modèles emboîtés A (réduit) et B (complet), la statistique

$$X_{obs} = \frac{D_A(y, \hat{\mu}) - D_B(y, \hat{\mu})}{\phi}$$

suit une χ^2_d sous l'hypothèse que le modèle réduit est vrai (d = différence du nombre de paramètres). On rejette au seuil α si $X_{obs} > \chi^2_{d, \alpha}$.

3.4.2 Cas ϕ inconnu

On remplace ϕ par $\tilde{\phi}_P$ et les quantiles de la $\mathcal{N}(0, 1)$ par ceux de la loi de Student à $n - (p + 1)$ degrés de liberté :

$$\left[\hat{\beta}_j - t_{\alpha/2, n-(p+1)} \sqrt{\tilde{\phi}_P v_j}; \hat{\beta}_j + t_{\alpha/2, n-(p+1)} \sqrt{\tilde{\phi}_P v_j} \right].$$

Pour la comparaison de modèles emboîtés, la statistique devient

$$X_{obs} = \frac{\{D_A(y, \hat{\mu}) - D_B(y, \hat{\mu})\}/d}{\tilde{\phi}_P} \sim F_{d, n-(p+1)} \quad \text{sous } H_0.$$

3.5 Sélection et validation de modèles

Les procédures pas à pas *backward*, *forward* et *stepwise* restent valides pour tout MLG, sur la base de

$$AIC = -2l(\hat{\beta}, \tilde{\phi}_P \mid \Delta) + 2(p+1), \quad BIC = -2l(\hat{\beta}, \tilde{\phi}_P \mid \Delta) + \log(n)(p+1).$$

De même, les outils de validation (résidus, DFBETAS, DFFITS, distance de Cook) vus pour les régressions linéaire et logistique restent valides pour l'ensemble des MLG.

3.6 Exemple détaillé : la régression Poisson

La variable réponse $Y_i \in \mathbb{N}$ dénote un dénombrement (nombre de nouveaux cas d'une maladie, nombre d'absences, etc.). La régression Poisson suppose $Y_i \sim \mathcal{P}(\mu_i)$:

$$P(Y_i = y_i) = e^{-\mu_i} \frac{\mu_i^{y_i}}{y_i!}, \quad E[Y_i] = Var[Y_i] = \mu_i.$$

Avec la fonction de lien canonique $g(\mu_i) = \log(\mu_i)$, on a

$$\mu_i = e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}} = e^{\beta_0} \times \left\{ e^{\beta_1} \right\}^{X_{i1}} \times \dots \times \left\{ e^{\beta_p} \right\}^{X_{ip}}.$$

Remarque 3.1 (Interprétation). Si X_{ij} augmente de 1, μ_i est **multiplié** par e^{β_j} . Si $\beta_j > 0$, alors $e^{\beta_j} > 1$ et μ_i croît.

La log-vraisemblance est

$$l(\beta) = \sum_{i=1}^n \left\{ y_i(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}) - e^{\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}} \right\} + K,$$

et la distribution asymptotique de $\hat{\beta}$ est $\mathcal{N}\{\beta, (X^\top W X)^{-1}\}$, où $W = \text{diag}(w_i)$ avec $w_i = \hat{\mu}_i = e^{\hat{\eta}_i}$.

La déviance individuelle est

$$d(y, \mu) = 2 \left\{ y \log\left(\frac{y}{\mu}\right) - (y - \mu) \right\}$$

et l'adéquation se vérifie avec

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \quad \text{et} \quad D = \sum_{i=1}^n d(y_i, \hat{\mu}_i),$$

qui suivent approximativement une $\chi_{n-(p+1)}^2$ si le modèle est bien adapté.

3.6.1 Variables explicatives *offset*

Considérons le jeu de données `danishlc` (bibliothèque `GLMsData`) : nombre de nouveaux cas de cancer du poumon par ville (4 villes) et tranche d'âge (6 tranches), avec la population m_i de chaque strate.

Lorsque la probabilité individuelle est très petite (ici $\hat{\pi}_1 = 11/3059 \approx 3.6 \times 10^{-3}$), une régression logistique n'est pas appropriée. On modélise plutôt l'espérance du **taux** Y_i/m_i :

$$\log\left(\frac{\mu_i}{m_i}\right) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} \iff \log(\mu_i) = \beta_0 + \log(m_i) + \beta_1 X_{i1} + \dots + \beta_p X_{ip}.$$

Le terme $\log(m_i)$ est une variable explicative dont le coefficient est **fixé à 1** : on parle de variable **offset**. Un offset est utile lorsque l'espérance de Y_i est proportionnelle à une autre variable (population, durée d'exposition, effort).

```
modele.additif <- glm(Cases ~ offset(log(Pop)) + City + Age,
                     family=poisson, data=danishlc)
```

Les tests par différence de déviations montrent une différence significative entre les tranches d'âge, mais pas entre les villes.

3.6.2 Variabilité extra-Poissonienne

En pratique, il arrive que $Var[Y_i] > E[Y_i]$ (**surdispersion**). Deux stratégies :

Approche quasi-Poisson. On spécifie seulement les deux premiers moments : $E[Y_i] = \mu_i$ et $Var[Y_i] = \phi \mu_i$. On obtient les mêmes estimateurs $\hat{\beta}$ que la régression Poisson, mais $Var(\hat{\beta})$ est multipliée par $\tilde{\phi}_P = X^2/(n - (p + 1))$. En R : `family=quasipoisson`. Cette approche permet des IC et des tests sur β , mais **n'implique pas de vraisemblance** : l'*AIC* et le *BIC* ne sont pas définis.

Loi binomiale négative. On dit que Y_i suit une loi binomiale négative de paramètres μ_i et α si

$$P(Y_i = y_i) = \frac{\Gamma(y_i + 1/\alpha)}{\Gamma(y_i + 1)\Gamma(1/\alpha)} \left(\frac{1/\alpha}{\mu_i + 1/\alpha} \right)^{1/\alpha} \left(\frac{\mu_i}{\mu_i + 1/\alpha} \right)^{y_i}, \quad y_i = 0, 1, 2, \dots, \alpha > 0.$$

On a $E[Y_i] = \mu_i$ et $Var[Y_i] = \mu_i + \alpha \mu_i^2$; la loi de Poisson est retrouvée quand $\alpha \rightarrow 0$. Avec $\mu_i = e^{x_i^\top \beta}$, les coefficients gardent la même interprétation que la régression Poisson. En R : `glm.nb` de la librairie **MASS**.

Ce modèle permet de tester $H_0 : \alpha = 0$. On calcule $Q_{obs} = D_0 - D_1$ (déviations des modèles Poisson et binomiale négative). Comme on teste α à la frontière de son domaine,

$$Q \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2 \quad \text{sous } H_0,$$

et le seuil observé est $\alpha^* = P(\chi_1^2 > Q_{obs})/2$. Sur les données `danishlc`, $\alpha^* = 0.143$: pas de variabilité extra-Poissonienne détectée.

4 Prédiction, mesures de performance et validation croisée

4.1 Adéquation versus précision de prédiction

Considérons le jeu de données **Auto** (bibliothèque ISLR, $n = 392$) : la réponse est **mpg** (miles par gallon) et la variable explicative est la puissance **horsepower**. On veut choisir parmi les modèles :

$$\text{Modèle 1 : } Y_i = \beta_0 + \beta_1 X_i + \epsilon_i,$$

$$\text{Modèle 2 : } Y_i = \beta_0 + \beta_1 X_i + \beta_2 \log(X_i) + \epsilon_i,$$

$$\text{Modèle 3 : } Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \epsilon_i,$$

$$\text{Modèle 4 : } Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \beta_3 X_i^3 + \epsilon_i.$$

Pour chaque modèle, on peut calculer $SSE = \sum_i (Y_i - \hat{Y}_i)^2$, l'*AIC*, le *BIC*, ou effectuer des tests pour modèles emboîtés : toutes ces procédures cherchent le modèle avec le meilleur **ajustement** aux données.

Supposons plutôt qu'on veuille prédire la réponse Y_0 d'une nouvelle observation X_0 : on cherche alors le modèle qui minimise $E[(Y_0 - \hat{Y}_0)^2]$. Les deux critères (adéquation et précision de la prédiction) sont différents et peuvent être contradictoires : avec n points, un polynôme d'ordre $n - 1$ a une adéquation parfaite ($SSE = 0$) mais sera inutile pour prédire des valeurs futures (**surajustement**).

On distingue donc :

- le **taux d'erreur d'entraînement**, évalué par SSE , qui mesure l'adéquation aux données observées ;
- le **taux d'erreur test**, qui mesure la précision de prédiction pour une observation future.

4.2 Validation croisée

4.2.1 Approche par ensemble de validation

On partage le jeu de données en deux parties : un **jeu d'entraînement** (pour estimer les paramètres) et un **jeu test** (pour estimer le taux d'erreur test). Avec n_1 observations d'entraînement et $n_2 = n - n_1$ observations test :

$$\widehat{Err}_{test} = \frac{1}{n_2} \sum_{i=n_1+1}^n (Y_i - \hat{Y}_i)^2,$$

où $\hat{Y}_i$ est calculé avec les paramètres estimés sur le jeu d'entraînement.

Cette approche a deux défauts : (i) la partition est arbitraire, ce qui introduit de la variabilité ; (ii) on n'estime β qu'avec une fraction des données, ce qui augmente la variance de $\hat{\beta}$. Pour le premier défaut, on peut répéter la partition aléatoirement un grand nombre de fois et moyenner les erreurs obtenues.

4.2.2 Validation croisée avec exclusion d'une observation (LOOCV)

Pour remédier au deuxième défaut, pour $i = 1, \dots, n$, on estime β avec toutes les observations **sauf** la $i^{\text{ème}}$ et on calcule $\hat{y}_{i,(-i)}$. Le critère est

$$VC_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{i,(-i)})^2.$$

Propriété 4.1 (Formule explicite pour la régression linéaire).

$$VC_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2,$$

où h_i est le levier de l'observation i . Il n'est donc pas nécessaire d'ajuster n régressions : un seul ajustement suffit.

4.2.3 Validation croisée à K blocs

Pour d'autres modèles (notamment les MLG), le calcul de $VC_{(n)}$ requiert l'ajustement de n modèles, ce qui peut être coûteux. On considère alors la validation croisée à K blocs (en pratique $K = 5$ ou $K = 10$). On partage le jeu de données en K parties de tailles quasiment égales $A_1, \dots, A_K$. Pour $k = 1, \dots, K$, on estime β à partir de toutes les données sauf A_k et on calcule

$$MSE_k = \frac{1}{n_k} \sum_{i \in A_k} \{y_i - \hat{y}_{i,(-k)}\}^2,$$

où n_k est la taille de A_k . On estime le taux d'erreur test par

$$VC_{(K)} = \frac{1}{K} \sum_{k=1}^K MSE_k.$$

En R, la fonction `cv.glm` de la librairie `boot` calcule $VC_{(n)}$ (par défaut) et $VC_{(K)}$ (argument `K`).

Exemple 4.1 (Auto). *Sur les quatre modèles polynomiaux, la validation croisée ($VC_{(n)}$, $VC_{(5)}$ et $VC_{(10)}$) désigne systématiquement le modèle 3 (quadratique) comme le meilleur pour la prédiction ($VC_{(n)} \approx 19.25$), alors que l'approche par ensemble de validation unique pouvait suggérer le modèle 4.*

4.3 Mesures de performance pour la classification

Pour une réponse binaire, le taux d'erreur test devient le **taux de mauvaise classification**

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{y_i \neq \hat{y}_i\}},$$

avec $\hat{y}_i = \mathbf{1}_{\{\hat{\pi}_i > u\}}$ pour un seuil u (souvent $1/2$). Les notions de **sensibilité**, **spécificité**, **courbe ROC** et **AUC** présentées à la section 2.5 fournissent des mesures de performance qui ne dépendent pas du choix d'un seuil unique : l'AUC est notamment utilisée comme critère de validation croisée en classification (voir chapitre 6).

5 Sélection de variables et régularisation

5.1 Sélection de variables : rappel

Les chapitres précédents ont présenté deux familles d'outils de sélection de variables :

- les **tests pour modèles emboîtés** (test F en régression linéaire, différence de déviances pour les MLG) ;
- les **critères d'information** AIC et BIC , combinés aux procédures pas à pas *forward*, *backward* et *stepwise*, pour les modèles non emboîtés ou lorsque le nombre de sous-modèles (2^p) est trop grand pour une recherche exhaustive.

La régression régularisée, présentée ci-dessous, offre une troisième approche qui effectue simultanément l'estimation et (pour le lasso) la sélection de variables.

5.2 Régression régularisée

Considérons le modèle de régression

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma^2).$$

L'estimateur des moindres carrés $\hat{\beta}$ est sans biais et de variance minimale parmi les estimateurs sans biais. Cependant, rien ne garantit qu'il possède la plus petite **erreur quadratique moyenne** :

$$E \left[(\beta_j - \hat{\beta}_j)^2 \right] = \text{biais}(\hat{\beta}_j)^2 + \text{Var}(\hat{\beta}_j).$$

La régression régularisée impose une pénalité au critère des moindres carrés : on minimise

$$l_\lambda(\beta) = l(\beta) + \lambda g(\beta_1, \dots, \beta_p),$$

où g est une fonction de pénalité connue et $\lambda \geq 0$ est le **coefficient de pénalité**. La pénalité **réduit la variance** des estimateurs au prix d'un **biais** ; avec un choix judicieux de g et de λ , on diminue l'erreur quadratique moyenne et on obtient des prédictions plus précises. C'est le **compromis biais-variance**.

Remarque 5.1. *L'ordonnée à l'origine β_0 n'est pas pénalisée. Par ailleurs, les variables explicatives sont généralement standardisées avant l'ajustement, car la pénalité n'est pas invariante à l'échelle des variables.*

5.2.1 Régression ridge

La régression ridge minimise

$$l_\lambda^{(R)}(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip})\}^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

En écriture matricielle, $l_\lambda^{(R)}(\beta) = (Y - X\beta)^\top (Y - X\beta) + \lambda \beta^\top \tilde{I}_p \beta$, où $\tilde{I}_p$ est diagonale de taille $p+1$ avec un 0 en première position (pas de pénalité sur β_0) et des 1 ailleurs. La solution est explicite :

$$\boxed{\hat{\beta}_\lambda^{(R)} = (X^\top X + \lambda \tilde{I}_p)^{-1} X^\top Y}$$

et on en déduit

$$\begin{aligned} E[\hat{\beta}_\lambda^{(R)}] &= (X^\top X + \lambda \tilde{I}_p)^{-1} X^\top X \beta \neq \beta, \\ Var[\hat{\beta}_\lambda^{(R)}] &= \sigma^2 (X^\top X + \lambda \tilde{I}_p)^{-1} X^\top X (X^\top X + \lambda \tilde{I}_p)^{-1}. \end{aligned}$$

L'estimateur est donc biaisé, sauf si $\lambda = 0$. Lorsque $\lambda = 0$, $\hat{\beta}_\lambda^{(R)} = \hat{\beta}$; lorsque $\lambda \rightarrow \infty$, tous les $\hat{\beta}_{j,\lambda}^{(R)}$ ($j \geq 1$) tendent vers 0 et l'ordonnée à l'origine tend vers $\bar{Y}$. On parle d'un phénomène de **rétrécissement** (*shrinkage*).

Exemple 5.1 (Hitters, librairie ISLR). La réponse est le salaire d'un joueur de baseball (19 variables explicatives). En R, la régression ridge s'ajuste avec `glmnet(x, y, alpha=0)`. Avec $\lambda = e^6$, on observe $\sum_j [\hat{\beta}_{j,\lambda}^{(R)}]^2 = 5721$ contre $\sum_j \hat{\beta}_j^2 = 18469$ pour les moindres carrés : rétrécissement marqué. Sur une partition entraînement/test, le taux d'erreur test passe de 124 716 (moindres carrés) à 91 274 (ridge), soit une diminution de près de 27%.

5.2.2 Régression lasso

La régression lasso minimise

$$l_\lambda^{(L)}(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip})\}^2 + \lambda \sum_{j=1}^p |\beta_j|.$$

Il n'existe pas d'expression explicite pour $\hat{\beta}_\lambda^{(L)}$, mais des algorithmes d'optimisation efficaces existent (en R : `glmnet(x, y, alpha=1)`).

La caractéristique clé du lasso : pour les grandes valeurs de λ , certains coefficients $\hat{\beta}_{j,\lambda}^{(L)}$ deviennent **identiquement égaux à 0**. Le lasso effectue donc une **sélection de variables** automatique, intuitive et naturelle. Comme pour ridge : quand λ croît, le biais croît et la variance diminue.

Exemple 5.2 (Hitters, suite). Avec $\lambda = e^2$, le lasso annule les coefficients de *HmRun*, *Runs*, *RBI*, *CAtBat*, *CHits*, *Assists* et *NewLeagueN* : le modèle retenu ne contient plus que 12 variables.

5.2.3 Sélection du paramètre λ

La méthode la plus intuitive est basée sur le taux d'erreur test, estimé par **validation croisée** pour une grille de valeurs de λ ; on choisit la valeur qui minimise le taux d'erreur test. En R :

```
reg.ridge.select <- cv.glmnet(x, y, alpha=0, lambda=grille.lambda)
reg.ridge.select$lambda.min
```

Sur les données Hitters, on obtient $\lambda = e^{2.2}$ pour ridge et $\lambda = e^3$ pour le lasso.

6 Régression non-paramétrique : k plus proches voisins et estimateur de noyau

Considérons le jeu de données `Auto` : la réponse Y est `mpg` et la variable explicative X est le poids de la voiture (`weight`). Le nuage de points montre que la relation entre X et Y n'est clairement pas linéaire. Ce chapitre présente des approches **non-paramétriques** pour étudier une telle relation, sans postuler de forme fonctionnelle.

6.1 Estimateur des k plus proches voisins

6.1.1 Définition

On suppose que la relation entre X et Y s'écrit

$$Y_i = f(X_i) + \epsilon_i,$$

où f est une fonction inconnue à estimer et ϵ_i vérifie $E[\epsilon_i | X_i] = 0$. On suppose f assez lisse (deux fois dérivable). Sous ces hypothèses,

$$f(x) = E[Y | X = x].$$

On suppose de plus X continue, de sorte que $P(X_i = X_{i'}) = 0$ si $i \neq i'$.

L'estimateur des k plus proches voisins (k NN) est

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i,$$

où $N_k(x)$ est l'ensemble des indices des k plus proches voisins de x : on pose $d_i(x) = (X_i - x)^2$, on ordonne $d_{(1)}(x) < \dots < d_{(n)}(x)$, et $N_k(x)$ contient les indices i tels que $d_i(x) \leq d_{(k)}(x)$.

En R : fonction `knn.reg` de la librairie `FNN`.

6.1.2 Compromis biais-variance et choix de k

Le comportement de $\hat{f}$ dépend fortement de k . Lorsque X_i est proche de x , un développement de Taylor donne

$$E[\hat{f}(x)] \approx f(x) + f'(x) \frac{1}{k} \sum_{i \in N_k(x)} (E[X_i] - x) + \frac{1}{2k} f''(x) \sum_{i \in N_k(x)} (E[X_i] - x)^2.$$

Si les X_i sont symétriquement distribués autour de x , le terme du premier ordre s'annule et

$$\text{biais}[\hat{f}(x)] \approx \frac{1}{2k} f''(x) \sum_{i \in N_k(x)} (E[X_i] - x)^2,$$

quantité qui **croît avec** k (les voisins sont de plus en plus éloignés). D'autre part, si $\text{Var}[\epsilon_i] = \sigma^2$, alors

$$\text{Var}[\hat{f}(x)] = \frac{\sigma^2}{k},$$

qui **décroît avec** k . Il faut donc sélectionner le k qui minimise l'erreur quadratique moyenne

$$\text{biais}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)].$$

En pratique, on sélectionne k par **validation croisée** (le critère `PRESS` de `knn.reg` correspond au LOOCV). Sur les données `Auto`, on obtient $k_{\min} = 45$.

6.1.3 Plusieurs variables explicatives et distance de Mahalanobis

Avec deux variables explicatives, le modèle devient $Y_i = f(X_{i1}, X_{i2}) + \epsilon_i$ et l'estimateur k NN est identique, seule la définition de la distance change. La distance euclidienne

$$d_i(x) = (X_{i1} - x_1)^2 + (X_{i2} - x_2)^2$$

pose problème si les ordres de grandeur des variables diffèrent (p. ex. poids en kg de 1500 à 5000 et cylindrée en pouces³ de 60 à 500) : la variable de plus grande amplitude domine. On pondère alors par l'inverse de la matrice de variance-covariance empirique :

$$d_i(x) = \begin{pmatrix} X_{i1} - x_1 \\ X_{i2} - x_2 \end{pmatrix}^\top V^{-1} \begin{pmatrix} X_{i1} - x_1 \\ X_{i2} - x_2 \end{pmatrix}, \quad V = \begin{pmatrix} s_1^2 & s_{12} \\ s_{12} & s_2^2 \end{pmatrix}.$$

C'est la **distance de Mahalanobis**, qui se généralise directement à p variables continues.

6.2 Estimateur de noyau (Nadaraya-Watson)

6.2.1 Des voisins aux noyaux

L'estimateur k NN peut s'écrire

$$\hat{f}(x) = \frac{\sum_{i=1}^n \mathbf{1}_{\{i \in N_k(x)\}} Y_i}{\sum_{i=1}^n \mathbf{1}_{\{i \in N_k(x)\}}}.$$

On peut définir le voisinage autrement : x et X_i sont voisins si $|X_i - x| \leq h$, où $h > 0$ est un **paramètre de fenêtre** jouant le même rôle que k . On obtient

$$\hat{f}(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)} = \sum_{i=1}^n w_i(x) Y_i,$$

où $K(u) = \mathbf{1}_{\{|u| < 1\}}$ est appelé **noyau** et

$$w_i(x) = \frac{K\left(\frac{X_i - x}{h}\right)}{\sum_{j=1}^n K\left(\frac{X_j - x}{h}\right)}$$

sont des poids positifs de somme 1.

Avec le noyau uniforme, la contribution d'une observation passe brusquement de $1/A$ à 0 lorsque x sort de son voisinage : $\hat{f}$ est **discontinue**. L'idée de l'**estimateur de Nadaraya-Watson** est d'utiliser des poids qui diminuent de façon continue au fur et à mesure que x s'éloigne de X_i : on prend par exemple le **noyau gaussien** $K(u) = e^{-u^2/2}$, qui donne des poids continus et un estimateur $\hat{f}_{NW}$ continu.

En R : `locpoly(x=X, y=Y, degree=0, bandwidth=h)` de la librairie `KernSmooth`.

6.2.2 Choix du paramètre de fenêtre h

Comme pour k NN : un h trop petit produit une courbe très oscillante (variance élevée), un h trop grand écrase la structure (biais élevé). On choisit h par validation croisée. En excluant une observation à la fois, on montre que le critère s'écrit

$$cv.n = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{f}(X_i)}{1 - w_i(X_i)} \right)^2.$$

Sur les données `Auto` avec le noyau gaussien, on obtient $h_{\min} = 110$.

6.3 Régression non-paramétrique et classification

Considérons le jeu de données **Default** (bibliothèque **ISLR**, $n = 10\,000$) : la réponse binaire Y_i vaut 1 si le sujet fait défaut sur sa carte de crédit, la variable explicative est le solde à payer. Le modèle est $g(x) = P(Y = 1 \mid X = x)$, qu'on estime par k NN :

$$\hat{g}(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i \in [0, 1].$$

Pour choisir k , deux critères de validation croisée :

1. **Taux d'erreur test** : on pose $\hat{Y}_i = \mathbf{1}_{\{\hat{f}_{-i}(X_i) > u\}}$ (avec $u = 1/2$ en pratique) et on minimise

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{y_i \neq \hat{y}_i\}}.$$

Sur **Default**, on obtient $k = 190$. Le résultat dépend toutefois du seuil arbitraire u (avec $u = 1/4$: $k = 290$; avec $u = 3/4$: $k = 50$).

2. **Aire sous la courbe ROC** : on choisit le k qui **maximise** l'AUC (bibliothèque **pROC**), critère qui ne dépend d'aucun seuil. Sur **Default**, on obtient $k = 200$, proche du résultat précédent avec $u = 1/2$.

7 Régression non-linéaire : polynômes, fonctions par morceaux et splines

Le chapitre précédent a présenté deux estimateurs locaux de $f(x) = E[Y | X = x]$: l'estimateur k NN et l'estimateur de noyau. Ce chapitre présente des approches alternatives fondées sur des **bases de fonctions** : on écrit

$$Y_i = \beta_0 b_0(X_i) + \beta_1 b_1(X_i) + \cdots + \beta_q b_q(X_i) + \epsilon_i,$$

où les $b_k(\cdot)$ sont des transformations connues de la variable explicative. Le modèle reste **linéaire en β** : toute la machinerie des moindres carrés (estimation, IC, tests) s'applique.

7.1 Régression polynomiale

On approxime $f(x)$ par un polynôme de degré p :

$$f(x) = \beta_0 + \beta_1 x + \cdots + \beta_p x^p,$$

ce qui donne le modèle linéaire $Y_i = \beta_0 + \beta_1 X_i + \cdots + \beta_p X_i^p + \epsilon_i$. On estime β par

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y, \quad X = \begin{pmatrix} 1 & X_1 & \cdots & X_1^p \\ \vdots & \vdots & & \vdots \\ 1 & X_n & \cdots & X_n^p \end{pmatrix}.$$

Le vecteur β contient $p + 1$ éléments : on dit qu'on a $p + 1$ **degrés de liberté**.

Pour sélectionner p , on peut utiliser l'*AIC*, le *BIC*, des tests F , ou — dans l'esprit du chapitre 4 — choisir la valeur qui minimise le taux d'erreur test estimé par validation croisée (la version LOOCV admet une expression explicite).

Une fois p choisi, $\hat{f}(x) = x_*^\top \hat{\beta}$ avec $x_* = (1, x, x^2, \dots, x^p)$, et

$$\text{Var}[\hat{f}(x)] = x_*^\top \text{Var}[\hat{\beta}] x_*,$$

ce qui permet de construire des bandes de confiance autour de $\hat{f}(x)$. En R : `lm(mpg ~ poly(weight, 2, raw=TRUE))`.

7.2 Régression avec des fonctions constantes par morceaux

Posons $[A, B]$ le domaine de X (en pratique $A = \min_i X_i - \varepsilon$ et $B = \max_i X_i + \varepsilon$). Considérons une partition $A = c_0 < c_1 < \cdots < c_K = B$ et définissons, pour $k = 1, \dots, K$,

$$b_k(x) = \begin{cases} 1 & \text{si } x \in [c_{k-1}, c_k], \\ 0 & \text{sinon.} \end{cases}$$

On approxime f par une fonction en escalier : $f(x) = \beta_1 b_1(x) + \cdots + \beta_K b_K(x)$. La variable X a été discrétisée et on retrouve un modèle d'ANOVA à un facteur à K modalités. L'estimateur des moindres carrés est

$$\hat{\beta}_k = \frac{\sum_{i=1}^n b_k(X_i) Y_i}{n_k}, \quad n_k = \sum_{i=1}^n b_k(X_i),$$

c'est-à-dire la moyenne des Y_i dans l'intervalle k , et $\text{Var}[\hat{\beta}_k] = \sigma^2/n_k$. En R : `lm(mpg ~ cut(weight, 4))`.

7.3 Régression avec des splines

7.3.1 Splines de régression

Les **splines** sont des polynômes définis par intervalles, avec des contraintes de régularité aux points de jonction (**nœuds**, *knots*).

Cas simple ($K = 2$ intervalles, degré $p = 3$) : on divise $[A, B]$ en $[c_0, c_1]$ et $[c_1, c_2]$ et on approxime

$$f(x) = \begin{cases} \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 & \text{si } x \in [c_0, c_1], \\ \gamma_0 + \gamma_1 x + \gamma_2 x^2 + \gamma_3 x^3 & \text{si } x \in [c_1, c_2]. \end{cases}$$

On a $4 + 4 = 8$ degrés de liberté ; en imposant que f soit continue et deux fois dérivable en c_1 (3 contraintes), il reste $8 - 3 = 5$ degrés de liberté.

Cas général : avec K intervalles et un degré p , on a $K(p+1)$ paramètres et $p(K-1)$ contraintes (continuité de $f, f', \dots, f^{(p-1)}$ aux $K-1$ nœuds intérieurs), d'où

$$K(p+1) - p(K-1) = K + p \text{ degrés de liberté.}$$

7.3.2 Base des puissances tronquées

Pour p et K donnés, un choix mathématiquement commode de base de $K + p$ splines est

$$b_1(x) = 1, \quad b_2(x) = x, \quad \dots, \quad b_{p+1}(x) = x^p, \quad b_{p+1+k}(x) = h(x, c_k), \quad k = 1, \dots, K-1,$$

où

$$h(x, c) = (x - c)_+^p = \begin{cases} (x - c)^p & \text{si } x \geq c, \\ 0 & \text{sinon.} \end{cases}$$

Il existe une infinité de bases équivalentes : n'importe quelles $K + p$ combinaisons linéaires indépendantes de cette base forment encore une base de splines.

Le modèle s'écrit alors

$$Y_i = \beta_1 b_1(X_i) + \dots + \beta_{K+p} b_{K+p}(X_i) + \epsilon_i,$$

et l'estimateur des moindres carrés est $\hat{\beta} = (X^\top X)^{-1} X^\top Y$ avec $X_{ik} = b_k(X_i)$. On obtient $\hat{f}(x) = \sum_k \hat{\beta}_k b_k(x)$.

7.3.3 B-splines

La base des puissances tronquées est conceptuellement simple mais numériquement instable ($X^\top X$ mal conditionnée). En pratique, les logiciels utilisent la base des **B-splines**, une base équivalente dont les fonctions sont à **support compact** : chaque B-spline de degré p est non nulle sur au plus $p + 1$ intervalles consécutifs.

Les B-splines se définissent par la récurrence de Cox-de Boor. Sur une suite de nœuds augmentée $\{t_j\}$, les B-splines de degré 0 sont

$$B_{j,0}(x) = \mathbf{1}_{\{t_j \leq x < t_{j+1}\}},$$

et pour $d = 1, \dots, p$:

$$B_{j,d}(x) = \frac{x - t_j}{t_{j+d} - t_j} B_{j,d-1}(x) + \frac{t_{j+d+1} - x}{t_{j+d+1} - t_{j+1}} B_{j+1,d-1}(x).$$

Propriétés : chaque $B_{j,p}(x) \geq 0$, $\sum_j B_{j,p}(x) = 1$ pour tout x (partition de l'unité), et la matrice de plan est **creuse par bandes**, ce qui rend les calculs stables et rapides.

En R, la fonction **bs** de la librairie **splines** construit la base de B-splines cubiques :

```
library(splines)
modele.splines <- lm(mpg ~ bs(weight, knots=c(2200,2800,3600)), data=Auto)
```

7.3.4 Splines naturelles

L'estimateur par splines peut être instable aux extrémités du domaine de X (comportement erratique des polynômes au-delà des nœuds extrêmes). Les **splines naturelles** remédient à ce problème : elles sont définies exactement comme les splines, à l'exception qu'on impose que la fonction soit **linéaire** sur les intervalles extrêmes $[c_0, c_1]$ et $[c_{K-1}, c_K]$. Ces contraintes supplémentaires libèrent des degrés de liberté qui peuvent être réinvestis en nœuds intérieurs. En R : `lm(mpg ~ ns(weight, df=4))`.

7.3.5 Splines de lissage (splines pénalisées)

Un autre défaut des splines de régression est qu'elles peuvent avoir tendance à « aller chercher » le maximum de points (surajustement). Pour y remédier, on impose une pénalité sur la rugosité de f : on estime β en minimisant

$$\sum_{i=1}^n \left\{ Y_i - \sum_k \beta_k b_k(X_i) \right\}^2 + \lambda \int_A^B f''(t)^2 dt.$$

Comme $f = \sum_k \beta_k b_k$, la pénalité s'écrit $\lambda \beta^\top M \beta$ avec $M_{lq} = \int_A^B b_l'(t) b_q'(t) dt$, et l'estimateur qui en résulte est explicite :

$$\hat{\beta}_\lambda = (X^\top X + \lambda M)^{-1} X^\top Y$$

Le paramètre λ contrôle la régularité de $\hat{f}$:

- $\lambda = 0$: aucune pénalité, risque de surajustement ;
- $\lambda \rightarrow \infty$: $f'' \equiv 0$, on retrouve la droite des moindres carrés.

On remarque l'analogie parfaite avec la régression ridge du chapitre 5. En pratique, λ est choisi par validation croisée. En R :

```
modele.sp <- smooth.spline(Auto$weight, Auto$mpg, cv=TRUE)
modele.sp$df # degrés de liberté effectifs, ~10.4 sur Auto
```

Remarque 7.1 (Degrés de liberté effectifs). *Pour un estimateur linéaire $\hat{Y} = A_\lambda Y$ avec $A_\lambda = X(X^\top X + \lambda M)^{-1} X^\top$, les **degrés de liberté effectifs** sont $\text{Tr}(A_\lambda)$. Ils décroissent de $K + p$ (pour $\lambda = 0$) vers 2 (pour $\lambda \rightarrow \infty$) et fournissent une échelle interprétable pour calibrer le lissage.*

8 Modèles additifs et modèles additifs généralisés (GAM)

8.1 Motivation

Les méthodes non-paramétriques des chapitres 6 et 7 fonctionnent bien avec une ou deux variables explicatives, mais se heurtent au **fléau de la dimension** lorsque p est grand : les voisinages deviennent vides et le nombre de fonctions de base explose. Les **modèles additifs** offrent un compromis entre la flexibilité des méthodes non-paramétriques et l'interprétabilité des modèles linéaires : on remplace la partie linéaire par une somme de fonctions univariées,

$$Y_i = \alpha + f_1(X_{i1}) + f_2(X_{i2}) + \cdots + f_p(X_{ip}) + \epsilon_i,$$

où chaque f_j est une fonction lisse inconnue.

Laissons les données nous montrer la forme fonctionnelle appropriée.

Chaque f_j est représentée par une base de splines (chapitre 7) : $f_j(x) = \sum_{k=1}^{K_j} b_{jk}(x) \beta_{jk}$. Pour assurer l'**identifiabilité** (une constante peut être transférée entre α et les f_j), on impose la contrainte de centrage

$$\sum_{i=1}^n f_j(X_{ij}) = 0, \quad j = 1, \dots, p.$$

8.2 Estimation par moindres carrés pénalisés

Plutôt que de choisir soigneusement le nombre de nœuds de chaque base, on prend des bases « suffisamment riches » et on pénalise la rugosité de chaque fonction : on minimise

$$\|Y - X\beta\|^2 + \sum_{j=1}^p \lambda_j \beta^\top S_j \beta,$$

où X regroupe toutes les fonctions de base évaluées aux observations, et S_j est la matrice de pénalité de la $j^{\text{ème}}$ fonction ($\beta^\top S_j \beta = \int f_j''(t)^2 dt$). La solution est explicite :

$$\hat{\beta} = \left(X^\top X + \sum_{j=1}^p \lambda_j S_j \right)^{-1} X^\top Y.$$

Chaque paramètre de lissage λ_j contrôle le compromis régularité/fidélité de la fonction $f_j : \lambda_j \rightarrow \infty$ force f_j à être linéaire, $\lambda_j = 0$ laisse f_j libre (risque de surajustement).

8.2.1 Matrice d'influence et degrés de liberté effectifs

Les valeurs ajustées s'écrivent $\hat{Y} = AY$ avec $A = X(X^\top X + \sum_j \lambda_j S_j)^{-1} X^\top$. Les **degrés de liberté effectifs** du modèle sont $\text{Tr}(A)$; on peut les décomposer par fonction f_j , ce qui donne une mesure interprétable de la complexité de chaque effet. La pénalisation induit un biais : $E(\hat{\beta}) \neq \beta$, exactement comme pour ridge.

8.2.2 Choix des paramètres de lissage

Les λ_j sont choisis en minimisant un estimateur de l'erreur de prédiction :

— **Validation croisée ordinaire (OCV)** :

$$OCV(\lambda) = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{f}_\lambda(x_i)}{1 - A_{ii}} \right)^2 ;$$

— **Validation croisée généralisée (GCV)**, qui remplace les A_{ii} par leur moyenne :

$$GCV(\lambda) = \frac{n \sum_i (y_i - \hat{f}_\lambda(x_i))^2}{(n - \text{Tr}(A))^2}.$$

8.2.3 Inférence

De la forme ridge de l'estimateur, on tire $\hat{\beta} \sim \mathcal{N}(E(\hat{\beta}), V_\beta)$ avec $V_\beta = \sigma^2 (X^\top X + \sum_j \lambda_j S_j)^{-1} X^\top X (X^\top X + \sum_j \lambda_j S_j)^{-1}$; l'approche bayésienne (pénalité = loi a priori gaussienne sur β) donne la forme plus simple $V_\beta = \sigma^2 (X^\top X + \sum_j \lambda_j S_j)^{-1}$, dont les intervalles de crédibilité

$$\hat{f}_j(x) \pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}[\hat{f}_j(x)]}$$

possèdent de bonnes propriétés de couverture fréquentistes. Pour tester $H_0 : f_j = 0$, on utilise des statistiques de type Wald basées sur $\hat{\beta}_j^\top V_{\beta_j}^{-1} \hat{\beta}_j$, référées à une χ^2 (ϕ connu) ou une F (ϕ inconnu).

8.3 Modèles additifs généralisés

Comme pour les MLG, on combine la structure additive avec les distributions de la famille exponentielle : Y_i suit une loi de la famille exponentielle avec $E[Y_i] = \mu_i$ et

$$g(\mu_i) = \alpha + f_1(X_{i1}) + \dots + f_p(X_{ip}),$$

où g est une fonction de lien. Cas particuliers : GAM logistique (réponse binaire), GAM Poisson (dénombrements, avec offset au besoin).

L'estimation se fait en minimisant la **déviance pénalisée** :

$$\hat{\beta} = \arg \min_{\beta} \left\{ D(y, \mu) + \sum_{j=1}^p \lambda_j \beta^\top S_j \beta \right\},$$

où $D(y, \mu)$ est la déviance du chapitre 3.

8.3.1 Algorithme d'ajustement (moindres carrés pondérés itératifs pénalisés)

L'ajustement combine l'algorithme des moindres carrés pondérés itératifs des MLG et le lissage pénalisé. À l'itération m :

1. construire la variable dépendante ajustée

$$z_i^{(m)} = \eta_i^{(m)} + (y_i - \mu_i^{(m)}) \left(\frac{\partial \eta_i}{\partial \mu_i} \right)^{(m)} ;$$

2. construire les poids

$$w_i^{(m)} = \frac{1}{V(\mu_i^{(m)})} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)_{(m)}^2 ;$$

3. ajuster un modèle additif pénalisé pondéré à $z^{(m)}$;

4. répéter jusqu'à convergence.

8.3.2 Choix des paramètres de lissage et comparaison de modèles

— Si ϕ est connu (logistique, Poisson) : critère **UBRE** (équivalent au C_p de Mallows)

$$UBRE(\lambda) = \frac{D(y, \hat{\mu})}{n} + \frac{2\phi \text{Tr}(A)}{n} ;$$

— si ϕ est inconnu : **GCV**

$$GCV(\lambda) = \frac{n D(y, \hat{\mu})}{(n - \text{Tr}(A))^2}.$$

Pour comparer des modèles : $AIC = -2l(\hat{\beta}; y) + 2 \text{Tr}(A)$ (les degrés de liberté effectifs remplacent le nombre de paramètres), GCV, ou proportion de déviance expliquée $(D_{null} - D)/D_{null}$. Plus petit AIC ou GCV = meilleur modèle.

8.3.3 En pratique avec R

La librairie `mgcv` ajuste les GAM avec sélection automatique des paramètres de lissage :

```
library(mgcv)
## Modèle additif gaussien
mod1 <- gam(mpg ~ s(weight) + s(horsepower), data=Auto)
## GAM logistique
mod2 <- gam(y ~ s(SOI), family=binomial, data=quilpie)
## GAM Poisson avec offset
mod3 <- gam(Cases ~ s(AgeNum) + City + offset(log(Pop)),
            family=poisson, data=danishlc)
summary(mod1) # tests approximatifs de  $f_j = 0$ , DLE par fonction
plot(mod1)    # courbes estimées avec bandes de confiance
```

La fonction `summary` rapporte, pour chaque fonction lisse, ses degrés de liberté effectifs et un test approximatif de nullité ; `plot` trace chaque $\hat{f}_j$ avec ses bandes de confiance. Une fonction dont les degrés de liberté effectifs sont proches de 1 peut être remplacée par un terme linéaire : le GAM sert ainsi aussi d'outil diagnostique pour guider la spécification d'un MLG paramétrique.

8.4 Synthèse du cours

Le tableau suivant situe les principales méthodes du cours selon la nature de la réponse et la forme de la relation avec les variables explicatives :

	Relation linéaire	Relation flexible
Réponse normale	régression linéaire (+ ridge/lasso)	polynômes, splines, k NN, Nadaraya-Watson, modèle additif
Réponse binaire	régression logistique	GAM logistique, k NN
Dénombrement	régression Poisson	GAM Poisson
Famille exponentielle	MLG	GAM

Dans tous les cas, l'**estimation de l'erreur de prévision** (validation croisée) fournit le fil conducteur pour choisir la complexité du modèle : le degré du polynôme, le nombre de voisins k , la fenêtre h , le coefficient de pénalité λ ou les paramètres de lissage λ_j .