

STT-4300 — Notes de tableau

Plan de cours hebdomadaire (14 semaines $\times$ 3 heures)

Rappels de régression linéaire, MLG, régression non-paramétrique et GAM

Mode d'emploi. Chaque semaine correspond à une séance de 3 heures, découpée en trois blocs d'environ 50 minutes (avec pauses). Les encadrés **Au tableau** contiennent ce qui est effectivement écrit au tableau ; le texte entre les encadrés est le discours d'accompagnement (à dire, pas à écrire). Les encadrés **Moment R** indiquent les démonstrations à faire au projecteur.

Table des matières

1	Semaine 1 — Rappels de régression linéaire (I) : modèle et estimation	2
2	Semaine 2 — Rappels de régression linéaire (II) : inférence, diagnostics et sélection	5
3	Semaine 3 — Données binaires (I) : modèle, fonctions de lien et estimation	8
4	Semaine 4 — Données binaires (II) : inférence, déviance et sélection de modèles	10
5	Semaine 5 — Données binaires (III) : diagnostics, surdispersion et courbe ROC	12
6	Semaine 6 — Modèles linéaires généralisés (I) : la famille exponentielle	14
7	Semaine 7 — Modèles linéaires généralisés (II) : définition, estimation et inférence	16
8	Semaine 8 — MLG (III) : régression Poisson, offset et surdispersion	19
9	Semaine 9 — Prédiction, taux d'erreur et validation croisée	21
10	Semaine 10 — Sélection de variables et régularisation : ridge et lasso	23
11	Semaine 11 — Régression non-paramétrique : k plus proches voisins et noyaux	25
12	Semaine 12 — Régression non-linéaire : polynômes, fonctions par morceaux et splines	27
13	Semaine 13 — Splines naturelles, splines de lissage et modèles additifs	29
14	Semaine 14 — Modèles additifs généralisés (GAM) et synthèse du cours	31

1 Semaine 1 — Rappels de régression linéaire (I) : modèle et estimation

Objectifs : (i) réactiver le modèle linéaire et son écriture matricielle ; (ii) redériver l'estimateur des moindres carrés et ses propriétés ; (iii) introduire la matrice chapeau et l'estimation de σ^2 .

Bloc 1 — Le modèle linéaire et son écriture matricielle

Commencer par un exemple concret (p. ex. `mpg` en fonction de la puissance dans `Auto`) et demander aux étudiants de formuler le modèle.

Au tableau

Données : $\{(Y_i, X_i), i = 1, \dots, n\}$, Y_i réponse continue, $X_i = (X_{i1}, \dots, X_{ip})^\top$.
Modèle de régression linéaire multiple :

$$Y_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} + \epsilon_i, \quad \epsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2).$$

Écriture matricielle : $Y = X\beta + \epsilon$, avec

$$X = \begin{pmatrix} 1 & X_{11} & \dots & X_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{pmatrix} \quad (n \times (p+1)), \quad \beta = (\beta_0, \beta_1, \dots, \beta_p)^\top.$$

Conséquences des hypothèses :

$$E[Y_i] = \mu_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}, \quad \text{Var}[Y_i] = \sigma^2 \text{ (homoscédasticité).}$$

▷ *Question à la classe : quelles sont les deux hypothèses fortes de ce modèle ? (normalité de la réponse ; linéarité de la relation). Annoncer que tout le cours consiste à lever ces deux hypothèses, l'une après l'autre.*

Bloc 2 — Estimation par moindres carrés (dérivation complète)

Au tableau

Critère des moindres carrés :

$$l(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip})\}^2 = (Y - X\beta)^\top (Y - X\beta).$$

Développer :

$$l(\beta) = Y^\top Y - 2\beta^\top X^\top Y + \beta^\top X^\top X \beta.$$

Dériver par rapport à β et annuler (équations normales) :

$$\frac{\partial l}{\partial \beta} = -2X^\top Y + 2X^\top X \beta = 0 \quad \Longleftrightarrow \quad X^\top X \beta = X^\top Y.$$

Si $X^\top X$ inversible :

$$\boxed{\hat{\beta} = (X^\top X)^{-1} X^\top Y}$$

Propriétés (à dériver au tableau) :

$$\begin{aligned} E[\hat{\beta}] &= (X^\top X)^{-1} X^\top E[Y] = (X^\top X)^{-1} X^\top X \beta = \beta \quad (\text{sans biais}) \\ \text{Var}[\hat{\beta}] &= (X^\top X)^{-1} X^\top \sigma^2 I X (X^\top X)^{-1} = \sigma^2 (X^\top X)^{-1}. \end{aligned}$$

Comme Y gaussien et $\hat{\beta}$ linéaire en Y :

$$\hat{\beta} \sim \mathcal{N} \left\{ \beta, \sigma^2 (X^\top X)^{-1} \right\}.$$

Mentionner (sans démontrer) : sous normalité, moindres carrés = maximum de vraisemblance ;
théorème de Gauss–Markov (variance minimale parmi les estimateurs linéaires sans biais).

Bloc 3 — Matrice chapeau, résidus et estimation de σ^2

Au tableau

Valeurs prédites :

$$\hat{Y} = X\hat{\beta} = \underbrace{X(X^\top X)^{-1}X^\top}_{=H} Y = HY.$$

H = **matrice chapeau** (*hat matrix*) ; elle « met le chapeau » sur Y . Propriétés : $H^\top = H$, $H^2 = H$ (projection orthogonale sur l'espace engendré par les colonnes de X).

Les éléments diagonaux $h_i = H_{ii}$ sont les **leviers** (*leverage*) ; on y reviendra pour les diagnostics.

Résidus et estimation de σ^2 :

$$e_i = Y_i - \hat{Y}_i, \quad SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2, \quad \hat{\sigma}^2 = \frac{SSE}{n - (p + 1)}.$$

Le dénominateur $n - (p + 1)$ = nombre d'observations – nombre de paramètres estimés (degrés de liberté).

Moment R (projecteur)

Ajuster une première régression avec `lm`, montrer `summary`, faire le lien entre chaque nombre affiché et les formules du tableau (Estimate, Std. Error, Residual standard error, degrés de liberté).

2 Semaine 2 — Rappels de régression linéaire (II) : inférence, diagnostics et sélection

Objectifs : (i) inférence sur les coefficients (tests t , test F) ; (ii) prédiction avec intervalles ; (iii) diagnostics graphiques et mesures d'influence ; (iv) critères AIC/BIC ; (v) motiver la suite du cours (limites du modèle linéaire).

Bloc 1 — Inférence statistique

Au tableau

IC à $100(1 - \alpha)\%$ pour β_j :

$$\left[\hat{\beta}_j \pm t_{\alpha/2, n-(p+1)} se(\hat{\beta}_j) \right], \quad se(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 [(X^\top X)^{-1}]_{j+1, j+1}}.$$

Test de $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$:

$$t_{obs} = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)} \sim t_{n-(p+1)} \text{ sous } H_0 ; \quad \text{rejet si } |t_{obs}| > t_{\alpha/2, n-(p+1)}.$$

Modèles emboîtés : le modèle réduit ($q+1$ param.) est un cas particulier du modèle complet ($p+1$ param., $q < p$). Test F :

$$F_{obs} = \frac{(SSE_{réduit} - SSE_{complet})/(p - q)}{SSE_{complet}/(n - (p + 1))} \sim F_{p-q, n-(p+1)} \text{ sous } H_0.$$

Coefficient de détermination :

$$R^2 = 1 - \frac{SSE}{SST}, \quad R_{adj}^2 = 1 - \frac{SSE/(n - (p + 1))}{SST/(n - 1)}, \quad SST = \sum_i (Y_i - \bar{Y})^2.$$

▷ *Question à la classe : pourquoi le R^2 augmente-t-il toujours quand on ajoute une variable ? D'où la nécessité du R^2 ajusté et, plus tard, des critères pénalisés.*

Bloc 2 — Prédiction et diagnostics

Au tableau

Nouvelle observation $X^* = (1, X_1^*, \dots, X_p^*)^\top$: $\hat{Y}^* = X^{*\top} \hat{\beta}$, $\text{Var}[\hat{Y}^*] = \sigma^2 X^{*\top} (X^\top X)^{-1} X^*$.
Deux intervalles à ne pas confondre :

- IC pour la **moyenne** $E[Y^*]$: $X^{*\top} \hat{\beta} \pm t_{\alpha/2, n-(p+1)} \hat{\sigma} \sqrt{X^{*\top} (X^\top X)^{-1} X^*}$;
- Intervalle de **prédiction** pour Y^* : $X^{*\top} \hat{\beta} \pm t_{\alpha/2, n-(p+1)} \hat{\sigma} \sqrt{1 + X^{*\top} (X^\top X)^{-1} X^*}$.

Le « 1+ » vient de la variance de l'erreur ϵ^* de la nouvelle observation.

Résidus : bruts $e_i = Y_i - \hat{Y}_i$; standardisés $r_i = e_i / (\hat{\sigma} \sqrt{1 - h_i})$; studentisés (σ estimé sans l'observation i).

Vérifications graphiques (4 graphiques à esquisser au tableau) : linéarité (résidus vs $\hat{Y}$), homoscedasticité, normalité (QQ-plot), indépendance (résidus vs ordre).

Influence : levier h_i (seuil indicatif $2(p+1)/n$) ; distance de Cook

$$D_i = \frac{r_i^2}{p+1} \cdot \frac{h_i}{1-h_i} ;$$

DFBETAS (effet du retrait de i sur chaque $\hat{\beta}_j$), DFFITS (effet sur $\hat{Y}_i$).

Moment R (projecteur)

Montrer `plot(modele)` (les 4 graphiques de diagnostic), `predict(..., interval="confidence")` vs `interval="prediction", cooks.distance`.

Bloc 3 — Sélection de variables et limites du modèle linéaire

Au tableau

Critères d'information (valables pour des modèles emboîtés ou non) :

$$AIC = -2l(\hat{\beta}; y) + 2(p+1), \quad BIC = -2l(\hat{\beta}; y) + \log(n)(p+1).$$

Plus petit = meilleur. Le BIC pénalise plus fortement dès que $n \geq 8$.

Procédures automatiques : *forward* (ajout progressif), *backward* (retrait progressif), *stepwise* (mixte). En R : `step`.

Conclure la semaine en écrivant les **deux limites** du modèle linéaire :

Au tableau

Le modèle linéaire suppose :

1. Y continue et normale → que faire si Y est binaire ? un dénombrement ? (chapitres 2-3) ;
2. $E[Y]$ linéaire en X → que faire si la relation est fortement non linéaire ? (chapitres 6-8).

▷ *Question à la classe : donnez-moi des exemples de réponses non normales dans vos domaines (défaut de paiement, présence d'une maladie, nombre de réclamations...). Noter les exemples au tableau : ils serviront toute la session.*

3 Semaine 3 — Données binaires (I) : modèle, fonctions de lien et estimation

Objectifs : (i) présenter les données Bernoulli et binomiales par des exemples ; (ii) introduire prédicteur linéaire et fonction de lien ; (iii) interpréter les coefficients (rapport de cotes) ; (iv) écrire la log-vraisemblance et expliquer l'estimation numérique.

Bloc 1 — Exemples et structure des données

Présenter les quatre exemples de GLMsData : **quilpie** (pluie > 10 mm : oui/non), **nminer** (oiseau détecté : oui/non), **deposit** (insectes tués parmi m_i exposés), **turbines** (machines fissurées parmi m_i).

Au tableau

Données individuelles (Bernoulli) : $Y_i \in \{0, 1\}$,

$$P(Y_i = y_i) = \pi_i^{y_i} (1 - \pi_i)^{1-y_i}, \quad E[Y_i] = \pi_i, \quad \text{Var}[Y_i] = \pi_i(1 - \pi_i).$$

Données groupées (binomiale) : $Y_i \in \{0, \dots, m_i\}$, m_i connu,

$$P(Y_i = y_i) = \binom{m_i}{y_i} \pi_i^{y_i} (1 - \pi_i)^{m_i - y_i}, \quad E[Y_i] = m_i \pi_i, \quad \text{Var}[Y_i] = m_i \pi_i (1 - \pi_i).$$

Bernoulli = binomiale avec $m_i = 1$: un seul cadre pour les deux.

Remarque clé : la variance dépend de la moyenne ! (contrairement au modèle linéaire).

▷ *Question à la classe : pourquoi ne pas simplement faire une régression linéaire de Y_i sur les X ?*
Laisser chercher : prédictions hors de $[0, 1]$, variance non constante, normalité impossible.

Bloc 2 — Prédicteur linéaire et fonctions de lien

Au tableau

Prédicteur linéaire : $\eta_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$.

Fonction de lien g (connue, monotone) : $\eta_i = g(\pi_i)$, i.e. $\pi_i = g^{-1}(\eta_i) \in [0, 1]$.

Trois choix classiques :

- **logit** : $g(u) = \log\{u/(1-u)\} \Rightarrow \pi_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$;
- **probit** : $g(u) = \Phi^{-1}(u) \Rightarrow \pi_i = \Phi(\eta_i)$;
- **c-log-log** : $g(u) = \log\{-\log(1-u)\} \Rightarrow \pi_i = 1 - e^{-e^{\eta_i}}$.

Dans les trois cas, g^{-1} est une fonction de répartition (tracer les trois courbes en S au tableau : très similaires en pratique).

Interprétation (lien logit) : cote (*odds*) $o_i = \pi_i/(1 - \pi_i) = e^{\eta_i}$. $X_j \rightarrow X_j + 1 \Rightarrow$ cote multipliée par e^{β_j} = **rapport de cotes** (*odds ratio*).

Faire un exemple numérique d'interprétation : si $\hat{\beta}_1 = 0.7$, alors $e^{0.7} \approx 2$: la cote double pour chaque unité de X_1 .

Bloc 3 — Estimation par maximum de vraisemblance

Au tableau

Log-vraisemblance (cas binomial, couvre Bernoulli) :

$$l = \sum_{i=1}^n \left\{ \log \binom{m_i}{y_i} + y_i \log(\pi_i) + (m_i - y_i) \log(1 - \pi_i) \right\},$$

avec $\pi_i = g^{-1}(\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip})$.

En posant $\mu_i = m_i \pi_i$:

$$l(\mu; y) = \sum_{i=1}^n \{y_i \log(\mu_i) + (m_i - y_i) \log(m_i - \mu_i)\} + K.$$

Pas de forme fermée pour $\hat{\beta} \rightarrow$ maximisation numérique (moindres carrés pondérés itératifs ; glm en R).

Matrice d'information de Fisher $I : I_{jk} = -\partial^2 l / \partial \beta_j \partial \beta_k$ évaluée en $\hat{\beta}$. Alors

$$v(\hat{\beta}) = I^{-1} = (X^\top W X)^{-1}, \quad W = \text{diag}\{w_i\}, \quad w_i = \frac{\hat{\mu}_i(m_i - \hat{\mu}_i)}{m_i},$$

et asymptotiquement $\hat{\beta} \approx \mathcal{N}\{\beta, v(\hat{\beta})\}$.

Moment R (projecteur)

Premier glm : `glm(y ~ SOI, family=binomial, data=quilpie)`. Comparer la sortie `summary` à celle de `lm : z value` au lieu de `t value`, déviance au lieu de `SSE` (annoncer que tout cela sera justifié aux semaines 4 et 6). Montrer la syntaxe `cbind(succès, échecs)` pour les données groupées.

4 Semaine 4 — Données binaires (II) : inférence, déviance et sélection de modèles

Objectifs : (i) tests et IC de Wald; (ii) IC pour une probabilité prédite (deux méthodes); (iii) déviance et comparaison de modèles emboîtés; (iv) AIC/BIC et sélection automatique.

Bloc 1 — Inférence de Wald

Au tableau

IC à $100(1 - \alpha)\%$ pour β_j (Wald, asymptotique) :

$$\left[\hat{\beta}_j \pm z_{\alpha/2} \sqrt{v(\hat{\beta}_j)} \right], \quad z_\gamma : P(Z > z_\gamma) = \gamma, \quad Z \sim \mathcal{N}(0, 1).$$

Test de $H_0 : \beta_j = 0$: $z_{obs} = \hat{\beta}_j / \sqrt{v(\hat{\beta}_j)}$; rejet si $|z_{obs}| > z_{\alpha/2}$; p -valeur = $2P(Z > |z_{obs}|)$.

Différence avec la régression linéaire : loi normale (asymptotique) au lieu de Student (exacte).

Bloc 2 — IC pour une probabilité prédite; exemple turbines

Au tableau

Pour X^* donné : $\hat{\pi}^* = g^{-1}(X^{*\top} \hat{\beta})$. Deux méthodes pour un IC :

(1) **Transformation** : IC pour $\eta^* = X^{*\top} \beta$:

$$\left[X^{*\top} \hat{\beta} \pm z_{\alpha/2} \sqrt{X^{*\top} v(\hat{\beta}) X^*} \right],$$

puis appliquer g^{-1} aux deux bornes $\rightarrow$ toujours dans $[0, 1]$.

(2) **Règle du delta** : $v(\hat{\pi}^*) = h(X^{*\top} \hat{\beta}) v(X^{*\top} \hat{\beta})$ avec $h(u) = \{\partial g^{-1}(u) / \partial u\}^2$, puis $\left[\hat{\pi}^* \pm z_{\alpha/2} \sqrt{v(\hat{\pi}^*)} \right]$.

En pratique : résultats très similaires. Préférer (1) près de 0 ou 1.

Moment R (projecteur)

Exemple turbines : ajuster les trois liens (logit, probit, cloglog), superposer les trois courbes $\hat{\pi}^*$ (quasi identiques), calculer les IC avec `predict(..., se.fit=TRUE)` sur l'échelle du lien puis transformer.

Bloc 3 — Déviance et sélection de modèles

Au tableau

Modèle saturé : n paramètres $\tilde{\mu}_i$, $EMV = y_i$ (ajustement parfait). **Déviance** du modèle considéré :

$$D = 2\{l(y, y) - l(\hat{\mu}, y)\} = 2 \sum_{i=1}^n \left\{ y_i \log \frac{y_i}{\hat{\mu}_i} + (m_i - y_i) \log \frac{m_i - y_i}{m_i - \hat{\mu}_i} \right\} = \sum_i d_i.$$

D joue le rôle du SSE : petit D = bon ajustement.

Modèles emboîtés : D_2 (réduit) – D_1 (complet) :

$$\chi^2 = D_2 - D_1 \sim \chi_d^2 \text{ sous } H_0 \quad (d = \text{diff. du nombre de paramètres}).$$

Modèles non emboîtés :

$$AIC = -2l(\hat{\mu}; y) + 2(p + 1), \quad BIC = -2l(\hat{\mu}; y) + \log(n)(p + 1).$$

Sélection automatique *forward/backward/stepwise* : comme en régression linéaire (**step**).

Moment R (projecteur)

Sur turbines : tester $H_0 : \beta_2 = \beta_3 = 0$ (termes en Hours^2 , Hours^3) par différence de déviances :
1 - `pchisq(stat, df=2)` donne 0.4767 $\rightarrow$ modèle réduit adéquat. Sur deposit : `step` retient type d'insecticide + dose + dose².

5 Semaine 5 — Données binaires (III) : diagnostics, surdispersion et courbe ROC

Objectifs : (i) résidus déviance et de Pearson ; (ii) tests d'adéquation globale et leurs limites ; (iii) surdispersion et quasi-binomiale ; (iv) sensibilité, spécificité, courbe ROC et AUC.

Bloc 1 — Résidus et adéquation

Au tableau

Résidus déviance : $r_{D,i} = \text{signe}(y_i - \hat{\mu}_i)\sqrt{d_i}$.

Résidus de Pearson :

$$r_{P,i} = \frac{y_i - \hat{\mu}_i}{\sqrt{\hat{\mu}_i(m_i - \hat{\mu}_i)/m_i}} \quad (\text{observation centrée-réduite}).$$

Adéquation globale : si le modèle est bien spécifié et $m_i \rightarrow \infty$:

$$D = \sum_i r_{D,i}^2 \quad \text{et} \quad \chi_P^2 = \sum_i r_{P,i}^2 \approx \chi_{n-(p+1)}^2.$$

Attention : valide seulement pour données **groupées** avec m_i élevés. Inutilisable pour données Bernoulli !

▷ *Question à la classe : pourquoi le test d'adéquation échoue-t-il avec des données 0/1 ? (l'asymptotique est en m_i , pas en n).*

Bloc 2 — Extra-variabilité (surdispersion)

Au tableau

Diagnostic : plusieurs $|r_i| > 3 \rightarrow$ suspicion de **surdispersion** : $\text{Var}[Y_i] > m_i \pi_i (1 - \pi_i)$.

Modélisation : $\text{Var}[Y_i] = \phi m_i \pi_i (1 - \pi_i)$, avec

$$\hat{\phi} = \frac{\chi_P^2}{n - (p + 1)}.$$

En R : `family=quasibinomial()` — mêmes $\hat{\beta}$, erreurs types multipliées par $\sqrt{\hat{\phi}}$.

Vérification de la linéarité du prédicteur : tracer $\{(\hat{\pi}_i, \tilde{\pi}_i = y_i/m_i)\}$: points autour de $y = x$ si OK.

Observations influentes : leviers, Cook, DFBETAS, DFFITS — mêmes interprétations qu'en régression linéaire.

Bloc 3 — Spécificité, sensibilité et courbe ROC

Motiver : pour des données individuelles, l'adéquation est difficile à évaluer, mais on peut mesurer la **capacité prédictive**.

Au tableau

Seuil $u \in [0, 1]$ (souvent $1/2$) : classer $\hat{y}_i = \mathbf{1}_{\{\hat{\pi}_i > u\}}$.

$$\text{Spécificité} = P(\hat{y} = 0 \mid y = 0), \quad \text{Sensibilité} = P(\hat{y} = 1 \mid y = 1).$$

Estimateurs (à écrire avec les indicatrices) :

$$\widehat{Spec}(u) = \frac{\#\{\hat{\pi}_i < u \text{ et } y_i = 0\}}{\#\{y_i = 0\}}, \quad \widehat{Sens}(u) = \frac{\#\{\hat{\pi}_i > u \text{ et } y_i = 1\}}{\#\{y_i = 1\}}.$$

Courbe ROC : faire varier u de 0 à 1, tracer $\{(1 - \widehat{Spec}(u), \widehat{Sens}(u))\}$. Diagonale = classement au hasard.

AUC (aire sous la courbe) : $[0.9, 1]$ excellent ; $[0.8, 0.9)$ bon ; $[0.7, 0.8)$ moyen ; $[0.6, 0.7)$ mauvais ; $[0.5, 0.6)$ très faible.

Moment R (projecteur)

Sur quipie : `roc.curve` (bibliothèque `clinfun`) avec les probabilités ajustées ; $AUC = 0.784$ (e.t. 0.057) $\rightarrow$ bon modèle. Faire varier le seuil u en direct pour montrer le compromis sensibilité/spécificité.

6 Semaine 6 — Modèles linéaires généralisés (I) : la famille exponentielle

Objectifs : (i) définir la famille exponentielle ; (ii) dériver espérance et variance à partir de $b(\theta)$; (iii) reconnaître normale, binomiale, Poisson et gamma comme cas particuliers ; (iv) définir la déviance dans le cadre général.

Bloc 1 — Définition et propriétés fondamentales

Motiver : régressions linéaire et logistique partagent la même mécanique (coefficients, tests, sélection, diagnostics) → chercher le cadre unifié.

Au tableau

Définition. Y appartient à la **famille exponentielle** si

$$f_Y(y) = a(y, \phi) \exp \left\{ \frac{y\theta - b(\theta)}{\phi} \right\},$$

θ = paramètre **canonique**, ϕ = paramètre de **dispersion**.

Propriété. $E[Y] = \mu = b'(\theta)$ et $Var[Y] = \phi b''(\theta) = \phi V(\mu)$, où $V(u) = b''[(b')^{-1}(u)]$ est la **fonction de variance**.

Esquisse de preuve (à faire) : partir de $\int f_Y(y) dy = 1$, dériver sous l'intégrale par rapport à θ :

$$\int \frac{y - b'(\theta)}{\phi} f_Y(y) dy = 0 \Rightarrow E[Y] = b'(\theta) ;$$

dériver une seconde fois pour la variance.

Bloc 2 — Exemples (à dériver un par un au tableau)

Au tableau

Normale $\mathcal{N}(\mu, \sigma^2)$: réécrire la densité :

$$f_Y(y) = \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-y^2/(2\sigma^2)}}_{a(y, \phi)} \exp \left\{ \frac{y\mu - \mu^2/2}{\sigma^2} \right\} \Rightarrow \theta = \mu, \phi = \sigma^2, b(\theta) = \theta^2/2, V(\mu) = 1.$$

Binomiale $\text{Bin}(m, \pi)$: $\theta = \log \frac{\pi}{1-\pi}$, $\phi = 1$, $b(\theta) = m \log(1 + e^\theta)$, $V(\mu) = \mu(m - \mu)/m$.

Poisson $\mathcal{P}(\lambda)$: $\theta = \log \lambda$, $\phi = 1$, $b(\theta) = e^\theta$, $V(\mu) = \mu$.

Gamma (reparamétrée, $\mu = \alpha\beta$, $\phi = 1/\alpha$) : $\theta = -1/\mu$, $b(\theta) = -\log(-\theta)$, $V(\mu) = \mu^2$.

Distribution	θ	ϕ	$b(\theta)$	$V(\mu)$
$\mathcal{N}(\mu, \sigma^2)$	μ	σ^2	$\theta^2/2$	1
$\text{Bin}(m, \pi)$	$\log\{\pi/(1-\pi)\}$	1	$m \log(1 + e^\theta)$	$\mu(m - \mu)/m$
$\mathcal{P}(\lambda)$	$\log(\lambda)$	1	e^θ	μ
$\text{Gamma}(\mu, \phi)$	$-1/\mu$	ϕ	$-\log(-\theta)$	μ^2

Faire vérifier par les étudiants (exercice de 10 min en classe) : retrouver $E[Y]$ et $Var[Y]$ de la Poisson à partir de $b(\theta) = e^\theta$.

Bloc 3 — Déviance dans le cadre général

Au tableau

Poser $t(y, \mu) = y\theta - b(\theta)$ et $d(y, \mu) = 2\{t(y, y) - t(y, \mu)\}$.

Montrer que $d(y, \mu) \geq 0$ avec égalité ssi $\mu = y$:

$$\frac{\partial d}{\partial \theta} = -\{y - b'(\theta)\}, \quad \frac{\partial^2 d}{\partial \theta^2} = b''(\theta) = V(\mu) > 0.$$

Cas normal : $d(y, \mu) = (y - \mu)^2 \rightarrow$ la déviance **généralise le carré du résidu**.

Pour $Y_1, \dots, Y_n$ indépendantes (dispersion commune ϕ) :

$$D(y, \mu) = \sum_{i=1}^n d(y_i, \mu_i), \quad D^*(y, \mu) = \frac{D(y, \mu)}{\phi} \underset{\text{approx.}}{\sim} \chi_n^2.$$

Terminer en annonçant la définition complète du MLG (semaine 7) : les trois composantes seront la famille exponentielle, le prédicteur linéaire, le lien.

7 Semaine 7 — Modèles linéaires généralisés (II) : définition, estimation et inférence

Objectifs : (i) définir formellement un MLG (trois composantes) ; (ii) estimation de β et de ϕ ; (iii) inférence pour ϕ connu et inconnu ; (iv) sélection et validation dans le cadre général.

Bloc 1 — Les trois composantes d'un MLG

Au tableau

Un **modèle linéaire généralisé** = trois composantes :

1. **Aléatoire** : $Y_i \sim$ famille exponentielle(θ_i, ϕ) (ϕ commun) : $E[Y_i] = \mu_i = b'(\theta_i)$, $Var[Y_i] = \phi V(\mu_i)$;
2. **Systématique** : $\eta_i = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$;
3. **Lien** : $g(\mu_i) = \eta_i$, g monotone dérivable. Lien **canonique** si $\eta_i = \theta_i$, i.e. $g[b'(u)] = u$.

Cas particuliers (tableau à compléter avec la classe) :

Modèle	Distribution	Lien canonique
Régression linéaire	normale	identité
Régression logistique	binomiale	logit
Régression Poisson	Poisson	log

Bloc 2 — Estimation de β et de ϕ

Au tableau

Log-vraisemblance :

$$l(\beta, \phi \mid \Delta) = \underbrace{\sum_i \log a(y_i, \phi)}_{l_1(\phi)} + \frac{1}{\phi} \underbrace{\sum_i \{y_i \theta_i - b(\theta_i)\}}_{l_2(\beta)}.$$

$\hat{\beta}$ maximise $l_2(\beta)$: il **ne dépend pas de** ϕ .

Distribution asymptotique :

$$\hat{\beta} \sim \mathcal{N} \left\{ \beta, \phi (X^\top W X)^{-1} \right\}, \quad W_i = \frac{1}{V(\hat{\mu}_i) [g'(\hat{\mu}_i)]^2}.$$

Estimation de ϕ (si nécessaire : normale, gamma) : par la méthode des moments, à partir de

$$X^2 = \sum_i \frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)} \quad \text{ou} \quad D(y, \hat{\mu}),$$

qui, divisées par ϕ , sont $\approx \chi_{n-(p+1)}^2$:

$$\tilde{\phi}_P = \frac{X^2}{n - (p + 1)} \quad (\text{Pearson, défaut de glm}), \quad \tilde{\phi}_D = \frac{D(y, \hat{\mu})}{n - (p + 1)}.$$

Pearson : biais négligeable, robuste. Déviance : faible variance mais sensible aux y proches des bornes.

Bloc 3 — Inférence, sélection et validation

Au tableau

Cas ϕ connu (logistique, Poisson) : quantiles normaux :

$$\text{IC} : \left[\hat{\beta}_j \pm z_{\alpha/2} \sqrt{\phi v_j} \right], \quad v_j = [(X^\top W X)^{-1}]_{j+1, j+1};$$

modèles emboîtés : $X_{obs} = \{D_A - D_B\} / \phi \sim \chi_d^2$ sous H_0 .

Cas ϕ inconnu : remplacer ϕ par $\tilde{\phi}_P$ et normale par Student :

$$\left[\hat{\beta}_j \pm t_{\alpha/2, n-(p+1)} \sqrt{\tilde{\phi}_P v_j} \right], \quad X_{obs} = \frac{(D_A - D_B)/d}{\tilde{\phi}_P} \sim F_{d, n-(p+1)}.$$

(Parallèle exact avec $z \rightarrow t$ et $\chi^2 \rightarrow F$ en régression linéaire.)

Sélection : AIC/BIC + *forward/backward/stepwise*, comme avant. **Validation** : résidus, leviers, Cook, DFBETAS, DFFITS : tout reste valide.

Moment R (projecteur)

Reprendre les modèles des semaines 1 et 3 et montrer qu'ils sont deux instances de `glm` (`family=gaussian` et `family=binomial`) : mêmes sorties, même mécanique. Ajuster un modèle gamma (`family=Gamma`) pour montrer un cas où ϕ est estimé (ligne `Dispersion parameter` de `summary`).

8 Semaine 8 — MLG (III) : régression Poisson, offset et surdispersion

Objectifs : (i) régression Poisson et interprétation multiplicative ; (ii) variables offset pour modéliser des taux ; (iii) surdispersion : quasi-Poisson et binomiale négative.

Bloc 1 — La régression Poisson

Au tableau

$Y_i \in \mathbb{N}$ (dénombrement) : $Y_i \sim \mathcal{P}(\mu_i)$,

$$P(Y_i = y_i) = e^{-\mu_i} \frac{\mu_i^{y_i}}{y_i!}, \quad E[Y_i] = \text{Var}[Y_i] = \mu_i.$$

Lien canonique $g(\mu) = \log(\mu)$:

$$\mu_i = e^{\beta_0} \times \{e^{\beta_1}\}^{X_{i1}} \times \dots \times \{e^{\beta_p}\}^{X_{ip}}.$$

Interprétation multiplicative : $X_j \rightarrow X_j + 1 \Rightarrow \mu_i$ multiplié par e^{β_j} .

Log-vraisemblance :

$$l(\beta) = \sum_i \{y_i \eta_i - e^{\eta_i}\} + K, \quad \hat{\beta} \approx \mathcal{N}\{\beta, (X^\top W X)^{-1}\}, \quad w_i = \hat{\mu}_i.$$

Déviance individuelle et adéquation :

$$d(y, \mu) = 2 \left\{ y \log \frac{y}{\mu} - (y - \mu) \right\}, \quad X^2 = \sum_i \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \approx \chi_{n-(p+1)}^2.$$

Bloc 2 — Variables offset : modéliser des taux

Présenter `danishlc` : cas de cancer du poumon par ville (4) et tranche d'âge (6), population m_i connue par strate.

▷ *Question à la classe : pourquoi pas une régression logistique ici ? ($\tilde{\pi} \approx 3.6 \times 10^{-3}$: événement rare, et on connaît surtout la population exposée, pas des essais individuels).*

Au tableau

On modélise le **taux** μ_i/m_i :

$$\log\left(\frac{\mu_i}{m_i}\right) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip} \iff \log(\mu_i) = \underbrace{\log(m_i)}_{\text{offset}} + \beta_0 + \dots + \beta_p X_{ip}.$$

$\log(m_i)$: variable explicative à coefficient **fixé à 1 = offset**.

Utile dès que $E[Y_i] \propto \text{exposition}$ (population, durée, effort).

Moment R (projecteur)

`glm(Cases ~ offset(log(Pop)) + City + Age, family=poisson, data=danishlc)`. Tests par différence de déviances : effet d'âge significatif, pas d'effet de ville.

Bloc 3 — Variabilité extra-Poissonienne

Au tableau

Problème fréquent : $Var[Y_i] > E[Y_i]$ (**surdispersion**).

(1) **Quasi-Poisson** : on ne spécifie que les moments : $E[Y_i] = \mu_i$, $Var[Y_i] = \phi\mu_i$. Mêmes β , variance multipliée par $\tilde{\phi}_P$. **Pas de vraisemblance** $\Rightarrow$ pas d'AIC/BIC. En R : `family=quasipoisson`.

(2) **Binomiale négative** : $E[Y_i] = \mu_i$, $Var[Y_i] = \mu_i + \alpha\mu_i^2$, $\alpha > 0$; Poisson retrouvée quand $\alpha \rightarrow 0$. Interprétation des β inchangée. En R : `glm.nb (MASS)`.

Test de $H_0 : \alpha = 0$ (frontière du domaine!) : $Q_{obs} = D_0 - D_1$ et

$$Q \sim \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2 \text{ sous } H_0, \quad p\text{-valeur} = \frac{1}{2}P(\chi_1^2 > Q_{obs}).$$

Moment R (projecteur)

Sur `danishlc` : comparer Poisson et binomiale négative ; p -valeur = 0.143 $\rightarrow$ pas de surdispersion détectée.

Conclure la première moitié du cours : on sait maintenant traiter des réponses normales, binaires, de dénombrement et gamma **avec un prédicteur linéaire**. Reste la deuxième limite : la **linéarité** ; ce sera l'objet des semaines 9 à 14, en commençant par la question « comment comparer des modèles selon leur capacité de **prédiction** ? ».

9 Semaine 9 — Prédiction, taux d'erreur et validation croisée

Objectifs : (i) distinguer adéquation et précision de prédiction ; (ii) approche par ensemble de validation ; (iii) LOOCV et sa formule explicite ; (iv) validation croisée à K blocs ; (v) mesures de performance en classification.

Bloc 1 — Adéquation versus prédiction

Présenter Auto ($n = 392$) : mpg vs horsepower, et les quatre modèles candidats.

Au tableau

Modèles candidats :

$$M1 : Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

$$M2 : Y_i = \beta_0 + \beta_1 X_i + \beta_2 \log(X_i) + \epsilon_i$$

$$M3 : Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \epsilon_i$$

$$M4 : Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \beta_3 X_i^3 + \epsilon_i$$

Deux critères **différents** :

- **Adéquation** aux données observées : SSE , AIC, BIC, tests $\rightarrow$ **taux d'erreur d'entraînement** ;
- **Prédiction** d'une nouvelle observation (X_0, Y_0) : minimiser $E[(Y_0 - \hat{Y}_0)^2]$ $\rightarrow$ **taux d'erreur test**.

Cas extrême : avec n points, un polynôme de degré $n - 1$ donne $SSE = 0$ mais prédit très mal : **surajustement**.

Dessiner au tableau la courbe classique : erreur d'entraînement qui décroît toujours avec la complexité ; erreur test en U.

Bloc 2 — Validation croisée

Au tableau

(1) **Ensemble de validation** : partager les données en entraînement (n_1 obs.) et test ($n_2 = n - n_1$) :

$$\widehat{Err}_{test} = \frac{1}{n_2} \sum_{i=n_1+1}^n (Y_i - \hat{Y}_i)^2 \quad (\hat{Y}_i \text{ calculé avec les paramètres d'entraînement}).$$

Défauts : (i) partition arbitraire (variabilité); (ii) β estimé sur une fraction des données seulement.

(2) **LOOCV** (exclusion d'une observation) : pour $i = 1, \dots, n$, estimer sans l'observation i , prédire $\hat{y}_{i,(-i)}$:

$$VC_{(n)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{i,(-i)})^2.$$

Formule magique (régression linéaire) : un seul ajustement suffit !

$$VC_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2 \quad (h_i = \text{levier}).$$

(3) **Validation croisée à K blocs** ($K = 5$ ou 10) : partition $A_1, \dots, A_K$; pour chaque k , estimer sans A_k :

$$MSE_k = \frac{1}{n_k} \sum_{i \in A_k} \{y_i - \hat{y}_{i,(-k)}\}^2, \quad VC_{(K)} = \frac{1}{K} \sum_{k=1}^K MSE_k.$$

Moment R (projecteur)

`cv.glm` (bibliothèque `boot`) sur les 4 modèles de `Auto` : $VC_{(n)}$, $VC_{(5)}$, $VC_{(10)}$ désignent tous M3 (quadratique), $VC_{(n)} \approx 19.25$, alors qu'une partition unique pouvait suggérer M4.

Bloc 3 — Performance en classification

Au tableau

Réponse binaire : le taux d'erreur test devient le **taux de mauvaise classification**

$$\frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{y_i \neq \hat{y}_i\}}, \quad \hat{y}_i = \mathbf{1}_{\{\hat{\pi}_i > u\}}.$$

Dépend du seuil u ! Alternative sans seuil : l'**AUC** (courbe ROC, semaine 5) comme critère de validation croisée.

Annoncer : la validation croisée sera l'outil universel de tout le reste de la session (choix de λ , de k , de h , des paramètres de lissage).

10 Semaine 10 — Sélection de variables et régularisation : ridge et lasso

Objectifs : (i) motiver la régularisation par le compromis biais-variance ; (ii) régression ridge (solution explicite, rétrécissement) ; (iii) lasso et sélection de variables ; (iv) choix de λ par validation croisée.

Bloc 1 — Le compromis biais-variance

Au tableau

Moindres carrés : $\hat{\beta}$ sans biais, variance minimale **parmi les estimateurs sans biais**. Mais le critère pertinent est l'**erreur quadratique moyenne** :

$$E[(\beta_j - \hat{\beta}_j)^2] = \text{biais}(\hat{\beta}_j)^2 + \text{Var}(\hat{\beta}_j).$$

Un estimateur **biaisé** mais de faible variance peut faire mieux !

Régression régularisée : minimiser

$$l_\lambda(\beta) = l(\beta) + \lambda g(\beta_1, \dots, \beta_p), \quad \lambda \geq 0 \text{ (coefficient de pénalité).}$$

$\lambda \uparrow \Rightarrow$ biais $\uparrow$, variance $\downarrow$.

Conventions : β_0 **jamais pénalisé** ; variables **standardisées** avant l'ajustement (la pénalité n'est pas invariante d'échelle).

Bloc 2 — Régression ridge

Au tableau

Pénalité ℓ_2 : minimiser

$$l_\lambda^{(R)}(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip})\}^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

Forme matricielle : $(Y - X\beta)^\top (Y - X\beta) + \lambda \beta^\top \tilde{I}_p \beta$ ($\tilde{I}_p$: identité avec un 0 en position (1,1)).
Solution explicite (dérivation identique à la semaine 1) :

$$\hat{\beta}_\lambda^{(R)} = (X^\top X + \lambda \tilde{I}_p)^{-1} X^\top Y$$

Propriétés :

$$E[\hat{\beta}_\lambda^{(R)}] = (X^\top X + \lambda \tilde{I}_p)^{-1} X^\top X \beta \neq \beta \quad (\text{biaisé si } \lambda > 0),$$

$$\lambda = 0 : \hat{\beta}^{(R)} = \hat{\beta} ; \quad \lambda \rightarrow \infty : \hat{\beta}_j^{(R)} \rightarrow 0 \quad (j \geq 1) = \text{rétrécissement (shrinkage)}.$$

Moment R (projecteur)

Hitters (ISLR, salaire de joueurs de baseball, 19 variables) : `glmnet(x, y, alpha=0)`. Tracer les trajectoires $\hat{\beta}_{j,\lambda}^{(R)}$ en fonction de λ . Avec $\lambda = e^6$: $\sum_j [\hat{\beta}_j^{(R)}]^2 = 5721$ vs 18469 (MC). Erreur test : 124 716 (MC) $\rightarrow$ 91 274 (ridge) : gain de $\sim 27\%$.

Bloc 3 — Régression lasso et choix de λ

Au tableau

Pénalité ℓ_1 : minimiser

$$l_{\lambda}^{(L)}(\beta) = \sum_{i=1}^n \{Y_i - (\beta_0 + \dots + \beta_p X_{ip})\}^2 + \lambda \sum_{j=1}^p |\beta_j|.$$

Pas de solution explicite (mais algorithmes efficaces : `glmnet`, `alpha=1`).

Propriété clé : pour λ assez grand, certains $\hat{\beta}_{j,\lambda}^{(L)}$ deviennent **exactement 0** $\rightarrow$ **sélection de variables** automatique. (Dessiner l'argument géométrique : contours elliptiques du SSE et boule ℓ_1 en losange vs boule ℓ_2 ronde.)

Choix de λ : validation croisée sur une grille : choisir λ qui minimise l'erreur test estimée. En R : `cv.glmnet(x, y, alpha=...)`, puis `$lambda.min`.

Moment R (projecteur)

Lasso sur Hitters avec $\lambda = e^2$: 7 coefficients annulés (HmRun, Runs, RBI, CAtBat, CHits, Assists, NewLeagueN) : modèle à 12 variables. `cv.glmnet` : $\lambda = e^{2.2}$ (ridge), $\lambda = e^3$ (lasso).

11 Semaine 11 — Régression non-paramétrique : k plus proches voisins et noyaux

Objectifs : (i) estimateur k NN et son compromis biais-variance ; (ii) distance de Mahalanobis pour plusieurs variables ; (iii) estimateur de Nadaraya-Watson ; (iv) classification non-paramétrique.

Bloc 1 — L'estimateur des k plus proches voisins

Montrer le nuage `mpg` vs `weight` (Auto) : relation clairement non linéaire. On abandonne toute forme fonctionnelle.

Au tableau

Modèle non-paramétrique :

$$Y_i = f(X_i) + \epsilon_i, \quad E[\epsilon_i | X_i] = 0, \quad f \text{ inconnue, lisse.}$$

Alors $f(x) = E[Y | X = x]$: la fonction de régression.

Estimateur k NN : moyenne des Y_i des k plus proches voisins :

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i,$$

$N_k(x)$: indices des k plus petites distances $d_i(x) = (X_i - x)^2$.

Compromis biais-variance (développement de Taylor autour de x) :

$$\text{biais}[\hat{f}(x)] \approx \frac{f''(x)}{2k} \sum_{i \in N_k(x)} (E[X_i] - x)^2 \quad (\nearrow \text{ avec } k), \quad \text{Var}[\hat{f}(x)] = \frac{\sigma^2}{k} \quad (\searrow \text{ avec } k).$$

Choix de k : minimiser $\text{biais}^2 + \text{variance} \rightarrow$ en pratique, **validation croisée**.

Dessiner deux estimations au tableau : k petit (courbe erratique), k grand (courbe trop plate).

Moment R (projecteur)

`knn.reg` (bibliothèque `FNN`) sur Auto : montrer $k = 2$, $k = 45$, $k = 300$; le critère PRESS (LOOCV) donne $k_{\min} = 45$.

Bloc 2 — Plusieurs variables et estimateur de noyau

Au tableau

Plusieurs variables : seule la distance change. La distance euclidienne échoue si les échelles diffèrent (poids : 1500–5000 ; cylindrée : 60–500). **Distance de Mahalanobis** :

$$d_i(x) = (X_i - x)^\top V^{-1}(X_i - x), \quad V = \text{matrice de var-cov empirique.}$$

De k NN aux noyaux : réécrire k NN comme moyenne pondérée :

$$\hat{f}(x) = \frac{\sum_i \mathbf{1}_{\{i \in N_k(x)\}} Y_i}{\sum_i \mathbf{1}_{\{i \in N_k(x)\}}}.$$

Autre voisinage : $|X_i - x| \leq h$ (h = **fenêtre**) :

$$\hat{f}(x) = \frac{\sum_i K\left(\frac{X_i - x}{h}\right) Y_i}{\sum_i K\left(\frac{X_i - x}{h}\right)} = \sum_i w_i(x) Y_i, \quad K(u) = \mathbf{1}_{\{|u| < 1\}} \text{ (noyau uniforme).}$$

Problème : poids qui « sautent » $\rightarrow \hat{f}$ discontinue.

Nadaraya-Watson : noyau continu, p. ex. gaussien $K(u) = e^{-u^2/2} \rightarrow$ poids continus, $\hat{f}_{NW}$ continue.

Choix de h : LOOCV, avec formule explicite :

$$cv.n = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{f}(X_i)}{1 - w_i(X_i)} \right)^2.$$

Moment R (projecteur)

locpoly (bibliothèque KernSmooth) sur Auto : noyau gaussien, $h_{\min} = 110$ par validation croisée ; comparer petits et grands h .

Bloc 3 — Classification non-paramétrique

Au tableau

Default (ISLR, $n = 10\,000$) : $Y = 1$ si défaut de carte de crédit, $X =$ solde. Modèle : $g(x) = P(Y = 1 | X = x)$, estimé par

$$\hat{g}(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i \in [0, 1].$$

Choix de k par validation croisée, deux critères :

1. **taux de mauvaise classification** avec seuil u : $k = 190$ ($u = 1/2$) ; mais dépend de u ($u = 1/4$: $k = 290$; $u = 3/4$: $k = 50$) ;
2. **AUC** (à maximiser, aucun seuil) : $k = 200$.

12 Semaine 12 — Régression non-linéaire : polynômes, fonctions par morceaux et splines

Objectifs : (i) cadre des bases de fonctions ; (ii) régression polynomiale et constantes par morceaux ; (iii) splines : comptage des degrés de liberté, base des puissances tronquées, B-splines.

Bloc 1 — Bases de fonctions et régression polynomiale

Au tableau

Idée générale : garder la machinerie **linéaire en** β avec des transformations connues :

$$Y_i = \beta_0 b_0(X_i) + \beta_1 b_1(X_i) + \cdots + \beta_q b_q(X_i) + \epsilon_i.$$

Tout s'applique : $\hat{\beta} = (X^\top X)^{-1} X^\top Y$, IC, tests.

Régression polynomiale : $b_k(x) = x^k$:

$$f(x) = \beta_0 + \beta_1 x + \cdots + \beta_p x^p \quad (p+1 \text{ degrés de liberté}).$$

Choix de p : AIC, BIC, tests F , ou **validation croisée** (sem. 9).

Bandes de confiance : $\hat{f}(x) = x_*^\top \hat{\beta}$, $x_* = (1, x, \dots, x^p)$:

$$\text{Var}[\hat{f}(x)] = x_* \text{Var}[\hat{\beta}] x_*^\top.$$

Constantes par morceaux : partition $A = c_0 < c_1 < \cdots < c_K = B$ du domaine, $b_k(x) = \mathbf{1}_{\{x \in [c_{k-1}, c_k]\}}$:

$$\hat{\beta}_k = \frac{\sum_i b_k(X_i) Y_i}{n_k} = \text{moyenne locale}, \quad \text{Var}[\hat{\beta}_k] = \sigma^2 / n_k.$$

(X discrétisée : ANOVA à un facteur à K modalités.)

Moment R (projecteur)

`lm(mpg ~ poly(weight, 2, raw=TRUE))` et `lm(mpg ~ cut(weight, 4))` sur Auto : superposer polynôme et fonction en escalier sur le nuage de points.

Bloc 2 — Splines : définition et degrés de liberté

Au tableau

Splines : polynômes par morceaux avec contraintes de régularité aux **nœuds** (*knots*).

Cas simple ($K = 2$ intervalles, degré 3) :

$$f(x) = \begin{cases} \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 & x \in [c_0, c_1) \\ \gamma_0 + \gamma_1 x + \gamma_2 x^2 + \gamma_3 x^3 & x \in [c_1, c_2) \end{cases}$$

$4 + 4 = 8$ paramètres ; imposer f, f', f'' continues en c_1 (3 contraintes) $\Rightarrow 8 - 3 = 5$ degrés de liberté.

Cas général : K intervalles, degré p :

$$\underbrace{K(p+1)}_{\text{paramètres}} - \underbrace{p(K-1)}_{\text{contraintes}} = K + p \text{ degrés de liberté.}$$

Base des puissances tronquées ($K + p$ fonctions) :

$$1, x, \dots, x^p, (x - c_k)_+^p \quad (k = 1, \dots, K - 1),$$

où $(x - c)_+^p = (x - c)^p \mathbf{1}_{\{x \geq c\}}$. Vérifier au tableau que $(x - c)_+^p$ est bien $p - 1$ fois continûment dérivable en c .

Bloc 3 — B-splines

Au tableau

Puissances tronquées : simples mais **numériquement instables** ($X^\top X$ mal conditionnée).

Les logiciels utilisent les **B-splines** : base équivalente, à **support compact** (chaque fonction non nulle sur $\leq p + 1$ intervalles).

Récurrance de Cox-de Boor (sur les nœuds augmentés $\{t_j\}$) :

$$B_{j,0}(x) = \mathbf{1}_{\{t_j \leq x < t_{j+1}\}},$$

$$B_{j,d}(x) = \frac{x - t_j}{t_{j+d} - t_j} B_{j,d-1}(x) + \frac{t_{j+d+1} - x}{t_{j+d+1} - t_{j+1}} B_{j+1,d-1}(x).$$

Propriétés : $B_{j,p} \geq 0$; $\sum_j B_{j,p}(x) = 1$ (partition de l'unité) ; matrice de plan creuse par bandes $\Rightarrow$ calculs stables et rapides.

Moment R (projecteur)

bs (bibliothèque `splines`) : `lm(mpg ~ bs(weight, knots=c(2200,2800,3600)), data=Auto)`. Tracer les fonctions de base B-splines elles-mêmes, puis l'ajustement.

13 Semaine 13 — Splines naturelles, splines de lissage et modèles additifs

Objectifs : (i) splines naturelles ; (ii) splines de lissage (pénalisées) et lien avec ridge ; (iii) degrés de liberté effectifs ; (iv) le modèle additif gaussien : définition et estimation pénalisée.

Bloc 1 — Splines naturelles et splines de lissage

Au tableau

Splines naturelles : comportement erratique des splines aux extrémités $\rightarrow$ imposer f **linéaire** sur $[c_0, c_1)$ et $[c_{K-1}, c_K)$. Contraintes supplémentaires = degrés de liberté libérés (réinvestis en nœuds intérieurs). En R : `ns(weight, df=4)`.

Splines de lissage : contre le surajustement, pénaliser la rugosité :

$$\min_{\beta} \sum_{i=1}^n \left\{ Y_i - \sum_k \beta_k b_k(X_i) \right\}^2 + \lambda \int_A^B f''(t)^2 dt.$$

Comme $f = \sum_k \beta_k b_k$: pénalité $= \lambda \beta^\top M \beta$, $M_{lq} = \int b_l''(t) b_q''(t) dt$:

$$\hat{\beta}_\lambda = (X^\top X + \lambda M)^{-1} X^\top Y$$

Analogie parfaite avec ridge ! (sem. 10)

- $\lambda = 0$: pas de pénalité, surajustement possible ;
- $\lambda \rightarrow \infty$: $f'' \equiv 0$: droite des moindres carrés.

Degrés de liberté effectifs : $\hat{Y} = A_\lambda Y$, $A_\lambda = X(X^\top X + \lambda M)^{-1} X^\top$:

$$dle = \text{Tr}(A_\lambda) \in]2, K + p], \quad \text{décroît quand } \lambda \text{ croît.}$$

Moment R (projecteur)

`smooth.spline(Auto$weight, Auto$mpg, cv=TRUE)` : λ choisi par validation croisée, $dle \approx 10.4$.
Faire varier `df` pour montrer l'effet du lissage.

Bloc 2 — Le modèle additif

Au tableau

Problème en dimension p grande : **fléau de la dimension** (voisins vides, explosion du nombre de fonctions de base).

Modèle additif : compromis flexibilité/interprétabilité :

$$Y_i = \alpha + f_1(X_{i1}) + f_2(X_{i2}) + \cdots + f_p(X_{ip}) + \epsilon_i,$$

chaque f_j lisse et inconnue, représentée par une base de splines : $f_j(x) = \sum_{k=1}^{K_j} b_{jk}(x)\beta_{jk}$.

Identifiabilité : une constante peut circuler entre α et les $f_j \rightarrow$ contrainte de centrage

$$\sum_{i=1}^n f_j(X_{ij}) = 0, \quad j = 1, \dots, p.$$

Bloc 3 — Estimation pénalisée et inférence

Au tableau

Bases riches + pénalités : minimiser

$$\|Y - X\beta\|^2 + \sum_{j=1}^p \lambda_j \beta^\top S_j \beta \quad (\beta^\top S_j \beta = \int f_j''(t)^2 dt),$$

$$\hat{\beta} = \left(X^\top X + \sum_j \lambda_j S_j \right)^{-1} X^\top Y.$$

$\lambda_j \rightarrow \infty$: f_j linéaire ; $\lambda_j = 0$: f_j libre.

$\tilde{Y} = AY$: degrés de liberté effectifs $\text{Tr}(A)$, **décomposables par fonction** f_j .

Choix des λ_j :

$$OCV(\lambda) = \frac{1}{n} \sum_i \left(\frac{y_i - \hat{f}_\lambda(x_i)}{1 - A_{ii}} \right)^2, \quad GCV(\lambda) = \frac{n \sum_i (y_i - \hat{f}_\lambda(x_i))^2}{(n - \text{Tr}(A))^2}.$$

Inférence : forme ridge $\Rightarrow \hat{\beta}$ gaussien ; approche bayésienne : $V_\beta = \sigma^2 (X^\top X + \sum_j \lambda_j S_j)^{-1}$, intervalles $\hat{f}_j(x) \pm z_{\alpha/2} \sqrt{\widehat{\text{Var}}[\hat{f}_j(x)]}$ (bonne couverture fréquentiste). Test de $H_0 : f_j = 0$: Wald (χ^2 si ϕ connu, F sinon).

Moment R (projecteur)

Premier modèle additif : `gam(mpg ~ s(weight) + s(horsepower), data=Auto)` (bibliothèque `mgcv`) ; `plot(mod)` pour les courbes $\hat{f}_j$ avec bandes de confiance.

14 Semaine 14 — Modèles additifs généralisés (GAM) et synthèse du cours

Objectifs : (i) définir le GAM (structure additive + famille exponentielle) ; (ii) algorithme d'ajustement ; (iii) UBRE/GCV et comparaison de modèles ; (iv) pratique avec `mgcv` ; (v) synthèse générale du cours.

Bloc 1 — Définition et ajustement des GAM

Au tableau

GAM = MLG (sem. 7) + structure additive (sem. 13) : $Y_i \sim$ famille exponentielle, $E[Y_i] = \mu_i$,

$$g(\mu_i) = \alpha + f_1(X_{i1}) + \cdots + f_p(X_{ip}).$$

Cas particuliers : GAM logistique (binaire), GAM Poisson (dénombrements, offset au besoin).

Estimation : déviance pénalisée :

$$\hat{\beta} = \arg \min_{\beta} \left\{ D(y, \mu) + \sum_{j=1}^p \lambda_j \beta^\top S_j \beta \right\}.$$

Algorithme (moindres carrés pondérés itératifs pénalisés) ; à l'itération m :

1. variable ajustée : $z_i^{(m)} = \eta_i^{(m)} + (y_i - \mu_i^{(m)}) \left(\frac{\partial \eta_i}{\partial \mu_i} \right)^{(m)}$;
2. poids : $w_i^{(m)} = \frac{1}{V(\mu_i^{(m)})} \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2_{(m)}$;
3. ajuster un modèle additif pénalisé pondéré à $z^{(m)}$;
4. répéter jusqu'à convergence.

Bloc 2 — Choix des paramètres de lissage et pratique avec R

Au tableau

ϕ **connu** (logistique, Poisson) : critère **UBRE** :

$$UBRE(\lambda) = \frac{D(y, \hat{\mu})}{n} + \frac{2\phi \text{Tr}(A)}{n} ;$$

ϕ **inconnu** : **GCV** :

$$GCV(\lambda) = \frac{n D(y, \hat{\mu})}{(n - \text{Tr}(A))^2}.$$

Comparaison de modèles : $AIC = -2l(\hat{\beta}; y) + 2 \text{Tr}(A)$ (dle au lieu du nombre de paramètres), GCV, proportion de déviance expliquée $(D_{null} - D)/D_{null}$.

Diagnostic : $dle(f_j) \approx 1 \Rightarrow f_j$ remplaçable par un terme linéaire : le GAM guide la spécification d'un MLG paramétrique.

Moment R (projecteur)

Reprendre les jeux de données de toute la session avec `mgcv` :

- `gam(mpg ~ s(weight) + s(horsepower), data=Auto)` ;
- `gam(y ~ s(SOI), family=binomial, data=quilpie)` ;
- `gam(Cases ~ s(AgeNum) + City + offset(log(Pop)), family=poisson, data=danishlc)`.

`summary` : dle et test de nullité par fonction ; `plot` : courbes avec bandes de confiance.

Bloc 3 — Synthèse du cours

Construire le tableau récapitulatif **avec** les étudiants : donner les lignes/colonnes et leur demander de remplir chaque case.

Au tableau

	Relation linéaire	Relation flexible
Réponse normale	régression linéaire (+ ridge/lasso)	polynômes, splines, k NN, Nadaraya-Watson, modèle additif
Réponse binaire	régression logistique	GAM logistique, k NN
Dénombrement	régression Poisson	GAM Poisson
Famille exponentielle	MLG	GAM

Fil conducteur : l'estimation de l'erreur de prévision (**validation croisée**) pour choisir la complexité : degré p , nombre de voisins k , fenêtre h , pénalités λ , λ_j .

Terminer par une période de questions et de révision en vue de l'examen final.